

Notas de Estudio

Concavidad y Optimización en Economía

Curso de posgrado

Eric Torres

eric.torres@pucp.edu.pe

Notas elaboradas a partir de la siguiente bibliografía:

Aragón, Goberna, López & Rodríguez, *Nonlinear Optimization*

Boyd & Vandenberghe, *Convex Optimization*

Brinkhuis, *Convex Analysis for Optimization*

Li, *Selected Applications of Convex Optimization*

Nocedal & Wright, *Numerical Optimization*

Ruszczynski, *Nonlinear Optimization*

Snyman & Wilke, *Practical Mathematical Optimization*

Wright & Recht, *Optimization for Data Analysis*

2026

Índice general

Cómo usar este cuaderno	x
1. Preliminares matemáticos [P2]	1
1.1. Espacios vectoriales reales [P2]	1
1.1.1. Motivación: cestas de consumo como vectores	1
1.1.2. Subespacios, combinaciones lineales y bases	3
1.2. Producto interno y norma [P1]	4
1.2.1. Otras normas: ℓ_1 y ℓ_∞	6
1.3. Topología de $\mathbb{R}^n$ [P1]	7
1.3.1. Bolas, abiertos y cerrados	7
1.3.2. Sucesiones, convergencia y compacidad	8
1.3.3. Continuidad y el teorema de Weierstrass	9
1.4. Cálculo diferencial en varias variables [P1]	10
1.4.1. Derivadas parciales y gradiente	10
1.4.2. Jacobiana, regla de la cadena y Hessiana	12
1.4.3. Teorema de Taylor: la herramienta de las condiciones de optimalidad	12
1.4.4. Ejemplo resuelto completo: Cobb–Douglas	13
1.5. Formas cuadráticas y definitud [P1]	14
1.5.1. Criterio 1: autovalores	15
1.5.2. Criterio 2: menores principales líderes (Sylvester)	16
1.6. Ejercicios tipo examen [P1]	18
2. Conjuntos convexos y conjuntos afines [P2]	22
2.1. Segmentos y combinaciones convexas [P1]	23
2.1.1. El segmento entre dos puntos	23
2.1.2. Combinaciones convexas: promedios ponderados y loterías	23
2.2. Conjuntos convexos [P1]	24
2.2.1. La definición	24
2.2.2. Ejemplos fundamentales, resueltos paso a paso	25
2.2.3. No-ejemplos	27
2.2.4. Convexidad y combinaciones de muchos puntos	28
2.3. Conjuntos afines [P2]	29
2.3.1. Rectas en lugar de segmentos	29
2.4. Operaciones que preservan convexidad [P1]	31

2.5. Aspectos topológicos [P2]	34
2.5.1. El interior relativo	35
2.6. Convexidad en microeconomía [P1]	37
2.6.1. La caja de Edgeworth como producto de convexos	37
2.6.2. Preferencias convexas y conjuntos de contorno superior	38
2.6.3. El conjunto de asignaciones factibles	38
2.7. Resumen y ejercicios [P1]	39
3. Estructura cónica, cápsula convexa y cápsula afín [P2]	44
3.1. Conos y conos convexos [P2]	45
3.2. Cápsula convexa, afín y cónica [P2]	48
3.3. El teorema de Carathéodory [P2]	52
3.4. Puntos extremos y el teorema de Minkowski [P2]	55
3.5. Poliedros y politopos [P3]	58
3.6. Cono de recesión [P3]	60
3.7. Resumen y ejercicios [P1]	61
4. Hiperplanos y teoremas de separación [P1]	67
4.1. Hiperplanos y semiespacios [P1]	68
4.1.1. Motivación: los conjuntos de nivel de una función lineal	68
4.1.2. Geometría del vector normal	69
4.1.3. Interpretación económica: el precio es la normal	69
4.2. Proyección sobre un convexo cerrado [P1]	71
4.2.1. Motivación: el punto más cercano	71
4.2.2. No expansividad de la proyección	74
4.3. Separación de un punto y un convexo [P1]	75
4.3.1. El vocabulario de la separación	75
4.3.2. Separación fuerte de un punto y un convexo cerrado	76
4.3.3. Consecuencia: los convexos cerrados son intersecciones de semiespacios	77
4.4. Hiperplanos soporte [P1]	78
4.4.1. Motivación y definición	78
4.5. Separación de dos conjuntos convexos [P1]	80
4.5.1. El truco de la diferencia de Minkowski	80
4.5.2. Separación fuerte: compacto y cerrado disjuntos	81
4.5.3. Separación de convexos disjuntos cualesquiera	82
4.6. El lema de Farkas [P1]	84
4.6.1. Motivación: sistemas lineales con signo	84
4.7. Aplicación estrella: el Segundo Teorema del Bienestar [P1]	87
4.7.1. El escenario: una economía de intercambio	87
4.7.2. El teorema y su demostración por separación	88
4.7.3. ¿Qué compra cada hipótesis, y qué falla sin convexidad?	89
4.8. Resumen del capítulo [P1]	91
4.9. Ejercicios [P1]	92

5. Funciones cóncavas y convexas [P1]	105
5.1. Definiciones y caracterización gráfica [P1]	106
5.1.1. La idea: la cuerda y el grafo	106
5.1.2. Definiciones formales	107
5.1.3. Ejemplos verificados desde la definición	107
5.2. Desigualdad de Jensen y aversión al riesgo [P1]	110
5.2.1. Aplicación desarrollada: aversión al riesgo	111
5.3. Epígrafo, hipografo y conjuntos de nivel [P1]	113
5.3.1. Conjuntos de nivel inferior	115
5.4. Funciones extendidas e indicatriz [P2]	116
5.5. Caracterización de primer orden [P1]	117
5.6. Caracterización de segundo orden [P1]	120
5.6.1. Ejemplos resueltos con Hessiana y menores	121
5.7. Operaciones que preservan convexidad [P1]	124
5.7.1. El supremo puntual: la operación estrella	125
5.7.2. Composición monótona-convexa	126
5.7.3. Mínimo parcial	127
5.8. Continuidad y diferenciabilidad [P2]	128
5.9. Función soporte [P1]	129
5.9.1. Ejemplos calculados	131
5.9.2. Aplicación económica: beneficio y gasto como funciones soporte	131
5.10. Resumen del capítulo [P1]	133
5.11. Ejercicios [P1]	134
6. Concavidad generalizada [P1]	147
6.1. La utilidad es ordinal: por qué la concavidad no basta [P1]	148
6.1.1. Preferencias, utilidad y transformaciones monótonas	148
6.1.2. Un ejemplo revelador: $u(x, y) = xy$	149
6.2. Cuasiconcavidad: definiciones y equivalencia [P1]	150
6.2.1. Cuasiconvexidad, cuasilinealidad y versión estricta	152
6.3. Jerarquía y propiedades ordinales [P1]	153
6.3.1. Cóncava implica cuasicóncava (pero no al revés)	153
6.3.2. La propiedad ordinal clave	154
6.3.3. Operaciones que no preservan la cuasiconcavidad	155
6.4. Ejemplos económicos fundamentales [P1]	156
6.4.1. Cobb–Douglas	156
6.4.2. CES, Leontief y utilidad lineal	157
6.4.3. Preferencias convexas y utilidad cuasicóncava	158
6.5. Caracterización diferencial de primer orden [P1]	159
6.6. El Hessiano orlado [P1]	160
6.6.1. Construcción de la matriz	160
6.6.2. Ejemplo completo 2×2 : Cobb–Douglas	162
6.6.3. Ejemplo 3×3	163

6.7. Funciones pseudocóncavas [P2]	165
6.8. Aplicaciones de la concavidad generalizada [P1]	167
6.8.1. El conjunto de soluciones es convexo	167
6.8.2. Unicidad: la demanda es una función	168
6.8.3. El teorema del máximo de Berge	170
6.8.4. Arrow–Enthoven: cuándo KKT basta	173
6.8.5. La condición de cruce único (Spence–Mirrlees)	174
6.8.6. Nota sobre concavificación	176
6.9. Ejercicios [P1]	179
7. Subdiferenciabilidad [P3]	188
7.1. Motivación: cuando la derivada no existe [P3]	188
7.2. Subgradiente y subdiferencial [P3]	189
7.3. Propiedades básicas del subdiferencial [P3]	192
7.4. Derivadas direccionales [P2]	194
7.5. La regla de Fermat generalizada [P3]	196
7.6. Cálculo de subdiferenciales [P3]	198
7.7. Aplicaciones económicas [P3]	200
7.8. Resumen y ejercicios [P3]	202
8. Optimización sin restricciones [P2]	206
8.1. Planteamiento del problema y existencia de soluciones [P2]	207
8.1.1. Mínimos locales y globales	207
8.1.2. Existencia: Weierstrass y coercividad	208
8.2. Condición necesaria de primer orden [P1]	210
8.3. Condiciones de segundo orden [P1]	212
8.3.1. Ejemplos resueltos de clasificación	213
8.4. Minimización de funciones convexas [P1]	215
8.4.1. Ejemplo estrella: mínimos cuadrados ordinarios	217
8.5. Distancia a un conjunto y función proyección [P2]	218
8.5.1. El teorema de la proyección	219
8.5.2. Proyecciones que se pueden calcular a mano	222
8.6. Aplicaciones económicas de la proyección [P3]	223
8.6.1. MCO es una proyección ortogonal	223
8.6.2. Racionamiento: la cesta factible más cercana a la deseada	224
9. Optimización con restricciones [P1]	229
9.1. El problema general y las convenciones de signos [P1]	230
9.1.1. El problema no lineal estándar	230
9.1.2. Restricciones activas e inactivas	230
9.1.3. Convenciones de signos: cómo traducir entre libros	231
9.2. Geometría de la optimalidad: conos tangente y normal [P1]	233
9.2.1. La imagen en dos dimensiones	233

9.2.2.	Direcciones factibles y de descenso	234
9.2.3.	El cono tangente	235
9.2.4.	El cono normal y la condición $-\nabla f(x^*) \in N_X(x^*)$	237
9.3.	El teorema de Lagrange: restricciones de igualdad [P1]	238
9.3.1.	El ejemplo canónico: Cobb–Douglas con presupuesto	239
9.4.	Cualificaciones de restricciones [P1]	241
9.4.1.	Un contraejemplo completo: la cúspide	241
9.4.2.	Las tres cualificaciones que debes conocer	242
9.5.	El teorema de Karush–Kuhn–Tucker [P1]	245
9.5.1.	Demostración vía linealización y el lema de Farkas	246
9.5.2.	Holgura complementaria: la condición del economista	248
9.6.	KKT bajo convexidad: suficiencia [P1]	249
9.6.1.	Más allá de la concavidad: Arrow–Enthoven	250
9.7.	Manual de resolución de problemas KKT [P1]	251
9.7.1.	Ejemplo 1: UMP Cobb–Douglas con no negatividad (solución interior)	252
9.7.2.	Ejemplo 2: solución de esquina con utilidad cuasilineal	253
9.7.3.	Ejemplo 3: minimización de costos de la firma (el dual de la producción)	254
9.7.4.	Ejemplo 4: mini principal–agente con información simétrica	255
9.8.	Interpretación económica de los multiplicadores [P1]	257
9.8.1.	La función de valor y el enunciado formal	257
9.8.2.	Lectura en el consumidor y en la firma	259
9.8.3.	Ejemplo numérico completo: comprobar el precio sombra	260
9.8.4.	Lectura en teoría de contratos: IR e IC	261
9.9.	Condiciones de segundo orden con restricciones [P2]	263
9.9.1.	El cono crítico y los enunciados	263
9.9.2.	El criterio del Hessiano orlado (caso de igualdades)	264
9.9.3.	Ejemplo resuelto 2×2	266
9.10.	Ejercicios [P1]	269
10.	Punto silla y dualidad lagrangiana [P2]	282
10.1.	La función dual de Lagrange [P2]	283
10.1.1.	El problema primal y su lagrangiano	283
10.1.2.	La concavidad del dual: gratis y siempre	284
10.1.3.	Dos ejemplos calculados por completo	285
10.2.	Dualidad débil y brecha de dualidad [P2]	286
10.3.	Interpretación económica del dual [P2]	287
10.3.1.	Multiplicadores como precios de recursos	287
10.3.2.	El caso lineal y la condición de no arbitraje	288
10.4.	Punto silla del lagrangiano [P2]	290
10.4.1.	Definición y primera lectura	290
10.4.2.	El teorema central	290
10.4.3.	Punto silla y KKT	291
10.5.	Dualidad fuerte y condición de Slater [P2]	292

10.5.1. El enunciado	292
10.5.2. La geometría: el conjunto de valores alcanzables	293
10.5.3. Brecha positiva sin convexidad: un contraejemplo calculado	294
10.6. Tres ejemplos resueltos: consumidor, QP y minimax [P2]	295
10.6.1. El dual del problema del consumidor y la dualidad Marshall–Hicks	295
10.6.2. Dual de un QP con restricciones lineales	297
10.6.3. El teorema minimax de von Neumann	297
10.7. Perturbación: la geometría profunda de la dualidad [P2]	299
10.8. Resumen y ejercicios [P2]	300
11. Teoremas de la envolvente [P1]	305
11.1. Funciones de valor [P1]	306
11.1.1. Definición y ejemplos que ya conoces	306
11.1.2. ¿Por qué “envolvente”? La imagen geométrica	307
11.2. Envolvente sin restricciones [P1]	309
11.2.1. Discusión de las hipótesis	310
11.3. Envolvente con restricciones [P1]	311
11.3.1. El multiplicador como precio sombra	313
11.4. Las cuatro joyas de la microeconomía [P1]	315
11.4.1. Joya 1: el lema de Hotelling	315
11.4.2. Joya 2: el lema de Shephard	316
11.4.3. Joya 3: la identidad de Roy	317
11.4.4. Joya 4: la derivada de la función de costo	318
11.5. Curvatura de las funciones de valor [P1]	319
11.6. Milgrom–Segal y mecanismos [P1]	322
11.6.1. Motivación: cuando no se puede derivar en x	322
11.6.2. Aplicación: subastas y equivalencia de ingresos	324
11.7. Sensibilidad general [P2]	325
11.7.1. Soluciones múltiples: quiebres y subdiferencial	326
11.8. Ejercicios tipo examen [P1]	328
12. Conjugación en el sentido de Fenchel [P3]	332
12.1. Motivación: describir una función por sus rectas soporte [P3]	333
12.2. La conjugada de Fenchel: definición y primeras observaciones [P3]	334
12.3. Ejemplos calculados en detalle [P3]	336
12.4. Propiedades básicas de la conjugada [P3]	338
12.5. Igualdad en Fenchel–Young y subdiferenciales [P3]	340
12.6. Biconjugada y teorema de Fenchel–Moreau [P3]	342
12.6.1. Aplicación: recuperar la tecnología desde el beneficio	344
12.7. Dualidad de Fenchel [P4]	345
12.8. Resumen y ejercicios [P3]	348

13. Programación lineal y aplicaciones [P3]	352
13.1. Motivación: el caso lineal [P3]	353
13.2. Formas estándar y canónica [P3]	354
13.3. Geometría: poliedros y vértices [P3]	356
13.3.1. La región factible es un poliedro	356
13.3.2. Soluciones básicas: el álgebra de los vértices	356
13.3.3. El teorema fundamental de la programación lineal	358
13.3.4. Resolución gráfica de un LP en dos variables	359
13.4. Dualidad en programación lineal [P2]	361
13.4.1. El dual desde la dualidad lagrangiana	361
13.4.2. Reglas de construcción del dual	362
13.4.3. Dualidad débil y fuerte	362
13.4.4. Holgura complementaria	363
13.5. Interpretación económica de la dualidad [P2]	365
13.5.1. El dual valora los recursos: precios sombra	365
13.5.2. El problema de la dieta	366
13.5.3. Análisis de sensibilidad: validez de los precios sombra	367
13.6. Algoritmos: simplex y puntos interiores [P4]	367
13.6.1. El método simplex: caminar por los vértices	367
13.6.2. Puntos interiores: atravesar el poliedro	368
13.7. Aplicaciones [P3]	369
13.7.1. Juegos matriciales de suma cero	369
13.7.2. Transporte y asignación	371
13.7.3. Screening con tipos finitos como programa lineal	371
13.8. Resumen y ejercicios [P3]	372
14. Máquinas de vectores soporte [P5]	377
14.1. El problema de clasificación binaria [P5]	377
14.1.1. Datos, etiquetas y clasificadores lineales	377
14.1.2. Separabilidad lineal y el teorema de separación	378
14.2. Margen y el problema primal [P5]	380
14.2.1. Distancia de un punto a un hiperplano	380
14.2.2. Margen funcional, margen geométrico y normalización canónica	381
14.2.3. Derivación: del margen máximo al programa cuadrático	381
14.3. Margen duro: convexidad y KKT [P5]	383
14.3.1. Es un QP convexo con Slater	383
14.3.2. Lagrangiano y condiciones KKT, paso a paso	383
14.3.3. Vectores soporte	384
14.4. El dual del SVM y el kernel [P5]	385
14.4.1. Derivación completa de la función dual	385
14.4.2. El truco del kernel	386
14.5. Margen blando [P5]	388
14.5.1. Variables de holgura y el parámetro C	388

14.5.2. Equivalencia con la pérdida bisagra	389
14.6. Ejemplo numérico completo [P5]	390
14.7. SVM en economía y proyecto final [P5]	391
14.8. Ejercicios [P5]	392
15. Métodos de optimización de primer orden [P4]	396
15.1. Panorama: por qué métodos iterativos [P4]	396
15.1.1. No hay fórmulas cerradas	396
15.1.2. Direcciones de descenso	397
15.1.3. Criterio de parada	398
15.2. Suavidad y convexidad fuerte [P4]	398
15.2.1. Gradiente Lipschitz y el lema de descenso	399
15.2.2. Convexidad fuerte y número de condición	400
15.3. Descenso de gradiente [P4]	401
15.3.1. El algoritmo	401
15.3.2. Elección del paso	401
15.3.3. Convergencia en el caso convexo: tasa $O(1/k)$	403
15.3.4. Convergencia con convexidad fuerte: tasa lineal	404
15.3.5. Ejemplo a mano: el efecto del condicionamiento	405
15.4. Descenso más pronunciado en cuadráticas [P4]	406
15.5. Método de gradiente conjugado [P4]	407
15.5.1. Motivación: arreglar el zigzag con memoria	407
15.5.2. El algoritmo CG	409
15.5.3. CG no lineal	411
15.6. Método de gradiente proyectado [P4]	411
15.6.1. Motivación y algoritmo	411
15.6.2. Por qué funciona	412
15.6.3. Ejemplo completo sobre una caja	413
15.6.4. Ejemplo completo sobre el simplex	414
15.7. Nota aplicada: economía computacional [P4]	415
15.7.1. Tatonnement walrasiano como dinámica de gradiente	415
15.7.2. Estimación estructural y aprendizaje automático	415
15.7.3. Sugerencias para el trabajo computacional	416
15.8. Resumen y ejercicios [P4]	416
16. Penalización y lagrangiano aumentado [P5]	420
16.1. Penalización cuadrática [P5]	421
16.1.1. Motivación: multar la infactibilidad	421
16.1.2. Un ejemplo 1D resuelto por completo	422
16.1.3. El precio numérico: mal condicionamiento	424
16.2. Métodos de barrera [P4]	424
16.2.1. La idea: un peaje por acercarse a la frontera	424
16.3. Lagrangiano aumentado [P5]	426

16.3.1. Dos defectos, una cura	426
16.3.2. El algoritmo de Hestenes–Powell	427
16.3.3. Exactitud con penalización finita: el teorema central	429
16.3.4. Ejemplo numérico completo: tres iteraciones a mano	430
16.4. Desigualdades y ADMM [P4]	432
16.4.1. Lagrangiano aumentado con desigualdades	432
16.4.2. ADMM: el método de dirección alternada de multiplicadores	433
16.4.3. Lectura económica: planificación descentralizada por precios	433
16.5. Aplicación: portafolio de Markowitz [P4]	435
16.5.1. Formulación como programa cuadrático	435
16.5.2. Solución analítica por lagrangiano con tres activos	435
16.5.3. Cómo lo resolvería el lagrangiano aumentado	436
16.6. Guía práctica [P3]	437
A. Guía de estudio, examen y glosario [P2]	441
A.1. Mapa del curso y dependencias [P2]	441
A.1.1. El grafo de dependencias	441
A.1.2. Las tres columnas vertebrales	442
A.2. Plan de estudio semanal [P2]	442
A.2.1. Semana a semana (S1–S15)	442
A.2.2. Plan intensivo pre-parcial (el EP cae hacia S8–S9)	444
A.3. Teoremas estrella: chuleta legal [P2]	444
A.3.1. Existencia y proyección	445
A.3.2. Separación, soporte y Carathéodory	445
A.3.3. Convexidad de funciones y jerarquía generalizada	446
A.3.4. Condiciones de optimalidad	446
A.3.5. Dualidad, envolvente y Fenchel	447
A.4. Errores clásicos de examen [P2]	448
A.5. Cómo escribir demostraciones [P2]	449
A.5.1. Estructura de una demostración	449
A.5.2. Frases estándar del español matemático	450
A.5.3. Verificar un KKT antes de entregarlo	450
A.5.4. Gestión del tiempo en el examen	450
A.6. Estrategia para los trabajos prácticos [P2]	451
A.7. Estrategia para la exposición final [P2]	451
A.7.1. Criterios probables del jurado	451
A.7.2. Seis propuestas de tema desarrolladas	452
A.7.3. Estructura de los 20 minutos	453
A.8. Puente a Microeconomía [P2]	453
A.9. Glosario español–inglés [P2]	456

Cómo usar este cuaderno

Estas son notas de estudio de *Concavidad y Optimización en Economía*, pensadas para un curso de posgrado. Siguen, semana a semana, el orden en que suele dictarse el curso, y están elaboradas a partir de la bibliografía que se lista más abajo.

Están escritas pensando en un público concreto: quien llega al análisis convexo y la optimización **desde la economía**, con formación matemática de nivel básico-intermedio. De ahí las dos decisiones de estilo que gobiernan todo el texto: **no se asume nada** (cada concepto se construye desde cero, con todos los pasos algebraicos explicados) y la intuición va siempre antes del formalismo, sin renunciar después al rigor.

Observación 0.1 (Nota preliminar). Este es material de estudio no oficial: no es la guía del curso ni sustituye las clases, el sílabo o los libros de texto, y no está avalado por ninguna institución. Las demostraciones siguen los desarrollos estándar de la bibliografía citada, con la redacción y el orden expositivo adaptados a los objetivos de estas notas. Las marcas de prioridad que se explican abajo son un criterio de estudio propio, no una clasificación oficial de contenidos. Cualquier error es atribuible a estas notas y no a las fuentes.

Estructura de cada capítulo

- **Objetivos y ubicación en el curso:** qué semana del cronograma cubre y qué libro de la bibliografía lo trata.
- **Motivación:** por qué existe el concepto y qué problema resuelve.
- **Definiciones y teoremas:** numerados, con demostraciones explicadas *paso a paso* (cada paso dice qué se hace y por qué).
- Cajas de colores:
 - **Intuición:** la idea en lenguaje llano, antes del formalismo.
 - **Cuidado (error común):** errores típicos que cuestan puntos en exámenes.
 - **Estrategia de examen:** cómo suele preguntarse el tema y cómo atacarlo.
 - **Conexión con economía:** dónde aparece el concepto en teoría económica.
 - **¿Para qué sirve esto en Microeconomía?:** la conexión concreta con los temas de un curso de micro de posgrado.
 - **Resumen del capítulo:** lo mínimo que hay que saber de memoria.
- **Ejercicios tipo examen con solución completa.**

Las marcas de prioridad y para qué sirven

Un curso de optimización cubre bastante más de lo que un economista usará después a diario. Como estas notas se escribieron también como *punteo* hacia la microeconomía de posgrado, cada capítulo y cada sección llevan una **marca de prioridad [P1]–[P5]** que responde a una sola pregunta: ¿cuánto se usa este material en un curso típico de **Microeconomía**?

La calibración se hizo contra el temario canónico de un curso de posgrado basado en MAS-COLELL, WHINSTON y GREEN (MWG), que se organiza en cinco partes. A ellas remiten las cajas moradas a lo largo del texto:

1. **Decisión individual** (MWG caps. 1–6): preferencia, elección y preferencia revelada; teoría clásica de la demanda (dualidad, ecuación de Slutsky, teorema de la envolvente); demanda agregada; producción y dualidad; elección bajo incertidumbre (utilidad esperada, aversión al riesgo).
2. **Teoría de juegos** (MWG caps. 7–9): juegos estáticos y equilibrio de Nash en estrategias puras y mixtas; juegos dinámicos; juegos bayesianos; juegos repetidos y descuento.
3. **Equilibrio de mercado y fallas de mercado** (MWG caps. 10–14): equilibrio parcial y excedentes; externalidades y bienes públicos; poder de mercado; selección adversa, señalización y escrutinio; problema principal-agente y riesgo moral.
4. **Equilibrio general** (MWG caps. 15–18): intercambio puro y economías con producción, caja de Edgeworth; óptimo de Pareto y los dos teoremas del bienestar; existencia del equilibrio walrasiano; núcleo.
5. **Bienestar e incentivos** (MWG caps. 21–23): elección social y teorema de Arrow; economía del bienestar; diseño de mecanismos, principio de revelación e implementación.

El significado de las marcas es:

- **[P1] Esencial:** se usa directa y repetidamente en micro (separación de convexos, concavidad y cuasiconcavidad, condiciones de Karush–Kuhn–Tucker, teoremas de la envolvente).
- **[P2] Muy útil:** lenguaje y herramientas que aparecen con frecuencia o sostienen a los temas [P1].
- **[P3] Útil como formación:** da madurez y contexto; se usa de forma indirecta.
- **[P4] Periférico:** aparece poco en microeconomía (aunque puede ser central en economía computacional, econometría o finanzas).
- **[P5] Marginal para micro:** casi no se usa en ese curso.

Cuidado (error común)

Dos salvedades sobre las marcas. Primera: son *relativas a la microeconomía*, no al curso de optimización. Un tema [P5] sigue siendo materia examinable del curso y puede caer perfectamente en el parcial o en la exposición final; las marcas sirven para decidir dónde profundizar con vistas a micro, no para decidir qué estudiar para los exámenes de optimización. Segunda: un programa concreto puede ponderar distinto. Un curso con mucha

teoría de juegos o con diseño de mecanismos subirá el valor de los puntos extremos, del simplex de estrategias mixtas y de la dualidad; uno centrado en equilibrio general y teoría de la demanda lo bajará. Conviene contrastar las marcas con el sílabo que a uno le toque.

Observación 0.2 (Lo que este cuaderno no cubre y micro sí usa). Por honestidad con el lector conviene señalar los vacíos, que vienen del temario del curso de optimización y no de estas notas. Faltan aquí tres herramientas que la microeconomía moderna emplea. Primera, los **teoremas de punto fijo** de Brouwer y Kakutani, que aquí solo se mencionan de pasada: son la vía estándar para probar la existencia del equilibrio de Nash y del equilibrio walrasiano, y se estudian en un curso de análisis real. Segunda, la **teoría de la medida y la probabilidad**, necesaria para tratar con rigor la incertidumbre, los juegos bayesianos y los espacios de loterías generales. Tercera, la **estática comparativa monótona** (retículos, supermodularidad, teoremas de Topkis y de Milgrom–Shannon), hoy habitual en los cursos de micro y de la que aquí solo hay menciones sueltas: es la herramienta para obtener resultados de monotonía *sin* suponer concavidad ni diferenciabilidad. Quien apunte a micro hará bien en cubrir esos tres frentes por separado.

Bibliografía y cómo se usa aquí

- ARAGÓN, F.; GOBERNA, M.A.; LÓPEZ, M.A.; RODRÍGUEZ, M. *Nonlinear Optimization* [1]. Fuente principal para optimalidad con y sin restricciones y cualificaciones de restricciones.
- BOYD, S.; VANDENBERGHE, L. *Convex Optimization* [2]. Fuente para funciones convexas, dualidad lagrangiana y métodos numéricos. Disponible en abierto.
- BRINKHUIS, J. *Convex Analysis for Optimization* [3]. Fuente para separación y conjugación de Fenchel.
- LI, L. *Selected Applications of Convex Optimization* [4]. Aplicaciones.
- NOCEDAL, J.; WRIGHT, S. *Numerical Optimization* [5]. Métodos numéricos.
- RUSZCZYŃSKI, A. *Nonlinear Optimization* [6]. Fuente para conos, subdiferenciales y condiciones de optimalidad.
- SNYMAN, J.; WILKE, D. *Practical Mathematical Optimization* [7]. Algoritmos y práctica computacional.
- WRIGHT, S.; RECHT, B. *Optimization for Data Analysis* [8]. Métodos de primer orden y clasificación.

Para las conexiones con teoría económica, la referencia de fondo es MAS-COLELL, A.; WHINSTON, M.; GREEN, J. *Microeconomic Theory* [9], citada como MWG. Las referencias completas de todas estas obras están en la bibliografía al final del cuaderno.

Plan de estudio sugerido

El curso suele evaluarse con un examen parcial, varios trabajos prácticos escritos y una exposición final, esta última con un peso considerable. Una forma eficaz de usar estas notas:

1. **Antes de cada clase:** leer la motivación y las definiciones del capítulo correspondiente (30–45 min). Llegar sabiendo las definiciones permite seguir las demostraciones en vivo, que es donde se aprende de verdad.
2. **Después de cada clase:** repasar las demostraciones e intentar los ejercicios *sin mirar* la solución; comparar después.
3. **Memorizar con precisión quirúrgica** los enunciados con sus hipótesis exactas (qué pide cada versión de los teoremas de separación, qué cualificación exige el teorema de Karush–Kuhn–Tucker). En este tipo de curso, citar un teorema sin sus hipótesis invalida el argumento.
4. **Antes del examen y de la exposición:** usar el apéndice de guía y glosario, que condensa los teoremas con sus hipótesis, los errores clásicos y propuestas de tema para la exposición.

Cuidado (error común)

El error más caro en este curso es confundir condiciones *necesarias* con *suficientes*, y aplicar las condiciones de Karush–Kuhn–Tucker sin verificar la cualificación de restricciones. El capítulo correspondiente insiste en ello con un contraejemplo explícito; conviene no saltárselo.

Capítulo 1

Preliminares matemáticos: espacios vectoriales, topología y cálculo [P2]

Lectura previa a la Semana 1. Bibliografía: Brinkhuis [3]; Wright y Recht [8]; Aragón et al. [1].

¿Para qué sirve esto en Microeconomía?

Este capítulo construye el lenguaje sobre el que descansa *todo* el curso de Microeconomía. En la parte de *equilibrio general* (caja de Edgeworth, óptimos de Pareto, primer y segundo teorema del bienestar, núcleo; MWG caps. 15–18) las cestas de consumo son vectores de $\mathbb{R}_+^n$, la *continuidad de las preferencias* es una condición topológica, y la *existencia* de la demanda del consumidor y del equilibrio walrasiano se demuestra con el teorema de Weierstrass sobre conjuntos compactos (el conjunto presupuestario es compacto cuando los precios son estrictamente positivos). En la parte de *fallas de mercado* (contratos: riesgo moral a la Holmström, selección adversa de Baron–Myerson, señalización de Spence; MWG caps. 13–14) los problemas del principal se resuelven con condiciones de primer y segundo orden: el *gradiente* y la *Hessiana* que aquí estudiamos. En la *decisión individual* bajo incertidumbre (utilidad esperada, aversión al riesgo; MWG cap. 6) la concavidad de la utilidad de Bernoulli, que se verifica con la definitud de la Hessiana, es la aversión al riesgo, y los teoremas de la envoltente tipo Milgrom–Segal [11] requieren manejar con soltura derivadas y expansiones de Taylor. En resumen: sin este capítulo no se puede leer [9] ni [10] con rigor. Referencias de apoyo: [1] caps. 1–2, [3] apéndices, [7] cap. 1.

1.1. Espacios vectoriales reales [P2]

1.1.1. Motivación: cestas de consumo como vectores

Un consumidor elige cantidades de n bienes: x_1 kilos de arroz, x_2 litros de leche, $\dots$, x_n horas de internet. Su elección se describe con una lista ordenada de n números reales,

$$x = (x_1, x_2, \dots, x_n),$$

llamada *cesta de consumo* (*consumption bundle*). El conjunto de todas las cestas posibles con cantidades no negativas es

$$\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x_i \geq 0 \text{ para todo } i = 1, \dots, n\},$$

el *ortante no negativo*. Con las cestas queremos hacer dos operaciones naturales: *sumarlas* (juntar dos canastas de compras) y *escalarlas* (comprar el doble de todo). Un *espacio vectorial* es precisamente un conjunto donde estas dos operaciones se comportan bien.

Definición 1.1 (Espacio vectorial real). Un **espacio vectorial real** (*real vector space*) es un conjunto V (cuyos elementos llamamos *vectores*) dotado de dos operaciones:

- **suma:** a cada par $u, v \in V$ le asigna un vector $u + v \in V$;
- **producto por escalar:** a cada $\lambda \in \mathbb{R}$ y $v \in V$ le asigna un vector $\lambda v \in V$;

que satisfacen, para todos $u, v, w \in V$ y $\lambda, \mu \in \mathbb{R}$:

- (A1) $u + v = v + u$ (*conmutatividad:* el orden de la suma no importa)
- (A2) $(u + v) + w = u + (v + w)$ (*asociatividad:* no importa cómo agrupemos)
- (A3) existe $0 \in V$ con $v + 0 = v$ (*vector cero:* sumar “nada” no cambia nada)
- (A4) para cada v existe $-v$ con $v + (-v) = 0$ (*opuesto:* toda suma se puede deshacer)
- (A5) $\lambda(u + v) = \lambda u + \lambda v$ (escalar una suma = sumar los escalados)
- (A6) $(\lambda + \mu)v = \lambda v + \mu v$ (distributividad en el escalar)
- (A7) $\lambda(\mu v) = (\lambda\mu)v$ (escalar dos veces = escalar por el producto)
- (A8) $1 \cdot v = v$ (escalar por 1 no hace nada)

Los ocho axiomas son exactamente las reglas de “álgebra de flechas” que uno usa sin pensar; la definición solo las hace explícitas para poder trabajar en abstracto.

Ejemplo 1.2 (El espacio central del curso: $\mathbb{R}^n$). El conjunto $\mathbb{R}^n = \{(x_1, \dots, x_n) : x_i \in \mathbb{R}\}$ con las operaciones *componente a componente*

$$x + y = (x_1 + y_1, \dots, x_n + y_n), \quad \lambda x = (\lambda x_1, \dots, \lambda x_n),$$

es un espacio vectorial real. Verifiquemos numéricamente (A5) en $\mathbb{R}^2$ con $x = (1, 2)$, $y = (3, -1)$, $\lambda = 2$:

$$\begin{aligned} \lambda(x + y) &= 2((1, 2) + (3, -1)) = 2(1 + 3, 2 + (-1)) = 2(4, 1) = (8, 2), \\ \lambda x + \lambda y &= 2(1, 2) + 2(3, -1) = (2, 4) + (6, -2) = (2 + 6, 4 - 2) = (8, 2). \end{aligned}$$

Coinciden, como debía ser. El vector cero es $0 = (0, \dots, 0)$ y el opuesto de x es $-x = (-x_1, \dots, -x_n)$.

Cuidado (error común)

Tres errores frecuentes en los primeros exámenes:

1. $\mathbb{R}_+^n$ **no es un espacio vectorial**. Si $x = (1, 2) \in \mathbb{R}_+^2$ y $\lambda = -1$, entonces $\lambda x = (-1, -2) \notin \mathbb{R}_+^2$: falla la cerradura bajo producto por escalar. $\mathbb{R}_+^n$ es un *cono convexo* (lo veremos en el capítulo de conjuntos convexos), no un subespacio.
2. **No confundir el escalar** $0 \in \mathbb{R}$ **con el vector** $0 \in V$. Son objetos distintos aunque se escriban igual.
3. La “multiplicación de vectores” **componente a componente no es parte de la estructura**. En un espacio vectorial solo hay suma y producto por *escalar*; el producto interno (Sección 1.2) devuelve un *número*, no un vector.

1.1.2. Subespacios, combinaciones lineales y bases

Definición 1.3 (Subespacio). Un subconjunto no vacío $S \subseteq V$ es un **subespacio vectorial** (*linear subspace*) si es cerrado bajo las dos operaciones: para todos $u, v \in S$ y $\lambda \in \mathbb{R}$ se cumple $u + v \in S$ y $\lambda v \in S$. Equivalentemente: $\lambda u + \mu v \in S$ para todos $u, v \in S$, $\lambda, \mu \in \mathbb{R}$.

Todo subespacio contiene al vector 0 (toma $\lambda = 0$). En $\mathbb{R}^3$ los subespacios son exactamente: $\{0\}$, las rectas por el origen, los planos por el origen, y $\mathbb{R}^3$ completo. Una recta que *no* pasa por el origen no es subespacio (no contiene al 0); por ejemplo, la recta presupuestaria $\{x \in \mathbb{R}^2 : p_1x_1 + p_2x_2 = m\}$ con $m > 0$ no es un subespacio.

Definición 1.4 (Combinación lineal, independencia, base). Sean $v_1, \dots, v_k \in V$.

1. Una **combinación lineal** (*linear combination*) es un vector de la forma $\lambda_1 v_1 + \dots + \lambda_k v_k$ con $\lambda_i \in \mathbb{R}$.
2. Los vectores son **linealmente independientes** (*linearly independent*) si la *única* forma de obtener el vector cero como combinación lineal es con todos los coeficientes nulos:

$$\lambda_1 v_1 + \dots + \lambda_k v_k = 0 \implies \lambda_1 = \dots = \lambda_k = 0.$$

En caso contrario son *linealmente dependientes*: alguno de ellos es combinación lineal de los demás (es “redundante”).

3. Una **base** (*basis*) de V es una familia de vectores linealmente independientes tal que *todo* vector de V es combinación lineal de ellos. Si V tiene una base con n elementos, toda base tiene n elementos, y decimos que la **dimensión** (*dimension*) de V es n .

Ejemplo 1.5 (Base canónica y un cálculo completo en $\mathbb{R}^n$). La *base canónica* de $\mathbb{R}^n$ es $e_1 = (1, 0, \dots, 0)$, $e_2 = (0, 1, 0, \dots, 0)$, $\dots$, $e_n = (0, \dots, 0, 1)$; todo $x = (x_1, \dots, x_n)$ se escribe $x = x_1 e_1 + \dots + x_n e_n$, así que $\dim \mathbb{R}^n = n$.

Ahora un cálculo con todos los pasos. ¿Son $v_1 = (1, 2)$ y $v_2 = (3, 4)$ linealmente independien-

tes? Planteamos $\lambda_1 v_1 + \lambda_2 v_2 = (0, 0)$, es decir,

$$\lambda_1(1, 2) + \lambda_2(3, 4) = (\lambda_1 + 3\lambda_2, 2\lambda_1 + 4\lambda_2) = (0, 0) \iff \begin{cases} \lambda_1 + 3\lambda_2 = 0, \\ 2\lambda_1 + 4\lambda_2 = 0. \end{cases}$$

De la primera ecuación, $\lambda_1 = -3\lambda_2$. Sustituyendo en la segunda: $2(-3\lambda_2) + 4\lambda_2 = -6\lambda_2 + 4\lambda_2 = -2\lambda_2 = 0$, luego $\lambda_2 = 0$ y entonces $\lambda_1 = -3 \cdot 0 = 0$. La única solución es la trivial: *son independientes*, y como son 2 vectores independientes en un espacio de dimensión 2, forman una base de $\mathbb{R}^2$.

En cambio, $w_1 = (1, 2)$ y $w_2 = (2, 4)$ son dependientes: $w_2 = 2w_1$, o sea $2w_1 + (-1)w_2 = 0$ con coeficientes no todos nulos.

Intuición

Piensa en una base como un *sistema de coordenadas*: un juego mínimo de “direcciones patrón” con las que puedes describir cualquier vector de manera única. La dimensión cuenta cuántos “grados de libertad” tiene el espacio. En economía: si hay n bienes, el espacio de cestas tiene n grados de libertad, y cada e_i es la cesta “una unidad del bien i y nada más”. Que un conjunto de vectores sea dependiente significa que alguna dirección es redundante: ya se podía fabricar con las otras.

1.2. Producto interno y norma [P1]

Para hacer *análisis* (límites, continuidad, optimización) necesitamos medir longitudes, distancias y ángulos. En $\mathbb{R}^n$ todo sale de una sola operación: el producto interno.

Definición 1.6 (Producto interno euclidiano). El **producto interno** o **producto escalar** (*inner product*, *dot product*) de $x, y \in \mathbb{R}^n$ es el número real

$$\langle x, y \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n = \sum_{i=1}^n x_i y_i.$$

Propiedades inmediatas (todas se verifican expandiendo la suma): para todos $x, y, z \in \mathbb{R}^n$ y $\lambda \in \mathbb{R}$,

(P1) $\langle x, y \rangle = \langle y, x \rangle$ (simetría);

(P2) $\langle \lambda x + z, y \rangle = \lambda \langle x, y \rangle + \langle z, y \rangle$ (linealidad en cada argumento);

(P3) $\langle x, x \rangle = x_1^2 + \cdots + x_n^2 \geq 0$, con igualdad si y solo si $x = 0$ (positividad).

Ejemplo 1.7 (Gasto como producto interno). Si $p = (p_1, \dots, p_n) \in \mathbb{R}_{++}^n$ es el vector de precios y $x \in \mathbb{R}_+^n$ una cesta, el *gasto* del consumidor es exactamente $\langle p, x \rangle = p_1 x_1 + \cdots + p_n x_n$, y la restricción presupuestaria es $\langle p, x \rangle \leq m$. Casi todas las expresiones lineales de la microeconomía (gasto, ingreso, beneficio $\langle p, y \rangle$ de un plan de producción y) son productos internos. Con $p = (2, 5)$ y $x = (3, 1)$: $\langle p, x \rangle = 2 \cdot 3 + 5 \cdot 1 = 6 + 5 = 11$.

Definición 1.8 (Norma euclidiana y distancia). La **norma euclidiana** (*Euclidean norm*) de $x \in \mathbb{R}^n$ es

$$\|x\| = \sqrt{\langle x, x \rangle} = \sqrt{x_1^2 + \cdots + x_n^2},$$

y la **distancia** entre x e y es $d(x, y) = \|x - y\|$.

Para $n = 2$ esto es el teorema de Pitágoras: la longitud de la flecha de $(0, 0)$ a $(3, 4)$ es $\|(3, 4)\| = \sqrt{3^2 + 4^2} = \sqrt{9 + 16} = \sqrt{25} = 5$.

Definición 1.9 (Norma en general). Una función $N : \mathbb{R}^n \rightarrow \mathbb{R}$ es una **norma** (*norm*) si para todos $x, y \in \mathbb{R}^n$ y $\lambda \in \mathbb{R}$:

(N1) $N(x) \geq 0$, y $N(x) = 0$ si y solo si $x = 0$ (positividad);

(N2) $N(\lambda x) = |\lambda| N(x)$ (homogeneidad absoluta);

(N3) $N(x + y) \leq N(x) + N(y)$ (desigualdad triangular).

La clave para probar que la norma euclidiana cumple (N3) es la desigualdad más importante del análisis en $\mathbb{R}^n$:

Teorema 1.10 (Desigualdad de Cauchy–Schwarz). Para todos $x, y \in \mathbb{R}^n$,

$$|\langle x, y \rangle| \leq \|x\| \|y\|,$$

con igualdad si y solo si x e y son linealmente dependientes (uno es múltiplo del otro).

Demostración. Si $y = 0$ ambos lados valen 0 y no hay nada que probar. Supongamos $y \neq 0$. La idea: para cualquier $t \in \mathbb{R}$, el vector $x - ty$ tiene norma al cuadrado no negativa. Expandimos usando la bilinealidad y simetría del producto interno:

$$\begin{aligned} 0 \leq \|x - ty\|^2 &= \langle x - ty, x - ty \rangle \\ &= \langle x, x \rangle - t \langle y, x \rangle - t \langle x, y \rangle + t^2 \langle y, y \rangle \\ &= \|x\|^2 - 2t \langle x, y \rangle + t^2 \|y\|^2. \end{aligned}$$

Esto es un polinomio cuadrático en t que nunca es negativo. Elegimos el t que lo minimiza. Derivando respecto de t e igualando a cero: $-2 \langle x, y \rangle + 2t \|y\|^2 = 0$, o sea $t^* = \langle x, y \rangle / \|y\|^2$ (bien definido porque $y \neq 0$). Sustituyendo t^* :

$$0 \leq \|x\|^2 - 2 \frac{\langle x, y \rangle}{\|y\|^2} \langle x, y \rangle + \frac{\langle x, y \rangle^2}{\|y\|^4} \|y\|^2 = \|x\|^2 - \frac{\langle x, y \rangle^2}{\|y\|^2}.$$

Multiplicando por $\|y\|^2 > 0$ y reordenando: $\langle x, y \rangle^2 \leq \|x\|^2 \|y\|^2$; tomando raíz cuadrada (ambos lados son no negativos) se obtiene $|\langle x, y \rangle| \leq \|x\| \|y\|$.

Igualdad: ocurre exactamente cuando $\|x - t^*y\|^2 = 0$, es decir cuando $x = t^*y$, o sea cuando x es múltiplo de y . $\square$

Corolario 1.11 (Desigualdad triangular). $\|x + y\| \leq \|x\| + \|y\|$ para todos $x, y \in \mathbb{R}^n$.

Demostración. Expandimos el cuadrado y aplicamos Cauchy–Schwarz en el paso central:

$$\|x + y\|^2 = \|x\|^2 + 2\langle x, y \rangle + \|y\|^2 \leq \|x\|^2 + 2\|x\|\|y\| + \|y\|^2 = (\|x\| + \|y\|)^2,$$

y tomamos raíz cuadrada. $\square$

Definición 1.12 (Ortogonalidad y ángulo). Dos vectores x, y son **ortogonales** (*orthogonal*), escrito $x \perp y$, si $\langle x, y \rangle = 0$. Para $x, y \neq 0$, el **ángulo** $\theta \in [0, \pi]$ entre ellos se define por

$$\cos \theta = \frac{\langle x, y \rangle}{\|x\| \|y\|}.$$

(La definición tiene sentido porque, por Cauchy–Schwarz, ese cociente está en $[-1, 1]$.)

Ejemplo 1.13 (Cálculo completo). Sean $x = (1, 2)$ e $y = (3, 1)$. Entonces

$$\langle x, y \rangle = 1 \cdot 3 + 2 \cdot 1 = 5, \quad \|x\| = \sqrt{1 + 4} = \sqrt{5}, \quad \|y\| = \sqrt{9 + 1} = \sqrt{10},$$

$$\cos \theta = \frac{5}{\sqrt{5}\sqrt{10}} = \frac{5}{\sqrt{50}} = \frac{5}{5\sqrt{2}} = \frac{1}{\sqrt{2}} \implies \theta = 45^\circ.$$

Y $d(x, y) = \|x - y\| = \|(1 - 3, 2 - 1)\| = \|(-2, 1)\| = \sqrt{4 + 1} = \sqrt{5}$. Como comprobación de Cauchy–Schwarz: $|\langle x, y \rangle| = 5 \leq \sqrt{5} \cdot \sqrt{10} = \sqrt{50} \approx 7.07$. Sí se cumple.


1.2.1. Otras normas: ℓ_1 y ℓ_∞

La euclidiana no es la única norma útil. Definimos

$$\|x\|_1 = |x_1| + \cdots + |x_n| \quad (\text{norma } \ell_1 \text{ o “del taxista”}),$$

$$\|x\|_\infty = \max\{|x_1|, \dots, |x_n|\} \quad (\text{norma } \ell_\infty \text{ o “del máximo”}).$$

Ambas cumplen (N1)–(N3); por ejemplo, la triangular para $\|\cdot\|_1$ sale de $|x_i + y_i| \leq |x_i| + |y_i|$ sumando sobre i . Para $x = (3, -4)$: $\|x\|_1 = 3 + 4 = 7$, $\|x\| = 5$, $\|x\|_\infty = 4$. La *bola unitaria* $\{x : N(x) \leq 1\}$ tiene forma distinta según la norma:



La bola ℓ_1 es un rombo, la ℓ_2 un círculo y la ℓ_∞ un cuadrado; se cumple siempre $\|x\|_\infty \leq \|x\| \leq \|x\|_1$. Un hecho importante que usaremos sin demostrar: *en $\mathbb{R}^n$ todas las normas son equivalentes* (generan las mismas nociones de convergencia y de conjunto abierto), así que en topología podemos usar la que más convenga [1, cap. 1].

Intuición

$\|x\|_1$ mide la distancia “maneja por una cuadrícula de calles” (solo movimientos horizontales y verticales); $\|x\|$ mide la distancia “en línea recta”; $\|x\|_\infty$ mide solo la peor coordenada. En optimización moderna la elección de norma importa muchísimo (la regularización ℓ_1 produce soluciones con muchos ceros, base del método LASSO en econometría; ver [8]), pero para la *topología* de $\mathbb{R}^n$ las tres cuentan la misma historia.

1.3. Topología de $\mathbb{R}^n$ [P1]

La topología responde preguntas del tipo: ¿qué significa “estar cerca”? ¿qué conjuntos “contienen a su borde”? ¿cuándo un problema de maximización *tiene* solución? Esta última pregunta es la razón de ser de esta sección: antes de calcular la demanda del consumidor hay que saber que *existe*.

1.3.1. Bolas, abiertos y cerrados

Definición 1.14 (Bolas). Sean $x_0 \in \mathbb{R}^n$ y $r > 0$. La **bola abierta** (*open ball*) de centro x_0 y radio r es

$$B(x_0, r) = \{x \in \mathbb{R}^n : \|x - x_0\| < r\},$$

y la **bola cerrada** es $\bar{B}(x_0, r) = \{x \in \mathbb{R}^n : \|x - x_0\| \leq r\}$. La diferencia es solo el borde: la abierta no incluye la esfera $\|x - x_0\| = r$, la cerrada sí.

Definición 1.15 (Conjunto abierto y cerrado). Un conjunto $A \subseteq \mathbb{R}^n$ es **abierto** (*open*) si cada uno de sus puntos tiene una bola abierta a su alrededor totalmente contenida en A : para todo $x \in A$ existe $r > 0$ tal que $B(x, r) \subseteq A$. Un conjunto C es **cerrado** (*closed*) si su complemento $\mathbb{R}^n \setminus C$ es abierto.

Ejemplo 1.16 (Ejemplos y no-ejemplos en $\mathbb{R}$). ■ $(0, 1)$ es abierto: si $x \in (0, 1)$, tomando $r = \min\{x, 1 - x\} > 0$ se tiene $(x - r, x + r) \subseteq (0, 1)$.

- $[0, 1]$ es cerrado: su complemento $(-\infty, 0) \cup (1, \infty)$ es unión de abiertos, luego abierto.
- $[0, 1)$ *no es abierto ni cerrado*: no es abierto porque ninguna bola centrada en 0 cabe dentro (siempre asoma a los negativos); no es cerrado porque su complemento contiene a 1 pero ninguna bola centrada en 1 evita a $[0, 1)$.
- $\mathbb{R}^n$ y $\emptyset$ son *a la vez* abiertos y cerrados. “Abierto” y “cerrado” **no** son contrarios: un conjunto puede ser ambos o ninguno.

En $\mathbb{R}^2$: el conjunto presupuestario $B(p, m) = \{x \in \mathbb{R}_+^2 : \langle p, x \rangle \leq m\}$ es *cerrado* (está definido por desigualdades no estrictas con funciones continuas), y el conjunto $\{x : \langle p, x \rangle < m\}$ es abierto.

Definición 1.17 (Interior, clausura, frontera, acotado). Sea $S \subseteq \mathbb{R}^n$.

- El **interior** $\text{int } S$ es el mayor abierto contenido en S : los puntos de S que tienen una bola alrededor dentro de S .

- La **clausura** (*closure*) $\text{cl } S$ es el menor cerrado que contiene a S : S junto con todos sus “puntos límite”.
- La **frontera** (*boundary*) es $\text{fr } S = \text{cl } S \setminus \text{int } S$: los puntos “en el borde”, arbitrariamente cerca de S y de su complemento a la vez.
- S es **acotado** (*bounded*) si cabe en alguna bola: existe $M > 0$ con $\|x\| \leq M$ para todo $x \in S$.

Por ejemplo, con $S = [0, 1) \subset \mathbb{R}$: $\text{int } S = (0, 1)$, $\text{cl } S = [0, 1]$, $\text{fr } S = \{0, 1\}$, y S es acotado (cabe en $\bar{B}(0, 1)$). Con el conjunto presupuestario en $\mathbb{R}^2$ y $p \gg 0$: su frontera incluye la recta de gasto $\langle p, x \rangle = m$ y los tramos de los ejes; su interior es $\{x \gg 0 : \langle p, x \rangle < m\}$.

1.3.2. Sucesiones, convergencia y compacidad

Definición 1.18 (Convergencia de sucesiones). Una **sucesión** (*sequence*) en $\mathbb{R}^n$ es una lista infinita $x^1, x^2, x^3, \dots$ de vectores, escrita $(x^k)_{k \in \mathbb{N}}$. La sucesión **converge** a $x^* \in \mathbb{R}^n$, escrito $x^k \rightarrow x^*$, si $\|x^k - x^*\| \rightarrow 0$ como sucesión de números reales; es decir, si para todo $\varepsilon > 0$ existe $K \in \mathbb{N}$ tal que $\|x^k - x^*\| < \varepsilon$ para todo $k \geq K$. En palabras: por pequeña que sea la tolerancia ε , desde algún momento en adelante *todos* los términos están a distancia menor que ε del límite. En $\mathbb{R}^n$, $x^k \rightarrow x^*$ equivale a que *cada coordenada* converja: $x_i^k \rightarrow x_i^*$ para $i = 1, \dots, n$.

Por ejemplo, $x^k = (\frac{1}{k}, 2 + \frac{3}{k}) \rightarrow (0, 2)$ porque $\frac{1}{k} \rightarrow 0$ y $2 + \frac{3}{k} \rightarrow 2$.

Una caracterización muy usada: C es **cerrado** si y solo si contiene los límites de todas sus *sucesiones convergentes* (si $x^k \in C$ para todo k y $x^k \rightarrow x^*$, entonces $x^* \in C$). Esta es la forma práctica de verificar cerradura en las demostraciones.

Definición 1.19 (Conjunto compacto). Un conjunto $K \subseteq \mathbb{R}^n$ es **compacto** (*compact*) si toda sucesión en K tiene una subsucesión convergente cuyo límite está en K . (Una *subsucesión* se obtiene quedándose con infinitos términos de la sucesión original, en orden: por ejemplo, los términos pares.)

En $\mathbb{R}^n$ hay una caracterización completamente operativa:

Teorema 1.20 (Heine–Borel). $K \subseteq \mathbb{R}^n$ es compacto si y solo si K es cerrado y acotado.

Es decir: en $\mathbb{R}^n$, para verificar compacidad basta chequear dos cosas concretas. (Cuidado: en espacios de dimensión infinita, que aparecen en macro y en contratos dinámicos, esto es falso; ahí compacto es más exigente que cerrado y acotado.) El motor detrás de Heine–Borel es:

Teorema 1.21 (Bolzano–Weierstrass). Toda sucesión acotada en $\mathbb{R}^n$ tiene una subsucesión convergente.

Idea de la demostración (caso $n = 1$): la sucesión vive en un intervalo $[a, b]$. Partimos el intervalo por la mitad; alguna de las dos mitades contiene infinitos términos de la sucesión; nos quedamos con esa mitad y repetimos. Obtenemos intervalos encajados de longitud $(b-a)/2^k \rightarrow 0$ que “atrapan” un punto x^* , y eligiendo un término de la sucesión en cada intervalo se construye una subsucesión que converge a x^* . Para $n > 1$ se aplica el caso unidimensional coordenada por coordenada. Puedes ver [1, cap. 1] o [3], apéndice sobre análisis.

Ejemplo 1.22 (El conjunto presupuestario es compacto). Sea $p \in \mathbb{R}_{++}^n$ (todos los precios estrictamente positivos) y $m > 0$. Afirmamos que $B(p, m) = \{x \in \mathbb{R}_+^n : \langle p, x \rangle \leq m\}$ es compacto.

- *Cerrado*: si $x^k \in B(p, m)$ y $x^k \rightarrow x$, entonces $x_i = \lim x_i^k \geq 0$ (los límites preservan desigualdades no estrictas) y $\langle p, x \rangle = \lim \langle p, x^k \rangle \leq m$. Luego $x \in B(p, m)$.
- *Acotado*: para cada i , como todas las coordenadas son no negativas, $p_i x_i \leq p_1 x_1 + \dots + p_n x_n \leq m$, de donde $0 \leq x_i \leq m/p_i$. Así $\|x\| \leq \sqrt{\sum_i (m/p_i)^2} =: M < \infty$.

Por Heine–Borel, $B(p, m)$ es compacto. *Este es el paso clave para que la demanda exista* (Teorema 1.24). Nota dónde se usó $p \gg 0$: si algún $p_i = 0$, la coordenada x_i queda libre y el conjunto deja de ser acotado (el consumidor “demandaría infinito” del bien gratuito).

1.3.3. Continuidad y el teorema de Weierstrass

Definición 1.23 (Función continua). Sea $f : D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ y $x_0 \in D$. Dos definiciones equivalentes de que f es **continua** en x_0 :

1. *Versión secuencial*: para toda sucesión $x^k \in D$ con $x^k \rightarrow x_0$ se cumple $f(x^k) \rightarrow f(x_0)$. En palabras: “si las entradas se acercan, las salidas se acercan”; f conmuta con el límite.
2. *Versión ε - δ* : para todo $\varepsilon > 0$ existe $\delta > 0$ tal que si $x \in D$ y $\|x - x_0\| < \delta$, entonces $\|f(x) - f(x_0)\| < \varepsilon$. En palabras: fijada cualquier tolerancia de error ε en la salida, existe una tolerancia δ en la entrada que la garantiza.

f es continua (a secas) si lo es en cada punto de D . Sumas, productos, cocientes (con denominador no nulo) y composiciones de funciones continuas son continuas; polinomios, exponenciales, logaritmos y las funciones Cobb–Douglas son continuos en sus dominios.

En teoría del consumidor, la *continuidad de las preferencias* (los conjuntos “mejor o igual que x ” y “peor o igual que x ” son cerrados) es exactamente la condición que garantiza que las preferencias se representen con una función de utilidad *continua* (teorema de Debreu; ver [9, cap. 3] o [10, cap. 1]). Y la continuidad de u es lo que alimenta al teorema estrella de esta sección:

Teorema 1.24 (Weierstrass: existencia de extremos). Sea $K \subseteq \mathbb{R}^n$ compacto y no vacío, y sea $f : K \rightarrow \mathbb{R}$ continua. Entonces f alcanza máximo y mínimo en K : existen $x^{\max}, x^{\min} \in K$ tales que

$$f(x^{\min}) \leq f(x) \leq f(x^{\max}) \quad \text{para todo } x \in K.$$

Demostración (esquema, caso del máximo). La demostración tiene dos actos.

Acto 1: el supremo es finito. Supongamos que f no fuera acotada superiormente en K . Entonces para cada $k \in \mathbb{N}$ existiría $x^k \in K$ con $f(x^k) > k$. Como K es compacto, la sucesión (x^k) tiene una subsucesión $x^{k_j} \rightarrow x^* \in K$. Por continuidad, $f(x^{k_j}) \rightarrow f(x^*)$, un número real finito; pero $f(x^{k_j}) > k_j \rightarrow \infty$, contradicción. Luego $s = \sup_{x \in K} f(x)$ es finito.

Acto 2: el supremo se alcanza. Por definición de supremo, para cada k existe $x^k \in K$ con $f(x^k) > s - \frac{1}{k}$ (una *sucesión maximizante*). De nuevo por compacidad, hay una subsucesión $x^{k_j} \rightarrow x^{\max} \in K$. Por continuidad, $f(x^{\max}) = \lim_j f(x^{k_j}) = s$. Así el supremo es un máximo, alcanzado en $x^{\max} \in K$. Para el mínimo se aplica lo anterior a $-f$. Detalles completos en [1, cap. 2] y [3]. $\square$

Ejemplo 1.25 (La demanda del consumidor existe). Sea $u : \mathbb{R}_+^n \rightarrow \mathbb{R}$ continua (p.ej. Cobb–Douglas), $p \gg 0$, $m > 0$. El problema del consumidor es

$$\max_{x \in \mathbb{R}_+^n} u(x) \quad \text{sujeto a } \langle p, x \rangle \leq m.$$

El conjunto factible $B(p, m)$ es compacto (Ejemplo 1.22) y no vacío ($0 \in B(p, m)$), y u es continua. Por Weierstrass, *existe* al menos una cesta óptima $x^*(p, m)$: la correspondencia de demanda es no vacía. El mismo argumento da existencia de la oferta de la firma con conjuntos de producción compactos, y es un ingrediente esencial en la existencia de equilibrio walrasiano [9, caps. 15–17]. La *unicidad* y la *caracterización* de x^* requieren más estructura (concavidad, diferenciabilidad): eso es el resto del curso.

Cuidado (error común)

El teorema de Weierstrass necesita *las tres* hipótesis; si falla una, puede no haber óptimo:

- *Sin cerradura*: $f(x) = x$ en $(0, 1)$ no alcanza máximo (el candidato 1 no pertenece al conjunto).
- *Sin acotación*: $f(x) = x$ en $[0, \infty)$ no alcanza máximo. Económicamente: con un bien gratis, no hay demanda óptima.
- *Sin continuidad*: en $[0, 1]$, la función $f(x) = x$ para $x < 1$ y $f(1) = 0$ no alcanza máximo: el supremo es 1 pero nunca se logra.

En un examen, antes de derivar e igualar a cero, **siempre** pregúntate: ¿por qué existe el óptimo que estoy buscando? Weierstrass suele ser la respuesta.

1.4. Cálculo diferencial en varias variables [P1]

Weierstrass dice que el óptimo existe; el cálculo diferencial dice *dónde buscarlo*. Las condiciones de primer orden (gradiente nulo o condiciones de Lagrange/KKT) y de segundo orden (definitud de la Hessiana) son el pan de cada día del problema del consumidor, del productor y del principal en contratos.

1.4.1. Derivadas parciales y gradiente

Definición 1.26 (Derivada parcial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $x_0 \in \mathbb{R}^n$. La **derivada parcial** (*partial derivative*) de f respecto de x_i en x_0 es

$$\frac{\partial f}{\partial x_i}(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h e_i) - f(x_0)}{h},$$

cuando el límite existe: la tasa de cambio de f al mover *solo* la coordenada i , congelando las demás. Operativamente: deriva respecto de x_i tratando las otras variables como constantes.

En economía las parciales tienen nombre propio: si u es una utilidad, $\partial u / \partial x_i$ es la *utilidad marginal* del bien i ; si f es una función de producción, $\partial f / \partial x_i$ es el *producto marginal* del insumo i .

Definición 1.27 (Gradiente). El **gradiente** (*gradient*) de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en x_0 es el vector de todas las parciales (lo escribimos como fila, pero en los productos matriciales lo tratamos como vector columna):

$$\nabla f(x_0) = \left(\frac{\partial f}{\partial x_1}(x_0), \dots, \frac{\partial f}{\partial x_n}(x_0) \right).$$

Decimos que f es *diferenciable* en x_0 si admite una buena aproximación lineal ahí:

$$f(x_0 + v) = f(x_0) + \langle \nabla f(x_0), v \rangle + r(v), \quad \text{con } \frac{r(v)}{\|v\|} \rightarrow 0 \text{ cuando } v \rightarrow 0.$$

(El resto $r(v)$ se hace pequeño *más rápido* que $\|v\|$.) Si las parciales existen y son continuas cerca de x_0 (f de clase C^1), entonces f es diferenciable.

Definición 1.28 (Derivada direccional). La **derivada direccional** de f en x_0 en la dirección $d \in \mathbb{R}^n$, $\|d\| = 1$, es

$$D_d f(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + hd) - f(x_0)}{h}.$$

Si f es diferenciable, la fórmula clave es

$$D_d f(x_0) = \langle \nabla f(x_0), d \rangle :$$

la tasa de cambio en cualquier dirección es el producto interno del gradiente con esa dirección.

Proposición 1.29 (El gradiente apunta hacia el máximo crecimiento). *Sea f diferenciable en x_0 con $\nabla f(x_0) \neq 0$. Entre todas las direcciones unitarias d , la derivada direccional $D_d f(x_0)$ es máxima cuando $d = \nabla f(x_0) / \|\nabla f(x_0)\|$, y su valor máximo es $\|\nabla f(x_0)\|$. La dirección de máximo descenso es $-\nabla f(x_0) / \|\nabla f(x_0)\|$, y las direcciones ortogonales al gradiente son tangentes a la curva de nivel de f (a lo largo de ellas f no cambia a primer orden).*

Demostración. Por Cauchy–Schwarz (Teorema 1.10), para toda d con $\|d\| = 1$,

$$D_d f(x_0) = \langle \nabla f(x_0), d \rangle \leq \|\nabla f(x_0)\| \cdot \|d\| = \|\nabla f(x_0)\|,$$

y la igualdad en Cauchy–Schwarz ocurre exactamente cuando d es múltiplo (positivo, para el máximo) de $\nabla f(x_0)$, es decir cuando $d = \nabla f(x_0) / \|\nabla f(x_0)\|$. Sustituyendo esa d :

$$\left\langle \nabla f(x_0), \frac{\nabla f(x_0)}{\|\nabla f(x_0)\|} \right\rangle = \frac{\|\nabla f(x_0)\|^2}{\|\nabla f(x_0)\|} = \|\nabla f(x_0)\|. \quad \square$$

Intuición

Imagina la gráfica de f como un cerro e imagínate parado en el punto $(x_0, f(x_0))$. El gradiente es una brújula que señala, sobre el mapa (el plano del dominio), la dirección de subida más empinada; su norma dice *qué tan* empinada es. Caminar perpendicular al gradiente es bordear el cerro a altura constante: por eso el gradiente es *ortogonal a las curvas de nivel*. En micro, las curvas de nivel de u son las *curvas de indiferencia*, y $\nabla u(x)$ apunta hacia las cestas mejores; en el óptimo interior del consumidor, ∇u queda alineado con el vector de precios p (de ahí la tangencia TMS = p_1/p_2). Además, esta proposición

explica el método de *descenso de gradiente* que domina la optimización numérica y el machine learning [5, cap. 3], [8].

1.4.2. Jacobiana, regla de la cadena y Hessiana

Definición 1.30 (Matriz jacobiana). Para una función vectorial $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$, $F(x) = (F_1(x), \dots, F_m(x))$, la **matriz jacobiana** (*Jacobian matrix*) en x_0 es la matriz $m \times n$ cuyas filas son los gradientes (traspuestos) de las componentes:

$$JF(x_0) = \begin{pmatrix} \frac{\partial F_1}{\partial x_1}(x_0) & \cdots & \frac{\partial F_1}{\partial x_n}(x_0) \\ \vdots & & \vdots \\ \frac{\partial F_m}{\partial x_1}(x_0) & \cdots & \frac{\partial F_m}{\partial x_n}(x_0) \end{pmatrix}.$$

Es la “derivada” de F : la mejor aproximación lineal $F(x_0 + v) \approx F(x_0) + JF(x_0)v$.

Teorema 1.31 (Regla de la cadena). Si $g : \mathbb{R}^k \rightarrow \mathbb{R}^n$ es diferenciable en t_0 y $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es diferenciable en $g(t_0)$, entonces $f \circ g$ es diferenciable en t_0 y

$$J(f \circ g)(t_0) = Jf(g(t_0)) Jg(t_0) \quad (\text{producto de matrices}).$$

Caso más usado en el curso ($k = 1$, $m = 1$): si $x(t)$ es una curva en $\mathbb{R}^n$ y f es escalar,

$$\frac{d}{dt}f(x(t)) = \langle \nabla f(x(t)), x'(t) \rangle = \sum_{i=1}^n \frac{\partial f}{\partial x_i}(x(t)) x'_i(t).$$

Por ejemplo, con $f(x_1, x_2) = x_1 x_2$ y la curva $x(t) = (t, t^2)$: $\nabla f = (x_2, x_1)$, $x'(t) = (1, 2t)$, luego $\frac{d}{dt}f(x(t)) = x_2 \cdot 1 + x_1 \cdot 2t = t^2 + t \cdot 2t = 3t^2$. Comprobación directa: $f(x(t)) = t \cdot t^2 = t^3$, cuya derivada es $3t^2$. Coincide.

Definición 1.32 (Matriz Hessiana). Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ tiene segundas derivadas parciales, su **matriz Hessiana** (*Hessian matrix*) en x_0 es la matriz $n \times n$

$$\nabla^2 f(x_0) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}(x_0) \right]_{i,j=1}^n,$$

donde $\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial}{\partial x_i} \left(\frac{\partial f}{\partial x_j} \right)$. Si esas segundas parciales son continuas (f de clase C^2), el *teorema de Schwarz* (o de *Clairaut–Young*) garantiza que las cruzadas coinciden, $\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$, de modo que la *Hessiana es simétrica*. La Hessiana es la jacobiana del gradiente: mide cómo *cambia* la pendiente, es decir, la curvatura de f .

1.4.3. Teorema de Taylor: la herramienta de las condiciones de optimalidad

Teorema 1.33 (Taylor de primer y segundo orden). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $x_0 \in \mathbb{R}^n$.

1. Si f es de clase C^1 cerca de x_0 , entonces

$$f(x_0 + v) = f(x_0) + \langle \nabla f(x_0), v \rangle + o(\|v\|),$$

donde $o(\|v\|)$ denota un resto $r(v)$ con $r(v)/\|v\| \rightarrow 0$ cuando $v \rightarrow 0$: un error despreciable frente al tamaño del paso.

2. Si f es de clase C^2 cerca de x_0 , entonces

$$f(x_0 + v) = f(x_0) + \langle \nabla f(x_0), v \rangle + \frac{1}{2} v^\top \nabla^2 f(x_0) v + o(\|v\|^2),$$

con un resto despreciable frente a $\|v\|^2$. Versión con resto de Lagrange: existe $\theta \in (0, 1)$ tal que

$$f(x_0 + v) = f(x_0) + \langle \nabla f(x_0), v \rangle + \frac{1}{2} v^\top \nabla^2 f(x_0 + \theta v) v,$$

es decir, el término cuadrático evaluado en algún punto intermedio del segmento es exacto, no aproximado.

Puedes ver [1, cap. 2] y [5, cap. 2].

Intuición

Taylor dice: cerca de x_0 , toda función suave “es” un polinomio. A primer orden, f es un plano inclinado con pendiente $\nabla f(x_0)$; a segundo orden se le agrega una “taza” o “domo” cuadrático gobernado por la Hessiana. De ahí salen las condiciones de optimalidad: en un máximo interior x^* , el término lineal debe anularse ($\nabla f(x^*) = 0$, si no, moverse en la dirección del gradiente mejoraría f) y el término cuadrático no debe ser positivo en ninguna dirección ($v^\top \nabla^2 f(x^*) v \leq 0$ para todo v : Hessiana semidefinida negativa, Sección 1.5). Recíprocamente, $\nabla f(x^*) = 0$ con Hessiana *definida* negativa garantiza máximo local estricto. Toda la teoría de condiciones de segundo orden del consumidor y del principal es Taylor de orden 2 bien leído.

1.4.4. Ejemplo resuelto completo: Cobb–Douglas

Ejemplo 1.34 (Gradiente y Hessiana de $u(x, y) = x^a y^b$). Sea $u(x, y) = x^a y^b$ con $a, b > 0$, definida para $x, y > 0$. Calculemos todo paso a paso.

Paso 1: parciales de primer orden. Para $\partial u / \partial x$ tratamos y^b como constante y derivamos x^a (regla de la potencia, $\frac{d}{dx} x^a = ax^{a-1}$):

$$\frac{\partial u}{\partial x} = ax^{a-1}y^b, \quad \frac{\partial u}{\partial y} = bx^ay^{b-1}.$$

Ambas son positivas: más consumo da más utilidad (monotonidad). Luego

$$\nabla u(x, y) = (ax^{a-1}y^b, \quad bx^ay^{b-1}).$$

Paso 2: segundas parciales. Derivamos cada parcial respecto de cada variable.

$$\begin{aligned}\frac{\partial^2 u}{\partial x^2} &= \frac{\partial}{\partial x}(ax^{a-1}y^b) = a(a-1)x^{a-2}y^b, \\ \frac{\partial^2 u}{\partial y^2} &= \frac{\partial}{\partial y}(bx^ay^{b-1}) = b(b-1)x^ay^{b-2}, \\ \frac{\partial^2 u}{\partial y \partial x} &= \frac{\partial}{\partial y}(ax^{a-1}y^b) = abx^{a-1}y^{b-1} = \frac{\partial^2 u}{\partial x \partial y} \quad (\text{Schwarz, como debía}).\end{aligned}$$

Por tanto

$$\nabla^2 u(x, y) = \begin{pmatrix} a(a-1)x^{a-2}y^b & abx^{a-1}y^{b-1} \\ abx^{a-1}y^{b-1} & b(b-1)x^ay^{b-2} \end{pmatrix}.$$

Paso 3: evaluación numérica. Tomemos $a = b = \frac{1}{2}$ (la Cobb–Douglas simétrica $u = \sqrt{xy}$) y el punto $(x, y) = (1, 4)$.

$$\frac{\partial u}{\partial x}(1, 4) = \frac{1}{2} \cdot 1^{-1/2} \cdot 4^{1/2} = \frac{1}{2} \cdot 1 \cdot 2 = 1, \quad \frac{\partial u}{\partial y}(1, 4) = \frac{1}{2} \cdot 1^{1/2} \cdot 4^{-1/2} = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4},$$

así que $\nabla u(1, 4) = (1, \frac{1}{4})$: en esa cesta, una unidad extra de x vale (marginalmente) cuatro veces más que una de y ; la tasa marginal de sustitución es $\text{TMS} = \frac{u_x}{u_y} = \frac{1}{1/4} = 4$. Para la Hessiana, con $a(a-1) = \frac{1}{2} \cdot (-\frac{1}{2}) = -\frac{1}{4}$ y $ab = \frac{1}{4}$:

$$\frac{\partial^2 u}{\partial x^2}(1, 4) = -\frac{1}{4} \cdot 1^{-3/2} \cdot 4^{1/2} = -\frac{1}{4} \cdot 2 = -\frac{1}{2}, \quad \frac{\partial^2 u}{\partial y^2}(1, 4) = -\frac{1}{4} \cdot 1 \cdot 4^{-3/2} = -\frac{1}{4} \cdot \frac{1}{8} = -\frac{1}{32},$$

$$\frac{\partial^2 u}{\partial x \partial y}(1, 4) = \frac{1}{4} \cdot 1^{-1/2} \cdot 4^{-1/2} = \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{8}, \quad \implies \quad \nabla^2 u(1, 4) = \begin{pmatrix} -\frac{1}{2} & \frac{1}{8} \\ \frac{1}{8} & -\frac{1}{32} \end{pmatrix}.$$

En la Sección 1.5 aprenderemos a leer esta matriz: su definitud decidirá la concavidad de u (adelanto: con $a + b \leq 1$ la Cobb–Douglas es cóncava en $\mathbb{R}_{++}^2$; aquí $a + b = 1$ y la Hessiana resultará semidefinida negativa).

1.5. Formas cuadráticas y definitud [P1]

El término de segundo orden de Taylor, $\frac{1}{2}v^\top H v$, es una *forma cuadrática*. Saber decidir su signo es saber verificar condiciones de segundo orden y, más adelante, concavidad y convexidad. Esta sección da los dos criterios prácticos: autovalores y menores principales.

Definición 1.35 (Matriz simétrica y forma cuadrática). Una matriz $A \in \mathbb{R}^{n \times n}$ es **simétrica** si $A = A^\top$ (es decir, $a_{ij} = a_{ji}$: la matriz coincide con su reflejo respecto a la diagonal). La **forma cuadrática** (*quadratic form*) asociada a A es la función $Q_A : \mathbb{R}^n \rightarrow \mathbb{R}$,

$$Q_A(v) = v^\top A v = \sum_{i=1}^n \sum_{j=1}^n a_{ij} v_i v_j.$$

Para $n = 2$, escribiendo $A = \begin{pmatrix} \alpha & \beta \\ \beta & \gamma \end{pmatrix}$ y $v = (v_1, v_2)$:

$$Q_A(v) = \alpha v_1^2 + 2\beta v_1 v_2 + \gamma v_2^2.$$

(El 2 aparece porque los términos cruzados $a_{12}v_1v_2$ y $a_{21}v_2v_1$ son iguales y se suman.)

Definición 1.36 (Definitud). Una matriz simétrica A es:

- **definida positiva** (dp) si $v^\top Av > 0$ para todo $v \neq 0$;
- **semidefinida positiva** (sdp) si $v^\top Av \geq 0$ para todo v ;
- **definida negativa** (dn) si $v^\top Av < 0$ para todo $v \neq 0$;
- **semidefinida negativa** (sdn) si $v^\top Av \leq 0$ para todo v ;
- **indefinida** si toma valores positivos y negativos: existen v, w con $v^\top Av > 0 > w^\top Aw$.

Geométricamente, la gráfica de Q_A en $\mathbb{R}^2$ es: una taza hacia arriba (dp), una taza hacia abajo (dn), o una *silla de montar* (indefinida: sube en unas direcciones y baja en otras). Nota que $dp \Rightarrow sdp$ y $dn \Rightarrow sdn$, y que A es dn si y solo si $-A$ es dp (útil para reciclar criterios).

1.5.1. Criterio 1: autovalores

Definición 1.37 (Autovalor y autovector). Un número $\lambda \in \mathbb{R}$ es un **autovalor** (*eigenvalue*) de la matriz A si existe un vector $v \neq 0$, llamado **autovector** (*eigenvector*), tal que

$$Av = \lambda v.$$

En palabras: v es una dirección que la matriz *no tuerce*, solo *estira* (o encoge, o invierte) por el factor λ . Los autovalores se calculan resolviendo la *ecuación característica* $\det(A - \lambda I) = 0$, un polinomio de grado n en λ (aquí I es la matriz identidad y $\det$ el determinante).

Hecho fundamental (teorema espectral): si A es *simétrica*, todos sus autovalores son reales y existe una base ortonormal de autovectores; en esas coordenadas la forma cuadrática se “desacopla” como $Q_A(v) = \lambda_1 w_1^2 + \dots + \lambda_n w_n^2$, una suma de cuadrados con pesos los autovalores. De esa expresión se lee directamente:

Teorema 1.38 (Definitud vía autovalores). Sea A simétrica con autovalores $\lambda_1, \dots, \lambda_n$ (contados con repetición). Entonces A es $dp \Leftrightarrow$ todos los $\lambda_i > 0$; $sdp \Leftrightarrow$ todos los $\lambda_i \geq 0$; $dn \Leftrightarrow$ todos los $\lambda_i < 0$; $sdn \Leftrightarrow$ todos los $\lambda_i \leq 0$; *indefinida* $\Leftrightarrow$ hay autovalores de ambos signos.

Ejemplo 1.39 (Cálculo completo de autovalores, 2×2). Clasifiquemos $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. La ecuación característica:

$$\det(A - \lambda I) = \det \begin{pmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{pmatrix} = (2 - \lambda)^2 - 1 \cdot 1 = \lambda^2 - 4\lambda + 4 - 1 = \lambda^2 - 4\lambda + 3.$$

Igualando a cero y factorizando: $\lambda^2 - 4\lambda + 3 = (\lambda - 1)(\lambda - 3) = 0$, luego $\lambda_1 = 1$ y $\lambda_2 = 3$. Ambos positivos: A es *definida positiva*. Comprobación directa con la forma cuadrática: $v^\top Av =$

$2v_1^2 + 2v_1v_2 + 2v_2^2 = v_1^2 + v_2^2 + (v_1 + v_2)^2 > 0$ para todo $v \neq 0$. (Escribir la forma como suma de cuadrados es otra técnica válida y a veces la más rápida.)

1.5.2. Criterio 2: menores principales líderes (Sylvester)

Definición 1.40 (Menores principales líderes). El **menor principal líder** (*leading principal minor*) de orden k de A , denotado D_k , es el determinante de la submatriz $k \times k$ formada por las primeras k filas y las primeras k columnas de A . Así, $D_1 = a_{11}$, $D_2 = \det \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$, $\dots$, $D_n = \det A$.

Teorema 1.41 (Criterio de Sylvester). Sea A simétrica de orden n con menores principales líderes $D_1, \dots, D_n$.

1. A es **definida positiva** $\iff D_k > 0$ para todo $k = 1, \dots, n$.
2. A es **definida negativa** $\iff$ los D_k alternan de signo empezando en negativo: $(-1)^k D_k > 0$, es decir $D_1 < 0$, $D_2 > 0$, $D_3 < 0$, $\dots$

Para la semidefinitud el criterio con menores líderes **no** basta: hay que revisar todos los menores principales (los de submatrices obtenidas borrando cualesquiera filas y las mismas columnas): $sdp \iff$ todos los menores principales ≥ 0 ; $sdn \iff$ los de orden k tienen signo $(-1)^k$ o valen 0. Puedes ver [7, cap. 1] y [2, apéndice].

Ejemplo 1.42 (Sylvester en 2×2 : la Cobb–Douglas del ejemplo 1.34). Clasifiquemos $H = \nabla^2 u(1, 4) = \begin{pmatrix} -\frac{1}{2} & \frac{1}{8} \\ \frac{1}{8} & -\frac{1}{32} \end{pmatrix}$.

$$D_1 = -\frac{1}{2} < 0, \quad D_2 = \det H = \left(-\frac{1}{2}\right)\left(-\frac{1}{32}\right) - \left(\frac{1}{8}\right)^2 = \frac{1}{64} - \frac{1}{64} = 0.$$

Como $D_2 = 0$, H no es definida negativa (Sylvester exige $D_2 > 0$ estricto). ¿Es semidefinida negativa? Revisamos *todos* los menores principales: de orden 1 son $-\frac{1}{2} \leq 0$ y $-\frac{1}{32} \leq 0$ (signo $(-1)^1$ o cero: bien); el de orden 2 es $D_2 = 0 \geq 0$ (signo $(-1)^2$ o cero: bien). Conclusión: H es *semidefinida negativa pero no definida negativa*. Esto refleja que $u = \sqrt{xy}$ es cóncava pero no *estrictamente* cóncava a lo largo de los rayos por el origen (es homogénea de grado 1: sobre la recta $y = 4x$ la función es lineal).

Ejemplo 1.43 (Sylvester en 3×3 , resuelto). Clasifiquemos

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}.$$

Paso 1: $D_1 = 2 > 0$.

Paso 2: $D_2 = \det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} = 2 \cdot 2 - (-1)(-1) = 4 - 1 = 3 > 0$.

Paso 3: $D_3 = \det A$, expandiendo por la primera fila:

$$\begin{aligned} D_3 &= 2 \cdot \det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} - (-1) \cdot \det \begin{pmatrix} -1 & -1 \\ 0 & 2 \end{pmatrix} + 0 \cdot \det \begin{pmatrix} -1 & 2 \\ 0 & -1 \end{pmatrix} \\ &= 2 \cdot (4 - 1) + 1 \cdot ((-1)(2) - (-1)(0)) + 0 = 2 \cdot 3 + 1 \cdot (-2) = 6 - 2 = 4 > 0. \end{aligned}$$

Los tres menores son positivos: A es *definida positiva*. En cambio, $-A$ tiene menores $-2 < 0$, $3 > 0$, $-4 < 0$ (alternan empezando en negativo): $-A$ es definida negativa, como debía ser.

Estrategia de examen

Receta de examen para clasificar una matriz simétrica A (típicamente una Hessiana):

1. *Mira la diagonal primero.* Si hay entradas de ambos signos en la diagonal, A ya es indefinida (pues $e_i^\top A e_i = a_{ii}$), y terminaste. Si algún $a_{ii} = 0$, A no puede ser definida (ni positiva ni negativa); si además la fila i es no nula, tampoco es semidefinida.
2. *Para definitud estricta, usa Sylvester:* calcula $D_1, D_2, \dots, D_n$ en orden. Todos positivos $\Rightarrow$ dp; alternando $-, +, -, \dots \Rightarrow$ dn. Si algún D_k rompe con desigualdad estricta los dos patrones a la vez (por ejemplo, $D_k < 0$ con k par: contradice tanto dp como dn), A es indefinida.
3. *Si aparece algún $D_k = 0$,* o si el patrón se rompe sin contradecir ambos casos, Sylvester líder no decide: pasa a todos los menores principales (o a autovalores) para distinguir semidefinida de indefinida.
4. *En 2×2 hay atajo:* $\det A > 0$ y $a_{11} > 0 \Rightarrow$ dp; $\det A > 0$ y $a_{11} < 0 \Rightarrow$ dn; $\det A < 0 \Rightarrow$ indefinida (el determinante es el producto de autovalores: signo negativo de los autovalores de signos opuestos).
5. *Conexión con el curso:* Hessiana dn en todo el dominio (convexo y abierto) $\Rightarrow f$ estrictamente cóncava $\Rightarrow$ el punto crítico del problema del consumidor/principal es el máximo global único. Esta cadena se demuestra en los capítulos siguientes; memoriza desde ya el flujo lógico.

Observación 1.44. En Microeconomía la definitud aparece por todas partes: la condición de segundo orden del consumidor es que la Hessiana del lagrangiano sea definida negativa sobre el espacio tangente a la restricción (Hessiana orlada); la aversión al riesgo de un agente con utilidad de Bernoulli u es $u'' < 0$ (caso 1×1 de definitud negativa); la ley de la oferta viene de que la matriz de sustitución de Slutsky es semidefinida negativa [9, cap. 3]. Dominar esta sección paga dividendos todo el año.

Resumen del capítulo

Resultados clave del capítulo, con sus hipótesis exactas:

- **Espacio vectorial** (Def. 1.1): conjunto con suma y producto por escalar cumpliendo (A1)–(A8). $\mathbb{R}^n$ lo es; $\mathbb{R}_+^n$ no (falla con escalares negativos). $\dim \mathbb{R}^n = n$, con base

canónica $e_1, \dots, e_n$.

- **Cauchy–Schwarz** (Teo. 1.10): para *todos* $x, y \in \mathbb{R}^n$, $|\langle x, y \rangle| \leq \|x\| \|y\|$, con igualdad si y solo si son linealmente dependientes. De ahí la desigualdad triangular y la buena definición del ángulo.
- **Norma** (Def. 1.9): positividad, homogeneidad absoluta, triangular. $\|\cdot\|_1, \|\cdot\|, \|\cdot\|_\infty$ son normas y todas las normas de $\mathbb{R}^n$ son equivalentes.
- **Heine–Borel** (Teo. 1.20): en $\mathbb{R}^n$ (¡solo en dimensión finita!), compacto $\Leftrightarrow$ cerrado y acotado. **Bolzano–Weierstrass** (Teo. 1.21): toda sucesión acotada en $\mathbb{R}^n$ tiene subsucesión convergente.
- **Weierstrass** (Teo. 1.24): si K es compacto *no vacío* y $f : K \rightarrow \mathbb{R}$ es *continua*, entonces f alcanza máximo y mínimo en K . Aplicación: con $p \gg 0$, $m > 0$ y utilidad continua, la demanda del consumidor existe.
- **Gradiente** (Prop. 1.29): si f es diferenciable y $\nabla f(x_0) \neq 0$, la dirección de máximo crecimiento es $\nabla f(x_0) / \|\nabla f(x_0)\|$ con tasa $\|\nabla f(x_0)\|$; el gradiente es ortogonal a las curvas de nivel (de indiferencia).
- **Taylor** (Teo. 1.33): si $f \in C^1$, $f(x_0 + v) = f(x_0) + \langle \nabla f(x_0), v \rangle + o(\|v\|)$; si $f \in C^2$, se agrega $\frac{1}{2}v^\top \nabla^2 f(x_0)v$ con resto $o(\|v\|^2)$ (o resto de Lagrange exacto en un punto intermedio). Si $f \in C^2$, la Hessiana es *simétrica* (Schwarz).
- **Definitud** (Teo. 1.38 y 1.41): A simétrica es dp/dn si y solo si todos sus autovalores son $> 0 / < 0$; equivalentemente (Sylvester), si sus menores líderes cumplen $D_k > 0$ para todo k / $(-1)^k D_k > 0$ para todo k . Para *semidefinitud* se requieren *todos* los menores principales, no solo los líderes.

1.6. Ejercicios tipo examen [P1]

Ejercicio 1.45. Sean $v_1 = (1, 1, 0)$, $v_2 = (0, 1, 1)$ y $v_3 = (1, 0, 1)$ en $\mathbb{R}^3$. (a) Demuestra que son linealmente independientes. (b) Concluye que forman una base de $\mathbb{R}^3$ y expresa el vector $x = (2, 3, 5)$ como combinación lineal de ellos.

Solución. (a) Planteamos $\lambda_1 v_1 + \lambda_2 v_2 + \lambda_3 v_3 = 0$:

$$\lambda_1(1, 1, 0) + \lambda_2(0, 1, 1) + \lambda_3(1, 0, 1) = (\lambda_1 + \lambda_3, \lambda_1 + \lambda_2, \lambda_2 + \lambda_3) = (0, 0, 0),$$

que da el sistema $\lambda_1 + \lambda_3 = 0$, $\lambda_1 + \lambda_2 = 0$, $\lambda_2 + \lambda_3 = 0$. De la primera, $\lambda_3 = -\lambda_1$; de la segunda, $\lambda_2 = -\lambda_1$. Sustituyendo ambas en la tercera: $-\lambda_1 - \lambda_1 = -2\lambda_1 = 0$, luego $\lambda_1 = 0$ y por tanto $\lambda_2 = \lambda_3 = 0$. Solo hay solución trivial: los vectores son linealmente independientes.

(b) Tres vectores independientes en un espacio de dimensión 3 forman base. Buscamos μ_1, μ_2, μ_3 con $\mu_1 v_1 + \mu_2 v_2 + \mu_3 v_3 = (2, 3, 5)$, es decir

$$\mu_1 + \mu_3 = 2, \quad \mu_1 + \mu_2 = 3, \quad \mu_2 + \mu_3 = 5.$$

Sumando las tres ecuaciones: $2(\mu_1 + \mu_2 + \mu_3) = 10$, o sea $\mu_1 + \mu_2 + \mu_3 = 5$. Restando de esta cada ecuación original: $\mu_2 = 5 - 2 = 3$, $\mu_3 = 5 - 3 = 2$, $\mu_1 = 5 - 5 = 0$. Verificación: $0 \cdot (1, 1, 0) + 3 \cdot (0, 1, 1) + 2 \cdot (1, 0, 1) = (0 + 0 + 2, 0 + 3 + 0, 0 + 3 + 2) = (2, 3, 5)$. Correcto: $x = 0v_1 + 3v_2 + 2v_3$. $\square$

Ejercicio 1.46. Sean $x = (3, -1, 2)$ e $y = (1, 2, -2)$ en $\mathbb{R}^3$. (a) Calcula $\langle x, y \rangle$, $\|x\|$, $\|y\|$, $\|x\|_1$ y $\|y\|_\infty$. (b) Verifica numéricamente la desigualdad de Cauchy–Schwarz y la desigualdad triangular para x e y . (c) ¿Son x e y ortogonales?

Solución. (a) $\langle x, y \rangle = 3 \cdot 1 + (-1) \cdot 2 + 2 \cdot (-2) = 3 - 2 - 4 = -3$. $\|x\| = \sqrt{3^2 + (-1)^2 + 2^2} = \sqrt{9 + 1 + 4} = \sqrt{14}$. $\|y\| = \sqrt{1^2 + 2^2 + (-2)^2} = \sqrt{1 + 4 + 4} = \sqrt{9} = 3$. $\|x\|_1 = |3| + |-1| + |2| = 6$. $\|y\|_\infty = \max\{1, 2, 2\} = 2$.

(b) Cauchy–Schwarz: $|\langle x, y \rangle| = 3$ y $\|x\| \|y\| = 3\sqrt{14} \approx 3 \times 3.742 = 11.22$; en efecto $3 \leq 11.22$. Triangular: $x + y = (4, 1, 0)$, así que $\|x + y\| = \sqrt{16 + 1 + 0} = \sqrt{17} \approx 4.12$, mientras que $\|x\| + \|y\| = \sqrt{14} + 3 \approx 6.74$; en efecto $4.12 \leq 6.74$.

(c) No: $x \perp y$ exigiría $\langle x, y \rangle = 0$, pero $\langle x, y \rangle = -3 \neq 0$. (El ángulo entre ellos es obtuso, pues el coseno $= -3/(3\sqrt{14}) = -1/\sqrt{14} < 0$.) $\square$

Ejercicio 1.47. Para cada conjunto, determina si es cerrado, acotado y compacto, justificando con Heine–Borel:

$$(a) A = \{x \in \mathbb{R}_+^2 : 2x_1 + 3x_2 \leq 12\}; \quad (b) B = \{x \in \mathbb{R}^2 : x_1 > 0, x_2 > 0, x_1x_2 \geq 1\};$$

$$(c) C = \{x \in \mathbb{R}_+^2 : 0 \cdot x_1 + 3x_2 \leq 12\}.$$

¿En cuáles de ellos garantiza Weierstrass que toda función continua alcanza su máximo?

Solución. (a) A es el conjunto presupuestario con $p = (2, 3) \gg 0$, $m = 12$. *Cerrado*: está definido por las desigualdades no estrictas $x_1 \geq 0$, $x_2 \geq 0$, $2x_1 + 3x_2 \leq 12$ con funciones continuas; los límites preservan desigualdades no estrictas, así que contiene los límites de sus sucesiones. *Acotado*: como $x_2 \geq 0$, $2x_1 \leq 2x_1 + 3x_2 \leq 12$ da $0 \leq x_1 \leq 6$; análogamente $0 \leq x_2 \leq 4$; luego $\|x\| \leq \sqrt{36 + 16} = \sqrt{52}$. Por Heine–Borel, A es *compacto*.

(b) *Cerrado*: sí. Aunque aparecen desigualdades estrictas $x_1 > 0$, $x_2 > 0$, estas son *consecuencia* de $x_1x_2 \geq 1$ con $x_1, x_2 > 0$: si $x^k \in B$ y $x^k \rightarrow x$, entonces $x_1x_2 = \lim x_1^k x_2^k \geq 1$, lo que fuerza $x_1 \neq 0 \neq x_2$; junto con $x_i = \lim x_i^k \geq 0$ se obtiene $x \in B$. *Acotado*: no; los puntos $(k, 1/k) \in B$ tienen $\|(k, 1/k)\| \geq k \rightarrow \infty$. Por Heine–Borel, B *no es compacto* (este B es el conjunto “al menos tan bueno como” de una Cobb–Douglas: cerrado pero no acotado).

(c) Aquí el precio del bien 1 es cero. C es cerrado (mismo argumento que en (a)), pero *no acotado*: $(k, 0) \in C$ para todo k . No es compacto.

Weierstrass se aplica con garantía solo en (a): compacto, no vacío. En (b) y (c) puede fallar la existencia de máximo; p.ej. $f(x) = x_1$ no alcanza máximo ni en B ni en C . $\square$

Ejercicio 1.48. Sea $f(x, y) = \ln x + \ln y$ (la transformación logarítmica de una Cobb–Douglas), definida para $x, y > 0$. (a) Calcula $\nabla f(x, y)$ y $\nabla^2 f(x, y)$. (b) Escribe la aproximación de Taylor de segundo orden de f alrededor del punto $(1, 1)$. (c) Úsala para aproximar $f(1.1, 0.9)$ y compara con el valor exacto $f(1.1, 0.9) = \ln(0.99) \approx -0.01005$.

Solución. (a) $\frac{\partial f}{\partial x} = \frac{1}{x}$ y $\frac{\partial f}{\partial y} = \frac{1}{y}$, luego $\nabla f(x, y) = (\frac{1}{x}, \frac{1}{y})$. Derivando otra vez: $\frac{\partial^2 f}{\partial x^2} = -\frac{1}{x^2}$, $\frac{\partial^2 f}{\partial y^2} = -\frac{1}{y^2}$, y las cruzadas son 0 (en $\partial f/\partial x = 1/x$ no aparece y). Así

$$\nabla^2 f(x, y) = \begin{pmatrix} -1/x^2 & 0 \\ 0 & -1/y^2 \end{pmatrix}.$$

(b) En $(1, 1)$: $f(1, 1) = \ln 1 + \ln 1 = 0$, $\nabla f(1, 1) = (1, 1)$, $\nabla^2 f(1, 1) = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$. Con $v = (h, k) = (x - 1, y - 1)$, Taylor de orden 2 da

$$f(1 + h, 1 + k) \approx 0 + \langle (1, 1), (h, k) \rangle + \frac{1}{2} \begin{pmatrix} h & k \end{pmatrix} \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} h \\ k \end{pmatrix} = h + k - \frac{1}{2}(h^2 + k^2).$$

(c) Para $(x, y) = (1.1, 0.9)$: $h = 0.1$, $k = -0.1$. Entonces

$$f(1.1, 0.9) \approx 0.1 + (-0.1) - \frac{1}{2}(0.1^2 + (-0.1)^2) = 0 - \frac{1}{2}(0.01 + 0.01) = -0.01.$$

El valor exacto es $\ln(1.1 \times 0.9) = \ln 0.99 \approx -0.01005$: el error de la aproximación es de orden 10^{-5} , consistente con un resto $o(\|v\|^2)$ para $\|v\| \approx 0.14$. Nota que la Hessiana es definida negativa en todo el dominio ($-1/x^2 < 0$ y determinante $1/(x^2 y^2) > 0$ con $D_1 < 0$): anticipo de que f es estrictamente cóncava, la propiedad que hace único al óptimo del consumidor. $\square$

Ejercicio 1.49. Clasifica según su definitud (definida positiva/negativa, semidefinida, indefinida):

$$(a) A = \begin{pmatrix} -2 & 1 \\ 1 & -3 \end{pmatrix}, \quad (b) B = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}, \quad (c) C = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 3 \end{pmatrix}.$$

Para (b), encuentra además los autovalores y un vector v con $v^\top B v < 0$.

Solución. (a) Menores líderes: $D_1 = -2 < 0$; $D_2 = (-2)(-3) - 1 \cdot 1 = 6 - 1 = 5 > 0$. Alternan empezando en negativo: A es *definida negativa*. (Como Hessiana, indicaría máximo local estricto en un punto crítico.)

(b) $D_1 = 1 > 0$, pero $D_2 = 1 \cdot 1 - 2 \cdot 2 = 1 - 4 = -3 < 0$. Un determinante negativo en 2×2 significa autovalores de signos opuestos: B es *indefinida*. Autovalores: $\det(B - \lambda I) = (1 - \lambda)^2 - 4 = \lambda^2 - 2\lambda - 3 = (\lambda - 3)(\lambda + 1) = 0$, luego $\lambda_1 = 3 > 0 > \lambda_2 = -1$, confirmando la indefinición. Un vector con forma cuadrática negativa: el autovector de $\lambda_2 = -1$ resuelve $(B + I)v = 0$, es decir $\begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} v = 0$, por ejemplo $v = (1, -1)$. Comprobación: la forma cuadrática de B es $Q_B(v) = v_1^2 + 4v_1v_2 + v_2^2$ (el 4 es $2b_{12}$), de modo que $Q_B(1, -1) = 1 - 4 + 1 = -2 < 0$. (Y con $w = (1, 1)$: $Q_B(1, 1) = 1 + 4 + 1 = 6 > 0$, lo que confirma la indefinición.)

(c) $D_1 = 1 > 0$. $D_2 = 1 \cdot 2 - 1 \cdot 1 = 1 > 0$. $D_3 = \det C$, expandiendo por la primera fila:

$$D_3 = 1 \cdot \det \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} - 1 \cdot \det \begin{pmatrix} 1 & 1 \\ 0 & 3 \end{pmatrix} + 0 = 1(6 - 1) - 1(3 - 0) = 5 - 3 = 2 > 0.$$

Los tres menores líderes son positivos: C es *definida positiva*. $\square$

Ejercicio 1.50. (Existencia y no existencia de demanda.) Un consumidor tiene utilidad $u(x_1, x_2) = x_1 + \ln(1 + x_2)$ sobre $\mathbb{R}_+^2$, riqueza $m = 10$ y enfrenta precios $p = (p_1, p_2)$. (a) Si $p = (1, 2)$, demuestra que el problema $\max\{u(x) : x \in \mathbb{R}_+^2, \langle p, x \rangle \leq 10\}$ tiene solución. (b) Si $p = (0, 2)$ (el bien 1 es gratuito), demuestra que *no* tiene solución. (c) Explica qué hipótesis de Weierstrass falla en (b).

Solución. (a) La función u es continua en $\mathbb{R}_+^2$: x_1 es continua (polinomio) y $\ln(1 + x_2)$ es composición del polinomio continuo $1 + x_2$ (que toma valores $\geq 1 > 0$) con $\ln$, continua en $(0, \infty)$; la suma de continuas es continua. El conjunto factible $B((1, 2), 10) = \{x \in \mathbb{R}_+^2 : x_1 + 2x_2 \leq 10\}$ es cerrado (desigualdades no estrictas de funciones continuas) y acotado: de $x_1, x_2 \geq 0$ y $x_1 + 2x_2 \leq 10$ salen $0 \leq x_1 \leq 10$ y $0 \leq x_2 \leq 5$. Por Heine–Borel es compacto, y es no vacío pues contiene a $(0, 0)$. Por el teorema de Weierstrass (Teo. 1.24), u alcanza su máximo: la demanda existe.

(b) Con $p = (0, 2)$ el conjunto factible es $F = \{x \in \mathbb{R}_+^2 : 2x_2 \leq 10\} = [0, \infty) \times [0, 5]$. Sobre F , tomando la sucesión $x^k = (k, 0)$ se tiene $u(x^k) = k + \ln 1 = k \rightarrow \infty$: la utilidad no está acotada superiormente en F , así que no existe ninguna cesta factible que sea máxima (cualquier candidata x es superada por $(x_1 + 1, x_2)$, que sigue siendo factible y da utilidad estrictamente mayor).

(c) Falla la *compacidad* del conjunto factible: F es cerrado pero *no acotado* en la dirección del bien gratuito, de modo que Heine–Borel no da compacidad y Weierstrass no se aplica. Moraleja económica: la existencia de demanda exige precios estrictamente positivos (o preferencias saciables); por eso en equilibrio general los teoremas de existencia cuidan que los bienes deseables tengan precio positivo [9, cap. 17]. $\square$

Capítulo 2

Conjuntos convexos y conjuntos afines [P2]

Semana 1 del cronograma. Bibliografía: Boyd y Vandenberghe [2]; Brinkhuis [3]; Ruszczyński [6].

¿Para qué sirve esto en Microeconomía?

Este capítulo es la base geométrica de casi todo lo que verás en Microeconomía. En **equilibrio general** (MWG caps. 15–18), la convexidad es *la* hipótesis que hace funcionar la teoría: el conjunto presupuestario $\{x \geq 0 : p \cdot x \leq m\}$ es convexo (lo demostramos en el Ejemplo 2.8); la convexidad de las preferencias y de los conjuntos de producción es la condición clave para la existencia de equilibrio walrasiano y para el *segundo teorema del bienestar* (todo óptimo de Pareto es descentralizable con precios), pues ambos resultados descansan en separar conjuntos convexos con hiperplanos (MWG, caps. 15–18, [9]). La caja de Edgeworth es un producto cartesiano de conjuntos convexos, y la *suma de Minkowski* $Y_1 + \dots + Y_J$ es exactamente cómo se agrega la tecnología de J empresas en una economía de producción (MWG, cap. 5). En **teoría de contratos** (MWG cap. 14), los conjuntos de pagos alcanzables mediante contratos aleatorios son combinaciones convexas de pagos puros. En **diseño de mecanismos** (MWG cap. 23), el conjunto de loterías sobre n resultados es el simplex de probabilidades Δ^{n-1} , un conjunto convexo compacto: sin ese hecho no se puede siquiera plantear la utilidad esperada ni los mecanismos aleatorios. Dominar este capítulo es dominar el idioma en que está escrita la microeconomía.

Antes de optimizar funciones necesitamos entender *sobre qué conjuntos* optimizamos. La idea central del curso es que los problemas de optimización se vuelven manejables cuando el conjunto factible es *convexo*: un conjunto sin “huecos” ni “entrantes”, en el que el promedio de dos opciones factibles sigue siendo factible. Este capítulo desarrolla esa idea desde cero: segmentos, combinaciones convexas, conjuntos convexos y afines, las operaciones que preservan la convexidad y las propiedades topológicas (interior, clausura, interior relativo) que usaremos más adelante en los teoremas de separación. Las referencias principales son [3] (cap. 2), [2] (cap. 2, secciones 2.1–2.3), [6] (cap. 2) y [1] (cap. 1). Todo lo que necesitamos del capítulo de preliminares es: la norma euclidiana $\|x\|$, el producto interno $\langle x, y \rangle$, la desigualdad triangular,

y las nociones de bola abierta, interior, clausura y frontera en $\mathbb{R}^n$.

2.1. Segmentos y combinaciones convexas [P1]

2.1.1. El segmento entre dos puntos

Empecemos con la pregunta más elemental posible: dados dos puntos x e y en $\mathbb{R}^n$, ¿cómo describimos algebraicamente el segmento de recta que los une? La idea es “caminar” de x hacia y : partimos de x , y el vector que apunta de x a y es $y - x$. Si avanzamos una fracción λ del camino (con $0 \leq \lambda \leq 1$), llegamos al punto

$$x + \lambda(y - x) = x + \lambda y - \lambda x = (1 - \lambda)x + \lambda y.$$

Observa el paso algebraico: distribuimos $\lambda(y - x) = \lambda y - \lambda x$ y luego agrupamos los términos con x , obteniendo $(1 - \lambda)x$. Cuando $\lambda = 0$ estamos en x ; cuando $\lambda = 1$ estamos en y ; cuando $\lambda = 1/2$ estamos exactamente en el punto medio.

Definición 2.1 (Segmento). Dados $x, y \in \mathbb{R}^n$, el *segmento* (*line segment*) que une x con y es el conjunto

$$[x, y] = \{ (1 - \lambda)x + \lambda y : \lambda \in [0, 1] \}.$$

Escribimos $[x, y)$ para el segmento que incluye a x pero no a y , es decir, tomando $\lambda \in [0, 1)$.

Ejemplo 2.2. Sean $x = (1, 2)$ e $y = (5, 4)$ en $\mathbb{R}^2$. El punto del segmento correspondiente a $\lambda = 1/4$ es

$$(1 - \frac{1}{4})(1, 2) + \frac{1}{4}(5, 4) = \frac{3}{4}(1, 2) + \frac{1}{4}(5, 4) = \left(\frac{3}{4} + \frac{5}{4}, \frac{6}{4} + \frac{4}{4}\right) = (2, 2.5).$$

Verifiquemos cada coordenada: la primera es $\frac{3}{4} \cdot 1 + \frac{1}{4} \cdot 5 = \frac{3}{4} + \frac{5}{4} = \frac{8}{4} = 2$; la segunda es $\frac{3}{4} \cdot 2 + \frac{1}{4} \cdot 4 = \frac{6}{4} + \frac{4}{4} = \frac{10}{4} = 2.5$. El punto $(2, 2.5)$ está a un cuarto del camino de x hacia y .

2.1.2. Combinaciones convexas: promedios ponderados y loterías

La expresión $(1 - \lambda)x + \lambda y$ es un *promedio ponderado* de x e y : los pesos son $1 - \lambda$ y λ , ambos no negativos y sumando 1. La generalización natural a k puntos es inmediata.

Definición 2.3 (Combinación convexa). Una *combinación convexa* (*convex combination*) de los puntos $x_1, \dots, x_k \in \mathbb{R}^n$ es cualquier punto de la forma

$$\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k, \quad \text{con } \lambda_i \geq 0 \text{ para todo } i \text{ y } \sum_{i=1}^k \lambda_i = 1.$$

Los números $\lambda_1, \dots, \lambda_k$ se llaman *pesos* o *ponderaciones*.

Intuición

Una combinación convexa es un *promedio ponderado*, y en economía los promedios ponderados con pesos no negativos que suman uno tienen un nombre: **loterías**. Si $x_1, \dots, x_k$

son k canastas (o pagos, o asignaciones) y λ_i es la probabilidad de recibir la canasta x_i , entonces la combinación convexa $\sum_i \lambda_i x_i$ es la *canasta esperada* de la lotería. Por eso, cuando en Microeconomía (elección bajo incertidumbre, MWG cap. 6) digas “el conjunto de loterías sobre k resultados”, estarás diciendo, en el idioma de este curso, “el conjunto de todas las combinaciones convexas de k puntos”. También puedes pensarlo físicamente: $\sum_i \lambda_i x_i$ es el *centro de masa* de un sistema de partículas ubicadas en los puntos x_i con masas λ_i .

Ejemplo 2.4 (Una lotería sobre tres pagos). Un contrato aleatorio paga al agente uno de tres montos: $x_1 = 100$, $x_2 = 400$ o $x_3 = 900$ (en soles), con probabilidades $\lambda_1 = 0.5$, $\lambda_2 = 0.3$, $\lambda_3 = 0.2$. Primero verificamos que los pesos son válidos: todos son no negativos y $0.5 + 0.3 + 0.2 = 1$. El pago esperado es la combinación convexa

$$0.5 \cdot 100 + 0.3 \cdot 400 + 0.2 \cdot 900 = 50 + 120 + 180 = 350.$$

Nota que 350 está entre el mínimo (100) y el máximo (900) de los pagos: toda combinación convexa de números reales cae entre el menor y el mayor de ellos. Esta es la versión unidimensional de un hecho general: las combinaciones convexas nunca “se salen” del conjunto de puntos originales en ninguna dirección.

2.2. Conjuntos convexos: definición y ejemplos [P1]

2.2.1. La definición

Definición 2.5 (Conjunto convexo). Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* (*convex set*) si para todo par de puntos $x, y \in C$ y todo $\lambda \in [0, 1]$ se cumple

$$(1 - \lambda)x + \lambda y \in C,$$

es decir, si $[x, y] \subseteq C$ para todos $x, y \in C$: el segmento que une cualquier par de puntos del conjunto está contenido en el conjunto. El conjunto vacío y los conjuntos de un solo punto son convexas: la condición se cumple trivialmente porque no hay pares que verificar, o porque el único segmento posible es el propio punto.




Figura 2.1: A la izquierda, un conjunto convexo: el segmento entre dos puntos cualesquiera queda dentro. A la derecha, un conjunto con forma de luna: el segmento punteado entre x e y sale del conjunto.

Estrategia de examen

Para **demostrar** que un conjunto C es convexo, la receta es siempre la misma y conviene memorizarla como un ritual de tres pasos:

- (1) Toma dos puntos *arbitrarios* $x, y \in C$ y un $\lambda \in [0, 1]$ arbitrario. Escribe explícitamente qué significa que x e y pertenezcan a C (las desigualdades o ecuaciones que definen a C).
- (2) Forma el punto $z = (1 - \lambda)x + \lambda y$ y *verifica que z satisface la definición de C* , usando las propiedades de x e y del paso (1). Las herramientas típicas son: linealidad del producto interno, desigualdad triangular, y que sumar/multiplicar desigualdades por números no negativos las preserva.
- (3) Concluye: como x, y, λ eran arbitrarios, C es convexo.

Para **refutar** la convexidad basta *un* contraejemplo concreto: dos puntos del conjunto y un valor de λ (casi siempre sirve $\lambda = 1/2$) tales que el punto intermedio no pertenece al conjunto. En un examen, exhibir el contraejemplo numérico completo vale todos los puntos; decir “se ve en el dibujo” no vale ninguno.

2.2.2. Ejemplos fundamentales, resueltos paso a paso

Ejemplo 2.6 (La bola es convexa). Sea $\bar{B}(c, r) = \{x \in \mathbb{R}^n : \|x - c\| \leq r\}$ la bola cerrada de centro c y radio $r > 0$ (misma notación que en el capítulo de preliminares: B para la bola abierta, $\bar{B}$ para la cerrada). Afirmamos que $\bar{B}(c, r)$ es convexa.

Paso 1. Tomemos $x, y \in \bar{B}(c, r)$ y $\lambda \in [0, 1]$ arbitrarios. Por definición de la bola, sabemos que $\|x - c\| \leq r$ y $\|y - c\| \leq r$.

Paso 2. Sea $z = (1 - \lambda)x + \lambda y$. Debemos probar que $\|z - c\| \leq r$. El truco clave es escribir c como combinación convexa de sí mismo: $c = (1 - \lambda)c + \lambda c$ (esto es cierto porque $(1 - \lambda) + \lambda = 1$). Entonces

$$z - c = (1 - \lambda)x + \lambda y - [(1 - \lambda)c + \lambda c] = (1 - \lambda)(x - c) + \lambda(y - c),$$

donde en el último paso simplemente agrupamos los términos que tienen factor $(1 - \lambda)$ y los que tienen factor λ . Ahora aplicamos la desigualdad triangular ($\|u + v\| \leq \|u\| + \|v\|$) y la homogeneidad de la norma ($\|\alpha u\| = |\alpha| \|u\|$, recordando que $1 - \lambda \geq 0$ y $\lambda \geq 0$, así que los valores absolutos sobran):

$$\|z - c\| = \|(1 - \lambda)(x - c) + \lambda(y - c)\| \leq (1 - \lambda) \|x - c\| + \lambda \|y - c\| \leq (1 - \lambda)r + \lambda r = r.$$

En la última desigualdad usamos $\|x - c\| \leq r$ y $\|y - c\| \leq r$, multiplicadas por los números no negativos $1 - \lambda$ y λ (lo cual preserva las desigualdades), y luego $(1 - \lambda)r + \lambda r = r[(1 - \lambda) + \lambda] = r \cdot 1 = r$.

Paso 3. Como $\|z - c\| \leq r$, tenemos $z \in \bar{B}(c, r)$. Concluimos que $\bar{B}(c, r)$ es convexa. El mismo argumento, cambiando $\leq$ por $<$, muestra que la bola *abierta* también es convexa.

Ejemplo 2.7 (Hiperplanos y semiespacios). Sea $a \in \mathbb{R}^n$ con $a \neq 0$ y sea $b \in \mathbb{R}$. El *hiperplano*

(*hyperplane*) de vector normal a y nivel b es

$$H = \{x \in \mathbb{R}^n : \langle a, x \rangle = b\},$$

y los *semiespacios* (*half-spaces*) asociados son $H^- = \{x : \langle a, x \rangle \leq b\}$ y $H^+ = \{x : \langle a, x \rangle \geq b\}$. En $\mathbb{R}^2$, un hiperplano es una recta; en $\mathbb{R}^3$, un plano. Probemos que H^- es convexo (el argumento para H y H^+ es idéntico).

Sean $x, y \in H^-$ y $\lambda \in [0, 1]$. Entonces $\langle a, x \rangle \leq b$ y $\langle a, y \rangle \leq b$. Usando la *linealidad del producto interno* (vista en el capítulo de preliminares: $\langle a, \alpha u + \beta v \rangle = \alpha \langle a, u \rangle + \beta \langle a, v \rangle$):

$$\langle a, (1 - \lambda)x + \lambda y \rangle = (1 - \lambda) \langle a, x \rangle + \lambda \langle a, y \rangle \leq (1 - \lambda)b + \lambda b = b,$$

donde de nuevo multiplicamos las desigualdades $\langle a, x \rangle \leq b$, $\langle a, y \rangle \leq b$ por los pesos no negativos y sumamos. Por lo tanto $(1 - \lambda)x + \lambda y \in H^-$: el semiespacio es convexo. Para H se obtiene igualdad en lugar de desigualdad, así que H también es convexo. *Interpretación económica:* si $a = p$ es un vector de precios y $b = m$ es el ingreso, H^- es el conjunto de canastas cuyo gasto no excede el ingreso; el hiperplano H es la *recta presupuestaria*, las canastas que agotan exactamente el ingreso.

Ejemplo 2.8 (El conjunto presupuestario es convexo). Sea $p \in \mathbb{R}^n$ un vector de precios con $p \gg 0$ (todas las coordenadas positivas) y $m > 0$ el ingreso del consumidor. El *conjunto presupuestario* (*budget set*) es

$$B(p, m) = \{x \in \mathbb{R}^n : x \geq 0, p \cdot x \leq m\},$$

donde $x \geq 0$ significa $x_i \geq 0$ para cada bien i , y $p \cdot x = \langle p, x \rangle = \sum_{i=1}^n p_i x_i$ es el gasto total. *Demostración de convexidad.* Sean $x, y \in B(p, m)$ y $\lambda \in [0, 1]$; escribamos $z = (1 - \lambda)x + \lambda y$. Debemos verificar las dos condiciones que definen a $B(p, m)$.

(i) *No negatividad.* Para cada coordenada i : como $x_i \geq 0$, $y_i \geq 0$, $1 - \lambda \geq 0$ y $\lambda \geq 0$, el número $z_i = (1 - \lambda)x_i + \lambda y_i$ es suma de dos productos de números no negativos, luego $z_i \geq 0$. Así $z \geq 0$.

(ii) *Restricción de gasto.* Por linealidad del producto interno,

$$p \cdot z = p \cdot [(1 - \lambda)x + \lambda y] = (1 - \lambda)(p \cdot x) + \lambda(p \cdot y) \leq (1 - \lambda)m + \lambda m = m,$$

usando $p \cdot x \leq m$ y $p \cdot y \leq m$. Por (i) y (ii), $z \in B(p, m)$, y el conjunto presupuestario es convexo. De hecho, acabamos de verificar en un caso concreto un principio general que probaremos en el Teorema 2.18: $B(p, m)$ es la intersección de $n + 1$ semiespacios ($x_i \geq 0$ para cada i , más $p \cdot x \leq m$), y la intersección de convexos es convexa. La interpretación económica es importante: si dos canastas son asequibles, cualquier “mezcla” (promedio ponderado) de ellas también lo es. Sin esta propiedad, el problema del consumidor de MWG cap. 3 [9] perdería casi toda su estructura.

Ejemplo 2.9 (Poliedros). Un *poliedro* (*polyhedron*) es una intersección finita de semiespacios e hiperplanos:

$$P = \{x \in \mathbb{R}^n : \langle a_j, x \rangle \leq b_j, j = 1, \dots, s; \langle c_k, x \rangle = d_k, k = 1, \dots, t\}.$$




Figura 2.2: El conjunto presupuestario con dos bienes: un triángulo, que es la intersección de tres semiespacios ($x_1 \geq 0$, $x_2 \geq 0$, $p \cdot x \leq m$). El segmento entre dos canastas asequibles queda dentro del conjunto.

Como cada semiespacio y cada hiperplano es convexo (Ejemplo 2.7) y la intersección de convexos es convexa (Teorema 2.18 más abajo), todo poliedro es convexo. El conjunto presupuestario del Ejemplo 2.8 es un poliedro; también lo son los conjuntos factibles de los problemas de programación lineal [2].

Ejemplo 2.10 (El simplex de probabilidades). El *simplex de probabilidades* (*probability simplex*) en $\mathbb{R}^n$ es

$$\Delta^{n-1} = \left\{ \pi \in \mathbb{R}^n : \pi_i \geq 0 \text{ para todo } i, \sum_{i=1}^n \pi_i = 1 \right\}.$$

Cada elemento de Δ^{n-1} es una *lotería*: una distribución de probabilidad sobre n resultados. Es un poliedro (n semiespacios $\pi_i \geq 0$ y un hiperplano $\sum_i \pi_i = 1$), luego es convexo. Verifiquémoslo también directamente para fijar el método: si $\pi, \sigma \in \Delta^{n-1}$ y $\lambda \in [0, 1]$, entonces cada coordenada de $\rho = (1 - \lambda)\pi + \lambda\sigma$ cumple $\rho_i = (1 - \lambda)\pi_i + \lambda\sigma_i \geq 0$, y

$$\sum_{i=1}^n \rho_i = (1 - \lambda) \sum_{i=1}^n \pi_i + \lambda \sum_{i=1}^n \sigma_i = (1 - \lambda) \cdot 1 + \lambda \cdot 1 = 1.$$

Interpretación: mezclar dos loterías con pesos $(1 - \lambda, \lambda)$ produce otra lotería (una “lotería compuesta”). Esta es la razón por la cual en diseño de mecanismos (MWG cap. 23) los mecanismos aleatorios viven en un conjunto convexo, y por la cual los axiomas de utilidad esperada se formulan sobre mezclas de loterías [9].

2.2.3. No-ejemplos

Ejemplo 2.11 (Dos conjuntos que no son convexos). (a) *El anillo*. Sea $A = \{x \in \mathbb{R}^2 : 1 \leq \|x\| \leq 2\}$ (una corona circular). Tomemos $x = (1, 0)$ e $y = (-1, 0)$; ambos cumplen $\|x\| = \|y\| = 1$, así que $x, y \in A$. Con $\lambda = 1/2$:

$$\frac{1}{2}(1, 0) + \frac{1}{2}(-1, 0) = (0, 0), \quad \|(0, 0)\| = 0 < 1,$$

de modo que el punto medio no pertenece a A . El anillo no es convexo: el “hueco” central rompe la convexidad.

(b) *Unión de dos bolas*. Sea $U = B((0, 0), 1) \cup B((4, 0), 1)$ en $\mathbb{R}^2$. Los puntos $x = (0, 0)$ e $y = (4, 0)$ están en U (cada uno es el centro de una bola). Con $\lambda = 1/2$, el punto medio es $(2, 0)$.

Pero $\|(2, 0) - (0, 0)\| = 2 > 1$ y $\|(2, 0) - (4, 0)\| = 2 > 1$, así que $(2, 0)$ no está en ninguna de las dos bolas y por tanto no está en U . La unión de convexos, en general, *no* es convexa (volveremos sobre esto en la Sección 2.4).

2.2.4. Convexidad y combinaciones de muchos puntos

La definición de convexidad solo pide que el conjunto contenga las combinaciones convexas de *dos* puntos. El siguiente resultado dice que eso basta para que contenga las de *cualquier* número finito de puntos. Es el análogo geométrico de un hecho que usarás mil veces: si las mezclas de dos loterías son admisibles, las mezclas de k loterías también.

Teorema 2.12 (Caracterización por combinaciones convexas). *Un conjunto $C \subseteq \mathbb{R}^n$ es convexo si y solo si toda combinación convexa de un número finito de puntos de C pertenece a C ; es decir, para todo $k \in \mathbb{N}$, todos $x_1, \dots, x_k \in C$ y todos $\lambda_1, \dots, \lambda_k \geq 0$ con $\sum_{i=1}^k \lambda_i = 1$ se tiene $\sum_{i=1}^k \lambda_i x_i \in C$.*

Demostración. ($\Leftarrow$) Es inmediato: el caso $k = 2$ es exactamente la definición de convexidad.

($\Rightarrow$) Supongamos que C es convexo y procedamos por inducción sobre k . *Caso base $k = 1$:* la única combinación es $1 \cdot x_1 = x_1 \in C$. *Caso $k = 2$:* es la definición. *Paso inductivo:* supongamos que el resultado vale para $k-1$ puntos ($k \geq 3$) y tomemos $x_1, \dots, x_k \in C$ con pesos $\lambda_1, \dots, \lambda_k \geq 0$ que suman 1. Si $\lambda_k = 1$, entonces todos los demás pesos son cero y la combinación es $x_k \in C$; listo. Si $\lambda_k < 1$, definamos $\mu = 1 - \lambda_k = \lambda_1 + \dots + \lambda_{k-1} > 0$ y escribamos

$$\sum_{i=1}^k \lambda_i x_i = \mu \underbrace{\sum_{i=1}^{k-1} \frac{\lambda_i}{\mu} x_i}_{=: y} + \lambda_k x_k.$$

Verifiquemos que y es una combinación convexa de $k-1$ puntos de C : los nuevos pesos λ_i/μ son no negativos (cociente de no negativos con denominador positivo) y suman

$$\sum_{i=1}^{k-1} \frac{\lambda_i}{\mu} = \frac{1}{\mu} \sum_{i=1}^{k-1} \lambda_i = \frac{\mu}{\mu} = 1.$$

Por la hipótesis inductiva, $y \in C$. Finalmente, $\sum_i \lambda_i x_i = \mu y + \lambda_k x_k = (1 - \lambda_k)y + \lambda_k x_k$ es una combinación convexa de los *dos* puntos $y, x_k \in C$, que pertenece a C por la definición de convexidad. Esto completa la inducción. $\square$

Intuición

El truco de la demostración anterior aparece por todas partes en teoría de la decisión: una lotería sobre k premios se puede “desarmar” como una lotería en dos etapas (primero decides entre “el premio k ” con probabilidad λ_k y “el resto” con probabilidad $1 - \lambda_k$; si sale “el resto”, juegas la lotería reducida sobre los $k-1$ premios restantes con probabilidades renormalizadas $\lambda_i/(1 - \lambda_k)$). El axioma de reducción de loterías compuestas de la utilidad esperada es exactamente esta identidad algebraica.

Definición 2.13 (Envoltura convexa). La *envoltura convexa* o *cápsula convexa* (*convex hull*) de un conjunto $S \subseteq \mathbb{R}^n$, denotada $\text{conv } S$, es el conjunto de todas las combinaciones convexas de puntos de S :

$$\text{conv } S = \left\{ \sum_{i=1}^k \lambda_i x_i : k \in \mathbb{N}, x_i \in S, \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1 \right\}.$$

Es el menor conjunto convexo que contiene a S (lo compruebas en el Ejercicio 2.38). Por ejemplo, $\Delta^{n-1} = \text{conv}\{e_1, \dots, e_n\}$, donde e_i son los vectores canónicos: toda lotería es una combinación convexa de las loterías degeneradas (las que dan un resultado con certeza).

2.3. Conjuntos afines y dimensión [P2]

2.3.1. Rectas en lugar de segmentos

Si en la definición de convexidad reemplazamos el *segmento* por la *recta completa*, permitiendo λ fuera de $[0, 1]$, obtenemos una clase más rígida de conjuntos.

Definición 2.14 (Conjunto afín). Un conjunto $M \subseteq \mathbb{R}^n$ es *afín* (*affine set*) si para todos $x, y \in M$ y *todo* $\lambda \in \mathbb{R}$ se cumple $(1-\lambda)x + \lambda y \in M$: la recta que pasa por dos puntos cualesquiera de M está contenida en M . Una *combinación afín* (*affine combination*) de $x_1, \dots, x_k$ es $\sum_i \lambda_i x_i$ con $\sum_i \lambda_i = 1$ pero *sin* exigir $\lambda_i \geq 0$.

Todo conjunto afín es convexo (si contiene la recta, contiene en particular el segmento), pero no al revés: la bola es convexa y no es afín. Los ejemplos típicos de conjuntos afines son: $\mathbb{R}^n$ entero, un punto, una recta, un plano en $\mathbb{R}^3$, y en general los hiperplanos $H = \{x : \langle a, x \rangle = b\}$ (repite el cálculo del Ejemplo 2.7 con $\lambda \in \mathbb{R}$: la igualdad se preserva para cualquier λ , no solo en $[0, 1]$).

Recordemos del capítulo de preliminares que un *subespacio vectorial* $V \subseteq \mathbb{R}^n$ es un conjunto que contiene al 0 y es cerrado bajo sumas y multiplicación por escalares. La relación entre conjuntos afines y subespacios es exactamente la que sugiere la geometría: un conjunto afín es un subespacio “desplazado” que ya no tiene por qué pasar por el origen.

Teorema 2.15 (Afín = subespacio trasladado). *Un conjunto no vacío $M \subseteq \mathbb{R}^n$ es afín si y solo si existe un subespacio vectorial $V \subseteq \mathbb{R}^n$ y un punto $x_0 \in M$ tales que*

$$M = x_0 + V := \{x_0 + v : v \in V\}.$$

Además, el subespacio $V = M - x_0 = \{x - x_0 : x \in M\}$ es el mismo sin importar qué punto $x_0 \in M$ se elija; se le llama el subespacio director de M .

Demostración. ($\Leftarrow$) Supongamos $M = x_0 + V$ con V subespacio. Tomemos $x = x_0 + v$, $y = x_0 + w$ con $v, w \in V$, y $\lambda \in \mathbb{R}$. Entonces

$$(1-\lambda)x + \lambda y = (1-\lambda)(x_0 + v) + \lambda(x_0 + w) = \underbrace{[(1-\lambda) + \lambda]}_{=1} x_0 + \underbrace{(1-\lambda)v + \lambda w}_{\in V},$$

donde el vector $(1 - \lambda)v + \lambda w$ pertenece a V porque V es cerrado bajo combinaciones lineales. Luego $(1 - \lambda)x + \lambda y \in x_0 + V = M$, y M es afín.

($\Rightarrow$) Supongamos que M es afín, fijemos cualquier $x_0 \in M$ y definamos $V = M - x_0$. Debemos verificar que V es un subespacio; comprobamos las tres propiedades.

(i) $0 \in V$: porque $0 = x_0 - x_0$ y $x_0 \in M$.

(ii) *Cerrado bajo escalares*: sea $v = x - x_0 \in V$ (con $x \in M$) y $\alpha \in \mathbb{R}$. Queremos ver que $\alpha v \in V$, es decir, que $x_0 + \alpha v \in M$. Escribimos

$$x_0 + \alpha v = x_0 + \alpha(x - x_0) = (1 - \alpha)x_0 + \alpha x,$$

que es un punto de la recta que pasa por $x_0, x \in M$; como M es afín, pertenece a M . Listo.

(iii) *Cerrado bajo sumas*: sean $v = x - x_0$ y $w = y - x_0$ en V , con $x, y \in M$. Queremos $v + w \in V$, o sea $x_0 + v + w \in M$. El truco es pasar por el punto medio y luego estirar. Primero, el punto medio $z = \frac{1}{2}x + \frac{1}{2}y$ está en M (es una combinación afín con $\lambda = 1/2$). Ahora notemos que

$$x_0 + v + w = x + y - x_0 = 2z - x_0 = (1 - 2)x_0 + 2z,$$

que es una combinación afín de $x_0, z \in M$ (los coeficientes son -1 y 2 , que suman 1 ; aquí es esencial que las combinaciones afines admiten pesos negativos). Como M es afín, $x_0 + v + w \in M$, es decir, $v + w \in V$.

Por (i)–(iii), V es subespacio y $M = x_0 + V$. *Unicidad de V* : si $x_1 \in M$ es otro punto, entonces para cada $x \in M$, $x - x_1 = (x - x_0) - (x_1 - x_0)$ es diferencia de dos elementos de V , luego está en V ; esto da $M - x_1 \subseteq V$, y el argumento simétrico da la otra inclusión. Así $M - x_1 = M - x_0 = V$. $\square$

Definición 2.16 (Envoltura afín y dimensión). La *envoltura afín* o *cápsula afín* (*affine hull*) de $S \subseteq \mathbb{R}^n$, denotada $\text{aff } S$, es el conjunto de todas las combinaciones afines de puntos de S ; es el menor conjunto afín que contiene a S . La *dimensión* de un conjunto afín $M = x_0 + V$ es la dimensión del subespacio director V (bien definida por el Teorema 2.15). La *dimensión de un conjunto convexo* C se define como $\dim C = \dim(\text{aff } C)$.

Ejemplo 2.17. Calculemos $\dim \Delta^2$, el simplex de loterías sobre 3 resultados, que vive en $\mathbb{R}^3$. Su envoltura afín es el hiperplano $H = \{\pi \in \mathbb{R}^3 : \pi_1 + \pi_2 + \pi_3 = 1\}$: en efecto, toda combinación afín de loterías sigue sumando 1 (mismo cálculo que en el Ejemplo 2.10), así que $\text{aff } \Delta^2 \subseteq H$; y recíprocamente puede verificarse que todo punto de H es combinación afín de los vértices e_1, e_2, e_3 (lo haces en el Ejercicio 2.35). Tomando $x_0 = e_1 = (1, 0, 0) \in H$, el subespacio director es $V = H - e_1 = \{v \in \mathbb{R}^3 : v_1 + v_2 + v_3 = 0\}$, que tiene dimensión 2 (una ecuación lineal independiente en $\mathbb{R}^3$ deja $3 - 1 = 2$ grados de libertad). Por tanto $\dim \Delta^2 = 2$: el simplex de tres resultados es un triángulo bidimensional “flotando” en $\mathbb{R}^3$. En general, $\dim \Delta^{n-1} = n - 1$, y esa es la razón del superíndice $n - 1$ en la notación. Guarda este ejemplo: será el protagonista cuando hablemos de interior relativo en la Sección 2.5.

2.4. Operaciones que preservan la convexidad [P1]

En la práctica casi nunca verificamos la convexidad “a mano” con la definición: reconocemos el conjunto como resultado de aplicar operaciones que preservan convexidad a bloques básicos (bolas, semiespacios, hiperplanos). Este es el “cálculo de conjuntos convexos” de [2], sección 2.3. Cada resultado de esta sección lo demostramos completo: son demostraciones cortas y son exactamente el tipo de pregunta de examen.

Teorema 2.18 (Intersección arbitraria). *Sea $\{C_i\}_{i \in I}$ una familia cualquiera (finita o infinita) de conjuntos convexos de $\mathbb{R}^n$. Entonces la intersección $C = \bigcap_{i \in I} C_i$ es convexa.*

Demostración. Sean $x, y \in C$ y $\lambda \in [0, 1]$. Por definición de intersección, x e y pertenecen a C_i para cada $i \in I$. Fijemos un i arbitrario: como C_i es convexo y $x, y \in C_i$, tenemos $(1 - \lambda)x + \lambda y \in C_i$. Como esto vale para todo $i \in I$, el punto $(1 - \lambda)x + \lambda y$ pertenece a todos los C_i a la vez, es decir, a C . Luego C es convexo. (Nota que no usamos en ningún momento que I sea finito: el resultado vale para intersecciones de familias infinitas, incluso no numerables.) $\square$

Cuidado (error común)

La **unión** de conjuntos convexos **no** es convexa en general. Ya lo vimos en el Ejemplo 2.11(b): la unión de dos bolas disjuntas no contiene el segmento que une sus centros. Un error frecuente en exámenes es “demostrar” que una unión es convexa tomando x, y en el *mismo* C_i ; la definición exige considerar también $x \in C_1, y \in C_2$ con $C_1 \neq C_2$, y ahí es donde el argumento se rompe. Otro error simétrico: creer que la intersección puede fallar; no puede, la intersección de convexos *siempre* es convexa (aunque sea vacía: el vacío es convexo por convención). Regla mnemotécnica: intersectar *recorta* (y recortar con condiciones lineales o convexas no crea huecos); unir *pega piezas separadas* (y pegar sí puede crear huecos).

Definición 2.19 (Suma de Minkowski y escalamiento). Dados $A, B \subseteq \mathbb{R}^n$ y $\alpha \in \mathbb{R}$, definimos la *suma de Minkowski* (*Minkowski sum*) y el *escalamiento* (*scaling*) por

$$A + B = \{a + b : a \in A, b \in B\}, \quad \alpha A = \{\alpha a : a \in A\}.$$

Teorema 2.20 (Suma y escalamiento preservan convexidad). *Si $A, B \subseteq \mathbb{R}^n$ son convexos y $\alpha \in \mathbb{R}$, entonces $A + B$ y αA son convexos.*

Demostración. Suma. Sean $z_1, z_2 \in A + B$ y $\lambda \in [0, 1]$. Por definición de la suma, existen $a_1, a_2 \in A$ y $b_1, b_2 \in B$ tales que $z_1 = a_1 + b_1$ y $z_2 = a_2 + b_2$. Entonces

$$(1 - \lambda)z_1 + \lambda z_2 = (1 - \lambda)(a_1 + b_1) + \lambda(a_2 + b_2) = \underbrace{[(1 - \lambda)a_1 + \lambda a_2]}_{\in A} + \underbrace{[(1 - \lambda)b_1 + \lambda b_2]}_{\in B},$$

donde solo hemos distribuido y reagrupado: los términos con a juntos y los términos con b juntos. El primer corchete está en A por convexidad de A ; el segundo, en B por convexidad de B . Luego la combinación es (elemento de A) + (elemento de B), que pertenece a $A + B$ por definición.

Escalamiento. Sean $\alpha a_1, \alpha a_2 \in \alpha A$ con $a_1, a_2 \in A$, y $\lambda \in [0, 1]$. Entonces

$$(1 - \lambda) \alpha a_1 + \lambda \alpha a_2 = \alpha [(1 - \lambda) a_1 + \lambda a_2] \in \alpha A,$$

porque el corchete pertenece a A por convexidad. (Esto vale para cualquier α , positivo, negativo o cero.) $\square$

Ejemplo 2.21 (Agregación de tecnologías, MWG cap. 5). En una economía con J empresas, la tecnología de la empresa j se describe con su *conjunto de producción* (*production set*) $Y_j \subseteq \mathbb{R}^n$: cada $y \in Y_j$ es un plan de producción, con la convención de signos de MWG [9] (cap. 5): las coordenadas negativas son insumos y las positivas son productos. El conjunto de producción *agregado* es lo que la economía en conjunto puede producir repartiendo la actividad entre las empresas:

$$Y = Y_1 + Y_2 + \cdots + Y_J = \{y_1 + \cdots + y_J : y_j \in Y_j \text{ para cada } j\},$$

¡exactamente una suma de Minkowski! Por el Teorema 2.20 (aplicado $J - 1$ veces), si cada Y_j es convexo, el agregado Y es convexo. Este hecho es el que permite, en los teoremas del bienestar de MWG cap. 16, tratar a “la producción de la economía” como un solo conjunto convexo y separarlo con un hiperplano de precios.

Ejemplo numérico completo con un insumo y un producto ($n = 2$; escribimos los planes como (insumo, producto)). Supongamos dos empresas con tecnologías lineales acotadas:

$$Y_1 = \{(-t, t) : t \in [0, 1]\}, \quad Y_2 = \{(-s, 2s) : s \in [0, 1]\}.$$

La empresa 1 convierte cada unidad de insumo en 1 de producto (hasta 1 unidad de insumo); la empresa 2 es más productiva: convierte cada unidad de insumo en 2 de producto (hasta 1 unidad). Cada Y_j es un segmento, luego es convexo. La suma es

$$Y_1 + Y_2 = \{(-t - s, t + 2s) : t \in [0, 1], s \in [0, 1]\}.$$

Calculemos algunos puntos: con $(t, s) = (0, 0)$ obtenemos $(0, 0)$ (no hacer nada); con $(t, s) = (1, 0)$, el punto $(-1, 1)$; con $(t, s) = (0, 1)$, el punto $(-1, 2)$; con $(t, s) = (1, 1)$, el punto $(-2, 3)$. El conjunto $Y_1 + Y_2$ es el paralelogramo con vértices $(0, 0)$, $(-1, 1)$, $(-1, 2)$, $(-2, 3)$: convexo, como predice el teorema. Nota económica: usando en total una unidad de insumo, la economía agregada puede producir cualquier cantidad entre 1 (todo en la empresa 1) y 2 (todo en la empresa 2), y también cualquier valor intermedio repartiendo el insumo; la *frontera eficiente* del agregado usa primero la tecnología más productiva. La suma de Minkowski hace automáticamente esta “contabilidad” de repartir la actividad entre las empresas.

Teorema 2.22 (Producto cartesiano). Si $C \subseteq \mathbb{R}^n$ y $D \subseteq \mathbb{R}^m$ son convexos, entonces el producto cartesiano $C \times D = \{(x, u) \in \mathbb{R}^{n+m} : x \in C, u \in D\}$ es convexo en $\mathbb{R}^{n+m}$.

Demostración. Sean $(x_1, u_1), (x_2, u_2) \in C \times D$ y $\lambda \in [0, 1]$. La combinación convexa se calcula coordenada a coordenada (por bloques):

$$(1 - \lambda)(x_1, u_1) + \lambda(x_2, u_2) = ((1 - \lambda)x_1 + \lambda x_2, (1 - \lambda)u_1 + \lambda u_2).$$

El primer bloque pertenece a C (convexidad de C , pues $x_1, x_2 \in C$) y el segundo a D (convexidad de D). Luego el par pertenece a $C \times D$. $\square$

Definición 2.23 (Transformación afín). Una función $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es *afín* (*affine map*) si $T(x) = Ax + b$ para alguna matriz A de tamaño $m \times n$ y algún vector $b \in \mathbb{R}^m$. (Si $b = 0$, T es lineal.) La propiedad clave, que usaremos sin cesar, es que las funciones afines *respetan las combinaciones convexas*: si $\lambda \in [0, 1]$,

$$T((1-\lambda)x + \lambda y) = A((1-\lambda)x + \lambda y) + b = (1-\lambda)Ax + \lambda Ay + \underbrace{[(1-\lambda) + \lambda]}_{=1} b = (1-\lambda)T(x) + \lambda T(y).$$

El paso intermedio usa la linealidad del producto matriz-vector y el truco, ya familiar, de escribir $b = (1-\lambda)b + \lambda b$.

Teorema 2.24 (Imagen y preimagen bajo transformaciones afines). Sea $T(x) = Ax + b$ una transformación afín de $\mathbb{R}^n$ en $\mathbb{R}^m$.

- (a) Si $C \subseteq \mathbb{R}^n$ es convexo, su imagen $T(C) = \{T(x) : x \in C\}$ es convexa en $\mathbb{R}^m$.
- (b) Si $D \subseteq \mathbb{R}^m$ es convexo, su preimagen $T^{-1}(D) = \{x \in \mathbb{R}^n : T(x) \in D\}$ es convexa en $\mathbb{R}^n$.

Demostración. (a) Sean $v_1, v_2 \in T(C)$ y $\lambda \in [0, 1]$. Existen $x_1, x_2 \in C$ con $v_1 = T(x_1)$, $v_2 = T(x_2)$. Usando la propiedad de la Definición 2.23 “al revés”:

$$(1-\lambda)v_1 + \lambda v_2 = (1-\lambda)T(x_1) + \lambda T(x_2) = T((1-\lambda)x_1 + \lambda x_2).$$

El punto $(1-\lambda)x_1 + \lambda x_2$ pertenece a C por convexidad, así que su imagen bajo T pertenece a $T(C)$. Luego $T(C)$ es convexo.

(b) Sean $x_1, x_2 \in T^{-1}(D)$ y $\lambda \in [0, 1]$; esto significa $T(x_1) \in D$ y $T(x_2) \in D$. Entonces

$$T((1-\lambda)x_1 + \lambda x_2) = (1-\lambda)T(x_1) + \lambda T(x_2) \in D,$$

donde la pertenencia final es por convexidad de D aplicada a los puntos $T(x_1), T(x_2) \in D$. Por definición de preimagen, $(1-\lambda)x_1 + \lambda x_2 \in T^{-1}(D)$. $\square$

Observación 2.25. Estos resultados generan una caja de herramientas muy potente. Ejemplos de uso inmediato: (i) la *proyección* de un convexo sobre algunas coordenadas es convexa, porque proyectar es aplicar la transformación lineal que borra las otras coordenadas; (ii) un conjunto definido por restricciones lineales $\{x : Ax \leq c\}$ es convexo por ser preimagen del conjunto $\{u : u \leq c\}$ (un ortante trasladado, convexo por ser intersección de semiespacios) bajo el mapa lineal $x \mapsto Ax$, lo que re-demuestra que los poliedros son convexos; (iii) la suma $A + B$ puede verse como la imagen del producto $A \times B$ (convexo por el Teorema 2.22) bajo el mapa lineal $(a, b) \mapsto a + b$, lo que da una segunda demostración del Teorema 2.20. Puedes ver [2], sección 2.3, y [3], cap. 2, para catálogos más amplios.

2.5. Aspectos topológicos de los conjuntos convexos [P2]

Recordemos del capítulo de preliminares las nociones topológicas que usaremos: el *interior* $\text{int } C$ (puntos que tienen una bolita alrededor contenida en C), la *clausura* $\text{cl } C$ (puntos que son límite de sucesiones de C , equivalentemente, C junto con su frontera) y la *frontera* $\text{fr } C = \text{cl } C \setminus \text{int } C$. La pregunta de esta sección: ¿heredan $\text{int } C$ y $\text{cl } C$ la convexidad de C ? La respuesta es sí, y la herramienta central es un lema tan útil que tiene nombre propio.

Lema 2.26 (Lema del segmento / accesibilidad del interior). *Sea $C \subseteq \mathbb{R}^n$ convexo. Si $x \in \text{int } C$ e $y \in \text{cl } C$, entonces todo el segmento salvo quizá el extremo y está en el interior:*

$$[x, y) \subseteq \text{int } C,$$

es decir, $(1 - \lambda)y + \lambda x \in \text{int } C$ para todo $\lambda \in (0, 1]$.

Demostración. Fijemos $\lambda \in (0, 1]$ y llamemos $z = \lambda x + (1 - \lambda)y$ al punto del segmento (nota el orden de los pesos: peso λ sobre el punto interior x). Si $\lambda = 1$ entonces $z = x \in \text{int } C$ y no hay nada que probar; supongamos pues $\lambda \in (0, 1)$. Queremos encontrar un radio $\rho > 0$ tal que $B(z, \rho) \subseteq C$.

Datos disponibles. Como $x \in \text{int } C$, existe $r > 0$ con $B(x, r) \subseteq C$. Como $y \in \text{cl } C$, hay puntos de C tan cerca de y como queramos: para cualquier $\delta > 0$ existe $y' \in C$ con $\|y' - y\| < \delta$. Elegiremos δ y ρ al final; primero veamos qué necesitamos.

La idea geométrica. Queremos escribir cualquier punto u cercano a z como combinación convexa $u = \lambda x' + (1 - \lambda)y'$ con $x' \in B(x, r) \subseteq C$ e $y' \in C$; la convexidad de C dará entonces $u \in C$. Dado u y dado el punto $y' \in C$ cercano a y , la ecuación $u = \lambda x' + (1 - \lambda)y'$ tiene una única solución para x' (despejamos):

$$x' = \frac{u - (1 - \lambda)y'}{\lambda}.$$

Solo falta comprobar que este x' cae dentro de $B(x, r)$ si u está suficientemente cerca de z e y' suficientemente cerca de y .

La estimación. Calculemos $\|x' - x\|$. Como $z = \lambda x + (1 - \lambda)y$, podemos despejar $x = (z - (1 - \lambda)y)/\lambda$. Restando las dos expresiones:

$$x' - x = \frac{u - (1 - \lambda)y'}{\lambda} - \frac{z - (1 - \lambda)y}{\lambda} = \frac{(u - z) + (1 - \lambda)(y - y')}{\lambda}.$$

Tomando normas y aplicando la desigualdad triangular:

$$\|x' - x\| \leq \frac{\|u - z\| + (1 - \lambda)\|y - y'\|}{\lambda}.$$

Elección de los parámetros. Elijamos

$$\rho = \frac{\lambda r}{2} \quad \text{y} \quad y' \in C \text{ con } \|y - y'\| < \frac{\lambda r}{2(1 - \lambda)}.$$

(Tal y' existe porque $y \in \text{cl } C$.) Entonces, para cualquier $u \in B(z, \rho)$:

$$\|x' - x\| < \frac{1}{\lambda} \left(\frac{\lambda r}{2} + (1 - \lambda) \cdot \frac{\lambda r}{2(1 - \lambda)} \right) = \frac{1}{\lambda} \left(\frac{\lambda r}{2} + \frac{\lambda r}{2} \right) = \frac{1}{\lambda} \cdot \lambda r = r.$$

Así $x' \in B(x, r) \subseteq C$. Como también $y' \in C$ y $\lambda \in (0, 1)$, la convexidad de C da

$$u = \lambda x' + (1 - \lambda)y' \in C.$$

Hemos probado que *todo* punto u de la bola $B(z, \rho)$ pertenece a C , es decir, $B(z, \rho) \subseteq C$, o sea $z \in \text{int } C$. Como $\lambda \in (0, 1]$ era arbitrario, $[x, y) \subseteq \text{int } C$. $\square$

Intuición

Piensa en el punto interior x como una *fuentes de luz* rodeada de una bolita libre $B(x, r) \subseteq C$, y en y como un punto en el borde (o casi). El lema dice que el “cono de luz” que va de la bolita hacia y queda dentro de C : al movernos desde y hacia x , aunque sea un poquito (λ pequeño pero positivo), inmediatamente ganamos un margen de holgura proporcional a λr : la bolita alrededor de x se “contrae” hacia z pero no desaparece mientras $\lambda > 0$. Esta imagen explica por qué el extremo y debe excluirse: en $\lambda = 0$ el margen $\lambda r/2$ se contrae a cero. Este lema es el caballo de batalla de la teoría: de él saldrán en un capítulo posterior los teoremas de separación, que a su vez son el corazón del segundo teorema del bienestar [9].

Teorema 2.27 (Interior y clausura de un convexo son convexos). *Si $C \subseteq \mathbb{R}^n$ es convexo, entonces $\text{int } C$ y $\text{cl } C$ son convexos.*

Demostración. Interior. Sean $x, y \in \text{int } C$ y $\lambda \in (0, 1)$ (los casos $\lambda \in \{0, 1\}$ son triviales porque devuelven x o y). Como en particular $y \in \text{int } C \subseteq \text{cl } C$, el Lema 2.26 con el punto interior x y el punto de clausura y da $[x, y) \subseteq \text{int } C$, y el punto $(1 - \lambda)x + \lambda y$ con $\lambda \in (0, 1)$ pertenece a $[x, y)$. Luego $\text{int } C$ es convexo.

Clausura. Sean $x, y \in \text{cl } C$ y $\lambda \in [0, 1]$. Por la caracterización secuencial de la clausura (capítulo de preliminares), existen sucesiones (x_k) e (y_k) de puntos de C con $x_k \rightarrow x$ e $y_k \rightarrow y$. Por convexidad de C , cada punto $z_k = (1 - \lambda)x_k + \lambda y_k$ pertenece a C . Por las reglas de límites (el límite de una combinación lineal es la combinación lineal de los límites):

$$z_k = (1 - \lambda)x_k + \lambda y_k \longrightarrow (1 - \lambda)x + \lambda y.$$

Así, $(1 - \lambda)x + \lambda y$ es límite de una sucesión de puntos de C , luego pertenece a $\text{cl } C$. Por tanto $\text{cl } C$ es convexo. $\square$

2.5.1. El interior relativo

Hay un problema práctico con el interior “ordinario”: muchos conjuntos convexos importantes en economía tienen interior *vacío*, no porque sean degenerados, sino porque son “planos” dentro de un espacio de dimensión mayor.

Ejemplo 2.28 (Un segmento en el plano no tiene interior). Sea $S = \{(x_1, 0) : x_1 \in [0, 1]\} \subseteq \mathbb{R}^2$, un segmento horizontal. Tomemos cualquier punto $z = (z_1, 0) \in S$ y cualquier radio $\varepsilon > 0$. La bola $B(z, \varepsilon)$ contiene el punto $(z_1, \varepsilon/2)$, cuya segunda coordenada no es cero, de modo que no pertenece a S . Es decir, *ninguna* bola centrada en un punto de S cabe dentro de S : $\text{int } S = \emptyset$. Sin embargo, nuestra intuición dice que los puntos “del medio” del segmento, como $(1/2, 0)$, son cualitativamente distintos de los extremos $(0, 0)$ y $(1, 0)$. El interior ordinario no captura esa diferencia; el interior *relativo* sí. Lo mismo ocurre con el simplex $\Delta^{n-1} \subseteq \mathbb{R}^n$ (Ejemplo 2.17): al vivir dentro del hiperplano $\sum_i \pi_i = 1$, su interior en $\mathbb{R}^n$ es vacío, pese a que las loterías con todas las probabilidades positivas son claramente “interiores” en el sentido relevante.

Definición 2.29 (Interior relativo). El *interior relativo* (*relative interior*) de un conjunto convexo $C \subseteq \mathbb{R}^n$, denotado $\text{ri } C$, es su interior visto dentro de su envoltura afín:

$$\text{ri } C = \{x \in C : \exists \varepsilon > 0 \text{ tal que } B(x, \varepsilon) \cap \text{aff } C \subseteq C\}.$$

Es decir: en lugar de exigir que una bola entera quepa en C (imposible si C es plano), exigimos que quepa la *rebanada* de la bola que vive en el plano afín natural de C .

Ejemplo 2.30. Para el segmento S del Ejemplo 2.28, la envoltura afín es la recta $\text{aff } S = \{(x_1, 0) : x_1 \in \mathbb{R}\}$ (el eje horizontal). Un punto $z = (z_1, 0)$ con $z_1 \in (0, 1)$ está en $\text{ri } S$: tomando $\varepsilon = \min\{z_1, 1 - z_1\} > 0$, la rebanada $B(z, \varepsilon) \cap \text{aff } S = \{(x_1, 0) : |x_1 - z_1| < \varepsilon\}$ queda dentro de S (pues ε se eligió como la distancia al extremo más cercano). Los extremos no están en $\text{ri } S$: cualquier rebanada alrededor de $(0, 0)$ contiene puntos $(x_1, 0)$ con $x_1 < 0$, que no están en S . Así,

$$\text{ri } S = \{(x_1, 0) : x_1 \in (0, 1)\} \neq \emptyset = \text{int } S.$$

Análogamente, $\text{ri } \Delta^{n-1} = \{\pi \in \Delta^{n-1} : \pi_i > 0 \text{ para todo } i\}$: las loterías *completamente mezcladas*. Este conjunto aparecerá en Microeconomía cada vez que un argumento requiera “perturbar” una lotería en todas las direcciones sin salir del simplex.




Figura 2.3: El segmento $S \subseteq \mathbb{R}^2$ tiene interior vacío: ninguna bola bidimensional cabe en él. Pero la intersección de la bola con $\text{aff } S$ (el trazo grueso sobre el eje) sí cabe: $z \in \text{ri } S$.

El siguiente resultado, que enunciamos sin demostración completa, dice que para conjuntos convexos no vacíos el interior relativo nunca es vacío y “llena” el conjunto al tomar clausura. Es la razón técnica por la que los teoremas de separación del final del curso se enuncian con ri y no con int .

Teorema 2.31 (Propiedades del interior relativo). Sea $C \subseteq \mathbb{R}^n$ convexo y no vacío. Entonces:

- (a) $\text{ri } C \neq \emptyset$ (y además $\dim(\text{ri } C) = \dim C$);
- (b) $\text{cl}(\text{ri } C) = \text{cl } C$ y $\text{ri}(\text{cl } C) = \text{ri } C$;
- (c) vale la versión relativa del lema del segmento: si $x \in \text{ri } C$ e $y \in \text{cl } C$, entonces $[x, y] \subseteq \text{ri } C$.

Esquema de la demostración. La idea de (a): si $\dim C = d$, dentro de C pueden elegirse $d + 1$ puntos $x_0, x_1, \dots, x_d$ “afínmente independientes” (es decir, tales que los vectores $x_1 - x_0, \dots, x_d - x_0$ son linealmente independientes; existen porque de lo contrario C cabría en un conjunto afín de dimensión menor). El promedio $\bar{x} = \frac{1}{d+1} \sum_i x_i$, llamado *baricentro*, pertenece a $\text{ri } C$: dentro de $\text{aff } C$ uno puede moverse desde $\bar{x}$ una pequeña distancia en cualquier dirección sin salir de la cápsula convexa de los x_i , que está contenida en C por el Teorema 2.12. Para (b) y (c), el argumento es el mismo que en el Lema 2.26 y el Teorema 2.27, trabajando dentro de $\text{aff } C$ en lugar de $\mathbb{R}^n$ (todas las bolas se reemplazan por rebanadas $B \cap \text{aff } C$). La inclusión $\text{cl}(\text{ri } C) \subseteq \text{cl } C$ es inmediata ($\text{ri } C \subseteq C$); para la recíproca, dado $y \in \text{cl } C$, se toma cualquier $x \in \text{ri } C$ (existe por (a)) y se usa (c): los puntos del segmento $[x, y]$ están en $\text{ri } C$ y convergen a y cuando $\lambda \rightarrow 0$, luego $y \in \text{cl}(\text{ri } C)$. Las demostraciones detalladas están en [6], cap. 2 (teoremas 2.26–2.27), y en [3], cap. 2. $\square$

Observación 2.32. Otro hecho topológico que usaremos con frecuencia (y que conecta con el teorema de Weierstrass del capítulo de preliminares): el conjunto presupuestario $B(p, m)$ con $p \gg 0$ y el simplex Δ^{n-1} son, además de convexos, *compactos* (cerrados y acotados). Cerrados, porque están definidos por desigualdades débiles ($\leq, \geq$) e igualdades de funciones continuas; acotados, porque $0 \leq x_i \leq m/p_i$ en el primer caso y $0 \leq \pi_i \leq 1$ en el segundo. La combinación “convexo + compacto” es la hipótesis estrella de los teoremas de existencia (de equilibrio, de punto fijo) en MWG caps. 15–17 [9].

2.6. Tres construcciones económicas con conjuntos convexos [P1]

Cerramos el capítulo desarrollando con detalle tres construcciones de Microeconomía que son, vistas con los lentes de este capítulo, puro manejo de conjuntos convexos.

2.6.1. La caja de Edgeworth como producto de convexos

Consideremos una economía de intercambio puro con dos consumidores (A y B) y dos bienes, con dotaciones agregadas $\omega = (\omega_1, \omega_2) \gg 0$. Una *asignación* para el consumidor A es una canasta $x^A = (x_1^A, x_2^A)$ con $0 \leq x_i^A \leq \omega_i$: el consumidor A no puede consumir cantidades negativas ni más de lo que existe en la economía. El conjunto de tales canastas es la *caja de Edgeworth* (*Edgeworth box*):

$$E = [0, \omega_1] \times [0, \omega_2] \subseteq \mathbb{R}^2.$$

Cada intervalo $[0, \omega_i]$ es un conjunto convexo de $\mathbb{R}$ (es un segmento), así que por el Teorema 2.22 la caja E es convexa (y es compacta, por ser producto de compactos). La asignación del consumidor B queda determinada por la de A mediante $x^B = \omega - x^A$, que es una transformación afín de x^A (con $A = -I$ y $b = \omega$ en la notación de la Definición 2.23); por el Teorema 2.24(a),

el conjunto de canastas posibles de B es la imagen afín de E , de nuevo convexa. Esta doble lectura, en la que cada punto de la caja es simultáneamente una canasta para A (medida desde su origen) y una para B (medida desde el origen opuesto), es el dispositivo gráfico central de MWG cap. 15 [9].

2.6.2. Preferencias convexas y conjuntos de contorno superior

Definición 2.33 (Preferencias convexas). Sea $\succsim$ una relación de preferencia sobre $X \subseteq \mathbb{R}^n$ convexo. Para cada canasta x , el *conjunto de contorno superior* (*upper contour set*) es

$$U(x) = \{y \in X : y \succsim x\},$$

las canastas al menos tan buenas como x . Decimos que $\succsim$ es *convexa* si $U(x)$ es un conjunto convexo para toda $x \in X$. Si las preferencias se representan por una función de utilidad u , entonces $U(x) = \{y \in X : u(y) \geq u(x)\}$, y la convexidad de todos estos conjuntos es exactamente la definición de que u sea *cuasicóncava*, la conexión que desarrollaremos en el capítulo de cuasiconcavidad.

Interpretación: gusto por la diversificación. Si $y \succsim x$ y $z \succsim x$ (dos canastas al menos tan buenas como x), la convexidad de $U(x)$ dice que cualquier mezcla $(1 - \lambda)y + \lambda z$ también es al menos tan buena como x : los promedios no son peores que los extremos. *Ejemplo resuelto.* Sea $u(x_1, x_2) = \min\{x_1, x_2\}$ (preferencias Leontief, bienes complementarios perfectos) sobre $X = \mathbb{R}_+^2$. Probemos que $U(x) = \{y \geq 0 : \min\{y_1, y_2\} \geq c\}$ es convexo, donde $c = \min\{x_1, x_2\}$. Primero reescribimos el conjunto sin el mínimo: $\min\{y_1, y_2\} \geq c$ equivale a exigir *ambas* desigualdades $y_1 \geq c$ e $y_2 \geq c$ (el mínimo de dos números es $\geq c$ exactamente cuando los dos lo son). Por lo tanto

$$U(x) = \{y : y_1 \geq c\} \cap \{y : y_2 \geq c\} \cap \mathbb{R}_+^2,$$

una intersección de tres semiespacios (los dos primeros con vectores normales e_1 y e_2 , y $\mathbb{R}_+^2$ que es intersección de otros dos). Por el Teorema 2.18, $U(x)$ es convexo, luego las preferencias Leontief son convexas. Nota el método: no tocamos la definición de convexidad; solo *reconocimos* el conjunto como intersección de piezas convexas. En MWG caps. 16–17 [9], la convexidad de las preferencias de *todos* los consumidores (junto con la de los conjuntos de producción) es la hipótesis que permite aplicar el teorema del hiperplano separador y demostrar el segundo teorema del bienestar; sin ella, hay óptimos de Pareto que ningún sistema de precios puede sostener.

2.6.3. El conjunto de asignaciones factibles

En una economía de intercambio con I consumidores y n bienes, una *asignación* es una lista $x = (x^1, \dots, x^I)$ de canastas, una por consumidor, es decir, un punto de $\mathbb{R}^{nI}$. La asignación es *factible* (*feasible*) si nadie consume cantidades negativas y los totales no exceden la dotación agregada $\omega \in \mathbb{R}^n$:

$$F = \left\{ (x^1, \dots, x^I) \in \mathbb{R}^{nI} : x^i \geq 0 \text{ para todo } i, \sum_{i=1}^I x^i \leq \omega \right\}.$$

Afirmación: F es convexo. Podemos verlo de dos maneras. *Vía operaciones:* las condiciones $x_j^i \geq 0$ son nI semiespacios en $\mathbb{R}^{nI}$, y cada una de las n condiciones de recursos $\sum_i x_j^i \leq \omega_j$ es también un semiespacio (la función $x \mapsto \sum_i x_j^i$ es lineal en el vector largo x); F es la intersección de todos ellos, convexa por el Teorema 2.18. *Vía definición,* para practicar: si $x = (x^1, \dots, x^I)$ y $\tilde{x} = (\tilde{x}^1, \dots, \tilde{x}^I)$ son factibles y $\lambda \in [0, 1]$, entonces la mezcla asigna a cada consumidor i la canasta $(1 - \lambda)x^i + \lambda\tilde{x}^i \geq 0$, y sumando sobre consumidores:

$$\sum_{i=1}^I [(1 - \lambda)x^i + \lambda\tilde{x}^i] = (1 - \lambda) \sum_{i=1}^I x^i + \lambda \sum_{i=1}^I \tilde{x}^i \leq (1 - \lambda)\omega + \lambda\omega = \omega,$$

donde la desigualdad es coordenada a coordenada y usa la factibilidad de x y $\tilde{x}$. La convexidad de F (junto con su compacidad) es un ingrediente permanente de los argumentos de existencia y de los teoremas del bienestar en MWG caps. 16–17 [9]; en economías con producción, se suma a F el conjunto agregado $Y = \sum_j Y_j$ del Ejemplo 2.21, otra vez vía suma de Minkowski.

2.7. Resumen y ejercicios resueltos [P1]

Resumen del capítulo

- Un conjunto C es **convexo** si contiene el segmento entre cualquier par de sus puntos: $(1 - \lambda)x + \lambda y \in C$ para $x, y \in C$, $\lambda \in [0, 1]$. Equivalentemente (Teorema 2.12), contiene todas las combinaciones convexas finitas de sus puntos. Combinación convexa = promedio ponderado = lotería.
- **Ejemplos base:** bolas (vía desigualdad triangular), hiperplanos y semiespacios (vía linealidad de $\langle a, \cdot \rangle$), poliedros, conjunto presupuestario $B(p, m)$, simplex de loterías Δ^{n-1} . **No-ejemplos:** anillo, unión de bolas disjuntas.
- Un conjunto **afín** contiene la *recta* por cada par de puntos; es exactamente un subespacio trasladado, $M = x_0 + V$ (Teorema 2.15). $\dim C := \dim(\text{aff } C)$.
- **Operaciones que preservan convexidad:** intersecciones arbitrarias, suma de Minkowski $A + B$ (agregación de tecnologías, MWG cap. 5), escalamiento αA , producto cartesiano $C \times D$ (caja de Edgeworth), imagen y preimagen bajo transformaciones afines. La **unión** no preserva convexidad.
- **Topología:** si C es convexo, $\text{int } C$ y $\text{cl } C$ son convexos; la pieza clave es el *lema del segmento*: $x \in \text{int } C$, $y \in \text{cl } C$ implican $[x, y) \subseteq \text{int } C$ (Lema 2.26). Cuando $\text{int } C = \emptyset$ por ser C “plano”, el sustituto correcto es el **interior relativo** $\text{ri } C$ (interior dentro de $\text{aff } C$), que nunca es vacío para C convexo no vacío, y cumple $\text{cl}(\text{ri } C) = \text{cl } C$ (Teorema 2.31).
- **En Microeconomía:** preferencias convexas = conjuntos de contorno superior convexas (gusto por la diversificación); asignaciones factibles y caja de Edgeworth son convexas y compactas; los teoremas del bienestar separan convexas con hiperplanos de precios (MWG caps. 15–18 [9]; ver también [10], cap. 5).

Ejercicio 2.34. Sea $C = \{(x_1, x_2) \in \mathbb{R}^2 : x_1 > 0, x_2 > 0, x_1 x_2 \geq 1\}$, el conjunto de contorno superior al nivel 1 de la utilidad Cobb–Douglas $u(x_1, x_2) = x_1 x_2$. Demuestra que C es convexo usando directamente la definición.

Solución. Sean $a = (a_1, a_2)$ y $b = (b_1, b_2)$ en C , y $\lambda \in [0, 1]$; escribamos $z = (1 - \lambda)a + \lambda b$. *Positividad:* $z_1 = (1 - \lambda)a_1 + \lambda b_1 > 0$ porque es combinación de números positivos con pesos no ambos nulos (si $\lambda \in \{0, 1\}$, z es a o b y no hay nada que probar; suponemos $\lambda \in (0, 1)$). Análogamente $z_2 > 0$. *La desigualdad del producto:* debemos probar $z_1 z_2 \geq 1$. Expandimos el producto con la propiedad distributiva:

$$z_1 z_2 = [(1 - \lambda)a_1 + \lambda b_1][(1 - \lambda)a_2 + \lambda b_2] = (1 - \lambda)^2 a_1 a_2 + \lambda^2 b_1 b_2 + \lambda(1 - \lambda)(a_1 b_2 + a_2 b_1).$$

Sabemos que $a_1 a_2 \geq 1$ y $b_1 b_2 \geq 1$. Para el término cruzado usamos la desigualdad entre media aritmética y geométrica (AM–GM: para $u, v \geq 0$, $u + v \geq 2\sqrt{uv}$, que se deduce de $(\sqrt{u} - \sqrt{v})^2 \geq 0$ expandiendo el cuadrado):

$$a_1 b_2 + a_2 b_1 \geq 2\sqrt{a_1 b_2 \cdot a_2 b_1} = 2\sqrt{(a_1 a_2)(b_1 b_2)} \geq 2\sqrt{1 \cdot 1} = 2.$$

Sustituyendo las tres cotas en la expansión:

$$z_1 z_2 \geq (1 - \lambda)^2 \cdot 1 + \lambda^2 \cdot 1 + \lambda(1 - \lambda) \cdot 2 = [(1 - \lambda) + \lambda]^2 = 1,$$

donde en el penúltimo paso reconocimos el desarrollo del binomio $(u + v)^2 = u^2 + 2uv + v^2$ con $u = 1 - \lambda$, $v = \lambda$. Luego $z \in C$ y C es convexo. (Este es un primer vistazo a la *cuasiconcavidad* de la Cobb–Douglas, tema del capítulo correspondiente.) $\square$

Ejercicio 2.35. (a) Demuestra que $\text{aff } \Delta^{n-1} = \{x \in \mathbb{R}^n : \sum_{i=1}^n x_i = 1\}$ y concluye que $\dim \Delta^{n-1} = n - 1$. (b) Describe $\text{ri } \Delta^{n-1}$ y justifica que la lotería uniforme $\bar{\pi} = (1/n, \dots, 1/n)$ pertenece a él.

Solución. (a) Llamemos $H = \{x : \sum_i x_i = 1\}$. *Inclusión $\subseteq$:* toda combinación afín $\sum_k \mu_k \pi^{(k)}$ de loterías (con $\sum_k \mu_k = 1$, pesos de cualquier signo) cumple

$$\sum_{i=1}^n \left(\sum_k \mu_k \pi_i^{(k)} \right) = \sum_k \mu_k \left(\sum_{i=1}^n \pi_i^{(k)} \right) = \sum_k \mu_k \cdot 1 = 1,$$

(intercambiamos el orden de las sumas finitas, siempre lícito), así que $\text{aff } \Delta^{n-1} \subseteq H$. *Inclusión $\supseteq$:* sea $x \in H$. Escribimos x como combinación afín de los vértices $e_1, \dots, e_n \in \Delta^{n-1}$: tomando $\mu_i = x_i$, tenemos $\sum_i \mu_i e_i = x$ (pues e_i tiene un 1 en la coordenada i) y $\sum_i \mu_i = \sum_i x_i = 1$; los μ_i pueden ser negativos, pero eso está permitido en una combinación afín. Luego $x \in \text{aff } \Delta^{n-1}$. Con $x_0 = e_1$, el subespacio director es $V = H - e_1 = \{v : \sum_i v_i = 0\}$, definido por una ecuación lineal no trivial en $\mathbb{R}^n$, luego $\dim V = n - 1$ y $\dim \Delta^{n-1} = n - 1$.

(b) $\text{ri } \Delta^{n-1} = \{\pi \in \Delta^{n-1} : \pi_i > 0 \ \forall i\}$. Justificación para $\bar{\pi}$: hay que hallar $\varepsilon > 0$ tal que todo $x \in H$ con $\|x - \bar{\pi}\| < \varepsilon$ pertenezca a Δ^{n-1} . Si $\|x - \bar{\pi}\| < \varepsilon$ entonces cada coordenada cumple $|x_i - 1/n| \leq \|x - \bar{\pi}\| < \varepsilon$ (el valor absoluto de una coordenada nunca supera la norma euclidiana), de donde $x_i > 1/n - \varepsilon$. Basta elegir $\varepsilon = 1/n$ para garantizar $x_i > 0$ para todo i ; y la

condición $\sum_i x_i = 1$ ya la da $x \in H$. Luego la rebanada $B(\bar{\pi}, 1/n) \cap H$ está contenida en Δ^{n-1} , es decir, $\bar{\pi} \in \text{ri } \Delta^{n-1}$. El mismo argumento, con $\varepsilon = \min_i \pi_i$, funciona para cualquier lotería con todas las probabilidades positivas. $\square$

Ejercicio 2.36. Sean $Y_1 = \{(-t, t) : t \in [0, 2]\}$ e $Y_2 = \{(-s, 3s) : s \in [0, 1]\}$ los conjuntos de producción de dos empresas (insumo, producto). (a) Calcula explícitamente $Y_1 + Y_2$ y dibújalo (o descríbelo con precisión). (b) ¿Cuál es la máxima producción alcanzable por la economía agregada si dispone de 2 unidades de insumo en total? Justifica usando el conjunto $Y_1 + Y_2$.

Solución. (a) Por definición de suma de Minkowski,

$$Y_1 + Y_2 = \{(-t - s, t + 3s) : t \in [0, 2], s \in [0, 1]\}.$$

Es la imagen del rectángulo $[0, 2] \times [0, 1]$ (convexo, producto de segmentos) bajo la transformación lineal $(t, s) \mapsto (-t - s, t + 3s)$, luego es convexo por el Teorema 2.24(a): un paralelogramo (posiblemente degenerado; aquí no lo es porque los vectores generadores $(-1, 1)$ y $(-1, 3)$ son linealmente independientes, ya que $(-1) \cdot 3 - 1 \cdot (-1) = -2 \neq 0$). Sus vértices son las imágenes de los vértices del rectángulo: $(t, s) = (0, 0) \mapsto (0, 0)$; $(2, 0) \mapsto (-2, 2)$; $(0, 1) \mapsto (-1, 3)$; $(2, 1) \mapsto (-3, 5)$.

(b) Disponer de 2 unidades de insumo significa restringirse a los planes agregados con primera coordenada ≥ -2 , es decir, $t + s \leq 2$. Queremos maximizar la producción $t + 3s$ sujeto a $t \in [0, 2]$, $s \in [0, 1]$, $t + s \leq 2$. Como el coeficiente de s en el objetivo (3) supera al de t (1), conviene usar primero la empresa 2 al máximo: $s = 1$; queda $t \leq 2 - s = 1$, y tomamos $t = 1$. La producción máxima es $t + 3s = 1 + 3 = 4$, con el plan agregado $(-2, 4)$. Interpretación: la agregación via Minkowski permite leer la eficiencia productiva de la economía directamente de la frontera del conjunto suma, tal como en MWG cap. 5 [9]. $\square$

Ejercicio 2.37. Sea $C \subseteq \mathbb{R}^n$ y sean $\alpha, \beta \geq 0$. (a) Demuestra que si C es convexo, entonces $\alpha C + \beta C = (\alpha + \beta)C$. (b) Da un contraejemplo que muestre que la igualdad puede fallar si C no es convexo. (c) ¿Qué inclusión vale siempre, sea o no convexo C ?

Solución. (c) primero (la inclusión fácil): $(\alpha + \beta)C \subseteq \alpha C + \beta C$ vale siempre: si $x \in C$, entonces $(\alpha + \beta)x = \alpha x + \beta x$, que es un elemento de αC más un elemento de βC (¡el mismo x en ambos!).

(a) Falta la inclusión $\alpha C + \beta C \subseteq (\alpha + \beta)C$ cuando C es convexo. Si $\alpha + \beta = 0$, entonces $\alpha = \beta = 0$ y ambos lados son $\{0\}$ (si $C \neq \emptyset$); supongamos $\alpha + \beta > 0$. Un elemento genérico del lado izquierdo es $\alpha x + \beta y$ con $x, y \in C$. Lo reescribimos sacando el factor $\alpha + \beta$:

$$\alpha x + \beta y = (\alpha + \beta) \left(\frac{\alpha}{\alpha + \beta} x + \frac{\beta}{\alpha + \beta} y \right).$$

Los pesos $\frac{\alpha}{\alpha + \beta}$ y $\frac{\beta}{\alpha + \beta}$ son no negativos y suman $\frac{\alpha + \beta}{\alpha + \beta} = 1$: el paréntesis es una combinación convexa de $x, y \in C$, que pertenece a C por convexidad. Luego $\alpha x + \beta y \in (\alpha + \beta)C$.

(b) Tomemos $C = \{0, 1\} \subseteq \mathbb{R}$ (dos puntos: no convexo, pues $1/2 \notin C$) y $\alpha = \beta = 1$. Entonces $C + C = \{0 + 0, 0 + 1, 1 + 0, 1 + 1\} = \{0, 1, 2\}$, mientras que $(\alpha + \beta)C = 2C = \{0, 2\}$. Como $1 \in C + C$ pero $1 \notin 2C$, la igualdad falla. Moraleja: para conjuntos no vacíos, la identidad $\alpha C + \beta C = (\alpha + \beta)C$ para todos $\alpha, \beta \geq 0$ es una *caracterización* de la convexidad. En efecto, si

vale para todos los pares, tomando $\alpha = \lambda$ y $\beta = 1 - \lambda$ con $\lambda \in [0, 1]$ se obtiene $\lambda x + (1 - \lambda)y \in (\alpha + \beta)C = C$ para todos $x, y \in C$, que es la definición. *Cuidado*: no basta el caso $\alpha = \beta = \frac{1}{2}$. La inclusión $\frac{1}{2}C + \frac{1}{2}C \subseteq C$ dice solo que C es convexo *en el punto medio*, y eso no implica convexidad sin una hipótesis adicional (por ejemplo, que C sea cerrado): el conjunto $C = \mathbb{Q} \subseteq \mathbb{R}$ cumple $\frac{1}{2}\mathbb{Q} + \frac{1}{2}\mathbb{Q} = \mathbb{Q}$ y no es convexo, pues $\frac{\sqrt{2}}{2} \cdot 0 + (1 - \frac{\sqrt{2}}{2}) \cdot 1 \notin \mathbb{Q}$. Iterando el punto medio solo se alcanzan pesos λ diádicos ($k/2^j$); para pasar de ellos a todo $[0, 1]$ hace falta un argumento de límite. $\square$

Ejercicio 2.38. Demuestra que $\text{conv } S$ (Definición 2.13) es el menor conjunto convexo que contiene a S ; es decir: (a) $\text{conv } S$ es convexo y contiene a S ; (b) si D es convexo y $S \subseteq D$, entonces $\text{conv } S \subseteq D$.

Solución. (a) $S \subseteq \text{conv } S$: cada $x \in S$ es la combinación convexa trivial $1 \cdot x$. Convexidad de $\text{conv } S$: sean $u = \sum_{i=1}^k \lambda_i x_i$ y $v = \sum_{j=1}^l \mu_j y_j$ dos combinaciones convexas de puntos de S , y $\theta \in [0, 1]$. Entonces

$$(1 - \theta)u + \theta v = \sum_{i=1}^k (1 - \theta)\lambda_i x_i + \sum_{j=1}^l \theta\mu_j y_j,$$

que es una combinación de los $k+l$ puntos $x_1, \dots, x_k, y_1, \dots, y_l \in S$ con coeficientes $(1 - \theta)\lambda_i \geq 0$ y $\theta\mu_j \geq 0$ cuya suma es

$$(1 - \theta) \sum_{i=1}^k \lambda_i + \theta \sum_{j=1}^l \mu_j = (1 - \theta) \cdot 1 + \theta \cdot 1 = 1.$$

Luego $(1 - \theta)u + \theta v \in \text{conv } S$.

(b) Sea D convexo con $S \subseteq D$. Todo elemento de $\text{conv } S$ es una combinación convexa finita de puntos de S , en particular de puntos de D ; por el Teorema 2.12, dicha combinación pertenece a D . Así $\text{conv } S \subseteq D$. Combinando (a) y (b): $\text{conv } S$ es convexo, contiene a S , y está contenido en cualquier otro convexo que contenga a S ; en ese sentido preciso es “el menor”. (Equivalentemente, $\text{conv } S$ es la intersección de todos los convexos que contienen a S , intersección que es convexa por el Teorema 2.18.) $\square$

Ejercicio 2.39. Sea $C \subseteq \mathbb{R}^n$ convexo con $\text{int } C \neq \emptyset$. Demuestra, usando el Lema 2.26, que $\text{cl}(\text{int } C) = \text{cl } C$. (Comentario: este es el análogo “con interior ordinario” de la identidad $\text{cl}(\text{ri } C) = \text{cl } C$ del Teorema 2.31, y el argumento de este ejercicio es exactamente el que se usa allí.)

Solución. *Inclusión $\subseteq$* : como $\text{int } C \subseteq C$, tomar clausura preserva la inclusión (la clausura es monótona: si $A \subseteq B$ entonces $\text{cl } A \subseteq \text{cl } B$, pues todo límite de puntos de A es límite de puntos de B), de modo que $\text{cl}(\text{int } C) \subseteq \text{cl } C$.

Inclusión $\supseteq$: sea $y \in \text{cl } C$; queremos ver que y es límite de puntos de $\text{int } C$. Fijemos un punto $x \in \text{int } C$ (existe por hipótesis). Por el Lema 2.26, para cada $\lambda \in (0, 1]$ el punto

$$z_\lambda = \lambda x + (1 - \lambda)y$$

pertenece a $\text{int } C$. Ahora tomemos la sucesión $\lambda_k = 1/k$ y calculemos el límite de z_{λ_k} cuando

$k \rightarrow \infty$:

$$\|z_{\lambda_k} - y\| = \left\| \frac{1}{k}x + \left(1 - \frac{1}{k}\right)y - y \right\| = \left\| \frac{1}{k}(x - y) \right\| = \frac{1}{k} \|x - y\| \longrightarrow 0,$$

donde simplemente agrupamos $(1 - \frac{1}{k})y - y = -\frac{1}{k}y$ y factorizamos $\frac{1}{k}$. Así, (z_{λ_k}) es una sucesión de puntos de $\text{int } C$ que converge a y , luego $y \in \text{cl}(\text{int } C)$. Ambas inclusiones dan $\text{cl}(\text{int } C) = \text{cl } C$. Geométricamente: un convexo con interior no vacío es la clausura de su interior; no tiene “pelos” ni “antenas” de dimensión menor pegadas al cuerpo principal (compara con [6], cap. 2, y [3], cap. 2). $\square$

Capítulo 3

Estructura cónica, cápsula convexa y cápsula afín [P2]

Semana 2 del cronograma. Bibliografía: Aragón et al. [1].

¿Para qué sirve esto en Microeconomía?

Este capítulo aporta tres herramientas que reaparecen en Microeconomía:

- **Decisión individual y diseño de mecanismos.** Una *lotería* sobre un conjunto de premios es exactamente una *combinación convexa* de esos premios, el objeto básico de la elección bajo incertidumbre (MWG cap. 6). El **teorema de Carathéodory** (Teorema 3.15) dice que cualquier resultado esperado en $\mathbb{R}^n$ alcanzable con una lotería complicada se replica con una lotería de a lo más $n + 1$ premios: por eso los mecanismos aleatorios óptimos, en la parte de bienestar e incentivos (MWG cap. 23), pueden buscarse entre loterías “pequeñas”. La aleatorización (randomization) en contratos y mecanismos vive matemáticamente en la cápsula convexa.
- **Equilibrio general (MWG caps. 15–18).** Una tecnología con *retornos constantes a escala* es un **cono** (Ejemplo 3.7); la *libre disposición* (free disposal) se modela sumando el cono $-\mathbb{R}_+^n$ al conjunto de producción; y el **cono de recesión** (Sección 3.6) aparece en las demostraciones de existencia de equilibrio, donde hay que garantizar que los conjuntos de asignaciones factibles sean acotados [9, cap. 17].
- **Puntos extremos.** Las asignaciones del núcleo y los contratos óptimos de tipo *bang-bang* (todo o nada) son puntos extremos de conjuntos convexos: un objetivo lineal sobre un compacto convexo siempre alcanza su óptimo en un punto extremo (Teorema 3.21).

En el capítulo anterior estudiamos los conjuntos convexos: aquellos que contienen el segmento entre cualesquiera dos de sus puntos. Este capítulo estudia tres estructuras emparentadas. Primero, los *conos*, conjuntos cerrados bajo el escalamiento de sus puntos: son el lenguaje natural de todo fenómeno “proporcional”, como una tecnología con retornos constantes a escala. Segundo, las *cápsulas* (convexa, afín y cónica): dado un conjunto arbitrario S , que puede ser feo (finito, disconexo, con huecos), la cápsula es el conjunto “bueno” más pequeño que lo contiene;

convexificar un conjunto es una operación constante en economía (loterías, convexificación de tecnologías, núcleo de una economía). Tercero, los *puntos extremos*: los puntos de un convexo que no son promedio de otros; el teorema de Minkowski dirá que un compacto convexo se reconstruye por completo a partir de ellos, y de ahí saldrá el resultado más usado de todo el capítulo: *un objetivo lineal sobre un compacto convexo se optimiza en un punto extremo*.

3.1. Conos y conos convexos [P2]

Motivación: escalar sin cambiar de naturaleza

Piensa en una empresa cuya tecnología permite producir 1 tonelada de acero usando 2 toneladas de mineral y 1 unidad de trabajo. Si la tecnología tiene *retornos constantes a escala*, entonces también puede producir 10 toneladas usando 20 de mineral y 10 de trabajo: multiplicar el plan de producción por cualquier número positivo produce otro plan factible. El conjunto de planes factibles es, entonces, un conjunto que “contiene todos los rayos que salen del origen y pasan por sus puntos”. Esa es exactamente la noción de cono.

Definición 3.1 (Cono). Un conjunto $C \subseteq \mathbb{R}^n$ es un **cono** (cone) si es cerrado bajo multiplicación por escalares positivos, es decir, si

$$x \in C, \lambda > 0 \implies \lambda x \in C.$$

Si además C es un conjunto convexo, decimos que C es un **cono convexo** (convex cone).

Observación 3.2. Algunos textos, como [2, cap. 2], exigen $\lambda \geq 0$ (con lo cual todo cono no vacío contiene al origen 0, pues $0 \cdot x = 0$); otros piden solo $\lambda > 0$. La diferencia es menor: con $\lambda > 0$, un cono puede contener o no al origen. En este cuaderno usamos $\lambda > 0$ y diremos explícitamente cuándo necesitamos $0 \in C$. En los ejemplos importantes ($\mathbb{R}_+^n$, cono de segundo orden, conos generados con $\lambda \geq 0$) el origen siempre está.

Geométricamente, un cono es una unión de *rayos* (semirrectas) que parten del origen: si $x \in C$, todo el rayo $\{\lambda x : \lambda > 0\}$ está en C . Un cono no tiene por qué ser convexo: la unión de los dos ejes coordenados de $\mathbb{R}^2$, $C = \{(t, 0) : t \in \mathbb{R}\} \cup \{(0, t) : t \in \mathbb{R}\}$, es un cono (escalar un punto de un eje lo deja en ese eje), pero no es convexo: $(1, 0)$ y $(0, 1)$ están en C , pero su punto medio $(1/2, 1/2)$ no.

La caracterización siguiente es el resultado central sobre conos convexos: sustituye la condición de convexidad (que involucra combinaciones con pesos λ y $1 - \lambda$) por dos condiciones algebraicas mucho más manejables.

Proposición 3.3 (Caracterización de los conos convexos). *Un conjunto no vacío $C \subseteq \mathbb{R}^n$ es un cono convexo si y solo si es cerrado bajo sumas y bajo multiplicación por escalares positivos:*

$$x, y \in C \implies x + y \in C \quad y \quad x \in C, \lambda > 0 \implies \lambda x \in C.$$

Demostración. Demostramos las dos implicaciones por separado.

($\Rightarrow$) Supongamos que C es un cono convexo. La cerradura bajo escalares positivos es la definición misma de cono, así que solo falta la cerradura bajo sumas. Sean $x, y \in C$. Como C es convexo, contiene la combinación convexa con pesos $\frac{1}{2}$ y $\frac{1}{2}$:

$$\frac{1}{2}x + \frac{1}{2}y \in C.$$

Como C es cono, podemos escalar este punto por $\lambda = 2 > 0$ y seguir dentro de C :

$$2\left(\frac{1}{2}x + \frac{1}{2}y\right) = x + y \in C.$$

Observa el truco: la convexidad solo da *promedios*, pero la estructura cónica permite “inflar” el promedio hasta convertirlo en la suma.

($\Leftarrow$) Supongamos ahora que C es cerrado bajo sumas y bajo escalares positivos. La segunda propiedad dice directamente que C es un cono. Veamos que es convexo. Sean $x, y \in C$ y $\lambda \in (0, 1)$ (los casos $\lambda = 0$ y $\lambda = 1$ dan y o x , que ya están en C). Como $\lambda > 0$ y $1 - \lambda > 0$, la cerradura bajo escalares positivos da

$$\lambda x \in C \quad \text{y} \quad (1 - \lambda)y \in C,$$

y la cerradura bajo sumas da

$$\lambda x + (1 - \lambda)y \in C.$$

Esto es exactamente la definición de convexidad. □

Intuición

La Proposición 3.3 dice que un cono convexo es lo más parecido a un subespacio vectorial sin serlo: en un subespacio puedes sumar y escalar por *cualquier* escalar; en un cono convexo puedes sumar y escalar solo por escalares *positivos*. Por eso los conos convexos son el modelo natural de situaciones económicas donde las cantidades no pueden ser negativas o donde la dirección importa: producir el doble tiene sentido, “producir -1 veces” no. De hecho, un cono convexo C que además cumple $C = -C$ es exactamente un subespacio vectorial.

Una consecuencia inmediata (aplicando la proposición repetidamente) es que un cono convexo es cerrado bajo **combinaciones cónicas**: si $x_1, \dots, x_k \in C$ y $\lambda_1, \dots, \lambda_k > 0$, entonces $\lambda_1 x_1 + \dots + \lambda_k x_k \in C$. Nota la diferencia con las combinaciones convexas: aquí los pesos son positivos pero *no* tienen que sumar 1.

Ejemplos fundamentales

Ejemplo 3.4 (El ortante no negativo). El **ortante no negativo** (nonnegative orthant)

$$\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x_i \geq 0 \text{ para todo } i = 1, \dots, n\}$$

es un cono convexo. Verifiquémoslo con la Proposición 3.3. Si $x, y \in \mathbb{R}_+^n$, cada coordenada de $x + y$ es $x_i + y_i \geq 0 + 0 = 0$, luego $x + y \in \mathbb{R}_+^n$. Si $\lambda > 0$, cada coordenada de λx es $\lambda x_i \geq 0$, luego $\lambda x \in \mathbb{R}_+^n$. En economía, $\mathbb{R}_+^n$ es el espacio de las canastas de consumo: cantidades no negativas

de n bienes.

Ejemplo 3.5 (El cono de segundo orden). El **cono de segundo orden** (second-order cone), también llamado *cono de Lorentz* o *cono de helado* (ice cream cone), es

$$\mathcal{K}_n = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : \|x\| \leq t\} \subseteq \mathbb{R}^{n+1},$$

donde $\|\cdot\|$ es la norma euclidiana. En $\mathbb{R}^3$ (es decir, $n = 2$), es literalmente un cono de helado apoyado en el origen y abriéndose hacia arriba: en la altura t , la “rebanada” horizontal es el disco de radio t .

Verifiquemos que es un cono convexo usando la Proposición 3.3.

- *Escalares positivos*: si $\|x\| \leq t$ y $\lambda > 0$, entonces $\|\lambda x\| = \lambda \|x\| \leq \lambda t$ (usamos la homogeneidad de la norma, vista en los preliminares), luego $(\lambda x, \lambda t) \in \mathcal{K}_n$.
- *Sumas*: si $\|x\| \leq t$ y $\|y\| \leq s$, la desigualdad triangular da

$$\|x + y\| \leq \|x\| + \|y\| \leq t + s,$$

luego $(x + y, t + s) \in \mathcal{K}_n$.

Este cono es la pieza básica de la *programación cónica de segundo orden*, una clase de problemas de optimización que generaliza la programación lineal [2, sec. 2.2.3].

Ejemplo 3.6 (Cono generado por un conjunto). Dado cualquier conjunto no vacío $S \subseteq \mathbb{R}^n$, el **cono generado** por S es el conjunto de todos los múltiplos no negativos de puntos de S :

$$\{\lambda x : x \in S, \lambda \geq 0\}.$$

Por ejemplo, si $S = \{(1, 1)\} \subset \mathbb{R}^2$, el cono generado es el rayo que sale del origen en dirección $(1, 1)$. Si $S = \{(1, 0), (0, 1)\}$, el cono generado es la unión de los dos semiejes positivos: un cono, pero *no* convexo. Para obtener un cono convexo hay que cerrar además bajo sumas; eso es la *cápsula cónica* $\text{cono}(S)$ que definiremos en la Sección 3.2.




Figura 3.1: Un cono convexo $C \subseteq \mathbb{R}^2$ generado por dos rayos. Contiene todos los múltiplos positivos de sus puntos $(2x)$ y todas las sumas de sus puntos $(x + y)$, como garantiza la Proposición 3.3.

Ejemplo económico: retornos constantes a escala y libre disposición

Ejemplo 3.7 (Tecnología con retornos constantes a escala). En la teoría del productor [9, cap. 5], una tecnología se describe con un **conjunto de producción** $Y \subseteq \mathbb{R}^n$: cada $y \in Y$ es un *plan de producción* donde las coordenadas negativas son insumos y las positivas son productos. Por ejemplo, $y = (-2, -1, 1)$ significa “usar 2 unidades del bien 1 y 1 unidad del bien 2 para producir 1 unidad del bien 3”.

La tecnología exhibe **retornos constantes a escala** (constant returns to scale) si

$$y \in Y, \lambda \geq 0 \implies \lambda y \in Y,$$

es decir, exactamente si Y es un cono (que contiene al origen: no producir nada es factible). Si además Y es convexo (la interpretación económica: se pueden combinar procesos productivos sin pérdida), entonces Y es un cono convexo y, por la Proposición 3.3, dos planes factibles pueden *operarse en paralelo*: $y, y' \in Y \Rightarrow y + y' \in Y$. Esta propiedad, llamada *aditividad*, es la que hace que en equilibrio competitivo con retornos constantes el beneficio máximo sea cero: si un plan y diera beneficio $p \cdot y > 0$, escalarlo por $\lambda \rightarrow \infty$ daría beneficios ilimitados, incompatible con la existencia de un máximo [9, sec. 5.B].

La **libre disposición** (free disposal) es el supuesto de que siempre es posible desechar bienes sin costo: si $y \in Y$ y $y' \leq y$ coordenada a coordenada (produce menos o usa más insumos), entonces $y' \in Y$. En notación de conjuntos:

$$Y - \mathbb{R}_+^n \subseteq Y, \quad \text{donde } Y - \mathbb{R}_+^n = \{y - z : y \in Y, z \in \mathbb{R}_+^n\}.$$

Es decir, la libre disposición equivale a que Y absorba al cono $-\mathbb{R}_+^n$ bajo sumas. Este supuesto, aparentemente inocuo, es clave en las demostraciones de existencia de equilibrio general [9, cap. 17]: garantiza que los precios de equilibrio sean no negativos.

3.2. Cápsula convexa, afín y cónica [P2]

Motivación: el convexo más pequeño que contiene a S

Muchos conjuntos que aparecen en la práctica no son convexos: un conjunto finito de puntos (los premios posibles de una lotería), una tecnología con indivisibilidades, la unión de dos regiones. Sin embargo, casi toda la maquinaria de optimización y de teoría económica requiere convexidad. La salida estándar es *convexificar*: sustituir S por el conjunto convexo más pequeño que lo contiene. La sorpresa agradable es que ese conjunto abstracto (“el menor convexo que contiene a S ”) tiene una descripción completamente concreta: es el conjunto de todas las combinaciones convexas de puntos de S . Probar esa equivalencia es el objetivo central de esta sección.

Recordemos del capítulo anterior: una **combinación convexa** de los puntos $x_1, \dots, x_k \in \mathbb{R}^n$ es cualquier punto de la forma

$$\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k, \quad \text{con } \lambda_i \geq 0 \text{ para todo } i \text{ y } \sum_{i=1}^k \lambda_i = 1.$$

Los pesos λ_i se interpretan de forma natural como *probabilidades*: una combinación convexa de premios es el valor esperado de una lotería sobre esos premios.

Definición 3.8 (Cápsula convexa). Sea $S \subseteq \mathbb{R}^n$ un conjunto no vacío. La **cápsula convexa** (convex hull) de S , denotada $\text{conv}(S)$, es la intersección de todos los conjuntos convexos que contienen a S :

$$\text{conv}(S) = \bigcap \{D \subseteq \mathbb{R}^n : D \text{ es convexo y } S \subseteq D\}.$$

Dos comentarios para que la definición no parezca un truco. Primero, la familia sobre la que se interseca no es vacía: $\mathbb{R}^n$ mismo es convexo y contiene a S . Segundo, en el capítulo anterior probamos que *la intersección de cualquier familia de conjuntos convexos es convexa*; por lo tanto $\text{conv}(S)$ es convexo, contiene a S (todos los conjuntos intersecados lo contienen), y es el *menor* con esas propiedades: si D es convexo y $S \subseteq D$, entonces D es uno de los conjuntos de la familia, así que $\text{conv}(S) \subseteq D$.

La definición como intersección es elegante pero inservible para calcular. El siguiente teorema da la descripción operativa.

Teorema 3.9 (La cápsula convexa es el conjunto de combinaciones convexas). *Para todo conjunto no vacío $S \subseteq \mathbb{R}^n$,*

$$\text{conv}(S) = \left\{ \sum_{i=1}^k \lambda_i x_i : k \in \mathbb{N}, x_i \in S, \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1 \right\}.$$

Demostración. Llamemos M al conjunto de la derecha (todas las combinaciones convexas de finitos puntos de S). Hay que probar dos inclusiones.

Paso 1: M es convexo y contiene a S ; por lo tanto $\text{conv}(S) \subseteq M$.

Que $S \subseteq M$ es inmediato: cada $x \in S$ es la combinación convexa “trivial” de un solo punto ($k = 1, \lambda_1 = 1$).

Veamos que M es convexo. Tomemos dos puntos de M :

$$u = \sum_{i=1}^k \lambda_i x_i, \quad v = \sum_{j=1}^m \mu_j y_j,$$

con $x_i, y_j \in S$, pesos no negativos, $\sum_i \lambda_i = 1$ y $\sum_j \mu_j = 1$. Sea $\theta \in [0, 1]$. Entonces

$$\theta u + (1 - \theta)v = \sum_{i=1}^k (\theta \lambda_i) x_i + \sum_{j=1}^m ((1 - \theta) \mu_j) y_j.$$

Esta expresión es de nuevo una combinación de puntos de S (los $k + m$ puntos $x_1, \dots, x_k, y_1, \dots, y_m$) con pesos $\theta \lambda_i \geq 0$ y $(1 - \theta) \mu_j \geq 0$. Verifiquemos que los pesos suman 1:

$$\sum_{i=1}^k \theta \lambda_i + \sum_{j=1}^m (1 - \theta) \mu_j = \theta \underbrace{\sum_{i=1}^k \lambda_i}_{=1} + (1 - \theta) \underbrace{\sum_{j=1}^m \mu_j}_{=1} = \theta + (1 - \theta) = 1.$$

Luego $\theta u + (1 - \theta)v \in M$, y M es convexo. Como $\text{conv}(S)$ es el *menor* convexo que contiene a S , concluimos $\text{conv}(S) \subseteq M$.

Paso 2: todo convexo que contiene a S contiene a M ; por lo tanto $M \subseteq \text{conv}(S)$.

Sea D convexo con $S \subseteq D$. Probamos por inducción sobre k que toda combinación convexa de k puntos de S está en D .

Base ($k = 1$): la combinación es un punto de S , que está en D por hipótesis. (El caso $k = 2$ es la definición misma de convexidad de D .)

Paso inductivo: supongamos el resultado cierto para $k - 1$ puntos, y sea

$$z = \sum_{i=1}^k \lambda_i x_i, \quad x_i \in S, \lambda_i \geq 0, \sum_{i=1}^k \lambda_i = 1.$$

Si $\lambda_k = 1$, entonces todos los demás pesos son cero y $z = x_k \in D$. Supongamos $\lambda_k < 1$, de modo que $1 - \lambda_k = \sum_{i=1}^{k-1} \lambda_i > 0$. El truco es *reagrupar*: separamos el último término y renormalizamos los primeros $k - 1$ pesos para que sumen 1:

$$z = (1 - \lambda_k) \underbrace{\sum_{i=1}^{k-1} \frac{\lambda_i}{1 - \lambda_k} x_i}_{=: w} + \lambda_k x_k.$$

Los nuevos pesos $\lambda_i/(1 - \lambda_k)$ son no negativos y suman

$$\sum_{i=1}^{k-1} \frac{\lambda_i}{1 - \lambda_k} = \frac{1 - \lambda_k}{1 - \lambda_k} = 1,$$

así que w es una combinación convexa de $k - 1$ puntos de S y, por hipótesis de inducción, $w \in D$. Finalmente, $z = (1 - \lambda_k)w + \lambda_k x_k$ es una combinación convexa de *dos* puntos de D (w y x_k), luego $z \in D$ por convexidad de D . Esto cierra la inducción.

Aplicando el Paso 2 con $D = \text{conv}(S)$ (que es convexo y contiene a S) obtenemos $M \subseteq \text{conv}(S)$. Las dos inclusiones dan la igualdad. $\square$


Intuición

Piensa en $\text{conv}(S)$ como “el conjunto de todo lo alcanzable mediante loterías sobre S ”. Si S es el conjunto de premios que un mecanismo puede entregar (en dinero, en canastas, en vectores de utilidades), entonces $\text{conv}(S)$ es el conjunto de *valores esperados* que el diseñador puede inducir aleatorizando entre premios. La demostración del Teorema 3.9 tiene además una lectura probabilística encantadora: el paso inductivo dice que una lotería sobre k premios se puede realizar en dos etapas: primero se sortea “ x_k o no x_k ” con probabilidades λ_k y $1 - \lambda_k$, y si sale “no”, se juega la lotería condicional sobre los otros $k - 1$ premios. Las loterías compuestas se reducen a loterías simples: este es el mismo argumento del axioma de reducción en teoría de la utilidad esperada [9, cap. 6].

Ejemplo 3.10 (Cápsula convexa de tres puntos). Sea $S = \{(0, 0), (2, 0), (0, 2)\} \subset \mathbb{R}^2$. Por el Teorema 3.9,

$$\begin{aligned} \text{conv}(S) &= \{\lambda_1(0, 0) + \lambda_2(2, 0) + \lambda_3(0, 2) : \lambda_i \geq 0, \lambda_1 + \lambda_2 + \lambda_3 = 1\} \\ &= \{(2\lambda_2, 2\lambda_3) : \lambda_2, \lambda_3 \geq 0, \lambda_2 + \lambda_3 \leq 1\}, \end{aligned}$$

que es el triángulo (relleno) con vértices en los tres puntos: $\text{conv}(S) = \{(u, v) \in \mathbb{R}_+^2 : u + v \leq 2\}$. Verifiquemos un punto concreto: $(1, \frac{1}{2})$ se obtiene con $\lambda_2 = \frac{1}{2}$, $\lambda_3 = \frac{1}{4}$, $\lambda_1 = \frac{1}{4}$. En general, la cápsula convexa de finitos puntos es un *politopo* (Sección 3.5), y los pesos λ_i son sus “coordenadas baricéntricas”.



$S =$ los 7 puntos; su cápsula convexa es el pentágono

Figura 3.2: La cápsula convexa de un conjunto finito S de puntos en $\mathbb{R}^2$. Los cinco puntos negros son los *puntos extremos* (Sección 3.4); los dos grises, al ser combinación convexa de los otros, no aportan nada a la cápsula.

Cápsula afín y dimensión

La cápsula convexa usa pesos no negativos que suman 1. Si mantenemos la restricción de que sumen 1 pero *permitimos pesos negativos*, obtenemos las combinaciones afines y la cápsula afín, que ya asomó en el capítulo anterior al definir el interior relativo. Recogemos aquí la definición para tener el cuadro completo.

Definición 3.11 (Cápsula afín y dimensión). Una **combinación afín** (affine combination) de $x_1, \dots, x_k \in \mathbb{R}^n$ es un punto $\sum_{i=1}^k \lambda_i x_i$ con $\sum_{i=1}^k \lambda_i = 1$ (pesos de cualquier signo). La **cápsula afín** (affine hull) de $S \subseteq \mathbb{R}^n$, denotada $\text{aff}(S)$, es el menor conjunto afín que contiene a S ; igual que en el Teorema 3.9 (misma demostración, sin la restricción de signo), coincide con el conjunto de todas las combinaciones afines de puntos de S . La **dimensión** de un conjunto convexo S se define como la dimensión de $\text{aff}(S)$ como trasladado de un subespacio: si $\text{aff}(S) = x_0 + V$ con V subespacio vectorial, entonces $\dim S = \dim V$.

Ejemplo 3.12. Con $S = \{(0, 0), (2, 0), (0, 2)\}$ del Ejemplo 3.10: $\text{conv}(S)$ es el triángulo, pero $\text{aff}(S) = \mathbb{R}^2$ entero, porque con pesos que pueden ser negativos se alcanza cualquier punto del plano; por ejemplo, $(-2, 0) = 2 \cdot (0, 0) + (-1) \cdot (2, 0) + 0 \cdot (0, 2)$, con pesos $2 - 1 + 0 = 1$. Así, el triángulo tiene dimensión 2. En cambio, si $S' = \{(0, 0), (2, 0)\}$, entonces $\text{conv}(S')$ es el segmento entre ambos puntos, $\text{aff}(S')$ es todo el eje horizontal $\{(t, 0) : t \in \mathbb{R}\}$, y $\dim \text{conv}(S') = 1$: el segmento es un objeto unidimensional aunque viva en $\mathbb{R}^2$. La cápsula afín es el “universo natural” del conjunto, y es respecto de ella que se define el interior relativo $\text{ri}(S)$ del capítulo anterior.

Cápsula cónica

Definición 3.13 (Cápsula cónica). La **cápsula cónica** (conic hull) de un conjunto no vacío $S \subseteq \mathbb{R}^n$, denotada $\text{cono}(S)$, es el menor cono convexo que contiene a S junto con el origen.

Coincide con el conjunto de todas las *combinaciones cónicas* de puntos de S :

$$\text{cono}(S) = \left\{ \sum_{i=1}^k \lambda_i x_i : k \in \mathbb{N}, x_i \in S, \lambda_i \geq 0 \right\}.$$

(La demostración de la equivalencia calca la del Teorema 3.9, quitando la restricción $\sum_i \lambda_i = 1$; con todos los $\lambda_i = 0$ se obtiene el origen.)

Ejemplo 3.14. $\text{cono}(\{(1,0), (0,1)\}) = \mathbb{R}_+^2$: toda combinación $\lambda_1(1,0) + \lambda_2(0,1) = (\lambda_1, \lambda_2)$ con $\lambda_1, \lambda_2 \geq 0$ recorre exactamente el ortante. Compara con el Ejemplo 3.6: el *cono generado* por esos dos puntos (solo escalar, sin sumar) era la unión de los dos semiejes; la *cápsula cónica* rellena todo el cuadrante. En general, $\text{cono}(S) = \{\lambda x : x \in \text{conv}(S), \lambda \geq 0\}$: primero convexificar, luego escalar.

Cuidado (error común)

Tres errores frecuentes con las cápsulas.

1. **Confundir las tres familias de pesos.** Convexa: $\lambda_i \geq 0$ y $\sum \lambda_i = 1$. Cónica: $\lambda_i \geq 0$ sin restricción de suma. Afín: $\sum \lambda_i = 1$ sin restricción de signo. Con ambas restricciones a la vez se obtiene el conjunto más chico (conv); sin ninguna, el más grande (el subespacio generado, span). En un examen, identifica *primero* qué restricciones tienen los pesos.
2. **Crear que $\text{conv}(S)$ de un conjunto cerrado es cerrada.** Es falso en general: si $S = \{(t, 1/t) : t > 0\} \cup \{(0,0)\} \subset \mathbb{R}^2$ (una rama de hipérbola más el origen), S es cerrado, pero $\text{conv}(S)$ contiene puntos $(t, 1/t)$ combinados con $(0,0)$ que se acumulan sobre el semieje horizontal abierto $\{(t,0) : t > 0\}$, el cual *no* pertenece a $\text{conv}(S)$: la cápsula no es cerrada. Lo que sí es cierto: la cápsula convexa de un conjunto *compacto* es compacta (Ejercicio 3.32).
3. **Olvidar el origen en $\text{cono}(S)$.** La cápsula cónica siempre contiene a 0 (tomando todos los pesos nulos), aunque $0 \notin S$.

3.3. El teorema de Carathéodory [P2]

El Teorema 3.9 describe $\text{conv}(S)$ mediante combinaciones de *finitos* puntos de S , pero no dice cuántos: en principio, un punto de la cápsula podría requerir combinar un millón de puntos. El teorema de Carathéodory pone una cota notablemente pequeña que depende solo de la dimensión del espacio: en $\mathbb{R}^n$ *nunca hacen falta más de $n+1$ puntos*. En $\mathbb{R}^2$, todo punto de $\text{conv}(S)$ es combinación de a lo más 3 puntos de S (está dentro de un triángulo con vértices en S); en $\mathbb{R}^3$, de a lo más 4; etcétera.

Teorema 3.15 (Carathéodory). *Sea $S \subseteq \mathbb{R}^n$ no vacío. Todo punto de $\text{conv}(S)$ puede escribirse como combinación convexa de a lo más $n+1$ puntos de S .*

Demostración. Sea $z \in \text{conv}(S)$. Por el Teorema 3.9, existe alguna representación

$$z = \sum_{i=1}^k \lambda_i x_i, \quad x_i \in S, \quad \lambda_i > 0, \quad \sum_{i=1}^k \lambda_i = 1$$

(podemos suponer todos los pesos estrictamente positivos: los términos con peso cero se descartan sin cambiar nada). Entre todas las representaciones posibles, tomemos una con el número de puntos k mínimo. La estrategia es demostrar: *si $k \geq n + 2$, entonces se puede construir otra representación con $k - 1$ puntos*, contradiciendo la minimalidad. De ahí seguirá $k \leq n + 1$.

Paso 1: encontrar una dependencia afín. Supongamos $k \geq n + 2$. Consideremos los $k - 1 \geq n + 1$ vectores

$$x_2 - x_1, x_3 - x_1, \dots, x_k - x_1 \in \mathbb{R}^n.$$

Son al menos $n + 1$ vectores en un espacio de dimensión n , así que son *linealmente dependientes*: existen escalares $\mu_2, \dots, \mu_k$, no todos nulos, con

$$\sum_{i=2}^k \mu_i (x_i - x_1) = 0.$$

Definiendo $\mu_1 = -\sum_{i=2}^k \mu_i$, la ecuación anterior se reescribe como

$$\sum_{i=1}^k \mu_i x_i = 0 \quad \text{con} \quad \sum_{i=1}^k \mu_i = 0,$$

y no todos los μ_i son cero. Esto se llama una *dependencia afín* entre los x_i . Como los μ_i suman cero y no son todos nulos, *al menos uno es estrictamente positivo*.

Paso 2: perturbar los pesos sin cambiar el punto. Para cualquier $t \in \mathbb{R}$, usando $\sum_i \mu_i x_i = 0$:

$$z = \sum_{i=1}^k \lambda_i x_i - t \underbrace{\sum_{i=1}^k \mu_i x_i}_{=0} = \sum_{i=1}^k (\lambda_i - t\mu_i) x_i.$$

Además los nuevos pesos siguen sumando 1, porque $\sum_i (\lambda_i - t\mu_i) = \sum_i \lambda_i - t \sum_i \mu_i = 1 - t \cdot 0 = 1$. Es decir: tenemos una *familia de representaciones* de z , una por cada t , y solo falta elegir t para que todos los pesos sigan siendo no negativos y *alguno se anule*.

Paso 3: elegir el t óptimo. Los pesos $\lambda_i - t\mu_i$ con $\mu_i \leq 0$ no decrecen al crecer $t \geq 0$; los que tienen $\mu_i > 0$ decrecen linealmente y en algún momento tocan cero. Elegimos t como el primer instante en que algún peso se anula:

$$t^* = \min_{i: \mu_i > 0} \frac{\lambda_i}{\mu_i} > 0,$$

que está bien definido porque existe al menos un $\mu_i > 0$ (Paso 1), y es positivo porque los λ_i lo son. Sea j un índice donde se alcanza el mínimo. Entonces, para cada i :

- si $\mu_i \leq 0$: $\lambda_i - t^* \mu_i \geq \lambda_i > 0 \geq 0$;
- si $\mu_i > 0$: $\lambda_i - t^* \mu_i = \mu_i \left(\frac{\lambda_i}{\mu_i} - t^* \right) \geq 0$, por definición de t^* como el mínimo de los cocientes;

- y para $i = j$: $\lambda_j - t^* \mu_j = \mu_j \left(\frac{\lambda_j}{\mu_j} - \frac{\lambda_j}{\mu_j} \right) = 0$.

Así, $z = \sum_{i \neq j} (\lambda_i - t^* \mu_i) x_i$ es una combinación convexa de a lo más $k - 1$ puntos de S : hemos eliminado el punto x_j . Esto contradice la minimalidad de k . Por lo tanto $k \leq n + 1$. $\square$

Intuición

La demostración es un *algoritmo de poda*: mientras la lotería use “demasiados” premios ($k \geq n + 2$), sus premios están afinmente ligados, y esa ligadura permite deslizar probabilidad de unos premios a otros (t es cuánto deslizamos) *sin mover el valor esperado* z , hasta que la probabilidad de algún premio llega exactamente a cero y ese premio se elimina. Repitiendo, se baja hasta $n + 1$ premios. Este mismo esquema de “perturbar a lo largo de una dirección de dependencia hasta anular una variable” es el corazón del método simplex de programación lineal y reaparecerá en el capítulo correspondiente. Puedes ver [3, cap. 2] y [6, lema 2.5] para otras presentaciones de esta prueba.

La versión para cápsulas cónicas es análoga y la cota mejora en uno, porque desaparece la restricción $\sum_i \lambda_i = 1$ (una ecuación menos que satisfacer).

Teorema 3.16 (Carathéodory, versión cónica). *Sea $S \subseteq \mathbb{R}^n$ no vacío. Todo punto de $\text{cono}(S)$ es combinación cónica de a lo más n puntos de S .*

Idea de la demostración. Se repite el argumento anterior con una representación minimal $z = \sum_{i=1}^k \lambda_i x_i$, $\lambda_i > 0$. Si $k \geq n + 1$, los vectores $x_1, \dots, x_k$ (¡ellos mismos, no sus diferencias!) son linealmente dependientes: $\sum_i \mu_i x_i = 0$ con algún $\mu_i \neq 0$; cambiando el signo de todos los μ_i si es preciso, alguno es positivo. Ya no se necesita $\sum_i \mu_i = 0$, porque los pesos cónicos no tienen que sumar 1. La misma elección $t^* = \min_{\mu_i > 0} \lambda_i / \mu_i$ anula un peso conservando la no negatividad de los demás, y se concluye $k \leq n$. Ver [3, cap. 2]. $\square$

Aplicación económica: cuántos premios necesita una lotería

Ejemplo 3.17 (Reducción de loterías en diseño de mecanismos). En diseño de mecanismos, el diseñador a menudo se beneficia de *aleatorizar*: en vez de asignar un resultado determinista, asigna una lotería sobre resultados (piensa en subastas con asignación aleatoria de desempate, en contratos con bonos estocásticos, o en mecanismos de asignación de plazas escolares por sorteo). Formalicemos con Carathéodory por qué esa aleatorización nunca necesita ser complicada.

Supongamos que cada resultado posible se resume en un vector de $\mathbb{R}^n$: por ejemplo, n podría ser el número de agentes y cada resultado $x \in S \subseteq \mathbb{R}^n$ el vector de utilidades (o de transferencias) que ese resultado genera para los agentes. Una lotería con soporte finito que asigna probabilidad p_i al resultado $x_i \in S$, $i = 1, \dots, k$, induce el vector esperado

$$\bar{x} = \sum_{i=1}^k p_i x_i, \quad p_i \geq 0, \quad \sum_{i=1}^k p_i = 1.$$

Si los agentes son neutrales al riesgo en estas variables (supuesto habitual cuando x son transferencias monetarias esperadas o probabilidades de asignación), todo lo que importa del mecanismo

es $\bar{x}$. Ahora bien, $\bar{x}$ es por construcción un punto de $\text{conv}(S)$, y el conjunto de vectores esperados implementables por *alguna* lotería es exactamente $\text{conv}(S)$. El Teorema 3.15 dice entonces:

cualquier vector esperado alcanzable con una lotería arbitraria (incluso con soporte enorme) es alcanzable con una lotería de a lo más $n + 1$ premios.

Consecuencias prácticas:

1. **Simplicidad sin pérdida.** Al buscar el mecanismo aleatorio óptimo, el diseñador puede restringirse sin pérdida de generalidad a loterías con soporte de tamaño $n + 1$. El problema de diseño pasa de ser una optimización sobre un espacio de medidas de probabilidad (de dimensión infinita) a una sobre finitos pesos y premios.
2. **Con una restricción esperada adicional, un premio más.** Si además la lotería debe cumplir una restricción en esperanza, por ejemplo un costo esperado fijo $\sum_i p_i c(x_i) = \bar{c}$, basta aplicar Carathéodory en $\mathbb{R}^{n+1}$ a los vectores aumentados $(x_i, c(x_i))$: se replican simultáneamente el vector esperado y el costo esperado con a lo más $(n + 1) + 1 = n + 2$ premios. Este truco de “aumentar la dimensión con las restricciones” es estándar en la literatura de mecanismos con aleatorización y en teoría de la información aplicada (persuasión bayesiana, donde las distribuciones a posteriori son combinaciones convexas que promedian a la a priori).
3. **Ejemplo numérico.** Un principal quiere inducir a un agente un pago esperado $\bar{x} = 50$ (aquí $n = 1$). Cualquier lotería sobre pagos con media 50, por compleja que sea, se replica con a lo más $n + 1 = 2$ premios: por ejemplo, pagar 0 con probabilidad 1/2 y 100 con probabilidad 1/2. Que baste una lotería binaria para replicar cualquier media es el caso más simple de Carathéodory, y explica por qué tantos contratos aleatorios óptimos de la literatura son binarios (“bono o no bono”).

3.4. Puntos extremos y el teorema de Minkowski [P2]

Motivación: los puntos que no son promedio de nadie

Mira otra vez la Figura 3.2: de los siete puntos de S , solo cinco “sostienen” la cápsula convexa; los dos grises son redundantes porque son promedios de los demás. Los puntos que sostienen un convexo (los que no pueden obtenerse promediando otros puntos del conjunto) se llaman puntos extremos, y son los protagonistas de la optimización lineal.

Definición 3.18 (Punto extremo). Sea $C \subseteq \mathbb{R}^n$ convexo. Un punto $x \in C$ es un **punto extremo** (extreme point) de C si no puede escribirse como combinación convexa estricta de dos puntos distintos de C ; es decir, si

$$x = \lambda y + (1 - \lambda)z, \quad y, z \in C, \quad \lambda \in (0, 1) \quad \implies \quad y = z = x.$$

Denotamos $\text{ext}(C)$ al conjunto de puntos extremos de C .

Dicho al revés: x *no* es extremo si está estrictamente dentro de algún segmento contenido en C . Un punto extremo necesariamente está en la frontera de C (si $x \in \text{int}(C)$, hay una bolita alrededor de x dentro de C , y x es el punto medio de un segmento diametral de esa bolita).

- Ejemplo 3.19** (Puntos extremos de figuras conocidas). 1. **Un triángulo** (relleno) en $\mathbb{R}^2$ tiene exactamente 3 puntos extremos: sus vértices. Un punto en el interior de una arista no es extremo (es promedio de los dos vértices de la arista); un punto del interior tampoco. En general, los puntos extremos de un politopo son sus *vértices* (Sección 3.5).
2. **La bola euclidiana cerrada** $B = \{x \in \mathbb{R}^n : \|x\| \leq 1\}$ tiene como puntos extremos exactamente a *toda* su esfera frontera $\{x : \|x\| = 1\}$: infinitos puntos extremos. Verifiquemos que x con $\|x\| = 1$ es extremo: si $x = \lambda y + (1 - \lambda)z$ con $\lambda \in (0, 1)$, $\|y\| \leq 1$ y $\|z\| \leq 1$, entonces por la desigualdad triangular $1 = \|x\| \leq \lambda\|y\| + (1 - \lambda)\|z\| \leq 1$; todas las desigualdades son igualdades, de modo que $\|y\| = \|z\| = 1$ y hay igualdad en la desigualdad triangular. En la norma euclidiana eso obliga a que λy y $(1 - \lambda)z$ sean múltiplos no negativos uno del otro (igualdad en Cauchy–Schwarz), es decir, y y z apuntan en la misma dirección; teniendo además la misma norma, $y = z$, y por lo tanto $y = z = x$.
3. **Un semiespacio** $\{x : \langle a, x \rangle \leq b\}$ con $a \neq 0$ no tiene ningún punto extremo: todo punto suyo está en medio de un segmento contenido en él (basta moverse en una dirección ortogonal a a). Los conjuntos no acotados pueden quedarse sin extremos; por eso el teorema siguiente pide compacidad.

Teorema 3.20 (Minkowski; Krein–Milman en dimensión finita). *Sea $C \subseteq \mathbb{R}^n$ un conjunto convexo y compacto (cerrado y acotado) no vacío. Entonces $\text{ext}(C) \neq \emptyset$ y*

$$C = \text{conv}(\text{ext}(C)) :$$

todo punto de C es combinación convexa de puntos extremos de C (por Carathéodory, de a lo más $n + 1$ de ellos).

Idea de la demostración. Se procede por inducción sobre la dimensión de C (Definición 3.11). Si $\dim C = 0$, C es un punto, que es extremo de sí mismo. Para el paso inductivo, sea $x \in C$.

Caso 1: x está en la frontera relativa de C . Por el teorema del hiperplano de apoyo (que se prueba en el capítulo de separación; aquí lo usamos como préstamo), existe un hiperplano H que “apoya” a C en x : C queda de un lado de H y $x \in H$. La cara $F = C \cap H$ es convexa, compacta y de dimensión estrictamente menor que la de C . Por hipótesis inductiva, $x \in F$ es combinación convexa de puntos extremos de F ; y un argumento directo muestra que todo punto extremo de una cara $F = C \cap H$ es también punto extremo de C (si un punto de F fuera promedio de dos puntos de C , ambos tendrían que estar en H , luego en F).

Caso 2: x está en el interior relativo de C . Se traza cualquier recta por x dentro de $\text{aff}(C)$; por compacidad de C , la recta corta la frontera relativa en dos puntos u, v , y x es combinación convexa de ellos: $x = \lambda u + (1 - \lambda)v$. Cada uno de u, v cae en el Caso 1, así que ambos son combinación convexa de extremos, y por lo tanto x también.

La demostración completa, con los detalles del hiperplano de apoyo, está en [3, cap. 3] y [6, teorema 2.30]; la versión en espacios de dimensión infinita es el teorema de Krein–Milman. $\square$

Intuición

El teorema de Minkowski dice que un compacto convexo queda *completamente codificado* por sus puntos extremos: son su “ADN”. En economía esto tiene dos lecturas. Primera: si el conjunto de asignaciones factibles (o de vectores de utilidades alcanzables) es compacto y convexo, entonces toda asignación es una lotería sobre asignaciones extremas; las asignaciones extremas son los “ladrillos” con los que se construye todo lo demás. Segunda: al analizar el núcleo (core) de una economía o el conjunto de pagos de equilibrio de un juego repetido, basta a menudo caracterizar los puntos extremos, porque el resto del conjunto se recupera convexificando.

La consecuencia clave para optimización

Teorema 3.21 (Un objetivo lineal se optimiza en un punto extremo). *Sea $C \subseteq \mathbb{R}^n$ convexo, compacto y no vacío, y sea $f(x) = \langle c, x \rangle$ una función lineal ($c \in \mathbb{R}^n$). Entonces el problema $\max_{x \in C} f(x)$ tiene solución, y al menos una solución es un punto extremo de C :*

$$\max_{x \in C} \langle c, x \rangle = \max_{x \in \text{ext}(C)} \langle c, x \rangle.$$

Lo mismo vale para el mínimo.

Demostración. Existencia. f es continua (es lineal) y C es compacto y no vacío; por el teorema de Weierstrass (visto en los preliminares), el máximo se alcanza en algún $x^* \in C$.

El máximo se alcanza en un extremo. Por el teorema de Minkowski (Teorema 3.20), x^* es combinación convexa de puntos extremos: existen $v_1, \dots, v_k \in \text{ext}(C)$ y pesos $\lambda_i > 0$ con $\sum_{i=1}^k \lambda_i = 1$ tales que $x^* = \sum_{i=1}^k \lambda_i v_i$. Por linealidad de f :

$$f(x^*) = \langle c, \sum_{i=1}^k \lambda_i v_i \rangle = \sum_{i=1}^k \lambda_i \langle c, v_i \rangle = \sum_{i=1}^k \lambda_i f(v_i).$$

Es decir, el valor óptimo $f(x^*)$ es un *promedio ponderado* de los valores $f(v_i)$. Un promedio nunca supera al mayor de sus términos, así que existe algún índice j con $f(v_j) \geq f(x^*)$. Formalmente: si fuera $f(v_i) < f(x^*)$ para todo i , entonces

$$f(x^*) = \sum_{i=1}^k \lambda_i f(v_i) < \sum_{i=1}^k \lambda_i f(x^*) = f(x^*),$$

una contradicción. Pero $f(x^*)$ es el valor máximo sobre C y $v_j \in C$, de modo que $f(v_j) \leq f(x^*)$. Concluimos $f(v_j) = f(x^*)$: el punto extremo v_j también es óptimo. Para el mínimo, aplica lo anterior a $-c$. $\square$

Este resultado, de demostración tan corta, es un puente hacia dos temas mayores:

1. **Programación lineal.** En un problema lineal $\max\{\langle c, x \rangle : Ax \leq b\}$ con región factible compacta, basta examinar los vértices. El *método simplex* [5, cap. 13] es precisamente un recorrido inteligente por los puntos extremos del poliedro factible, saltando de vértice a

vértice vecino mientras el objetivo mejore. Volveremos a esto en el capítulo de programación lineal.

2. **Soluciones “bang-bang” y de esquina en contratos.** En muchos problemas de contratos e incentivos, el objetivo del principal es lineal (o afín) en el instrumento de elección (por ejemplo, en las probabilidades de asignación o en transferencias esperadas) y el conjunto factible (determinado por restricciones de participación, incentivos y factibilidad) es compacto y convexo. El Teorema 3.21 implica que el óptimo puede tomarse en un punto extremo del conjunto factible: el contrato óptimo es *extremo*, del tipo **bang-bang** (todo o nada): pagar el bono completo o no pagar nada, asignar el objeto con probabilidad 1 o 0, castigar con la pena máxima o no castigar. Cuando en Microeconomía aparezca un contrato óptimo que “salta” entre esquinas en lugar de interpolar suavemente, la razón matemática de fondo suele ser esta: linealidad del objetivo + convexidad y compacidad del factible $\Rightarrow$ óptimo extremo. Puedes ver [9, cap. 14] y [10, cap. 9] para los modelos de contratos, y [11] para la maquinaria de envolvente que los acompaña.

Estrategia de examen

En los exámenes del curso (y en los trabajos prácticos), los pedidos típicos de este capítulo son cuatro, y conviene tener el reflejo de cada uno.

1. “*Prueba que C es un cono convexo*”: no uses la definición de convexidad; usa la Proposición 3.3 y verifica solo dos cosas: $x + y \in C$ y $\lambda x \in C$ para $\lambda > 0$. Suele ser un cálculo de dos líneas (imita los Ejemplos 3.4 y 3.5).
2. “*Calcula $\text{conv}(S)$ / $\text{cono}(S)$ / $\text{aff}(S)$* ”: escribe la combinación genérica con los pesos correctos (¡revisa la caja de alerta!), parametriza y elimina los pesos para obtener una descripción por desigualdades. Verifica siempre las dos inclusiones: tu candidato contiene a S y es convexo/cónico/afín (da una inclusión), y cada punto del candidato se escribe como combinación (da la otra).
3. “*Halla los puntos extremos de C* ”: primero descarta todo el interior (nunca hay extremos ahí); en la frontera, un punto es extremo si el sistema de restricciones *activas* en él lo determina de forma única. Para probar que un punto NO es extremo, exhibe explícitamente $y \neq z$ en C con $x = \frac{1}{2}y + \frac{1}{2}z$: es la vía más rápida y evaluable.
4. “*Muestra que el óptimo se alcanza en un vértice*”: cita Weierstrass para la existencia y reproduce el argumento del promedio del Teorema 3.21; es una demostración corta que los evaluadores piden con frecuencia porque combina tres ideas del curso.

3.5. Poliedros y politopos [P3]

Los conjuntos convexos más importantes en la práctica se describen con finitas desigualdades lineales: restricciones presupuestarias, de factibilidad, de no negatividad. Merecen nombre propio.

Definición 3.22 (Poliedro y politopo). Un **poliedro** (polyhedron) es la solución de un sistema finito de desigualdades lineales:

$$P = \{x \in \mathbb{R}^n : \langle a_i, x \rangle \leq b_i, i = 1, \dots, m\} = \{x : Ax \leq b\},$$

donde A es una matriz $m \times n$ y la desigualdad $Ax \leq b$ se entiende coordenada a coordenada. Un **politopo** (polytope) es un poliedro *acotado*. Los puntos extremos de un poliedro se llaman **vértices** (vertices).

Todo poliedro es convexo y cerrado: es intersección finita de semiespacios cerrados $\{x : \langle a_i, x \rangle \leq b_i\}$, cada uno convexo y cerrado, y ambas propiedades se preservan bajo intersecciones (capítulo anterior). Ejemplos: $\mathbb{R}_+^n$ es un poliedro (con $A = -I$, $b = 0$), pero no un politopo (no es acotado); el conjunto presupuestario $B(p, m) = \{x \in \mathbb{R}_+^n : \langle p, x \rangle \leq m\}$ con precios $p \gg 0$ y riqueza $m > 0$ es un politopo; el *símplex de probabilidad*

$$\Delta^{n-1} = \left\{ \pi \in \mathbb{R}_+^n : \sum_{i=1}^n \pi_i = 1 \right\}$$

(el conjunto de todas las loterías sobre n resultados) es un politopo cuyos vértices son los vectores canónicos $e_1, \dots, e_n$: las loterías degeneradas que dan un premio con certeza.

Hay, entonces, dos maneras naturales de describir un politopo: “desde afuera”, por desigualdades (representación $\mathcal{H}$, de half-spaces), y “desde adentro”, como cápsula convexa de sus vértices (representación $\mathcal{V}$, de vertices). El teorema fundamental de la teoría de poliedros dice que ambas describen la misma clase de objetos.

Teorema 3.23 (Minkowski–Weyl, caso acotado). *Un conjunto $P \subseteq \mathbb{R}^n$ es un politopo (poliedro acotado) si y solo si es la cápsula convexa de un conjunto finito de puntos:*

$$P = \{x : Ax \leq b\} \text{ acotado} \quad \Longleftrightarrow \quad P = \text{conv}(\{v_1, \dots, v_N\}).$$

En la versión general (no acotada), un conjunto es un poliedro si y solo si se escribe como $\text{conv}(\{v_1, \dots, v_N\}) + \text{cono}(\{d_1, \dots, d_M\})$: una parte “de vértices” más una parte cónica de direcciones de escape.

No demostraremos este teorema (las pruebas modernas usan eliminación de Fourier–Motzkin o dualidad; ver [3, cap. 4] y [6, sec. 2.1]), pero sí conviene digerir su contenido. La dirección “politopo $\Rightarrow$ cápsula de finitos puntos” es casi el teorema de Minkowski (Teorema 3.20) más el hecho, no trivial, de que un poliedro tiene *finitos* puntos extremos: cada vértice queda determinado por un subconjunto de n restricciones activas linealmente independientes, y solo hay finitos subconjuntos posibles. La dirección recíproca dice que el “envoltorio” de finitos puntos siempre puede recortarse con finitas desigualdades lineales.

Observación 3.24. Las dos representaciones tienen usos computacionales distintos. Verificar si un punto dado pertenece a P es inmediato en la forma $\mathcal{H}$ (evaluar m desigualdades) pero costoso en la forma $\mathcal{V}$; optimizar un objetivo lineal es inmediato en la forma $\mathcal{V}$ (evaluar el objetivo en los N vértices, por el Teorema 3.21) pero requiere un algoritmo (símplex, puntos interiores) en

la forma $\mathcal{H}$. Además, pasar de una forma a la otra puede ser exponencialmente costoso: el cubo $[0, 1]^n$ tiene $2n$ desigualdades pero 2^n vértices.

3.6. Cono de recesión [P3]

Motivación: ¿en qué direcciones escapa un convexo al infinito?

Para saber si un problema de optimización tiene solución, la pregunta crucial suele ser si el conjunto factible es acotado y, si no lo es, *en qué direcciones* es no acotado y cómo se comporta el objetivo en esas direcciones. El cono de recesión es el objeto que cataloga esas direcciones de escape.

Definición 3.25 (Cono de recesión). Sea $C \subseteq \mathbb{R}^n$ convexo, cerrado y no vacío. El **cono de recesión** (recession cone) de C es

$$C^\infty = \{d \in \mathbb{R}^n : x + \lambda d \in C \text{ para todo } x \in C \text{ y todo } \lambda \geq 0\},$$

el conjunto de *direcciones* d tales que, partiendo de cualquier punto del conjunto, se puede viajar indefinidamente en la dirección d sin salir de C . Se comprueba sin dificultad que C^∞ es un cono convexo que contiene a 0; para C convexo y *cerrado* basta verificar la condición desde *un solo* punto $x_0 \in C$ (la propiedad se propaga a todos los demás; ver [6, sec. 2.2]).

Ejemplo 3.26 (Conos de recesión concretos). 1. Si C es **acotado** (una bola, un politopo), entonces $C^\infty = \{0\}$: no hay ninguna dirección en la que se pueda viajar para siempre. La recíproca también vale para convexos cerrados: $C^\infty = \{0\}$ implica C acotado; esta equivalencia es la que hace útil al cono de recesión como *test de compacidad*.

2. Si C es un **cono convexo cerrado** (con $0 \in C$), entonces $C^\infty = C$: las direcciones de escape de un cono son el propio cono.
3. $C = \{(x_1, x_2) \in \mathbb{R}^2 : x_2 \geq x_1^2\}$ (el epigrafo de la parábola): $C^\infty = \{(0, t) : t \geq 0\}$, el semieje vertical. Desde cualquier punto sobre la parábola se puede subir verticalmente para siempre, pero cualquier dirección con componente horizontal no nula acaba chocando con la pared parabólica.
4. Para un poliedro $P = \{x : Ax \leq b\}$ no vacío: $P^\infty = \{d : Ad \leq 0\}$. En efecto, $A(x + \lambda d) = Ax + \lambda Ad \leq b$ para todo $\lambda \geq 0$ si y solo si $Ad \leq 0$. Nota que el cono de recesión “olvida” el lado derecho b : solo depende de las pendientes de las restricciones.

Para qué sirve: existencia de óptimos y equilibrio general

El cono de recesión responde dos preguntas de existencia que reaparecerán todo el curso.

(i) **Existencia de minimizadores sin compacidad.** El teorema de Weierstrass exige un factible compacto, pero muchos problemas económicos tienen factibles no acotados (no hay cota superior a priori para la producción o las transferencias). El sustituto es un argumento de recesión: si C es convexo cerrado y el objetivo lineal $\langle c, x \rangle$ satisface $\langle c, d \rangle > 0$ para toda dirección de recesión $d \in C^\infty \setminus \{0\}$, entonces $\min_{x \in C} \langle c, x \rangle$ se alcanza: el objetivo crece a lo largo de toda




Figura 3.3: El conjunto $C = \{x_2 \geq x_1^2\}$ es no acotado, pero solo “escapa al infinito” verticalmente: su cono de recesión es el semieje vertical.

dirección de escape, así que la búsqueda del mínimo puede confinarse a una porción acotada (y por tanto compacta) de C , donde Weierstrass sí aplica. Si en cambio existe $d \in C^\infty$ con $\langle c, d \rangle < 0$, el ínfimo es $-\infty$: viajar en dirección d mejora el objetivo indefinidamente. El cono de recesión convierte así la pregunta “¿existe el óptimo?” en el cálculo, a menudo mecánico, de $\{d : Ad \leq 0\}$ y de los signos $\langle c, d \rangle$; el tratamiento sistemático está en [6, sec. 2.2 y cap. 3] y [3, cap. 4].

(ii) **Acotación del conjunto de asignaciones factibles en equilibrio general.** En una economía de producción, la existencia de equilibrio walrasiano se demuestra aplicando un teorema de punto fijo sobre el conjunto de asignaciones factibles, y para ello dicho conjunto debe ser *compacto*. La factibilidad agregada es $\sum_j y_j + \omega \geq \sum_i x_i \geq 0$ con $y_j \in Y_j$: nada impide a priori que dos empresas tomen planes gigantescos que se cancelen entre sí ($y_1 = tv$, $y_2 = -tv$ con $t \rightarrow \infty$), dejando la suma acotada pero los planes individuales no. El supuesto que lo impide se formula con conos de recesión: se exige que las direcciones de recesión de la tecnología agregada $Y = \sum_j Y_j$ que son “mutuamente cancelables” sean triviales, esencialmente $Y^\infty \cap (-Y^\infty) \subseteq \{0\}$ junto con $Y^\infty \cap \mathbb{R}_+^n = \{0\}$ (no se produce algo de la nada a escala arbitraria: versión asintótica del “no free lunch”). Con ello, el conjunto de asignaciones factibles resulta compacto y el argumento de punto fijo procede. Esta es exactamente la maquinaria del apéndice del capítulo 17 de [9] (existencia de equilibrio con producción); el cono de recesión es la herramienta que ahí se usa, a veces bajo el nombre de *cono asintótico*.

3.7. Resumen y ejercicios resueltos [P1]

Resumen del capítulo

- **Cono:** C tal que $x \in C, \lambda > 0 \Rightarrow \lambda x \in C$. **Cono convexo** $\iff$ cerrado bajo sumas y escalares positivos (Proposición 3.3). Ejemplos: $\mathbb{R}_+^n$, cono de segundo orden $\|x\| \leq t$. Economía: tecnología con retornos constantes a escala = conjunto de producción cónico; libre disposición = $Y - \mathbb{R}_+^n \subseteq Y$.
- **Cápsulas:** $\text{conv}(S)$ (pesos ≥ 0 que suman 1) = menor convexo que contiene a S = todas las combinaciones convexas (Teorema 3.9); $\text{aff}(S)$ (pesos que suman 1, cualquier signo), define la *dimensión*; $\text{cono}(S)$ (pesos ≥ 0 , suma libre).

- **Carathéodory:** en $\mathbb{R}^n$, todo punto de $\text{conv}(S)$ usa a lo más $n+1$ puntos de S ; todo punto de $\text{cono}(S)$, a lo más n (Teoremas 3.15 y 3.16). Aplicación: toda lotería con valor esperado en $\mathbb{R}^n$ se replica con a lo más $n+1$ premios (mecanismos aleatorios simples sin pérdida de generalidad).
- **Puntos extremos:** los que no son promedio estricto de dos puntos distintos del conjunto. Minkowski (Teorema 3.20): compacto convexo = conv de sus extremos. Consecuencia (Teorema 3.21): un objetivo lineal sobre un compacto convexo alcanza su óptimo en un punto extremo $\Rightarrow$ programación lineal por vértices, contratos bang-bang.
- **Poliedros/politopos:** $\{x : Ax \leq b\}$; politopo = poliedro acotado. Minkowski–Weyl (Teorema 3.23): representación por desigualdades $\iff$ representación por vértices (+ cono en el caso no acotado).
- **Cono de recesión:** C^∞ = direcciones de viaje infinito dentro de C ; $C^\infty = \{0\} \iff C$ (convexo cerrado) acotado. Para poliedros, $P^\infty = \{d : Ad \leq 0\}$. Usos: existencia de óptimos en factibles no acotados; compacidad del conjunto de asignaciones en existencia de equilibrio general [9, cap. 17].

Referencias principales del capítulo: [3, caps. 2–4], [6, cap. 2], [2, cap. 2], [1].

Ejercicio 3.27. Sea $a \in \mathbb{R}^n$, $a \neq 0$. Demuestra que el semiespacio $H = \{x \in \mathbb{R}^n : \langle a, x \rangle \leq 0\}$ es un cono convexo, pero que el semiespacio trasladado $H_b = \{x : \langle a, x \rangle \leq b\}$ con $b > 0$ es convexo y *no* es un cono.

Solución. H es cono convexo. Usamos la Proposición 3.3 y la linealidad del producto interno. Sumas: si $\langle a, x \rangle \leq 0$ y $\langle a, y \rangle \leq 0$, entonces $\langle a, x+y \rangle = \langle a, x \rangle + \langle a, y \rangle \leq 0$, luego $x+y \in H$. Escalares positivos: si $\lambda > 0$, $\langle a, \lambda x \rangle = \lambda \langle a, x \rangle \leq 0$ (producto de un positivo por un no positivo), luego $\lambda x \in H$. Por la proposición, H es cono convexo.

H_b es convexo: si $\langle a, x \rangle \leq b$, $\langle a, y \rangle \leq b$ y $\theta \in [0, 1]$, entonces $\langle a, \theta x + (1-\theta)y \rangle = \theta \langle a, x \rangle + (1-\theta) \langle a, y \rangle \leq \theta b + (1-\theta)b = b$.

H_b no es cono si $b > 0$. Basta un contraejemplo de escalamiento. Como $a \neq 0$, el punto $x_0 = \frac{b}{\|a\|^2} a$ cumple $\langle a, x_0 \rangle = \frac{b}{\|a\|^2} \langle a, a \rangle = b \leq b$, así que $x_0 \in H_b$. Pero para $\lambda = 2$: $\langle a, 2x_0 \rangle = 2b > b$ (porque $b > 0$), de modo que $2x_0 \notin H_b$. La cerradura bajo escalares positivos falla, y H_b no es cono. (Moral: los conos son objetos “anclados al origen”; trasladar destruye la estructura cónica pero no la convexidad.) $\square$

Ejercicio 3.28. Sea $S = \{(1, 0), (0, 1), (1, 1)\} \subset \mathbb{R}^2$. Calcula y describe mediante igualdades/-desigualdades: (a) $\text{conv}(S)$; (b) $\text{aff}(S)$; (c) $\text{cono}(S)$. Indica la dimensión de $\text{conv}(S)$.

Solución. (a) Una combinación convexa genérica es

$$z = \lambda_1(1, 0) + \lambda_2(0, 1) + \lambda_3(1, 1) = (\lambda_1 + \lambda_3, \lambda_2 + \lambda_3), \quad \lambda_i \geq 0, \lambda_1 + \lambda_2 + \lambda_3 = 1.$$

Escribiendo $z = (u, v)$: $u + v = \lambda_1 + \lambda_2 + 2\lambda_3 = 1 + \lambda_3 \in [1, 2]$ (pues $\lambda_3 \in [0, 1]$), $u = \lambda_1 + \lambda_3 \in [0, 1]$ y $v = \lambda_2 + \lambda_3 \in [0, 1]$. Recíprocamente, si $(u, v) \in [0, 1]^2$ con $1 \leq u + v \leq 2$, tomando

$\lambda_3 = u + v - 1 \geq 0$, $\lambda_1 = u - \lambda_3 = 1 - v \geq 0$ y $\lambda_2 = v - \lambda_3 = 1 - u \geq 0$ se verifica que los pesos son no negativos y suman $(1 - v) + (1 - u) + (u + v - 1) = 1$. Por lo tanto

$$\text{conv}(S) = \{(u, v) : 0 \leq u \leq 1, 0 \leq v \leq 1, u + v \geq 1\} :$$

el triángulo con vértices en los tres puntos de S .

(b) Los tres puntos no están alineados: $(0, 1) - (1, 0) = (-1, 1)$ y $(1, 1) - (1, 0) = (0, 1)$ son linealmente independientes. Luego $\text{aff}(S) = \mathbb{R}^2$ (con dos direcciones independientes y pesos libres que suman 1 se alcanza todo el plano), y $\dim \text{conv}(S) = 2$.

(c) $\text{cono}(S) = \{\lambda_1(1, 0) + \lambda_2(0, 1) + \lambda_3(1, 1) : \lambda_i \geq 0\} = \{(\lambda_1 + \lambda_3, \lambda_2 + \lambda_3) : \lambda_i \geq 0\}$. Toda coordenada es no negativa, así que $\text{cono}(S) \subseteq \mathbb{R}_+^2$; y recíprocamente todo $(u, v) \in \mathbb{R}_+^2$ se obtiene con $\lambda_3 = 0$, $\lambda_1 = u$, $\lambda_2 = v$. Por lo tanto $\text{cono}(S) = \mathbb{R}_+^2$: el punto $(1, 1)$ es redundante para la cápsula cónica (es combinación cónica de los otros dos), aunque no lo era para la convexa (es un vértice del triángulo). Este contraste ilustra que ser “generador minimal” depende de la estructura considerada. $\square$

Ejercicio 3.29. El punto $z = (\frac{1}{2}, \frac{1}{2}) \in \mathbb{R}^2$ está representado como combinación convexa de cuatro puntos:

$$z = \frac{1}{4}(1, 0) + \frac{1}{4}(0, 1) + \frac{1}{4}(1, 1) + \frac{1}{4}(0, 0).$$

Siguiendo el algoritmo de la demostración del teorema de Carathéodory (Teorema 3.15), reduce la representación a una con a lo más $3 = n + 1$ puntos.

Solución. Etiquetamos $x_1 = (1, 0)$, $x_2 = (0, 1)$, $x_3 = (1, 1)$, $x_4 = (0, 0)$, con pesos $\lambda_i = \frac{1}{4}$. Como $k = 4 \geq n + 2 = 4$, el teorema garantiza una dependencia afín. La encontramos: buscamos μ_i , no todos nulos, con $\sum_i \mu_i x_i = 0$ y $\sum_i \mu_i = 0$. Observando que $(1, 0) + (0, 1) = (1, 1) + (0, 0)$, tomamos

$$\mu_1 = 1, \quad \mu_2 = 1, \quad \mu_3 = -1, \quad \mu_4 = -1,$$

que cumplen $\sum_i \mu_i x_i = (1, 0) + (0, 1) - (1, 1) - (0, 0) = (0, 0)$ y $\sum_i \mu_i = 0$. Los índices con $\mu_i > 0$ son $i = 1, 2$, con cocientes $\lambda_1/\mu_1 = \lambda_2/\mu_2 = \frac{1}{4}$; el paso del algoritmo es

$$t^* = \min \left\{ \frac{1/4}{1}, \frac{1/4}{1} \right\} = \frac{1}{4}.$$

Los nuevos pesos son $\lambda_i - t^* \mu_i$:

$$\lambda'_1 = \frac{1}{4} - \frac{1}{4} = 0, \quad \lambda'_2 = \frac{1}{4} - \frac{1}{4} = 0, \quad \lambda'_3 = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}, \quad \lambda'_4 = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}.$$

(Suman 1, como debe ser.) Se anulan dos pesos de golpe (el mínimo se alcanzaba en dos índices), y queda

$$z = \frac{1}{2}(1, 1) + \frac{1}{2}(0, 0),$$

que efectivamente es $(\frac{1}{2}, \frac{1}{2})$: una representación con solo 2 puntos, incluso mejor que la cota $n + 1 = 3$. Interpretación de loterías: la lotería uniforme sobre 4 premios con media $(\frac{1}{2}, \frac{1}{2})$ se replica con una moneda justa entre los premios $(1, 1)$ y $(0, 0)$. $\square$

Ejercicio 3.30. Considera el conjunto presupuestario $B = \{(x_1, x_2) \in \mathbb{R}_+^2 : 2x_1 + x_2 \leq 4\}$ (precios $p = (2, 1)$, riqueza 4). (a) Encuentra todos los puntos extremos de B . (b) Un consumidor tiene utilidad lineal $u(x_1, x_2) = 3x_1 + 2x_2$. Usa el Teorema 3.21 para hallar su demanda óptima. (c) Interpreta por qué la solución es “de esquina”.

Solución. (a) B es un politopo definido por tres desigualdades: $x_1 \geq 0$, $x_2 \geq 0$, $2x_1 + x_2 \leq 4$. Sus puntos extremos son los puntos donde dos restricciones linealmente independientes están activas (se cumplen con igualdad) y que además pertenecen a B :

$$x_1 = 0, x_2 = 0 \Rightarrow (0, 0); \quad x_1 = 0, 2x_1 + x_2 = 4 \Rightarrow (0, 4); \quad x_2 = 0, 2x_1 + x_2 = 4 \Rightarrow (2, 0).$$

Los tres pertenecen a B , así que $\text{ext}(B) = \{(0, 0), (0, 4), (2, 0)\}$: B es el triángulo con esos vértices. Para confirmar que, por ejemplo, $(1, 1) \in B$ no es extremo: $(1, 1) = \frac{1}{2}(0, 0) + \frac{1}{2}(2, 2)$ con ambos puntos en B y distintos.

(b) B es compacto (cerrado por ser poliedro; acotado porque $0 \leq x_1 \leq 2$ y $0 \leq x_2 \leq 4$) y convexo, y u es lineal. Por el Teorema 3.21, basta evaluar u en los tres extremos:

$$u(0, 0) = 0, \quad u(0, 4) = 3 \cdot 0 + 2 \cdot 4 = 8, \quad u(2, 0) = 3 \cdot 2 + 2 \cdot 0 = 6.$$

La demanda óptima es $x^* = (0, 4)$, con utilidad 8: el consumidor gasta toda su riqueza en el bien 2.

(c) Con utilidad lineal los bienes son sustitutos perfectos y el consumidor compara “utilidad por sol gastado”: el bien 1 rinde $3/2 = 1.5$ por unidad de gasto y el bien 2 rinde $2/1 = 2$. Como los rendimientos son constantes (no hay utilidad marginal decreciente que frene la especialización), conviene gastar *todo* en el bien de mayor rendimiento: solución de esquina. Este es el mecanismo bang-bang en miniatura: objetivo lineal + factible convexo compacto $\Rightarrow$ óptimo en un vértice. Si los dos rendimientos empataran ($3/2 = 2/1$ no se da aquí, pero p. ej. con $u = 4x_1 + 2x_2$), *toda* la arista entre dos vértices sería óptima: el óptimo extremo existe igualmente, pero no es único. $\square$

Ejercicio 3.31. Calcula el cono de recesión de los siguientes convexos cerrados de $\mathbb{R}^2$ y concluye en cada caso si el conjunto es acotado: (a) $C_1 = \{(x_1, x_2) : x_1 \geq 0, x_2 \geq 0, x_1 + x_2 \geq 1\}$; (b) $C_2 = \{(x_1, x_2) : x_1^2 + x_2^2 \leq 9\}$; (c) $C_3 = \{(x_1, x_2) : x_2 \geq e^{x_1}\}$.

Solución. (a) C_1 es un poliedro $\{x : Ax \leq b\}$ con filas $-x_1 \leq 0$, $-x_2 \leq 0$, $-x_1 - x_2 \leq -1$. Por el Ejemplo 3.26(4), $C_1^\infty = \{d : Ad \leq 0\} = \{(d_1, d_2) : -d_1 \leq 0, -d_2 \leq 0, -d_1 - d_2 \leq 0\} = \mathbb{R}_+^2$ (la tercera desigualdad es redundante dadas las dos primeras). Como $C_1^\infty \neq \{0\}$, C_1 es no acotado; sus direcciones de escape son todas las del primer cuadrante. Nota cómo el cono de recesión ignoró el término independiente -1 : trasladar las paredes no cambia hacia dónde se escapa.

(b) C_2 es la bola cerrada de radio 3: es acotada, luego $C_2^\infty = \{0\}$. Directamente: si $d \neq 0$, entonces $\|x + \lambda d\| \rightarrow \infty$ cuando $\lambda \rightarrow \infty$, y el punto sale de la bola; ninguna dirección no nula es de recesión.

(c) Buscamos $d = (d_1, d_2)$ tal que $(x_1 + \lambda d_1, x_2 + \lambda d_2) \in C_3$ para todo $\lambda \geq 0$, partiendo

p. ej. de $(0, 1) \in C_3$ (recuerda que para convexos cerrados basta un punto base). La condición es

$$1 + \lambda d_2 \geq e^{\lambda d_1} \quad \text{para todo } \lambda \geq 0.$$

Si $d_1 > 0$, el lado derecho crece exponencialmente y el izquierdo linealmente: imposible para λ grande. Si $d_1 \leq 0$, el lado derecho está acotado por 1 (pues $e^{\lambda d_1} \leq e^0 = 1$): con $d_2 \geq 0$ el lado izquierdo es $\geq 1 \geq e^{\lambda d_1}$ y la condición se cumple siempre; con $d_2 < 0$ el lado izquierdo se hace negativo para λ grande mientras el derecho es positivo: imposible. Conclusión:

$$C_3^\infty = \{(d_1, d_2) : d_1 \leq 0, d_2 \geq 0\},$$

el segundo cuadrante (cerrado). C_3 es no acotado: escapa hacia arriba y hacia la izquierda (donde la exponencial se aplanan hacia 0), pero nunca hacia la derecha, donde la pared exponencial crece más rápido que cualquier rayo. $\square$

Ejercicio 3.32. Demuestra, usando el teorema de Carathéodory, que si $S \subseteq \mathbb{R}^n$ es compacto entonces $\text{conv}(S)$ es compacta. (Sugerencia: escribe $\text{conv}(S)$ como imagen continua de un compacto.)

Solución. Por el Teorema 3.15, todo punto de $\text{conv}(S)$ es combinación convexa de a lo más $n+1$ puntos de S (si usa menos, se completan con pesos cero). Definamos el conjunto de “datos” de tales combinaciones:

$$D = \Delta^n \times S^{n+1} = \left\{ (\lambda, x_1, \dots, x_{n+1}) : \lambda \in \mathbb{R}_+^{n+1}, \sum_{i=1}^{n+1} \lambda_i = 1, x_i \in S \right\},$$

y la aplicación

$$\Phi : D \rightarrow \mathbb{R}^n, \quad \Phi(\lambda, x_1, \dots, x_{n+1}) = \sum_{i=1}^{n+1} \lambda_i x_i.$$

Tres observaciones cierran la prueba.

1. D es compacto. El simplex $\Delta^n = \{\lambda \in \mathbb{R}_+^{n+1} : \sum_i \lambda_i = 1\}$ (el de loterías sobre $n+1$ premios, con la misma convención de índices del capítulo anterior) es cerrado (intersección de semiespacios cerrados y un hiperplano) y acotado ($0 \leq \lambda_i \leq 1$), luego compacto; S es compacto por hipótesis; y un producto cartesiano finito de compactos es compacto (visto en los preliminares).
2. Φ es continua, pues es un polinomio (sumas y productos) en las coordenadas de sus argumentos.
3. $\Phi(D) = \text{conv}(S)$. La inclusión $\subseteq$ es clara: Φ produce combinaciones convexas de puntos de S , que están en $\text{conv}(S)$ por el Teorema 3.9. La inclusión $\supseteq$ es exactamente Carathéodory: todo $z \in \text{conv}(S)$ admite una representación con a lo más $n+1$ puntos, es decir, $z = \Phi(\lambda, x_1, \dots, x_{n+1})$ para algún dato en D .

La imagen continua de un compacto es compacta (preliminares), así que $\text{conv}(S) = \Phi(D)$ es compacta. Nota el papel esencial de Carathéodory: sin la cota uniforme $n+1$ en el número de puntos, no habría un dominio compacto de dimensión fija desde el cual parametrizar todas las

combinaciones. Compara con la caja de alerta: para S solo *cerrado* (no acotado) el resultado es falso. $\square$

Capítulo 4

Hiperplanos y teoremas de separación [P1]

Semana 3 del cronograma. Bibliografía: Ruszczyński [6]; Boyd y Vandenberghe [2]; Nocedal y Wright [5].

¿Para qué sirve esto en Microeconomía?

Si tuvieras que elegir *un solo* capítulo de este cuaderno para dominar a la perfección antes de Microeconomía, sería este. El **Segundo Teorema del Bienestar** (equilibrio general, MWG sección 16.D, [9]) afirma que todo óptimo de Pareto puede descentralizarse como un equilibrio de mercado con transferencias; su demostración consiste, literalmente, en separar dos conjuntos convexos con un hiperplano, y el **vector normal de ese hiperplano separador ES el vector de precios** que sostiene el óptimo. Es decir: los precios de equilibrio no se “postulan”, se *construyen* con el teorema de separación que demostraremos aquí. La misma maquinaria produce los *precios sombra* (multiplicadores) de cualquier problema de optimización con restricciones: el **lema de Farkas**, que probaremos vía separación, es el motor oculto detrás de las condiciones de Karush–Kuhn–Tucker (KKT) que gobiernan los problemas de contratos con restricciones de compatibilidad de incentivos (IC) y de participación (IR) de los modelos de principal–agente y diseño de mecanismos (MWG caps. 14 y 23). La separación también fundamenta la *dualidad* en optimización (capítulos posteriores), la existencia de probabilidades subjetivas en teoría de la decisión, y hasta la clasificación con *máquinas de vectores de soporte* (SVM) en econometría computacional: separar datos con un hiperplano es exactamente el problema geométrico de este capítulo. En resumen: aquí se fabrican los precios.

En el capítulo 2 aprendimos qué es un conjunto convexo y estudiamos su estructura topológica (interior, clausura, interior relativo). En este capítulo cosechamos el primer gran dividendo de esa inversión: los *teoremas de separación* (separation theorems), que afirman que dos conjuntos convexos que no se tocan pueden “ponerse en lados opuestos” de un hiperplano. Este resultado, geoméricamente obvio en un dibujo, es sorprendentemente profundo: es la versión en dimensión finita del teorema de Hahn–Banach, y es el puente entre la geometría convexa y el álgebra lineal de los precios. El plan del capítulo es constructivo y va de menos a más: primero repasamos qué

es un hiperplano y qué significa su vector normal (Sección 4.1); luego demostramos el *teorema de proyección* sobre un convexo cerrado (Sección 4.2), que es la herramienta técnica de la que todo lo demás se deduce; con la proyección en la mano, separamos un punto de un convexo cerrado (Sección 4.3), construimos hiperplanos soporte en puntos frontera (Sección 4.4), y separamos dos convexos entre sí (Sección 4.5); como aplicación algebraica probamos el lema de Farkas (Sección 4.6), y como aplicación económica estrella desarrollamos con todo detalle el Segundo Teorema del Bienestar (Sección 4.7). Las referencias principales son [6] (secciones 2.2–2.3), [3] (cap. 4), [2] (sección 2.5) y [1]. Para la aplicación económica seguimos a [9] (sección 16.D) y [10] (cap. 5).

4.1. Hiperplanos y semiespacios [P1]

4.1.1. Motivación: los conjuntos de nivel de una función lineal

Las funciones más simples de $\mathbb{R}^n$ a $\mathbb{R}$ son las *lineales*. Fija un vector $a \in \mathbb{R}^n$ con $a \neq 0$ y define

$$f(x) = \langle a, x \rangle = a_1x_1 + a_2x_2 + \cdots + a_nx_n.$$

(Recuerda del capítulo de preliminares que $\langle a, x \rangle$ denota el producto interno euclidiano.) Una pregunta natural: ¿cómo se ve el conjunto de puntos donde f vale exactamente un número β ? En $\mathbb{R}^2$ con $a = (2, 3)$ y $\beta = 12$, el conjunto $\{(x_1, x_2) : 2x_1 + 3x_2 = 12\}$ es una recta. En $\mathbb{R}^3$, el conjunto $\{x : \langle a, x \rangle = \beta\}$ es un plano. En $\mathbb{R}^n$ es un objeto plano de dimensión $n - 1$ que llamaremos *hiperplano*. Los hiperplanos son, entonces, los conjuntos de nivel (level sets) de las funciones lineales no nulas, y esa doble naturaleza, objeto geométrico y ecuación lineal, es la clave de todo el capítulo.

Definición 4.1 (Hiperplano y semiespacios). Sean $a \in \mathbb{R}^n$, $a \neq 0$, y $\beta \in \mathbb{R}$. El *hiperplano* (hyperplane) con *vector normal* (normal vector) a y nivel β es el conjunto

$$H(a, \beta) = \{x \in \mathbb{R}^n : \langle a, x \rangle = \beta\}.$$

El hiperplano determina dos *semiespacios cerrados* (closed half-spaces)

$$H^-(a, \beta) = \{x : \langle a, x \rangle \leq \beta\}, \quad H^+(a, \beta) = \{x : \langle a, x \rangle \geq \beta\},$$

y dos *semiespacios abiertos* (open half-spaces), definidos con las desigualdades estrictas $<$ y $>$.

Observación 4.2. El par (a, β) no es único: $H(a, \beta) = H(\lambda a, \lambda \beta)$ para todo $\lambda \neq 0$. Por eso muchas veces *normalizamos* tomando $\|a\| = 1$, lo que fija a salvo el signo. Multiplicar por $\lambda < 0$ intercambia los papeles de H^- y H^+ : el “lado positivo” depende de la orientación elegida para la normal. En economía esta libertad de escala es exactamente la *homogeneidad de grado cero* de las demandas en precios: solo importan los precios relativos, y normalizar $\|p\| = 1$ (o $p_1 = 1$, el bien numerario) es elegir una escala para el hiperplano presupuestario.

4.1.2. Geometría del vector normal

¿Por qué llamamos a a el vector “normal”? Porque a es perpendicular al hiperplano, en el sentido preciso siguiente.

Proposición 4.3 (El vector normal es ortogonal al hiperplano). *Sea $H = H(a, \beta)$ y sea $x_0 \in H$ cualquier punto del hiperplano. Entonces:*

- (a) $H = x_0 + \{v \in \mathbb{R}^n : \langle a, v \rangle = 0\}$; es decir, H es el trasladado por x_0 del subespacio de vectores ortogonales a a . En particular, H es un conjunto afín de dimensión $n - 1$.
- (b) Para cualesquiera $x, y \in H$ se cumple $\langle a, x - y \rangle = 0$: el vector a es ortogonal a todo vector “contenido en” H .
- (c) La función $x \mapsto \langle a, x \rangle$ crece en la dirección de a : si partimos de $x_0 \in H$ y avanzamos a $x_0 + ta$ con $t > 0$, entonces $\langle a, x_0 + ta \rangle = \beta + t\|a\|^2 > \beta$. El vector normal apunta hacia el semiespacio superior H^+ .

Demostración. (a) Si $x \in H$, entonces $\langle a, x - x_0 \rangle = \langle a, x \rangle - \langle a, x_0 \rangle = \beta - \beta = 0$, así que $v = x - x_0$ satisface $\langle a, v \rangle = 0$ y $x = x_0 + v$. Recíprocamente, si $\langle a, v \rangle = 0$ entonces $\langle a, x_0 + v \rangle = \beta + 0 = \beta$, luego $x_0 + v \in H$. El conjunto $\{v : \langle a, v \rangle = 0\}$ es el núcleo de la aplicación lineal $v \mapsto \langle a, v \rangle$, que es sobreyectiva sobre $\mathbb{R}$ (porque $a \neq 0$); por el teorema de la dimensión su núcleo tiene dimensión $n - 1$.

(b) Es inmediato de (a): $x - y = (x - x_0) - (y - x_0)$ es diferencia de dos vectores ortogonales a a , y por linealidad del producto interno $\langle a, x - y \rangle = 0$.

(c) Cálculo directo: $\langle a, x_0 + ta \rangle = \langle a, x_0 \rangle + t\langle a, a \rangle = \beta + t\|a\|^2$, y $\|a\|^2 > 0$ porque $a \neq 0$. $\square$

Intuición

Piensa en el hiperplano como una “loma de nivel” en un mapa topográfico donde la altura del punto x es $\langle a, x \rangle$. El vector normal a es la dirección de máxima pendiente: apunta perpendicularmente a las curvas de nivel, hacia donde la “altura” $\langle a, x \rangle$ crece más rápido (de hecho, a es el gradiente de la función lineal $x \mapsto \langle a, x \rangle$). Cuando en los teoremas de separación digamos que un hiperplano deja al conjunto A “abajo” y al conjunto B “arriba”, estaremos diciendo que la función lineal $\langle a, \cdot \rangle$ vale menos en todo A que en todo B . Separar es comparar con una regla lineal.

4.1.3. Interpretación económica: el precio es la normal

La recta presupuestaria es el hiperplano más famoso de la economía. Si $p = (p_1, \dots, p_L) \in \mathbb{R}^L$ es un vector de precios y $m > 0$ es la riqueza del consumidor, el conjunto de cestas que agotan el presupuesto es el hiperplano

$$H(p, m) = \{x \in \mathbb{R}^L : \langle p, x \rangle = m\},$$

y el conjunto presupuestario $\{x \geq 0 : \langle p, x \rangle \leq m\}$ es la intersección del semiespacio inferior $H^-(p, m)$ con el ortante no negativo. La Proposición 4.3 dice entonces que **el vector de precios es el vector normal a la recta presupuestaria**: p apunta perpendicular a ella, hacia las

cestas más caras. Análogamente, para una empresa con vector de producción neta y (insumos con signo negativo, productos con signo positivo), las rectas de *isobeneficio* $\{y : \langle p, y \rangle = \pi\}$ son hiperplanos con normal p , y maximizar beneficios es empujar el hiperplano en la dirección de la normal tanto como la tecnología lo permita. Esta imagen (precios como normales de hiperplanos) es la que hará transparente el Segundo Teorema del Bienestar en la Sección 4.7.

Ejemplo 4.4 (Recta presupuestaria y su normal). Sea $L = 2$, $p = (2, 3)$ y $m = 12$. La recta presupuestaria es $\{(x_1, x_2) : 2x_1 + 3x_2 = 12\}$, que corta los ejes en $(6, 0)$ y $(0, 4)$. Verifiquemos con todos los pasos que $p = (2, 3)$ es ortogonal a ella. Tomemos los dos puntos de corte: el vector que va de $(6, 0)$ a $(0, 4)$ es $v = (0, 4) - (6, 0) = (-6, 4)$. Entonces

$$\langle p, v \rangle = 2 \cdot (-6) + 3 \cdot 4 = -12 + 12 = 0,$$

como predice la Proposición 4.3(b). Además, la cesta $(3, 3)$ cuesta $2 \cdot 3 + 3 \cdot 3 = 15 > 12$: está en el semiespacio superior, el lado hacia el que apunta p (las cestas inasequibles). La cesta $(3, 1)$ cuesta $9 < 12$: está en el semiespacio inferior (las asequibles con holgura). Nota la interpretación de la pendiente: la recta tiene pendiente $-p_1/p_2 = -2/3$, el precio relativo, mientras que la normal $(2, 3)$ tiene “pendiente” $3/2$, perpendicular a la anterior (el producto de pendientes es -1).




Figura 4.1: La recta presupuestaria es un hiperplano en $\mathbb{R}^2$; el vector de precios p es su normal y apunta hacia las cestas inasequibles.

Observación 4.5 (Semiespacios y convexidad). Todo semiespacio (abierto o cerrado) es convexo, y todo hiperplano es convexo: son conjuntos definidos por una igualdad o desigualdad *lineal*, y las desigualdades lineales se preservan al tomar combinaciones convexas. En efecto, si $\langle a, x \rangle \leq \beta$ y $\langle a, y \rangle \leq \beta$, entonces para $\lambda \in [0, 1]$,

$$\langle a, \lambda x + (1 - \lambda)y \rangle = \lambda \langle a, x \rangle + (1 - \lambda) \langle a, y \rangle \leq \lambda\beta + (1 - \lambda)\beta = \beta.$$

Como la intersección de convexos es convexa (capítulo 2), cualquier intersección de semiespacios es convexa; los *poliedros* (polyhedra), intersecciones finitas de semiespacios cerrados, son el ejemplo central en programación lineal [2]. Uno de los resultados estrella de este capítulo (Corolario 4.12) es el recíproco “infinito”: todo convexo cerrado es intersección de los semiespacios que lo contienen. La convexidad cerrada es, exactamente, “ser describable por desigualdades

lineales”.

4.2. Proyección sobre un convexo cerrado [P1]

4.2.1. Motivación: el punto más cercano

Toda la teoría de separación descansa en una sola construcción: dado un conjunto C y un punto x fuera de él, encontrar *el punto de C más cercano a x* . La intuición es física: si conectas x con su punto más cercano $z \in C$ mediante una cuerda tensa, la dirección de la cuerda $x - z$ es perpendicular a la “superficie” de C en z , y el hiperplano perpendicular a la cuerda que pasa por el punto medio deja a x de un lado y a todo C del otro. Para que este plan funcione necesitamos tres cosas: que el punto más cercano *exista*, que sea *único* (para poder hablar de “la” proyección), y una caracterización algebraica manejable de “ser el más cercano”. Las tres cosas requieren hipótesis: la existencia pide que C sea *cerrado* (si C es la bola abierta y x está fuera, el ínfimo de la distancia no se alcanza), y la unicidad pide que C sea *convexo* (si C es una circunferencia y x su centro, todos los puntos de C están igual de cerca). Este es el contenido del siguiente teorema, el caballo de batalla del capítulo ([6], Teorema 2.10; [3], cap. 4; [1]).

Teorema 4.6 (Teorema de proyección). *Sea $C \subseteq \mathbb{R}^n$ un conjunto no vacío, cerrado y convexo, y sea $x \in \mathbb{R}^n$ un punto cualquiera. Entonces:*

- (I) **Existencia:** *existe al menos un punto $z \in C$ que minimiza la distancia a x , es decir, $\|x - z\| \leq \|x - y\|$ para todo $y \in C$.*
- (II) **Unicidad:** *ese minimizador es único. Lo denotamos $z = \text{proy}_C(x)$ y lo llamamos la proyección (projection) de x sobre C .*
- (III) **Caracterización variacional:** *un punto $z \in C$ es la proyección de x si y solo si*

$$\langle x - z, y - z \rangle \leq 0 \quad \text{para todo } y \in C. \quad (4.1)$$

Antes de la demostración, entendamos la condición (4.1), llamada *desigualdad variacional* (variational inequality). Recuerda del capítulo de preliminares que $\langle u, v \rangle = \|u\| \|v\| \cos \theta$, donde θ es el ángulo entre u y v . La condición (4.1) dice que el ángulo entre el vector “residual” $x - z$ (que va de la proyección hacia el punto original) y cualquier vector $y - z$ (que va de la proyección hacia cualquier otro punto del conjunto) es *obtuso o recto*: mayor o igual que 90 grados. Geométricamente: desde z , el conjunto C entero queda “del otro lado” del hiperplano perpendicular a $x - z$ que pasa por z . Ya se ve venir la separación.

Demostración. Parte (i): existencia, vía Weierstrass. La función $f(y) = \|x - y\|$ es continua en $\mathbb{R}^n$ (es composición de la norma, que es continua por la desigualdad triangular inversa $|\|u\| - \|v\|| \leq \|u - v\|$, con la traslación $y \mapsto x - y$). Nos gustaría aplicar el teorema de Weierstrass del capítulo de preliminares, pero C puede no ser acotado (piensa en $C = \mathbb{R}_+^n$). El truco estándar es *compactificar*: fija cualquier punto $y_0 \in C$ (existe porque $C \neq \emptyset$) y sea $r = \|x - y_0\|$. Considera el conjunto recortado

$$C_0 = C \cap \bar{B}(x, r) = \{y \in C : \|x - y\| \leq r\}.$$

Este conjunto es cerrado (intersección de dos cerrados: C por hipótesis y la bola cerrada $\bar{B}(x, r)$), es acotado (está dentro de la bola de radio r) y no vacío (contiene a y_0). Por el teorema de Heine–Borel, C_0 es compacto, y por Weierstrass la función continua f alcanza un mínimo en algún $z \in C_0$. Falta ver que z minimiza sobre *todo* C , no solo sobre C_0 : si $y \in C \setminus C_0$, entonces por definición de C_0 tenemos $\|x - y\| > r = \|x - y_0\| \geq \|x - z\|$ (la última desigualdad porque $y_0 \in C_0$ y z minimiza en C_0). Así que ningún punto fuera del recorte puede mejorar a z , y z minimiza la distancia sobre todo C . Observa que en esta parte *no usamos la convexidad de C* : todo cerrado no vacío admite punto más cercano.

Parte (iii) primero, dirección “ $\Rightarrow$ ”: todo minimizador satisface (4.1). (Probamos (iii) antes que (ii) porque la unicidad saldrá gratis de la caracterización; este orden es el de [6].) Sea z un minimizador y sea $y \in C$ arbitrario. Aquí entra la convexidad: para cada $\lambda \in (0, 1]$, el punto

$$y_\lambda = z + \lambda(y - z) = (1 - \lambda)z + \lambda y$$

pertenece a C (es combinación convexa de $z, y \in C$). Como z es minimizador, $\|x - y_\lambda\|^2 \geq \|x - z\|^2$. Expandimos el lado izquierdo usando $\|u - v\|^2 = \|u\|^2 - 2\langle u, v \rangle + \|v\|^2$ con $u = x - z$ y $v = \lambda(y - z)$:

$$\|x - y_\lambda\|^2 = \|(x - z) - \lambda(y - z)\|^2 = \|x - z\|^2 - 2\lambda\langle x - z, y - z \rangle + \lambda^2\|y - z\|^2.$$

Sustituyendo en $\|x - y_\lambda\|^2 \geq \|x - z\|^2$ y cancelando $\|x - z\|^2$ en ambos lados:

$$-2\lambda\langle x - z, y - z \rangle + \lambda^2\|y - z\|^2 \geq 0.$$

Como $\lambda > 0$, podemos dividir entre λ sin voltear la desigualdad:

$$-2\langle x - z, y - z \rangle + \lambda\|y - z\|^2 \geq 0.$$

Esta desigualdad vale para *todo* $\lambda \in (0, 1]$; haciendo $\lambda \rightarrow 0^+$ (el lado izquierdo es una función continua, de hecho afín, de λ), obtenemos $-2\langle x - z, y - z \rangle \geq 0$, es decir, $\langle x - z, y - z \rangle \leq 0$. Como $y \in C$ era arbitrario, (4.1) queda probada. Fíjate en la lógica del paso al límite: si solo hubiéramos evaluado en $\lambda = 1$ obtendríamos una desigualdad contaminada por el término cuadrático $\|y - z\|^2$; mandar $\lambda \rightarrow 0^+$ aísla el término de primer orden, exactamente como en una condición de primer orden de cálculo.

Parte (iii), dirección “ $\Leftarrow$ ”: la condición (4.1) implica que z es minimizador. Supongamos que $z \in C$ satisface (4.1) y sea $y \in C$ cualquiera. Escribimos $x - y = (x - z) + (z - y)$ y expandimos:

$$\begin{aligned} \|x - y\|^2 &= \|(x - z) + (z - y)\|^2 \\ &= \|x - z\|^2 + 2\langle x - z, z - y \rangle + \|z - y\|^2 \\ &= \|x - z\|^2 + \underbrace{-2\langle x - z, y - z \rangle}_{\geq 0 \text{ por (4.1)}} + \underbrace{\|z - y\|^2}_{\geq 0} \geq \|x - z\|^2. \end{aligned}$$

(En la tercera línea usamos $\langle x - z, z - y \rangle = -\langle x - z, y - z \rangle$, y que (4.1) dice precisamente

que $-\langle x - z, y - z \rangle \geq 0$.) Tomando raíz cuadrada, $\|x - y\| \geq \|x - z\|$ para todo $y \in C$: z es minimizador. Nota que esta dirección da algo más fuerte que necesitábamos, la cota cuantitativa

$$\|x - y\|^2 \geq \|x - z\|^2 + \|y - z\|^2 \quad \text{para todo } y \in C, \quad (4.2)$$

una especie de “teorema de Pitágoras con desigualdad” que usaremos en los ejercicios.

Parte (ii): unicidad. Damos dos demostraciones, porque ambas técnicas reaparecen en el curso.

Demostración A (vía la caracterización). Supón que $z_1, z_2 \in C$ son ambos minimizadores. Por la parte (iii), ambos satisfacen (4.1). Aplica (4.1) en z_1 tomando $y = z_2$, y en z_2 tomando $y = z_1$:

$$\langle x - z_1, z_2 - z_1 \rangle \leq 0, \quad \langle x - z_2, z_1 - z_2 \rangle \leq 0.$$

En la segunda, factoriza el signo: $\langle x - z_2, z_1 - z_2 \rangle = -\langle x - z_2, z_2 - z_1 \rangle \leq 0$, o sea $\langle x - z_2, z_2 - z_1 \rangle \geq 0$. Restando la primera desigualdad de esta última (es decir, sumando $\langle z_2 - x, z_2 - z_1 \rangle \geq 0$ y $\langle x - z_1, z_2 - z_1 \rangle \leq 0$ con el signo adecuado):

$$\begin{aligned} 0 &\leq \langle x - z_2, z_2 - z_1 \rangle - \langle x - z_1, z_2 - z_1 \rangle \\ &= \langle (x - z_2) - (x - z_1), z_2 - z_1 \rangle = \langle z_1 - z_2, z_2 - z_1 \rangle = -\|z_1 - z_2\|^2. \end{aligned}$$

Espera: obtuvimos $0 \leq -\|z_1 - z_2\|^2$, y como una norma al cuadrado es siempre ≥ 0 , la única posibilidad es $\|z_1 - z_2\| = 0$, es decir, $z_1 = z_2$. Unicidad probada.

Demostración B (vía la ley del paralelogramo). Recuerda la identidad del paralelogramo, válida en cualquier espacio con producto interno (se verifica expandiendo ambos lados):

$$\|u + v\|^2 + \|u - v\|^2 = 2\|u\|^2 + 2\|v\|^2.$$

Sean z_1, z_2 dos minimizadores, ambos a distancia $d = \|x - z_1\| = \|x - z_2\|$ de x . Aplica la identidad con $u = x - z_1$ y $v = x - z_2$; entonces $u + v = 2x - z_1 - z_2 = 2(x - \frac{z_1 + z_2}{2})$ y $u - v = z_2 - z_1$:

$$4\left\|x - \frac{z_1 + z_2}{2}\right\|^2 + \|z_2 - z_1\|^2 = 2d^2 + 2d^2 = 4d^2,$$

de donde, despejando,

$$\left\|x - \frac{z_1 + z_2}{2}\right\|^2 = d^2 - \frac{1}{4}\|z_2 - z_1\|^2.$$

Aquí entra la convexidad: el punto medio $\frac{z_1 + z_2}{2}$ pertenece a C (combinación convexa con $\lambda = \frac{1}{2}$), así que su distancia a x es al menos d , la distancia mínima: $\left\|x - \frac{z_1 + z_2}{2}\right\|^2 \geq d^2$. Combinando,

$$d^2 \leq d^2 - \frac{1}{4}\|z_2 - z_1\|^2 \implies \|z_2 - z_1\|^2 \leq 0 \implies z_1 = z_2. \quad \square$$

Intuición

La demostración B tiene una moraleja geométrica hermosa: si hubiera *dos* puntos más cercanos distintos, el punto medio entre ellos estaría *estrictamente más cerca* de x (la hipotenusa es más larga que el cateto), y por convexidad ese punto medio seguiría es-

tando en C : contradicción con la minimalidad. La convexidad es la que garantiza que “promediar candidatos” no te saca del conjunto. Esta es la misma lógica por la que las funciones *estrictamente convexas* tienen minimizador único, como veremos más adelante: de hecho, la función $y \mapsto \|x - y\|^2$ es estrictamente convexa, y la demostración B es un caso particular de ese principio general.

Ejemplo 4.7 (Proyección sobre una bola y sobre el ortante). Dos proyecciones que se calculan a mano y conviene memorizar.

(a) *Bola cerrada* $C = \bar{B}(0, r) = \{y : \|y\| \leq r\}$. Si $\|x\| \leq r$, entonces $x \in C$ y $\text{proy}_C(x) = x$ (la distancia mínima, cero, se alcanza en el propio punto). Si $\|x\| > r$, afirmamos que $\text{proy}_C(x) = rx / \|x\|$ (el punto de la esfera en la dirección de x). Verifiquémoslo con la caracterización variacional, que es lo más limpio: con $z = rx / \|x\|$,

$$x - z = \left(1 - \frac{r}{\|x\|}\right)x,$$

y para cualquier $y \in C$,

$$\langle x - z, y - z \rangle = \left(1 - \frac{r}{\|x\|}\right)(\langle x, y \rangle - \langle x, z \rangle) = \left(1 - \frac{r}{\|x\|}\right)(\langle x, y \rangle - r\|x\|).$$

El primer factor es positivo (pues $\|x\| > r$). Para el segundo, Cauchy–Schwarz da $\langle x, y \rangle \leq \|x\| \|y\| \leq \|x\| r$, así que $\langle x, y \rangle - r\|x\| \leq 0$. El producto es ≤ 0 : la condición (4.1) se cumple y, por la unicidad, z es la proyección.

(b) *Ortante no negativo* $C = \mathbb{R}_+^n$. Afirmamos que la proyección se calcula coordenada a coordenada: $\text{proy}_C(x) = x^+$, donde $(x^+)_i = \max\{x_i, 0\}$. Verificación variacional: $x - x^+$ tiene coordenadas $(x - x^+)_i = \min\{x_i, 0\} \leq 0$, y además $(x - x^+)_i = 0$ siempre que $x_i \geq 0$. Para $y \in \mathbb{R}_+^n$,

$$\langle x - x^+, y - x^+ \rangle = \sum_{i=1}^n (x - x^+)_i (y_i - x_i^+) = \sum_{i: x_i < 0} x_i y_i \leq 0,$$

porque en las coordenadas con $x_i \geq 0$ el primer factor es cero, y en las coordenadas con $x_i < 0$ tenemos $x_i^+ = 0$, primer factor $x_i < 0$ y segundo factor $y_i \geq 0$. De nuevo (4.1) se cumple y la fórmula queda demostrada. Esta proyección aparece en economía cada vez que se imponen restricciones de no negatividad (cantidades, precios, multiplicadores KKT).

4.2.2. No expansividad de la proyección

La proyección no solo existe y es única: es un operador extraordinariamente bien portado. La siguiente propiedad, llamada *no expansividad* (nonexpansiveness), dice que proyectar nunca aleja: la distancia entre las proyecciones de dos puntos es a lo sumo la distancia entre los puntos originales. Es la base de los algoritmos de proyecciones alternantes y del análisis de métodos de gradiente proyectado ([5], cap. 16; [8]).

Proposición 4.8 (No expansividad). *Sea $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo. Para todos $x, x' \in \mathbb{R}^n$:*

$$(a) \text{ (No expansividad firme) } \|\text{proy}_C(x) - \text{proy}_C(x')\|^2 \leq \langle x - x', \text{proy}_C(x) - \text{proy}_C(x') \rangle.$$

(b) (No expansividad) $\|\text{proy}_C(x) - \text{proy}_C(x')\| \leq \|x - x'\|$. En particular, proy_C es una función continua (de hecho, Lipschitz con constante 1).

Demostración. Escribamos $z = \text{proy}_C(x)$ y $z' = \text{proy}_C(x')$ para aligerar la notación.

(a) Aplicamos la desigualdad variacional (4.1) dos veces, cruzando los puntos: en x con el punto de prueba $y = z' \in C$, y en x' con el punto de prueba $y = z \in C$:

$$\langle x - z, z' - z \rangle \leq 0, \quad \langle x' - z', z - z' \rangle \leq 0.$$

La estrategia es sumarmos y agrupar; hay que llevar los signos con cuidado. Sumamos las dos desigualdades tal cual:

$$\langle x - z, z' - z \rangle + \langle x' - z', z - z' \rangle \leq 0.$$

En el segundo sumando, $\langle x' - z', z - z' \rangle = -\langle x' - z', z' - z \rangle$, así que

$$\langle x - z, z' - z \rangle - \langle x' - z', z' - z \rangle \leq 0 \iff \langle (x - x') - (z - z'), z' - z \rangle \leq 0.$$

Distribuyendo el producto interno:

$$\langle x - x', z' - z \rangle - \langle z - z', z' - z \rangle \leq 0.$$

Como $\langle z - z', z' - z \rangle = -\|z - z'\|^2$, esto es

$$\langle x - x', z' - z \rangle + \|z - z'\|^2 \leq 0 \iff \|z - z'\|^2 \leq \langle x - x', z - z' \rangle,$$

que es exactamente (a).

(b) Si $z = z'$ no hay nada que probar. Si $z \neq z'$, aplicamos la desigualdad de Cauchy-Schwarz al lado derecho de (a):

$$\|z - z'\|^2 \leq \langle x - x', z - z' \rangle \leq \|x - x'\| \|z - z'\|.$$

Dividiendo ambos lados entre $\|z - z'\| > 0$ obtenemos $\|z - z'\| \leq \|x - x'\|$. La continuidad Lipschitz es inmediata de esta cota. $\square$

Observación 4.9. La versión “firme” (a) es más fuerte que (b): dice que el desplazamiento de las proyecciones no solo es corto, sino que está *positivamente alineado* con el desplazamiento de los puntos originales. En los capítulos de algoritmos esta propiedad garantiza la convergencia del gradiente proyectado; en teoría del consumidor, es la razón técnica por la que las demandas (que son proyecciones generalizadas sobre el conjunto presupuestario) responden con continuidad a los precios cuando hay convexidad.

4.3. Separación de un punto y un convexo [P1]

4.3.1. El vocabulario de la separación

Antes de los teoremas, fijemos con precisión qué significa “separar”, porque hay varias nociones de fuerza creciente y los enunciados de Microeconomía y de los textos las mezclan si uno no está

atento.

Definición 4.10 (Tipos de separación). Sean $A, B \subseteq \mathbb{R}^n$ no vacíos y sea $H(a, \beta)$ un hiperplano ($a \neq 0$). Decimos que $H(a, \beta)$:

- (a) *separa* (separates) A y B si $\langle a, u \rangle \leq \beta \leq \langle a, v \rangle$ para todos $u \in A, v \in B$; equivalentemente, $A \subseteq H^-$ y $B \subseteq H^+$;
- (b) los *separa propiamente* (properly) si además $A \cup B \not\subseteq H$, es decir, no ocurre que ambos conjuntos vivan dentro del propio hiperplano (lo que haría la separación trivial e inútil);
- (c) los *separa estrictamente* (strictly) si $\langle a, u \rangle < \beta < \langle a, v \rangle$ para todos $u \in A, v \in B$;
- (d) los *separa fuertemente* (strongly) si existe $\varepsilon > 0$ tal que $\langle a, u \rangle \leq \beta - \varepsilon < \beta + \varepsilon \leq \langle a, v \rangle$ para todos $u \in A, v \in B$; equivalentemente, $\sup_{u \in A} \langle a, u \rangle < \inf_{v \in B} \langle a, v \rangle$.

Claramente fuerte $\Rightarrow$ estricta $\Rightarrow$ propia $\Rightarrow$ separación a secas (la segunda implicación vale porque, si todos los puntos de A cumplen $\langle a, u \rangle < \beta$, entonces $A \cup B \not\subseteq H$). Las implicaciones inversas fallan, y parte del trabajo de este capítulo es entender *qué hipótesis compran qué nivel de separación*; la Sección 4.5 da los contraejemplos.




Figura 4.2: Dos conjuntos convexos separados por el hiperplano $H(a, \beta)$: la función lineal $\langle a, \cdot \rangle$ vale a lo sumo β en A y al menos β en B . La normal a apunta del lado de B .

4.3.2. Separación fuerte de un punto y un convexo cerrado

Con el teorema de proyección, el primer teorema de separación sale casi solo: la cuerda tensa $x - \text{proy}_C(x)$ nos regala la normal.

Teorema 4.11 (Separación fuerte punto–conjunto). Sea $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo, y sea $x \notin C$. Entonces existen $a \in \mathbb{R}^n$, $a \neq 0$, y $\beta \in \mathbb{R}$ tales que

$$\langle a, y \rangle < \beta < \langle a, x \rangle \quad \text{para todo } y \in C,$$

y de hecho la separación es fuerte: $\sup_{y \in C} \langle a, y \rangle < \beta < \langle a, x \rangle$. Concretamente sirve $a = x - \text{proy}_C(x)$ con $\beta = \langle a, \text{proy}_C(x) \rangle + \frac{1}{2} \|a\|^2$.

Demostración. Sea $z = \text{proy}_C(x)$, que existe y es única por el Teorema 4.6, y define $a = x - z$.

Paso 1: $a \neq 0$. Si fuera $a = 0$ tendríamos $x = z \in C$, contradiciendo $x \notin C$. (Aquí es esencial que C sea cerrado: es lo que garantiza que la proyección esté en C y que un punto fuera de C esté a distancia positiva, $\|a\| > 0$.)

Paso 2: la función lineal $\langle a, \cdot \rangle$ está acotada en C por su valor en z . Tomemos cualquier $y \in C$. La desigualdad variacional (4.1) dice $\langle x - z, y - z \rangle \leq 0$, es decir, $\langle a, y - z \rangle \leq 0$. Por linealidad,

$$\langle a, y \rangle \leq \langle a, z \rangle \quad \text{para todo } y \in C.$$

En palabras: todo el conjunto C vive en el semiespacio $\{w : \langle a, w \rangle \leq \langle a, z \rangle\}$.

Paso 3: el valor en x es estrictamente mayor, con holgura cuantificada. Calculamos

$$\langle a, x \rangle - \langle a, z \rangle = \langle a, x - z \rangle = \langle a, a \rangle = \|a\|^2 > 0.$$

Es decir, $\langle a, x \rangle = \langle a, z \rangle + \|a\|^2$.

Paso 4: elegir el nivel β en medio. Tomamos $\beta = \langle a, z \rangle + \frac{1}{2} \|a\|^2$, el punto medio entre el valor máximo posible en C y el valor en x . Entonces, para todo $y \in C$,

$$\langle a, y \rangle \leq \langle a, z \rangle = \beta - \frac{1}{2} \|a\|^2 < \beta < \beta + \frac{1}{2} \|a\|^2 = \langle a, x \rangle.$$

La cadena muestra separación con holgura $\varepsilon = \frac{1}{2} \|a\|^2 > 0$ a cada lado: separación fuerte. Además $\sup_{y \in C} \langle a, y \rangle \leq \langle a, z \rangle < \beta$, como se afirmó. $\square$

Intuición

La demostración es un algoritmo de construcción de precios en miniatura: (1) proyecta el punto sobre el conjunto; (2) la dirección del “error de proyección” $x - \text{proy}_C(x)$ es la normal separadora; (3) el nivel β se pone a mitad de camino. En el Segundo Teorema del Bienestar haremos exactamente esto con C igual a un conjunto de asignaciones “mejores que el óptimo” y la normal resultante será el vector de precios. Cuando pienses “¿de dónde salen los precios?”, la respuesta técnica es: de una proyección.

4.3.3. Consecuencia: los convexos cerrados son intersecciones de semiespacios

Corolario 4.12 (Representación externa de un convexo cerrado). *Todo conjunto $C \subseteq \mathbb{R}^n$ convexo, cerrado y no vacío es la intersección de todos los semiespacios cerrados que lo contienen:*

$$C = \bigcap \{H^-(a, \beta) : C \subseteq H^-(a, \beta)\}.$$

Demostración. Llamemos D a la intersección de la derecha.

($\subseteq$) Si $x \in C$, entonces x pertenece a cada semiespacio que contiene a C , luego $x \in D$. Esta inclusión es trivial y no usa ninguna hipótesis.

($\supseteq$) Probamos el contrarrecíproco: si $x \notin C$, exhibimos un semiespacio que contiene a C pero no a x , con lo cual $x \notin D$. Por el Teorema 4.11 existen $a \neq 0$ y β con $\langle a, y \rangle < \beta$ para todo $y \in C$ y $\langle a, x \rangle > \beta$. Entonces $C \subseteq H^-(a, \beta)$ (incluso con desigualdad estricta), así que $H^-(a, \beta)$ es uno de los semiespacios de la familia, pero $x \notin H^-(a, \beta)$ porque $\langle a, x \rangle > \beta$. Por tanto $x \notin D$. $\square$

Observación 4.13 (Dualidad embrionaria). Este corolario es conceptualmente enorme: dice que un convexo cerrado admite dos descripciones equivalentes, una *interna* (como conjunto de sus puntos, o de combinaciones convexas de ellos) y una *externa* (como intersección de desigualdades

lineales). Pasar de una descripción a la otra es la esencia de la *dualidad* en optimización convexa ([2], secciones 2.5 y 5.1; [6], cap. 2). En economía, la misma dualidad conecta la función de utilidad con la función de gasto, y el conjunto de producción con la función de beneficios: conocer “todos los hiperplanos soporte” de un convexo es conocer el convexo. El teorema de la envolvente y las identidades de Shephard y Hotelling (que verás en Microeconomía y en el capítulo 11, [11]) viven precisamente en esta correspondencia.

Cuidado (error común)

Las hipótesis del Teorema 4.11 son las dos imprescindibles y ninguna se puede quitar. **Sin cerradura:** toma $C = B(0, 1)$ la bola abierta en $\mathbb{R}^2$ y $x = (1, 0) \notin C$. Todo hiperplano que “separe” debe cumplir $\langle a, y \rangle \leq \beta \leq \langle a, x \rangle$, pero como hay puntos de C arbitrariamente cercanos a x , por continuidad $\sup_{y \in C} \langle a, y \rangle \geq \langle a, x \rangle$: la separación existe (no estricta, con igualdad de sup e ínfimo) pero la separación *fuerte* es imposible. **Sin convexidad:** toma $C = \{y \in \mathbb{R}^2 : \|y\| = 1\}$ la circunferencia (cerrada pero no convexa) y $x = 0$. Cualquier hiperplano por el origen deja puntos de C estrictamente a ambos lados, y un hiperplano que no pasa por el origen tampoco puede dejar a toda la circunferencia de un lado y al origen del otro (la circunferencia “rodea” a x). No hay separación de ningún tipo. Moraleja: cuando en un examen te pidan separar, *verifica primero* cerradura y convexidad, y si piden separación fuerte entre dos conjuntos, busca además compacidad (Teorema 4.19).

4.4. Hiperplanos soporte [P1]

4.4.1. Motivación y definición

El Teorema 4.11 separa un punto *fuera* del conjunto. Pero en economía los puntos interesantes suelen estar en la *frontera*: la cesta óptima está en la recta presupuestaria, el plan de producción óptimo está en la frontera del conjunto de producción, el óptimo de Pareto está en la frontera del conjunto de utilidades factibles. Para esos puntos no puede haber separación fuerte (el punto pertenece a la clausura del conjunto), pero sí algo muy útil: un hiperplano que *toca* al conjunto en ese punto y lo deja todo de un lado, como una regla apoyada contra el borde de un plato.

Definición 4.14 (Hiperplano soporte). Sea $C \subseteq \mathbb{R}^n$ y $x_0 \in \text{fr } C$ un punto de su frontera. Un hiperplano $H(a, \beta)$ es un *hiperplano soporte* (supporting hyperplane) de C en x_0 si

$$\langle a, x_0 \rangle = \beta \quad \text{y} \quad \langle a, y \rangle \leq \beta \quad \text{para todo } y \in C.$$

Es decir: el hiperplano pasa por x_0 y el conjunto entero queda en el semiespacio inferior. El vector a se llama *normal exterior* (outer normal) de C en x_0 , y decimos que H *soporta* a C en x_0 .

Observa la relación con la maximización: $H(a, \beta)$ soporta a C en x_0 exactamente cuando $x_0 \in \arg \max_{y \in C} \langle a, y \rangle$, con valor máximo β . Un hiperplano soporte es, literalmente, el certificado de que x_0 maximiza una función lineal sobre C : en la empresa, “el plan y^* maximiza beneficios a

precios p ” significa “el hiperplano de isobeneficio con normal p soporta al conjunto de producción en y^* ”.

Teorema 4.15 (Existencia de hiperplano soporte). *Sea $C \subseteq \mathbb{R}^n$ convexo y no vacío, y sea $x_0 \in \text{fr } C$ un punto frontera de C . Entonces existe un hiperplano soporte de C en x_0 : hay $a \neq 0$ tal que $\langle a, y \rangle \leq \langle a, x_0 \rangle$ para todo $y \in C$.*

Demostración. La idea: aproximar x_0 por puntos *exteriores* $x_k \rightarrow x_0$, separar cada x_k del conjunto con el Teorema 4.11, y pasar al límite en las normales. El paso al límite exige un argumento de compacidad que detallamos.

Paso 0: reducción al caso con interior no vacío. Si $\text{int } C = \emptyset$, el capítulo 2 nos dice que C está contenido en un conjunto afín propio $\text{aff } C \neq \mathbb{R}^n$, y por tanto en algún hiperplano $H(a, \beta)$ que pasa por x_0 (todo conjunto afín propio que contiene a C está contenido en un hiperplano que contiene a C ; como $x_0 \in \text{cl } C \subseteq H$ por cerradura del hiperplano, sirve $\beta = \langle a, x_0 \rangle$). Un hiperplano que *contiene* a C lo soporta trivialmente en cualquiera de sus puntos: $\langle a, y \rangle = \beta$ para todo $y \in C$. Supondremos en adelante $\text{int } C \neq \emptyset$.

Paso 1: existencia de la sucesión exterior. Trabajamos con $D = \text{cl } C$, que es convexo (clausura de convexo, cap. 2) y cerrado. Como $\text{int } C \neq \emptyset$, sabemos del capítulo 2 que $\text{int}(\text{cl } C) = \text{int } C$ y $\text{fr}(\text{cl } C) = \text{fr } C$; en particular $x_0 \in \text{fr } D$, de modo que toda bola $B(x_0, 1/k)$ contiene puntos del complemento de D . Elegimos para cada $k \in \mathbb{N}$ un punto $x_k \notin D$ con $\|x_k - x_0\| < 1/k$; por construcción $x_k \rightarrow x_0$.

Paso 2: separar cada x_k . Como D es cerrado, convexo, no vacío y $x_k \notin D$, el Teorema 4.11 produce un vector $\tilde{a}_k \neq 0$ con $\langle \tilde{a}_k, y \rangle < \langle \tilde{a}_k, x_k \rangle$ para todo $y \in D$. Normalizamos (Observación 4.2): definimos $a_k = \tilde{a}_k / \|\tilde{a}_k\|$, que satisface la misma desigualdad (dividir entre un número positivo la preserva):

$$\langle a_k, y \rangle < \langle a_k, x_k \rangle \quad \text{para todo } y \in D, \quad \|a_k\| = 1. \quad (4.3)$$

Paso 3: compacidad de la esfera unitaria. Aquí está el corazón del argumento. La sucesión (a_k) vive en la esfera unitaria $S^{n-1} = \{a \in \mathbb{R}^n : \|a\| = 1\}$, que es un conjunto cerrado y acotado de $\mathbb{R}^n$, luego *compacto* (Heine–Borel). Por el teorema de Bolzano–Weierstrass (capítulo de preliminares), toda sucesión en un compacto tiene una subsucesión convergente *con límite en el compacto*: existe una subsucesión (a_{k_j}) y un vector $a \in S^{n-1}$ con $a_{k_j} \rightarrow a$. Lo crucial es que $\|a\| = 1$, en particular $a \neq 0$: la normalización del Paso 2 es lo que impide que las normales “degeneren” a cero en el límite, que produciría el enunciado vacío $0 \leq 0$. Sin compacidad no habría manera de garantizar un límite; este patrón (normalizar + Bolzano–Weierstrass) es una técnica que reaparece en todo el análisis convexo y en teoría del equilibrio general.

Paso 4: pasar al límite. Fijemos $y \in D$ y tomemos límite en (4.3) a lo largo de la subsucesión. El producto interno es continuo en cada argumento, y $a_{k_j} \rightarrow a$, $x_{k_j} \rightarrow x_0$; por tanto

$$\langle a_{k_j}, y \rangle \rightarrow \langle a, y \rangle, \quad \langle a_{k_j}, x_{k_j} \rangle \rightarrow \langle a, x_0 \rangle$$

(para la segunda convergencia: $|\langle a_{k_j}, x_{k_j} \rangle - \langle a, x_0 \rangle| \leq |\langle a_{k_j}, x_{k_j} - x_0 \rangle| + |\langle a_{k_j} - a, x_0 \rangle| \leq \|x_{k_j} - x_0\| + \|a_{k_j} - a\| \|x_0\| \rightarrow 0$, usando Cauchy–Schwarz y $\|a_{k_j}\| = 1$). Las desigualdades

estrictas se vuelven no estrictas en el límite (regla general: $u_j < v_j$ y $u_j \rightarrow u$, $v_j \rightarrow v$ solo garantizan $u \leq v$), y obtenemos

$$\langle a, y \rangle \leq \langle a, x_0 \rangle \quad \text{para todo } y \in D \supseteq C.$$

Con $\beta = \langle a, x_0 \rangle$, el hiperplano $H(a, \beta)$ pasa por x_0 y deja a C en el semiespacio inferior: es un hiperplano soporte. $\square$

Observación 4.16 (¿Por qué solo separación no estricta?). En el límite perdimos la desigualdad estricta, y no es un defecto de la demostración: es imposible hacerlo mejor. Como $x_0 \in \text{cl } C$, hay puntos $y \in C$ arbitrariamente cercanos a x_0 , y por continuidad $\sup_{y \in C} \langle a, y \rangle = \langle a, x_0 \rangle$ exactamente. El hiperplano soporte *toca* al conjunto; separa, pero ni estricta ni fuertemente. Este fenómeno reaparecerá en el Segundo Teorema del Bienestar: la separación que se obtiene ahí también es no estricta, y por eso el teorema entrega primero un “cuasi-equilibrio” que luego hay que mejorar con un argumento adicional (Sección 4.7).

Ejemplo 4.17 (Hiperplanos soporte del disco y del cuadrado). (a) Sea $C = \bar{B}(0, 1) \subset \mathbb{R}^2$ y $x_0 = (\frac{3}{5}, \frac{4}{5}) \in \text{fr } C$ (está en la circunferencia unitaria pues $(3/5)^2 + (4/5)^2 = 1$). Afirmamos que $a = x_0$ es normal exterior. En efecto, para $y \in C$, Cauchy–Schwarz da

$$\langle x_0, y \rangle \leq \|x_0\| \|y\| \leq 1 \cdot 1 = 1 = \langle x_0, x_0 \rangle,$$

así que el hiperplano $\{y : \frac{3}{5}y_1 + \frac{4}{5}y_2 = 1\}$ soporta a C en x_0 y es único (la circunferencia es “suave”: en cada punto frontera hay exactamente una recta tangente).

(b) Sea $C = [0, 1]^2$ y $x_0 = (1, 1)$, una esquina. Aquí hay *muchos* hiperplanos soporte: cualquier $a = (a_1, a_2)$ con $a_1, a_2 \geq 0$, $a \neq 0$, cumple, para $y \in [0, 1]^2$, $\langle a, y \rangle = a_1y_1 + a_2y_2 \leq a_1 + a_2 = \langle a, x_0 \rangle$. En los puntos “con esquina” el hiperplano soporte existe pero no es único. Esta multiplicidad no es una curiosidad: es exactamente lo que ocurre con las curvas de indiferencia con quiebres (por ejemplo, preferencias Leontief $u(x) = \min\{x_1, x_2\}$), donde hay un abanico de precios que soportan la misma cesta óptima, y es el germen de la noción de *subdiferencial* del capítulo 7.

4.5. Separación de dos conjuntos convexos [P1]

4.5.1. El truco de la diferencia de Minkowski

Para separar dos conjuntos A y B el truco maestro es reducir el problema al caso punto–conjunto que ya dominamos, usando la *diferencia de Minkowski*

$$A - B = \{u - v : u \in A, v \in B\}.$$

La observación clave es puramente lógica:

$$A \cap B = \emptyset \iff 0 \notin A - B,$$

porque $0 = u - v$ con $u \in A$, $v \in B$ equivale a $u = v \in A \cap B$. Además, si A y B son convexos, $A - B = A + (-B)$ es convexo (suma de Minkowski de convexos, capítulo 2). Y separar el

punto 0 de $A - B$ con normal a , es decir $\langle a, u - v \rangle \leq 0$ para todos u, v , es exactamente decir $\langle a, u \rangle \leq \langle a, v \rangle$: ¡ A y B quedan separados! Todo el problema se reduce entonces a una pregunta: ¿qué propiedades hereda $A - B$ de A y B ? Aquí aparece una sutileza topológica famosa.

Lema 4.18 (Compacto menos cerrado es cerrado). *Si $A \subseteq \mathbb{R}^n$ es compacto y $B \subseteq \mathbb{R}^n$ es cerrado, entonces $A - B$ es cerrado. En cambio, la diferencia de dos cerrados puede no ser cerrada.*

Demostración. Sea (w_k) una sucesión en $A - B$ con $w_k \rightarrow w$; debemos probar $w \in A - B$. Escribimos $w_k = u_k - v_k$ con $u_k \in A$, $v_k \in B$. Como A es compacto, por Bolzano–Weierstrass hay una subsucesión $u_{k_j} \rightarrow u \in A$. Entonces

$$v_{k_j} = u_{k_j} - w_{k_j} \longrightarrow u - w,$$

porque tanto u_{k_j} como w_{k_j} convergen (¡aquí la compacidad de A es la que “ancla” la sucesión v_{k_j} , que a priori podría escaparse a infinito!). Como B es cerrado y $v_{k_j} \in B$, el límite cumple $u - w \in B$. Por tanto $w = u - (u - w) \in A - B$.

Para el contraejemplo con dos cerrados: en $\mathbb{R}^2$ tomemos

$$A = \{(t, 0) : t \in \mathbb{R}\} \quad (\text{el eje horizontal}), \quad B = \{(t, 1/t) : t > 0\} \quad (\text{una rama de hipérbola}),$$

ambos cerrados y, de hecho, convexo el primero (el segundo no es convexo, pero puede reemplazarse por su “epígrafo” convexo $\{(t, s) : t > 0, s \geq 1/t\}$, también cerrado, y el argumento es idéntico). La diferencia $A - B$ contiene los puntos $(t - t, 0 - 1/t) = (0, -1/t)$ para todo $t > 0$, que convergen a $(0, 0)$; pero $(0, 0) \notin A - B$, pues $(0, 0) = (t, 0) - (s, 1/s)$ exigiría $1/s = 0$, imposible. El origen es punto de acumulación que no pertenece: $A - B$ no es cerrado. $\square$

4.5.2. Separación fuerte: compacto y cerrado disjuntos

Teorema 4.19 (Separación fuerte de dos convexos). *Sean $A, B \subseteq \mathbb{R}^n$ convexos, no vacíos y disjuntos, con A compacto y B cerrado. Entonces existen $\alpha \neq 0$ y $\beta_1 < \beta_2$ tales que*

$$\langle \alpha, u \rangle \leq \beta_1 < \beta_2 \leq \langle \alpha, v \rangle \quad \text{para todos } u \in A, v \in B :$$

separación fuerte, $\sup_{u \in A} \langle \alpha, u \rangle < \inf_{v \in B} \langle \alpha, v \rangle$.

Demostración. Consideramos $D = B - A$. Por lo dicho arriba: D es convexo (suma de Minkowski $B + (-A)$ de convexos), es cerrado (por el Lema 4.18, aplicado a la diferencia del cerrado B y el compacto A ; nota que $B - A = -(A - B)$ y el negativo de un cerrado es cerrado), es no vacío, y $0 \notin D$ porque $A \cap B = \emptyset$.

Estamos en las hipótesis exactas del Teorema 4.11 con $C = D$ y $x = 0$: el teorema punto–conjunto entrega $\tilde{\alpha} \neq 0$ (concretamente $\tilde{\alpha} = 0 - \text{proy}_D(0) = -\text{proy}_D(0)$) y un nivel β con

$$\langle \tilde{\alpha}, d \rangle < \beta < \langle \tilde{\alpha}, 0 \rangle = 0 \quad \text{para todo } d \in D.$$

La conclusión de separación fuerte de aquel teorema dice más: $\sup_{d \in D} \langle \tilde{\alpha}, d \rangle < \beta < 0$, de modo

que existe $\varepsilon = -\beta > 0$ tal que

$$\langle \tilde{a}, v - u \rangle \leq -\varepsilon \quad \text{para todos } u \in A, v \in B.$$

Definimos $a = -\tilde{a}$ para orientar la normal hacia B ; la desigualdad se convierte en $\langle a, v - u \rangle \geq \varepsilon$, o sea

$$\langle a, v \rangle \geq \langle a, u \rangle + \varepsilon \quad \text{para todos } u \in A, v \in B.$$

Tomando supremo sobre $u \in A$ en el lado derecho (el supremo es finito: A es compacto y $\langle a, \cdot \rangle$ continua, así que por Weierstrass el supremo se alcanza) y luego ínfimo sobre $v \in B$ en el izquierdo:

$$\inf_{v \in B} \langle a, v \rangle \geq \sup_{u \in A} \langle a, u \rangle + \varepsilon > \sup_{u \in A} \langle a, u \rangle.$$

Basta elegir $\beta_1 = \sup_{u \in A} \langle a, u \rangle$ y $\beta_2 = \beta_1 + \varepsilon$; cualquier nivel $\beta \in (\beta_1, \beta_2)$ define un hiperplano que separa fuertemente. $\square$

Observación 4.20. La demostración muestra por qué pedimos *un* compacto y no dos cerrados: sin compacidad, $B - A$ podría no ser cerrado y el origen podría ser un punto de acumulación de $B - A$ sin pertenecerle, lo que mata la separación fuerte. El contraejemplo canónico, que debes saber dibujar y citar en el examen, es:

$$A = \{(x_1, x_2) \in \mathbb{R}^2 : x_2 \leq 0\}, \quad B = \{(x_1, x_2) \in \mathbb{R}^2 : x_1 > 0, x_2 \geq 1/x_1\}.$$

Ambos son cerrados, convexos (el segundo es el epígrafo de la función convexa $x_1 \mapsto 1/x_1$ sobre el dominio $x_1 > 0$, y se verifica sin dificultad que es cerrado) y disjuntos. El único hiperplano separador es el eje horizontal $\{x_2 = 0\}$: separa, incluso propiamente, pero *no fuertemente*, porque $\inf_{v \in B} v_2 = 0 = \sup_{u \in A} u_2$ (la hipérbola se acerca asintóticamente al eje sin tocarlo). La distancia entre A y B es cero aunque son disjuntos. Otro contraejemplo, aún más simple, para “estricta”: dos discos cerrados tangentes exteriormente, como $\bar{B}((-1, 0), 1)$ y $\bar{B}((1, 0), 1)$, que se tocan en el origen; la recta vertical $\{x_1 = 0\}$ los separa, pero ningún hiperplano puede separarlos estrictamente porque el punto común $(0, 0)$ tendría que estar estrictamente en ambos lados a la vez.

4.5.3. Separación de convexos disjuntos cualesquiera

¿Y si no hay compacidad? Todavía se puede separar, aunque solo en el sentido débil. El siguiente teorema no exige cerradura ni acotación: solo convexidad y disjunción.

Teorema 4.21 (Separación de convexos disjuntos). *Sean $A, B \subseteq \mathbb{R}^n$ convexos, no vacíos y disjuntos. Entonces existe $a \neq 0$ tal que*

$$\langle a, u \rangle \leq \langle a, v \rangle \quad \text{para todos } u \in A, v \in B;$$

es decir, $\sup_{u \in A} \langle a, u \rangle \leq \inf_{v \in B} \langle a, v \rangle$, y cualquier β entre esos dos valores define un hiperplano separador.

Demostración. Sea $D = B - A$, convexo y no vacío, con $0 \notin D$ (disjunción). Distinguimos dos casos según la posición del origen respecto de la clausura $\text{cl } D$, y en ambos producimos $a \neq 0$ con $\langle a, d \rangle \geq 0$ para todo $d \in D$.

Caso 1: $0 \notin \text{cl } D$. El conjunto $\text{cl } D$ es cerrado, convexo (clausura de convexo) y no vacío, y el origen está fuera. El Teorema 4.11 (aplicado con la orientación adecuada de la normal, como en la demostración anterior) da $a \neq 0$ con $\langle a, d \rangle > \langle a, 0 \rangle = 0$ para todo $d \in \text{cl } D \supseteq D$. Listo (incluso con desigualdad estricta).

Caso 2: $0 \in \text{cl } D$ pero $0 \notin D$. Entonces el origen está en la clausura sin estar en el conjunto, luego $0 \in \text{fr } D$ (un punto de $\text{cl } D \setminus D$ no puede ser interior, pues $\text{int } D \subseteq D$). Por el teorema del hiperplano soporte (Teorema 4.15, aplicado al convexo D y su punto frontera 0 ; nota que aquel teorema no exige que el punto pertenezca al conjunto, solo que esté en la frontera), existe $a' \neq 0$ con $\langle a', d \rangle \leq \langle a', 0 \rangle = 0$ para todo $d \in D$. Tomando $a = -a'$: $\langle a, d \rangle \geq 0$ para todo $d \in D$.

En ambos casos tenemos $a \neq 0$ con $\langle a, v - u \rangle \geq 0$, es decir $\langle a, u \rangle \leq \langle a, v \rangle$, para todos $u \in A$, $v \in B$. Tomando supremo e ínfimo se obtiene la conclusión. $\square$

Observación 4.22 (La versión de interior relativo). El enunciado más fino, que es el que citan [6] (Teorema 2.15) y Rockafellar, usa el *interior relativo* del capítulo 2: dos convexos no vacíos A y B admiten separación *propia* (Definición 4.10(b)) si y solo si

$$\text{ri } A \cap \text{ri } B = \emptyset.$$

Esta condición es más débil que la disjunción: permite que A y B compartan puntos frontera. Por ejemplo, los dos discos tangentes de arriba se tocan en un punto, pero sus interiores relativos son disjuntos, y en efecto la recta tangente común los separa propiamente. La necesidad de pedir separación *propia* (y no a secas) se ve con $A = B =$ un segmento dentro de una recta: el hiperplano que contiene a la recta “separa” trivialmente ($\langle a, u \rangle = \beta = \langle a, v \rangle$ para todos los puntos) sin dar información alguna; la separación propia excluye esa trivialidad. No demostraremos aquí la suficiencia general (requiere un análisis fino de $\text{ri}(A - B)$; puedes ver [6], sec. 2.2), pero conviene memorizar el enunciado porque es el que se usa en las demostraciones serias de equilibrio general. Un caso particular útil que sí se deduce de lo que probamos: si A es *abierto* y disjunto de B , la separación del Teorema 4.21 es automáticamente estricta del lado de A , es decir $\langle a, u \rangle < \beta$ para todo $u \in A$ (si algún punto de un conjunto abierto alcanzara el nivel β del supremo, podríamos movernos un poco en la dirección a sin salir de A y superar β , contradicción); este es el Ejercicio 4.34.

Estrategia de examen

Ante un problema de separación (en el examen o en un paper), hazte estas preguntas en orden. (1) ¿Los dos conjuntos son convexos? Si no, no hay teorema que valga: busca convexificar (cápsula convexa, aleatorización, agregación a la Aumann). (2) ¿Qué fuerza de separación necesito? Para *existencia de precios* suele bastar la separación no estricta (Teorema 4.21 o soporte); para *unicidad o robustez* se busca fuerte. (3) ¿Qué topología tengo? punto fuera de cerrado $\Rightarrow$ fuerte (Teorema 4.11); compacto vs. cerrado disjuntos $\Rightarrow$ fuerte (Teorema 4.19); solo disjuntos $\Rightarrow$ débil (Teorema 4.21); se tocan en la frontera

$\Rightarrow$ soporte / interiores relativos disjuntos (Teorema 4.15, Observación 4.22). (4) Para *construir* el hiperplano en ejemplos concretos: proyecta y usa $a = x - \text{proy}_C(x)$, o en el caso de dos conjuntos minimiza $\|u - v\|$ sobre $A \times B$. (5) Verifica siempre la conclusión evaluando la función lineal en puntos concretos de cada conjunto: es la manera más rápida de detectar un error de signo.

4.6. El lema de Farkas [P1]

4.6.1. Motivación: sistemas lineales con signo

Muchas preguntas de optimización y de economía se reducen a: ¿tiene solución este sistema de ecuaciones/desigualdades lineales? Por ejemplo: ¿existe una cartera con rendimientos no negativos en todos los estados y costo negativo (un arbitraje)? ¿Existen multiplicadores no negativos que expresen el gradiente del objetivo como combinación de los gradientes de las restricciones activas (KKT)? El *lema de Farkas* (Farkas lemma) responde este tipo de preguntas con una estructura lógica muy elegante llamada *alternativa*: de dos sistemas, **exactamente uno** tiene solución. Cuando el sistema “primal” no tiene solución, el sistema alternativo produce un *certificado* verificable de esa imposibilidad. La demostración es una aplicación directa de la separación fuerte, con los conos del capítulo 3 como protagonistas.

Recordemos del capítulo 3 el objeto clave: dada una matriz A de tamaño $m \times n$ con columnas $A_1, \dots, A_n \in \mathbb{R}^m$, el *cono finitamente generado*

$$K = \{Ax : x \in \mathbb{R}^n, x \geq 0\} = \left\{ \sum_{j=1}^n x_j A_j : x_j \geq 0 \right\} = \text{cono}\{A_1, \dots, A_n\}$$

es el conjunto de combinaciones lineales *no negativas* de las columnas. En el capítulo 3 vimos que K es un cono convexo. Necesitamos además un segundo hecho, que allí solo enunciamos al presentar el teorema de Minkowski–Weyl y que aquí admitimos sin demostrar: todo cono finitamente generado es *cerrado* (se prueba con un argumento de tipo Carathéodory, reduciendo a combinaciones de columnas linealmente independientes; ver [6, cap. 2] y [3, cap. 4]). Ese hecho, nada obvio (¡la imagen lineal de un cerrado puede no ser cerrada!), es el que permite usar separación fuerte.

Teorema 4.23 (Lema de Farkas). Sean $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. *Exactamente uno de los dos sistemas siguientes tiene solución:*

- (I) $Ax = b, \quad x \geq 0 \quad (\text{con } x \in \mathbb{R}^n);$
- (II) $A^\top y \leq 0, \quad \langle b, y \rangle > 0 \quad (\text{con } y \in \mathbb{R}^m).$

Antes de la prueba, leamos los dos sistemas. El sistema (I) dice “ b es combinación no negativa de las columnas de A ”, es decir, $b \in K$. El sistema (II) dice “existe un vector y que forma ángulo agudo con b (pues $\langle b, y \rangle > 0$) y ángulo obtuso o recto con cada columna A_j (pues $(A^\top y)_j = \langle A_j, y \rangle \leq 0$)”. Tal y es la normal de un hiperplano por el origen que deja al cono K entero de un lado y a b estrictamente del otro: un *certificado geométrico* de que $b \notin K$. La alternativa dice: o b está en el cono, o hay un hiperplano-testigo que lo delata; no hay tercera posibilidad, y nunca ambas.

Demostración. Paso 1: (I) y (II) no pueden valer a la vez. Supón que $x \geq 0$ resuelve (I) y que y resuelve (II). Entonces

$$0 < \langle b, y \rangle = \langle Ax, y \rangle = \langle x, A^\top y \rangle = \sum_{j=1}^n x_j (A^\top y)_j \leq 0,$$

donde la segunda igualdad es la definición de matriz traspuesta (propiedad adjunta del producto interno, capítulo 1) y la última desigualdad usa que cada sumando es (no negativo) $\times$ (no positivo) ≤ 0 . La cadena $0 < 0$ es absurda; a lo sumo uno de los sistemas es soluble.

Paso 2: si (I) no tiene solución, (II) sí. Que (I) no tenga solución significa exactamente $b \notin K$, con $K = \{Ax : x \geq 0\}$ el cono de columnas. Por el capítulo 3, K es convexo, cerrado y no vacío ($0 = A \cdot 0 \in K$). Aplicamos la separación fuerte punto–conjunto (Teorema 4.11) al conjunto K y al punto $b \notin K$: existen $y \neq 0$ y β tales que

$$\langle y, k \rangle < \beta < \langle y, b \rangle \quad \text{para todo } k \in K. \quad (4.4)$$

(Hemos llamado y a la normal, orientada hacia b .) Ahora explotamos la estructura de cono de K en dos observaciones.

Observación (a): $\beta > 0$, y por tanto $\langle b, y \rangle > 0$. Como $0 \in K$, la desigualdad (4.4) con $k = 0$ da $0 = \langle y, 0 \rangle < \beta$. Y entonces $\langle y, b \rangle > \beta > 0$. Ya tenemos la segunda condición de (II).

Observación (b): $\langle y, k \rangle \leq 0$ para todo $k \in K$, y por tanto $A^\top y \leq 0$. Aquí está el argumento típico con conos: supongamos, buscando una contradicción, que algún $k_0 \in K$ tuviera $\langle y, k_0 \rangle > 0$. Como K es un cono, $t k_0 \in K$ para todo $t > 0$, y entonces

$$\langle y, t k_0 \rangle = t \langle y, k_0 \rangle \xrightarrow{t \rightarrow \infty} +\infty,$$

lo que viola la cota superior $\langle y, k \rangle < \beta$ de (4.4) para t grande. Contradicción. Luego $\langle y, k \rangle \leq 0$ para todo $k \in K$. En particular, cada columna $A_j = A e_j$ (con e_j el j -ésimo vector canónico, $e_j \geq 0$) pertenece a K , así que $(A^\top y)_j = \langle A_j, y \rangle \leq 0$ para todo j : esto es $A^\top y \leq 0$, la primera condición de (II).

Con (a) y (b), el vector y resuelve (II), y la alternativa queda demostrada. $\square$

Intuición

Nota cómo la estructura de cono “mejora gratis” la separación: un hiperplano que separa un punto de un cono puede siempre tomarse pasando por el origen (nivel 0), porque la cota lineal sobre un cono solo es sostenible si la función lineal es ≤ 0 en todo el cono. Los conos convierten desigualdades con nivel β en desigualdades homogéneas con nivel 0; esa homogeneización es la razón por la que los multiplicadores KKT y los precios de arbitraje aparecen “sin unidades absolutas”, definidos salvo escala.

Observación 4.24 (Farkas es la llave de KKT). En el capítulo 9 demostraremos las condiciones de Karush–Kuhn–Tucker para $\max f(x)$ sujeto a $g_i(x) \leq 0$. El paso central será: “en un óptimo x^* , no existe dirección d que mejore el objetivo ($\langle \nabla f(x^*), d \rangle > 0$) y mantenga la factibilidad de primer orden ($\langle \nabla g_i(x^*), d \rangle \leq 0$ para las restricciones activas)”. Esa no-existencia es exactamente

un sistema (II) sin solución con $b = \nabla f(x^*)$ y columnas $\nabla g_i(x^*)$... es decir, por Farkas, ¡el sistema (I) correspondiente tiene solución! Y la solución $x \geq 0$ de (I) son precisamente los *multiplicadores* $\lambda_i \geq 0$ con $\nabla f(x^*) = \sum_i \lambda_i \nabla g_i(x^*)$. En los problemas de contratos (principal-agente con restricciones IC e IR, MWG cap. 14), los multiplicadores de las restricciones IC que entrega Farkas/KKT miden cuánto “cuesta” en términos del objetivo la necesidad de incentivar: son precios sombra de la información. Ver [5] (cap. 12), [7], [4] y [8] para las versiones algorítmicas.

Teorema 4.25 (Alternativa de Gordan). *Sea $A \in \mathbb{R}^{m \times n}$ con filas $a_1^\top, \dots, a_m^\top$. Exactamente uno de los dos sistemas tiene solución:*

(I) $Ax < 0$ (todas las desigualdades estrictas; $x \in \mathbb{R}^n$);

(II) $A^\top y = 0, \quad y \geq 0, \quad y \neq 0 \quad (y \in \mathbb{R}^m)$.

Demostración. No ambos. Si $Ax < 0$ y $A^\top y = 0$ con $y \geq 0, y \neq 0$, entonces

$$0 = \langle A^\top y, x \rangle = \langle y, Ax \rangle = \sum_{i=1}^m y_i (Ax)_i < 0,$$

porque cada $(Ax)_i < 0$, cada $y_i \geq 0$ y al menos un $y_i > 0$ hace el sumando estrictamente negativo. Absurdo.

Si (I) falla, vale (II). Considera los dos convexos de $\mathbb{R}^m$

$$P = \{Ax : x \in \mathbb{R}^n\} \quad (\text{subespacio imagen, convexo}),$$

$$N = \{w \in \mathbb{R}^m : w < 0\} \quad (\text{ortante negativo abierto, convexo}).$$

Que (I) no tenga solución significa $P \cap N = \emptyset$. Por el Teorema 4.21 existe $y \neq 0$ con

$$\langle y, w \rangle \leq \langle y, Ax \rangle \quad \text{para todos } w \in N, x \in \mathbb{R}^n.$$

Primero, el lado derecho: la función $x \mapsto \langle y, Ax \rangle = \langle A^\top y, x \rangle$ es lineal y está acotada inferiormente sobre todo $\mathbb{R}^n$ (por la constante $\langle y, w_0 \rangle$, fijando cualquier $w_0 \in N$, por ejemplo $w_0 = -\mathbf{1}$); una función lineal acotada por abajo en un subespacio debe ser idénticamente nula sobre él (si $\langle A^\top y, x_0 \rangle \neq 0$ para algún x_0 , evaluando en tx_0 con $t \rightarrow \pm\infty$ la función toma valores arbitrariamente negativos). Concluimos $A^\top y = 0$. Segundo, el lado izquierdo: con $A^\top y = 0$ la desigualdad se lee $\langle y, w \rangle \leq 0$ para todo $w < 0$. Tomando $w = -e_i - \epsilon \mathbf{1}$ con $\epsilon \rightarrow 0^+$ (aquí $\mathbf{1}$ es el vector de unos, para mantener w estrictamente negativo) obtenemos en el límite $\langle y, -e_i \rangle \leq 0$, es decir $y_i \geq 0$, para cada i . Así $y \geq 0, y \neq 0$: (II) tiene solución. $\square$

Observación 4.26. Gordan es la alternativa “sin lado derecho” y es la que se usa para demostrar la condición de Fritz John (KKT sin cualificación de restricciones, [5]). En economía financiera, el teorema fundamental de valoración de activos es un Farkas: o existe una cartera de arbitraje, o existen precios de estado positivos (probabilidades riesgo-neutrales, salvo normalización) que valoran todos los activos; el vector $y \geq 0$ de la alternativa es literalmente el vector de precios de estado. La misma lógica de “separación $\Rightarrow$ pesos positivos que racionalizan decisiones” da la existencia de probabilidades subjetivas en los teoremas de utilidad esperada: las apuestas

aceptadas y rechazadas por un decisor coherente forman conos convexos disjuntos, y la normal separadora, normalizada para sumar uno, es su probabilidad subjetiva.

4.7. Aplicación estrella: el Segundo Teorema del Bienestar [P1]

Esta sección desarrolla en detalle la aplicación que da sentido económico a todo el capítulo: la *descentralización* de los óptimos de Pareto mediante precios. Seguimos la estructura de [9] (sección 16.D) y [10] (cap. 5), simplificando a una economía de intercambio puro para que cada paso matemático sea transparente.

4.7.1. El escenario: una economía de intercambio

Hay L bienes y I consumidores. Cada consumidor $i \in \{1, \dots, I\}$ tiene conjunto de consumo $X_i = \mathbb{R}_+^L$ y una relación de preferencias $\succsim_i$ sobre X_i que suponemos *racional* (completa y transitiva) y *continua*. Denotamos $x_i \succ_i x'_i$ la preferencia estricta. La dotación agregada de la economía es $\bar{\omega} \in \mathbb{R}_+^L$, $\bar{\omega} \neq 0$. Una *asignación* (allocation) es un vector $x = (x_1, \dots, x_I)$ con $x_i \in X_i$; es *factible* (feasible) si $\sum_{i=1}^I x_i \leq \bar{\omega}$ (con igualdad si se quiere agotamiento; trabajaremos con igualdad para simplificar).

Definición 4.27 (Óptimo de Pareto). Una asignación factible $x^* = (x_1^*, \dots, x_I^*)$ es un *óptimo de Pareto* (Pareto optimum) si no existe otra asignación factible x tal que $x_i \succsim_i x_i^*$ para todo i y $x_j \succ_j x_j^*$ para al menos un j . Es decir: no se puede mejorar a alguien sin empeorar a otro.

Definición 4.28 (Equilibrio con transferencias). Una asignación factible x^* junto con un vector de precios $p \in \mathbb{R}^L$, $p \neq 0$, constituye un *equilibrio con transferencias* (price equilibrium with transfers) si, dando a cada consumidor i la riqueza $w_i = \langle p, x_i^* \rangle$, cada x_i^* es *maximal* para $\succsim_i$ en el conjunto presupuestario $\{x_i \in X_i : \langle p, x_i \rangle \leq w_i\}$; equivalentemente,

$$x_i \succ_i x_i^* \implies \langle p, x_i \rangle > \langle p, x_i^* \rangle \quad \text{para todo } i :$$

todo lo estrictamente mejor es estrictamente más caro. Si solo se garantiza la implicación débil $x_i \succ_i x_i^* \implies \langle p, x_i \rangle \geq \langle p, x_i^* \rangle$ (lo mejor no es más barato), hablamos de un *cuasi-equilibrio con transferencias* (price quasi-equilibrium).

El Primer Teorema del Bienestar dice que (bajo no saciedad local) todo equilibrio es Pareto óptimo: el mercado no desperdicia. El *Segundo* Teorema es el recíproco, mucho más profundo: *todo* óptimo de Pareto puede sostenerse como equilibrio, eligiendo bien las transferencias de riqueza. Es el teorema que justifica separar la eficiencia de la distribución: si la sociedad prefiere otro punto de la frontera de Pareto, no necesita abolir el mercado, solo redistribuir riqueza y dejar que los precios hagan el resto. Y los precios que hacen el resto salen de un hiperplano separador.

Necesitamos dos hipótesis sobre las preferencias, ambas ya familiares del capítulo 2:

Definición 4.29. La preferencia $\succsim_i$ es *convexa* si el conjunto de mejora $\{x_i \in X_i : x_i \succsim_i \hat{x}_i\}$ es convexo para todo $\hat{x}_i$; es *localmente no saciada* (locally nonsatiated, LNS) si para todo $\hat{x}_i \in X_i$ y todo $\varepsilon > 0$ existe $x_i \in X_i$ con $\|x_i - \hat{x}_i\| < \varepsilon$ y $x_i \succ_i \hat{x}_i$: arbitrariamente cerca de cualquier cesta hay una estrictamente mejor.

4.7.2. El teorema y su demostración por separación

Teorema 4.30 (Segundo Teorema del Bienestar, versión de intercambio). *Supongamos que cada $\succsim_i$ es racional, continua, convexa y localmente no saciada. Sea x^* un óptimo de Pareto con $\sum_i x_i^* = \bar{\omega}$. Entonces existe $p \in \mathbb{R}^L$, $p \neq 0$, tal que (x^*, p) es un cuasi-equilibrio con transferencias:*

$$x_i \succ_i x_i^* \implies \langle p, x_i \rangle \geq \langle p, x_i^* \rangle \quad \text{para todo } i.$$

Si además cada consumidor tiene en su presupuesto una cesta estrictamente más barata que x_i^ (condición de punto más barato, cheaper point; por ejemplo, si $\langle p, x_i^* \rangle > 0$ para todo i), entonces (x^*, p) es un equilibrio con transferencias.*

Demostración. La demostración tiene cinco pasos; el corazón es el Paso 3, donde se separa.

Paso 1: construir el conjunto de “mejoras agregadas”. Para cada consumidor definimos el conjunto de cestas estrictamente preferidas a su asignación óptima:

$$V_i = \{x_i \in X_i : x_i \succ_i x_i^*\} \subseteq \mathbb{R}^L,$$

y sumamos (suma de Minkowski, capítulo 2):

$$V = V_1 + V_2 + \cdots + V_I = \left\{ \sum_i x_i : x_i \succ_i x_i^* \forall i \right\}.$$

V es el conjunto de *demandas agregadas de recursos* que permitirían darle a *cada* consumidor algo estrictamente mejor. Cada V_i es no vacío por LNS (cerca de x_i^* hay algo mejor), luego $V \neq \emptyset$.

Paso 2: V es convexo y no contiene a $\bar{\omega}$. *Convexidad:* probamos primero que cada V_i es convexo; aquí entra la convexidad de las preferencias, junto con la continuidad y la transitividad. Sean $x_i, x'_i \in V_i$ y $\lambda \in [0, 1]$; sin pérdida de generalidad $x'_i \succsim_i x_i$ (completitud). Entonces x_i y x'_i pertenecen ambos al conjunto de mejora $\{z : z \succsim_i x_i\}$, que es convexo por hipótesis, así que $\lambda x_i + (1 - \lambda)x'_i \succsim_i x_i \succ_i x_i^*$, y por transitividad (de la parte mixta $\succsim$ - $\succ$, que se deduce de racionalidad más continuidad) $\lambda x_i + (1 - \lambda)x'_i \succ_i x_i^*$: la combinación está en V_i . Luego V , suma de Minkowski de convexos, es convexo (capítulo 2). $\bar{\omega} \notin V$: si fuera $\bar{\omega} \in V$, existirían $x_i \succ_i x_i^*$ para *todos* los i con $\sum_i x_i = \bar{\omega}$: una asignación factible que mejora estrictamente a todos, contradiciendo que x^* es óptimo de Pareto. (Nota: la definición de Pareto prohíbe mejorar a *uno* sin dañar a otros; aquí solo hemos usado la versión débil (mejorar a todos), así que hasta este punto bastaría optimalidad de Pareto débil. La LNS convertirá después la conclusión en la correcta.)

Paso 3: separar. Tenemos un convexo no vacío V y un punto $\bar{\omega} \notin V$. El conjunto $\{\bar{\omega}\}$ es convexo, no vacío y disjunto de V ; por el teorema de separación de convexos disjuntos (Teorema 4.21) existe $p \neq 0$ tal que

$$\langle p, z \rangle \geq \langle p, \bar{\omega} \rangle \quad \text{para todo } z \in V. \quad (4.5)$$

(Orientamos la normal hacia V : las mejoras agregadas cuestan al menos tanto como la dotación.)

Este p es el vector de precios del enunciado: la normal del hiperplano separador. Observa

que no hemos necesitado que V sea cerrado ni acotado (no lo es), por eso fue importante demostrar la separación débil sin hipótesis topológicas.

Paso 4: de la desigualdad agregada a la individual. Queremos: si $x_j \succ_j x_j^*$ entonces $\langle p, x_j \rangle \geq \langle p, x_j^* \rangle$. Fijemos j y tal x_j . La dificultad: (4.5) habla de sumas $\sum_i x_i$ con *todos* mejorando, y nosotros solo tenemos mejorando a j . La solución es la no saciedad local: para $\varepsilon > 0$ y cada $i \neq j$, LNS produce $x_i^\varepsilon \in X_i$ con $\|x_i^\varepsilon - x_i^*\| < \varepsilon$ y $x_i^\varepsilon \succ_i x_i^*$. Entonces $x_j + \sum_{i \neq j} x_i^\varepsilon \in V$, y (4.5) da

$$\langle p, x_j \rangle + \sum_{i \neq j} \langle p, x_i^\varepsilon \rangle \geq \langle p, \bar{\omega} \rangle = \sum_{i=1}^I \langle p, x_i^* \rangle,$$

usando $\bar{\omega} = \sum_i x_i^*$ en la igualdad. Reordenando,

$$\langle p, x_j \rangle - \langle p, x_j^* \rangle \geq \sum_{i \neq j} \langle p, x_i^* - x_i^\varepsilon \rangle \geq - \sum_{i \neq j} \|p\| \|x_i^* - x_i^\varepsilon\| \geq -(I-1) \|p\| \varepsilon,$$

donde la segunda desigualdad es Cauchy–Schwarz. Haciendo $\varepsilon \rightarrow 0^+$ obtenemos $\langle p, x_j \rangle \geq \langle p, x_j^* \rangle$: exactamente la condición de cuasi-equilibrio. (De paso, tomando x_j cercano a x_j^* con $x_j \succ_j x_j^*$ (LNS de nuevo) y pasando al límite, se ve que x_j^* está en la clausura de V_j , y el hiperplano “soporta” al conjunto de mejora de cada consumidor en su cesta óptima: cada consumidor está en tangencia con la misma recta de precios.)

Paso 5: del cuasi-equilibrio al equilibrio. Supongamos que el consumidor i tiene un punto más barato: existe $x'_i \in X_i$ con $\langle p, x'_i \rangle < \langle p, x_i^* \rangle = w_i$. Afirmamos que entonces la implicación débil se vuelve estricta. Sea $x_i \succ_i x_i^*$ y supongamos, por contradicción, que $\langle p, x_i \rangle = w_i$ (por el Paso 4 no puede ser $<$; descartamos el $=$). Para $\lambda \in (0, 1)$ considera $x_i^\lambda = \lambda x_i + (1 - \lambda)x'_i$. Su costo es $\lambda \langle p, x_i \rangle + (1 - \lambda) \langle p, x'_i \rangle < w_i$: estrictamente más barato que w_i para todo $\lambda \in (0, 1)$. Por *continuidad* de $\succ_i$, el conjunto $\{z : z \succ_i x_i^*\}$ es abierto (relativo a X_i); como x_i le pertenece y $x_i^\lambda \rightarrow x_i$ cuando $\lambda \rightarrow 1^-$, para λ suficientemente cercano a 1 tenemos $x_i^\lambda \succ_i x_i^*$ y $\langle p, x_i^\lambda \rangle < w_i$. Pero eso contradice el Paso 4 (cuasi-equilibrio: lo mejor nunca es estrictamente más barato). Luego $\langle p, x_i \rangle > w_i$: equilibrio con transferencias para el consumidor i . Si todos tienen punto más barato (por ejemplo si $p \geq 0$, $p \neq 0$ y todo consumidor tiene riqueza positiva $w_i > 0$, pues entonces la cesta 0 o una reducción proporcional es más barata), el par (x^*, p) es un equilibrio con transferencias completo. Las transferencias que lo implementan son $T_i = w_i - \langle p, \omega_i \rangle$ si las dotaciones individuales originales eran ω_i : se redistribuye riqueza, no bienes. $\square$

Observación 4.31 (Signo de los precios). Si además las preferencias son *monótonas* (más es mejor), los precios separadores salen no negativos: $p \geq 0$. El argumento es de cono: por monotonía, $V + \mathbb{R}_+^L \subseteq V$ (si una canasta agregada permite mejorar a todos, añadir recursos también). Si algún $p_\ell < 0$, tomando $z \in V$ y sumando te_ℓ con $t \rightarrow +\infty$, el costo $\langle p, z + te_\ell \rangle = \langle p, z \rangle + tp_\ell \rightarrow -\infty$ violaría (4.5). El mismo argumento de “conos que fuerzan signos” que usamos en Farkas (Teorema 4.23).

4.7.3. ¿Qué compra cada hipótesis, y qué falla sin convexidad?

Hagamos la autopsia de la demostración, hipótesis por hipótesis:

- **Convexidad de preferencias** $\Rightarrow V$ convexo $\Rightarrow$ se puede separar. Sin ella el teorema es

falso: con preferencias no convexas, el conjunto de mejora de un consumidor puede tener una “bahía” no convexa, y la cesta óptima de Pareto puede estar en el fondo de la bahía. Cualquier recta de precios que pase por esa cesta *corta* el conjunto de mejora: a esos precios el consumidor puede comprar algo estrictamente mejor y no más caro, y la descentralización fracasa. Gráficamente: una curva de indiferencia con un tramo cóncavo no puede “apoyarse” en una recta presupuestaria por el lado correcto en los puntos del tramo cóncavo (Figura 4.3). El óptimo sigue siendo óptimo; lo que no existe es un *precio* que lo sostenga.

- **No saciedad local** entra dos veces: para que $V_i \neq \emptyset$ y, crucialmente, en el Paso 4, para “aislar” a un consumidor perturbando a los demás con mejoras arbitrariamente pequeñas. Sin LNS (piensa en un consumidor saciado en x_i^*), la desigualdad agregada no baja al nivel individual y pueden hacer falta precios distintos para consumidores distintos, lo que destruye la interpretación de mercado.
- **Continuidad** sostiene el Paso 5 (los conjuntos de preferencia estricta son abiertos) y el paso al límite del Paso 4.
- **El punto más barato** evita la trampa del cuasi-equilibrio: si en x_i^* el consumidor tiene riqueza mínima posible (por ejemplo $w_i = 0$ con $p \geq 0$ y $X_i = \mathbb{R}_+^L$), puede haber cestas mejores que cuestan exactamente lo mismo y el consumidor no maximiza de verdad. El ejemplo clásico de Arrow: en la frontera del ortante, cuasi-equilibrio sin equilibrio. En los exámenes de Microeconomía esta distinción cae con frecuencia ([9], sección 16.D, Ejemplo 16.D.3).




Figura 4.3: Izquierda: con preferencias convexas, la recta de precios soporta al conjunto de mejora en la cesta óptima (hiperplano soporte). Derecha: con un tramo no convexo, toda recta por la cesta marcada corta el conjunto de cestas estrictamente preferidas: no existe precio que descentralice ese punto.

Intuición

Vale la pena detenerse en la moraleja conceptual. El Segundo Teorema del Bienestar es, matemáticamente, *solo* el teorema del hiperplano separador aplicado al conjunto de mejoras agregadas. La frase “los precios son señales de escasez” se formaliza así: el hiperplano $\{z : \langle p, z \rangle = \langle p, \bar{w} \rangle\}$ pone del mismo lado todo lo que la economía *puede* pagar, y del otro todo lo que *querría* consumir para mejorar a todos; los precios son la normal que testifica que ambos deseos son incompatibles salvo en la frontera. Y como el hiperplano es *común* a todos los consumidores (la misma p para todos), la descentralización funciona:

cada agente, mirando solo p y su riqueza, reproduce por su cuenta el óptimo social. La convexidad es el precio de esta magia; con no convexidades (indivisibilidades, rendimientos crecientes), la separación falla y aparecen los problemas clásicos de fijación de precios con costos fijos. La misma matemática, con otra ropa, aparece en los *precios sombra* de KKT (Observación 4.24), en la dualidad lagrangiana (capítulo 10) y en los teoremas de representación de utilidad esperada.

4.8. Resumen del capítulo [P1]

Resumen del capítulo

- **Vocabulario.** $H(a, \beta) = \{x : \langle a, x \rangle = \beta\}$ con $a \neq 0$ (Definición 4.1); los semiespacios $H^-(a, \beta)$, $H^+(a, \beta)$ son convexos y cerrados, y la normal a puede normalizarse ($\|a\| = 1$) sin perder nada (Observación 4.2). La escala de fuerza, de menos a más exigente, es: separación a secas, propia, estricta, fuerte; cada una implica todas las anteriores, es decir, fuerte $\Rightarrow$ estricta $\Rightarrow$ propia $\Rightarrow$ separación (Definición 4.10). *Qué hipótesis compra qué fuerza* es la pregunta central del capítulo.

- **Teorema de proyección** (Teorema 4.6). *Hipótesis:* $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo; $x \in \mathbb{R}^n$ arbitrario. *Conclusión:* existe (Weierstrass + cerradura) y es único (convexidad) el punto $\text{proy}_C(x)$ que minimiza $\|x - y\|$ sobre C , caracterizado por la desigualdad variacional

$$\langle x - \text{proy}_C(x), y - \text{proy}_C(x) \rangle \leq 0 \quad \text{para todo } y \in C$$

y con la cota tipo Pitágoras $\|x - y\|^2 \geq \|x - \text{proy}_C(x)\|^2 + \|y - \text{proy}_C(x)\|^2$ (4.2). Además proy_C es *no expansiva* (1-Lipschitz, luego continua), Proposición 4.8. Quitar cerradura mata la existencia; quitar convexidad mata la unicidad.

- **Separación fuerte punto-convexo** (Teorema 4.11). *Hipótesis:* C no vacío, cerrado y convexo, $x \notin C$. *Conclusión:* con $a = x - \text{proy}_C(x) \neq 0$ y $\beta = \langle a, \text{proy}_C(x) \rangle + \frac{1}{2} \|a\|^2$,

$$\sup_{y \in C} \langle a, y \rangle < \beta < \langle a, x \rangle,$$

separación *fuerte* con holgura $\frac{1}{2} \|a\|^2$ a cada lado. Sin cerradura (bola abierta y un punto de su frontera) solo hay separación no estricta; sin convexidad (circunferencia y su centro) no hay ninguna. Corolario: todo convexo cerrado no vacío es la *intersección de los semiespacios cerrados que lo contienen* (Corolario 4.12): descripción externa = descripción interna, el germen de la dualidad.

- **Hiperplano soporte** (Teorema 4.15). *Hipótesis:* C convexo y no vacío (no se pide cerrado ni acotado) y $x_0 \in \text{fr } C$. *Conclusión:* existe $a \neq 0$ con $\langle a, y \rangle \leq \langle a, x_0 \rangle$ para todo $y \in C$; equivalentemente $x_0 \in \arg \max_{y \in C} \langle a, y \rangle$. La separación es forzosamente *no estricta* (Observación 4.16): el hiperplano toca al conjunto. Técnica de demostración a memorizar: aproximar por puntos exteriores, separar cada uno, *normalizar* las normales

y usar Bolzano–Weierstrass en la esfera unitaria. El soporte es único en puntos “suaves” y múltiple en esquinas (Ejemplo 4.17), que es la semilla del subdiferencial (capítulo 7).

- **Separación de dos convexos: dos versiones, dos precios.** (i) *Fuerte* (Teorema 4.19): A, B convexos, no vacíos, *disjuntos*, con A **compacto** y B **cerrado** $\Rightarrow \sup_A \langle a, \cdot \rangle < \inf_B \langle a, \cdot \rangle$. La compacidad se usa para que $B - A$ sea cerrado (Lema 4.18); con *dos cerrados* no basta: el epígrafo de $1/x_1$ y el semiplano $\{x_2 \leq 0\}$ son cerrados, convexos y disjuntos pero están a distancia cero (Ejercicio 4.34). (ii) *Débil* (Teorema 4.21): A, B convexos, no vacíos y disjuntos, **sin ninguna hipótesis topológica** $\Rightarrow$ existe $a \neq 0$ con $\sup_A \langle a, \cdot \rangle \leq \inf_B \langle a, \cdot \rangle$. (iii) *Versión fina* (Observación 4.22): A, B convexos no vacíos admiten separación *propia* si y solo si $\text{ri } A \cap \text{ri } B = \emptyset$: no hace falta que sean disjuntos, solo que no se solapen en sus interiores relativos. Si además uno de ellos es *abierto*, la separación es estricta de ese lado.
- **Lema de Farkas** (Teorema 4.23). *Hipótesis*: $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, ninguna otra (la hipótesis escondida es un teorema que aquí admitimos sin demostrar: el cono finitamente generado $K = \{Ax : x \geq 0\}$ es *cerrado*, en la línea de Weyl–Minkowski). *Conclusión*: exactamente uno de los sistemas tiene solución,

$$(I) \ Ax = b, \ x \geq 0 \quad \text{o} \quad (II) \ A^\top y \leq 0, \ \langle b, y \rangle > 0.$$

El y de (II) es el *certificado* de infactibilidad: la normal de un hiperplano por el origen que deja el cono de un lado y b del otro. Variante homogénea: **alternativa de Gordan** (Teorema 4.25): o $Ax < 0$ tiene solución, o existe $y \geq 0$, $y \neq 0$, con $A^\top y = 0$. Farkas es la llave de KKT (Observación 4.24) y del teorema fundamental de valoración de activos.

- **Segundo Teorema del Bienestar** (Teorema 4.30). *Hipótesis*: economía de intercambio con $X_i = \mathbb{R}_+^L$; cada $\succsim_i$ *racional, continua, convexa y localmente no saciada*; x^* óptimo de Pareto con $\sum_i x_i^* = \bar{\omega}$. *Conclusión*: existe $p \neq 0$ tal que (x^*, p) es *cuasi-equilibrio* con transferencias ($x_i \succsim_i x_i^* \Rightarrow \langle p, x_i \rangle \geq \langle p, x_i^* \rangle$); si además cada consumidor tiene un *punto más barato* en su presupuesto (por ejemplo $\langle p, x_i^* \rangle > 0$), es equilibrio con transferencias (implicación estricta). *Papel de cada hipótesis*: la **convexidad** hace convexo al conjunto de mejoras agregadas $V = \sum_i V_i$ y es lo único que permite separar pues sin ella el teorema es falso, no solo indemostrable (Figura 4.3); la **no saciedad local** garantiza $V_i \neq \emptyset$ y permite bajar de la desigualdad agregada a la individual perturbando a los demás consumidores; la **continuidad** da el paso del cuasi-equilibrio al equilibrio; la **monotonía** (si se añade) da $p \geq 0$ (Observación 4.31). Los precios *son* la normal del hiperplano que separa V de $\bar{\omega}$: no son un dato, son un teorema.

4.9. Ejercicios resueltos [P1]

Ejercicio 4.32 (Proyecciones explícitas y verificación variacional). Calcula, en $\mathbb{R}^2$, la proyección del punto $x = (3, 3)$ sobre cada uno de los siguientes conjuntos, y verifica en cada caso la caracterización variacional (4.1):

- (a) el semiespacio $S = \{y \in \mathbb{R}^2 : y_1 + 2y_2 \leq 4\}$;
- (b) el hiperplano $H = \{y \in \mathbb{R}^2 : y_1 + 2y_2 = 4\}$;
- (c) la bola cerrada $\bar{B}(0, 2) = \{y : \|y\| \leq 2\}$.

Deduce además la fórmula general de la distancia de un punto a un hiperplano.

Solución. (a) *Semiespacio.* Escribimos $a = (1, 2)$, $\beta = 4$, de modo que $S = H^-(a, \beta)$; nota $\|a\|^2 = 1^2 + 2^2 = 5$. Primero verificamos que $x \notin S$: $\langle a, x \rangle = 3 + 6 = 9 > 4 = \beta$. *Candidato:* bajamos desde x en la dirección $-a$ (la única dirección en la que la función lineal $\langle a, \cdot \rangle$ decrece más rápido) justo lo necesario para llegar al borde. Buscamos $t \geq 0$ con $\langle a, x - ta \rangle = \beta$, es decir $\langle a, x \rangle - t\|a\|^2 = \beta$, o sea

$$t = \frac{\langle a, x \rangle - \beta}{\|a\|^2} = \frac{9 - 4}{5} = 1, \quad z = x - ta = (3, 3) - (1, 2) = (2, 1).$$

Verificación: $z \in S$ porque $\langle a, z \rangle = 2 + 2 = 4 \leq 4$. Y para cualquier $y \in S$,

$$\langle x - z, y - z \rangle = \langle ta, y - z \rangle = t(\langle a, y \rangle - \langle a, z \rangle) = 1 \cdot (\underbrace{\langle a, y \rangle}_{\leq 4} - 4) \leq 0.$$

La condición (4.1) se cumple, y por la unicidad del Teorema 4.6, $\text{proy}_S(x) = (2, 1)$. La distancia es $\|x - z\| = \|(1, 2)\| = \sqrt{5}$. En general, para $\langle a, x \rangle > \beta$,

$$\text{proy}_{H^-(a, \beta)}(x) = x - \frac{\langle a, x \rangle - \beta}{\|a\|^2} a, \quad d(x, H^-(a, \beta)) = \frac{\langle a, x \rangle - \beta}{\|a\|},$$

y $\text{proy}_{H^-(a, \beta)}(x) = x$ cuando $\langle a, x \rangle \leq \beta$ (el punto ya está en el conjunto, la distancia mínima es cero y se alcanza en él mismo).

(b) *Hiperplano.* El mismo cálculo sirve, con una diferencia importante en la verificación. El candidato es de nuevo $z = (2, 1)$, que ahora cumple $\langle a, z \rangle = 4$ con igualdad, luego $z \in H$. Para $y \in H$ se tiene $\langle a, y \rangle = 4$ exactamente, así que

$$\langle x - z, y - z \rangle = t(\langle a, y \rangle - \langle a, z \rangle) = 1 \cdot (4 - 4) = 0 \quad \text{para todo } y \in H.$$

Se cumple (4.1) (con igualdad), luego $\text{proy}_H(x) = (2, 1)$. La igualdad no es casual: cuando C es un conjunto *afín*, el vector $y - z$ recorre todo el subespacio director y puede tomarse en las dos direcciones $\pm v$; la desigualdad $\langle x - z, v \rangle \leq 0$ y $\langle x - z, -v \rangle \leq 0$ obligan a $\langle x - z, v \rangle = 0$. Es decir, para conjuntos afines la caracterización variacional se convierte en la *ortogonalidad* clásica: el residuo es perpendicular al conjunto. De la fórmula general se lee la conocida distancia punto–hiperplano

$$d(x, H(a, \beta)) = \frac{|\langle a, x \rangle - \beta|}{\|a\|} \quad \left(\text{aquí } \frac{|9 - 4|}{\sqrt{5}} = \sqrt{5}\right),$$

válida ahora en ambos sentidos (por eso el valor absoluto: al hiperplano se puede llegar desde cualquiera de los dos lados, mientras que al semiespacio solo se “cae” desde fuera).

(c) *Bola.* Como $\|x\| = \|(3, 3)\| = 3\sqrt{2} > 2$, el punto está fuera y el candidato natural es el

punto de la esfera en la dirección de x :

$$z = 2 \frac{x}{\|x\|} = \frac{2}{3\sqrt{2}}(3, 3) = (\sqrt{2}, \sqrt{2}), \quad \|z\| = \sqrt{2+2} = 2 \text{ (está en el borde).}$$

Verificación: $x - z = (3 - \sqrt{2})(1, 1)$ con $3 - \sqrt{2} > 0$, y para $y \in \bar{B}(0, 2)$,

$$\langle x - z, y - z \rangle = (3 - \sqrt{2})(\langle (1, 1), y \rangle - \langle (1, 1), z \rangle) = (3 - \sqrt{2})(y_1 + y_2 - 2\sqrt{2}).$$

Por Cauchy-Schwarz, $y_1 + y_2 = \langle (1, 1), y \rangle \leq \|(1, 1)\| \|y\| \leq \sqrt{2} \cdot 2 = 2\sqrt{2}$, así que el paréntesis es ≤ 0 y el producto también: (4.1) se cumple y $\text{proy}_{\bar{B}(0,2)}(x) = (\sqrt{2}, \sqrt{2})$, a distancia $\|x - z\| = (3 - \sqrt{2})\sqrt{2} = 3\sqrt{2} - 2$. (Coherente con el Ejemplo 4.7: $\|x\| - r = 3\sqrt{2} - 2$.) Para una bola centrada en c , la misma cuenta trasladada da $\text{proy}_{\bar{B}(c,r)}(x) = c + r(x - c) / \|x - c\|$ cuando $\|x - c\| > r$.

Moraleja operativa. En los tres casos el método fue el mismo: (1) adivinar el candidato con geometría; (2) comprobar que pertenece al conjunto; (3) verificar (4.1); (4) invocar la unicidad. Nunca hace falta resolver el problema de minimización. $\square$

Ejercicio 4.33 (Construcción explícita de un hiperplano separador). Sea el poliedro

$$P = \{y \in \mathbb{R}^2 : y_1 + 2y_2 \geq 4, \ y_1 \geq 0, \ y_2 \geq 0\}.$$

- (a) Comprueba que P es convexo, cerrado y no vacío. Para $x = (1, 0)$, verifica que $x \notin P$, calcula $\text{proy}_P(x)$ y construye explícitamente el hiperplano que separa fuertemente x de P siguiendo la receta del Teorema 4.11.
- (b) Repite el ejercicio con $x' = (-3, -1)$, donde la proyección cae en una *cara* distinta del poliedro.

Solución. *Estructura de P .* P es la intersección de tres semiespacios cerrados: $\{y : \langle (1, 2), y \rangle \geq 4\} = H^+((1, 2), 4)$, $\{y : y_1 \geq 0\}$ y $\{y : y_2 \geq 0\}$. Cada semiespacio es convexo y cerrado (Observación 4.5), y la intersección de convexos cerrados es convexa y cerrada; $P \neq \emptyset$ porque, por ejemplo, $(4, 0) \in P$. (No es acotado: contiene la semirrecta $\{(4+s, 0) : s \geq 0\}$. La compacidad no hace falta: el Teorema 4.11 solo pide cerrado y convexo.)

(a) *El punto $x = (1, 0)$.* No pertenece a P : $\langle (1, 2), x \rangle = 1 + 0 = 1 < 4$. *Candidato a proyección:* el conjunto es un poliedro, así que la proyección está en su frontera; empezamos ignorando las restricciones de signo y proyectando sobre la recta $L = \{y : y_1 + 2y_2 = 4\}$ con la fórmula del ejercicio anterior. Con $a = (1, 2)$, $\|a\|^2 = 5$:

$$z = x - \frac{\langle a, x \rangle - 4}{\|a\|^2} a = (1, 0) - \frac{1 - 4}{5}(1, 2) = (1, 0) + \frac{3}{5}(1, 2) = \left(\frac{8}{5}, \frac{6}{5}\right).$$

¿Es válido? Hay que comprobar que este z satisface también las restricciones que habíamos ignorado: $z_1 = 8/5 \geq 0$ y $z_2 = 6/5 \geq 0$, y $\langle a, z \rangle = 8/5 + 12/5 = 4$. Sí: $z \in P$. *Verificación variacional (esto es lo que legitima el atajo):* para todo $y \in P$ se tiene $\langle a, y \rangle \geq 4 = \langle a, z \rangle$, y como

$$x - z = -\frac{3}{5}(1, 2) = -\frac{3}{5}a,$$

resulta

$$\langle x - z, y - z \rangle = -\frac{3}{5}(\langle a, y \rangle - \langle a, z \rangle) = -\frac{3}{5}(\underbrace{\langle a, y \rangle - 4}_{\geq 0}) \leq 0.$$

Luego $\text{proy}_P(x) = (8/5, 6/5)$, con distancia $\|x - z\| = \frac{3}{5}\|(1, 2)\| = \frac{3\sqrt{5}}{5} = \frac{3}{\sqrt{5}}$.

El hiperplano. La receta del Teorema 4.11 (pensando el teorema con el papel del “conjunto” jugado por P y el “punto” por x) da la normal

$$\tilde{a} = x - \text{proy}_P(x) = -\frac{3}{5}(1, 2), \quad \|\tilde{a}\|^2 = \frac{9}{25} \cdot 5 = \frac{9}{5},$$

y el nivel $\tilde{\beta} = \langle \tilde{a}, z \rangle + \frac{1}{2}\|\tilde{a}\|^2 = -\frac{3}{5} \cdot 4 + \frac{9}{10} = -\frac{12}{5} + \frac{9}{10} = -\frac{3}{2}$. Comprobación de la cadena de separación fuerte: para $y \in P$, $\langle \tilde{a}, y \rangle = -\frac{3}{5}\langle a, y \rangle \leq -\frac{12}{5} = -2.4$, mientras que $\langle \tilde{a}, x \rangle = -\frac{3}{5} \cdot 1 = -0.6$; en efecto

$$-2.4 < -1.5 < -0.6.$$

Como la normal está definida salvo escala positiva (Observación 4.2), conviene reescalar multiplicando por $-5/3 < 0$ y *voltear las desigualdades*, o equivalentemente presentar el resultado con la normal orientada hacia P : con $p = (1, 2)$ y $\beta = 5/2$,

$$\langle p, x \rangle = 1 < \frac{5}{2} < 4 \leq \langle p, y \rangle \quad \text{para todo } y \in P.$$

El hiperplano separador es la recta $\{y : y_1 + 2y_2 = 5/2\}$, paralela a la cara activa del poliedro y colocada a mitad de camino. Es separación *fuerte*: el valor de $\langle p, \cdot \rangle$ en x es 1 y su ínfimo sobre P es 4, con una holgura de $3/2$ a cada lado del nivel elegido.

(b) *El punto* $x' = (-3, -1)$. Ahora el atajo falla: proyectando sobre la recta L ,

$$\hat{z} = x' - \frac{\langle a, x' \rangle - 4}{5} a = (-3, -1) - \frac{-5 - 4}{5}(1, 2) = (-3, -1) + \frac{9}{5}(1, 2) = \left(-\frac{6}{5}, \frac{13}{5}\right),$$

que tiene primera coordenada negativa: $\hat{z} \notin P$. Esto indica que el mínimo sobre P se alcanza en otra cara, la semirrecta vertical $F = \{(0, y_2) : y_2 \geq 2\}$ (parte de la frontera $y_1 = 0$ que sobrevive a la restricción $y_1 + 2y_2 \geq 4$, es decir $y_2 \geq 2$). Proyectar sobre F es fácil: el punto de F más cercano a $(-3, -1)$ tiene primera coordenada 0 y segunda coordenada igual a -1 truncado al intervalo permitido $[2, \infty)$, es decir 2. Candidato: $z' = (0, 2)$.

Verificación variacional (la que decide de verdad). Tenemos $x' - z' = (-3, -1) - (0, 2) = (-3, -3)$. Para $y \in P$:

$$\langle x' - z', y - z' \rangle = -3(y_1 - 0) - 3(y_2 - 2) = -3(y_1 + y_2 - 2).$$

Hay que ver que $y_1 + y_2 \geq 2$ en todo P . Sea $y \in P$. Si $y_2 \geq 2$, entonces $y_1 + y_2 \geq 0 + 2 = 2$. Si $y_2 < 2$, la restricción $y_1 \geq 4 - 2y_2$ da $y_1 + y_2 \geq 4 - 2y_2 + y_2 = 4 - y_2 > 4 - 2 = 2$. En ambos casos $y_1 + y_2 \geq 2$, luego $\langle x' - z', y - z' \rangle \leq 0$ y, por unicidad, $\text{proy}_P(x') = (0, 2)$: la proyección es el vértice del poliedro. La distancia es $\|(-3, -3)\| = 3\sqrt{2}$.

El hiperplano. Normal $\tilde{a}' = x' - z' = (-3, -3)$, o tras reescalar y orientar hacia P , $p' = (1, 1) = -\frac{1}{3}\tilde{a}'$. El nivel que da el teorema es $\tilde{\beta}' = \langle \tilde{a}', z' \rangle + \frac{1}{2}\|\tilde{a}'\|^2 = -6 + 9 = 3$, y la cadena es $\langle \tilde{a}', y \rangle \leq -6 < 3 < 12 = \langle \tilde{a}', x' \rangle$. Al dividir entre -3 (número negativo) las desigualdades se

voltean y el nivel pasa a ser $\beta' = 3/(-3) = -1$; con $p' = (1, 1)$ tenemos entonces $\langle p', y \rangle \geq 2$ para todo $y \in P$ (lo acabamos de probar) y $\langle p', x' \rangle = -4$, es decir

$$\langle p', x' \rangle = -4 < -1 < 2 \leq \langle p', y \rangle \quad \text{para todo } y \in P.$$

Comentario. Fíjate en el fenómeno: al variar el punto exterior, la normal separadora salta de $(1, 2)$ (paralela a una cara) a $(1, 1)$ (una de las infinitas normales soporte del vértice $(0, 2)$). Es la multiplicidad de hiperplanos soporte en las esquinas del Ejemplo 4.17(b): en un vértice hay un *abanico* de precios que lo sostienen, y cuál de ellos aparece depende de desde dónde mires. En programación lineal (capítulo 13) ese abanico es el conjunto de soluciones duales óptimas. $\square$

Ejercicio 4.34 (Cuando la separación fuerte es imposible; y cuando es gratis la estricta). (a) Sean

$$A = \{u \in \mathbb{R}^2 : u_2 \leq 0\}, \quad B = \{v \in \mathbb{R}^2 : v_1 > 0, v_2 \geq 1/v_1\}.$$

Demuestra que A y B son convexos, cerrados, no vacíos y disjuntos, pero que *no* admiten separación fuerte (ni siquiera estricta); identifica el único hiperplano que los separa y explica exactamente qué hipótesis del Teorema 4.19 falla y dónde se rompe la demostración.

- (b) Demuestra la afirmación de la Observación 4.22: si A y B son convexos no vacíos y disjuntos y *además* A es abierto, entonces la separación del Teorema 4.21 es estricta del lado de A : $\langle a, u \rangle < \beta$ para todo $u \in A$, con $\beta = \sup_A \langle a, \cdot \rangle$.

Solución. (a1) A es convexo y cerrado. Es el semiespacio $H^-((0, 1), 0)$, luego convexo y cerrado (Observación 4.5); contiene a $(0, 0)$.

(a2) B es convexo. B es el epígrafo de la función $f(t) = 1/t$ sobre $t > 0$. Sean $u, v \in B$ y $\lambda \in [0, 1]$, y sea $w = \lambda u + (1 - \lambda)v$. Primero, $w_1 = \lambda u_1 + (1 - \lambda)v_1 > 0$ (combinación de positivos con pesos no ambos nulos). Segundo, usamos que $f(t) = 1/t$ es convexa en $(0, \infty)$: como $f''(t) = 2/t^3 > 0$, se cumple $f(\lambda u_1 + (1 - \lambda)v_1) \leq \lambda f(u_1) + (1 - \lambda)f(v_1)$. Entonces

$$w_2 = \lambda u_2 + (1 - \lambda)v_2 \geq \lambda \frac{1}{u_1} + (1 - \lambda) \frac{1}{v_1} \geq \frac{1}{\lambda u_1 + (1 - \lambda)v_1} = \frac{1}{w_1},$$

donde la primera desigualdad usa $u, v \in B$ y la segunda es la convexidad de $1/t$. Luego $w \in B$.

(a3) B es cerrado. Sea $v^{(k)} \in B$ con $v^{(k)} \rightarrow v$. Como $v_1^{(k)} > 0$, en el límite $v_1 \geq 0$. Si fuera $v_1 = 0$, entonces $v_2^{(k)} \geq 1/v_1^{(k)} \rightarrow +\infty$, contradiciendo que $v_2^{(k)} \rightarrow v_2 \in \mathbb{R}$ (una sucesión convergente es acotada). Luego $v_1 > 0$, y pasando al límite en $v_2^{(k)} \geq 1/v_1^{(k)}$ (la función $t \mapsto 1/t$ es continua en $v_1 > 0$) obtenemos $v_2 \geq 1/v_1$. Así $v \in B$ y B es cerrado.

(a4) Son disjuntos. Si $v \in B$ entonces $v_2 \geq 1/v_1 > 0$, mientras que todo $u \in A$ tiene $u_2 \leq 0$. Ningún punto cumple ambas cosas.

(a5) La distancia entre ellos es cero. Para cada $t > 0$, el punto $v^t = (t, 1/t)$ está en B y el punto $u^t = (t, 0)$ está en A , y $\|v^t - u^t\| = 1/t \rightarrow 0$ cuando $t \rightarrow \infty$. Por tanto $\inf\{\|u - v\| : u \in A, v \in B\} = 0$ aunque el ínfimo no se alcanza (los conjuntos son disjuntos). *Esto ya impide la separación fuerte:* si existieran $a \neq 0$ y $\varepsilon > 0$ con $\langle a, u \rangle \leq \beta - \varepsilon$ y $\langle a, v \rangle \geq \beta + \varepsilon$, entonces para

todos $u \in A$, $v \in B$,

$$2\varepsilon \leq \langle a, v - u \rangle \leq \|a\| \|v - u\| \implies \|v - u\| \geq \frac{2\varepsilon}{\|a\|} > 0,$$

(Cauchy–Schwarz), contradiciendo que la distancia es cero. La separación fuerte *siempre* implica distancia positiva; ese es su contenido geométrico.

(a6) *El único hiperplano separador, y por qué la separación no es siquiera estricta.* Supongamos que $H(a, \beta)$ separa: $\langle a, u \rangle \leq \beta \leq \langle a, v \rangle$ para $u \in A$, $v \in B$. Primero, $a_1 = 0$: los puntos $(s, 0)$ pertenecen a A para todo $s \in \mathbb{R}$, luego $a_1 s \leq \beta$ para todo $s \in \mathbb{R}$, lo que solo es posible si $a_1 = 0$ (si $a_1 \neq 0$, tomando s del mismo signo que a_1 y grande, el lado izquierdo supera cualquier β). Segundo, $a_2 > 0$: como $a \neq 0$, queda $a_2 \neq 0$; los puntos $(0, u_2)$ con $u_2 \leq 0$ están en A , y $a_2 u_2 \leq \beta$ para todo $u_2 \leq 0$ obliga a $a_2 > 0$ (si $a_2 < 0$, con $u_2 \rightarrow -\infty$ el producto $a_2 u_2 \rightarrow +\infty$). Tercero, $\beta = 0$: de A obtenemos $\beta \geq \sup_{u \in A} a_2 u_2 = 0$ (el supremo se alcanza en $u_2 = 0$); de B obtenemos $\beta \leq \inf_{v \in B} a_2 v_2 = a_2 \inf_{v \in B} v_2 = 0$, porque $v_2 = 1/t$ puede hacerse arbitrariamente pequeño y positivo (ínfimo 0, no alcanzado). Luego $\beta = 0$ y, salvo escala positiva, $a = (0, 1)$: el único hiperplano separador es el eje horizontal $\{x_2 = 0\}$. Y la separación *no es estricta* porque el punto $(0, 0) \in A$ cumple $\langle a, (0, 0) \rangle = 0 = \beta$: hay contacto con el hiperplano por el lado de A .

(a7) *Qué hipótesis falla.* En el Teorema 4.19 se pide que *uno de los dos conjuntos sea compacto*; aquí ambos son cerrados pero *ninguno es acotado*. El lugar exacto donde se rompe la demostración es el Lema 4.18: sin compacidad, el conjunto diferencia $D = B - A$ puede no ser cerrado. En efecto,

$$(t, 1/t) - (t, 0) = (0, 1/t) \in D \quad \text{para todo } t > 0, \quad (0, 1/t) \rightarrow (0, 0),$$

así que $0 \in \text{cl } D$ aunque $0 \notin D$ (por disjunción). Estamos exactamente en el “Caso 2” de la demostración del Teorema 4.21: el origen es un punto *frontera* de D , y lo único que se puede invocar es el hiperplano soporte, que da separación no estricta. Todo encaja: el teorema débil sí se aplica (dos convexos disjuntos siempre se separan) y entrega precisamente el eje horizontal.

(b) *Con un conjunto abierto la separación se vuelve estricta de ese lado.* Por el Teorema 4.21 existe $a \neq 0$ con $\langle a, u \rangle \leq \langle a, v \rangle$ para todos $u \in A$, $v \in B$; sea $\beta = \sup_{u \in A} \langle a, u \rangle$, que es finito (está acotado por $\langle a, v_0 \rangle$ para cualquier $v_0 \in B$ fijo). Supongamos, por contradicción, que existe $u_0 \in A$ con $\langle a, u_0 \rangle = \beta$. Como A es abierto, hay $\varepsilon > 0$ con $B(u_0, \varepsilon) \subseteq A$. Consideremos el punto

$$u_* = u_0 + \frac{\varepsilon}{2} \frac{a}{\|a\|}, \quad \|u_* - u_0\| = \frac{\varepsilon}{2} < \varepsilon \implies u_* \in A.$$

Pero entonces

$$\langle a, u_* \rangle = \langle a, u_0 \rangle + \frac{\varepsilon}{2} \frac{\langle a, a \rangle}{\|a\|} = \beta + \frac{\varepsilon}{2} \|a\| > \beta,$$

lo que contradice que β sea el supremo de $\langle a, \cdot \rangle$ sobre A . Por tanto ningún punto de A alcanza el nivel β : $\langle a, u \rangle < \beta \leq \langle a, v \rangle$ para todos $u \in A$, $v \in B$.

Lectura. El truco es siempre el mismo: *en un abierto se puede caminar un poco en la dirección a* , y caminar en la dirección de la normal aumenta estrictamente la función lineal. Por eso los conjuntos con interior no vacío (conjuntos de mejora estricta de preferencias continuas, por ejemplo) dan separaciones más fuertes, y por eso en el Segundo Teorema del Bienestar la

continuidad de las preferencias (que hace *abiertos* los conjuntos $\{z \succ_i x_i^*\}$) es la que permite el salto del cuasi-equilibrio al equilibrio. $\square$

Ejercicio 4.35 (Farkas: certificado numérico y la alternativa para desigualdades). (a) Sean

$$A = \begin{pmatrix} 1 & -1 & 2 \\ 1 & 1 & 0 \end{pmatrix}, \quad b = \begin{pmatrix} -2 \\ 1 \end{pmatrix}.$$

Demuestra que el sistema $Ax = b$, $x \geq 0$, no tiene solución exhibiendo un *certificado* y del sistema (II) del lema de Farkas (Teorema 4.23), y explica cómo ese y “es” la combinación lineal de ecuaciones que revela la imposibilidad.

(b) Usando el lema de Farkas, demuestra la siguiente alternativa para sistemas de *desigualdades* (teorema de Gale): dados $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, exactamente uno de los sistemas tiene solución:

$$(I') \quad Ax \leq b \quad (x \in \mathbb{R}^n \text{ libre}) \quad \text{o} \quad (II') \quad A^\top w = 0, \quad w \geq 0, \quad \langle b, w \rangle < 0 \quad (w \in \mathbb{R}^m).$$

Solución. (a) *Búsqueda del certificado.* Las columnas de A son $A_1 = (1, 1)$, $A_2 = (-1, 1)$ y $A_3 = (2, 0)$, y el sistema (I) pregunta si $b = (-2, 1)$ pertenece al cono $K = \text{cono}\{A_1, A_2, A_3\}$. Un vistazo geométrico: las combinaciones no negativas de $(1, 1)$ y $(-1, 1)$ llenan el semiplano superior $\{y_2 \geq 0\}$ “inclinado” hacia arriba, y añadir $(2, 0)$ empuja hacia la derecha; en concreto se comprueba que $K = \{y : y_2 \geq 0, y_1 + y_2 \geq 0\}$. Como $b_1 + b_2 = -2 + 1 = -1 < 0$, el punto b está fuera de K , y la desigualdad violada, $y_1 + y_2 \geq 0$, sugiere la normal.

Buscamos y con $A^\top y \leq 0$ y $\langle b, y \rangle > 0$. La condición $A^\top y \leq 0$ significa $\langle A_j, y \rangle \leq 0$ para cada columna:

$$y_1 + y_2 \leq 0, \quad -y_1 + y_2 \leq 0, \quad 2y_1 \leq 0.$$

El vector $y = (-1, -1)$ los cumple los tres: $-2 \leq 0$, $1 - 1 = 0 \leq 0$, $-2 \leq 0$. Y además

$$\langle b, y \rangle = (-2)(-1) + (1)(-1) = 2 - 1 = 1 > 0.$$

Luego $y = (-1, -1)$ resuelve (II) y, por el lema de Farkas, (I) no tiene solución.

Lectura del certificado como combinación de ecuaciones. El sistema (I) escrito por filas es

$$(\text{fila } 1) \quad x_1 - x_2 + 2x_3 = -2, \quad (\text{fila } 2) \quad x_1 + x_2 = 1.$$

Multiplicar la fila i por y_i y sumar es exactamente calcular $\langle y, Ax \rangle = \langle A^\top y, x \rangle$ frente a $\langle y, b \rangle$. Con $y = (-1, -1)$: $(-1) \times (\text{fila } 1) + (-1) \times (\text{fila } 2)$ da

$$-2x_1 - 2x_3 = 2 - 1 = 1 \quad \Longleftrightarrow \quad x_1 + x_3 = -\frac{1}{2}.$$

Pero $x \geq 0$ obliga a $x_1 + x_3 \geq 0$: contradicción. El certificado y es, literalmente, *la receta de qué combinación de ecuaciones hay que tomar* para que el lado izquierdo quede con coeficientes ≤ 0 (eso es $A^\top y \leq 0$) mientras el lado derecho queda > 0 (eso es $\langle b, y \rangle > 0$). Verificar una infactibilidad se vuelve así una comprobación aritmética de tres desigualdades, sin necesidad de

recorrer los infinitos $x \geq 0$: ese es el valor práctico de una alternativa. Geométricamente, y es la normal del hiperplano $\{z : \langle y, z \rangle = 0\}$, que deja todo el cono K en el semiespacio $\langle y, \cdot \rangle \leq 0$ y a b estrictamente del otro lado.

(b) *De Farkas a Gale*. La idea es reescribir (I') como un sistema en *forma estándar* (igualdades y variables no negativas) y aplicar Farkas a la matriz ampliada.

Paso 1: reescritura. Todo $x \in \mathbb{R}^n$ se descompone como $x = x^+ - x^-$ con $x^+, x^- \geq 0$ (por ejemplo $x_i^+ = \max\{x_i, 0\}$, $x_i^- = \max\{-x_i, 0\}$), y recíprocamente cualquier par $x^+, x^- \geq 0$ define un x libre. Además $Ax \leq b$ equivale a que exista una *holgura* $s \geq 0$ con $Ax + s = b$ (basta $s = b - Ax \geq 0$). Por tanto

$$(I') \text{ tiene solución} \iff \exists \bar{x} = (x^+, x^-, s) \geq 0 : \tilde{A}\bar{x} = b, \quad \tilde{A} = [A \quad -A \quad I_m] \in \mathbb{R}^{m \times (2n+m)}.$$

El sistema de la derecha es exactamente el sistema (I) del lema de Farkas para la matriz $\tilde{A}$ y el vector b .

Paso 2: escribir la alternativa (II) de $\tilde{A}$. Por el Teorema 4.23, ese sistema es infactible si y solo si existe $y \in \mathbb{R}^m$ con $\tilde{A}^\top y \leq 0$ y $\langle b, y \rangle > 0$. Ahora desmenuzamos $\tilde{A}^\top y \leq 0$ bloque por bloque:

$$A^\top y \leq 0, \quad (-A)^\top y = -A^\top y \leq 0, \quad I_m^\top y = y \leq 0.$$

Las dos primeras juntas dicen $A^\top y \leq 0$ y $A^\top y \geq 0$, es decir $A^\top y = 0$ (aquí se ve el efecto de tener la variable *libre*: convierte una desigualdad dual en una igualdad). La tercera dice $y \leq 0$. Así:

$$(I') \text{ infactible} \iff \exists y : A^\top y = 0, y \leq 0, \langle b, y \rangle > 0.$$

Paso 3: cambio de signo cosmético. Poniendo $w = -y$, las condiciones $y \leq 0$, $A^\top y = 0$, $\langle b, y \rangle > 0$ se convierten en $w \geq 0$, $A^\top w = 0$, $\langle b, w \rangle < 0$: exactamente (II'). Como Farkas garantiza que *exactamente uno* de los dos sistemas de la alternativa aplicada a $\tilde{A}$ tiene solución, lo mismo vale para (I') y (II').

Comprobación directa de “no ambos” (útil como control). Si $Ax \leq b$ y $w \geq 0$ con $A^\top w = 0$, entonces multiplicando $Ax \leq b$ por $w \geq 0$ componente a componente y sumando (multiplicar una desigualdad por un número no negativo la preserva):

$$\langle b, w \rangle \geq \langle Ax, w \rangle = \langle x, A^\top w \rangle = \langle x, 0 \rangle = 0,$$

que es incompatible con $\langle b, w \rangle < 0$. La interpretación económica de (II') es transparente: w es una combinación no negativa de restricciones cuya parte en x se cancela ($A^\top w = 0$) y cuyo lado derecho agregado es negativo ($\langle b, w \rangle < 0$): la propia lista de restricciones dice “ $0 \leq$ algo negativo”, es decir, se contradice a sí misma. Esta versión es la que se usa para la dualidad en programación lineal (capítulo 13) y para el teorema de existencia de precios sin arbitraje. $\square$

Ejercicio 4.36 (La función soporte determina al convexo cerrado). Sea $C \subseteq \mathbb{R}^n$ no vacío. Su *función soporte* (support function) es

$$\sigma_C : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}, \quad \sigma_C(a) = \sup_{x \in C} \langle a, x \rangle.$$

- (a) Demuestra que σ_C es positivamente homogénea ($\sigma_C(ta) = t\sigma_C(a)$ para $t > 0$) y subaditiva ($\sigma_C(a + a') \leq \sigma_C(a) + \sigma_C(a')$); deduce que es convexa. Comprueba también que $\sigma_C = \sigma_{\text{cl conv } C}$.
- (b) Demuestra que si C es además convexo y cerrado, entonces

$$C = \{x \in \mathbb{R}^n : \langle a, x \rangle \leq \sigma_C(a) \text{ para todo } a \in \mathbb{R}^n\},$$

y concluye que dos convexos cerrados no vacíos con la misma función soporte son iguales.

- (c) Calcula σ_C para $C = \bar{B}(0, r)$ y para $C = \text{conv}\{v_1, \dots, v_m\}$, y verifica en el primer caso la representación de (b).

Solución. (a) *Homogeneidad positiva.* Para $t > 0$,

$$\sigma_C(ta) = \sup_{x \in C} \langle ta, x \rangle = \sup_{x \in C} t \langle a, x \rangle = t \sup_{x \in C} \langle a, x \rangle = t \sigma_C(a),$$

donde en el tercer paso se usa que multiplicar por una constante *positiva* conmuta con el supremo (si $t > 0$, $tu \leq tM$ equivale a $u \leq M$). La identidad vale también si $\sigma_C(a) = +\infty$, con el convenio $t \cdot (+\infty) = +\infty$. Nota que $\sigma_C(0) = 0$ (supremo de la función nula sobre un conjunto no vacío).

Subaditividad. Para cada $x \in C$,

$$\langle a + a', x \rangle = \langle a, x \rangle + \langle a', x \rangle \leq \sigma_C(a) + \sigma_C(a'),$$

porque cada sumando está acotado por el supremo correspondiente (evaluados en el *mismo* x !). Tomando supremo sobre $x \in C$ en el lado izquierdo, $\sigma_C(a + a') \leq \sigma_C(a) + \sigma_C(a')$. La desigualdad puede ser estricta: la clave es que en el lado derecho cada supremo puede alcanzarse en un punto distinto.

Convexidad. Homogeneidad positiva + subaditividad implican convexidad: para $\lambda \in [0, 1]$,

$$\sigma_C(\lambda a + (1 - \lambda)a') \leq \sigma_C(\lambda a) + \sigma_C((1 - \lambda)a') = \lambda \sigma_C(a) + (1 - \lambda) \sigma_C(a'),$$

(usando subaditividad y luego homogeneidad; los casos $\lambda \in \{0, 1\}$ son triviales). Una función positivamente homogénea y subaditiva se llama *sublineal*, y el resultado profundo (que veremos en el capítulo 12) es que *toda* función sublineal cerrada es la función soporte de algún convexo cerrado.

$\sigma_C = \sigma_{\text{cl conv } C}$. Como $C \subseteq \text{cl conv } C$, el supremo sobre el conjunto mayor es al menos el del menor. Para la otra desigualdad: si $x = \sum_k \lambda_k x_k$ es una combinación convexa de puntos de C , entonces $\langle a, x \rangle = \sum_k \lambda_k \langle a, x_k \rangle \leq \sum_k \lambda_k \sigma_C(a) = \sigma_C(a)$; y si $x = \lim_j x_j$ con $x_j \in \text{conv } C$, la continuidad de $\langle a, \cdot \rangle$ da $\langle a, x \rangle = \lim_j \langle a, x_j \rangle \leq \sigma_C(a)$. Luego $\sigma_{\text{cl conv } C}(a) \leq \sigma_C(a)$. *Consecuencia conceptual:* la función soporte no distingue un conjunto de su cápsula convexa cerrada; solo puede reconstruir esta última, que es justo lo que afirma (b).

(b) *Representación.* Llamemos D al conjunto de la derecha.

($\subseteq$) Si $x \in C$, entonces por la propia definición de supremo, $\langle a, x \rangle \leq \sigma_C(a)$ para todo a ; luego $x \in D$. Esta inclusión no usa hipótesis alguna.

($\supseteq$) Contrarrecíproco: sea $x \notin C$. Como C es no vacío, cerrado y convexo, el Teorema 4.11 da $a \neq 0$ y β con

$$\sup_{y \in C} \langle a, y \rangle < \beta < \langle a, x \rangle, \quad \text{es decir} \quad \sigma_C(a) < \langle a, x \rangle.$$

Esa a testimonia que $x \notin D$. Por tanto $D \subseteq C$, y con la otra inclusión, $D = C$.

Este es el Corolario 4.12 en su forma más económica: en lugar de tomar *todos* los semiespacios que contienen a C , basta con uno por cada dirección a , el más ajustado posible, es decir el de nivel $\sigma_C(a)$. *Unicidad*: si C y C' son convexos cerrados no vacíos con $\sigma_C = \sigma_{C'}$, entonces por la representación

$$C = \{x : \langle a, x \rangle \leq \sigma_C(a) \ \forall a\} = \{x : \langle a, x \rangle \leq \sigma_{C'}(a) \ \forall a\} = C'.$$

Conocer todos los hiperplanos soporte *es* conocer el conjunto (Observación 4.13).

(c) *Ejemplos. Bola*: para $C = \bar{B}(0, r)$ y $a \neq 0$, Cauchy–Schwarz da $\langle a, x \rangle \leq \|a\| \|x\| \leq r \|a\|$, y el valor $r \|a\|$ se alcanza en $x = ra / \|a\| \in C$; luego $\sigma_{\bar{B}(0, r)}(a) = r \|a\|$ (y $\sigma_C(0) = 0$, coherente con la fórmula). *Verificación de (b)*: el conjunto $D = \{x : \langle a, x \rangle \leq r \|a\| \ \forall a\}$ contiene claramente a la bola; y si $x \in D$, tomando la dirección particular $a = x$ obtenemos $\|x\|^2 = \langle x, x \rangle \leq r \|x\|$, de donde $\|x\| \leq r$ (dividiendo entre $\|x\| > 0$; si $x = 0$ no hay nada que probar). Así $D = \bar{B}(0, r)$: una sola dirección bien elegida basta para recuperar el conjunto en este caso.

Politopo: si $C = \text{conv}\{v_1, \dots, v_m\}$, entonces por lo probado en (a) $\sigma_C = \sigma_{\{v_1, \dots, v_m\}}$, es decir

$$\sigma_C(a) = \max_{1 \leq k \leq m} \langle a, v_k \rangle,$$

un máximo de finitas funciones lineales: finito para todo a (el conjunto es acotado) y *poliédrico*. En general, σ_C es finita en todo $\mathbb{R}^n$ si y solo si C es acotado.

Lectura económica. La función soporte es un objeto que ya conoces con otros nombres: la *función de beneficios* $\pi(p) = \sup_{y \in Y} \langle p, y \rangle$ es la función soporte del conjunto de producción Y , y por el apartado (b) determina el $\text{conv } Y$: dos tecnologías con la misma función de beneficios son indistinguibles ([9], cap. 5; [10], cap. 3). Análogamente, la *función de gasto* $e(p, u) = \inf\{\langle p, x \rangle : x \succeq u\}$ es (con un signo) la función soporte del conjunto de contorno superior, y la recuperación del conjunto a partir de ella es la dualidad utilidad–gasto. Todo esto reaparece formalizado en la conjugación de Fenchel (capítulo 12) y en [2], sec. 2.5. $\square$

Ejercicio 4.37 (Descentralizar un óptimo de Pareto en la caja de Edgeworth). Una economía de intercambio con $L = 2$ bienes e $I = 2$ consumidores tiene dotación agregada $\bar{\omega} = (10, 10)$ y preferencias representadas por

$$u_A(x_1, x_2) = x_1^{1/2} x_2^{1/2}, \quad u_B(x_1, x_2) = x_1^{1/3} x_2^{2/3}, \quad x \in \mathbb{R}_{++}^2.$$

Considera la asignación

$$x_A^* = \left(4, \frac{5}{2}\right), \quad x_B^* = \left(6, \frac{15}{2}\right).$$

(a) Verifica que es factible y demuestra que es un óptimo de Pareto.

- (b) Encuentra un vector de precios p que la descentralice como equilibrio con transferencias, y comprueba directamente que cada consumidor maximiza su utilidad en su presupuesto.
- (c) Si las dotaciones iniciales fueran $\omega_A = \omega_B = (5, 5)$, ¿qué transferencias implementan el óptimo?
- (d) Identifica con precisión en qué paso del argumento se usó separación, exhibiendo el conjunto separado y el hiperplano.

Solución. (a) *Factibilidad.* $x_A^* + x_B^* = (4 + 6, \frac{5}{2} + \frac{15}{2}) = (10, 10) = \bar{\omega}$: la asignación agota los recursos y es factible con igualdad.

Optimalidad de Pareto por pesos de Negishi. La estrategia limpia (y rigurosa) es: encontrar pesos $\lambda \in (0, 1)$ tales que x^* maximice la suma ponderada

$$W(x_A) = \lambda \ln u_A(x_A) + (1 - \lambda) \ln u_B(\bar{\omega} - x_A)$$

sobre las asignaciones factibles, y observar que *todo maximizador de una suma ponderada con pesos estrictamente positivos de utilidades (o de transformaciones estrictamente crecientes de ellas) es un óptimo de Pareto*. Este último hecho es inmediato: si existiera una asignación factible y con $u_A(y_A) \geq u_A(x_A^*)$, $u_B(y_B) \geq u_B(x_B^*)$ y al menos una desigualdad estricta, entonces, siendo $\ln$ estrictamente creciente y los pesos positivos, se tendría $W(y_A) > W(x_A^*)$, contradiciendo la maximalidad.

Escribiendo $x_A = (a_1, a_2)$ y $x_B = (10 - a_1, 10 - a_2)$,

$$W(a) = \lambda \left(\frac{1}{2} \ln a_1 + \frac{1}{2} \ln a_2 \right) + (1 - \lambda) \left(\frac{1}{3} \ln(10 - a_1) + \frac{2}{3} \ln(10 - a_2) \right).$$

W es cóncava en a sobre el rectángulo abierto $(0, 10)^2$ (es suma de funciones cóncavas: $\ln$ es cóncava y $a \mapsto \ln(10 - a)$ es la composición de $\ln$ con una función afín), luego un punto donde el gradiente se anula es un máximo global (capítulo 8). Las condiciones de primer orden son

$$\frac{\partial W}{\partial a_1} = \frac{\lambda}{2a_1} - \frac{1 - \lambda}{3(10 - a_1)} = 0, \quad \frac{\partial W}{\partial a_2} = \frac{\lambda}{2a_2} - \frac{2(1 - \lambda)}{3(10 - a_2)} = 0.$$

Evaluemos en el candidato $a = (4, \frac{5}{2})$, donde $10 - a_1 = 6$ y $10 - a_2 = \frac{15}{2}$. La primera ecuación pide

$$\frac{\lambda}{8} = \frac{1 - \lambda}{18} \iff 18\lambda = 8 - 8\lambda \iff \lambda = \frac{8}{26} = \frac{4}{13}.$$

Comprobamos que ese mismo λ satisface la segunda ecuación:

$$\frac{\lambda}{2 \cdot \frac{5}{2}} = \frac{4/13}{5} = \frac{4}{65}, \quad \frac{2(1 - \lambda)}{3 \cdot \frac{15}{2}} = \frac{2 \cdot \frac{9}{13}}{\frac{45}{2}} = \frac{18}{13} \cdot \frac{2}{45} = \frac{36}{585} = \frac{4}{65}.$$

Coinciden. Por tanto, con $\lambda = 4/13$, el punto x^* anula el gradiente de la función cóncava W y es su máximo global sobre las asignaciones factibles interiores; los puntos de la frontera del rectángulo dan $W = -\infty$ (alguna utilidad nula), así que el máximo global es interior. Conclusión: x^* es un óptimo de Pareto. (Equivalentemente, y más rápido para el examen: las tasas marginales de sustitución se igualan: para A , $\text{TMS}_A = \frac{\partial_1 u_A}{\partial_2 u_A} = \frac{x_2}{x_1} = \frac{5/2}{4} = \frac{5}{8}$; para B ,

$\text{TMS}_B = \frac{(1/3)u_B/x_1}{(2/3)u_B/x_2} = \frac{x_2}{2x_1} = \frac{15/2}{12} = \frac{5}{8}$; y con preferencias convexas y monótonas la igualación de TMS en el interior caracteriza la curva de contrato.)

(b) *Los precios.* El precio relativo debe igualar la TMS común: $p_1/p_2 = 5/8$. Normalizando, tomamos

$$p = (5, 8).$$

Las riquezas que sostienen la asignación son

$$w_A = \langle p, x_A^* \rangle = 5 \cdot 4 + 8 \cdot \frac{5}{2} = 20 + 20 = 40, \quad w_B = \langle p, x_B^* \rangle = 5 \cdot 6 + 8 \cdot \frac{15}{2} = 30 + 60 = 90,$$

que suman $130 = \langle p, \bar{\omega} \rangle = 50 + 80$, como debe ser.

Comprobación 1 (vía demandas). Para una Cobb–Douglas $u(x) = x_1^\alpha x_2^{1-\alpha}$, la demanda marshalliana es $x_1 = \alpha w/p_1$, $x_2 = (1-\alpha)w/p_2$ (gastar la fracción α de la riqueza en el bien 1). Entonces:

$$\begin{aligned} \text{consumidor } A: \quad x_1 &= \frac{1}{2} \cdot \frac{40}{5} = 4, & x_2 &= \frac{1}{2} \cdot \frac{40}{8} = \frac{5}{2}; \\ \text{consumidor } B: \quad x_1 &= \frac{1}{3} \cdot \frac{90}{5} = 6, & x_2 &= \frac{2}{3} \cdot \frac{90}{8} = \frac{15}{2}. \end{aligned}$$

Cada consumidor demanda exactamente su asignación, y los mercados se vacían ($4 + 6 = 10$, $\frac{5}{2} + \frac{15}{2} = 10$): (x^*, p) es un equilibrio con transferencias.

Comprobación 2 (vía hiperplano soporte, que es la que conecta con el capítulo). Verifiquemos sin usar cálculo que el presupuesto soporta al conjunto de mejora de cada consumidor, es decir que todo lo al menos tan bueno cuesta al menos lo mismo. Para A : si $x \in \mathbb{R}_{++}^2$ cumple $u_A(x) = \sqrt{x_1 x_2} \geq \sqrt{4 \cdot \frac{5}{2}} = \sqrt{10}$, entonces $x_1 x_2 \geq 10$ y, por la desigualdad entre medias aritmética y geométrica aplicada a los números $5x_1$ y $8x_2$,

$$5x_1 + 8x_2 \geq 2\sqrt{(5x_1)(8x_2)} = 2\sqrt{40x_1x_2} \geq 2\sqrt{400} = 40 = w_A,$$

con igualdad si y solo si $5x_1 = 8x_2$ y $x_1 x_2 = 10$, es decir en $x = x_A^*$. Para B usamos la AM–GM ponderada (que se deduce de la concavidad del logaritmo: $\theta \ln u + (1-\theta) \ln v \leq \ln(\theta u + (1-\theta)v)$, y se exponencia), con $\theta = 1/3$, $u = 15x_1$, $v = 12x_2$:

$$5x_1 + 8x_2 = \frac{1}{3}(15x_1) + \frac{2}{3}(12x_2) \geq (15x_1)^{1/3}(12x_2)^{2/3} = 15^{1/3}12^{2/3}x_1^{1/3}x_2^{2/3}.$$

Si $u_B(x) \geq u_B(x_B^*) = 6^{1/3}(15/2)^{2/3}$, sustituyendo:

$$5x_1 + 8x_2 \geq (15 \cdot 6)^{1/3}(12 \cdot \frac{15}{2})^{2/3} = 90^{1/3}90^{2/3} = 90 = w_B,$$

otra vez con igualdad exactamente en $x = x_B^*$ (allí $15x_1 = 90 = 12x_2$). Hemos demostrado que las rectas presupuestarias $\{x : \langle p, x \rangle = w_i\}$ son *hiperplanos soporte* de los conjuntos de contorno superior $\{x : u_i(x) \geq u_i(x_i^*)\}$ en x_i^* (Definición 4.14), que es literalmente la condición de maximización de la Definición 4.28: todo lo estrictamente mejor es estrictamente más caro.

(c) *Transferencias.* Con $\omega_A = \omega_B = (5, 5)$, el valor de cada dotación es $\langle p, (5, 5) \rangle = 25 + 40 = 65$. Las riquezas objetivo son $w_A = 40$ y $w_B = 90$, luego

$$T_A = w_A - \langle p, \omega_A \rangle = 40 - 65 = -25, \quad T_B = w_B - \langle p, \omega_B \rangle = 90 - 65 = +25,$$

y en efecto $T_A + T_B = 0$: la transferencia es presupuestariamente neutral, como exige el Segundo Teorema del Bienestar (Teorema 4.30). Se le quitan 25 unidades de cuenta al consumidor A y se le dan a B ; *no se redistribuyen bienes, solo poder de compra*, y el mercado hace el resto.

(d) ¿Dónde estuvo la separación? En el Paso 3 de la demostración del Teorema 4.30. Aquí podemos exhibirlo explícitamente. Los conjuntos de mejora estricta son

$$V_A = \{x \in \mathbb{R}_{++}^2 : \sqrt{x_1 x_2} > \sqrt{10}\}, \quad V_B = \{x \in \mathbb{R}_{++}^2 : x_1^{1/3} x_2^{2/3} > 6^{1/3} (15/2)^{2/3}\},$$

ambos convexos (son los conjuntos de contorno superior estricto de funciones cuasicóncavas: es la *convexidad de las preferencias*), y el conjunto de mejoras agregadas es la suma de Minkowski $V = V_A + V_B$. Las dos desigualdades de AM–GM del apartado (b), con desigualdad *estricta* cuando la utilidad es estrictamente mayor, dan para todo $z = x_A + x_B \in V$:

$$\langle p, z \rangle = \langle p, x_A \rangle + \langle p, x_B \rangle > 40 + 90 = 130 = \langle p, \bar{\omega} \rangle.$$

Es decir, el hiperplano

$$H = \{z \in \mathbb{R}^2 : 5z_1 + 8z_2 = 130\}$$

deja a $\bar{\omega} = (10, 10)$ sobre él y a todo el conjunto de mejoras agregadas V estrictamente por encima: es exactamente la desigualdad (4.5), y su normal $p = (5, 8)$ es el vector de precios. Que $\bar{\omega} \notin V$ es la traducción de que x^* es Pareto óptimo; que V sea convexo es lo que permite invocar el Teorema 4.21 para *producir* tal hiperplano en general.

Dos observaciones finales sobre el papel de las hipótesis en este ejemplo concreto. Primero, la no saciedad local (aquí, monotonía estricta de las Cobb–Douglas) se usó dos veces: para que los V_i sean no vacíos y, en el Paso 4 del teorema, para pasar de la desigualdad agregada a la individual; además garantiza $p > 0$ (Observación 4.31). Segundo, la condición del *punto más barato* se cumple sin esfuerzo: $w_A = 40 > 0$ y $w_B = 90 > 0$, y con precios positivos siempre hay cestas más baratas que la óptima (reduce cualquier coordenada), así que el cuasi-equilibrio que entrega la separación es un equilibrio de verdad. Si en cambio las preferencias tuvieran un tramo no convexo, la separación podría fallar y *ningún* precio descentralizaría este óptimo (Figura 4.3); y si la asignación estuviera en la frontera del ortante con riqueza nula, tendríamos el clásico cuasi-equilibrio sin equilibrio de [9], sec. 16.D. Compara con el tratamiento de [10], cap. 5, donde la misma caja de Edgeworth se resuelve con cálculo: el cálculo da los precios cuando las funciones son diferenciables e interiores, pero solo la separación garantiza que existan siempre. $\square$

Capítulo 5

Funciones cóncavas y convexas [P1]

Semana 4 del cronograma. Bibliografía: Boyd y Vandenberghe [2]; Ruszczyński [6]; Aragón et al. [1].

¿Para qué sirve esto en Microeconomía?

Ninguna propiedad estructural se invoca tanto en Microeconomía como la concavidad, y este es el capítulo que la construye. En la **teoría de la decisión bajo incertidumbre**, la concavidad de la función de utilidad de Bernoulli *es*, literalmente, la aversión al riesgo: la desigualdad de Jensen (Teorema 5.9) dice que $u(\mathbb{E}[X]) \geq \mathbb{E}[u(X)]$ cuando u es cóncava, es decir, el agente prefiere el valor esperado seguro antes que la lotería; de ahí nacen el equivalente cierto, la *prima de riesgo* y los coeficientes de aversión absoluta y relativa de Arrow–Pratt que usarás en cada problema de utilidad esperada (MWG, cap. 6, [9]). En **equilibrio general** (MWG, caps. 15–18), la concavidad de la función de producción hace que el conjunto de producción sea convexo (es el hipografo de la función, Sección 5.3), y esa convexidad es la hipótesis sobre la que descansan la existencia de equilibrio y los teoremas del bienestar. En la **teoría de dualidad** del consumidor y de la empresa, la función de gasto $e(p, u)$ es *cóncava* en precios y la función de beneficio $\pi(p)$ es *convexa* en precios, no por casualidad, sino porque ambas son funciones soporte de un conjunto (Sección 5.9), y de esa concavidad/convexidad salen los lemas de Shephard y de Hotelling con los que se calculan demandas hicksianas y ofertas netas (MWG, caps. 3 y 5; [10], caps. 1–3). Finalmente, en la **teoría de contratos** (MWG, cap. 14), la concavidad de la utilidad del agente es la fuente del *trade-off* entre aseguramiento e incentivos del modelo de riesgo moral de Holmström: como el agente es averso al riesgo, cargarle riesgo para incentivarlo es costoso, y el contrato óptimo equilibra ambas fuerzas. Todo eso está construido sobre las definiciones y teoremas de este capítulo. Estúdialo hasta que puedas reproducir cada demostración.


Hasta ahora hemos estudiado *conjuntos* convexos: segmentos, cápsulas, conos, y los teoremas de separación. Este capítulo da el salto a las *funciones*. Una función convexa es, en esencia, una función cuyo grafo “se curva hacia arriba”: la cuerda que une dos puntos del grafo queda *por encima* del grafo. Una función cóncava es lo contrario: la cuerda queda por debajo. Veremos que esta idea geométrica tan simple tiene consecuencias enormes: las funciones convexas se pueden

caracterizar por su epígrafo (un conjunto convexo, lo que conecta este capítulo con los anteriores), por su gradiente (la tangente subestima) y por su Hessiana (semidefinida positiva); son continuas en el interior de su dominio sin pedirlo; se preservan bajo operaciones naturales como sumas y supremos; y satisfacen la desigualdad de Jensen, que es la piedra angular de la teoría de la decisión bajo incertidumbre. Cerramos con la *función soporte* de un conjunto, el puente entre la geometría convexa y la dualidad económica. Referencias principales: [2] (cap. 3, secciones 3.1–3.2), [3] (cap. 2), [6] (secciones 2.4–2.5) y [1] (caps. 3–4). Del capítulo de preliminares usaremos: gradiente, Hessiana, el teorema de Taylor y los criterios de definitud por menores principales; del capítulo de conjuntos convexos, la definición de conjunto convexo y sus operaciones.

5.1. Definiciones y caracterización gráfica [P1]

5.1.1. La idea: la cuerda y el grafo

Toma la parábola $f(x) = x^2$ y dos puntos de su grafo, digamos $(-1, 1)$ y $(2, 4)$. Dibuja el segmento de recta (la *cuerda*, *chord*) que los une. Si observas la figura, verás que la cuerda queda completamente *por encima* de la parábola en el tramo entre -1 y 2 . Esa es exactamente la propiedad que define a una función convexa. Para una función cóncava, como $f(x) = \ln x$, ocurre lo contrario: la cuerda queda *por debajo* del grafo.



La figura muestra la traducción algebraica de “la cuerda está por encima”. Fija dos puntos x e y del dominio y un peso $\lambda \in [0, 1]$. El punto del dominio “a fracción λ del camino de x a y ” es $(1 - \lambda)x + \lambda y$ (una combinación convexa, como en el Capítulo 2). Sobre ese punto hay dos alturas que comparar:

- la altura del *grafo*: $f((1 - \lambda)x + \lambda y)$;
- la altura de la *cuerda*: $(1 - \lambda)f(x) + \lambda f(y)$, que es el promedio ponderado de las alturas en los extremos (la cuerda es una recta, y sobre una recta el valor intermedio es el promedio ponderado de los valores extremos).

“Cuerda por encima del grafo” significa entonces $f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y)$. Esa desigualdad es la definición.

5.1.2. Definiciones formales

Antes de definir, una advertencia sobre el dominio: para que la desigualdad tenga sentido necesitamos que f esté definida en el punto intermedio $(1-\lambda)x + \lambda y$. Eso está garantizado exactamente cuando el dominio es un *conjunto convexo*. Por eso toda la teoría de funciones convexas se hace sobre dominios convexos.

Definición 5.1 (Función convexa y función cóncava). Sea $C \subseteq \mathbb{R}^n$ un conjunto convexo no vacío y $f : C \rightarrow \mathbb{R}$.

(I) f es *convexa* (*convex*) en C si para todos $x, y \in C$ y todo $\lambda \in [0, 1]$,

$$f((1-\lambda)x + \lambda y) \leq (1-\lambda)f(x) + \lambda f(y). \quad (5.1)$$

(II) f es *estrictamente convexa* (*strictly convex*) si la desigualdad (5.1) es estricta ($<$) siempre que $x \neq y$ y $\lambda \in (0, 1)$.

(III) f es *cóncava* (*concave*) si la desigualdad se invierte: $f((1-\lambda)x + \lambda y) \geq (1-\lambda)f(x) + \lambda f(y)$ para todos $x, y \in C$, $\lambda \in [0, 1]$; y *estrictamente cóncava* si es estricta cuando $x \neq y$ y $\lambda \in (0, 1)$.

Observación 5.2. Directamente de la definición: f es cóncava si y solo si $-f$ es convexa. En efecto, multiplicar la desigualdad $f((1-\lambda)x + \lambda y) \geq (1-\lambda)f(x) + \lambda f(y)$ por -1 invierte el sentido y produce exactamente (5.1) para $-f$. Esta observación trivial es importantísima en la práctica: *todo* teorema sobre funciones convexas se traduce automáticamente en un teorema sobre cóncavas cambiando f por $-f$ e invirtiendo desigualdades. En este capítulo demostramos casi todo para convexas; tú debes ser capaz de enunciar la versión cóncava de cada resultado, porque en microeconomía las protagonistas (utilidad, producción, gasto) suelen ser cóncavas.

Observación 5.3. En (5.1) los casos $\lambda = 0$ y $\lambda = 1$ son triviales (dan $f(x) \leq f(x)$ y $f(y) \leq f(y)$), así que la condición sustantiva es para $\lambda \in (0, 1)$. Nota también que en la definición de *estricta* exigimos $x \neq y$: si $x = y$, ambos lados son iguales sin remedio.

Intuición

Tres lecturas de la misma desigualdad, y conviene tener las tres a mano: **(1) Geométrica:** la cuerda está por encima del grafo (convexa) o por debajo (cóncava). **(2) De promedios:** “la función del promedio es menor o igual que el promedio de la función” (convexa); para cóncavas, “la función del promedio es mayor o igual que el promedio de la función”. **(3) Económica:** si x y y son dos canastas y λ una probabilidad, la versión cóncava dice que la utilidad de la *canasta esperada* supera a la *utilidad esperada*: el consumidor prefiere lo seguro al promedio aleatorio. Esa tercera lectura es la desigualdad de Jensen con dos puntos, y es la semilla de toda la teoría de aversión al riesgo (Sección 5.2).

5.1.3. Ejemplos verificados desde la definición

Verificar convexidad directamente desde la definición es laborioso, y en la práctica casi siempre usaremos los criterios de primer y segundo orden (Secciones 5.5 y 5.6). Pero hacerlo “a mano”

al menos una vez es el mejor entrenamiento para entender qué dice la definición.

Ejemplo 5.4 ($f(x) = x^2$ es estrictamente convexa). Sea $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2$. Tomemos $x, y \in \mathbb{R}$ y $\lambda \in [0, 1]$, y comparemos los dos lados de (5.1). Calculamos la diferencia “cuerda menos grafo”:

$$D := (1 - \lambda)x^2 + \lambda y^2 - ((1 - \lambda)x + \lambda y)^2.$$

Expandimos el cuadrado del binomio:

$$((1 - \lambda)x + \lambda y)^2 = (1 - \lambda)^2 x^2 + 2\lambda(1 - \lambda)xy + \lambda^2 y^2.$$

Sustituyendo y agrupando los términos en x^2 , en y^2 y el cruzado:

$$\begin{aligned} D &= [(1 - \lambda) - (1 - \lambda)^2]x^2 + [\lambda - \lambda^2]y^2 - 2\lambda(1 - \lambda)xy \\ &= (1 - \lambda)[1 - (1 - \lambda)]x^2 + \lambda(1 - \lambda)y^2 - 2\lambda(1 - \lambda)xy \\ &= \lambda(1 - \lambda)x^2 + \lambda(1 - \lambda)y^2 - 2\lambda(1 - \lambda)xy \\ &= \lambda(1 - \lambda)(x - y)^2, \end{aligned}$$

donde en el segundo paso usamos $1 - (1 - \lambda) = \lambda$ y en el último reconocimos el cuadrado perfecto $x^2 - 2xy + y^2 = (x - y)^2$. Como $\lambda(1 - \lambda) \geq 0$ para $\lambda \in [0, 1]$ y $(x - y)^2 \geq 0$, concluimos $D \geq 0$: la cuerda está por encima, f es convexa. Más aún: si $x \neq y$ y $\lambda \in (0, 1)$, entonces $\lambda(1 - \lambda) > 0$ y $(x - y)^2 > 0$, luego $D > 0$: f es *estrictamente* convexa.

Ejemplo 5.5 (Las funciones afines son convexas y cóncavas a la vez). Sea $f(x) = ax + b$ con $a, b \in \mathbb{R}$ (y en general $f(x) = \langle a, x \rangle + b$ en $\mathbb{R}^n$). Calculamos directamente:

$$f((1 - \lambda)x + \lambda y) = a((1 - \lambda)x + \lambda y) + b = (1 - \lambda)(ax) + \lambda(ay) + (1 - \lambda)b + \lambda b,$$

donde usamos $b = (1 - \lambda)b + \lambda b$ (los pesos suman uno). Agrupando, esto es exactamente $(1 - \lambda)f(x) + \lambda f(y)$. La desigualdad (5.1) se cumple *con igualdad*, así que f es convexa; y como también se cumple la desigualdad invertida, es cóncava. De hecho, las funciones afines son las *únicas* que son convexas y cóncavas a la vez. Y ninguna función afín es estrictamente convexa ni estrictamente cóncava: la igualdad en la definición lo impide.

Ejemplo 5.6 ($f(x) = |x|$ es convexa pero no estrictamente). Sea $f(x) = |x|$. Por la desigualdad triangular en $\mathbb{R}$ y la homogeneidad del valor absoluto ($|ct| = |c||t|$, y $|1 - \lambda| = 1 - \lambda$, $|\lambda| = \lambda$ para $\lambda \in [0, 1]$):

$$|(1 - \lambda)x + \lambda y| \leq |(1 - \lambda)x| + |\lambda y| = (1 - \lambda)|x| + \lambda|y|.$$

Eso es exactamente (5.1): f es convexa. No es estrictamente convexa: tomando $x = 1$, $y = 2$ y $\lambda = 1/2$, el lado izquierdo es $|3/2| = 3/2$ y el derecho es $\frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 2 = 3/2$; hay igualdad con $x \neq y$, porque f es lineal en el tramo $[1, 2]$. El mismo argumento con la desigualdad triangular de la norma muestra que $f(x) = \|x\|$ es convexa en $\mathbb{R}^n$. Nota además que $|x|$ es convexa *sin ser diferenciable* en 0: la convexidad no requiere derivadas.

Ejemplo 5.7 (e^x es estrictamente convexa; $\ln x$ es estrictamente cóncava). Para estas funciones la verificación directa desde la definición es posible pero engorrosa (requiere la desigualdad entre medias aritmética y geométrica ponderadas). Damos el argumento para $\ln$ porque lo usaremos: queremos ver que para $x, y > 0$ y $\lambda \in (0, 1)$,

$$\ln((1 - \lambda)x + \lambda y) \geq (1 - \lambda) \ln x + \lambda \ln y.$$

El lado derecho es $\ln(x^{1-\lambda}y^\lambda)$ (propiedades del logaritmo: $a \ln t = \ln t^a$ y $\ln s + \ln t = \ln st$). Como $\ln$ es creciente, la desigualdad equivale a

$$(1 - \lambda)x + \lambda y \geq x^{1-\lambda}y^\lambda,$$

que es la *desigualdad media aritmética-media geométrica ponderada* (AM–GM). Y esta, a su vez, se demuestra usando la convexidad de e^t : escribiendo $x = e^s$, $y = e^t$, la desigualdad se convierte en $(1 - \lambda)e^s + \lambda e^t \geq e^{(1-\lambda)s + \lambda t}$, que es exactamente la convexidad de la exponencial. Moraleja: en la práctica, la manera limpia de verificar que e^x es estrictamente convexa y $\ln x$ estrictamente cóncava es el criterio de segunda derivada de la Sección 5.6: $(e^x)'' = e^x > 0$ para todo x , y $(\ln x)'' = -1/x^2 < 0$ para todo $x > 0$. Guarda este ejemplo como ilustración de que “desde la definición” puede ser duro, y de que las herramientas de cálculo que desarrollaremos valen oro.

Estrategia de examen

Ante la pregunta “¿es f convexa/cóncava?”, este es el orden de ataque que recomiendo en un examen:

1. **¿Es afín?** Entonces es ambas cosas (Ejemplo 5.5). Fin.
2. **¿Es C^2 ?** Calcula la Hessiana y aplica el criterio de segundo orden (Teorema 5.25) con los menores principales del capítulo de preliminares. Es la vía más mecánica.
3. **¿Se construye a partir de convexas conocidas?** Usa el catálogo de operaciones que preservan convexidad (Sección 5.7): sumas con pesos no negativos, supremos, composición con afines, composición monótona-convexa. Esto salva los casos no diferenciables como $\|x\|$ o $\max_i x_i$.
4. **¿Es un supremo de afines en la variable de interés?** (funciones de beneficio, funciones soporte, conjugadas): convexa automáticamente, sin importar qué tan fea sea la otra parte del problema (Teorema 5.33).
5. **Solo como último recurso**, verifica la definición a mano, como en el Ejemplo 5.4.

Para *refutar* convexidad basta un contraejemplo numérico: dos puntos y un λ que violen la desigualdad, o una dirección en la que la Hessiana tenga curvatura negativa.

5.2. Desigualdad de Jensen y aversión al riesgo [P1]

La definición de convexidad compara la función en un promedio de *dos* puntos con el promedio de los valores. La desigualdad de Jensen dice que lo mismo vale para promedios de *cualquier* número de puntos, y en el límite, para esperanzas de variables aleatorias. Es, sin exagerar, la desigualdad más importante de la teoría económica de la incertidumbre.

Teorema 5.8 (Desigualdad de Jensen, versión finita). *Sea $C \subseteq \mathbb{R}^n$ convexo y $f : C \rightarrow \mathbb{R}$ convexa. Entonces para cualesquiera puntos $x_1, \dots, x_k \in C$ y pesos $\lambda_1, \dots, \lambda_k \geq 0$ con $\sum_{i=1}^k \lambda_i = 1$,*

$$f\left(\sum_{i=1}^k \lambda_i x_i\right) \leq \sum_{i=1}^k \lambda_i f(x_i).$$

Si f es cóncava, la desigualdad se invierte.

Demostración. Por inducción sobre k . **Caso base $k = 2$:** es exactamente la definición de convexidad (5.1) con $\lambda_1 = 1 - \lambda$, $\lambda_2 = \lambda$. (El caso $k = 1$ es trivial: $\lambda_1 = 1$ y ambos lados son $f(x_1)$.)

Paso inductivo: supongamos que el resultado vale para $k-1$ puntos (hipótesis de inducción) y probémoslo para k puntos. Sean $x_1, \dots, x_k \in C$ y pesos $\lambda_1, \dots, \lambda_k \geq 0$ que suman 1. Si $\lambda_k = 1$, entonces todos los demás pesos son cero y la desigualdad es trivial ($f(x_k) \leq f(x_k)$). Supongamos entonces $\lambda_k < 1$, de modo que $\mu := 1 - \lambda_k = \sum_{i=1}^{k-1} \lambda_i > 0$. La idea es *reagrupar*: separamos el último punto y tratamos los primeros $k-1$ como un solo bloque. Definimos el punto

$$z := \sum_{i=1}^{k-1} \frac{\lambda_i}{\mu} x_i.$$

Observa que los pesos λ_i/μ son no negativos y suman $\frac{1}{\mu} \sum_{i=1}^{k-1} \lambda_i = \mu/\mu = 1$: son pesos convexos legítimos sobre $k-1$ puntos, así que $z \in C$ (un conjunto convexo contiene todas las combinaciones convexas de sus puntos, Capítulo 2). Además, por construcción,

$$\sum_{i=1}^k \lambda_i x_i = \mu z + \lambda_k x_k, \quad \mu + \lambda_k = 1.$$

Ahora aplicamos primero la definición de convexidad (caso $k = 2$) a los puntos z y x_k con pesos μ y λ_k :

$$f\left(\sum_{i=1}^k \lambda_i x_i\right) = f(\mu z + \lambda_k x_k) \leq \mu f(z) + \lambda_k f(x_k),$$

y después la hipótesis de inducción a $f(z)$:

$$f(z) = f\left(\sum_{i=1}^{k-1} \frac{\lambda_i}{\mu} x_i\right) \leq \sum_{i=1}^{k-1} \frac{\lambda_i}{\mu} f(x_i).$$

Combinando ambas:

$$f\left(\sum_{i=1}^k \lambda_i x_i\right) \leq \mu \sum_{i=1}^{k-1} \frac{\lambda_i}{\mu} f(x_i) + \lambda_k f(x_k) = \sum_{i=1}^{k-1} \lambda_i f(x_i) + \lambda_k f(x_k) = \sum_{i=1}^k \lambda_i f(x_i),$$

que es lo que queríamos. La versión cóncava se obtiene aplicando lo anterior a $-f$ (Observación 5.2). $\square$

Cuando los pesos λ_i son probabilidades, la suma $\sum_i \lambda_i x_i$ es la *esperanza* de una variable aleatoria discreta y $\sum_i \lambda_i f(x_i)$ es la esperanza de f de esa variable. Eso da inmediatamente la versión probabilística:

Teorema 5.9 (Desigualdad de Jensen, versión con esperanza). *Sea X una variable aleatoria que toma valores en un conjunto convexo $C \subseteq \mathbb{R}^n$ y tiene esperanza finita $\mathbb{E}[X] \in C$. Si $f : C \rightarrow \mathbb{R}$ es convexa (y $\mathbb{E}[f(X)]$ existe), entonces*

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

Si f es cóncava, $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$. Si f es estrictamente convexa (resp. estrictamente cóncava) y X no es constante (es decir, es genuinamente aleatoria), la desigualdad es estricta.

Idea de la demostración. Si X es discreta con soporte finito, es exactamente el Teorema 5.8 con $\lambda_i = \Pr(X = x_i)$. Para el caso general se usa la caracterización de primer orden que veremos en la Sección 5.5 (o, sin diferenciabilidad, la existencia de una recta soporte, que probaremos en el capítulo de subdiferenciales): existe un vector g tal que $f(x) \geq f(\mathbb{E}[X]) + \langle g, x - \mathbb{E}[X] \rangle$ para todo $x \in C$. Evaluando en $x = X$ y tomando esperanzas a ambos lados (la esperanza preserva desigualdades y es lineal):

$$\mathbb{E}[f(X)] \geq f(\mathbb{E}[X]) + \langle g, \mathbb{E}[X] - \mathbb{E}[X] \rangle = f(\mathbb{E}[X]). \quad \square$$

5.2.1. Aplicación desarrollada: aversión al riesgo

Esta subsección es un mini-curso de la teoría de aversión al riesgo que verás en Microeconomía (decisión bajo incertidumbre; MWG cap. 6, [9]; [10] cap. 2). Considera un agente con riqueza aleatoria: una *lotería* X que paga x_i soles con probabilidad λ_i . El agente evalúa loterías con *utilidad esperada*: su bienestar es $\mathbb{E}[u(X)] = \sum_i \lambda_i u(x_i)$, donde $u : \mathbb{R} \rightarrow \mathbb{R}$ es su función de utilidad de Bernoulli sobre dinero, que supondremos estrictamente creciente.

Aversión al riesgo. Se dice que el agente es *averso al riesgo* (*risk averse*) si para toda lotería prefiere recibir la esperanza $\mathbb{E}[X]$ con seguridad antes que jugar la lotería:

$$u(\mathbb{E}[X]) \geq \mathbb{E}[u(X)] \quad \text{para toda lotería } X.$$

Por la desigualdad de Jensen (Teorema 5.9), *esto ocurre si y solo si u es cóncava*. La dirección “cóncava $\Rightarrow$ aversa” es Jensen; la recíproca sale tomando loterías de dos puntos: si la desigualdad vale para toda lotería binaria (x con probabilidad $1 - \lambda$, y con probabilidad λ), entonces $u((1 - \lambda)x + \lambda y) \geq (1 - \lambda)u(x) + \lambda u(y)$ para todos x, y, λ , que es la definición de concavidad. La concavidad de la utilidad *es* la aversión al riesgo: no son dos supuestos, son el mismo.

Equivalente cierto y prima de riesgo. El *equivalente cierto* (*certainty equivalent*) de la lotería X , denotado $c(X)$, es la cantidad segura que deja al agente indiferente con la lotería:

$$u(c(X)) = \mathbb{E}[u(X)] \quad \Longleftrightarrow \quad c(X) = u^{-1}(\mathbb{E}[u(X)]),$$

donde u^{-1} existe porque u es estrictamente creciente. La *prima de riesgo* (*risk premium*) es

$$\rho(X) := \mathbb{E}[X] - c(X),$$

lo máximo que el agente pagaría por deshacerse del riesgo y quedarse con un pago seguro. Si u es cóncava, Jensen da $u(\mathbb{E}[X]) \geq \mathbb{E}[u(X)] = u(c(X))$, y como u es creciente, $\mathbb{E}[X] \geq c(X)$: la *prima de riesgo de un agente averso es no negativa*, y es estrictamente positiva si u es estrictamente cóncava y la lotería tiene riesgo genuino. Este es el fundamento del negocio del seguro: el asegurado averso está dispuesto a pagar por encima de la pérdida esperada.

Ejemplo 5.10 (Cálculo completo de un equivalente cierto). Un agente con $u(x) = \ln x$ (estrictamente cóncava, Ejemplo 5.7) enfrenta la lotería: riqueza 100 con probabilidad $1/2$ y riqueza 25 con probabilidad $1/2$.

- *Riqueza esperada*: $\mathbb{E}[X] = \frac{1}{2}(100) + \frac{1}{2}(25) = 62.5$.
- *Utilidad esperada*: $\mathbb{E}[u(X)] = \frac{1}{2} \ln 100 + \frac{1}{2} \ln 25 = \ln(100^{1/2} \cdot 25^{1/2}) = \ln(\sqrt{2500}) = \ln 50$.
- *Equivalente cierto*: $c(X)$ resuelve $\ln c = \ln 50$, es decir, $c(X) = 50$. (Para utilidad logarítmica, el equivalente cierto es la *media geométrica* de los pagos.)
- *Prima de riesgo*: $\rho(X) = 62.5 - 50 = 12.5$.

Verificación de Jensen: $u(\mathbb{E}[X]) = \ln 62.5 \approx 4.135 > \ln 50 \approx 3.912 = \mathbb{E}[u(X)]$. El agente sacrifica hasta 12.5 soles de valor esperado con tal de eliminar el riesgo: un asegurador neutral al riesgo puede ofrecerle un contrato que ambos prefieren.

Coefficientes de Arrow–Pratt. ¿Cómo medir *cuánta* aversión al riesgo tiene un agente? La curvatura de u es la candidata natural ($u'' \leq 0$ es concavidad, como veremos en la Sección 5.6), pero u'' sola no sirve como medida: la utilidad esperada es invariante a transformaciones afines positivas ($u \mapsto au + b$ con $a > 0$ representa las mismas preferencias), y u'' cambia con a . La normalización correcta divide por u' :

Definición 5.11 (Coefficientes de Arrow–Pratt). Sea u dos veces diferenciable con $u' > 0$. El *coeficiente de aversión absoluta al riesgo* (*absolute risk aversion*) en la riqueza x es

$$A(x) := -\frac{u''(x)}{u'(x)},$$

y el *coeficiente de aversión relativa al riesgo* (*relative risk aversion*) es

$$R(x) := -\frac{x u''(x)}{u'(x)} = x A(x).$$

Ambos son invariantes a transformaciones afines positivas de u (el factor a se cancela en el cociente), y $A(x) \geq 0$ exactamente donde u es cóncava. Una aproximación de Taylor (que verás en Microeconomía) muestra que para riesgos pequeños la prima de riesgo es aproximadamente $\rho \approx \frac{1}{2} A(x) \sigma^2$, donde σ^2 es la varianza de la lotería: A mide, literalmente, cuánta prima por unidad de varianza.

Ejemplo 5.12 (CARA y CRRA, cálculo completo). Las dos familias de utilidades más usadas en macro, finanzas y contratos:

(a) *CARA (aversión absoluta constante)*: $u(x) = -e^{-\alpha x}$ con $\alpha > 0$. Calculamos las derivadas paso a paso:

$$u'(x) = -e^{-\alpha x} \cdot (-\alpha) = \alpha e^{-\alpha x} > 0, \quad u''(x) = \alpha e^{-\alpha x} \cdot (-\alpha) = -\alpha^2 e^{-\alpha x} < 0.$$

(Cóncava en todo $\mathbb{R}$, por el criterio de segundo orden.) Entonces

$$A(x) = -\frac{u''(x)}{u'(x)} = -\frac{-\alpha^2 e^{-\alpha x}}{\alpha e^{-\alpha x}} = \alpha \quad \text{constante}, \quad R(x) = \alpha x.$$

La aversión absoluta no depende de la riqueza: un agente CARA paga la misma prima por un riesgo aditivo sea rico o pobre. Por eso CARA es la utilidad estándar en modelos de contratos y riesgo moral (MWG, cap. 14): combinada con ruido normal produce el famoso equivalente cierto “media menos $\frac{\alpha}{2}$ varianza”.

(b) *CRRA (aversión relativa constante)*: $u(x) = \frac{x^{1-\gamma}}{1-\gamma}$ para $\gamma > 0$, $\gamma \neq 1$, con $x > 0$ (y $u(x) = \ln x$ para $\gamma = 1$, que es el límite de $(x^{1-\gamma} - 1)/(1-\gamma)$ cuando $\gamma \rightarrow 1$; restar la constante $1/(1-\gamma)$ no cambia las preferencias). Derivamos:

$$u'(x) = \frac{(1-\gamma)x^{-\gamma}}{1-\gamma} = x^{-\gamma} > 0, \quad u''(x) = -\gamma x^{-\gamma-1} < 0.$$

Entonces

$$A(x) = -\frac{-\gamma x^{-\gamma-1}}{x^{-\gamma}} = \frac{\gamma}{x}, \quad R(x) = x \cdot \frac{\gamma}{x} = \gamma \quad \text{constante}.$$

La aversión *relativa* es constante: el agente paga la misma *fracción* de su riqueza por evitar un riesgo *proporcional* a su riqueza, sea rico o pobre. Para $\gamma = 1$ ($u = \ln$): $u' = 1/x$, $u'' = -1/x^2$, $A(x) = 1/x$, $R(x) = 1$, consistente con el límite. Comprueba que en el Ejemplo 5.10 el agente tenía $R \equiv 1$.

Intuición

El puente completo, de la geometría a la economía: *cuerda por debajo del grafo* (concavidad) $\Rightarrow$ *la función del promedio supera al promedio de la función* (Jensen) $\Rightarrow$ *lo seguro se prefiere a lo aleatorio* (aversión al riesgo) $\Rightarrow$ *existe una prima positiva por eliminar riesgo* (mercados de seguros, trade-off seguro-incentivos en contratos). Cada flecha de esta cadena es un teorema de este capítulo. Cuando en Microeconomía te digan “suponga u cóncava”, debes *ver* la cuerda bajo el grafo y *oír* “el agente odia la varianza”.

5.3. Epígrafo, hipografo y conjuntos de nivel [P1]

Esta sección conecta el capítulo con los anteriores: toda la teoría de *funciones* convexas puede reducirse a la teoría de *conjuntos* convexos mirando el conjunto de puntos que están *sobre* el grafo.

Definición 5.13 (Epígrafo e hipógrafo). Sea $f : C \rightarrow \mathbb{R}$ con $C \subseteq \mathbb{R}^n$. El *epígrafo* (*epigraph*, “lo que está sobre el grafo”) de f es el subconjunto de $\mathbb{R}^{n+1}$

$$\text{epi } f = \{ (x, t) \in C \times \mathbb{R} : t \geq f(x) \},$$

y el *hipógrafo* (*hypograph*) es $\text{hyp } f = \{ (x, t) \in C \times \mathbb{R} : t \leq f(x) \}$.

Piensa en el grafo de f como una “superficie” en $\mathbb{R}^{n+1}$: el epígrafo es todo lo que queda encima (incluyendo la superficie), el hipógrafo todo lo que queda debajo. Para $f(x) = x^2$, el epígrafo es la región interior de la parábola (hacia arriba); para una función de producción f cóncava, el hipógrafo $\{ (x, q) : q \leq f(x) \}$ es, salvo signos de convención, el *conjunto de producción*: los pares insumo–producto factibles.

Teorema 5.14 (Caracterización por el epígrafo). Sea $C \subseteq \mathbb{R}^n$ convexo y $f : C \rightarrow \mathbb{R}$. Entonces:

$$f \text{ es convexa} \iff \text{epi } f \text{ es un conjunto convexo de } \mathbb{R}^{n+1}.$$

Análogamente, f es cóncava si y solo si su hipógrafo es convexo.

Demostración. $(\Rightarrow)$ Supongamos f convexa. Tomemos dos puntos del epígrafo, (x, s) y (y, t) con $x, y \in C$, $s \geq f(x)$, $t \geq f(y)$, y un peso $\lambda \in [0, 1]$. Debemos ver que la combinación convexa

$$(1 - \lambda)(x, s) + \lambda(y, t) = ((1 - \lambda)x + \lambda y, (1 - \lambda)s + \lambda t)$$

también está en $\text{epi } f$. Su primera componente está en C (porque C es convexo). Para la segunda, encadenamos dos desigualdades: primero la convexidad de f , y luego las cotas $s \geq f(x)$, $t \geq f(y)$ multiplicadas por los pesos no negativos $(1 - \lambda)$ y λ :

$$f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y) \leq (1 - \lambda)s + \lambda t.$$

Es decir, la segunda componente del punto combinado está por encima de f evaluada en la primera componente: el punto está en $\text{epi } f$. Luego $\text{epi } f$ es convexo.

$(\Leftarrow)$ Supongamos $\text{epi } f$ convexo. Tomemos $x, y \in C$ y $\lambda \in [0, 1]$. Los puntos $(x, f(x))$ y $(y, f(y))$ están en $\text{epi } f$ (con igualdad $t = f$). Por convexidad del epígrafo, su combinación

$$((1 - \lambda)x + \lambda y, (1 - \lambda)f(x) + \lambda f(y)) \in \text{epi } f,$$

y pertenecer al epígrafo significa, por definición, que la segunda coordenada domina a f de la primera:

$$(1 - \lambda)f(x) + \lambda f(y) \geq f((1 - \lambda)x + \lambda y),$$

que es exactamente la convexidad de f . La afirmación para cóncavas se obtiene aplicando lo anterior a $-f$ y observando que $\text{hyp } f = \{ (x, t) : (x, -t) \in \text{epi}(-f) \}$, y que la aplicación $(x, t) \mapsto (x, -t)$ es lineal y por tanto preserva convexidad de conjuntos. $\square$

Intuición

Este teorema es un *diccionario*: cada teorema sobre conjuntos convexos se puede intentar traducir a funciones vía el epígrafo, y viceversa. Ejemplos que veremos: la intersección de convexos es convexa $\leftrightarrow$ el supremo de funciones convexas es convexo (Teorema 5.33, porque el epígrafo del supremo es la intersección de los epígrafos); los hiperplanos soporte de $\text{epi } f \leftrightarrow$ las tangentes/subgradiientes que minoran a f (capítulo de subdiferenciales). En economía: “función de producción cóncava” $\leftrightarrow$ “conjunto de producción convexo”, que es la hipótesis de los teoremas del bienestar. El puente conjuntos–funciones no es una curiosidad: es el método de trabajo del análisis convexo.

5.3.1. Conjuntos de nivel inferior

Definición 5.15 (Conjunto de nivel inferior). Para $f : C \rightarrow \mathbb{R}$ y $\alpha \in \mathbb{R}$, el *conjunto de nivel inferior* (*sublevel set*) de altura α es

$$S_\alpha(f) = \{x \in C : f(x) \leq \alpha\}.$$

El *conjunto de contorno superior* (*upper level set* o *upper contour set*) es $U_\alpha(f) = \{x \in C : f(x) \geq \alpha\}$; para una utilidad u , $U_\alpha(u)$ es el conjunto de canastas “al menos tan buenas como” el nivel α .

Proposición 5.16. Si f es convexa, todos sus conjuntos de nivel inferior $S_\alpha(f)$ son convexos. Si f es cóncava, todos sus conjuntos de contorno superior $U_\alpha(f)$ son convexos.

Demostración. Sean $x, y \in S_\alpha(f)$, es decir, $f(x) \leq \alpha$ y $f(y) \leq \alpha$, y sea $\lambda \in [0, 1]$. Por convexidad de f y luego por las dos cotas:

$$f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y) \leq (1 - \lambda)\alpha + \lambda\alpha = \alpha.$$

Luego $(1 - \lambda)x + \lambda y \in S_\alpha(f)$, y $S_\alpha(f)$ es convexo. Para f cóncava, aplica lo anterior a $-f$ con nivel $-\alpha$: $U_\alpha(f) = S_{-\alpha}(-f)$. $\square$

Cuidado (error común)

El recíproco es falso, y confundirse aquí cuesta puntos en los exámenes de micro. Que *todos* los conjuntos de nivel inferior sean convexos **no** implica que la función sea convexa. Contraejemplo: $f(x) = x^3$ en $\mathbb{R}$. Sus conjuntos de nivel inferior son

$$S_\alpha = \{x : x^3 \leq \alpha\} = (-\infty, \alpha^{1/3}],$$

siempre un intervalo, siempre convexo. Pero x^3 *no* es convexa: con $x = -1$, $y = 0$ y $\lambda = 1/2$, el lado izquierdo de (5.1) es $f(-1/2) = -1/8$ y el derecho es $\frac{1}{2}(-1) + \frac{1}{2}(0) = -1/2$; como $-1/8 > -1/2$, la desigualdad falla. (También: $f''(x) = 6x < 0$ para $x < 0$.) Las funciones cuyos conjuntos de nivel inferior son todos convexos se llaman *cuasiconvexas* (*quasiconvex*), y las de contornos superiores convexos, *cuasicóncavas*: son una clase es-

trictamente más grande que estudiaremos en el capítulo correspondiente. En micro esto importa muchísimo: las preferencias convexas piden utilidad *cuasicóncava*, no cóncava; la concavidad es más fuerte y no es una propiedad ordinal.

5.4. Funciones con valores extendidos e indicatriz [P2]

Esta sección introduce una convención que al principio parece extraña pero que simplifica enormemente el análisis convexo moderno: permitir que las funciones tomen el valor $+\infty$.

Motivación. Considera el problema de minimizar $f(x)$ sujeto a $x \in C$. Son dos objetos: una función y una restricción. La convención de valores extendidos los funde en uno solo: define

$$\tilde{f}(x) = \begin{cases} f(x) & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

Minimizar $\tilde{f}$ sobre *todo* $\mathbb{R}^n$ es lo mismo que minimizar f sobre C : los puntos fuera de C tienen valor $+\infty$ y jamás serán elegidos por un minimizador. La restricción quedó “codificada” dentro de la función. Esto permite enunciar teoremas una sola vez, sin arrastrar el dominio como objeto aparte.

Definición 5.17 (Función extendida, dominio efectivo, función propia). Una *función con valores extendidos* es una función $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$. Su *dominio efectivo* (*effective domain*) es

$$\text{dom } f = \{x \in \mathbb{R}^n : f(x) < +\infty\},$$

los puntos donde f toma valores reales. Decimos que f es *convexa* si la desigualdad (5.1) vale para todos $x, y \in \mathbb{R}^n$, con las convenciones aritméticas naturales ($t + \infty = \infty$, $\lambda \cdot \infty = \infty$ para $\lambda > 0$, $0 \cdot \infty = 0$). Equivalentemente, f es convexa si $\text{epi } f$ es convexo. Una función convexa es *propia* (*proper*) si no es idénticamente $+\infty$, es decir, si $\text{dom } f \neq \emptyset$.

Observación 5.18. Si f es convexa en el sentido extendido, entonces $\text{dom } f$ es un conjunto convexo. En efecto, si $x, y \in \text{dom } f$ (valores finitos), la desigualdad de convexidad da $f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y) < +\infty$, así que el punto intermedio también está en $\text{dom } f$. La convención de $+\infty$ no crea dominios raros: automáticamente son convexos.

Definición 5.19 (Función indicatriz). La *función indicatriz* (*indicator function*) de un conjunto $C \subseteq \mathbb{R}^n$ es

$$\delta_C(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

Proposición 5.20. δ_C es convexa si y solo si C es convexo. Además, si $C \neq \emptyset$, para cualquier $f : \mathbb{R}^n \rightarrow \mathbb{R}$,

$$\min_{x \in C} f(x) \quad y \quad \min_{x \in \mathbb{R}^n} [f(x) + \delta_C(x)]$$

tienen el mismo valor óptimo y los mismos minimizadores.

Demostración. Para la primera parte: el epígrafo de δ_C es $\text{epi } \delta_C = \{(x, t) : x \in C, t \geq 0\} = C \times [0, \infty)$, un producto cartesiano. Un producto cartesiano es convexo si y solo si cada factor lo es ($[0, \infty)$ es convexo siempre), así que $\text{epi } \delta_C$ es convexo si y solo si C lo es; por el Teorema 5.14 (en su versión extendida), eso equivale a la convexidad de δ_C . Para la segunda parte: si $x \in C$, $f(x) + \delta_C(x) = f(x) + 0 = f(x)$; si $x \notin C$, $f(x) + \delta_C(x) = +\infty$, que nunca es mínimo si $C \neq \emptyset$. Los dos problemas coinciden punto a punto donde importa. $\square$

Observación 5.21 (Cuidado con el nombre). No confundas la *indicatriz* del análisis convexo (0 dentro, $+\infty$ fuera) con la *indicadora* de probabilidad ($\mathbf{1}_C$: 1 dentro, 0 fuera). Son objetos distintos con nombres parecidos; la de aquí está diseñada para que *sumarla* imponga la restricción $x \in C$ en problemas de minimización.

Esta maquinaria reaparecerá en el capítulo de subdiferenciales y dualidad: por ejemplo, la función soporte de la Sección 5.9 resulta ser la *conjugada* de la indicatriz. Por ahora, basta con que la convención de $+\infty$ te resulte natural. En adelante, cuando digamos “sea f convexa” sin especificar dominio, permitimos valores extendidos y $\text{dom } f$ es su dominio efectivo (puedes ver [6], sec. 2.4, y [1]).

5.5. Caracterización de primer orden [P1]

Si f es diferenciable, la convexidad se puede leer en el *gradiente*. La idea geométrica: en una función convexa, el plano tangente en cualquier punto queda *por debajo* del grafo en todas partes. La tangente es la mejor aproximación lineal local; para una convexa, esa aproximación es además una *cota inferior global*.

Teorema 5.22 (Caracterización de primer orden). *Sea $C \subseteq \mathbb{R}^n$ convexo y abierto, y $f : C \rightarrow \mathbb{R}$ diferenciable. Entonces f es convexa en C si y solo si*

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle \quad \text{para todos } x, y \in C. \quad (5.2)$$

Además, f es estrictamente convexa si y solo si la desigualdad es estricta siempre que $y \neq x$. Para f cóncava, la desigualdad se invierte: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle$.

Antes de la demostración, entendamos qué dice. El lado derecho de (5.2) es la *aproximación de Taylor de primer orden* de f centrada en x , es decir, el hiperplano tangente al grafo en $(x, f(x))$. El teorema afirma que para una función convexa esa tangente *subestima* a f en todo el dominio, no solo cerca de x : una información local (el gradiente en un punto) produce una cota global. Esta es la propiedad que hace que en optimización convexa las condiciones de primer orden sean *suficientes* para optimalidad global, como veremos más adelante en el curso.

Demostración. La estrategia es clásica y debes dominarla: primero el caso $n = 1$, y luego el caso general *restringiendo f a rectas*.

Paso 1: caso $n = 1$. Sea $f : I \rightarrow \mathbb{R}$ diferenciable en un intervalo abierto I .

($\Rightarrow$) Supongamos f convexa y sean $x, y \in I$ con $x \neq y$. Para $\lambda \in (0, 1]$, la convexidad en el punto $x + \lambda(y - x) = (1 - \lambda)x + \lambda y$ da

$$f(x + \lambda(y - x)) \leq (1 - \lambda)f(x) + \lambda f(y) = f(x) + \lambda(f(y) - f(x)).$$

Restamos $f(x)$ y dividimos entre $\lambda > 0$:

$$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \leq f(y) - f(x).$$

El lado izquierdo, multiplicando y dividiendo por $(y - x)$, es

$$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda(y - x)} (y - x),$$

y cuando $\lambda \downarrow 0$ el cociente converge, por definición de derivada (con incremento $h = \lambda(y - x) \rightarrow 0$), a $f'(x)$. Tomando el límite en la desigualdad (los límites preservan desigualdades no estrictas):

$$f'(x)(y - x) \leq f(y) - f(x),$$

que es exactamente (5.2) en una dimensión.

($\Leftarrow$) Supongamos ahora que $f(y) \geq f(x) + f'(x)(y - x)$ para todos $x, y \in I$. Sean $u, v \in I$, $\lambda \in (0, 1)$, y llamemos $z = (1 - \lambda)u + \lambda v$ al punto intermedio. Aplicamos la hipótesis *dos veces*, *ambas centradas en z* : una vez con $y = u$ y otra con $y = v$:

$$f(u) \geq f(z) + f'(z)(u - z), \quad (5.3)$$

$$f(v) \geq f(z) + f'(z)(v - z). \quad (5.4)$$

Multiplicamos (5.3) por $(1 - \lambda) \geq 0$ y (5.4) por $\lambda \geq 0$ (multiplicar por números no negativos preserva el sentido) y sumamos:

$$(1 - \lambda)f(u) + \lambda f(v) \geq f(z) + f'(z)[(1 - \lambda)(u - z) + \lambda(v - z)].$$

El corchete es cero: $(1 - \lambda)u + \lambda v - [(1 - \lambda) + \lambda]z = z - z = 0$. Queda $(1 - \lambda)f(u) + \lambda f(v) \geq f(z)$, la definición de convexidad. Observa la belleza del argumento: las dos tangentes en z “levantan” la cuerda por encima del grafo.

Paso 2: caso general por restricción a rectas. La herramienta es la siguiente equivalencia, útil por sí misma: f es convexa en C si y solo si su restricción a cada recta es convexa; formalmente, si y solo si para todos $x, y \in C$ la función de una variable

$$\varphi_{x,y}(\lambda) := f(x + \lambda(y - x)), \quad \lambda \in [0, 1],$$

es convexa. La equivalencia es directa: la desigualdad de convexidad de f entre x e y con peso λ es exactamente la desigualdad de convexidad de $\varphi_{x,y}$ entre 0 y 1 con peso λ ; y recíprocamente, cualquier par de puntos de un segmento en C vive en una de estas rectas. (Verifica el detalle: si $s, t \in [0, 1]$ y $\mu \in [0, 1]$, entonces $\varphi_{x,y}((1 - \mu)s + \mu t)$ es f evaluada en la combinación con peso μ de los puntos $x + s(y - x)$ y $x + t(y - x)$.)

Por la regla de la cadena, $\varphi_{x,y}$ es diferenciable con

$$\varphi'_{x,y}(\lambda) = \langle \nabla f(x + \lambda(y - x)), y - x \rangle.$$

($\Rightarrow$) Si f es convexa, cada $\varphi_{x,y}$ es convexa y diferenciable en una variable; por el Paso 1 aplicado en $\lambda = 0$ con punto de comparación 1:

$$\varphi_{x,y}(1) \geq \varphi_{x,y}(0) + \varphi'_{x,y}(0)(1-0),$$

que traducido es $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$: obtuvimos (5.2).

($\Leftarrow$) Si vale (5.2), fijamos x, y y probamos que $\varphi := \varphi_{x,y}$ satisface la desigualdad de primer orden del Paso 1. Sean $\lambda, \mu \in [0, 1]$, y llamemos $x_\lambda = x + \lambda(y - x)$, $x_\mu = x + \mu(y - x)$. Aplicando (5.2) a los puntos x_λ (centro) y x_μ :

$$f(x_\mu) \geq f(x_\lambda) + \langle \nabla f(x_\lambda), x_\mu - x_\lambda \rangle = f(x_\lambda) + (\mu - \lambda) \langle \nabla f(x_\lambda), y - x \rangle,$$

donde usamos $x_\mu - x_\lambda = (\mu - \lambda)(y - x)$. En notación de φ : $\varphi(\mu) \geq \varphi(\lambda) + \varphi'(\lambda)(\mu - \lambda)$. Por el Paso 1 ($\Leftarrow$), φ es convexa; como esto vale para todos x, y , f es convexa.

Caso estricto. Si f es estrictamente convexa y $y \neq x$, repetimos ($\Rightarrow$) con más cuidado: por convexidad estricta en $\lambda = 1/2$,

$$f\left(\frac{x+y}{2}\right) < \frac{1}{2}f(x) + \frac{1}{2}f(y),$$

y aplicando (5.2) (la versión no estricta, ya demostrada) entre x y el punto medio:

$$f\left(\frac{x+y}{2}\right) \geq f(x) + \left\langle \nabla f(x), \frac{x+y}{2} - x \right\rangle = f(x) + \frac{1}{2} \langle \nabla f(x), y - x \rangle.$$

Combinando ambas: $f(x) + \frac{1}{2} \langle \nabla f(x), y - x \rangle < \frac{1}{2}f(x) + \frac{1}{2}f(y)$, y multiplicando por 2 y reordenando, $f(y) > f(x) + \langle \nabla f(x), y - x \rangle$: la desigualdad estricta. Recíprocamente, si la desigualdad de primer orden es estricta para $y \neq x$, el argumento del Paso 1 ($\Leftarrow$) con las desigualdades (5.3)–(5.4) estrictas (nota que $u \neq z \neq v$ cuando $u \neq v$ y $\lambda \in (0, 1)$) produce convexidad estricta. $\square$

Intuición

“La tangente subestima.” En términos económicos: si u es una utilidad cóncava y la linealizas alrededor de x (como se hace al aproximar), la versión cóncava de (5.2) dice $u(y) \leq u(x) + \langle \nabla u(x), y - x \rangle$: la linealización sobreestima la utilidad verdadera en cualquier otro punto. Un planificador que evalúe políticas con una aproximación lineal de una utilidad cóncava será sistemáticamente demasiado optimista. La misma desigualdad, leída al revés, es la que hace globales a las condiciones de primer orden: si $\nabla f(x^*) = 0$ en una convexa, entonces $f(y) \geq f(x^*) + 0$ para todo y : todo punto crítico es mínimo global. Esa sola frase justifica el curso entero.

Ejemplo 5.23 (Uso directo). Sabemos que e^x es convexa. La tangente en $x = 0$ es $e^0 + e^0(y - 0) = 1 + y$. El teorema da, gratis, la desigualdad global

$$e^y \geq 1 + y \quad \text{para todo } y \in \mathbb{R},$$

con igualdad solo en $y = 0$ (convexidad estricta). Análogamente, la concavidad de $\ln$ con tangente

en $x = 1$ da $\ln y \leq y - 1$ para todo $y > 0$. Estas dos desigualdades aparecen una y otra vez en teoría de la información, en estimación y en macro; ahora sabes de dónde salen: son la “tangente que subestima/sobreestima”.

Observación 5.24 (Monotonía del gradiente). Sumando (5.2) escrita en (x, y) y en (y, x) :

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle, \quad f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle,$$

se cancelan $f(x) + f(y)$ y queda $0 \geq \langle \nabla f(x) - \nabla f(y), y - x \rangle$, es decir,

$$\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0 \quad \text{para todos } x, y \in C.$$

Esta propiedad se llama *monotonía* del gradiente: en una dimensión dice simplemente que f' es no decreciente. También es equivalente a la convexidad (no lo probamos aquí; puedes ver [6], sec. 2.5). En micro, la monotonía del gradiente de la función de beneficio es la *ley de la oferta*: los cambios de precios y los cambios de la oferta neta “van en la misma dirección”.

5.6. Caracterización de segundo orden [P1]

Para funciones dos veces diferenciables, la convexidad se lee en la *Hessiana*. Este es, en la práctica, el criterio que usarás en el 90 % de los ejercicios. Recuerda del capítulo de preliminares: la Hessiana $\nabla^2 f(x)$ es la matriz simétrica de segundas derivadas $[\partial^2 f / \partial x_i \partial x_j]$; una matriz simétrica A es *semidefinida positiva* (PSD, $A \succeq 0$) si $\langle v, Av \rangle \geq 0$ para todo v , y *definida positiva* (PD, $A \succ 0$) si $\langle v, Av \rangle > 0$ para todo $v \neq 0$; los criterios por menores: PD equivale a menores principales líderes todos positivos (Sylvester), y PSD equivale a *todos* los menores principales (no solo los líderes) no negativos.

Teorema 5.25 (Caracterización de segundo orden). Sea $C \subseteq \mathbb{R}^n$ convexo y abierto, y $f : C \rightarrow \mathbb{R}$ de clase C^2 . Entonces:

- (I) f es convexa en C si y solo si $\nabla^2 f(x) \succeq 0$ (PSD) para todo $x \in C$.
- (II) Si $\nabla^2 f(x) \succ 0$ (PD) para todo $x \in C$, entonces f es estrictamente convexa. **El recíproco es falso.**

Para concavidad: f es cóncava sii $\nabla^2 f(x) \preceq 0$ (NSD) en todo C , y Hessiana ND en todo punto implica estrictamente cóncava.

Demostración. Como en el teorema anterior, todo se reduce a una variable por rectas. Fijemos $x \in C$ y una dirección $v \in \mathbb{R}^n$, y consideremos $\varphi(\lambda) = f(x + \lambda v)$ para los λ tales que $x + \lambda v \in C$ (un intervalo abierto que contiene a 0, porque C es abierto). Por la regla de la cadena aplicada dos veces:

$$\varphi'(\lambda) = \langle \nabla f(x + \lambda v), v \rangle, \quad \varphi''(\lambda) = \langle v, \nabla^2 f(x + \lambda v) v \rangle.$$

La segunda igualdad merece un comentario: derivar $\langle \nabla f(x + \lambda v), v \rangle = \sum_i \partial_i f(x + \lambda v) v_i$ respecto de λ da $\sum_i \sum_j \partial_{ij}^2 f(x + \lambda v) v_j v_i$, que es la forma cuadrática de la Hessiana en v .

($\Leftarrow$ de (i)) Supongamos $\nabla^2 f \succeq 0$ en todo C . Entonces $\varphi''(\lambda) = \langle v, \nabla^2 f(x + \lambda v) v \rangle \geq 0$ en su intervalo. Usamos el teorema de Taylor con resto de Lagrange (preliminares): para λ en el

intervalo existe θ entre 0 y λ tal que

$$\varphi(\lambda) = \varphi(0) + \varphi'(0)\lambda + \frac{1}{2}\varphi''(\theta)\lambda^2 \geq \varphi(0) + \varphi'(0)\lambda,$$

porque el término de segundo orden es ≥ 0 . Traducido con $y = x + \lambda v$ (es decir, $v = y - x$, $\lambda = 1$, tomando cualquier $y \in C$; el segmento $[x, y]$ está en C por convexidad):

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle.$$

Es la caracterización de primer orden (5.2), y por el Teorema 5.22, f es convexa.

($\Rightarrow$ de (i)) Supongamos f convexa y, por contradicción, que existe $x \in C$ y $v \neq 0$ con $\langle v, \nabla^2 f(x) v \rangle < 0$. Como f es C^2 , la función $\lambda \mapsto \langle v, \nabla^2 f(x + \lambda v) v \rangle$ es continua, así que $\varphi'' < 0$ en todo un intervalo $(-\varepsilon, \varepsilon)$. Por Taylor centrado en 0 con resto en $\theta \in (0, \lambda)$, para $0 < \lambda < \varepsilon$:

$$\varphi(\lambda) = \varphi(0) + \varphi'(0)\lambda + \frac{1}{2}\varphi''(\theta)\lambda^2 < \varphi(0) + \varphi'(0)\lambda,$$

lo que viola la desigualdad de primer orden (5.2) entre x y $y = x + \lambda v$ (que la convexidad garantiza). Contradicción; luego la Hessiana es PSD en todo punto.

(ii) Si $\nabla^2 f \succ 0$ en todo C y $y \neq x$, el mismo Taylor da, con $v = y - x \neq 0$,

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle y - x, \nabla^2 f(z)(y - x) \rangle$$

para algún z en el segmento $(x, y) \subseteq C$; el último término es estrictamente positivo por PD, así que $f(y) > f(x) + \langle \nabla f(x), y - x \rangle$, y por la parte estricta del Teorema 5.22, f es estrictamente convexa. $\square$

Cuidado (error común)

Estrictamente convexa NO implica Hessiana definida positiva. El contraejemplo canónico es $f(x) = x^4$ en $\mathbb{R}$: es estrictamente convexa (verifícalo: su derivada $f'(x) = 4x^3$ es estrictamente creciente, lo que en una variable equivale a convexidad estricta; o hazlo desde la definición), pero $f''(x) = 12x^2$ se *anula* en $x = 0$: allí la Hessiana es solo PSD, no PD. La lógica correcta es:

$$\nabla^2 f \succ 0 \text{ en todo punto} \implies f \text{ estrictamente convexa} \implies \nabla^2 f \succeq 0 \text{ en todo punto},$$

y ninguna flecha se invierte. En los exámenes: para *probar* convexidad estricta basta PD en todo punto; pero si la Hessiana es PD salvo en puntos aislados, no concluyas que falla la estrictez (puede cumplirse igual, como en x^4) ni tampoco que se cumple: hay que mirar más fino.

5.6.1. Ejemplos resueltos con Hessiana y menores

Ejemplo 5.26 (Función cuadrática). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(x) = \frac{1}{2} x^\top Q x + b^\top x + c,$$

con Q simétrica ($n \times n$), $b \in \mathbb{R}^n$, $c \in \mathbb{R}$. Calculemos el gradiente componente a componente: $f(x) = \frac{1}{2} \sum_{i,j} Q_{ij} x_i x_j + \sum_i b_i x_i + c$, y derivando respecto de x_k (usando la simetría $Q_{ij} = Q_{ji}$ para juntar los dos términos donde aparece x_k):

$$\frac{\partial f}{\partial x_k} = \frac{1}{2} \left(\sum_j Q_{kj} x_j + \sum_i Q_{ik} x_i \right) + b_k = \sum_j Q_{kj} x_j + b_k,$$

es decir, $\nabla f(x) = Qx + b$. Derivando otra vez, $\nabla^2 f(x) = Q$ para todo x : la Hessiana es constante. Por el Teorema 5.25:

$$f \text{ es convexa} \iff Q \succeq 0, \quad f \text{ es estrictamente convexa} \iff Q \succ 0.$$

(Para cuadráticas sí vale el “si y solo si” en el caso estricto: si Q no es PD, existe $v \neq 0$ con $v^\top Q v \leq 0$, y sobre la recta $\{x + \lambda v\}$ la función es afín o cóncava en λ , matando la estrictez.) Caso numérico: $Q = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$. Menores principales líderes: $\Delta_1 = 2 > 0$, $\Delta_2 = \det Q = 2 \cdot 3 - 1 \cdot 1 = 5 > 0$; por Sylvester, $Q \succ 0$ y f es estrictamente convexa en todo $\mathbb{R}^2$.

Ejemplo 5.27 (Cobb–Douglas: concavidad sii rendimientos no crecientes). Sea $f : \mathbb{R}_{++}^2 \rightarrow \mathbb{R}$ (el ortante abierto positivo, que es convexo y abierto),

$$f(x, y) = x^a y^b, \quad a, b > 0.$$

Afirmación: f es cóncava en $\mathbb{R}_{++}^2$ si y solo si $a + b \leq 1$ (con $a, b > 0$); es decir, exactamente cuando los rendimientos a escala son no crecientes.

Cálculo de las derivadas. Primeras:

$$f_x = a x^{a-1} y^b, \quad f_y = b x^a y^{b-1}.$$

Segundas (deriva otra vez, con cuidado en los exponentes):

$$f_{xx} = a(a-1) x^{a-2} y^b, \quad f_{yy} = b(b-1) x^a y^{b-2}, \quad f_{xy} = f_{yx} = ab x^{a-1} y^{b-1}.$$

La Hessiana es

$$\nabla^2 f(x, y) = \begin{pmatrix} a(a-1) x^{a-2} y^b & ab x^{a-1} y^{b-1} \\ ab x^{a-1} y^{b-1} & b(b-1) x^a y^{b-2} \end{pmatrix}.$$

Criterio para NSD en 2×2 (preliminares): una matriz simétrica 2×2 es semidefinida negativa si y solo si sus elementos diagonales son ≤ 0 y su determinante es ≥ 0 (equivalentemente: todos los menores principales de orden 1 son ≤ 0 y el de orden 2 es ≥ 0).

Menores de orden 1 (la diagonal). Como $x, y > 0$, los factores $x^{a-2} y^b$ y $x^a y^{b-2}$ son positivos, así que

$$f_{xx} \leq 0 \iff a(a-1) \leq 0 \iff a \leq 1, \quad f_{yy} \leq 0 \iff b \leq 1.$$

Menor de orden 2 (el determinante). Calculamos:

$$\begin{aligned}\det \nabla^2 f &= a(a-1)x^{a-2}y^b \cdot b(b-1)x^a y^{b-2} - (abx^{a-1}y^{b-1})^2 \\ &= ab(a-1)(b-1)x^{2a-2}y^{2b-2} - a^2b^2x^{2a-2}y^{2b-2} \\ &= abx^{2a-2}y^{2b-2}[(a-1)(b-1) - ab].\end{aligned}$$

Expandimos el corchete: $(a-1)(b-1) - ab = ab - a - b + 1 - ab = 1 - a - b$. Por lo tanto,

$$\det \nabla^2 f(x, y) = abx^{2a-2}y^{2b-2}(1 - a - b),$$

y como $abx^{2a-2}y^{2b-2} > 0$ en $\mathbb{R}_{++}^2$,

$$\det \nabla^2 f \geq 0 \iff a + b \leq 1.$$

Conclusión. Si $a + b \leq 1$ (y $a, b > 0$, que fuerza $a \leq 1$ y $b \leq 1$ automáticamente, pues $a \leq a + b \leq 1$), los tres menores cumplen las condiciones y la Hessiana es NSD en todo punto de $\mathbb{R}_{++}^2$: f es cóncava. Recíprocamente, si $a + b > 1$, el determinante es negativo en todo punto; una matriz 2×2 con determinante negativo tiene un valor propio positivo y uno negativo (indefinida), así que la Hessiana no es NSD y f no es cóncava (existe una dirección de curvatura positiva). Si además $a + b < 1$, se puede comprobar que la Hessiana es ND (menores líderes: $f_{xx} < 0$ y $\det > 0$) y f es *estrictamente* cóncava en $\mathbb{R}_{++}^2$; con $a + b = 1$ (rendimientos constantes) el determinante es cero: la función es cóncava pero no estrictamente: es lineal a lo largo de los rayos desde el origen, como corresponde a una función homogénea de grado 1. En Microeconomía: una tecnología Cobb–Douglas da un conjunto de producción convexo exactamente cuando $a + b \leq 1$; con rendimientos crecientes ($a + b > 1$) la convexidad falla y con ella los teoremas del bienestar y la existencia de equilibrio competitivo.

Ejemplo 5.28 (Log-suma-exp y la norma). Dos miembros más del catálogo que conviene conocer:

- (a) *Log-suma-exp*: $f(x) = \ln(e^{x_1} + \dots + e^{x_n})$ es convexa en $\mathbb{R}^n$ (lo enunciamos sin demostración; la prueba calcula la Hessiana y verifica PSD usando la desigualdad de Cauchy–Schwarz; ver [2], sec. 3.1.5). Es la “suavización” del máximo: $\max_i x_i \leq f(x) \leq \max_i x_i + \ln n$, y aparece en los modelos logit de elección discreta que verás en econometría estructural: la utilidad esperada del mejor de n alternativas con choques Gumbel es exactamente un log-suma-exp.
- (b) *Normas*: toda norma en $\mathbb{R}^n$ (en particular $\|x\|$ euclidiana, $\|x\|_1$, $\|x\|_\infty$) es convexa: el argumento del Ejemplo 5.6 usa solo la desigualdad triangular y la homogeneidad absoluta, que toda norma satisface. Ninguna norma es estrictamente convexa como función (sobre un rayo desde el origen es lineal: $\|\lambda x\| = \lambda \|x\|$ para $\lambda \geq 0$). Nota que la euclidiana no es diferenciable en 0: otro ejemplo de convexa no suave.

5.7. Operaciones que preservan convexidad [P1]

Así como en el Capítulo 2 armamos un catálogo de operaciones que preservan la convexidad de *conjuntos* (intersecciones, imágenes afines, sumas), aquí armamos el catálogo para *funciones*. Es la caja de herramientas que permite certificar convexidad de funciones complicadas sin calcular una sola Hessiana. Referencia: [2], sec. 3.2.

Teorema 5.29 (Combinaciones lineales no negativas). *Si $f_1, \dots, f_m$ son convexas en un convexo C y $\alpha_1, \dots, \alpha_m \geq 0$, entonces $g = \alpha_1 f_1 + \dots + \alpha_m f_m$ es convexa en C . Si además alguna f_i con $\alpha_i > 0$ es estrictamente convexa, g es estrictamente convexa. Lo mismo vale con “cóncava” en lugar de “convexa”.*

Demostración. Basta el caso $m = 2$ (el general sale iterando). Para $x, y \in C$ y $\lambda \in [0, 1]$, aplicamos la convexidad de f_1 y de f_2 y multiplicamos por $\alpha_1, \alpha_2 \geq 0$ (lo que preserva el sentido de las desigualdades) antes de sumar:

$$\begin{aligned} g((1-\lambda)x + \lambda y) &= \alpha_1 f_1((1-\lambda)x + \lambda y) + \alpha_2 f_2((1-\lambda)x + \lambda y) \\ &\leq \alpha_1 [(1-\lambda)f_1(x) + \lambda f_1(y)] + \alpha_2 [(1-\lambda)f_2(x) + \lambda f_2(y)] \\ &= (1-\lambda)g(x) + \lambda g(y). \end{aligned}$$

Si f_1 es estrictamente convexa, $\alpha_1 > 0$, $x \neq y$ y $\lambda \in (0, 1)$, la primera desigualdad usada es estricta y la suma también. $\square$

Observación 5.30. Cuidado con lo que **no** está en el teorema: la *diferencia* de convexas no tiene por qué ser convexa ($x^2 - 2x^2 = -x^2$), ni el *producto* de convexas. A veces el producto sale bien ($x \cdot x = x^2$), pero en general falla: $f(x) = x^2$ y $g(x) = (x-1)^2$ son convexas y su producto $f(x)g(x) = x^2(x-1)^2$ no lo es, pues tiene dos mínimos (en $x = 0$ y $x = 1$) con un máximo local entre ellos. Solo pesos no negativos.

Teorema 5.31 (Composición con una función afín). *Sea A una matriz $m \times n$, $b \in \mathbb{R}^m$ y $f : \mathbb{R}^m \rightarrow \mathbb{R}$ convexa. Entonces $g(x) = f(Ax + b)$ es convexa en $\mathbb{R}^n$ (en $\{x : Ax + b \in \text{dom } f\}$, que es convexo).*

Demostración. La clave es que la aplicación afín *conmuta* con las combinaciones convexas:

$$A((1-\lambda)x + \lambda y) + b = (1-\lambda)(Ax + b) + \lambda(Ay + b) + [(1-\lambda) + \lambda]b = (1-\lambda)(Ax + b) + \lambda(Ay + b).$$

Entonces

$$g((1-\lambda)x + \lambda y) = f((1-\lambda)(Ax + b) + \lambda(Ay + b)) \leq (1-\lambda)f(Ax + b) + \lambda f(Ay + b) = (1-\lambda)g(x) + \lambda g(y),$$

usando la convexidad de f en los puntos $Ax + b$ y $Ay + b$. $\square$

Ejemplo 5.32. $g(x_1, x_2) = e^{3x_1 - 2x_2 + 1}$ es convexa: es $f(t) = e^t$ (convexa) compuesta con la afín $t = 3x_1 - 2x_2 + 1$. Igualmente, $g(x) = \|Ax - b\|$ (el error de un sistema lineal) es convexa: norma compuesta con afín. Nada de Hessianas.

5.7.1. El supremo puntual: la operación estrella

Teorema 5.33 (Supremo puntual). Sea $\{f_i\}_{i \in I}$ una familia arbitraria (finita o infinita) de funciones convexas en un convexo C . Entonces

$$g(x) = \sup_{i \in I} f_i(x)$$

es convexa en C (como función extendida: puede valer $+\infty$).

Demostración. Damos dos demostraciones, porque ambas enseñan algo.

Vía epígrafos (la elegante). Un punto (x, t) está en $\text{epi } g$ si y solo si $t \geq \sup_i f_i(x)$, si y solo si $t \geq f_i(x)$ para *todo* i , si y solo si $(x, t) \in \text{epi } f_i$ para todo i . Es decir,

$$\text{epi } g = \bigcap_{i \in I} \text{epi } f_i.$$

Cada $\text{epi } f_i$ es convexo (Teorema 5.14) y la intersección arbitraria de convexos es convexa (Capítulo 2); luego $\text{epi } g$ es convexo y g es convexa.

Vía la definición (la directa). Sean $x, y \in C$, $\lambda \in [0, 1]$. Para cada $i \in I$:

$$f_i((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f_i(x) + \lambda f_i(y) \leq (1 - \lambda)g(x) + \lambda g(y),$$

donde la segunda desigualdad usa $f_i \leq g$ punto a punto y los pesos no negativos. El lado derecho es una cota superior de $f_i((1 - \lambda)x + \lambda y)$ *uniforme en* i ; tomando supremo sobre i en el lado izquierdo (el supremo de una familia acotada por M es $\leq M$):

$$g((1 - \lambda)x + \lambda y) \leq (1 - \lambda)g(x) + \lambda g(y). \quad \square$$

Intuición

Máximo de lineales. El caso más importante del teorema: si cada $f_i(x) = \langle a_i, x \rangle + b_i$ es *afín* (convexa y cóncava a la vez), el supremo $g(x) = \sup_i \{\langle a_i, x \rangle + b_i\}$ es convexo, por muy infinita que sea la familia. Geométricamente, g es la “envolvente superior” de una familia de rectas/hiperplanos, y su grafo es un “cuenco poliédrico” (o suave, si la familia es continua). Lo notable es el recíproco, que veremos al hablar de conjugadas: *toda* función convexa (cerrada) es un supremo de afines: sus tangentes o minorantes afines. Las funciones convexas son, ni más ni menos, los supremos de familias de funciones afines. Muchísimas funciones de la economía se definen como supremos de afines en los precios: beneficio, gasto (con signo), costo... y por eso su convexidad/concavidad es *gratis*, sin supuesto alguno sobre la tecnología o las preferencias subyacentes. Este es uno de los resultados más potentes y menos apreciados de toda la microeconomía.

Ejemplo 5.34 (La función de beneficio es convexa en precios, siempre). Una empresa elige un plan de producción $y \in Y \subseteq \mathbb{R}^n$ (componentes positivas: productos; negativas: insumos) o, en la formulación con función de costo, un nivel $y \geq 0$ con costo $c(y)$. Su función de beneficio es

$$\pi(p) = \sup_y \{p \cdot y - c(y)\} \quad (\text{o } \pi(p) = \sup_{y \in Y} p \cdot y \text{ en la versión conjuntista}).$$

Afirmación: π es convexa en p sin ninguna hipótesis sobre c (ni convexidad, ni continuidad, ni nada) o sobre Y .

Demostración. Para cada y fijo, la función

$$p \mapsto p \cdot y - c(y)$$

es *afín en p* : lineal en p (con coeficiente y) más la constante $-c(y)$, que no depende de p . Entonces π es un supremo de funciones afines de p , indexadas por y , y el Teorema 5.33 concluye que π es convexa. Fin.

Nota lo que acaba de pasar: la convexidad de π en precios no dice nada sobre la tecnología; es un puro reflejo de que la empresa *optimiza*. La estructura $\sup_y \{p \cdot y - c(y)\}$ es exactamente la de la *conjugada de Fenchel* $c^*(p)$ de la función de costo, que estudiaremos en el capítulo de dualidad: la función de beneficio es la conjugada del costo. De la convexidad de π saldrá, vía diferenciabilidad, el *lema de Hotelling* ($\nabla \pi(p) = y(p)$, la oferta neta) y la ley de la oferta (monotonía del gradiente, Observación 5.24); ver MWG, cap. 5 [9].

5.7.2. Composición monótona-convexa

¿Cuándo es convexa una composición $g(x) = h(f(x))$? No siempre: composición de convexas puede fallar. Las reglas exactas:

Teorema 5.35 (Reglas de composición escalar). Sean $f : C \rightarrow \mathbb{R}$ (C convexo) y $h : D \rightarrow \mathbb{R}$ con $D \subseteq \mathbb{R}$ un intervalo que contiene a $f(C)$. Entonces $g = h \circ f$ es convexa en C si se cumple alguna de:

(I) f convexa y h convexa y no decreciente;

(II) f cóncava y h convexa y no creciente.

Y g es cóncava si:

(III) f cóncava y h cóncava y no decreciente;

(IV) f convexa y h cóncava y no creciente.

Demostración. Probamos (i); las demás son idénticas cambiando signos y sentidos. Sean $x, y \in C$, $\lambda \in [0, 1]$. Primero, la convexidad de f :

$$f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y).$$

Ahora aplicamos h a ambos lados. Aquí es donde entra la *monotonía*: como h es no decreciente, preserva la desigualdad:

$$h(f((1 - \lambda)x + \lambda y)) \leq h((1 - \lambda)f(x) + \lambda f(y)).$$

Finalmente, la *convexidad de h* aplicada a los números $f(x)$ y $f(y)$ con peso λ :

$$h((1 - \lambda)f(x) + \lambda f(y)) \leq (1 - \lambda)h(f(x)) + \lambda h(f(y)).$$

Encadenando: $g((1 - \lambda)x + \lambda y) \leq (1 - \lambda)g(x) + \lambda g(y)$. □

Cuidado (error común)

Las condiciones de monotonía no son decorativas. Si las violas, la composición puede no ser convexa aunque f y h lo sean. El contraejemplo más barato es $f(x) = x^2$ (convexa) con $h(t) = -t$, que es convexa (es afín) pero *decreciente*: la composición $h(f(x)) = -x^2$ es cóncava, no convexa. Y para que no parezca que el problema es solo el signo, toma $h(t) = (t-1)^2$, convexa pero *no monótona* (decrece en $t < 1$, crece en $t > 1$). La composición es

$$g(x) = h(f(x)) = (x^2 - 1)^2 = x^4 - 2x^2 + 1.$$

Calculamos $g''(x) = 12x^2 - 4$, que es *negativa* en el intervalo $(-1/\sqrt{3}, 1/\sqrt{3})$: g no es convexa (su grafo tiene forma de “W”, con dos mínimos en $x = \pm 1$ y un máximo local en 0). Ambas piezas eran convexas; falló la monotonía de h . Un ejemplo económico del mismo fenómeno: la utilidad indirecta compuesta con funciones no monótonas de índices de precios puede perder toda estructura de curvatura. Memoriza el eslogan de [2]: “convexa creciente de convexa es convexa; convexa decreciente de cóncava es convexa”, y verifica *siempre* la monotonía en el rango relevante.

Ejemplo 5.36. Aplicaciones de las reglas, sin Hessianas:

- (a) $g(x) = e^{\|x\|}$: $\|x\|$ convexa, e^t convexa creciente $\Rightarrow$ convexa (regla (i)).
- (b) $g(x) = \frac{1}{f(x)}$ con f cóncava y positiva: $h(t) = 1/t$ es convexa y *decreciente* en $t > 0$, y f es cóncava $\Rightarrow g$ convexa (regla (ii)). Ejemplo: $1/(xy)^{1/3}$ en $\mathbb{R}_{++}^2$ es convexa porque $(xy)^{1/3}$ es Cobb–Douglas cóncava (Ejemplo 5.27, $a + b = 2/3 \leq 1$).
- (c) $g(x) = \ln f(x)$ con f cóncava positiva: $\ln$ es cóncava creciente, f cóncava $\Rightarrow g$ cóncava (regla (iii)). Así, el logaritmo de una Cobb–Douglas cóncava es cóncavo; de hecho $\ln(x^a y^b) = a \ln x + b \ln y$ es cóncava para *todos* $a, b \geq 0$, otra muestra de que la concavidad no es ordinal.

5.7.3. Mínimo parcial

Teorema 5.37 (Minimización parcial). Sea $f : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ convexa conjuntamente en (x, y) , y sea $D \subseteq \mathbb{R}^m$ convexo no vacío. Entonces

$$g(x) = \inf_{y \in D} f(x, y)$$

es convexa en $\mathbb{R}^n$ (donde sea $> -\infty$; en general es convexa como función extendida si $g > -\infty$ en algún punto).

Demostración. Sean $x_1, x_2 \in \mathbb{R}^n$ y $\lambda \in [0, 1]$; escribamos $x_\lambda = (1 - \lambda)x_1 + \lambda x_2$. Fijemos $\varepsilon > 0$ arbitrario. Por definición de ínfimo, existen $y_1, y_2 \in D$ “casi óptimos”:

$$f(x_1, y_1) \leq g(x_1) + \varepsilon, \quad f(x_2, y_2) \leq g(x_2) + \varepsilon.$$

(Este truco del ε es necesario porque el ínfimo puede no alcanzarse.) El punto $y_\lambda = (1-\lambda)y_1 + \lambda y_2$ está en D por convexidad de D , así que es un candidato admisible en la minimización que define $g(x_\lambda)$:

$$\begin{aligned} g(x_\lambda) &\leq f(x_\lambda, y_\lambda) = f((1-\lambda)(x_1, y_1) + \lambda(x_2, y_2)) \\ &\leq (1-\lambda)f(x_1, y_1) + \lambda f(x_2, y_2) && \text{(convexidad conjunta de } f) \\ &\leq (1-\lambda)[g(x_1) + \varepsilon] + \lambda[g(x_2) + \varepsilon] && \text{(casi-optimalidad)} \\ &= (1-\lambda)g(x_1) + \lambda g(x_2) + \varepsilon. \end{aligned}$$

Como $\varepsilon > 0$ es arbitrario, tomando $\varepsilon \downarrow 0$ queda $g(x_\lambda) \leq (1-\lambda)g(x_1) + \lambda g(x_2)$. $\square$

Observación 5.38. Fíjate en el contraste entre los dos teoremas de esta sección que involucran optimización: el *supremo* de convexas es convexo *sin condiciones* sobre cómo dependen del índice (Teorema 5.33); el *ínfimo*, en cambio, exige convexidad *conjunta* en las dos variables. Un ínfimo de convexas en x (sin convexidad conjunta) puede no ser convexo: por ejemplo $g(x) = \inf_{y \in \{-1, 1\}} (x - y)^2 = (|x| - 1)^2$ no es convexa (vale 0 en $x = \pm 1$ y 1 en $x = 0$, violando la desigualdad de la cuerda entre -1 y 1); aquí falla porque $D = \{-1, 1\}$ no es convexo. En economía, el Teorema 5.37 es el que hace convexa a la *función de costo* $c(w, q) = \min_z \{w \cdot z : F(z) \geq q\}$ como función conjunta cuando el problema tiene estructura convexa, y en general está detrás de que “optimizar preserva convexidad” en la variable de parámetros.

5.8. Continuidad y diferenciabilidad de las funciones convexas [P2]

Las funciones convexas son sorprendentemente regulares: la convexidad, que es una condición puramente algebraica (una desigualdad), implica continuidad sin pedirla.

Teorema 5.39 (Continuidad en el interior). *Sea $f : C \rightarrow \mathbb{R}$ convexa, con $C \subseteq \mathbb{R}^n$ convexo. Entonces f es continua en $\text{int } C$ (el interior de C). En particular, una función convexa $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida en todo el espacio es continua en todas partes. Más aún, f es localmente Lipschitz en $\text{int } C$.*

Idea de la demostración. Damos el esqueleto del argumento (los detalles en [6], teorema 2.35, o [1]). Sea $x_0 \in \text{int } C$. **Paso 1:** f **está acotada superiormente cerca de x_0** . Como x_0 es interior, cabe un pequeño cubo (o simplex) con vértices $v_1, \dots, v_{2^n}$ alrededor de x_0 dentro de C . Todo punto x del cubo es combinación convexa de los vértices, $x = \sum_i \lambda_i v_i$, y por la desigualdad de Jensen finita (Teorema 5.8),

$$f(x) \leq \sum_i \lambda_i f(v_i) \leq \max_i f(v_i) =: M.$$

Paso 2: la cota superior fuerza una cota inferior. Para x cerca de x_0 , el punto reflejado $x' = 2x_0 - x$ también está en el cubo, y $x_0 = \frac{1}{2}x + \frac{1}{2}x'$; la convexidad da $f(x_0) \leq \frac{1}{2}f(x) + \frac{1}{2}f(x') \leq \frac{1}{2}f(x) + \frac{1}{2}M$, de donde $f(x) \geq 2f(x_0) - M$: acotada inferiormente. **Paso 3: acotación local + convexidad $\Rightarrow$ Lipschitz local.** Con f atrapada en una banda $[m, M]$ cerca de x_0 , un

argumento con cuerdas (comparar pendientes: la pendiente de una cuerda de una convexa crece con el punto base) muestra que $|f(x) - f(y)| \leq L \|x - y\|$ para una constante L que depende de $M - m$ y del radio; Lipschitz implica continuidad. $\square$

Ejemplo 5.40 (En la frontera puede fallar). La hipótesis “interior” es esencial. Sea $f : [0, 1] \rightarrow \mathbb{R}$,

$$f(x) = \begin{cases} x^2 & \text{si } 0 < x \leq 1, \\ 1 & \text{si } x = 0. \end{cases}$$

Verifiquemos que es convexa: su epígrafo es el de x^2 sobre $(0, 1]$ junto con la semirrecta $\{0\} \times [1, \infty)$, y se comprueba que la desigualdad de la cuerda se cumple (subir el valor en un *punto extremo* del dominio nunca rompe la convexidad: las cuerdas que salen de $(0, 1)$ hacia puntos (x, x^2) quedan por encima de la parábola). Pero f es discontinua en $x = 0$: $\lim_{x \downarrow 0} f(x) = 0 \neq 1 = f(0)$. La discontinuidad solo pudo ocurrir en la frontera del dominio, y solo “saltando hacia arriba”. En $\mathbb{R}^n$ con $n \geq 2$ las patologías de frontera pueden ser peores; por eso los libros trabajan con funciones convexas *cerradas* (semicontinuas inferiormente), un tecnicismo que retomaremos al hablar de conjugadas.

Observación 5.41 (Diferenciabilidad en casi todo punto). Aunque una convexa puede no ser diferenciable (como $|x|$ en 0 o $\|x\|$ en el origen), no puede ser “muy” irregular: un teorema de Rademacher–Alexandrov garantiza que una función convexa es diferenciable en *casi todo punto* de $\text{int dom } f$ (salvo un conjunto de medida cero), y dos veces diferenciable en casi todo punto. Los puntos de no diferenciabilidad se manejan con el *subdiferencial*, el conjunto de pendientes de las rectas soporte, que es el tema del Capítulo 7 si sigues el orden del cuaderno. En micro, la no diferenciabilidad no es exótica: la función de beneficio de una tecnología lineal tiene “quiebres” exactamente en los precios donde la empresa es indiferente entre planes, y el subdiferencial ahí es el conjunto de ofertas óptimas.

5.9. La función soporte [P1]

Cerramos el capítulo con el objeto que une todo lo anterior con la dualidad económica: la función soporte de un conjunto. La pregunta que responde es: dado un conjunto C y una dirección p , ¿hasta dónde llega C en la dirección p ?

Definición 5.42 (Función soporte). Sea $C \subseteq \mathbb{R}^n$ no vacío. La *función soporte* (*support function*) de C es $\sigma_C : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$,

$$\sigma_C(p) = \sup_{x \in C} \langle p, x \rangle.$$

Interpretación geométrica: para $\|p\| = 1$, $\langle p, x \rangle$ es la “altura” de x medida en la dirección p , y $\sigma_C(p)$ es la altura del hiperplano soporte de C con normal p (del capítulo de separación: el hiperplano $\{x : \langle p, x \rangle = \sigma_C(p)\}$ “toca” a C por fuera, si el supremo se alcanza). Interpretación económica inmediata: si $C = Y$ es un conjunto de producción y p un vector de precios, $\langle p, y \rangle$ es el beneficio del plan y , y $\sigma_Y(p)$ es *el beneficio máximo*: la función soporte del conjunto de producción es la función de beneficio.

Teorema 5.43 (Propiedades básicas de la función soporte). *Para cualquier $C \neq \emptyset$ (no hace falta que sea convexo ni cerrado ni acotado):*

- (I) σ_C es convexa en $\mathbb{R}^n$.
- (II) σ_C es positivamente homogénea de grado 1: $\sigma_C(tp) = t\sigma_C(p)$ para todo $t > 0$ (y $\sigma_C(0) = 0$).
- (III) $\sigma_C = \sigma_{\text{cl}C} = \sigma_{\text{conv}C}$: el conjunto, su clausura y su cápsula convexa tienen la misma función soporte.

Demostración. (i) Para cada $x \in C$ fijo, la función $p \mapsto \langle p, x \rangle$ es *lineal* en p (¡la variable ahora es p , no x !). Entonces σ_C es un supremo de funciones lineales de p , indexadas por $x \in C$, y el Teorema 5.33 da la convexidad. Nota que es el mismo argumento del Ejemplo 5.34.

(ii) Sea $t > 0$. Usamos que el supremo “saca escalares positivos”:

$$\sigma_C(tp) = \sup_{x \in C} \langle tp, x \rangle = \sup_{x \in C} t \langle p, x \rangle = t \sup_{x \in C} \langle p, x \rangle = t \sigma_C(p),$$

donde el paso central es válido porque multiplicar por $t > 0$ es una biyección creciente de $\mathbb{R}$ en $\mathbb{R}$ y por tanto conmuta con supremos. En $p = 0$: $\sigma_C(0) = \sup_x \langle 0, x \rangle = \sup_x 0 = 0$.

(iii) $\sigma_{\text{cl}C} = \sigma_C$ porque $\langle p, \cdot \rangle$ es continua y el supremo sobre un conjunto y sobre su clausura coinciden. Para la cápsula: claramente $\sigma_{\text{conv}C} \geq \sigma_C$ (el supremo sobre un conjunto más grande es mayor o igual). Recíprocamente, todo $z \in \text{conv}C$ es $z = \sum_i \lambda_i x_i$ con $x_i \in C$, pesos convexos; entonces

$$\langle p, z \rangle = \sum_i \lambda_i \langle p, x_i \rangle \leq \sum_i \lambda_i \sigma_C(p) = \sigma_C(p),$$

y tomando supremo sobre z , $\sigma_{\text{conv}C} \leq \sigma_C$. □

Observación 5.44. La parte (iii) tiene una lectura económica profunda: como la función soporte no distingue entre C y $\text{cl conv}C$, *el beneficio máximo solo ve la cápsula convexa cerrada de la tecnología*. Dos conjuntos de producción con la misma cápsula convexa cerrada son indistinguibles para un observador que solo ve beneficios a distintos precios. Recíprocamente (y este es el teorema de dualidad que hace funcionar la “recuperabilidad” en micro), un convexo cerrado queda *completamente determinado* por su función soporte:

$$\text{cl conv}C = \{x \in \mathbb{R}^n : \langle p, x \rangle \leq \sigma_C(p) \text{ para todo } p \in \mathbb{R}^n\}.$$

La inclusión $\subseteq$ es inmediata de la definición; la $\supseteq$ usa el teorema de separación del capítulo anterior: si $x_0 \notin \text{cl conv}C$, existe un hiperplano que separa estrictamente x_0 del convexo cerrado $\text{cl conv}C$, es decir, existe p con $\langle p, x_0 \rangle > \sup_{x \in C} \langle p, x \rangle = \sigma_C(p)$, así que x_0 no satisface el sistema de desigualdades. Conclusión: *conocer σ_C es conocer $\text{cl conv}C$* . En micro: de la función de beneficio se recupera la tecnología (convexificada), y de la función de gasto se recuperan las preferencias; ver MWG, cap. 5 (secciones 5.C y 5.E) [9] y [10], cap. 2.

5.9.1. Ejemplos calculados

Ejemplo 5.45 (Soporte de la bola, la caja y un cono). (a) *Bola unitaria euclidiana* $B = \{x : \|x\| \leq 1\}$. Por la desigualdad de Cauchy-Schwarz, $\langle p, x \rangle \leq \|p\| \|x\| \leq \|p\|$ para $x \in B$, con igualdad en $x = p / \|p\|$ (si $p \neq 0$), que está en B . Por lo tanto

$$\sigma_B(p) = \|p\|.$$

¡La función soporte de la bola es la norma! (Convexa y homogénea de grado 1, como debía ser.)

(b) *Caja* $Q = [-1, 1]^n = \{x : |x_i| \leq 1 \ \forall i\}$. El producto $\langle p, x \rangle = \sum_i p_i x_i$ se maximiza coordenada a coordenada: la elección óptima es $x_i = \text{signo}(p_i)$ (es decir, $x_i = 1$ si $p_i > 0$, $x_i = -1$ si $p_i < 0$, cualquiera si $p_i = 0$), dando $p_i x_i = |p_i|$. Entonces

$$\sigma_Q(p) = \sum_{i=1}^n |p_i| = \|p\|_1.$$

(La soporte de la bola de la norma ∞ es la norma 1: las normas son “duales” por parejas.)

(c) *Un cono*. Sea $K \subseteq \mathbb{R}^n$ un cono (cerrado bajo multiplicación por escalares ≥ 0). Si $\langle p, x_0 \rangle > 0$ para algún $x_0 \in K$, entonces $\langle p, tx_0 \rangle = t \langle p, x_0 \rangle \rightarrow +\infty$ cuando $t \rightarrow \infty$: el supremo es $+\infty$. Si en cambio $\langle p, x \rangle \leq 0$ para todo $x \in K$, el supremo es 0 (se alcanza en $x = 0$ si $0 \in K$, o como límite). Conclusión:

$$\sigma_K(p) = \begin{cases} 0 & \text{si } p \in K^\circ := \{p : \langle p, x \rangle \leq 0 \ \forall x \in K\}, \\ +\infty & \text{en otro caso;} \end{cases}$$

es decir, $\sigma_K = \delta_{K^\circ}$, la *indicatriz* (Definición 5.19) del *cono polar* K° del capítulo de conos. Los tres ejemplos muestran el patrón: la función soporte codifica la geometría del conjunto en el lenguaje de precios, y las funciones extendidas aparecen de manera natural (razón adicional para la convención del $+\infty$ de la Sección 5.4). Ejemplo económico del caso (c): un conjunto de producción con rendimientos constantes a escala es un cono, y su función de beneficio vale 0 en los precios “sostenibles” y $+\infty$ donde habría beneficios ilimitados: exactamente la condición de beneficio nulo del equilibrio con rendimientos constantes.

5.9.2. Aplicación económica: beneficio y gasto como funciones soporte

(1) **La función de beneficio.** Como ya adelantamos, si $Y \subseteq \mathbb{R}^n$ es el conjunto de producción (planes netos factibles), la función de beneficio es

$$\pi(p) = \sup_{y \in Y} \langle p, y \rangle = \sigma_Y(p).$$

El Teorema 5.43 entrega en bandeja las propiedades que MWG (cap. 5, proposición 5.C.1) lista para π : *convexa en p y homogénea de grado 1 en p* (duplicar todos los precios duplica el beneficio máximo: la escala de los precios es nominal). Y la observación de dualidad da la recuperación: el $\text{conv } Y = \{y : \langle p, y \rangle \leq \pi(p) \ \forall p\}$, la tecnología se reconstruye desde los datos de beneficio.

(2) **La función de gasto es cóncava en precios.** Sea u una utilidad y $V_u = \{x \in \mathbb{R}_+^n :$

$u(x) \geq u\}$ el conjunto de contorno superior del nivel u (las canastas que alcanzan al menos utilidad u). La *función de gasto* (*expenditure function*) es

$$e(p, u) = \inf_{x \in V_u} \langle p, x \rangle,$$

el costo mínimo de alcanzar la utilidad u a precios p .

Proposición 5.46. *Para cada nivel fijo u , la función $p \mapsto e(p, u)$ es cóncava y homogénea de grado 1 en p , cualquiera sea el conjunto $V_u \neq \emptyset$ (sin supuestos sobre la utilidad).*

Demostración. El truco es reconocer un ínfimo como “menos un supremo”:

$$e(p, u) = \inf_{x \in V_u} \langle p, x \rangle = - \sup_{x \in V_u} \langle -p, x \rangle = - \sigma_{V_u}(-p).$$

(Usamos $\inf_x g(x) = -\sup_x [-g(x)]$ y $-\langle p, x \rangle = \langle -p, x \rangle$.) Ahora encadenamos operaciones que preservan estructura: σ_{V_u} es convexa (Teorema 5.43(i)); componer con la aplicación lineal $p \mapsto -p$ preserva convexidad (Teorema 5.31); y anteponer el signo menos convierte convexa en cóncava (Observación 5.2). Luego $e(\cdot, u)$ es cóncava. La demostración directa también es instructiva y conviene verla una vez: para p_1, p_2 y $\lambda \in [0, 1]$, y cualquier $x \in V_u$,

$$\langle (1 - \lambda)p_1 + \lambda p_2, x \rangle = (1 - \lambda) \langle p_1, x \rangle + \lambda \langle p_2, x \rangle \geq (1 - \lambda) e(p_1, u) + \lambda e(p_2, u),$$

porque $\langle p_i, x \rangle \geq e(p_i, u)$ (nadie gasta menos que el gasto mínimo). Tomando ínfimo sobre $x \in V_u$ en el lado izquierdo:

$$e((1 - \lambda)p_1 + \lambda p_2, u) \geq (1 - \lambda)e(p_1, u) + \lambda e(p_2, u) :$$

concavidad. La homogeneidad es como en el Teorema 5.43(ii): $\inf_x \langle tp, x \rangle = t \inf_x \langle p, x \rangle$ para $t > 0$. $\square$

Intuición

¿Por qué el gasto es *cóncavo* en precios? Intuición económica de la demostración directa: fija la canasta $\bar{x}$ que era óptima a los precios medios. Si el gasto no pudiera reoptimizar, sería *lineal* en p (gastar $\langle p, \bar{x} \rangle$ a cada p). Pero el consumidor *sí* reoptimiza: cuando un precio sube, sustituye hacia bienes relativamente más baratos, y por eso su gasto real crece *menos* que linealmente. “Mínimo de lineales” = “lineal menos las ganancias de sustitución” = cóncava. Simétricamente, el beneficio es *convexo* en precios porque la empresa reoptimiza a su favor: “máximo de lineales”. De la concavidad de e en p salen dos joyas de Microeconomía: el *lema de Shephard* ($\nabla_p e(p, u) = h(p, u)$, la demanda hicksiana, que es el punto donde el hiperplano de pendiente p soporta a V_u) y la *negatividad semidefinida de la matriz de Slutsky* (que es exactamente $\nabla_p^2 e \preceq 0$, la caracterización de segundo orden de la concavidad, Teorema 5.25). La ley de la demanda compensada no es un supuesto psicológico: es la Hessiana de una función cóncava. Ver MWG, secciones 3.E–3.G [9], y [10], cap. 1.

5.10. Resumen del capítulo [P1]

Resumen del capítulo

- **Definición (Definición 5.1).** Sea $C \subseteq \mathbb{R}^n$ *convexo* (la hipótesis sobre el dominio no es opcional: sin ella el punto $(1 - \lambda)x + \lambda y$ puede no estar en C y la desigualdad ni siquiera se puede escribir). $f : C \rightarrow \mathbb{R}$ es **convexa** si

$$f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y) \quad \forall x, y \in C, \forall \lambda \in [0, 1],$$

y **estrictamente convexa** si la desigualdad es *estricta* para todo $x \neq y$ y todo $\lambda \in (0, 1)$ (los extremos $\lambda \in \{0, 1\}$ y el caso $x = y$ deben excluirse: allí siempre hay igualdad). f es cóncava sii $-f$ es convexa (Observación 5.2); las afines son las únicas convexas y cóncavas a la vez (Ejemplo 5.5).

- **Jensen (Teoremas 5.8 y 5.9).** Si f es convexa, $f(\sum_i \lambda_i x_i) \leq \sum_i \lambda_i f(x_i)$ para pesos $\lambda_i \geq 0$ con $\sum_i \lambda_i = 1$ y puntos $x_i \in C$; en versión probabilística, $f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]$ para X con valores en C e integrable. Para f cóncava las desigualdades se invierten. *Lectura económica:* u cóncava $\iff$ aversión al riesgo; prima de riesgo $\rho(X) = \mathbb{E}[X] - c(X) \geq 0$ con $u(c(X)) = \mathbb{E}[u(X)]$; Arrow–Pratt $A = -u''/u'$, $R = xA$ (Definición 5.11); CARA tiene A constante, CRRA tiene R constante (Ejemplo 5.12).
- **Epígrafo (Teorema 5.14).** f es convexa si y solo si $\text{epi } f = \{(x, t) \in C \times \mathbb{R} : f(x) \leq t\}$ es un conjunto convexo de $\mathbb{R}^{n+1}$; f es cóncava sii su hipógrafo es convexo. Este puente traduce todo el capítulo anterior en resultados sobre funciones.
- **Conjuntos de nivel (Proposición 5.16).** Si f es convexa, entonces $S_\alpha = \{x \in C : f(x) \leq \alpha\}$ es convexo para todo $\alpha \in \mathbb{R}$. **El recíproco es falso:** $f(x) = \sqrt{|x|}$ o $f(x) = x^3$ en $\mathbb{R}$ tienen todos sus conjuntos de nivel inferior convexas (son intervalos) sin ser convexas. La clase que caracteriza esa propiedad es la de las funciones *cuasiconvexas* (Capítulo 6).
- **Primer orden (Teorema 5.22).** Hipótesis: C convexo abierto y f diferenciable en C . Entonces f convexa $\iff f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ para todos $x, y \in C$ (el grafo está por encima de cada plano tangente); y f estrictamente convexa $\iff$ la desigualdad es estricta para $y \neq x$. Consecuencias: si $\nabla f(x^*) = 0$, x^* es mínimo *global*; y el gradiente es monótono, $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0$ (Observación 5.24).
- **Segundo orden (Teorema 5.25).** Hipótesis: C convexo abierto, f de clase C^2 . Entonces (i) f convexa $\iff \nabla^2 f(x) \succeq 0$ (PSD) **en todo punto de C** (no basta en un punto ni en parte del dominio); (ii) $\nabla^2 f \succ 0$ (PD) en todo punto $\Rightarrow f$ estrictamente convexa, **pero el recíproco es falso** ($f(x) = x^4$ es estrictamente convexa y $f''(0) = 0$). Para concavidad, NSD y ND respectivamente. *Menores:* el criterio de Sylvester con menores principales *líderes* caracteriza PD (todos > 0) y ND (signos alternados empezando en < 0); para PSD/NSD hay que usar *todos* los menores principales, no solo los líderes.
- **Operaciones que preservan convexidad.** Con f, f_i convexas: (1) $\sum_i \alpha_i f_i$ con $\alpha_i \geq 0$

(Teorema 5.29); (2) $x \mapsto f(Ax+b)$, composición con una *afín* (Teorema 5.31); (3) supremo puntual $\sup_{i \in I} f_i$ de una familia *arbitraria*, sin condiciones sobre I (Teorema 5.33); (4) composición escalar $h \circ f$ (Teorema 5.35) *solo* bajo las combinaciones exactas: h convexa **no decreciente** con f convexa, o h convexa **no creciente** con f cóncava (para concavidad: h cóncava no decreciente con f cóncava, o h cóncava no creciente con f convexa), donde la monotonía debe valer en un intervalo que contenga al rango de f ; (5) minimización parcial $g(x) = \inf_{y \in D} f(x, y)$ exige convexidad *conjunta* en (x, y) y D convexo (Teorema 5.37). *No* preservan: el mínimo puntual de convexas, el producto de convexas, la composición sin monotonía.

- **Continuidad (Teorema 5.39).** Una función convexa *de valores finitos* sobre un convexo C es continua, y localmente Lipschitz, en el *interior* $\text{int } C$. En la frontera puede saltar (Ejemplo 5.40); por eso se trabaja con funciones convexas *cerradas*. Además es diferenciable en casi todo punto de $\text{int dom } f$.
- **Función soporte (Teorema 5.43).** Para cualquier $C \neq \emptyset$ (sin convexidad, sin clausura, sin acotación), $\sigma_C(p) = \sup_{x \in C} \langle p, x \rangle$ es *convexa* y *positivamente homogénea de grado 1* ($\sigma_C(tp) = t\sigma_C(p)$ para $t > 0$, $\sigma_C(0) = 0$), con valores en $\mathbb{R} \cup \{+\infty\}$. Además $\sigma_C = \sigma_{\text{cl } C} = \sigma_{\text{conv } C}$, y un convexo cerrado se recupera de su soporte: $\text{cl conv } C = \{x : \langle p, x \rangle \leq \sigma_C(p) \ \forall p\}$.
- **Micro (Sección 5.9.2).** La función de beneficio $\pi(p) = \sup_{y \in Y} \langle p, y \rangle$ es *convexa* y homogénea de grado 1 en precios *sin supuesto alguno* sobre la tecnología (Ejemplo 5.34); la función de gasto $e(p, u) = \inf_{x \in V_u} \langle p, x \rangle$ es *cóncava* y homogénea de grado 1 en precios sin supuestos sobre las preferencias (Proposición 5.46). De ahí salen Hotelling, Shephard y la semidefinición negativa de la matriz de Slutsky, que no es más que $\nabla_p^2 e \preceq 0$ vía el Teorema 5.25. Ver [9] caps. 3 y 5, [10] caps. 1–3; para el aparato convexo, [2] cap. 3, [6] cap. 2, [3] y [1].

5.11. Ejercicios resueltos [P1]

Los seis ejercicios siguientes recorren, en orden, las herramientitas del capítulo: menores y Hessiana, álgebra de operaciones, aversión al riesgo, el supremo puntual, la función soporte y, al final, las trampas típicas de examen. Todas las soluciones están completas: no hay ningún “se deja al lector”.

Ejercicio 5.47 (Hessiana con parámetro y menores). Sea $\alpha \in \mathbb{R}$ y $f_\alpha : \mathbb{R}^3 \rightarrow \mathbb{R}$ definida por

$$f_\alpha(x_1, x_2, x_3) = x_1^2 + x_2^2 + x_3^2 + 2\alpha(x_1x_2 + x_1x_3 + x_2x_3).$$

- (a) Calcula $\nabla^2 f_\alpha$. (b) Determina exactamente para qué valores de α la función es convexa, y para cuáles es *estrictamente* convexa. (c) ¿Para qué α es cóncava? (d) Explica por qué el criterio de los menores principales *líderes* (Sylvester) no basta para responder (b).

Solución. (a) *La Hessiana.* Escribimos $f_\alpha(x) = x^\top M(\alpha) x$ con

$$M(\alpha) = \begin{pmatrix} 1 & \alpha & \alpha \\ \alpha & 1 & \alpha \\ \alpha & \alpha & 1 \end{pmatrix},$$

pues $x^\top Mx = \sum_i x_i^2 + 2\alpha \sum_{i < j} x_i x_j$ (cada producto cruzado $x_i x_j$ aparece dos veces, en las posiciones (i, j) y (j, i)). Por el Ejemplo 5.26 con $Q = 2M(\alpha)$, $b = 0$, $c = 0$:

$$\nabla f_\alpha(x) = 2M(\alpha)x, \quad \nabla^2 f_\alpha(x) = 2M(\alpha) \quad \text{para todo } x,$$

una Hessiana *constante*. El dominio $\mathbb{R}^3$ es convexo y abierto y f_α es un polinomio (clase C^∞), así que las hipótesis del Teorema 5.25 se cumplen y podemos usarlo sin reparos.

(b) *Los valores de α .* Lo más limpio aquí es diagonalizar. Sea J la matriz 3×3 de puros unos. Entonces

$$M(\alpha) = (1 - \alpha)I + \alpha J.$$

La matriz J tiene rango 1: su imagen es la recta generada por $\mathbf{1} = (1, 1, 1)^\top$ y su núcleo es el plano $\{v : \sum_i v_i = 0\}$. Sus valores propios son, por tanto, 3 (con vector propio $\mathbf{1}$, pues $J\mathbf{1} = 3\mathbf{1}$) y 0 (doble). Como sumar $(1 - \alpha)I$ desplaza todos los valores propios en $1 - \alpha$, los valores propios de $M(\alpha)$ son

$$\mu_1 = (1 - \alpha) + 3\alpha = 1 + 2\alpha \quad (\text{vector propio } \mathbf{1}), \quad \mu_2 = \mu_3 = 1 - \alpha \quad (\text{el plano } \sum_i v_i = 0).$$

Una matriz simétrica es PSD sii todos sus valores propios son ≥ 0 , y PD sii todos son > 0 . Luego

$$M(\alpha) \succeq 0 \iff 1 + 2\alpha \geq 0 \text{ y } 1 - \alpha \geq 0 \iff -\frac{1}{2} \leq \alpha \leq 1,$$

$$M(\alpha) \succ 0 \iff -\frac{1}{2} < \alpha < 1.$$

Por el Teorema 5.25(i), f_α es **convexa si y solo si** $\alpha \in [-1/2, 1]$, y por (ii) es estrictamente convexa cuando $\alpha \in (-1/2, 1)$. En este caso el recíproco de (ii) también vale, porque la función es cuadrática (Ejemplo 5.26): en los extremos la estrictez falla de verdad. Verifiquémoslo:

- Si $\alpha = 1$: $M = J$ y $f_1(x) = x^\top Jx = (x_1 + x_2 + x_3)^2$. Sobre cualquier recta contenida en el plano $x_1 + x_2 + x_3 = 0$ la función vale idénticamente 0: es afín (constante) ahí, así que es convexa pero *no* estrictamente.
- Si $\alpha = -1/2$: el vector $\mathbf{1}$ cumple $M\mathbf{1} = (1 + 2\alpha)\mathbf{1} = 0$, y sobre la recta $t \mapsto t\mathbf{1}$ tenemos $f_{-1/2}(t\mathbf{1}) = t^2 \mathbf{1}^\top M\mathbf{1} = 0$: de nuevo constante sobre una recta, luego no estrictamente convexa.

Una comprobación alternativa, sin valores propios, sale de la identidad

$$x^\top M(\alpha)x = (1 - \alpha) \|x\|^2 + \alpha \left(\sum_{i=1}^3 x_i \right)^2,$$

que se verifica desarrollando el cuadrado. Para $0 \leq \alpha \leq 1$ ambos coeficientes son ≥ 0 y f_α es

suma no negativa de dos convexas (Teorema 5.29); para α fuera de $[-1/2, 1]$ basta evaluar en la dirección que rompe todo: si $\alpha > 1$, en $v = (1, -1, 0)$ resulta $v^\top Mv = 2 - 2\alpha < 0$; si $\alpha < -1/2$, en $v = \mathbf{1}$ resulta $v^\top Mv = 3 + 6\alpha < 0$. En ambos casos la Hessiana no es PSD y f_α no es convexa.

(c) *Concavidad.* f_α sería cóncava si $\nabla^2 f_\alpha \preceq 0$, lo que exige en particular que las entradas diagonales sean ≤ 0 (tomando $v = e_i$ se obtiene $e_i^\top M e_i = M_{ii} = 1 \leq 0$, falso). Como $M_{ii} = 1 > 0$ para todo α , *no existe* ningún α que haga cóncava a f_α .

(d) *Por qué Sylvester líder no basta.* Los menores principales líderes de $M(\alpha)$ son

$$\Delta_1 = 1, \quad \Delta_2 = \det \begin{pmatrix} 1 & \alpha \\ \alpha & 1 \end{pmatrix} = 1 - \alpha^2,$$

$$\Delta_3 = \det M(\alpha) = 1 - 3\alpha^2 + 2\alpha^3 = (1 - \alpha)^2(1 + 2\alpha),$$

donde la factorización se comprueba notando que $\alpha = 1$ anula el polinomio ($1 - 3 + 2 = 0$) y dividiendo dos veces por $(\alpha - 1)$. El criterio de Sylvester dice: $M \succ 0$ si $\Delta_1, \Delta_2, \Delta_3 > 0$, es decir, $1 - \alpha^2 > 0$ y $(1 - \alpha)^2(1 + 2\alpha) > 0$, o sea $-1/2 < \alpha < 1$: coincide con lo hallado, *para el caso estricto*. Pero la versión “no estricta” del criterio de líderes es **falsa**: pedir $\Delta_1, \Delta_2, \Delta_3 \geq 0$ no garantiza PSD. El contraejemplo mínimo es

$$N = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}, \quad \Delta_1 = 0, \quad \Delta_2 = \det N = 0,$$

ambos ≥ 0 , y sin embargo N no es PSD, pues $e_2^\top N e_2 = -1 < 0$; lo que delata el problema es el menor principal *no líder* obtenido al borrar la primera fila y columna, que vale $-1 < 0$. La regla correcta es: $M \succeq 0$ si *todos los menores principales (no solo los líderes) son ≥ 0* . Para $M(\alpha)$ esos menores son: los de orden 1, todos iguales a $1 > 0$; los de orden 2, todos iguales a $1 - \alpha^2$, que exige $|\alpha| \leq 1$; y el de orden 3, $(1 - \alpha)^2(1 + 2\alpha) \geq 0$, que dentro de ese rango exige $\alpha \geq -1/2$. Intersecando: $-1/2 \leq \alpha \leq 1$, el mismo resultado que dieron los valores propios. Moraleja de examen: *menores líderes para lo estricto (PD/ND); todos los menores principales para lo no estricto (PSD/NSD)*. $\square$

Ejercicio 5.48 (Convexidad sin Hessianas). Demuestra que las siguientes funciones son convexas usando *únicamente* las operaciones que preservan convexidad, sin calcular ninguna derivada segunda. En cada caso identifica el dominio, verifica que es convexo y cita el resultado exacto que usas.

- (a) $f(x) = (\max\{0, \langle a, x \rangle - b\})^2$ en $\mathbb{R}^n$, con $a \in \mathbb{R}^n$, $b \in \mathbb{R}$ (costo cuadrático por exceder un umbral).
- (b) $g(x) = \ln \left(\sum_{j=1}^m e^{\langle a_j, x \rangle + b_j} \right)$ en $\mathbb{R}^n$ (el *valor inclusivo* del modelo logit).
- (c) $h(x) = -\ln(b - \langle a, x \rangle)$ en $D = \{x \in \mathbb{R}^n : \langle a, x \rangle < b\}$ (barrera logarítmica de una restricción presupuestaria).

Solución. (a) Descomponemos $f = h \circ u$ con

$$u(x) = \max\{0, \langle a, x \rangle - b\}, \quad h(t) = t^2.$$

Paso 1: u es convexa. La función constante 0 es afín, y $x \mapsto \langle a, x \rangle - b$ es afín; ambas son convexas (Ejemplo 5.5). El máximo puntual de dos funciones convexas es convexo: es el caso finito del Teorema 5.33 con $I = \{1, 2\}$. Luego u es convexa en $\mathbb{R}^n$ (que es convexo).

Paso 2: el rango de u . Por construcción $u(x) \geq 0$ para todo x , así que $u(\mathbb{R}^n) \subseteq [0, \infty) =: D_h$, un intervalo.

Paso 3: h es convexa y no decreciente en D_h . En $[0, \infty)$, $h(t) = t^2$ es convexa (Ejemplo 5.4) y además *no decreciente*, pues para $0 \leq s \leq t$ se tiene $t^2 - s^2 = (t - s)(t + s) \geq 0$. Aquí está el detalle fino: t^2 *no* es no decreciente en todo $\mathbb{R}$, pero el Teorema 5.35 solo pide la monotonía en un intervalo que contenga al rango de la función interna, y ese rango es $[0, \infty)$.

Paso 4: conclusión. Por el Teorema 5.35(i) (u convexa, h convexa no decreciente en un intervalo que contiene a $u(\mathbb{R}^n)$), $f = h \circ u$ es convexa en $\mathbb{R}^n$.

(b) Descomponemos $g = \text{lse} \circ A$ donde $\text{lse}(z) = \ln(\sum_{j=1}^m e^{z_j})$ y $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ es la aplicación afín $A(x) = (\langle a_1, x \rangle + b_1, \dots, \langle a_m, x \rangle + b_m)$, que en forma matricial es $A(x) = Ax + b$ con filas $a_j^\top$. En efecto,

$$g(x) = \ln\left(\sum_j e^{\langle a_j, x \rangle + b_j}\right) = \text{lse}(Ax + b).$$

La función log-suma-exp es convexa en $\mathbb{R}^m$ (Ejemplo 5.28), y la composición con una aplicación afín preserva la convexidad (Teorema 5.31). Luego g es convexa en $\mathbb{R}^n$. *Nota económica:* en el modelo de elección discreta con utilidades $\langle a_j, x \rangle + b_j$ y shocks Gumbel, esta g es exactamente la utilidad esperada del máximo (el “valor inclusivo”), y su gradiente son las probabilidades de elección logit; su convexidad en los parámetros es lo que hace tratable la estimación por máxima verosimilitud.

(c) **El dominio.** $D = \{x : \langle a, x \rangle < b\}$ es un semiespacio abierto, y los semiespacios son convexos (Capítulo 2); además $\langle a, x \rangle < b$ garantiza $b - \langle a, x \rangle > 0$, así que el logaritmo está bien definido. **La descomposición.** Sea $\varphi(t) = -\ln t$ en $t > 0$ y $u(x) = b - \langle a, x \rangle$, que es afín (luego convexa y cóncava) con rango contenido en $(0, \infty)$. Hay dos caminos, ambos legítimos:

- *Vía composición afín:* $\varphi(t) = -\ln t$ es convexa en $(0, \infty)$ porque $\ln$ es cóncava (Ejemplo 5.7) y cambiar el signo intercambia convexidad y concavidad (Observación 5.2); componer φ con la aplicación afín $x \mapsto b - \langle a, x \rangle$ preserva convexidad (Teorema 5.31). Luego $h = \varphi \circ u$ es convexa.
- *Vía composición escalar:* u es cóncava (por ser afín) y φ es convexa y *no creciente* en $(0, \infty)$ (pues $\varphi(s) - \varphi(t) = \ln(t/s) \geq 0$ para $s \leq t$); el Teorema 5.35(ii) da directamente la convexidad de $\varphi \circ u$.

En ambos casos h es convexa en D . *Nota:* esta es la barrera logarítmica que usan los métodos de punto interior para la restricción $\langle a, x \rangle \leq b$ [2]; su convexidad es precisamente lo que permite resolver el problema penalizado con métodos de descenso. $\square$

Ejercicio 5.49 (Equivalente cierto, prima de riesgo y Arrow–Pratt). (a) Un agente con utilidad CARA $u(w) = -e^{-\alpha w}$, $\alpha = 0.1$, enfrenta la lotería X que paga 0 soles con probabilidad $1/2$ y 20 soles con probabilidad $1/2$. Calcula $\mathbb{E}[X]$, $\mathbb{E}[u(X)]$, el equivalente cierto $c(X)$, la prima de riesgo $\rho(X)$ y los coeficientes $A(w)$ y $R(w)$. Compara $\rho(X)$ con la aproximación $\frac{1}{2}A\sigma^2$. Demuestra además que si el agente parte de una riqueza inicial W (la lotería se suma a W), la prima no

cambia.

(b) Un agente con utilidad CRRA $u(w) = w^{1-\gamma}/(1-\gamma)$, $\gamma = 2$, enfrenta la lotería que paga 100 o 25 con probabilidad $1/2$ cada una. Calcula $c(X)$ y $\rho(X)$, compáralos con el agente logarítmico del Ejemplo 5.10 y demuestra que para CRRA el equivalente cierto es homogéneo de grado 1 en los pagos.

Solución. (a) *Agente CARA.* Primero lo elemental:

$$\mathbb{E}[X] = \frac{1}{2}(0) + \frac{1}{2}(20) = 10.$$

Utilidad esperada. Con $\alpha = 0.1$:

$$\mathbb{E}[u(X)] = \frac{1}{2}(-e^{-0.1 \cdot 0}) + \frac{1}{2}(-e^{-0.1 \cdot 20}) = -\frac{1}{2}(1 + e^{-2}).$$

Numéricamente, $e^{-2} = 0.135335$, luego $\mathbb{E}[u(X)] = -\frac{1}{2}(1.135335) = -0.567668$.

Equivalente cierto. Resolvemos $u(c) = \mathbb{E}[u(X)]$:

$$-e^{-0.1c} = -0.567668 \implies e^{-0.1c} = 0.567668 \implies -0.1c = \ln(0.567668) \implies c = -10 \ln(0.567668).$$

Como $\ln(0.567668) = -0.566221$, obtenemos

$$c(X) = 5.6622 \text{ soles (aprox.)}.$$

(Observa que $c(X) < \mathbb{E}[X] = 10$, como exige Jensen para un agente averso: u es cóncava porque $u''(w) = -\alpha^2 e^{-\alpha w} < 0$, Ejemplo 5.12.)

Prima de riesgo.

$$\rho(X) = \mathbb{E}[X] - c(X) = 10 - 5.6622 = 4.3378 \text{ soles}.$$

El agente pagaría hasta 4.34 soles por convertir esta lotería en su valor esperado seguro; equivalentemente, vendería la lotería por cualquier precio mayor que 5.66.

Coefficientes de Arrow–Pratt. Con $u'(w) = \alpha e^{-\alpha w}$ y $u''(w) = -\alpha^2 e^{-\alpha w}$:

$$A(w) = -\frac{u''(w)}{u'(w)} = \alpha = 0.1 \quad (\text{constante}), \quad R(w) = w A(w) = 0.1 w.$$

Comparación con la aproximación. La varianza de una lotería binaria simétrica con pagos 0 y 20 es

$$\sigma^2 = \frac{1}{2}(0 - 10)^2 + \frac{1}{2}(20 - 10)^2 = 100,$$

de modo que $\frac{1}{2}A\sigma^2 = \frac{1}{2}(0.1)(100) = 5$, frente a la prima exacta 4.34. La aproximación sobreestima en aproximadamente un 15 por ciento, y no debe sorprenderte: la fórmula de Arrow–Pratt es un desarrollo de Taylor válido para riesgos *pequeños*, y aquí la desviación estándar ($\sigma = 10$) es del mismo orden que la riqueza en juego. Con la misma α pero pagos ± 1 alrededor de la media, la aproximación sería excelente.

Invarianza a la riqueza inicial. Sea W la riqueza inicial y consideremos la lotería $W + X$.

Su equivalente cierto c_W resuelve

$$-e^{-\alpha c_W} = \mathbb{E}[-e^{-\alpha(W+X)}] = -e^{-\alpha W} \mathbb{E}[e^{-\alpha X}],$$

donde sacamos $e^{-\alpha W}$ de la esperanza por ser constante. Tomando logaritmos en la igualdad $e^{-\alpha c_W} = e^{-\alpha W} \mathbb{E}[e^{-\alpha X}]$:

$$-\alpha c_W = -\alpha W + \ln \mathbb{E}[e^{-\alpha X}] \implies c_W = W - \frac{1}{\alpha} \ln \mathbb{E}[e^{-\alpha X}] = W + c(X),$$

puesto que $c(X) = -\frac{1}{\alpha} \ln \mathbb{E}[e^{-\alpha X}]$ es justamente el cálculo de arriba con $W = 0$. Entonces

$$\rho(W + X) = \mathbb{E}[W + X] - c_W = (W + \mathbb{E}[X]) - (W + c(X)) = \rho(X) :$$

la prima *no depende de la riqueza*. Esto es exactamente lo que significa “aversión absoluta constante”, y es la razón por la que CARA es la utilidad estándar en modelos de contratos, donde no se quiere que los efectos riqueza contaminen los incentivos.

(b) *Agente CRRA con $\gamma = 2$* . Aquí $u(w) = w^{-1}/(-1) = -1/w$ para $w > 0$. Calculamos:

$$\mathbb{E}[u(X)] = \frac{1}{2} \left(-\frac{1}{100} \right) + \frac{1}{2} \left(-\frac{1}{25} \right) = -\frac{1}{2} (0.01 + 0.04) = -0.025.$$

El equivalente cierto resuelve $-1/c = -0.025$, es decir

$$c(X) = \frac{1}{0.025} = 40.$$

(Nota que $c(X)$ es la *media armónica* de los pagos: $c = [\frac{1}{2} \cdot \frac{1}{100} + \frac{1}{2} \cdot \frac{1}{25}]^{-1} = 40$.) Con $\mathbb{E}[X] = \frac{1}{2}(100) + \frac{1}{2}(25) = 62.5$:

$$\rho(X) = 62.5 - 40 = 22.5.$$

Comparación. Ordenando por aversión relativa γ :

Agente	γ	$c(X)$	$\rho(X)$
neutral ($u(w) = w$)	0	62.5	0
logarítmico (Ejemplo 5.10)	1	50	12.5
CRRA	2	40	22.5

El equivalente cierto pasa de la media aritmética ($\gamma = 0$) a la media geométrica ($\gamma = 1$) y a la media armónica ($\gamma = 2$), que es la cadena clásica de desigualdades entre medias: a mayor γ , menor c y mayor prima. Los coeficientes de Arrow-Pratt del agente con $\gamma = 2$ son $A(w) = -u''/u' = 2/w$ y $R(w) = 2$ (Ejemplo 5.12).

Homogeneidad del equivalente cierto. Sea $t > 0$ y consideremos la lotería reescalada tX . Como

$$u(tw) = \frac{(tw)^{1-\gamma}}{1-\gamma} = t^{1-\gamma} u(w),$$

al tomar esperanzas resulta $\mathbb{E}[u(tX)] = t^{1-\gamma} \mathbb{E}[u(X)]$. Si c es el equivalente cierto de X , entonces

$$u(tc) = t^{1-\gamma} u(c) = t^{1-\gamma} \mathbb{E}[u(X)] = \mathbb{E}[u(tX)],$$

y como u es estrictamente creciente, el equivalente cierto es único: $c(tX) = tc(X)$. Por tanto $\rho(tX) = t\rho(X)$, y la prima como *fracción* de la riqueza en juego es la misma. Verificación numérica: duplicando los pagos a 200 y 50, $\mathbb{E}[u] = -\frac{1}{2}(1/200 + 1/50) = -0.0125$ y $c = 80 = 2 \times 40$, en efecto. Eso es “aversión relativa constante”: el agente evalúa riesgos *proporcionales* igual, sea rico o pobre, lo que hace de CRRA la especificación natural en modelos de crecimiento y de cartera. $\square$

Ejercicio 5.50 (El máximo puntual, desde la definición, y el beneficio). (a) Sean $f_1, \dots, f_m : C \rightarrow \mathbb{R}$ convexas sobre un convexo $C \subseteq \mathbb{R}^n$. Demuestra *desde la definición* (sin usar epígrafos) que $g(x) = \max_{1 \leq j \leq m} f_j(x)$ es convexa. (b) Explica qué hay que cambiar si la familia es infinita y $g = \sup_j f_j$. (c) Una empresa dispone de tres planes de producción: no producir (beneficio 0), el plan A (produce 3 unidades a un costo total de 6) y el plan B (produce 5 unidades a un costo total de 14). Escribe la función de beneficio $\pi(p)$, describe su forma explícita por tramos, verifica su convexidad y deduce la oferta óptima y su monotonía.

Solución. (a) *Demostración directa.* Sean $x, y \in C$ y $\lambda \in [0, 1]$, y escribamos $x_\lambda = (1-\lambda)x + \lambda y$, que pertenece a C por ser C convexo. Como el máximo es sobre un conjunto *finito* de índices, se alcanza: existe $k \in \{1, \dots, m\}$ tal que

$$g(x_\lambda) = f_k(x_\lambda).$$

Ahora encadenamos dos pasos. Primero, la convexidad de esa f_k concreta:

$$f_k(x_\lambda) \leq (1-\lambda)f_k(x) + \lambda f_k(y).$$

Segundo, la definición de g como máximo implica que g domina a cada miembro de la familia en cada punto; en particular $f_k(x) \leq g(x)$ y $f_k(y) \leq g(y)$. Como los pesos $1-\lambda$ y λ son *no negativos*, podemos sustituirlos preservando el sentido de la desigualdad (aquí se usa la no negatividad: multiplicar una desigualdad por un número negativo la invertiría):

$$(1-\lambda)f_k(x) + \lambda f_k(y) \leq (1-\lambda)g(x) + \lambda g(y).$$

Uniendo las tres relaciones:

$$g((1-\lambda)x + \lambda y) = f_k(x_\lambda) \leq (1-\lambda)f_k(x) + \lambda f_k(y) \leq (1-\lambda)g(x) + \lambda g(y),$$

que es exactamente la desigualdad de convexidad para g . Observa que el índice k que alcanza el máximo *depende de* x_λ , y que eso no molesta en absoluto: la demostración solo necesita que exista *alguno*.

(b) *Familia infinita.* Con $g = \sup_{j \in I} f_j$ y I arbitrario, el supremo puede no alcanzarse, así que el paso “existe k con $g(x_\lambda) = f_k(x_\lambda)$ ” ya no es válido. La reparación es estándar: para cada

$j \in I$,

$$f_j(x_\lambda) \leq (1 - \lambda)f_j(x) + \lambda f_j(y) \leq (1 - \lambda)g(x) + \lambda g(y),$$

es decir, el número $(1 - \lambda)g(x) + \lambda g(y)$ es una *cota superior* del conjunto $\{f_j(x_\lambda) : j \in I\}$. Por definición de supremo (la menor de las cotas superiores),

$$g(x_\lambda) = \sup_{j \in I} f_j(x_\lambda) \leq (1 - \lambda)g(x) + \lambda g(y).$$

Este es el argumento del Teorema 5.33; hay que admitir además el valor $+\infty$ (trabajar con funciones extendidas, Sección 5.4) porque el supremo puede ser infinito en algunos puntos.

(c) *La función de beneficio.* Cada plan da un beneficio *afín* en el precio p del producto:

$$\pi_0(p) = 0, \quad \pi_A(p) = 3p - 6, \quad \pi_B(p) = 5p - 14.$$

La empresa elige el mejor plan a cada precio, de modo que

$$\pi(p) = \max\{0, 3p - 6, 5p - 14\},$$

un máximo de tres afines: convexa por la parte (a), y también por el Ejemplo 5.34, con $Y = \{0, 3, 5\}$ y costos $c(0) = 0$, $c(3) = 6$, $c(5) = 14$. **Forma por tramos.** Buscamos los cortes:

$$0 = 3p - 6 \iff p = 2, \quad 3p - 6 = 5p - 14 \iff 2p = 8 \iff p = 4.$$

Comparando en cada región (por ejemplo, evaluando en $p = 1$: los valores son 0, -3 , -9 ; en $p = 3$: 0, 3, 1; en $p = 5$: 0, 9, 11):

$$\pi(p) = \begin{cases} 0 & \text{si } p \leq 2, \\ 3p - 6 & \text{si } 2 \leq p \leq 4, \\ 5p - 14 & \text{si } p \geq 4. \end{cases}$$

Convexidad, verificada a mano. La función es continua (en $p = 2$ ambos tramos valen 0; en $p = 4$ ambos valen 6) y lineal a trozos con pendientes $0 < 3 < 5$, *crecientes* de izquierda a derecha: una función lineal a trozos es convexa si y solo si sus pendientes son no decrecientes, que es la versión discreta de “la derivada crece” (Teorema 5.22 y Observación 5.24).

Oferta y ley de la oferta. Donde π es diferenciable, el lema de Hotelling dice que $\pi'(p)$ es la cantidad ofrecida:

$$y(p) = \pi'(p) = \begin{cases} 0 & \text{si } p < 2, \\ 3 & \text{si } 2 < p < 4, \\ 5 & \text{si } p > 4, \end{cases}$$

que es *no decreciente* en p : la ley de la oferta no es un supuesto de comportamiento, es la monotonía de la derivada de una función convexa. En los precios de quiebre $p = 2$ y $p = 4$ la empresa es *indiferente* entre dos planes y π no es diferenciable; ahí la oferta es multivaluada ($\{0, 3\}$ y $\{3, 5\}$ respectivamente, y sus combinaciones convexas si se permite mezclar), y el objeto

correcto es el subdiferencial $\partial\pi(p) = [0, 3]$ y $[3, 5]$ (Capítulo 7). $\square$

Ejercicio 5.51 (Funciones soporte del simplex y de una caja). Calcula paso a paso, y verifica en cada caso la convexidad y la homogeneidad de grado 1:

(a) $\sigma_\Delta(p)$ para el simplex $\Delta = \{x \in \mathbb{R}^n : x_i \geq 0 \ \forall i, \ \sum_{i=1}^n x_i = 1\}$.

(b) $\sigma_Q(p)$ para la caja $Q = \prod_{i=1}^n [a_i, b_i]$ con $a_i \leq b_i$.

Interpreta (a) cuando Δ es el conjunto de loterías sobre n escenarios y (b) cuando Q describe rangos factibles de actividades.

Solución. (a) *El simplex.* Afirmamos que

$$\sigma_\Delta(p) = \max_{1 \leq i \leq n} p_i.$$

Cota superior ($\leq$). Sea $x \in \Delta$ y llamemos $p_{\max} = \max_i p_i$. Como $x_i \geq 0$ para todo i , cada término cumple $p_i x_i \leq p_{\max} x_i$ (multiplicamos la desigualdad $p_i \leq p_{\max}$ por el número *no negativo* x_i). Sumando y usando $\sum_i x_i = 1$:

$$\langle p, x \rangle = \sum_{i=1}^n p_i x_i \leq p_{\max} \sum_{i=1}^n x_i = p_{\max} \cdot 1 = p_{\max}.$$

Como esto vale para todo $x \in \Delta$, el supremo cumple $\sigma_\Delta(p) \leq p_{\max}$.

Cota inferior ($\geq$) y alcanzabilidad. Sea i^* un índice donde se alcanza el máximo, $p_{i^*} = p_{\max}$, y tomemos el vértice $x = e_{i^*}$ (el vector con un 1 en la posición i^* y ceros en el resto). Es claro que $e_{i^*} \in \Delta$ (coordenadas no negativas que suman 1), y

$$\langle p, e_{i^*} \rangle = p_{i^*} = p_{\max}.$$

Luego $\sigma_\Delta(p) \geq p_{\max}$. Ambas desigualdades dan la igualdad, y además el supremo se *alcanza* (en un vértice).

Verificación de las propiedades. $\sigma_\Delta(p) = \max_i p_i$ es un máximo finito de funciones lineales $p \mapsto \langle e_i, p \rangle$: convexa por el Ejercicio 5.50(a), como garantiza el Teorema 5.43(i). Y para $t > 0$, $\max_i (tp_i) = t \max_i p_i$, la homogeneidad de grado 1 del Teorema 5.43(ii). Además nunca vale $+\infty$, porque Δ es compacto.

Interpretación. Si Δ es el conjunto de loterías sobre n escenarios y p_i es el pago en el escenario i , entonces $\langle p, x \rangle$ es el pago esperado bajo la lotería x , y $\sigma_\Delta(p) = \max_i p_i$ dice que el mejor pago esperado se logra poniendo toda la probabilidad en el mejor escenario: *optimizar sobre un politopo lleva a un vértice*, el principio que sostiene el método simplex (Capítulo 13). Lo mismo con signo cambiado: $\min_{x \in \Delta} \langle p, x \rangle = \min_i p_i$ es el criterio *maximin* de decisiones robustas, y su concavidad en p es la Proposición 5.46 en miniatura. En producción: si $Y = \text{conv}\{y^1, \dots, y^n\}$ es la cápsula convexa de finitos planes, $\pi(p) = \sigma_Y(p) = \max_j \langle p, y^j \rangle$, que es exactamente el Ejercicio 5.50(c).

(b) *La caja.* Afirmamos que

$$\sigma_Q(p) = \sum_{i=1}^n \max\{a_i p_i, b_i p_i\}.$$

Separabilidad. La clave es que tanto el objetivo como la restricción se descomponen coordenada a coordenada:

$$\sup_{x \in Q} \langle p, x \rangle = \sup_{\substack{x_i \in [a_i, b_i] \\ i=1, \dots, n}} \sum_{i=1}^n p_i x_i = \sum_{i=1}^n \sup_{x_i \in [a_i, b_i]} p_i x_i,$$

porque cada sumando depende de una sola variable y las variables se eligen *independientemente* (maximizar una suma de términos sin restricciones cruzadas equivale a maximizar cada término por separado).

El problema unidimensional. La función $x_i \mapsto p_i x_i$ es lineal en un intervalo cerrado, así que su máximo se alcanza en un extremo:

$$\sup_{x_i \in [a_i, b_i]} p_i x_i = \begin{cases} b_i p_i & \text{si } p_i \geq 0 \quad (\text{conviene } x_i = b_i), \\ a_i p_i & \text{si } p_i < 0 \quad (\text{conviene } x_i = a_i), \end{cases} = \max\{a_i p_i, b_i p_i\}.$$

Sumando en i se obtiene la fórmula. **Forma alternativa (centro y radio).** Escribiendo $m_i = (a_i + b_i)/2$ y $r_i = (b_i - a_i)/2 \geq 0$,

$$\max\{a_i p_i, b_i p_i\} = m_i p_i + r_i |p_i|,$$

que se comprueba por casos: si $p_i \geq 0$, $m_i p_i + r_i p_i = (m_i + r_i) p_i = b_i p_i$; si $p_i < 0$, $m_i p_i - r_i p_i = (m_i - r_i) p_i = a_i p_i$. Por lo tanto

$$\sigma_Q(p) = \langle p, m \rangle + \sum_{i=1}^n r_i |p_i|.$$

En el caso simétrico $a_i = -1$, $b_i = 1$ queda $m = 0$, $r_i = 1$ y $\sigma_Q(p) = \sum_i |p_i| = \|p\|_1$, recuperando el Ejemplo 5.45(b).

Verificación. σ_Q es convexa: es suma con coeficientes no negativos de la función lineal $\langle p, m \rangle$ y de las funciones $|p_i|$, convexas (Ejemplo 5.6) y compuestas con la aplicación lineal $p \mapsto p_i$ (Teoremas 5.29 y 5.31). Y es homogénea de grado 1, porque tanto $\langle \cdot, m \rangle$ como $|\cdot|$ lo son. *Chequeo numérico:* con $n = 2$, $Q = [0, 2] \times [1, 3]$ y $p = (1, -2)$, la fórmula directa da $\max\{0, 2\} + \max\{-2, -6\} = 2 - 2 = 0$; la fórmula centro-radio, con $m = (1, 2)$ y $r = (1, 1)$, da $(1)(1) + (-2)(2) + 1 \cdot |1| + 1 \cdot |-2| = -3 + 3 = 0$. Coinciden.

Interpretación. Si x_i es el nivel de la actividad i , confinado a un rango técnico $[a_i, b_i]$, y p_i es su margen unitario, el beneficio máximo se obtiene llevando cada actividad rentable a su tope b_i y cada actividad de margen negativo a su piso a_i : una solución “de esquina” (*bang-bang*). La no diferenciabilidad de σ_Q en los puntos donde algún $p_i = 0$ refleja justamente el precio de indiferencia en el que la empresa puede saltar de un extremo al otro. $\square$

Ejercicio 5.52 (Tres trampas clásicas). (a) Sea $f(x, y) = x^3 + y^3$ en $\mathbb{R}^2$. Calcula su Hessiana, determina en qué conjuntos es PSD y decide si f es convexa en $\mathbb{R}^2$, exhibiendo un contraejemplo numérico explícito. (b) Demuestra que la suma de dos funciones cóncavas es cóncava, y muestra con un ejemplo que el *producto* de dos cóncavas positivas puede no ser cóncavo. (c) Formula la moraleja general sobre “verificar la Hessiana en un punto”.

Solución. (a) PSD solo en parte del dominio. Las derivadas parciales son

$$f_x = 3x^2, \quad f_y = 3y^2, \quad f_{xx} = 6x, \quad f_{yy} = 6y, \quad f_{xy} = f_{yx} = 0,$$

de modo que

$$\nabla^2 f(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 6y \end{pmatrix}.$$

Al ser diagonal, sus valores propios son $6x$ y $6y$; por tanto

$$\nabla^2 f(x, y) \succeq 0 \iff x \geq 0 \text{ y } y \geq 0.$$

El conjunto donde la Hessiana es PSD es el ortante cerrado $\mathbb{R}_+^2$, que es convexo, así que el Teorema 5.25 permite concluir: **f es convexa en $\mathbb{R}_+^2$** (aplicándolo en el interior $\mathbb{R}_{++}^2$ y extendiendo por continuidad hasta la frontera). Pero **no** es convexa en $\mathbb{R}^2$: allí la Hessiana no es PSD en ningún punto con alguna coordenada negativa.

Contraejemplo explícito. Basta trabajar sobre la recta $y = 0$, donde $f(x, 0) = x^3$. Tomemos $u = (-1, 0)$ y $v = (0, 0)$ con $\lambda = 1/2$, cuyo punto medio es $w = (-1/2, 0)$:

$$f(w) = \left(-\frac{1}{2}\right)^3 = -\frac{1}{8} = -0.125, \quad \frac{1}{2}f(u) + \frac{1}{2}f(v) = \frac{1}{2}(-1) + \frac{1}{2}(0) = -\frac{1}{2} = -0.5.$$

La desigualdad de convexidad exigiría $-0.125 \leq -0.5$, que es **falsa**. Luego f no es convexa en $\mathbb{R}^2$ (ni siquiera restringida a la recta $y = 0$ completa). Nota que sí es *cóncava* en $\mathbb{R}_-^2$ (donde $\nabla^2 f \preceq 0$): la misma función es convexa en un trozo y cóncava en otro, y no es ni lo uno ni lo otro globalmente.

(b) *Suma sí, producto no. La suma.* Sean $f, g : C \rightarrow \mathbb{R}$ cóncavas, C convexo. Para $x, y \in C$ y $\lambda \in [0, 1]$,

$$f((1 - \lambda)x + \lambda y) \geq (1 - \lambda)f(x) + \lambda f(y), \quad g((1 - \lambda)x + \lambda y) \geq (1 - \lambda)g(x) + \lambda g(y).$$

Sumando ambas desigualdades miembro a miembro (lícito: si $A \geq B$ y $C \geq D$, entonces $A + C \geq B + D$) y agrupando:

$$(f + g)((1 - \lambda)x + \lambda y) \geq (1 - \lambda)(f + g)(x) + \lambda(f + g)(y),$$

que es la concavidad de $f + g$. Es el Teorema 5.29 aplicado a $-f$ y $-g$ con coeficientes $1, 1 \geq 0$. (La hipótesis de coeficientes *no negativos* es esencial: $f - g$ con g cóncava no tiene por qué ser cóncava.)

El producto. Contraejemplo mínimo: en $C = (0, \infty)$ tomemos $f(x) = g(x) = x$. Ambas son afines, luego cóncavas (Ejemplo 5.5), y positivas en C . Su producto es

$$(fg)(x) = x^2,$$

que es *estrictamente convexa* (Ejemplo 5.4) y, por tanto, todo lo contrario de cóncava. Si se quiere un contraejemplo con factores *estrictamente* cóncavos, toma $f(x) = g(x) = \ln x$ en $x > 1$

(donde $\ln x > 0$): el producto es $\varphi(x) = (\ln x)^2$, y

$$\varphi'(x) = \frac{2 \ln x}{x}, \quad \varphi''(x) = \frac{\frac{2}{x} \cdot x - 2 \ln x}{x^2} = \frac{2(1 - \ln x)}{x^2},$$

que es *positiva* para $1 < x < e$: φ es convexa en $(1, e)$ pese a ser el producto de dos funciones estrictamente cóncavas y positivas allí. *Moraleja económica*: si u y v son utilidades cóncavas, $u + v$ es cóncava (por eso los bienestar utilitarios heredan concavidad), pero una utilidad multiplicativa tipo $u(x)v(y)$ no hereda concavidad: la Cobb–Douglas $x^a y^b$ es el caso paradigmático, pues con $0 < a, b \leq 1$ es un producto de dos cóncavas que solo resulta cóncavo si $a + b \leq 1$ (Ejemplo 5.27). Lo que sí se preserva siempre al multiplicar dos funciones *cóncavas y positivas* es la *cuasiconcavidad*: el logaritmo del producto es suma de dos funciones cóncavas, luego cóncavo, y los conjuntos de contorno superior del producto coinciden con los de ese logaritmo. Es el tema del Capítulo 6.

(c) *La moraleja*. La convexidad es una propiedad *global sobre un conjunto convexo*, no una propiedad puntual. Las tres reglas que hay que interiorizar:

- (I) *Un punto no dice nada*. Que $\nabla^2 f(x_0) \succeq 0$ en un punto x_0 no implica convexidad en ningún entorno con contenido económico; el Teorema 5.25 pide PSD en *todos* los puntos del convexo abierto donde se afirma la convexidad. El ejemplo (a) lo muestra: $\nabla^2 f(1, 1) \succ 0$ y sin embargo f no es convexa en $\mathbb{R}^2$.
- (II) *El dominio debe ser convexo*. Si el conjunto donde la Hessiana es PSD no es convexo, no se puede concluir nada global; hay que restringirse a un subconjunto convexo de él (en (a), $\mathbb{R}_+^2$ funciona).
- (III) *Las operaciones tienen hipótesis*. Sumar con pesos ≥ 0 , tomar supremos y componer con afines es siempre seguro; componer sin verificar monotonía, multiplicar funciones o tomar mínimos puntuales no lo es. Ante la duda, vuelve a la definición o al epígrafo.

□

Estrategia de examen

Protocolo para “¿es convexa esta función?” en un examen.

1. *Mira el dominio primero*. Si no es convexo, la pregunta está mal planteada o hay que restringirse (Ejercicio 5.52).
2. *Intenta el álgebra de operaciones antes que las derivadas*. Suma con pesos ≥ 0 , composición afín, supremo puntual, composición monótona: si la función se arma con esas piezas, terminaste en tres líneas y sin errores de cálculo (Ejercicio 5.48).
3. *Si es un supremo o un ínfimo de afines, ya está*. Supremo de afines $\Rightarrow$ convexa; ínfimo de afines $\Rightarrow$ cóncava. Toda función valor de un problema de optimización lineal en el parámetro cae aquí: beneficio, gasto, costo, valor inclusivo (Ejercicios 5.50 y 5.51).
4. *Solo entonces, la Hessiana*. Verifica C^2 , calcula $\nabla^2 f$ y usa menores líderes para

PD/ND y *todos* los principales para PSD/NSD (Ejercicio 5.47). Si hay parámetros, resuelve las desigualdades en ellos.

5. *Para negar la convexidad, un contraejemplo numérico.* Dos puntos y $\lambda = 1/2$ suelen bastar; o una recta sobre la que la restricción no sea convexa. Es más rápido y más convincente que argumentar con Hessianas.
6. *Convexidad estricta:* PD en todo punto la garantiza, pero su ausencia no la niega (x^4). Para negarla, busca un segmento sobre el que f sea afín.

Con esto cerramos el estudio de la convexidad “plena”. El capítulo siguiente (Capítulo 6) relaja la exigencia: veremos que para la mayor parte de la teoría de la demanda no hace falta que la utilidad sea cóncava (basta que sus conjuntos de contorno superior sean convexos, es decir, la *cuasiconcavidad*), la propiedad que recupera el recíproco fallido de la Proposición 5.16 y que es, a diferencia de la concavidad, *ordinal*.

Capítulo 6

Concavidad generalizada: funciones cuasicóncavas y cuasiconvexas [P1]

Semana 4 del cronograma. Bibliografía: Aragón et al. [1]; Brinkhuis [3].

¿Para qué sirve esto en Microeconomía?

Ningún supuesto sobre preferencias se usa tanto en Microeconomía como la cuasiconcavidad, y este es el capítulo que la construye. La razón es un hecho conceptual profundo: en la teoría del consumidor la utilidad es **ordinal**, no cardinal. La función u solo codifica un *orden* de preferencias, de modo que u y $v = g \circ u$ (con g estrictamente creciente) representan exactamente las mismas preferencias y deben ser económicamente indistinguibles. Pero la concavidad *no* sobrevive a transformaciones monótonas crecientes (lo verificaremos con $u(x, y) = xy$ y $v = \ln u$), mientras que la **cuasiconcavidad** sí: es la noción de “curvatura” *invariante ordinal*, la única que tiene sentido pedirle a una función de utilidad. En **decisión individual** (teoría del consumidor, MWG caps. 1–3, [9]), las preferencias convexas equivalen exactamente a utilidad cuasicóncava, y la *cuasiconcavidad estricta* es lo que garantiza que el problema del consumidor tenga solución *única*, es decir, que exista una *función* de demanda $x(p, m)$ bien definida (y no solo una correspondencia); sin ella, la estática comparativa, la ecuación de Slutsky y todo el aparato de demanda se vuelven mucho más delicados. El **Hessiano orlado** (*bordered Hessian*) es la herramienta operativa con la que se verifica cuasiconcavidad en los exámenes: en este capítulo lo construimos con cuidado, separamos condición necesaria de condición suficiente (punto donde muchos textos son imprecisos) y lo calculamos paso a paso en ejemplos 2×2 y 3×3 . Finalmente, la condición de **Spence–Mirrlees** o de *cruce único* (*single crossing*), pariente directo de esta familia de propiedades ordinales, es el motor de los modelos de señalización de Spence y de discriminación de precios y *screening* de Mussa–Rosen y Maskin–Riley (**fallas de mercado**, MWG caps. 13–14): ordena las curvas de indiferencia de los distintos tipos de agentes y hace que los contratos que separan tipos funcionen. Todo lo que hagas en contratos y mecanismos usará, a veces sin decirlo, los conceptos de este capítulo.

Los capítulos anteriores desarrollaron la teoría de las funciones cóncavas: la desigualdad de Jensen, las caracterizaciones de primer y segundo orden, la función soporte. La concavidad es

una propiedad *cardinal*: depende de los *valores* numéricos que toma la función, no solo del orden que induce entre los puntos. En economía, sin embargo, la utilidad es ordinal, y necesitamos una noción de “preferencia por la mezcla” que dependa únicamente de las *curvas de nivel* de la función y no de las etiquetas numéricas que les pongamos. Esa noción es la cuasiconcavidad, y este capítulo la desarrolla desde cero: definiciones equivalentes, jerarquía con la concavidad, criterios diferenciales (gradiente y Hessiano orlado), la clase intermedia de las funciones pseudocóncavas, y las aplicaciones económicas que justifican todo el esfuerzo. Las referencias principales son [1] (capítulo de convexidad generalizada), [9] (caps. 1–3 y apéndice M), [10] (caps. 1–2) y [3]. Del cuaderno usaremos: conjuntos convexos e intersecciones (cap. 2), y las caracterizaciones de primer y segundo orden de la concavidad.

6.1. La utilidad es ordinal: por qué la concavidad no basta [P1]

6.1.1. Preferencias, utilidad y transformaciones monótonas

Recordemos el punto de partida de la teoría del consumidor. Un consumidor tiene una relación de preferencias $\succsim$ sobre un conjunto de canastas $X \subseteq \mathbb{R}_+^n$: la expresión $x \succsim y$ se lee “ x es al menos tan buena como y ”. Una función $u: X \rightarrow \mathbb{R}$ *representa* a $\succsim$ si

$$x \succsim y \iff u(x) \geq u(y) \quad \text{para todo } x, y \in X.$$

Lo único que hace u es *ordenar* canastas. Los números concretos no significan nada: decir que $u(x) = 10$ y $u(y) = 5$ *no* dice que x “da el doble de felicidad” que y ; solo dice que $x \succ y$. Por eso se dice que la utilidad es *ordinal* (*ordinal utility*) y no *cardinal*.

Esta observación tiene una consecuencia inmediata. Sea $g: \mathbb{R} \rightarrow \mathbb{R}$ una función *estrictamente creciente* (*strictly increasing*): $s > t$ implica $g(s) > g(t)$. Entonces la función compuesta $v = g \circ u$, es decir $v(x) = g(u(x))$, satisface

$$v(x) \geq v(y) \iff g(u(x)) \geq g(u(y)) \iff u(x) \geq u(y) \iff x \succsim y,$$

donde la segunda equivalencia usa que g es estrictamente creciente (si $u(x) \geq u(y)$ entonces $g(u(x)) \geq g(u(y))$; y si $u(x) < u(y)$ entonces $g(u(x)) < g(u(y))$), así que $g(u(x)) \geq g(u(y))$ obliga a $u(x) \geq u(y)$). Conclusión: u y $v = g \circ u$ *representan exactamente las mismas preferencias*. Se dice que v es una *transformación monótona creciente* (*monotone increasing transformation*) de u .

Intuición

Piensa en u como un termómetro que en lugar de temperatura mide “qué tan arriba” está una canasta en el ranking del consumidor. Cambiar de u a $g \circ u$ es como pasar de grados Celsius a Fahrenheit, o a cualquier escala rara, incluso no lineal: los números cambian, pero el orden “hace más calor aquí que allá” es el mismo. Cualquier propiedad de u que pretenda tener *significado económico* debe ser invariante ante estos cambios de escala. Las propiedades que sobreviven se llaman *ordinales*; las que no, *cardinales*. La gran lección de

este capítulo: la concavidad es cardinal, la cuasiconcavidad es ordinal.

6.1.2. Un ejemplo revelador: $u(x, y) = xy$

Veamos con todo detalle que la concavidad puede aparecer o desaparecer al aplicar una transformación monótona, aunque las preferencias no cambien.

Ejemplo 6.1 ($u(x, y) = xy$ no es cóncava, pero $\ln u$ sí). Consideremos $u(x, y) = xy$ en el cuadrante abierto $\mathbb{R}_{++}^2 = \{(x, y) : x > 0, y > 0\}$, un conjunto convexo y abierto.

Paso 1: u no es cóncava. Como u es de clase C^2 , podemos usar la caracterización de segundo orden: u es cóncava en un abierto convexo si y solo si su matriz Hessiana es semidefinida negativa en todo punto. Calculamos las derivadas parciales:

$$\frac{\partial u}{\partial x} = y, \quad \frac{\partial u}{\partial y} = x, \quad \frac{\partial^2 u}{\partial x^2} = 0, \quad \frac{\partial^2 u}{\partial y^2} = 0, \quad \frac{\partial^2 u}{\partial x \partial y} = 1.$$

La Hessiana es, por tanto, constante:

$$H_u(x, y) = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Para que H_u sea semidefinida negativa se necesita, en particular, que su determinante (producto de los autovalores en el caso 2×2) sea ≥ 0 . Pero $\det H_u = 0 \cdot 0 - 1 \cdot 1 = -1 < 0$: los autovalores tienen signos opuestos (de hecho son $+1$ y -1 , con autovectores $(1, 1)$ y $(1, -1)$), así que H_u es *indefinida* y u no es cóncava (ni convexa) en $\mathbb{R}_{++}^2$. Concretamente, a lo largo de la diagonal $x = y = t$ tenemos $u = t^2$, que es *convexa* en t ; a lo largo de la antidiagonal la restricción es cóncava. La superficie $z = xy$ es una “silla de montar”.

Paso 2: $v = \ln u$ sí es cóncava. Apliquemos la transformación estrictamente creciente $g(t) = \ln t$ (definida sobre los valores $u > 0$ que toma u en $\mathbb{R}_{++}^2$):

$$v(x, y) = \ln(xy) = \ln x + \ln y.$$

Sus derivadas son $v_x = 1/x$, $v_y = 1/y$, y la Hessiana es

$$H_v(x, y) = \begin{pmatrix} -1/x^2 & 0 \\ 0 & -1/y^2 \end{pmatrix},$$

que es diagonal con entradas estrictamente negativas: definida negativa en todo punto de $\mathbb{R}_{++}^2$. Por la caracterización de segundo orden, v es (estrictamente) cóncava.


Conclusión. Las funciones $u = xy$ y $v = \ln x + \ln y$ representan *las mismas preferencias* (una es transformación monótona creciente de la otra), tienen *las mismas curvas de indiferencia* (las hipérbolas $xy = c$), pero una es cóncava y la otra no. La concavidad, por tanto, no es una propiedad de las preferencias: es un artefacto de la escala elegida. $\square$

Este ejemplo plantea la pregunta central del capítulo: ¿qué propiedad geométrica *comparten* $u = xy$ y $v = \ln x + \ln y$, y en general todas las representaciones de unas mismas preferencias

“bien comportadas”? La respuesta está en las *curvas de nivel*. Ambas funciones tienen los mismos conjuntos

$$\{(x, y) \in \mathbb{R}_{++}^2 : u(x, y) \geq c\} = \{(x, y) : xy \geq c\},$$

y estos conjuntos, la región “por encima” de cada hipérbola, son *convexas*. Esa es exactamente la definición de cuasiconcavidad.



La figura muestra curvas de indiferencia “convexas hacia el origen” (las hipérbolas $xy = c$ con $c_1 < c_2 < c_3$). Los puntos a y b están sobre la curva $u = c_2$; todo el segmento $[a, b]$ queda *por encima* de esa curva, es decir, dentro del conjunto $\{u \geq c_2\}$. Que esto ocurra para *cualquier* par de puntos y *cualquier* nivel es la cuasiconcavidad.

6.2. Cuasiconcavidad: definiciones y equivalencia [P1]

A lo largo del capítulo, $S \subseteq \mathbb{R}^n$ denota un conjunto *convexo* no vacío (el dominio de nuestras funciones). Recuerda del cap. 2 que esto significa: si $x, y \in S$ y $\lambda \in [0, 1]$, entonces $\lambda x + (1 - \lambda)y \in S$.

Definición 6.2 (Conjuntos de contorno superior e inferior). Sea $f: S \rightarrow \mathbb{R}$ y $\alpha \in \mathbb{R}$. El *conjunto de contorno superior* (*upper level set* o *upper contour set*) de nivel α es

$$S_\alpha(f) = \{x \in S : f(x) \geq \alpha\},$$

y el *conjunto de contorno inferior* (*lower level set*) es $I_\alpha(f) = \{x \in S : f(x) \leq \alpha\}$.

En la teoría del consumidor, si u representa a $\succsim$, el conjunto $S_{u(x^0)}(u) = \{x : u(x) \geq u(x^0)\}$ es exactamente el conjunto de canastas *al menos tan buenas como* x^0 : el conjunto de contorno superior de las preferencias en x^0 .

Definición 6.3 (Función cuasicóncava). Una función $f: S \rightarrow \mathbb{R}$ sobre un convexo $S \subseteq \mathbb{R}^n$ es *cuasicóncava* (*quasiconcave*) si su conjunto de contorno superior $S_\alpha(f)$ es convexo para *todo* $\alpha \in \mathbb{R}$.

Definición 6.4 (Definición por desigualdad). Una función $f: S \rightarrow \mathbb{R}$ satisface la *desigualdad de cuasiconcavidad* si para todo $x, y \in S$ y todo $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \geq \min\{f(x), f(y)\}.$$

Antes de demostrar que ambas definiciones coinciden, comparemos con la concavidad. Una función cóncava satisface $f(\lambda x + (1 - \lambda)y) \geq \lambda f(x) + (1 - \lambda)f(y)$: el valor en el punto intermedio supera al *promedio ponderado* de los valores extremos. La cuasiconcavidad pide algo mucho más débil: superar al *peor* de los dos valores. Como el promedio ponderado siempre está entre el mínimo y el máximo, la exigencia cuasicóncava es menor, y esto anticipa que toda cóncava será cuasicóncava.

Teorema 6.5 (Equivalencia de las dos definiciones). *Sea $S \subseteq \mathbb{R}^n$ convexo y $f: S \rightarrow \mathbb{R}$. Son equivalentes:*

(I) $S_\alpha(f)$ es convexo para todo $\alpha \in \mathbb{R}$;

(II) $f(\lambda x + (1 - \lambda)y) \geq \min\{f(x), f(y)\}$ para todo $x, y \in S$ y $\lambda \in [0, 1]$.

Demostración. (ii) $\Rightarrow$ (i). Fijemos $\alpha \in \mathbb{R}$ arbitrario y tomemos dos puntos cualesquiera $x, y \in S_\alpha(f)$; queremos ver que todo el segmento $[x, y]$ queda dentro de $S_\alpha(f)$. Por definición de $S_\alpha(f)$ tenemos $f(x) \geq \alpha$ y $f(y) \geq \alpha$, y por tanto $\min\{f(x), f(y)\} \geq \alpha$ (el mínimo de dos números $\geq \alpha$ es $\geq \alpha$). Sea $\lambda \in [0, 1]$. Como S es convexo, el punto $z = \lambda x + (1 - \lambda)y$ pertenece a S , y aplicando (ii):

$$f(z) \geq \min\{f(x), f(y)\} \geq \alpha,$$

es decir, $z \in S_\alpha(f)$. Como x, y, λ eran arbitrarios, $S_\alpha(f)$ es convexo; y como α era arbitrario, todos los conjuntos de contorno superior son convexos.

(i) $\Rightarrow$ (ii). Tomemos $x, y \in S$ y $\lambda \in [0, 1]$ arbitrarios. La idea clave es *elegir bien el nivel α* : definimos

$$\alpha^* = \min\{f(x), f(y)\}.$$

Con esta elección, *ambos* puntos pertenecen a $S_{\alpha^*}(f)$: en efecto, $f(x) \geq \alpha^*$ (pues α^* es el mínimo entre $f(x)$ y otro número) y análogamente $f(y) \geq \alpha^*$. Por (i), $S_{\alpha^*}(f)$ es convexo, así que el punto $z = \lambda x + (1 - \lambda)y$ también pertenece a $S_{\alpha^*}(f)$. Pero pertenecer a $S_{\alpha^*}(f)$ significa exactamente

$$f(z) \geq \alpha^* = \min\{f(x), f(y)\},$$

que es la desigualdad (ii). □

Intuición

La definición por conjuntos de nivel es la *económica*: dice que los conjuntos “al menos tan bueno como” son convexos, o sea, que las curvas de indiferencia se curvan hacia el origen y el consumidor (débilmente) prefiere las mezclas. La definición por desigualdad es la *operativa*: dice que al caminar en línea recta de x a y , el valor de f nunca cae por debajo del peor de los dos extremos: no hay “valles” en el camino. El truco de la demostración (i) $\Rightarrow$ (ii) merece memorizarse: cuando quieras usar convexidad de conjuntos de nivel para comparar dos puntos, evalúa el nivel en $\alpha = \min\{f(x), f(y)\}$, porque ese es el mayor nivel al que ambos puntos pertenecen simultáneamente.

6.2.1. Cuasiconvexidad, cuasilinealidad y versión estricta

Definición 6.6 (Función cuasiconvexa). $f: S \rightarrow \mathbb{R}$ es *cuasiconvexa* (*quasiconvex*) si $-f$ es cuasicóncava; equivalentemente, si sus conjuntos de contorno inferior $I_\alpha(f) = \{x \in S : f(x) \leq \alpha\}$ son convexos para todo α , o si

$$f(\lambda x + (1 - \lambda)y) \leq \max\{f(x), f(y)\} \quad \text{para todo } x, y \in S, \lambda \in [0, 1].$$

La equivalencia de las tres formulaciones se obtiene aplicando el Teorema 6.5 a $-f$ y usando que $\{x : -f(x) \geq -\alpha\} = \{x : f(x) \leq \alpha\}$ y que $\min\{-a, -b\} = -\max\{a, b\}$ (verifícalo con dos números). En economía, las funciones de *costo* o de *gasto* vistas como funciones de las cantidades suelen tratarse con cuasiconvexidad; y la función de utilidad *indirecta* $v(p, m)$ es cuasiconvexa en p (un resultado clásico de la teoría del consumidor, MWG cap. 3, que ahora podrás demostrar).

Definición 6.7 (Función cuasilineal). $f: S \rightarrow \mathbb{R}$ es *cuasilineal* (*quasilinear*, también llamada *cuasimonótona*) si es a la vez cuasicóncava y cuasiconvexa; equivalentemente, si *todos* sus conjuntos de contorno superior e inferior son convexos.

Ejemplo 6.8 (Toda función monótona en $\mathbb{R}$ es cuasilineal). Sea $f: \mathbb{R} \rightarrow \mathbb{R}$ monótona no decreciente (el caso no creciente es análogo). Entonces $S_\alpha(f) = \{x : f(x) \geq \alpha\}$ es un intervalo de la forma $[c, \infty)$ o (c, ∞) (o vacío, o todo $\mathbb{R}$): en efecto, si $f(x) \geq \alpha$ y $x' > x$, la monotonía da $f(x') \geq f(x) \geq \alpha$, así que $S_\alpha(f)$ contiene a todo punto a la derecha de cualquiera de sus elementos, y un conjunto de $\mathbb{R}$ con esa propiedad es un intervalo no acotado por la derecha. Los intervalos son convexos, luego f es cuasicóncava. El mismo argumento con desigualdades invertidas muestra que los contornos inferiores son intervalos, luego f es también cuasiconvexa: f es cuasilineal. En particular, $f(x) = x^3$ y $f(x) = e^x$ son cuasilineales en $\mathbb{R}$, aunque x^3 no es cóncava ni convexa y e^x es convexa pero no cóncava. $\square$

Observación 6.9 (Sobre el término “utilidad cuasilineal” en micro). En microeconomía se llama *utilidad cuasilineal* a $u(x, m) = \varphi(x) + m$, lineal en el numerario m (“dinero”). El nombre alude a esa linealidad parcial, y *no* coincide con la Definición 6.7: si φ es cóncava, $u(x, m) = \varphi(x) + m$ es cóncava (suma de cóncava y lineal), luego cuasicóncava, pero en general *no* es cuasiconvexa, así que no es cuasilineal en el sentido de la convexidad generalizada. El ejemplo canónico que sí une ambos mundos es la utilidad *lineal* $u(x) = \langle a, x \rangle$, que es cóncava y convexa a la vez y, por tanto, cuasilineal: sus conjuntos de contorno superior e inferior son semiespacios. Ten presente el doble uso del término para no confundirte en Microeconomía.

Definición 6.10 (Cuasiconcavidad estricta). $f: S \rightarrow \mathbb{R}$ es *estrictamente cuasicóncava* (*strictly quasiconcave*) si para todo $x, y \in S$ con $x \neq y$ y todo $\lambda \in (0, 1)$,

$$f(\lambda x + (1 - \lambda)y) > \min\{f(x), f(y)\}.$$

Análogamente, f es *estrictamente cuasiconvexa* si $-f$ es estrictamente cuasicóncava.

La versión estricta prohíbe “tramos planos” en las curvas de indiferencia: si dos canastas distintas son indiferentes entre sí, cualquier mezcla propia es *estrictamente mejor*. Geométricamente, las curvas de indiferencia no contienen segmentos de recta. Esta es la hipótesis que en la Sección 6.8 nos dará *unicidad* de la demanda.

Cuidado (error común)

Cuidado con dos deslices frecuentes en exámenes. *Primero:* en la Definición 6.10 la desigualdad estricta se exige para *todo* par $x \neq y$, incluso cuando $f(x) = f(y)$; algunos textos usan una versión más débil (solo cuando $f(x) \neq f(y)$), pero esa versión débil *no* garantiza unicidad del maximizador, que es justamente lo que queremos en micro. Usa siempre la Definición 6.10 salvo indicación contraria. *Segundo:* “estrictamente cuasicóncava” *no* implica “estrictamente cóncava” ni al revés que “cóncava” implique “estrictamente cuasicóncava”: en $\mathbb{R}^n$ con $n \geq 2$, la función lineal $f(x) = \langle a, x \rangle$ con $a \neq 0$ es cóncava pero no estrictamente cuasicóncava (sobre un hiperplano de indiferencia, las mezclas no mejoran nada); y $f(x) = x^3$ es estrictamente cuasicóncava en $\mathbb{R}$ (es estrictamente creciente, mira el Ejercicio 6.49) sin ser cóncava. Son jerarquías paralelas, no anidadas entre sí.

6.3. Jerarquía y propiedades ordinales [P1]**6.3.1. Cóncava implica cuasicóncava (pero no al revés)**

Proposición 6.11 (Concavidad implica cuasiconcavidad). *Si $f: S \rightarrow \mathbb{R}$ es cóncava en el convexo S , entonces f es cuasicóncava. Si f es estrictamente cóncava, entonces es estrictamente cuasicóncava.*

Demostración. Sean $x, y \in S$ y $\lambda \in [0, 1]$. Escribamos $m = \min\{f(x), f(y)\}$; por definición de mínimo, $f(x) \geq m$ y $f(y) \geq m$. La concavidad de f da la primera desigualdad de la cadena

$$f(\lambda x + (1 - \lambda)y) \geq \lambda f(x) + (1 - \lambda)f(y) \geq \lambda m + (1 - \lambda)m = m,$$

y la segunda desigualdad usa que $\lambda \geq 0$ y $1 - \lambda \geq 0$ (multiplicar una desigualdad por un número no negativo la preserva, y luego sumamos las dos desigualdades resultantes). Esto es exactamente la desigualdad de cuasiconcavidad. Para la versión estricta: si $x \neq y$ y $\lambda \in (0, 1)$, la concavidad estricta hace estricta la primera desigualdad, y se concluye $f(\lambda x + (1 - \lambda)y) > m$. $\square$

El recíproco es falso, y los contraejemplos son importantes porque delimitan cuánto más débil es la cuasiconcavidad.

Ejemplo 6.12 (Cuasicóncavas que no son cóncavas). (a) $f(x) = x^3$ en $\mathbb{R}$ es estrictamente creciente, luego cuasicóncava (Ejemplo 6.8); pero no es cóncava: $f''(x) = 6x > 0$ para $x > 0$, y una función cóncava diferenciable dos veces debe tener $f'' \leq 0$ en todo punto.

(b) $f(x) = e^x$ en $\mathbb{R}$ es creciente, luego cuasicóncava; pero es estrictamente *convexa* ($f'' = e^x > 0$). Una función puede ser convexa y cuasicóncava a la vez: la cuasiconcavidad no impone curvatura “hacia abajo”, solo la forma de los conjuntos de nivel.

(c) Cualquier función monótona de una variable, por escalonada o irregular que sea, es cuasicóncava. En $\mathbb{R}$, la cuasiconcavidad de f equivale a que f sea “unimodal” en sentido amplio (no decreciente hasta un punto y no creciente después, incluidos como casos límite los dos tipos de monotonía); no dice nada sobre curvatura.

- (d) $u(x, y) = xy$ en $\mathbb{R}_{++}^2$: como vimos en el Ejemplo 6.1, no es cóncava; en la Sección 6.4 demostraremos que sí es cuasicóncava. $\square$

6.3.2. La propiedad ordinal clave

El siguiente teorema es la razón de ser del capítulo: la cuasiconcavidad sobrevive a los cambios de escala ordinales.

Teorema 6.13 (Invariancia ante transformaciones monótonas). *Sea $f: S \rightarrow \mathbb{R}$ cuasicóncava y sea $g: T \rightarrow \mathbb{R}$ no decreciente, donde $T \subseteq \mathbb{R}$ contiene a la imagen de f . Entonces $g \circ f$ es cuasicóncava. Si f es estrictamente cuasicóncava y g es estrictamente creciente, entonces $g \circ f$ es estrictamente cuasicóncava.*

Demostración. Usamos la definición por desigualdad. Sean $x, y \in S$ y $\lambda \in [0, 1]$, y llamemos $z = \lambda x + (1 - \lambda)y \in S$. Por cuasiconcavidad de f ,

$$f(z) \geq \min\{f(x), f(y)\}.$$

Aplicamos g , que es no decreciente, a ambos lados (esto preserva la desigualdad):

$$g(f(z)) \geq g(\min\{f(x), f(y)\}).$$

Falta un paso pequeño pero crucial: para cualquier función no decreciente g y números s, t ,

$$g(\min\{s, t\}) = \min\{g(s), g(t)\}.$$

En efecto, supongamos sin pérdida de generalidad $s \leq t$; entonces $\min\{s, t\} = s$ y, como g es no decreciente, $g(s) \leq g(t)$, de modo que $\min\{g(s), g(t)\} = g(s) = g(\min\{s, t\})$. Combinando:

$$(g \circ f)(z) \geq \min\{(g \circ f)(x), (g \circ f)(y)\},$$

que es la cuasiconcavidad de $g \circ f$. Para la versión estricta: si $x \neq y$, $\lambda \in (0, 1)$, la cuasiconcavidad estricta de f da $f(z) > \min\{f(x), f(y)\}$ y la monotonía estricta de g convierte esa desigualdad estricta en $g(f(z)) > g(\min\{f(x), f(y)\}) = \min\{g(f(x)), g(f(y))\}$. $\square$

Intuición

Compara con la concavidad: si f es cóncava y g es creciente, $g \circ f$ puede perder la concavidad, porque la desigualdad de concavidad involucra el *promedio* $\lambda f(x) + (1 - \lambda)f(y)$, y las funciones crecientes no conmutan con promedios (solo las afines lo hacen; las crecientes *cóncavas* al menos preservan la desigualdad en el sentido correcto, por eso “cóncava creciente de cóncava es cóncava”). En cambio, la desigualdad de cuasiconcavidad involucra el *mínimo*, y cualquier función creciente conmuta con el mínimo: aplicar g no cambia cuál de los dos valores es el menor. Por eso la cuasiconcavidad es ordinal y la concavidad no. Ejemplo concreto de la pérdida de concavidad: $f(x) = \sqrt{x}$ es cóncava en $\mathbb{R}_+$ y $g(t) = t^4$ es creciente en $\mathbb{R}_+$, pero $(g \circ f)(x) = x^2$ es estrictamente convexa.

6.3.3. Operaciones que no preservan la cuasiconcavidad

Con las funciones cóncavas tenemos un “álgebra” cómoda: la suma de cóncavas es cóncava, las combinaciones lineales con coeficientes positivos son cóncavas, el mínimo puntual de cóncavas es cóncavo. Con la cuasiconcavidad casi toda esa álgebra *se pierde*. La trampa de examen por excelencia:

Cuidado (error común)

La suma de funciones cuasicóncavas NO es, en general, cuasicóncava. Contraejemplo explícito en $\mathbb{R}$: sean $f(x) = x^3$ y $g(x) = -x$. Ambas son monótonas, luego cuasicóncavas (Ejemplo 6.8). Su suma es $h(x) = x^3 - x$. Evaluemos: $h(-1) = -1 + 1 = 0$, $h(0) = 0$, $h(1) = 1 - 1 = 0$ y $h(1/2) = 1/8 - 1/2 = -3/8 < 0$. Si h fuera cuasicóncava, el conjunto $S_0(h) = \{x : h(x) \geq 0\}$ sería convexo; pero $-1 \in S_0(h)$ y $1 \in S_0(h)$ mientras que el punto intermedio $1/2 = \frac{1}{4}(-1) + \frac{3}{4}(1)$ es combinación convexa de -1 y 1 y cumple $h(1/2) < 0$, así que $1/2 \notin S_0(h)$. El contorno superior $S_0(h) = [-1, 0] \cup [1, \infty)$ no es convexo: h no es cuasicóncava. Moraleja de examen: si te piden “demuestra o refuta: la suma de cuasicóncavas es cuasicóncava”, la respuesta es *refuta*, con este contraejemplo. Lo mismo vale para restas, productos y combinaciones lineales en general.

¿Qué operaciones *sí* preservan la cuasiconcavidad? Las que actúan sobre los conjuntos de nivel de forma compatible con la convexidad:

Proposición 6.14 (Operaciones que preservan cuasiconcavidad). (a) (Mínimo puntual) Si $f_1, \dots, f_k : S \rightarrow \mathbb{R}$ son cuasicóncavas, entonces $f(x) = \min\{f_1(x), \dots, f_k(x)\}$ es cuasicóncava.

(b) (Transformación monótona) Si f es cuasicóncava y g es no decreciente, $g \circ f$ es cuasicóncava (Teorema 6.13).

(c) (Composición con afín) Si f es cuasicóncava en un convexo $D \subseteq \mathbb{R}^m$ y $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, entonces $h(x) = f(Ax + b)$ es cuasicóncava en el convexo $\{x \in \mathbb{R}^n : Ax + b \in D\}$.

(d) (Restricción a convexos) Si f es cuasicóncava en S y $C \subseteq S$ es convexo, la restricción de f a C es cuasicóncava.

Demostración. (a) Para cada α ,

$$\{x : \min_i f_i(x) \geq \alpha\} = \bigcap_{i=1}^k \{x : f_i(x) \geq \alpha\} = \bigcap_{i=1}^k S_\alpha(f_i),$$

porque el mínimo de varios números es $\geq \alpha$ exactamente cuando todos lo son. Cada $S_\alpha(f_i)$ es convexo por hipótesis, y la intersección de convexos es convexa (cap. 2); luego el contorno superior de f es convexo para todo α . (c) $\{x : f(Ax + b) \geq \alpha\}$ es la preimagen del convexo $S_\alpha(f)$ bajo la aplicación afín $x \mapsto Ax + b$, y las preimágenes afines de convexos son convexas (cap. 2). (d) $S_\alpha(f|_C) = S_\alpha(f) \cap C$, intersección de convexos. $\square$

Nota el contraste con el *máximo*: el máximo puntual de cuasicóncavas *no* es cuasicóncavo en general (el Ejercicio 6.46 pide el contraejemplo), mientras que para funciones *convexas* el máximo

sí preserva convexidad. La simetría es: cuasicóncava $\leftrightarrow$ mínimo e intersección de contornos superiores; cuasiconvexa $\leftrightarrow$ máximo e intersección de contornos inferiores.

6.4. Ejemplos económicos fundamentales [P1]

Esta sección resuelve con todos los pasos los cuatro ejemplos de función de utilidad que aparecen una y otra vez en Microeconomía.

6.4.1. Cobb–Douglas

Proposición 6.15 (Cuasiconcavidad de Cobb–Douglas). *Sea $u(x, y) = x^a y^b$ con $a, b > 0$, definida en $\mathbb{R}_+^2$. Entonces:*

- (a) *u es cuasicóncava en $\mathbb{R}_+^2$ para todos los valores $a, b > 0$, y estrictamente cuasicóncava en $\mathbb{R}_{++}^2$;*
- (b) *u es cóncava en $\mathbb{R}_+^2$ si y solo si $a + b \leq 1$.*

Demostración. (a) *Paso 1: el interior, vía transformación logarítmica.* En $\mathbb{R}_{++}^2$ los valores de u son positivos y podemos escribir

$$u(x, y) = \exp(a \ln x + b \ln y) = (g \circ v)(x, y), \quad v(x, y) = a \ln x + b \ln y, \quad g(t) = e^t.$$

La función v es cóncava: es combinación lineal con coeficientes positivos a, b de las funciones cóncavas $\ln x$ y $\ln y$ (cada una es cóncava porque su segunda derivada, $-1/x^2$ y $-1/y^2$ respectivamente, es negativa; y las sumas ponderadas con pesos positivos de cóncavas son cóncavas). Más aún, v es estrictamente cóncava en $\mathbb{R}_{++}^2$: su Hessiana $\text{diag}(-a/x^2, -b/y^2)$ es definida negativa. Por la Proposición 6.11, v es estrictamente cuasicóncava; y como $g(t) = e^t$ es estrictamente creciente, el Teorema 6.13 da que $u = g \circ v$ es estrictamente cuasicóncava en $\mathbb{R}_{++}^2$.

Paso 2: extensión a la frontera de $\mathbb{R}_+^2$. Verificamos directamente que los contornos superiores de u en $\mathbb{R}_+^2$ son convexos. Si $\alpha \leq 0$, entonces $S_\alpha(u) = \mathbb{R}_+^2$ (pues $u \geq 0$ siempre), que es convexo. Si $\alpha > 0$, entonces $u(x, y) \geq \alpha$ obliga a $x > 0$ e $y > 0$, así que $S_\alpha(u) = \{(x, y) \in \mathbb{R}_{++}^2 : u(x, y) \geq \alpha\}$, que es convexo por el Paso 1 (es un contorno superior de una cuasicóncava en el convexo $\mathbb{R}_{++}^2$). Luego u es cuasicóncava en todo $\mathbb{R}_+^2$.

(b) Calculemos la Hessiana en $\mathbb{R}_{++}^2$. Las derivadas parciales son

$$u_x = ax^{a-1}y^b = \frac{a}{x}u, \quad u_y = bx^ay^{b-1} = \frac{b}{y}u,$$

$$u_{xx} = a(a-1)x^{a-2}y^b, \quad u_{yy} = b(b-1)x^ay^{b-2}, \quad u_{xy} = abx^{a-1}y^{b-1}.$$

El determinante de la Hessiana es

$$\begin{aligned} \det H_u &= u_{xx}u_{yy} - u_{xy}^2 \\ &= a(a-1)b(b-1)x^{2a-2}y^{2b-2} - a^2b^2x^{2a-2}y^{2b-2} \\ &= abx^{2a-2}y^{2b-2}[(a-1)(b-1) - ab] \\ &= abx^{2a-2}y^{2b-2}[ab - a - b + 1 - ab] = abx^{2a-2}y^{2b-2}(1 - a - b). \end{aligned}$$

Si $a + b > 1$, entonces $\det H_u < 0$ en todo punto: la Hessiana es indefinida y u no es cóncava (esto generaliza el caso $a = b = 1$, $u = xy$, del Ejemplo 6.1). Si $a + b \leq 1$, entonces $\det H_u \geq 0$ y además $u_{xx} = a(a-1)x^{a-2}y^b \leq 0$ (porque $a \leq a+b \leq 1$ implica $a-1 \leq 0$): la Hessiana es semidefinida negativa en $\mathbb{R}_{++}^2$ y u es cóncava allí; la concavidad se extiende a $\mathbb{R}_+^2$ por continuidad de u (la desigualdad de concavidad, al ser no estricta, pasa al límite en la frontera). $\square$

Intuición

El mensaje económico de la Proposición 6.15 es exactamente el de la Sección 6.1: las preferencias Cobb–Douglas son las mismas para $u = x^a y^b$ que para su transformación monótona $u^{1/(a+b)} = x^{a/(a+b)} y^{b/(a+b)}$, cuyos exponentes suman 1 y que por tanto *sí* es cóncava. La “no concavidad” cuando $a + b > 1$ es puro artefacto de escala; la cuasiconcavidad, que es lo que importa para las preferencias y para la demanda, vale siempre. Esta técnica, concavificar tomando logaritmos o raíces, reaparecerá en la Sección 6.8 como “concavidad oculta”.

6.4.2. CES, Leontief y utilidad lineal

Ejemplo 6.16 (CES). La utilidad de *elasticidad de sustitución constante* (CES, *constant elasticity of substitution*) es

$$u(x, y) = (ax^\rho + by^\rho)^{1/\rho}, \quad a, b > 0, \quad \rho \leq 1, \quad \rho \neq 0,$$

en $\mathbb{R}_{++}^2$. Demostremos que es cuasicóncava, separando por casos.

Caso $0 < \rho \leq 1$. La función interior $w(x, y) = ax^\rho + by^\rho$ es cóncava: $t \mapsto t^\rho$ tiene segunda derivada $\rho(\rho-1)t^{\rho-2} \leq 0$ en $t > 0$ (pues $0 < \rho \leq 1$ hace $\rho-1 \leq 0$), así que x^ρ e y^ρ son cóncavas y w es suma ponderada positiva de cóncavas. La transformación exterior $g(t) = t^{1/\rho}$ es estrictamente creciente en $t > 0$ (exponente positivo). Entonces $u = g \circ w$ es transformación creciente de una cóncava (en particular cuasicóncava), luego cuasicóncava por el Teorema 6.13. (Nota: g es convexa si $\rho < 1$, así que este argumento *no* da concavidad de u directamente; la concavidad de la CES es cierta pero requiere el argumento de homogeneidad: una función no negativa, cuasicóncava y positivamente homogénea de grado 1 sobre un cono convexo es cóncava.)

Caso $\rho < 0$. Ahora $t \mapsto t^\rho$ es *convexa* y decreciente en $t > 0$ (segunda derivada $\rho(\rho-1)t^{\rho-2} > 0$ porque $\rho < 0$ y $\rho-1 < 0$ tienen producto positivo), de modo que $w = ax^\rho + by^\rho$ es convexa, y por tanto *cuasiconvexa*. La transformación exterior $g(t) = t^{1/\rho}$ es estrictamente *decreciente* en $t > 0$ (exponente negativo). Una transformación decreciente intercambia contornos superiores e inferiores: $\{u \geq \alpha\} = \{g(w) \geq \alpha\} = \{w \leq g^{-1}(\alpha)\}$ para α en el rango relevante (la desigualdad se invierte al aplicar g^{-1} , también decreciente), y los contornos *inferiores* de la convexa w son convexos. Luego los contornos superiores de u son convexos: u es cuasicóncava.

Los casos límite completan la familia: cuando $\rho \rightarrow 0$ la CES converge a Cobb–Douglas (con exponentes $a/(a+b)$, $b/(a+b)$), y cuando $\rho \rightarrow -\infty$ converge a la Leontief $\min\{x, y\}$; ambas cuasicóncavas, como corresponde. $\square$

Ejemplo 6.17 (Leontief o proporciones fijas). Sea $u(x, y) = \min\{ax, by\}$ con $a, b > 0$ en $\mathbb{R}_+^2$

(complementos perfectos: zapatos izquierdos y derechos). Cada una de las funciones ax y by es lineal, luego cóncava y cuasicóncava; por la Proposición 6.14(a), el mínimo u es cuasicóncavo. Se puede ver también directamente: para $\alpha \leq 0$ el contorno superior es todo $\mathbb{R}_+^2$; para $\alpha > 0$,

$$\{(x, y) : \min\{ax, by\} \geq \alpha\} = \{x \geq \alpha/a\} \cap \{y \geq \alpha/b\},$$

intersección de dos semiespacios, convexa. (De hecho u es *cóncava*: el mínimo puntual de funciones cóncavas es cóncavo.) Pero u no es estrictamente cuasicóncava: los puntos $(1, 2)$ y $(1, 3)$ con $a = b = 1$ cumplen $u = 1$ en ambos, y en cualquier punto intermedio $(1, y)$ con $2 \leq y \leq 3$ sigue siendo $u = 1$, no > 1 : las curvas de indiferencia en forma de “L” tienen tramos planos. $\square$

Ejemplo 6.18 (Utilidad lineal). $u(x, y) = ax + by$ con $a, b > 0$ (sustitutos perfectos) es cóncava y convexa a la vez (es afín), luego cuasicóncava y cuasiconvexa: cuasilineal en el sentido de la Definición 6.7. Sus curvas de indiferencia son rectas de pendiente $-a/b$. No es estrictamente cuasicóncava: dos puntos distintos sobre la misma recta de indiferencia tienen mezclas exactamente indiferentes. Veremos en la Sección 6.8 que esta falla es la responsable de que la demanda con sustitutos perfectos pueda ser *multivaluada* (todo el segmento presupuestario es óptimo cuando $p_1/p_2 = a/b$). $\square$

6.4.3. Preferencias convexas y utilidad cuasicóncava

Definición 6.19 (Preferencias convexas). Una relación de preferencias $\succsim$ sobre un convexo $X \subseteq \mathbb{R}^n$ es *convexa* si para todo $x^0 \in X$ el conjunto de contorno superior $\{y \in X : y \succsim x^0\}$ es convexo. Es *estrictamente convexa* si, además, $y \succsim x^0$, $z \succsim x^0$ y $y \neq z$ implican $\lambda y + (1 - \lambda)z \succ x^0$ para todo $\lambda \in (0, 1)$.

Teorema 6.20 (Convexidad de preferencias = cuasiconcavidad de la utilidad). Sea $\succsim$ una relación de preferencias sobre el convexo X representada por la función de utilidad $u: X \rightarrow \mathbb{R}$. Entonces $\succsim$ es convexa si y solo si u es cuasicóncava; $y \succsim$ es estrictamente convexa si y solo si u es estrictamente cuasicóncava.

Demostración. ($\Leftarrow$) Si u es cuasicóncava, para cada x^0 el conjunto $\{y : y \succsim x^0\} = \{y : u(y) \geq u(x^0)\} = S_{u(x^0)}(u)$ es un contorno superior de u , luego convexo.

($\Rightarrow$) Supongamos que $\succsim$ es convexa, es decir, que $S_{u(x^0)}(u)$ es convexo para niveles de la forma $\alpha = u(x^0)$ (niveles alcanzados por u). Ojo: esto no es directamente la Definición 6.3, que pide convexidad para *todo* $\alpha \in \mathbb{R}$, incluso niveles que u no alcanza. Usamos entonces la definición por desigualdad. Sean $x, y \in X$, $\lambda \in [0, 1]$; sin pérdida de generalidad $u(y) \leq u(x)$, de modo que $\min\{u(x), u(y)\} = u(y)$, un nivel alcanzado (en el punto y). Ambos puntos pertenecen a $\{z : z \succsim y\}$: y trivialmente (reflexividad: $u(y) \geq u(y)$) y x porque $u(x) \geq u(y)$. Por convexidad de las preferencias, $\lambda x + (1 - \lambda)y \in \{z : z \succsim y\}$, o sea

$$u(\lambda x + (1 - \lambda)y) \geq u(y) = \min\{u(x), u(y)\} :$$

la desigualdad de cuasiconcavidad. El caso estricto es idéntico usando la Definición 6.19 estricta con $x^0 = y$ y la Definición 6.10. $\square$

Intuición

Preferencia convexa significa *gusto por la diversificación*: si dos canastas son aceptables, sus mezclas también lo son; en la versión estricta, mezclar canastas indiferentes es estrictamente mejor (“mejor un poco de pan y un poco de queso que mucho de uno solo”). El Teorema 6.20 dice que esta propiedad puramente *conductual*, formulada sin mencionar números, es exactamente la cuasiconcavidad de *cualquier* representación de utilidad. Es la confirmación final de que la cuasiconcavidad es la noción correcta: una propiedad de preferencias tenía que corresponder a una propiedad ordinal de u . Puedes ver MWG, cap. 3.B–3.C [9] y [10], cap. 1.

6.5. Caracterización diferencial de primer orden [P1]

Recordemos la caracterización de primer orden de la concavidad: f diferenciable es cóncava si y solo si $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle$ para todo x, y (el grafo queda debajo de cada plano tangente). La versión cuasicóncava reemplaza esa desigualdad *cardinal* por una condición puramente *direccional*: el gradiente debe “apuntar hacia” los puntos mejores.

Teorema 6.21 (Caracterización de primer orden de la cuasiconcavidad). *Sea $S \subseteq \mathbb{R}^n$ convexo y abierto, y $f: S \rightarrow \mathbb{R}$ diferenciable. Entonces f es cuasicóncava si y solo si*

$$\text{para todo } x, y \in S: \quad f(y) \geq f(x) \implies \langle \nabla f(x), y - x \rangle \geq 0.$$

Demostración. ($\Rightarrow$) Demostración completa. Supongamos f cuasicóncava y tomemos $x, y \in S$ con $f(y) \geq f(x)$. Para cada $\lambda \in (0, 1]$, el punto $x + \lambda(y - x) = (1 - \lambda)x + \lambda y$ está en S , y la desigualdad de cuasiconcavidad da

$$f(x + \lambda(y - x)) \geq \min\{f(x), f(y)\} = f(x),$$

donde la igualdad final usa la hipótesis $f(y) \geq f(x)$. Restando $f(x)$ y dividiendo entre $\lambda > 0$ (lo cual preserva el sentido de la desigualdad):

$$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \geq 0 \quad \text{para todo } \lambda \in (0, 1].$$

El lado izquierdo es el cociente incremental de la función de una variable $\varphi(\lambda) = f(x + \lambda(y - x))$ en $\lambda = 0$. Como f es diferenciable, la regla de la cadena garantiza que el límite cuando $\lambda \rightarrow 0^+$ existe y vale la derivada direccional

$$\lim_{\lambda \rightarrow 0^+} \frac{f(x + \lambda(y - x)) - f(x)}{\lambda} = \langle \nabla f(x), y - x \rangle.$$

Los límites preservan desigualdades no estrictas, así que $\langle \nabla f(x), y - x \rangle \geq 0$, como se quería.

($\Leftarrow$) *Idea y referencia.* La dirección recíproca es más laboriosa; la enunciamos con su esquema y remitimos la prueba detallada a [1] (capítulo de convexidad generalizada) o [9], Teorema M.C.3. Esquema: si f no fuera cuasicóncava, existirían x, y y un punto $z^* = (1 - \lambda^*)x + \lambda^*y$ del segmento

con $f(z^*) < \min\{f(x), f(y)\}$. Se toma z^* como un mínimo de f sobre el (compacto) segmento $[x, y]$, alcanzado en el interior del segmento. Como $f(x) \geq f(z^*)$ y $f(y) \geq f(z^*)$, la condición del gradiente aplicada en z^* contra x y contra y da $\langle \nabla f(z^*), x - z^* \rangle \geq 0$ y $\langle \nabla f(z^*), y - z^* \rangle \geq 0$. Pero $x - z^*$ e $y - z^*$ son múltiplos *negativos* uno del otro (apuntan en sentidos opuestos a lo largo del segmento), así que ambos productos internos son opuestos en signo: la única salida es que ambos sean cero, es decir, la derivada de f a lo largo del segmento se anula en z^* . Un argumento adicional (aplicando lo anterior a *todos* los puntos del conjunto donde el mínimo se alcanza y usando el teorema del valor medio) muestra que entonces f sería constante en un subsegmento que contiene a z^* y a un punto con valor $> f(z^*)$, contradicción. $\square$

Intuición

Interpretación geométrica, que conecta con el capítulo de separación y función soporte: fija x con $\nabla f(x) \neq 0$. El teorema dice que *todo* el conjunto de contorno superior $S_{f(x)}(f) = \{y : f(y) \geq f(x)\}$ queda contenido en el semiespacio

$$H^+ = \{y : \langle \nabla f(x), y - x \rangle \geq 0\},$$

cuyo borde es el hiperplano que pasa por x con normal $\nabla f(x)$. Es decir: **el gradiente soporta al conjunto de contorno superior en x** . En la teoría del consumidor esto es la tangencia clásica: el hiperplano es la recta tangente a la curva de indiferencia, el gradiente $\nabla u(x)$ (el vector de utilidades marginales) es normal a ella, y todas las canastas mejores quedan del lado hacia el que apunta el gradiente. En el óptimo del consumidor, ese hiperplano soporte es la recta presupuestaria y $\nabla u(x^*) = \mu p$: la condición de primer orden de Lagrange es un enunciado de *separación* entre el conjunto “mejor que” y el conjunto presupuestario.

6.6. El Hessiano orlado [P1]

Para funciones cóncavas, la herramienta de segundo orden es la Hessiana (semidefinida negativa). Para funciones cuasicóncavas, la herramienta es la Hessiana *orlada* con el gradiente. Esta sección es la más “operativa” del capítulo: es la que usarás en los exámenes.

6.6.1. Construcción de la matriz

Definición 6.22 (Hessiano orlado). Sea $f : S \rightarrow \mathbb{R}$ de clase C^2 en un abierto $S \subseteq \mathbb{R}^n$. Escribimos $f_i = \partial f / \partial x_i$ y $f_{ij} = \partial^2 f / \partial x_i \partial x_j$. Para cada $r = 1, \dots, n$, el *Hessiano orlado* (*bordered Hessian*) de orden r en el punto x es la matriz $(r+1) \times (r+1)$

$$B_r(x) = \begin{pmatrix} 0 & f_1 & f_2 & \cdots & f_r \\ f_1 & f_{11} & f_{12} & \cdots & f_{1r} \\ f_2 & f_{21} & f_{22} & \cdots & f_{2r} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ f_r & f_{r1} & f_{r2} & \cdots & f_{rr} \end{pmatrix},$$

todas las derivadas evaluadas en x : es la esquina $r \times r$ superior-izquierda de la Hessiana, “orlada” (bordeada) por el gradiente truncado en la primera fila y la primera columna, con un 0 en la esquina. Los determinantes $\det B_1(x), \dots, \det B_n(x)$ se llaman *menores principales orlados* (*bordered leading principal minors*).

Observa que $\det B_1 = \det \begin{pmatrix} 0 & f_1 \\ f_1 & f_{11} \end{pmatrix} = -f_1^2 \leq 0$ siempre, para cualquier función: el primer menor orlado no distingue nada por sí solo (volveremos sobre esto al discutir la condición necesaria).

Teorema 6.23 (Criterio del Hessiano orlado). Sea $S \subseteq \mathbb{R}^n$ convexo y abierto, y $f: S \rightarrow \mathbb{R}$ de clase C^2 .

(a) (**Condición necesaria.**) Si f es cuasicóncava en S , entonces

$$(-1)^r \det B_r(x) \geq 0 \quad \text{para todo } x \in S \text{ y } r = 1, \dots, n,$$

es decir, $\det B_1 \leq 0$, $\det B_2 \geq 0$, $\det B_3 \leq 0$, y así alternando.

(b) (**Condición suficiente.**) Si

$$(-1)^r \det B_r(x) > 0 \quad \text{para todo } x \in S \text{ y } r = 1, \dots, n$$

(desigualdades estrictas: $\det B_1 < 0$, $\det B_2 > 0$, $\det B_3 < 0$, ...), entonces f es cuasicóncava en S ; más aún, es pseudocóncava y estrictamente cuasicóncava en S .

Para cuasiconvexidad los papeles se invierten: la condición necesaria es $\det B_r(x) \leq 0$ para todo r (todos los menores orlados no positivos), y la suficiente es $\det B_r(x) < 0$ para todo r y todo x .

No demostraremos este teorema (la prueba usa la teoría de formas cuadráticas restringidas a un subespacio: la condición dice que la Hessiana es definida negativa sobre el hiperplano tangente a la curva de nivel, $\{v : \langle \nabla f(x), v \rangle = 0\}$; puedes ver [9], Teorema M.C.4 y sección M.D, y [1]), pero sí insistiremos en la lógica, porque aquí es donde los libros, y los estudiantes, se confunden.

Cuidado (error común)

La condición necesaria y la suficiente NO son la misma, y ninguna es equivalencia. Hay una “brecha” cuando algún determinante se anula, exactamente como con la Hessiana ordinaria (semidefinida vs. definida). Dos errores típicos de examen:

- (I) Creer que los signos débiles implican cuasiconcavidad. Falso. Contraejemplo mínimo: $f(x) = x^2$ en $\mathbb{R}$ ($n = 1$). Aquí $\det B_1(x) = -f'(x)^2 = -4x^2 \leq 0$ en todo punto, así que la condición necesaria $(-1)^1 \det B_1 \geq 0$ se cumple en todo $\mathbb{R}$; pero x^2 no es cuasicóncava: su contorno superior $\{x : x^2 \geq 1\} = (-\infty, -1] \cup [1, \infty)$ no es convexo. La condición débil (a) sirve solo para descartar: si falla en un punto, f no es cuasicóncava.
- (II) Creer que una cuasicóncava debe cumplir los signos estrictos. Falso: $f(x, y) = x$ (lineal, cuasicóncava) tiene $f_2 = 0$ y $\det B_2 = 0$. Las condiciones estrictas (b) fallan donde el gradiente tiene ceros o la curvatura degenera, sin que ello refute la

cuasiconcavidad. La condición estricta sirve solo para *afirmar*.

En resumen: signos estrictos en todo el dominio $\Rightarrow$ cuasicóncava; cuasicóncava $\Rightarrow$ signos débiles; y entre ambas hay casos indecisos por este método (habrá que usar la definición o una transformación monótona).

Una advertencia adicional sobre el *orden de las variables*. Los B_r se construyen con la esquina superior-izquierda de la Hessiana, de modo que dependen de cómo numeres las variables. La condición necesaria (a) no sufre por ello: la cuasiconcavidad es invariante ante permutaciones de las variables, así que los signos débiles valen *para cualquier ordenamiento* (equivalentemente, para todos los menores principales orlados, no solo los “líderes”). La condición suficiente (b), en cambio, exige $\det B_1 = -f_1^2 < 0$, es decir $f_1 \neq 0$: si tu primera variable resulta tener derivada nula, el test estricto falla por una razón puramente notacional. Renombra las variables antes de concluir nada.

6.6.2. Ejemplo completo 2×2 : Cobb–Douglas

Ejemplo 6.24 (Menores orlados de $u = x^a y^b$, paso a paso). Sea $u(x, y) = x^a y^b$ con $a, b > 0$, en $\mathbb{R}_{++}^2$. Ya calculamos en la Proposición 6.15:

$$u_x = \frac{au}{x}, \quad u_y = \frac{bu}{y}, \quad u_{xx} = \frac{a(a-1)u}{x^2}, \quad u_{yy} = \frac{b(b-1)u}{y^2}, \quad u_{xy} = \frac{abu}{xy},$$

donde escribimos todo en términos de $u = x^a y^b > 0$ para aligerar la notación (verifica, por ejemplo, que $a(a-1)x^{a-2}y^b = a(a-1)u/x^2$).

Primer menor orlado ($r = 1$):

$$\det B_1 = \det \begin{pmatrix} 0 & u_x \\ u_x & u_{xx} \end{pmatrix} = 0 \cdot u_{xx} - u_x \cdot u_x = -u_x^2 = -\frac{a^2 u^2}{x^2} < 0,$$

estrictamente negativo en $\mathbb{R}_{++}^2$ porque $a > 0$ y $u > 0$. Se cumple $(-1)^1 \det B_1 > 0$. ✓

Segundo menor orlado ($r = 2$): la matriz es

$$B_2 = \begin{pmatrix} 0 & u_x & u_y \\ u_x & u_{xx} & u_{xy} \\ u_y & u_{xy} & u_{yy} \end{pmatrix}.$$

Expandimos el determinante por la primera fila (cofactores):

$$\begin{aligned} \det B_2 &= 0 \cdot \det \begin{pmatrix} u_{xx} & u_{xy} \\ u_{xy} & u_{yy} \end{pmatrix} - u_x \det \begin{pmatrix} u_x & u_{xy} \\ u_y & u_{yy} \end{pmatrix} + u_y \det \begin{pmatrix} u_x & u_{xx} \\ u_y & u_{xy} \end{pmatrix} \\ &= -u_x(u_x u_{yy} - u_{xy} u_y) + u_y(u_x u_{xy} - u_{xx} u_y) \\ &= 2u_x u_y u_{xy} - u_x^2 u_{yy} - u_y^2 u_{xx}. \end{aligned}$$

Esta fórmula final, $\det B_2 = 2f_x f_y f_{xy} - f_x^2 f_{yy} - f_y^2 f_{xx}$, vale para cualquier f de dos variables y

conviene memorizarla. Sustituyendo los valores Cobb–Douglas, término a término:

$$2u_x u_y u_{xy} = 2 \cdot \frac{au}{x} \cdot \frac{bu}{y} \cdot \frac{abu}{xy} = \frac{2a^2 b^2 u^3}{x^2 y^2},$$

$$u_x^2 u_{yy} = \frac{a^2 u^2}{x^2} \cdot \frac{b(b-1)u}{y^2} = \frac{a^2 b(b-1)u^3}{x^2 y^2}, \quad u_y^2 u_{xx} = \frac{b^2 u^2}{y^2} \cdot \frac{a(a-1)u}{x^2} = \frac{ab^2(a-1)u^3}{x^2 y^2}.$$

Entonces

$$\begin{aligned} \det B_2 &= \frac{u^3}{x^2 y^2} [2a^2 b^2 - a^2 b(b-1) - ab^2(a-1)] = \frac{ab u^3}{x^2 y^2} [2ab - a(b-1) - b(a-1)] \\ &= \frac{ab u^3}{x^2 y^2} [2ab - ab + a - ab + b] = \frac{ab(a+b)u^3}{x^2 y^2} > 0 \end{aligned}$$

para todos los $a, b > 0$ y todo $(x, y) \in \mathbb{R}_{++}^2$. Se cumple $(-1)^2 \det B_2 > 0$. ✓

Como ambos menores orlados tienen los signos estrictos alternantes requeridos en todo $\mathbb{R}_{++}^2$, el Teorema 6.23(b) confirma que u es cuasicóncava (de hecho estrictamente cuasicóncava y pseudocóncava) en $\mathbb{R}_{++}^2$, para todo $a, b > 0$, en perfecta concordancia con la demostración por transformación logarítmica de la Proposición 6.15, y sin ninguna restricción del tipo $a+b \leq 1$. □

6.6.3. Ejemplo 3×3

Ejemplo 6.25 (Tres bienes: $u(x, y, z) = xyz$). Sea $u(x, y, z) = xyz$ en $\mathbb{R}_{++}^3$. (Sabemos por adelantado que debe ser cuasicóncava: $\ln u = \ln x + \ln y + \ln z$ es cóncava y $u = e^{\ln u}$; el objetivo del ejemplo es practicar la mecánica orlada en dimensión 3.) Las derivadas:

$$u_x = yz, \quad u_y = xz, \quad u_z = xy; \quad u_{xx} = u_{yy} = u_{zz} = 0, \quad u_{xy} = z, \quad u_{xz} = y, \quad u_{yz} = x.$$

$$\text{Orden } r = 1: \det B_1 = -u_x^2 = -(yz)^2 < 0. \quad \checkmark$$

Orden $r = 2$:

$$\det B_2 = \det \begin{pmatrix} 0 & yz & xz \\ yz & 0 & z \\ xz & z & 0 \end{pmatrix} = -yz \det \begin{pmatrix} yz & z \\ xz & 0 \end{pmatrix} + xz \det \begin{pmatrix} yz & 0 \\ xz & z \end{pmatrix},$$

expandiendo por la primera fila. Los cofactores: $\det \begin{pmatrix} yz & z \\ xz & 0 \end{pmatrix} = 0 - xz^2 = -xz^2$ y $\det \begin{pmatrix} yz & 0 \\ xz & z \end{pmatrix} = yz \cdot z - 0 = yz^2$. Luego

$$\det B_2 = -yz \cdot (-xz^2) + xz \cdot yz^2 = xyz^3 + xyz^3 = 2xyz^3 > 0. \quad \checkmark$$

Orden $r = 3$: la matriz completa es

$$B_3 = \begin{pmatrix} 0 & yz & xz & xy \\ yz & 0 & z & y \\ xz & z & 0 & x \\ xy & y & x & 0 \end{pmatrix}.$$

Expandimos por la primera fila: $\det B_3 = -yz \cdot M_1 + xz \cdot M_2 - xy \cdot M_3$, con

$$M_1 = \det \begin{pmatrix} yz & z & y \\ xz & 0 & x \\ xy & x & 0 \end{pmatrix}, \quad M_2 = \det \begin{pmatrix} yz & 0 & y \\ xz & z & x \\ xy & y & 0 \end{pmatrix}, \quad M_3 = \det \begin{pmatrix} yz & 0 & z \\ xz & z & 0 \\ xy & y & x \end{pmatrix}.$$

Calculamos cada uno por la regla de Sarrus o por cofactores de la primera fila:

$$\begin{aligned} M_1 &= yz(0 \cdot 0 - x \cdot x) - z(xz \cdot 0 - x \cdot xy) + y(xz \cdot x - 0 \cdot xy) \\ &= -x^2yz + x^2yz + x^2yz = x^2yz; \\ M_2 &= yz(z \cdot 0 - x \cdot y) - 0 + y(xz \cdot y - z \cdot xy) = -xy^2z + y \cdot 0 = -xy^2z; \\ M_3 &= yz(z \cdot x - 0 \cdot y) - 0 + z(xz \cdot y - z \cdot xy) = xyz^2 + z \cdot 0 = xyz^2. \end{aligned}$$

Por tanto

$$\det B_3 = -yz \cdot x^2yz + xz \cdot (-xy^2z) - xy \cdot xyz^2 = -x^2y^2z^2 - x^2y^2z^2 - x^2y^2z^2 = -3x^2y^2z^2 < 0. \checkmark$$

Los tres signos alternan estrictamente: $\det B_1 < 0$, $\det B_2 > 0$, $\det B_3 < 0$, es decir $(-1)^r \det B_r > 0$ para $r = 1, 2, 3$ en todo $\mathbb{R}_{++}^3$. Por el Teorema 6.23(b), $u = xyz$ es cuasicóncava (y pseudocóncava) en $\mathbb{R}_{++}^3$. $\square$

Estrategia de examen

Receta de examen para el Hessiano orlado. Ante “determina si u es cuasicóncava”:

1. *Antes de derivar*, intenta un atajo ordinal: ¿es u una transformación monótona creciente de algo cóncavo o ya conocido? (logaritmo para productos de potencias, raíz $1/\rho$ para CES). Si sí, concluye por el Teorema 6.13 y ahórrate los determinantes. ¿Es un mínimo de cuasicóncavas, o composición con una afín? Usa la Proposición 6.14.
2. Si no hay atajo, calcula gradiente y Hessiana, y forma los B_r agregando la orla (fila y columna con el gradiente, 0 en la esquina).
3. Calcula $\det B_1 = -f_1^2, \det B_2, \dots, \det B_n$ (para $n = 2$ usa la fórmula memorizable $\det B_2 = 2f_x f_y f_{xy} - f_x^2 f_{yy} - f_y^2 f_{xx}$).
4. Si los signos alternan *estrictamente* empezando en negativo $(-, +, -, \dots)$ en *todo* el dominio: concluye “cuasicóncava (y pseudocóncava)” citando la condición suficiente.
5. Si algún signo *viola* el patrón débil $(\leq, \geq, \leq, \dots)$ en algún punto: concluye “no es cuasicóncava” citando la condición necesaria.
6. Si hay ceros (caso frontera): el criterio no decide; vuelve a la definición por conjuntos de nivel, a la desigualdad del mínimo o a una transformación monótona. Escribe explícitamente en el examen cuál condición usas y en qué dirección: confundir necesaria con suficiente cuesta puntos.

Para *cuasiconvexidad*, mismos pasos con el patrón de signos “todos ≤ 0 ” (necesaria) /

“todos < 0 ” (suficiente), o aplica el criterio cuasicóncavo a $-f$.

6.7. Funciones pseudocóncavas [P2]

Entre las cóncavas y las cuasicóncavas hay una clase intermedia, definida solo para funciones diferenciables, que conserva la propiedad más valiosa de la concavidad en optimización: *los puntos estacionarios son máximos globales*.

Motivación: la cuasiconcavidad es demasiado débil para las condiciones de primer orden. El ejemplo es $f(x) = x^3$: es cuasicóncava (monótona) y $f'(0) = 0$, así que $x = 0$ es un punto estacionario; pero obviamente no es un máximo (ni siquiera local): $f(1) = 1 > 0 = f(0)$. Con utilidades cuasicóncavas generales, “resolver la condición de primer orden” no basta para haber encontrado el óptimo. La pseudoconcavidad repara exactamente ese defecto.

Definición 6.26 (Función pseudocóncava). Sea $S \subseteq \mathbb{R}^n$ convexo y abierto, y $f: S \rightarrow \mathbb{R}$ diferenciable. f es *pseudocóncava* (*pseudoconcave*) si para todo $x, y \in S$,

$$f(y) > f(x) \implies \langle \nabla f(x), y - x \rangle > 0.$$

Equivalentemente (contrapositiva): si $\langle \nabla f(x), y - x \rangle \leq 0$, entonces $f(y) \leq f(x)$. f es *pseudocóncava* si $-f$ es pseudocóncava.

Compara con el Teorema 6.21: la cuasiconcavidad da $f(y) \geq f(x) \implies \langle \nabla f(x), y - x \rangle \geq 0$; la pseudoconcavidad exige que una mejora *estricta* sea detectada *estrictamente* por el gradiente. La diferencia parece cosmética pero no lo es: en $f(x) = x^3$, el punto $y = 1$ mejora estrictamente a $x = 0$ y sin embargo $f'(0)(1 - 0) = 0$, no > 0 : x^3 *no* es pseudocóncava, aunque sí cuasicóncava.

Teorema 6.27 (Jerarquía para funciones diferenciables). Sea f diferenciable en el convexo abierto S . Entonces:

$$f \text{ cóncava} \implies f \text{ pseudocóncava} \implies f \text{ cuasicóncava},$$

y ninguna implicación se revierte.

Demostración. Cóncava $\implies$ pseudocóncava. Si f es cóncava y diferenciable, la caracterización de primer orden de la concavidad da, para todo $x, y \in S$,

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle.$$

Si además $f(y) > f(x)$, restando $f(x)$:

$$\langle \nabla f(x), y - x \rangle \geq f(y) - f(x) > 0,$$

que es la pseudoconcavidad.

Pseudocóncava $\implies$ cuasicóncava. Supongamos, por contradicción, que f es pseudocóncava pero no cuasicóncava: existen $x, y \in S$ y un punto del segmento con valor menor que $m =$

$\min\{f(x), f(y)\}$. La función $\varphi(\lambda) = f((1-\lambda)x + \lambda y)$ es continua en el compacto $[0, 1]$, luego alcanza su mínimo (Weierstrass) en algún $\lambda^* \in [0, 1]$, con $\varphi(\lambda^*) < m \leq \min\{\varphi(0), \varphi(1)\}$; en particular $\lambda^* \in (0, 1)$ (no puede ser un extremo, donde $\varphi \geq m$). Sea $z^* = (1-\lambda^*)x + \lambda^*y$. Como $f(x) \geq m > f(z^*)$, la pseudoconcavidad aplicada al par (z^*, x) da

$$\langle \nabla f(z^*), x - z^* \rangle > 0.$$

Pero $x - z^* = \lambda^*(x - y)$: es un múltiplo positivo de $x - y$, así que $\langle \nabla f(z^*), x - y \rangle > 0$ y por tanto la derivada de φ en λ^* , que por regla de la cadena vale $\varphi'(\lambda^*) = \langle \nabla f(z^*), y - x \rangle$, es estrictamente *negativa*. Esto contradice que λ^* sea un mínimo *interior* de φ (en un mínimo interior de una función diferenciable, la derivada se anula: $\varphi'(\lambda^*) = 0$). Contradicción; luego f es cuasicóncava.

Las recíprocas fallan. x^3 es cuasicóncava y no pseudocóncava (visto arriba). En el otro escalón, $f(x) = x^3 + x$ es pseudocóncava en $\mathbb{R}$ (Ejercicio 6.49: es estrictamente creciente con $f' > 0$ en todo punto) pero no es cóncava ($f''(x) = 6x > 0$ en $x > 0$). $\square$

Proposición 6.28 (Por qué importan: estacionario $\Rightarrow$ máximo global). *Si f es pseudocóncava en el convexo abierto S y $\nabla f(x^*) = 0$ para algún $x^* \in S$, entonces x^* es un maximizador global de f en S .*

Demostración. Supongamos que no: existe $y \in S$ con $f(y) > f(x^*)$. Por pseudoconcavidad, $\langle \nabla f(x^*), y - x^* \rangle > 0$. Pero $\nabla f(x^*) = 0$ hace ese producto interno igual a 0, contradicción. $\square$

La misma lógica se extiende a problemas con restricciones: la pseudoconcavidad hace que las condiciones de Karush–Kuhn–Tucker (KKT) sean *suficientes* para optimalidad global.

Teorema 6.29 (Suficiencia de KKT; Arrow–Enthoven). *Considera el problema*

$$\max_{x \in \mathbb{R}^n} f(x) \quad \text{sujeto a} \quad g_j(x) \geq 0, \quad j = 1, \dots, k,$$

con f y $g_1, \dots, g_k$ diferenciables, y supongamos que x^* satisface las condiciones KKT: existen multiplicadores $\mu_1, \dots, \mu_k \geq 0$ tales que

$$\nabla f(x^*) + \sum_{j=1}^k \mu_j \nabla g_j(x^*) = 0, \quad \mu_j g_j(x^*) = 0, \quad g_j(x^*) \geq 0 \quad \forall j.$$

- (a) Si f es pseudocóncava y cada g_j es cuasicóncava, entonces x^* es un máximo global del problema (Mangasarian).
- (b) (Arrow–Enthoven, 1961.) La conclusión se mantiene si f es solo cuasicóncava, a cambio de una condición adicional de no degeneración; la versión más usable: basta que $\nabla f(x^*) \neq 0$ y que f sea dos veces diferenciable en un entorno de x^* (hay variantes con $x \geq 0$ y condiciones sobre las derivadas parciales, que recogemos en el Teorema 6.37).

No demostramos este teorema (puedes ver [1] y las referencias clásicas allí citadas; el caso (a) se demuestra en pocas líneas combinando la Definición 6.26 con la cuasiconcavidad de la región factible), pero registra el mensaje:

Intuición

En Microeconomía plantearás lagrangianos constantemente. La pregunta incómoda “¿y cómo sé que el punto que encontré con las CPO es de verdad el máximo?” tiene esta respuesta limpia: si la utilidad es pseudocóncava (por ejemplo, si pasa el test estricto del Hessiano orlado, que por el Teorema 6.23(b) implica pseudoconcavidad) y las restricciones definen un conjunto convexo (restricción presupuestaria lineal: cuasicóncava), entonces *KKT es suficiente* y las CPO cierran el problema. La cuasiconcavidad sola no basta, x^3 nos lo enseñó, pero casi todas las utilidades de los ejercicios (Cobb–Douglas, CES en el interior, etc.) son pseudocóncavas, con gradiente que nunca se anula. Este es el “seguro de calidad” que la concavidad generalizada le vende al economista.

6.8. Aplicaciones de la concavidad generalizada [P1]

Hasta aquí hemos construido la teoría: definiciones, equivalencias, jerarquía, criterios diferenciales. Esta sección cobra los dividendos. Todos los resultados que siguen son los que se usan en economía (a veces sin nombrarlos) cada vez que se escribe “sea $x(p, w)$ la demanda del consumidor” o “supongamos que las preferencias son estrictamente convexas”. El hilo conductor es este: *la cuasiconcavidad es exactamente la cantidad de estructura que se necesita para que los problemas de maximización de la microeconomía estén bien planteados*, y ni un gramo más.

6.8.1. El conjunto de soluciones es convexo

Teorema 6.30 (Convexidad del conjunto de maximizadores). *Sea $C \subseteq \mathbb{R}^n$ un conjunto convexo no vacío y $f: C \rightarrow \mathbb{R}$ cuasicóncava. Entonces el conjunto de maximizadores*

$$M = \arg \max_{x \in C} f(x) = \{x^* \in C : f(x^*) \geq f(x) \text{ para todo } x \in C\}$$

es convexo (posiblemente vacío).

Demostración. Si $M = \emptyset$ o M tiene un solo punto, es convexo trivialmente (el conjunto vacío y los singuletes son convexas: la condición del segmento se cumple por vacuidad o porque el segmento se reduce a un punto). Supongamos entonces $x, y \in M$ y sea $\lambda \in [0, 1]$; escribimos $z = \lambda x + (1 - \lambda)y$.

Paso 1: z es factible. Como $x, y \in M \subseteq C$ y C es convexo, $z \in C$. (Aquí se usa la convexidad del conjunto factible; sin ella el enunciado ni siquiera tiene sentido.)

Paso 2: $f(z)$ no puede ser menor que el valor óptimo. Llamemos $v^* = f(x) = f(y)$ al valor común de los maximizadores (es el mismo número: ambos son máximos globales). Por cuasiconcavidad de f en la forma de la Definición 6.4, justificada por el Teorema 6.5,

$$f(z) \geq \min\{f(x), f(y)\} = \min\{v^*, v^*\} = v^*.$$

Paso 3: $f(z)$ no puede ser mayor. Como $z \in C$ y $x^* = x$ es un maximizador sobre C , se tiene $f(z) \leq f(x) = v^*$.

Combinando los pasos 2 y 3, $f(z) = v^*$, es decir, z alcanza el valor máximo y por tanto $z \in M$. Como $x, y \in M$ y $\lambda \in [0, 1]$ eran arbitrarios, M es convexo. $\square$

Observa la economía de hipótesis: no pedimos continuidad, ni diferenciabilidad, ni compacidad. Solo convexidad del conjunto factible y cuasiconcavidad del objetivo. Una lectura alternativa, más geométrica, del mismo hecho: si el máximo v^* se alcanza, entonces

$$M = \{x \in C : f(x) \geq v^*\} = C \cap S_{v^*}(f),$$

la intersección del conjunto factible con el conjunto de contorno superior al nivel óptimo; es convexo por ser intersección de dos convexos (Definición 6.3 y cap. 2). Esta segunda demostración es de una línea, pero la primera enseña más sobre el mecanismo.

Intuición

Traducción económica: la demanda del consumidor es una correspondencia de valores convexos. Si a los precios p y con riqueza w el consumidor está indiferente entre dos canastas óptimas x e y , entonces cualquier mezcla de ambas también es óptima. Esto no es un detalle técnico: la convexidad de los valores de la correspondencia de demanda es *exactamente* la hipótesis que pide el teorema de punto fijo de Kakutani, la herramienta con la que se demuestra la existencia del equilibrio walrasiano cuando la demanda no es una función (MWG [9], cap. 17 y el apéndice matemático M.I). Sin preferencias convexas, es decir, sin cuasiconcavidad, el argumento de existencia se rompe.

6.8.2. Unicidad: la demanda es una función

Si reforzamos la cuasiconcavidad a estricta, el conjunto convexo M se colapsa a un punto.

Teorema 6.31 (Unicidad del maximizador). *Sea $C \subseteq \mathbb{R}^n$ convexo no vacío y $f: C \rightarrow \mathbb{R}$ estrictamente cuasiconcava (Definición 6.10). Entonces f tiene a lo sumo un maximizador sobre C : el conjunto $M = \arg \max_{x \in C} f(x)$ es vacío o un singulete. Si además C es compacto y f es continua, M es exactamente un punto.*

Demostración. Supongamos, buscando una contradicción, que existen dos maximizadores distintos $x, y \in M$, $x \neq y$, con valor común $v^* = f(x) = f(y)$. Tomemos el punto medio $z = \frac{1}{2}x + \frac{1}{2}y$, que pertenece a C por convexidad. La cuasiconcavidad *estricta* se aplica porque $x \neq y$ y $\lambda = \frac{1}{2} \in (0, 1)$:

$$f(z) > \min\{f(x), f(y)\} = v^*.$$

Pero z es factible y v^* es el valor máximo sobre C , luego $f(z) \leq v^*$. Las dos desigualdades juntas dan $v^* < f(z) \leq v^*$, absurdo. Por lo tanto no puede haber dos maximizadores distintos.

Para la última afirmación: si C es compacto no vacío y f continua, el teorema de Weierstrass garantiza que el máximo se alcanza, de modo que $M \neq \emptyset$; junto con lo anterior, M es un único punto. $\square$

Corolario 6.32 (La demanda marshalliana es una función). Sea $u: \mathbb{R}_+^n \rightarrow \mathbb{R}$ continua y estrictamente cuasicóncava, y considera el problema del consumidor

$$\max_{x \in \mathbb{R}_+^n} u(x) \quad \text{sujeto a} \quad \langle p, x \rangle \leq w,$$

con precios $p \in \mathbb{R}_{++}^n$ y riqueza $w > 0$. Entonces el conjunto presupuestario $B(p, w) = \{x \in \mathbb{R}_+^n : \langle p, x \rangle \leq w\}$ es no vacío, convexo y compacto, y el problema tiene exactamente una solución $x(p, w)$. Es decir, la demanda es una función $x: \mathbb{R}_{++}^n \times \mathbb{R}_{++} \rightarrow \mathbb{R}_+^n$, no una correspondencia.

Demostración. $B(p, w)$ es no vacío: contiene a $x = 0$ (pues $\langle p, 0 \rangle = 0 \leq w$). Convexo: es la intersección del ortante $\mathbb{R}_+^n$ (convexo) con el semiespacio $\{x : \langle p, x \rangle \leq w\}$ (convexo), y la intersección de convexos es convexa (cap. 2). Cerrado: es intersección de preimágenes de cerrados bajo funciones continuas. Acotado: si $x \in B(p, w)$ entonces, como todas las coordenadas son no negativas y $p_i > 0$,

$$p_i x_i \leq \sum_{j=1}^n p_j x_j \leq w \quad \implies \quad 0 \leq x_i \leq \frac{w}{p_i} \quad \text{para cada } i,$$

así que $B(p, w) \subseteq \prod_i [0, w/p_i]$, una caja acotada. Por Heine–Borel, $B(p, w)$ es compacto. Aplicando el Teorema 6.31 con $C = B(p, w)$ y $f = u$ se obtiene existencia (Weierstrass) y unicidad (cuasiconcavidad estricta). $\square$

Observación 6.33 (La versión ordinal: preferencias estrictamente convexas). Por el Teorema 6.20, la cuasiconcavidad de u equivale a la convexidad de las preferencias representadas. El paralelo estricto es exacto: u es estrictamente cuasicóncava si y solo si las preferencias $\succsim$ son *estrictamente convexas* en el sentido de MWG [9] (Definición 3.B.1 y la discusión que sigue): si $x \neq y$, $x \succsim z$ y $y \succsim z$, entonces $\lambda x + (1 - \lambda)y \succ z$ para todo $\lambda \in (0, 1)$. Traducido: mezclar dos canastas igual de buenas produce algo *estrictamente* mejor, no meramente igual de bueno. La versión no estricta permite curvas de indiferencia con tramos rectos (como la utilidad lineal del Ejemplo 6.18, donde la demanda es una correspondencia que puede saltar de un vértice del presupuesto al otro); la estricta las prohíbe.

Intuición

¿Por qué le importa tanto a un economista que la demanda sea una función y no una correspondencia? Tres razones, todas de MWG cap. 3:

- (I) **Estática comparativa.** Solo de una función se pueden tomar derivadas: $\partial x_i / \partial p_j$, la matriz de Slutsky, los signos de los efectos sustitución e ingreso. Con una correspondencia, la pregunta “¿cómo cambia la demanda si sube el precio?” no tiene respuesta única.
- (II) **Identificación empírica.** Al estimar un sistema de demanda, se supone que a cada (p, w) le corresponde una canasta observada. La multiplicidad rompería la relación entre datos y parámetros.
- (III) **Existencia de equilibrio.** Con demanda de valor único y continua, la demanda

agregada excedente es una función continua y basta el teorema de punto fijo de *Brouwer*; con correspondencias hace falta *Kakutani*, más delicado. Los dos caminos existen, pero el primero es el que se usa en un primer curso.

El precio de esta comodidad es una hipótesis sustantiva sobre gustos (estricta convexidad) que excluye, por ejemplo, bienes perfectamente sustitutos.

Cuidado (error común)

Cuasiconcavidad estricta *no* es lo mismo que “cuasicóncava y estrictamente creciente”, ni implica concavidad estricta, ni se deduce de que la desigualdad del Hessiano orlado se cumpla débilmente. Dos trampas frecuentes:

- La Cobb–Douglas $u = x^a y^b$ con $a, b > 0$ es estrictamente cuasicóncava en $\mathbb{R}_{++}^2$ (por el Teorema 6.23(b), verificado en el Ejemplo 6.24) para *cualquier* $a, b > 0$, aunque solo es cóncava si $a + b \leq 1$. La unicidad de la demanda no requiere concavidad.
- La Leontief $u = \min\{x, y\}$ (Ejemplo 6.17) es cóncava, luego cuasicóncava, pero *no* estrictamente cuasicóncava: sobre el tramo horizontal de una curva de indiferencia, $u(\lambda x + (1-\lambda)y) = \min\{u(x), u(y)\}$ con igualdad. Aun así su demanda es única, porque el óptimo cae siempre en el vértice: la cuasiconcavidad estricta es *suficiente*, no necesaria, para la unicidad.

6.8.3. El teorema del máximo de Berge

El Corolario 6.32 nos dice que la demanda está bien definida *para cada* (p, w) . Falta la otra mitad: que *varía con continuidad* en (p, w) . Ese es el contenido del teorema del máximo de Claude Berge (1959), la herramienta estándar para propagar continuidad desde los datos de un problema hacia su valor óptimo y su solución.

El enunciado necesita hablar de *correspondencias* (aplicaciones multivaluadas), porque el conjunto factible depende de parámetros y en general no es un punto.

Definición 6.34 (Correspondencia y hemicontinuidad). Sean $\Theta \subseteq \mathbb{R}^m$ (espacio de parámetros) y $X \subseteq \mathbb{R}^n$. Una *correspondencia* $\Gamma: \Theta \rightrightarrows X$ asigna a cada $\theta \in \Theta$ un subconjunto $\Gamma(\theta) \subseteq X$. Decimos que:

- (a) Γ es *hemicontinua superiormente* (*upper hemicontinuous*, uhc) en θ_0 si para todo abierto $V \subseteq X$ con $\Gamma(\theta_0) \subseteq V$ existe un entorno U de θ_0 tal que $\Gamma(\theta) \subseteq V$ para todo $\theta \in U$. Si Γ tiene valores compactos y X es compacto, esto equivale a la caracterización *secuencial*: si $\theta_k \rightarrow \theta_0$, $x_k \in \Gamma(\theta_k)$ y $x_k \rightarrow x_0$, entonces $x_0 \in \Gamma(\theta_0)$ (grafo cerrado).
- (b) Γ es *hemicontinua inferiormente* (*lower hemicontinuous*, lhc) en θ_0 si para todo abierto V con $\Gamma(\theta_0) \cap V \neq \emptyset$ existe un entorno U de θ_0 tal que $\Gamma(\theta) \cap V \neq \emptyset$ para todo $\theta \in U$. Secuencialmente: para todo $x_0 \in \Gamma(\theta_0)$ y toda sucesión $\theta_k \rightarrow \theta_0$ existen $x_k \in \Gamma(\theta_k)$ con $x_k \rightarrow x_0$.
- (c) Γ es *continua* si es a la vez uhc y lhc.

La intuición de los dos conceptos: la hemicontinuidad superior prohíbe que el conjunto *explote* en el límite (que aparezcan de golpe puntos nuevos); la inferior prohíbe que *implosione* (que desaparezcan de golpe puntos que estaban). Una función ordinaria vista como correspondencia de valor único es $\text{uhc} \Leftrightarrow \text{lhc} \Leftrightarrow \text{continua}$.

Teorema 6.35 (Teorema del máximo, Berge). Sean $\Theta \subseteq \mathbb{R}^m$ y $X \subseteq \mathbb{R}^n$, y considera

$$v(\theta) = \max_{x \in \Gamma(\theta)} f(x, \theta), \quad x^*(\theta) = \arg \max_{x \in \Gamma(\theta)} f(x, \theta).$$

Supongamos que

(H1) $f: X \times \Theta \rightarrow \mathbb{R}$ es continua (conjuntamente en (x, θ));

(H2) $\Gamma: \Theta \rightrightarrows X$ es continua (uhc y lhc) en θ ;

(H3) $\Gamma(\theta)$ es no vacío y compacto para cada θ .

Entonces:

- (a) la función de valor $v: \Theta \rightarrow \mathbb{R}$ está bien definida (el máximo se alcanza) y es continua;
- (b) la correspondencia de soluciones x^* tiene valores no vacíos y compactos y es hemicontinua superiormente;
- (c) si además $x^*(\theta)$ es un singulete para todo θ , entonces x^* es una función continua.

Esquema de la demostración. No la damos completa (puedes ver [1] y, en clave económica, MWG [9], apéndice M.K), pero el mecanismo se entiende en dos mitades, y conviene verlo porque explica *por qué* hacen falta las dos hemicontinuidades.

v es semicontinua superiormente, gracias a que Γ es uhc y compacta. Sea $\theta_k \rightarrow \theta_0$ y elijamos $x_k \in x^*(\theta_k)$, de modo que $v(\theta_k) = f(x_k, \theta_k)$; pasando de entrada a una subsucesión que realice el $\limsup_k v(\theta_k)$, podemos suponer que $v(\theta_k)$ converge a ese $\limsup$. Por compacidad (los x_k viven en un compacto para k grande, por la uhc) hay una subsucesión $x_{k_j} \rightarrow x_0$, y la uhc da $x_0 \in \Gamma(\theta_0)$. Por continuidad de f , $v(\theta_{k_j}) = f(x_{k_j}, \theta_{k_j}) \rightarrow f(x_0, \theta_0) \leq v(\theta_0)$, ya que x_0 es factible en θ_0 . Esto da $\limsup_k v(\theta_k) \leq v(\theta_0)$.

v es semicontinua inferiormente, gracias a que Γ es lhc. Sea $x_0 \in x^*(\theta_0)$, es decir $f(x_0, \theta_0) = v(\theta_0)$. Por lhc existen $x_k \in \Gamma(\theta_k)$ con $x_k \rightarrow x_0$. Como x_k es factible (no necesariamente óptimo) en θ_k , $v(\theta_k) \geq f(x_k, \theta_k) \rightarrow f(x_0, \theta_0) = v(\theta_0)$, luego $\liminf_k v(\theta_k) \geq v(\theta_0)$. Juntando ambas mitades, $v(\theta_k) \rightarrow v(\theta_0)$: v es continua.

x^ es uhc.* Con v ya continua, el primer argumento se recicla: si $\theta_k \rightarrow \theta_0$, $x_k \in x^*(\theta_k)$ y $x_k \rightarrow x_0$, entonces $x_0 \in \Gamma(\theta_0)$ (uhc de Γ) y $f(x_0, \theta_0) = \lim_k f(x_k, \theta_k) = \lim_k v(\theta_k) = v(\theta_0)$, luego $x_0 \in x^*(\theta_0)$: el grafo es cerrado. Finalmente, (c) es inmediata: una correspondencia uhc de valor único es una función continua. $\square$

Cuidado (error común)

Berge **no** dice que x^* sea hemicontinua *inferiormente*, y en general no lo es: la solución puede “saltar”. Ejemplo: maximizar $f(x, \theta) = \theta x$ sobre $\Gamma(\theta) = [-1, 1]$. Para $\theta > 0$ la solución es $x^* = 1$; para $\theta < 0$ es $x^* = -1$; en $\theta = 0$ es todo $[-1, 1]$. La correspondencia es

uhc (en 0 el conjunto “crece” pero no aparecen puntos fuera del límite) pero no lhc. Traducción microeconómica: con bienes sustitutos perfectos, la demanda salta de un extremo del presupuesto al otro cuando la razón de precios cruza el umbral. La cuasiconcavidad *estricta* es precisamente lo que elimina el salto: hace x^* de valor único y, por (c), continua.

Corolario 6.36 (Continuidad de la demanda marshalliana). *Sea $u: \mathbb{R}_+^n \rightarrow \mathbb{R}$ continua y estrictamente cuasiconcava. Entonces la demanda $x(p, w)$ del Corolario 6.32 es una función continua de (p, w) en $\mathbb{R}_{++}^n \times \mathbb{R}_{++}$, y la función de utilidad indirecta $v(p, w) = u(x(p, w))$ es continua.*

Demostración. Aplicamos el Teorema 6.35 con $\theta = (p, w)$, $\Theta = \mathbb{R}_{++}^n \times \mathbb{R}_{++}$, $f(x, \theta) = u(x)$ (continua, y trivialmente conjunta porque no depende de θ) y $\Gamma(p, w) = B(p, w)$. Las hipótesis (H3) ya se verificaron en el Corolario 6.32: $B(p, w)$ es no vacío y compacto. Falta (H2), la continuidad de la correspondencia presupuestaria, que damos en esbozo.

B es uhc en (p_0, w_0) con $p_0 \gg 0$, $w_0 > 0$: tomemos $(p_k, w_k) \rightarrow (p_0, w_0)$ y $x_k \in B(p_k, w_k)$ con $x_k \rightarrow x_0$. Entonces $x_0 \geq 0$ (el ortante es cerrado) y, pasando al límite en $\langle p_k, x_k \rangle \leq w_k$ (el producto interno es continuo), $\langle p_0, x_0 \rangle \leq w_0$: luego $x_0 \in B(p_0, w_0)$. Además, para (p_k, w_k) cerca de (p_0, w_0) todos los $B(p_k, w_k)$ caben en una misma caja acotada, lo que legitima el argumento por sucesiones.

B es lhc en (p_0, w_0) con $p_0 \gg 0$, $w_0 > 0$: sea $x_0 \in B(p_0, w_0)$ y $(p_k, w_k) \rightarrow (p_0, w_0)$. Si $\langle p_0, x_0 \rangle < w_0$ (interior del presupuesto), para k grande $\langle p_k, x_0 \rangle < w_k$ y basta tomar $x_k = x_0$. Si $\langle p_0, x_0 \rangle = w_0$, definimos

$$x_k = \min \left\{ 1, \frac{w_k}{\langle p_k, x_0 \rangle} \right\} x_0,$$

que es factible en (p_k, w_k) (encoge la canasta lo justo para que quepa) y converge a x_0 porque $w_k / \langle p_k, x_0 \rangle \rightarrow w_0 / w_0 = 1$. La hipótesis $w_0 > 0$ es esencial: es lo que impide dividir por cero y lo que hace que el presupuesto tenga interior.

Con (H1)–(H3) verificadas, Berge da la continuidad de v y la hemicontinuidad superior de x^* ; la cuasiconcavidad estricta hace x^* de valor único (Teorema 6.31), y la parte (c) del teorema convierte eso en continuidad. $\square$

Cuidado (error común)

Las hipótesis $p \gg 0$ y $w > 0$ no son decorativas, y conviene ver exactamente qué falla sin ellas. Si se permite $p_i = 0$, el conjunto $B(p, w)$ deja de ser *acotado* (el bien gratuito se puede consumir sin límite): se caen la compacidad de (H3) y la hemicontinuidad superior, y la demanda puede explotar. Si además $w = 0$, falla también la hemicontinuidad *inferior*: con p_0 que tenga una coordenada nula, $B(p_0, 0)$ contiene canastas no nulas, mientras que $B(p_k, 0) = \{0\}$ para cualquier $p_k \gg 0$, de modo que esas canastas no se pueden aproximar desde el límite. (En cambio, con $p_0 \gg 0$ y $w_0 = 0$ se tiene $B(p_0, 0) = \{0\}$ y no hay problema de lhc: basta tomar $x_k = 0$.) En equilibrio general esta es la razón de las *hipótesis de supervivencia* (cada consumidor tiene una dotación con valor estrictamente positivo, $\langle p, \omega_i \rangle > 0$) y de los trucos de truncamiento de la demanda que aparecen en MWG cap. 17: sin ellos, Berge no se puede aplicar en la frontera del simplex de precios y el argumento de punto fijo se cae.

Intuición

El encadenamiento completo, que conviene memorizar como una sola historia:

$$\underbrace{u \text{ cuasicóncava}}_{\text{contornos convexos}} \implies \underbrace{x(p, w) \text{ de valores convexos,}}_{\text{Kakutani}}$$

$$\underbrace{u \text{ estrict. cuasicóncava}}_{\text{sin tramos planos}} \implies \underbrace{x(p, w) \text{ única}}_{\text{función}} \xrightarrow{\text{Berge}} \underbrace{x(p, w) \text{ continua.}}_{\text{Brouwer}}$$

Y la demanda continua es el insumo del teorema de punto fijo que produce el equilibrio walrasiano. Toda la existencia del equilibrio general descansa, en su capa matemática, sobre convexidad de conjuntos factibles + cuasiconcavidad de utilidades + Berge.

6.8.4. Arrow–Enthoven: cuándo KKT basta

Ya enunciamos en el Teorema 6.29 la versión corta. Damos ahora el enunciado con las condiciones adicionales explícitas, porque el punto delicado del resultado es justamente esa letra pequeña: *la cuasiconcavidad sola no basta* (recuerda x^3), y hay que añadir una condición de no degeneración.

Teorema 6.37 (Arrow–Enthoven, 1961). *Considera el programa*

$$\max_{x \geq 0} f(x) \quad \text{sujeto a} \quad g_j(x) \geq 0, \quad j = 1, \dots, k,$$

con $f, g_1, \dots, g_k: \mathbb{R}_+^n \rightarrow \mathbb{R}$ diferenciables, f cuasicóncava y cada g_j cuasicóncava. Supongamos que $x^* \geq 0$ satisface las condiciones de Karush–Kuhn–Tucker: existen $\mu_1, \dots, \mu_k \geq 0$ con

$$\frac{\partial f}{\partial x_i}(x^*) + \sum_{j=1}^k \mu_j \frac{\partial g_j}{\partial x_i}(x^*) \leq 0, \quad x_i^* \left[\frac{\partial f}{\partial x_i}(x^*) + \sum_{j=1}^k \mu_j \frac{\partial g_j}{\partial x_i}(x^*) \right] = 0, \quad \mu_j g_j(x^*) = 0, \quad g_j(x^*) \geq 0.$$

Si además se cumple al menos una de las siguientes condiciones de no degeneración de Arrow–Enthoven:

- (I) $\partial f / \partial x_i(x^*) < 0$ para alguna variable i ;
- (II) $\partial f / \partial x_i(x^*) > 0$ para alguna variable i que pueda aumentarse sin salir de la región factible (es decir, x_i no está en su cota superior implícita);
- (III) $\nabla f(x^*) \neq 0$ y f es dos veces diferenciable en un entorno de x^* ;
- (IV) f es cóncava,

entonces x^* es un máximo global del programa.

Observación 6.38 (Cómo leer las condiciones adicionales). Todas las variantes (i)–(iv) dicen lo mismo con distinto disfraz: *impedir que el punto KKT sea un “falso estacionario” como el $x = 0$ de x^3* . En ese contraejemplo, $f(x) = x^3$ es cuasicóncava y $x^* = 0$ satisface trivialmente KKT (sin restricciones activas, con $f'(0) = 0$), pero no es máximo; ninguna de las condiciones (i)–(iv) se cumple ahí, porque $\nabla f(x^*) = 0$ y f no es cóncava. En la práctica, la condición (iii), gradiente no nulo, es la que se usa siempre, y es automática en microeconomía por la monotonía

de las preferencias (“más es mejor” $\Rightarrow$ utilidad marginal positiva $\Rightarrow \nabla u \neq 0$). Nota también la conexión con la sección anterior: bajo (iii) más regularidad, la cuasiconcavidad se “sube” de hecho a pseudoconcavidad (Definición 6.26), y entonces basta la versión (a) de Mangasarian del Teorema 6.29.

Intuición

El papel de Arrow–Enthoven en el currículo es el de *permiso oficial*. En el capítulo 9 demostraremos que, bajo una condición de cualificación de restricciones, KKT es *necesaria*: todo óptimo la satisface. Eso es lo que autoriza a plantear el lagrangiano. Arrow–Enthoven cierra el círculo por el otro lado: bajo cuasiconcavidad + no degeneración, KKT también es *suficiente*, así que el punto que resuelvas es el óptimo global y no hay que comparar candidatos ni revisar condiciones de segundo orden. Sin este teorema, cada problema de consumidor terminaría con un incómodo “y ahora habría que verificar que este punto es un máximo”. Con él, en cuanto verificas cuasiconcavidad (por ejemplo, con el Hessiano orlado, Teorema 6.23) y ves que el gradiente no se anula, el problema está cerrado.

6.8.5. La condición de cruce único (Spence–Mirrlees)

La última aplicación es la más “moderna” y la que más rendimiento te dará en los cursos de contratos, señalización y diseño de mecanismos. Hasta ahora hemos impuesto condiciones ordinales sobre *un* mapa de indiferencia (cuasiconcavidad: contornos superiores convexos). La condición de cruce único impone una condición ordinal sobre una *familia* de mapas de indiferencia indexada por un tipo θ : los ordena.

El escenario

Un agente de tipo $\theta \in \Theta \subseteq \mathbb{R}$ (su habilidad, su valoración, su costo) elige un par $(q, t) \in Q \times T \subseteq \mathbb{R}^2$, donde q es una variable “real” (calidad, cantidad, educación, esfuerzo) y t es una transferencia monetaria (precio pagado, salario recibido). Su utilidad es $U(q, t, \theta)$. El tipo es *información privada*: el principal (empresa, regulador, vendedor) solo conoce la distribución de θ .

Definición 6.39 (Condición de cruce único, versión diferencial). Sea $U: Q \times T \times \Theta \rightarrow \mathbb{R}$ de clase C^2 con $U_t \neq 0$. La *tasa marginal de sustitución* entre q y t del tipo θ en el punto (q, t) es

$$\text{TMS}(q, t, \theta) = - \frac{U_q(q, t, \theta)}{U_t(q, t, \theta)},$$

es decir, la pendiente dt/dq de la curva de indiferencia del tipo θ en el plano (q, t) . Decimos que U satisface la *condición de cruce único* o *condición de Spence–Mirrlees* si la TMS es *estrictamente monótona en el tipo*:

$$\frac{\partial}{\partial \theta} \left[- \frac{U_q(q, t, \theta)}{U_t(q, t, \theta)} \right] \neq 0 \quad \text{con signo constante, para todo } (q, t, \theta).$$

Definición 6.40 (Cruce único, versión ordinal). U satisface la *propiedad de cruce único* si para todos $q' > q$, todos t', t y todos $\theta' > \theta$:

$$U(q', t', \theta) \geq U(q, t, \theta) \implies U(q', t', \theta') > U(q, t, \theta').$$

En palabras: *si el tipo bajo está dispuesto a aceptar el paquete de mayor q , el tipo alto lo prefiere estrictamente*. Esta versión no requiere diferenciabilidad y es la que se usa en los teoremas generales de comparación estática monótona.

Por qué “cruce único”: la lectura gráfica

Dibuja el plano (q, t) con q en el eje horizontal. Cada tipo tiene su familia de curvas de indiferencia. La condición de Definición 6.39 dice que, *en cada punto del plano*, la pendiente de la curva del tipo θ' es estrictamente distinta (digamos, siempre menor) que la del tipo θ cuando $\theta' > \theta$. Ahora toma una curva de indiferencia del tipo bajo y otra del tipo alto y superponlas: si se tocaran en dos puntos A y B , entre A y B una de las dos tendría que estar por encima y luego por debajo, lo que obliga a que en algún punto intermedio las pendientes se igualen o se inviertan el orden, exactamente lo que la monotonía estricta de la TMS prohíbe. Conclusión: *dos curvas de indiferencia de tipos distintos se cruzan a lo sumo una vez*. De ahí el nombre. Y de ese hecho geométrico elemental sale toda la maquinaria de la economía de la información: el principal, al ofrecer un menú de contratos, puede confiar en que “más q ” identifica a “mayor θ ”, porque los gustos de los tipos están *ordenados* por pendiente y no se enredan.

Ejemplo 6.41 (Señalización educativa de Spence). El modelo canónico: $q = e \geq 0$ es educación (que no aumenta la productividad, solo cuesta), $t = w$ es el salario, $\theta > 0$ es la productividad/habilidad, y

$$u(w, e, \theta) = w - \frac{e^2}{\theta}.$$

La TMS entre educación y salario es

$$\left. \frac{dw}{de} \right|_{u \text{ constante}} = -\frac{u_e}{u_w} = -\frac{-2e/\theta}{1} = \frac{2e}{\theta}, \quad \frac{\partial}{\partial \theta} \left(\frac{2e}{\theta} \right) = -\frac{2e}{\theta^2} < 0 \quad (e > 0).$$

La TMS es *estrictamente decreciente* en θ : se cumple el cruce único. Interpretación: las curvas de indiferencia de los tipos altos son más *planas*; para renunciar a un dólar de salario, un tipo alto pide menos reducción de educación que un tipo bajo, porque educarse le cuesta menos. Esa asimetría de pendientes es lo que hace creíble un equilibrio *separador*: existe un nivel de educación e^* que al tipo alto le compensa alcanzar y al tipo bajo no (Ejercicio 6.48). Puedes ver MWG [9], cap. 13 (secciones 13.C y 13.D) y [10], cap. 8.

Ejemplo 6.42 (Discriminación de precios: Mussa–Rosen y Maskin–Riley). En *screening* el orden de juego se invierte: el principal (monopolista) mueve primero ofreciendo un menú $\{(q, t)\}$ y el agente informado elige. En Mussa–Rosen (1978) q es *calidad* y la utilidad del consumidor es

$$U(q, t, \theta) = \theta v(q) - t, \quad v' > 0, \quad v'' < 0,$$

con θ la disposición marginal a pagar por calidad. Aquí $U_q = \theta v'(q)$, $U_t = -1$, luego

$TMS = \theta v'(q)$, estrictamente creciente en θ : cruce único otra vez (con el signo opuesto al de Spence, porque ahora t es un pago y no un ingreso). En Maskin–Riley (1984) q es *cantidad* y el resultado es la discriminación de precios de segundo grado: tarifas no lineales, descuentos por volumen. La consecuencia técnica central, en ambos casos, es el *teorema de caracterización de la compatibilidad de incentivos*: un menú $\{(q(\theta), t(\theta))\}$ es incentivo-compatible si y solo si (a) $q(\cdot)$ es no decreciente y (b) se cumple la condición del sobre $\frac{d}{d\theta}U(q(\theta), t(\theta), \theta) = U_\theta(q(\theta), t(\theta), \theta)$. Sin cruce único, la condición local (el sobre) *no* implica la global (que ningún tipo quiera imitar a un tipo lejano), y el “enfoque de primer orden” se derrumba. Puedes ver MWG [9], cap. 14 (sección 14.C, el modelo principal–agente con selección adversa) y [10], cap. 8.

Observación 6.43 (Qué tiene que ver esto con la concavidad generalizada). Tres conexiones, en orden de importancia:

- (a) **Es una condición ordinal, como la cuasiconcavidad.** Si sustituyes $U(\cdot, \cdot, \theta)$ por $\varphi_\theta(U(\cdot, \cdot, \theta))$ con φ_θ estrictamente creciente (una transformación monótona *distinta para cada tipo*), la TMS no cambia: los factores φ'_θ se cancelan en el cociente $-U_q/U_t$. Es el mismo fenómeno del Teorema 6.13: hablamos de la *forma de las curvas de indiferencia*, no de los números que las etiquetan. Por eso el cruce único pertenece de pleno derecho a la familia de la concavidad generalizada.
- (b) **Cuasiconcavidad ordena *dentro* de un mapa; el cruce único ordena *entre* mapas.** La cuasiconcavidad dice que el conjunto $\{(q, t) : U(q, t, \theta) \geq \alpha\}$ es convexo (curvas de indiferencia con la curvatura “correcta”), lo que garantiza que el problema de cada tipo tenga solución única y bien comportada (Teorema 6.31). El cruce único añade que esas soluciones se ordenan monótonamente en θ . Las dos condiciones son complementarias y ambas son invariantes ordinales.
- (c) **Es la versión “un solo cruce” de la supermodularidad.** Si $U(q, t, \theta) = \theta v(q) - t$, se tiene $U_{q\theta} = v'(q) > 0$: *diferencias crecientes* en (q, θ) . El cruce único es la generalización ordinal de esa condición cardinal, igual que la cuasiconcavidad es la generalización ordinal de la concavidad. En el teorema de Milgrom–Shannon sobre estática comparativa monótona, la hipótesis exacta es “cuasi-supermodularidad + cruce único”, y es *necesaria y suficiente* para que $\arg \max$ crezca con el parámetro. El paralelismo con este capítulo es total: se sustituyen hipótesis cardinales (concavidad, supermodularidad) por sus contrapartes ordinales (cuasiconcavidad, cruce único), que es lo único que la teoría económica puede legítimamente suponer.

6.8.6. Nota sobre concavificación

Queda una pregunta natural que cierra el capítulo. Si la cuasiconcavidad es todo lo que la economía puede suponer, pero la concavidad es más cómoda para trabajar, ¿podríamos siempre *fabricar* concavidad eligiendo bien la representación de utilidad? Es decir: dada f cuasicóncava, ¿existe $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ estrictamente creciente tal que $\varphi \circ f$ sea cóncava? A esa φ se le llama una *concavificación* de f .

A veces sí, y de forma espectacular: la Cobb–Douglas $f(x, y) = xy$ no es cóncava, pero $\varphi = \ln$ da $\ln f = \ln x + \ln y$, que sí lo es (fue el Ejemplo 6.1, con el que abrimos el capítulo).

Lo mismo pasa con toda Cobb–Douglas $x^a y^b$ y con muchas familias usadas en aplicaciones. Pero la respuesta general es **no**: Fenchel (1953) construyó funciones cuasicóncavas continuas que no admiten ninguna concavificación, y el problema de caracterizar las que sí la admiten (estudiado por de Finetti, Debreu (1976, “Least concave utility functions”) y Kannai (1977)) es genuinamente difícil. Una condición suficiente clásica: si f es *pseudocóncava* de clase C^2 con gradiente que no se anula sobre un convexo *compacto*, entonces es concavificable.

Intuición

¿Por qué en economía casi nunca importa que la concavificación pueda fallar? Porque *todos los resultados que necesitamos ya los demostramos directamente desde la cuasiconcavidad*: contornos superiores convexos, convexidad del conjunto de óptimos (Teorema 6.30), unicidad de la demanda (Teorema 6.31), continuidad vía Berge (Corolario 6.36), suficiencia de KKT (Teorema 6.37). Ninguno pidió concavidad. La concavidad solo se vuelve indispensable cuando el modelo es *cardinal* y por tanto ya no somos libres de transformar la utilidad: bajo incertidumbre, la utilidad de von Neumann–Morgenstern está determinada salvo transformaciones afines, y ahí la concavidad *significa* aversión al riesgo, un contenido económico real y no un artefacto de la representación. Regla mnemotécnica: *en teoría del consumidor determinista, cuasicóncava es suficiente y cóncava es un lujo; bajo riesgo, cóncava es una hipótesis con contenido y no se puede fabricar*.

Resumen del capítulo

Resultados clave del capítulo, con hipótesis exactas.

- **Dos definiciones equivalentes.** Para $S \subseteq \mathbb{R}^n$ convexo y $f: S \rightarrow \mathbb{R}$ (sin más hipótesis: ni continuidad ni diferenciabilidad), son equivalentes (Teorema 6.5): (i) el contorno superior $S_\alpha(f) = \{x \in S : f(x) \geq \alpha\}$ es convexo para todo $\alpha \in \mathbb{R}$; (ii) $f(\lambda x + (1-\lambda)y) \geq \min\{f(x), f(y)\}$ para todos $x, y \in S$, $\lambda \in [0, 1]$. La versión *estricta* (Definición 6.10) exige desigualdad estricta para $x \neq y$ y $\lambda \in (0, 1)$.
- **Cóncava $\Rightarrow$ cuasicóncava, y el recíproco es falso.** Toda cóncava es cuasicóncava (Proposición 6.11); $f(x) = x^3$ y $f(x, y) = xy$ en $\mathbb{R}_{++}^2$ son cuasicóncavas y no cóncavas (Ejemplo 6.12). La inclusión es *estricta* y esa es la razón de ser del capítulo.
- **Invariancia ordinal.** Si f es cuasicóncava y g es *no decreciente* sobre un T que contenga la imagen de f , entonces $g \circ f$ es cuasicóncava (Teorema 6.13); si f es estrictamente cuasicóncava y g es *estrictamente creciente*, $g \circ f$ lo es. La concavidad *no* tiene esta propiedad: $\ln(xy)$ es cóncava y xy no. Corolario económico: la cuasiconcavidad es una propiedad de las *preferencias*, no de la representación (Teorema 6.20).
- **La suma NO preserva cuasiconcavidad.** Si f y g son cuasicóncavas, $f + g$ puede no serlo: $f(x) = x^3$ y $g(x) = -x$ son ambas monótonas (luego cuasicóncavas) pero $f + g = x^3 - x$ no lo es (Ejercicio 6.46). Lo que *sí* preserva: el *mínimo* puntual, la composición con afines, la restricción a convexos y las transformaciones monótonas (Proposición 6.14). El *máximo* tampoco preserva.

- **Caracterización de primer orden.** Si S es convexo abierto y f es *diferenciable* en S : f es cuasicóncava si y solo si para todos $x, y \in S$,

$$f(y) \geq f(x) \implies \langle \nabla f(x), y - x \rangle \geq 0$$

(Teorema 6.21). Lectura: el gradiente en x forma ángulo no obtuso con toda dirección que apunte a puntos al menos tan buenos; el gradiente “sostiene” el contorno superior.

- **Hessiano orlado: necesaria vs. suficiente.** Sea S convexo abierto y $f \in C^2(S)$, y sean $B_1, \dots, B_n$ los menores orlados de la Definición 6.22. Entonces (Teorema 6.23):

- *Necesaria (débil).* Si f es cuasicóncava en S , entonces $(-1)^r \det B_r(x) \geq 0$ para todo $r = 1, \dots, n$ y *todo* $x \in S$; es decir $\det B_1 \leq 0$, $\det B_2 \geq 0$, $\det B_3 \leq 0, \dots$ (signos alternantes empezando en negativo, con desigualdad débil). Sirve solo para **descartar**: si falla en un solo punto, f no es cuasicóncava.
- *Suficiente (estricta).* Si $(-1)^r \det B_r(x) > 0$ para todo r y *todo* $x \in S$ ($\det B_1 < 0$, $\det B_2 > 0$, $\det B_3 < 0, \dots$), entonces f es cuasicóncava, y además pseudocóncava y estrictamente cuasicóncava. Sirve solo para **afirmar**.
- El dominio importa: los signos deben verificarse *en todo el convexo abierto* S , no en un punto. Y hay una brecha entre ambas condiciones (cuando algún determinante se anula) en la que el criterio no decide.

Para cuasiconvexidad: necesaria $\det B_r \leq 0$ para todo r ; suficiente $\det B_r < 0$ para todo r .

- **Jerarquía (para f diferenciable en convexo abierto).**

$$\text{cóncava} \Rightarrow \text{pseudocóncava} \Rightarrow \text{cuasicóncava},$$

y ninguna se revierte (Teorema 6.27): $x^3 + x$ es pseudocóncava y no cóncava; x^3 es cuasicóncava y no pseudocóncava. La utilidad de la clase intermedia: bajo pseudoconcauidad, $\nabla f(x^*) = 0 \Rightarrow x^*$ es máximo *global* (Proposición 6.28) y KKT es suficiente (Teoremas 6.29 y 6.37; ver cap. 9).

- **Aplicaciones a la demanda.** Con C convexo no vacío: si f es cuasicóncava, $\arg \max_{x \in C} f$ es *convexo* (Teorema 6.30); si f es *estrictamente* cuasicóncava, tiene *a lo sumo un elemento* (Teorema 6.31), y si además C es compacto y f continua, exactamente uno. Con u continua y estrictamente cuasicóncava, $p \gg 0$ y $w > 0$: la demanda marshalliana es una *función* (Corolario 6.32) y, por el teorema del máximo de Berge (Teorema 6.35: objetivo continuo, correspondencia de restricción continua con valores no vacíos y compactos), es *continua*, igual que la utilidad indirecta (Corolario 6.36). Esa continuidad es el insumo del punto fijo que da la existencia del equilibrio walrasiano.
- **Cruce único (Spence–Mirrlees).** Con tipos $\theta \in \Theta \subseteq \mathbb{R}$ y utilidad $U(q, t, \theta)$: la TMS $-U_q/U_t$ es estrictamente monótona en θ (Definición 6.39). Ordena las curvas de

indiferencia por tipo, garantiza que dos curvas de tipos distintos se crucen a lo sumo una vez y es la hipótesis que hace válido el enfoque de primer orden en señalización y screening (MWG [9], caps. 13 y 14; [10], cap. 8). Como la cuasiconcavidad, es una condición *ordinal*.

6.9. Ejercicios resueltos [P1]

Ejercicio 6.44 (Hessiano orlado, todos los menores). Sea $f: \mathbb{R}_{++}^2 \rightarrow \mathbb{R}$ dada por

$$f(x, y) = xy + x + y.$$

(a) Calcula todos los menores principales orlados $\det B_1$ y $\det B_2$ y determina si f es cuasicóncava en $\mathbb{R}_{++}^2$, justificando qué parte del Teorema 6.23 usas. (b) ¿Es f cóncava? (c) ¿Es estrictamente cuasicóncava? ¿Pseudocóncava?

Solución. (a) *Derivadas.* Directamente:

$$f_1 = y + 1, \quad f_2 = x + 1, \quad f_{11} = 0, \quad f_{22} = 0, \quad f_{12} = f_{21} = 1.$$

El primer menor orlado es

$$\det B_1 = \det \begin{pmatrix} 0 & f_1 \\ f_1 & f_{11} \end{pmatrix} = 0 \cdot f_{11} - f_1^2 = -(y + 1)^2.$$

En $\mathbb{R}_{++}^2$ se tiene $y > 0$, luego $(y + 1)^2 > 0$ y por tanto $\det B_1 < 0$ *estrictamente*. El signo requerido por el criterio es $(-1)^1 \det B_1 > 0$, o sea $\det B_1 < 0$: **se cumple**.

El segundo menor es el determinante 3×3

$$\det B_2 = \det \begin{pmatrix} 0 & f_1 & f_2 \\ f_1 & f_{11} & f_{12} \\ f_2 & f_{21} & f_{22} \end{pmatrix} = 2f_1f_2f_{12} - f_1^2f_{22} - f_2^2f_{11},$$

usando la fórmula memorizable del caso $n = 2$ (desarrollo por la primera fila; mira la sección 6.6). Sustituyendo:

$$\det B_2 = 2(y + 1)(x + 1)(1) - (y + 1)^2 \cdot 0 - (x + 1)^2 \cdot 0 = 2(x + 1)(y + 1).$$

En $\mathbb{R}_{++}^2$, $x + 1 > 0$ e $y + 1 > 0$, luego $\det B_2 > 0$ *estrictamente*. El signo requerido es $(-1)^2 \det B_2 > 0$, o sea $\det B_2 > 0$: **se cumple**.

Como los dos signos alternan *estrictamente* $(-, +)$ en *todo* el conjunto convexo abierto $\mathbb{R}_{++}^2$, la **condición suficiente** del Teorema 6.23(b) permite concluir que f es cuasicóncava en $\mathbb{R}_{++}^2$. (Insistimos en la dirección lógica: usamos (b), la suficiente; la parte (a) del teorema solo habría servido para descartar.)

(b) ¿Cóncava? No. La Hessiana ordinaria es

$$H = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \det H = -1 < 0,$$

y una matriz simétrica 2×2 con determinante negativo es *indefinida* (sus valores propios son $+1$ y -1 : tienen signos opuestos). Para ser cóncava haría falta H semidefinida negativa, que exige $\det H \geq 0$. Alternativa directa: a lo largo de la recta $y = x$, $\varphi(t) = f(t, t) = t^2 + 2t$ tiene $\varphi''(t) = 2 > 0$, es decir f es *estrictamente convexa* sobre esa recta; una función cóncava debe ser cóncava sobre toda recta contenida en su dominio.

(c) Sí a ambas: la condición suficiente del Teorema 6.23(b) entrega, en el mismo paquete, cuasiconcavidad *estricta* y pseudoconcavidad. Comprobación independiente e instructiva: nota que

$$f(x, y) + 1 = xy + x + y + 1 = (x + 1)(y + 1),$$

así que $f = \psi((x + 1)(y + 1))$ con $\psi(s) = s - 1$ estrictamente creciente, y $(x + 1)(y + 1)$ es una Cobb–Douglas trasladada, estrictamente cuasicóncava por la Proposición 6.15 y la composición con la aplicación afín $(x, y) \mapsto (x + 1, y + 1)$ (Proposición 6.14(c)). De paso, esto exhibe una concavificación: $\ln(f(x, y) + 1) = \ln(x + 1) + \ln(y + 1)$ es cóncava, y $s \mapsto \ln(s + 1)$ es estrictamente creciente. $\square$

Ejercicio 6.45 (Cuasicóncava pero no cóncava, y su concavificación). Sea $f: \mathbb{R}_{++}^2 \rightarrow \mathbb{R}$, $f(x, y) = x^2 y^2$. (a) Demuestra que f es cuasicóncava. (b) Demuestra que f *no* es cóncava. (c) Exhibe una transformación estrictamente creciente φ tal que $\varphi \circ f$ sea cóncava, y verifícalo.

Solución. (a) Escribimos f como transformación monótona de una función conocida. Sea

$$g(x, y) = x^{1/2} y^{1/2} \quad \text{en } \mathbb{R}_{++}^2, \quad \text{de modo que} \quad f(x, y) = (g(x, y))^4,$$

pues $(x^{1/2} y^{1/2})^4 = x^2 y^2$. La función $\varphi_0(s) = s^4$ es estrictamente creciente en $s > 0$ (su derivada $4s^3$ es positiva ahí), y $g > 0$ en $\mathbb{R}_{++}^2$.

Ahora bien, g es *cóncava*: es la Cobb–Douglas $x^a y^b$ con $a = b = 1/2$, y su Hessiana tiene

$$g_{11} = a(a - 1)x^{a-2}y^b = -\frac{1}{4}x^{-3/2}y^{1/2} < 0, \quad \det H_g = ab(1 - a - b)x^{2a-2}y^{2b-2} = 0$$

(la fórmula del determinante para Cobb–Douglas, con $a + b = 1$, da exactamente 0). Una matriz simétrica 2×2 con $g_{11} < 0$ y $\det H_g = 0$ es semidefinida negativa, luego g es cóncava. Por la Proposición 6.11, g es cuasicóncava, y por el Teorema 6.13 (composición con la no decreciente φ_0), $f = \varphi_0 \circ g$ es cuasicóncava. Como φ_0 es estrictamente creciente y g es de hecho estrictamente cuasicóncava en $\mathbb{R}_{++}^2$ (Ejemplo 6.24), f también lo es.

(b) f no es cóncava. Restrinjámosla a la diagonal: $\varphi(t) = f(t, t) = t^4$ para $t > 0$, con $\varphi''(t) = 12t^2 > 0$. Es decir, f es *estrictamente convexa* a lo largo de la recta $y = x$, y por tanto no puede ser cóncava (una cóncava lo es sobre toda recta de su dominio). Razón estructural: f es homogénea de grado $4 > 1$, y una función homogénea de grado > 1 , positiva y no idénticamente nula nunca es cóncava, porque $t \mapsto f(tx) = t^4 f(x)$ crece más rápido que linealmente.

(c) Tomamos $\varphi(s) = s^{1/4}$, estrictamente creciente en $s > 0$ (derivada $\frac{1}{4}s^{-3/4} > 0$). Entonces

$$(\varphi \circ f)(x, y) = (x^2 y^2)^{1/4} = x^{1/2} y^{1/2} = g(x, y),$$

que acabamos de probar cóncava. Otra concavificación válida es $\varphi(s) = \ln s$: $\ln f = 2 \ln x + 2 \ln y$, suma de dos cóncavas, cóncava. La moraleja del ejercicio: la *misma* preferencia (los mismos conjuntos de contorno superior, las mismas curvas de indiferencia, la misma demanda) tiene representaciones cóncavas y no cóncavas; la concavidad es una propiedad de la etiqueta numérica, la cuasiconcavidad es una propiedad de la preferencia. $\square$

Ejercicio 6.46 (La suma (y el máximo) no preservan cuasiconcavidad). (a) Construye explícitamente dos funciones cuasicóncavas $f, g: \mathbb{R} \rightarrow \mathbb{R}$ cuya suma no sea cuasicóncava, exhibiendo un conjunto de contorno superior no convexo. (b) Haz lo mismo con el *máximo* puntual, y explica por qué el *mínimo* sí funciona.

Solución. (a) Tomamos

$$f(x) = x^3, \quad g(x) = -x, \quad x \in \mathbb{R}.$$

Ambas son cuasicóncavas. Toda función monótona en $\mathbb{R}$ es cuasicóncava (Ejemplo 6.8): f es estrictamente creciente y g estrictamente decreciente, y en ambos casos los conjuntos de contorno superior son semirrectas, $\{x : x^3 \geq \alpha\} = [\alpha^{1/3}, \infty)$ y $\{x : -x \geq \alpha\} = (-\infty, -\alpha]$, que son convexas.

La suma no lo es. Sea $h = f + g$, $h(x) = x^3 - x$. Factorizamos:

$$h(x) = x(x^2 - 1) = x(x - 1)(x + 1),$$

cuyos ceros son $-1, 0, 1$. Analizando signos: $h(x) \geq 0$ exactamente cuando $x \in [-1, 0] \cup [1, \infty)$. En efecto, para $x < -1$ los tres factores son negativos y el producto es negativo; en $(-1, 0)$ hay dos factores negativos y uno positivo, luego el producto es positivo; en $(0, 1)$ hay uno negativo y dos positivos, producto negativo; y para $x > 1$ los tres son positivos. Puedes confirmarlo con valores de prueba: $h(-2) = -6 < 0$, $h(-1/2) = 3/8 > 0$, $h(1/2) = -3/8 < 0$, $h(2) = 6 > 0$. Por lo tanto el contorno superior al nivel $\alpha = 0$ es

$$S_0(h) = \{x \in \mathbb{R} : x^3 - x \geq 0\} = [-1, 0] \cup [1, \infty),$$

que **no es convexo**: contiene $x = 0$ y $y = 1$ pero no su punto medio $z = 1/2$, ya que $h(1/2) = 1/8 - 1/2 = -3/8 < 0$. Por la Definición 6.3, h no es cuasicóncava. Verificación directa con la desigualdad del mínimo:

$$h\left(\frac{1}{2} \cdot 0 + \frac{1}{2} \cdot 1\right) = -\frac{3}{8} < 0 = \min\{h(0), h(1)\}.$$

(b) *El máximo.* Sean ahora $u(x) = x$ y $v(x) = -x$, ambas monótonas y por tanto cuasicóncavas. Su máximo puntual es $m(x) = \max\{x, -x\} = |x|$, y

$$S_1(m) = \{x : |x| \geq 1\} = (-\infty, -1] \cup [1, \infty),$$

que no es convexo (contiene -1 y 1 pero no 0 , donde $m(0) = 0 < 1$). Luego m no es cuasicóncava; de hecho $|x|$ es convexa, y por tanto cuasiconvexa.

¿Por qué el mínimo sí? Porque la cuasiconcavidad es una propiedad de *conjuntos de contorno superior*, y el mínimo convierte contornos superiores en *intersecciones*:

$$\{x : \min\{f_1(x), f_2(x)\} \geq \alpha\} = \{x : f_1(x) \geq \alpha\} \cap \{x : f_2(x) \geq \alpha\} = S_\alpha(f_1) \cap S_\alpha(f_2),$$

intersección de convexos, que es convexa (Proposición 6.14(a)). El máximo, en cambio, produce *uniones* de contornos superiores, y la unión de convexos no es convexa en general. La suma no tiene ninguna descripción simple en términos de contornos superiores: por eso falla, y por eso la cuasiconcavidad, a diferencia de la concavidad, no define un *cono convexo* de funciones. $\square$

Ejercicio 6.47 (Demanda Cobb–Douglas y unicidad). Un consumidor tiene utilidad $u(x, y) = x^\alpha y^{1-\alpha}$ con $\alpha \in (0, 1)$, precios $p, q > 0$ y riqueza $w > 0$. (a) Deriva la demanda marshalliana. (b) Justifica rigurosamente que el óptimo existe, que es interior y que es *único*, indicando qué teorema del capítulo usas en cada paso. (c) Comprueba que la demanda es continua en (p, q, w) y comenta la relación con el teorema de Berge.

Solución. (a) *Derivación.* Como $u > 0$ en $\mathbb{R}_{++}^2$ y $\ln$ es estrictamente creciente, maximizar u equivale a maximizar

$$U(x, y) = \ln u(x, y) = \alpha \ln x + (1 - \alpha) \ln y,$$

que es cóncava (suma de cóncavas). El cambio de objetivo es legítimo precisamente por el Teorema 6.13: la transformación monótona no altera ni el conjunto de maximizadores ni los conjuntos de contorno.

La restricción presupuestaria se satura ($px + qy = w$) porque u es estrictamente creciente en cada argumento: si sobrara riqueza se podría comprar más de x y mejorar. Formamos el lagrangiano $\mathcal{L} = \alpha \ln x + (1 - \alpha) \ln y + \lambda(w - px - qy)$ y tomamos condiciones de primer orden:

$$\frac{\alpha}{x} = \lambda p, \quad \frac{1 - \alpha}{y} = \lambda q, \quad px + qy = w.$$

De las dos primeras, $\alpha = \lambda px$ y $1 - \alpha = \lambda qy$; sumando, $1 = \lambda(px + qy) = \lambda w$, de donde $\lambda = 1/w$. Sustituyendo hacia atrás:

$$\boxed{x(p, q, w) = \frac{\alpha w}{p}, \quad y(p, q, w) = \frac{(1 - \alpha)w}{q}.$$

Es el resultado clásico: con Cobb–Douglas se gasta una fracción fija α de la riqueza en el primer bien, sea cual sea el precio.

(b) *Existencia, interioridad, unicidad.*

- *Existencia:* $B(p, q, w)$ es no vacío, convexo y compacto (demostrado en el Corolario 6.32) y u es continua en $\mathbb{R}_{++}^2$; Weierstrass garantiza que el máximo se alcanza.
- *Interioridad:* sobre los ejes ($x = 0$ o $y = 0$) se tiene $u = 0$, mientras que el punto interior $(\frac{w}{2p}, \frac{w}{2q})$ es factible y da $u > 0$. Luego ningún punto de la frontera con una coordenada nula puede ser óptimo, y podemos trabajar en el abierto $\mathbb{R}_{++}^2$, donde las CPO tienen sentido.

- *Unicidad:* u es estrictamente cuasicóncava en $\mathbb{R}_{++}^2$, como se verificó con el Hessiano orlado en el Ejemplo 6.24 (los menores alternan estrictamente para cualesquiera exponentes positivos), y el Teorema 6.23(b) entrega, junto con la cuasiconcavidad estricta, la pseudoconcavidad. Entonces:

- por el Teorema 6.31, el maximizador sobre el convexo $B(p, q, w)$ es único: la demanda es una *función*;
- por la pseudoconcavidad de u y la cuasiconcavidad (de hecho, linealidad) de la restricción, el Teorema 6.29(a) garantiza que el punto que resolvimos con las CPO es el máximo *global*, sin necesidad de condiciones de segundo orden.

Observa que $u = x^\alpha y^{1-\alpha}$ sí es cóncava aquí (porque $\alpha + (1 - \alpha) = 1$), pero el argumento anterior no usó ese hecho, y por eso funciona igual para $u = x^a y^b$ con $a + b > 1$, donde la concavidad falla y la cuasiconcavidad estricta no.

(c) *Continuidad.* Las fórmulas $\alpha w/p$ y $(1 - \alpha)w/q$ son cocientes de funciones continuas con denominadores no nulos en $\mathbb{R}_{++}^2 \times \mathbb{R}_{++}$: continuas. Esto es exactamente lo que predice el Corolario 6.36 sin necesidad de calcular nada: objetivo continuo + correspondencia presupuestaria continua de valores compactos + solución única $\Rightarrow$ demanda continua. La utilidad indirecta resulta

$$v(p, q, w) = \left(\frac{\alpha w}{p}\right)^\alpha \left(\frac{(1 - \alpha)w}{q}\right)^{1-\alpha} = \alpha^\alpha (1 - \alpha)^{1-\alpha} w p^{-\alpha} q^{-(1-\alpha)},$$

también continua, como asegura la parte (a) de Berge.

Apéndice: el caso CES. Con $u(x, y) = (x^\rho + y^\rho)^{1/\rho}$, $\rho < 1$, $\rho \neq 0$ (Ejemplo 6.16), las CPO dan $\rho x^{\rho-1} = \lambda p$, $\rho y^{\rho-1} = \lambda q$, luego $(x/y)^{\rho-1} = p/q$ y, con la elasticidad de sustitución $\sigma = 1/(1 - \rho)$,

$$x(p, q, w) = \frac{p^{-\sigma} w}{p^{1-\sigma} + q^{1-\sigma}}, \quad y(p, q, w) = \frac{q^{-\sigma} w}{p^{1-\sigma} + q^{1-\sigma}}.$$

La unicidad se justifica igual: la CES es estrictamente cuasicóncava para $\rho < 1$, $\rho \neq 0$. Además es cóncava, pero solo gracias a un argumento extra (es no negativa, cuasicóncava y homogénea de grado 1); y si la elevas a una potencia mayor que 1 deja de ser cóncava y sigue dando exactamente la misma demanda, que es justo la moraleja ordinal del capítulo. $\square$

Ejercicio 6.48 (Cruce único en el modelo de señalización de Spence). Un trabajador de tipo (productividad) $\theta > 0$ elige educación $e \geq 0$ y percibe salario w , con utilidad

$$u(w, e, \theta) = w - \frac{e^2}{\theta}.$$

(a) Calcula la tasa marginal de sustitución entre educación y salario y determina su monotonía en θ . (b) Verifica la condición de cruce único en su versión ordinal (Definición 6.40). (c) Con dos tipos $0 < \theta_L < \theta_H$ y salarios $w = \theta$ en un equilibrio separador, encuentra el rango de niveles de educación e^* que separan a los tipos.

Solución. (a) *TMS.* Las derivadas parciales son

$$u_w = 1, \quad u_e = -\frac{2e}{\theta}.$$

A lo largo de una curva de indiferencia, $du = u_w dw + u_e de = 0$, de donde

$$\text{TMS}(e, \theta) = \left. \frac{dw}{de} \right|_{u \text{ const.}} = -\frac{u_e}{u_w} = \frac{2e}{\theta} > 0 \quad (e > 0).$$

Es positiva: para mantener la utilidad constante, más educación exige más salario compensatorio (la educación es un “mal”). Su monotonía en el tipo:

$$\frac{\partial}{\partial \theta} \left(\frac{2e}{\theta} \right) = -\frac{2e}{\theta^2} < 0 \quad \text{para } e > 0.$$

La TMS es *estrictamente decreciente* en θ : se cumple la condición de Spence–Mirrlees de la Definición 6.39. Lectura gráfica en el plano (e, w) con e en el eje horizontal: las curvas de indiferencia del tipo alto son *más planas* en cada punto. Como la pendiente de un tipo domina a la del otro *en todo punto*, dos curvas de indiferencia de tipos distintos pueden cortarse a lo sumo una vez.

Equivalentemente, en versión cardinal: $\partial^2 u / \partial e \partial \theta = 2e / \theta^2 > 0$, es decir, u tiene *diferencias crecientes* en (e, θ) : el costo marginal de la educación es menos oneroso cuanto mayor es el tipo.

(b) *Versión ordinal*. Sean $e' > e \geq 0$, salarios w', w y tipos $\theta_H > \theta_L > 0$. Supongamos que el tipo bajo acepta (débilmente) el paquete de mayor educación:

$$u(w', e', \theta_L) \geq u(w, e, \theta_L) \iff (w' - w) \geq \frac{e'^2 - e^2}{\theta_L}.$$

Queremos concluir que el tipo alto lo prefiere *estrictamente*. Calculamos su diferencia de utilidad y sumamos y restamos el término del tipo bajo:

$$u(w', e', \theta_H) - u(w, e, \theta_H) = (w' - w) - \frac{e'^2 - e^2}{\theta_H} = \underbrace{\left[(w' - w) - \frac{e'^2 - e^2}{\theta_L} \right]}_{\geq 0 \text{ por hipótesis}} + \underbrace{(e'^2 - e^2)}_{> 0 \text{ pues } e' > e \geq 0} \underbrace{\left(\frac{1}{\theta_L} - \frac{1}{\theta_H} \right)}_{> 0 \text{ pues } \theta_L < \theta_H}.$$

El primer corchete es no negativo y el segundo sumando es estrictamente positivo, luego la suma es > 0 :

$$u(w', e', \theta_H) > u(w, e, \theta_H).$$

Esto es exactamente la Definición 6.40. Nota que la demostración no usó diferenciabilidad, solo álgebra: la versión ordinal es más robusta que la diferencial.

(c) *Equilibrio separador*. Consideremos el esquema salarial

$$w(e) = \begin{cases} \theta_H & \text{si } e \geq e^*, \\ \theta_L & \text{si } e < e^*, \end{cases}$$

con la conjetura de que el tipo bajo elige $e_L = 0$ y cobra θ_L , y el tipo alto elige $e_H = e^*$ y cobra θ_H . Para que esto sea un equilibrio hacen falta dos restricciones de compatibilidad de incentivos.

El tipo bajo no quiere imitar al alto:

$$\underbrace{\theta_L - \frac{0^2}{\theta_L}}_{\text{ser sincero}} \geq \underbrace{\theta_H - \frac{(e^*)^2}{\theta_L}}_{\text{imitar}} \iff (e^*)^2 \geq \theta_L(\theta_H - \theta_L).$$

El tipo alto prefiere educarse a hacerse pasar por bajo:

$$\underbrace{\theta_H - \frac{(e^*)^2}{\theta_H}}_{\text{ser sincero}} \geq \underbrace{\theta_L - 0}_{\text{fingir}} \iff (e^*)^2 \leq \theta_H(\theta_H - \theta_L).$$

Combinando, cualquier

$$e^* \in \left[\sqrt{\theta_L(\theta_H - \theta_L)}, \sqrt{\theta_H(\theta_H - \theta_L)} \right]$$

sostiene un equilibrio separador. El intervalo es *no vacío* porque $\theta_L < \theta_H$ implica $\theta_L(\theta_H - \theta_L) < \theta_H(\theta_H - \theta_L)$, y justamente esa desigualdad estricta es la condición de cruce único en acción: si el costo marginal de la educación no dependiera del tipo (si fallara el cruce único), los dos umbrales coincidirían y no quedaría margen para separar. La existencia de un continuo de equilibrios separadores, y la consiguiente multiplicidad, es el punto de partida de las discusiones sobre refinamientos en MWG [9], cap. 13. $\square$

Ejercicio 6.49 (Clasificación: cóncava, pseudocóncava o solo cuasicóncava). Para cada función, decide si es cóncava, pseudocóncava, cuasicóncava o ninguna, justificando cada respuesta:

- (I) $f(x) = x^3 + x$ en $\mathbb{R}$;
- (II) $f(x) = x^3$ en $\mathbb{R}$;
- (III) $f(x, y) = x^{1/2}y^{1/2}$ en $\mathbb{R}_{++}^2$;
- (IV) $f(x, y) = x^2y^2$ en $\mathbb{R}_{++}^2$;
- (V) $f(x) = x^2$ en $\mathbb{R}$;
- (VI) $f(x, y) = \min\{x, y\}$ en $\mathbb{R}^2$;
- (VII) $f(x) = e^x$ en $\mathbb{R}$.

Solución. Conviene tener a mano un *lema de trabajo*, que probamos primero porque resuelve varios casos de un golpe.

Lema. Si g es cóncava y diferenciable en un convexo abierto S y φ es diferenciable con $\varphi' > 0$ en un intervalo que contenga la imagen de g , entonces $f = \varphi \circ g$ es pseudocóncava.

Prueba. Sean $x, y \in S$ con $f(y) > f(x)$. Como φ es estrictamente creciente, $g(y) > g(x)$. La caracterización de primer orden de la concavidad da $\langle \nabla g(x), y - x \rangle \geq g(y) - g(x) > 0$. Por la regla de la cadena, $\nabla f(x) = \varphi'(g(x)) \nabla g(x)$ con $\varphi'(g(x)) > 0$, luego $\langle \nabla f(x), y - x \rangle = \varphi'(g(x)) \langle \nabla g(x), y - x \rangle > 0$, que es la Definición 6.26. $\square$

(i) $f(x) = x^3 + x$: *pseudocóncava, no cóncava*. Su derivada es $f'(x) = 3x^2 + 1 \geq 1 > 0$ en todo punto, luego f es estrictamente creciente y en particular cuasicóncava (Ejemplo 6.8). Es

pseudocóncava: si $f(y) > f(x)$, la monotonía estricta da $y > x$, y entonces $f'(x)(y - x) > 0$ porque $f'(x) > 0$ y $y - x > 0$. No es cóncava: $f''(x) = 6x > 0$ para $x > 0$. (Este es el ejemplo prometido en el Teorema 6.27 para mostrar que “pseudocóncava $\Rightarrow$ cóncava” es falso.) De hecho es también pseudoconvexa, por el mismo argumento aplicado a $-f$.

(ii) $f(x) = x^3$: *cuasicóncava, no pseudocóncava, no cóncava*. Es estrictamente creciente, luego cuasicóncava. Pero $f'(0) = 0$ mientras que $f(1) = 1 > 0 = f(0)$: hay una mejora estricta que el gradiente no detecta, contradiciendo la Definición 6.26. Equivalentemente, por la Proposición 6.28, si fuese pseudocóncava el punto estacionario $x = 0$ tendría que ser máximo global, y no lo es. No es cóncava porque $f''(x) = 6x > 0$ en $x > 0$. Este es *el* contraejemplo que hay que recordar: separa cuasiconcavidad de pseudoconcavidad y explica por qué Arrow–Enthoven necesita condiciones adicionales.

(iii) $f(x, y) = x^{1/2}y^{1/2}$: *cóncava* (luego pseudocóncava y cuasicóncava). Es Cobb–Douglas con $a + b = 1 \leq 1$; su Hessiana cumple $f_{11} < 0$ y $\det H = ab(1 - a - b)x^{2a-2}y^{2b-2} = 0$, luego es semidefinida negativa. Las otras dos propiedades se siguen del Teorema 6.27.

(iv) $f(x, y) = x^2y^2$: *pseudocóncava y estrictamente cuasicóncava, no cóncava*. La no concavidad se probó en el Ejercicio 6.45(b). La pseudoconcavidad sale del lema con $g = x^{1/2}y^{1/2}$ (cóncava, caso (iii)) y $\varphi(s) = s^4$, cuya derivada $4s^3$ es positiva en $s > 0$. Comprobación alternativa con menores orlados: $f_1 = 2xy^2$, $f_2 = 2x^2y$, $f_{11} = 2y^2$, $f_{22} = 2x^2$, $f_{12} = 4xy$, de donde

$$\det B_1 = -4x^2y^4 < 0,$$

$$\begin{aligned} \det B_2 &= 2(2xy^2)(2x^2y)(4xy) - (4x^2y^4)(2x^2) - (4x^4y^2)(2y^2) \\ &= 32x^4y^4 - 16x^4y^4 = 16x^4y^4 > 0, \end{aligned}$$

signos estrictamente alternantes en todo $\mathbb{R}_{++}^2$: el Teorema 6.23(b) da cuasiconcavidad estricta y pseudoconcavidad.

(v) $f(x) = x^2$: *ninguna de las tres* (es convexa, no cóncava; y es *cuasiconvexa*, no cuasicóncava). El contorno superior $\{x : x^2 \geq 1\} = (-\infty, -1] \cup [1, \infty)$ no es convexo. Recuerda la trampa de la caja de alerta de la sección 6.6: aquí $\det B_1 = -4x^2 \leq 0$ cumple la condición *necesaria* débil en todo punto, y sin embargo la función no es cuasicóncava; por eso la condición necesaria nunca sirve para afirmar.

(vi) $f(x, y) = \min\{x, y\}$: *cóncava* (luego cuasicóncava); la *pseudoconcavidad ni siquiera está definida* porque f no es diferenciable en la diagonal $x = y$. La concavidad: para $z = \lambda a + (1 - \lambda)b$,

$$\min\{z_1, z_2\} \geq \lambda \min\{a_1, a_2\} + (1 - \lambda) \min\{b_1, b_2\}$$

se obtiene notando que $z_i = \lambda a_i + (1 - \lambda)b_i \geq \lambda \min\{a_1, a_2\} + (1 - \lambda) \min\{b_1, b_2\}$ para $i = 1, 2$, y tomando el mínimo sobre i en el lado izquierdo. Punto pedagógico: la pseudoconcavidad es una noción *diferenciable*; para funciones no suaves, la generalización correcta pasa por el subdiferencial (cap. 7).

(vii) $f(x) = e^x$: *pseudocóncava y cuasicóncava, no cóncava* (es convexa). Cuasicóncava por monotonía; pseudocóncava porque $f'(x) = e^x > 0$ en todo punto y se repite el argumento de (i). Es además pseudoconvexa y cuasiconvexa: una función monótona en $\mathbb{R}$ pertenece a todas las clases “cuasi” a la vez. Moraleja: cuasicóncavo *no* significa “con forma de campana invertida”;

significa únicamente “contornos superiores convexos”, y las monótonas los tienen. $\square$

Estrategia de examen

Protocolo de examen para clasificar una función. Ante la pregunta “¿es f cóncava/pseudocóncava/cuasicóncava?”, sigue este orden, que va de lo barato a lo caro:

1. **¿Es monótona en una variable, o composición evidente?** Si $f = \varphi \circ g$ con φ creciente y g conocida (lineal, cóncava, Cobb–Douglas), cierra por el Teorema 6.13 y el lema del Ejercicio 6.49. Es la vía más rápida y la que más puntos da.
2. **Prueba primero la concavidad** (Hessiana semidefinida negativa): si sale, has terminado, porque cóncava $\Rightarrow$ pseudocóncava $\Rightarrow$ cuasicóncava (Teorema 6.27).
3. **Si no es cóncava, ve al Hessiano orlado** y busca signos *estrictos* alternantes en todo el dominio: eso da cuasiconcavidad estricta + pseudoconcavidad de una vez (Teorema 6.23(b)).
4. **Para refutar**, busca un contorno superior no convexo (dos puntos del conjunto cuyo punto medio se salga) o un punto donde falle el signo débil del criterio necesario.
5. **Si hay ceros del gradiente**, sospecha de la pseudoconcavidad: compruébala directamente contra la Proposición 6.28 (todo estacionario debe ser máximo global).

Y escribe siempre en qué dominio trabajas: casi todos los enunciados de este capítulo son verdaderos en $\mathbb{R}_{++}^n$ y falsos en $\mathbb{R}^n$.

Capítulo 7

Subdiferenciabilidad [P3]

Semana 5 del cronograma. Bibliografía: Ruszczyński [6]; Brinkhuis [3]; Boyd y Vandenberghe [2].

¿Para qué sirve esto en Microeconomía?

En Microeconomía las funciones de valor centrales del curso (la función de gasto $e(p, u)$, la función de beneficio $\pi(p)$ y la función de costo $c(w, y)$) son cóncavas o convexas en los precios, pero *no siempre diferenciables*: cuando el problema del consumidor o de la firma tiene soluciones múltiples, la función de valor exhibe un “quiebre” (kink) y la derivada clásica no existe. El objeto que sí existe siempre es el *subdiferencial*, y la versión general del lema de Shephard y del lema de Hotelling dice exactamente que *la demanda es el subdiferencial de la función de valor* (el *superdiferencial* cuando la función de valor es cóncava, como el gasto o el costo) [9, 10]. En teoría de contratos y diseño de mecanismos (las partes de fallas de mercado y de bienestar e incentivos, MWG caps. 13–14 y 23), la utilidad indirecta del agente es un máximo de funciones lineales en su tipo: convexa y con quiebres. El teorema de la envolvente de Milgrom y Segal [11], herramienta estándar en esos temas, está formulado precisamente en términos de derivadas laterales y subgradientes. Finalmente, los quiebres presupuestarios (impuestos por tramos, tarifas escalonadas de electricidad o agua) generan demandas caracterizadas por condiciones de primer orden con subdiferenciales. Este capítulo construye esa herramienta desde cero.

7.1. Motivación: cuando la derivada no existe [P3]

En el cap. 5 vimos la *caracterización de primer orden* de las funciones convexas diferenciables: si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa y diferenciable en x , entonces

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle \quad \text{para todo } y \in \mathbb{R}^n. \quad (7.1)$$


Geométricamente: la gráfica de f queda *por encima* de su plano tangente en x ; la aproximación lineal es una *cota inferior global*, no solo una aproximación local. Esta es la propiedad que hace que las condiciones de primer orden sean *suficientes* en optimización convexa.

El problema es que muchas funciones convexas importantes *no son diferenciables* en todos

los puntos, y no se trata de patologías raras sino de ejemplos completamente naturales:

- **El valor absoluto** $f(x) = |x|$: convexa en $\mathbb{R}$, pero en $x = 0$ la gráfica tiene una esquina y no hay recta tangente única.
- **Máximos de funciones lineales** $f(x) = \max\{\langle a_1, x \rangle + b_1, \dots, \langle a_m, x \rangle + b_m\}$: convexa (es un máximo puntual de convexas), pero no diferenciable donde dos o más “piezas” empatan. Las utilidades indirectas de agentes en mecanismos tienen exactamente esta forma.
- **Normas**: $\|x\|$, $\|x\|_1 = \sum_i |x_i|$, $\|x\|_\infty = \max_i |x_i|$ son convexas pero no diferenciables en el origen (y $\|\cdot\|_1$, $\|\cdot\|_\infty$ tampoco en muchos otros puntos).
- **En economía**: una tarifa por tramos (los primeros 100 kWh a un precio, el resto a otro) genera un gasto convexo con quiebre; la función de gasto $e(p, u)$ tiene quiebres en los precios donde la demanda hicksiana no es única; en econometría, la regresión de mínimas desviaciones absolutas minimiza $\sum_i |y_i - x_i^\top \beta|$, que no es diferenciable.

¿Cómo rescatar la desigualdad (7.1) sin derivada? La clave está en *leer la desigualdad al revés*. En (7.1) el vector $\nabla f(x)$ es la pendiente de *una* recta (o hiperplano) que toca la gráfica en $(x, f(x))$ y queda por debajo de ella en todas partes: una *recta soporte*. Cuando f es diferenciable, esa recta soporte es única. Cuando hay una esquina, no hay una única recta soporte: ¡hay muchas! La generalización correcta es entonces: en vez de *la* tangente, considerar *todas* las pendientes de rectas soporte en el punto. Ese conjunto de pendientes es el subdiferencial.



En la figura, cada recta $y = gx$ con $g \in [-1, 1]$ pasa por el origen y queda por debajo de $|x|$ en todo $\mathbb{R}$: cada una es una recta soporte de la gráfica en 0, y cada pendiente $g \in [-1, 1]$ será un *subgradiente* de $|x|$ en 0.

7.2. Subgradiente y subdiferencial [P3]

Trabajamos con funciones $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexas y propias (es decir, $f \not\equiv +\infty$), con dominio efectivo $\text{dom } f = \{x \in \mathbb{R}^n : f(x) < +\infty\}$. Permitir el valor $+\infty$ es cómodo: nos deja codificar restricciones dentro de la función (vía la indicatriz, como veremos) sin cambiar la teoría.

Definición 7.1 (Subgradiente y subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa y $x \in \text{dom } f$. Un vector $g \in \mathbb{R}^n$ es un **subgradiente** (*subgradient*) de f en x si

$$f(y) \geq f(x) + \langle g, y - x \rangle \quad \text{para todo } y \in \mathbb{R}^n. \quad (7.2)$$

El conjunto de todos los subgradiientes de f en x ,

$$\partial f(x) = \{ g \in \mathbb{R}^n : f(y) \geq f(x) + \langle g, y - x \rangle \quad \forall y \in \mathbb{R}^n \},$$

se llama el **subdiferencial** (*subdifferential*) de f en x . Si $\partial f(x) \neq \emptyset$ decimos que f es **subdiferenciable** en x .

Nota tres cosas sobre la definición. Primero, es una condición *global*: la desigualdad debe cumplirse para *todo* y , no solo cerca de x (para funciones convexas esto no es restrictivo: una desigualdad local de este tipo se propaga a todo el espacio). Segundo, $\partial f(x)$ es un *conjunto*, no un vector: la subdiferenciabilidad reemplaza un objeto puntual (el gradiente) por un objeto conjuntual. Tercero, la desigualdad (7.2) dice que la función afín $y \mapsto f(x) + \langle g, y - x \rangle$ es una *minorante afín* de f que es *exacta* en x (coincide con f ahí).

Intuición

Piensa en $\partial f(x)$ como el “abanico de pendientes” de todas las rectas (hiperplanos) que puedes apoyar contra la gráfica de f en el punto $(x, f(x))$ sin cortarla. En un punto suave el abanico colapsa a una sola pendiente: el gradiente. En una esquina, el abanico se abre: hay todo un rango de pendientes admisibles. Cuanto más “puntiaguda” la esquina, más grande el subdiferencial. Equivalentemente, en el lenguaje del cap. 4: $g \in \partial f(x)$ si y solo si el hiperplano (no vertical) de $\mathbb{R}^{n+1}$ determinado por $(g, -1)$ *soporta* al epígrafo $\text{epi } f$ en el punto $(x, f(x))$. La subdiferenciabilidad es la teoría de separación aplicada al epígrafo.

Calculemos ahora subdiferenciales *directamente desde la definición*. Es el mejor entrenamiento posible: obliga a manipular la desigualdad (7.2) con cuidado.

Ejemplo 7.2 (El valor absoluto). Sea $f(x) = |x|$ en $\mathbb{R}$. Afirmamos que

$$\partial f(x) = \begin{cases} \{-1\} & \text{si } x < 0, \\ [-1, 1] & \text{si } x = 0, \\ \{1\} & \text{si } x > 0. \end{cases}$$

Verifiquémoslo con todo detalle en el caso interesante, $x = 0$. Por definición, $g \in \partial f(0)$ si y solo si

$$|y| \geq |0| + g(y - 0) = gy \quad \text{para todo } y \in \mathbb{R}.$$

(*Necesidad.*) Supongamos que g cumple $|y| \geq gy$ para todo y . Tomando $y = 1$: $1 \geq g$. Tomando $y = -1$: $1 \geq -g$, es decir $g \geq -1$. Por lo tanto $g \in [-1, 1]$.

(*Suficiencia.*) Recíprocamente, sea $g \in [-1, 1]$, o sea $|g| \leq 1$. Para cualquier $y \in \mathbb{R}$,

$$gy \leq |gy| = |g||y| \leq 1 \cdot |y| = |y|,$$

que es exactamente la desigualdad requerida. Concluimos $\partial f(0) = [-1, 1]$.

Para $x > 0$: si $g \in \partial f(x)$, tomando y cercano a x (donde $f(y) = y$) la desigualdad $y \geq x + g(y - x)$ con $y > x$ da $g \leq 1$ y con $y < x$ (aún positivo) da $g \geq 1$; luego $g = 1$. Y $g = 1$ sí

funciona globalmente: $|y| \geq y = x + 1 \cdot (y - x)$ para todo y . El caso $x < 0$ es simétrico.

Observa el patrón unidimensional que reaparecerá siempre: en un quiebre, el subdiferencial es el *intervalo entre la pendiente por la izquierda y la pendiente por la derecha*.

Ejemplo 7.3 (Máximo de dos funciones afines). Sea $f(x) = \max\{a_1x + b_1, a_2x + b_2\}$ en $\mathbb{R}$, con $a_1 < a_2$, y supongamos que las dos rectas se cortan en el punto $\bar{x}$ (es decir, $a_1\bar{x} + b_1 = a_2\bar{x} + b_2$). Entonces

$$\partial f(x) = \begin{cases} \{a_1\} & \text{si } x < \bar{x}, \\ [a_1, a_2] & \text{si } x = \bar{x}, \\ \{a_2\} & \text{si } x > \bar{x}. \end{cases}$$

En efecto, para $x \neq \bar{x}$ solo una pieza está activa, f es afín en un entorno y globalmente queda por encima de esa pieza, así que la pendiente activa es el único subgradiente. En $\bar{x}$, sea $g \in [a_1, a_2]$; escribamos $g = \lambda a_1 + (1 - \lambda)a_2$ con $\lambda \in [0, 1]$. Para todo y :

$$f(y) \geq \lambda(a_1y + b_1) + (1 - \lambda)(a_2y + b_2) = f(\bar{x}) + g(y - \bar{x}),$$

donde la primera desigualdad usa que $f(y)$ domina a cada pieza (y por tanto a cualquier promedio de ellas), y la igualdad usa que ambas piezas valen $f(\bar{x})$ en $\bar{x}$. Luego $[a_1, a_2] \subseteq \partial f(\bar{x})$. Para la inclusión opuesta, la desigualdad de subgradiente evaluada en $y \rightarrow \bar{x}^+$ y $y \rightarrow \bar{x}^-$ fuerza $a_1 \leq g \leq a_2$, como en el Ejemplo 7.2. Nota que $\partial f(\bar{x}) = \text{conv}\{a_1, a_2\}$: la cápsula convexa de las pendientes activas. Esto anticipa el teorema del máximo puntual de la Sección 7.6.

Ejemplo 7.4 (La norma euclidiana en el origen). Sea $f(x) = \|x\|$ (norma euclidiana) en $\mathbb{R}^n$. Afirmamos que

$$\partial f(0) = \{g \in \mathbb{R}^n : \|g\| \leq 1\} = \bar{B}(0, 1),$$

la bola unitaria cerrada. En efecto, $g \in \partial f(0)$ si y solo si $\|y\| \geq \langle g, y \rangle$ para todo $y \in \mathbb{R}^n$.

(*Suficiencia.*) Si $\|g\| \leq 1$, la desigualdad de Cauchy–Schwarz da $\langle g, y \rangle \leq \|g\| \|y\| \leq \|y\|$ para todo y .

(*Necesidad.*) Si $\|y\| \geq \langle g, y \rangle$ para todo y , elegimos el y más desfavorable: $y = g$. Entonces $\|g\| \geq \langle g, g \rangle = \|g\|^2$, de donde $\|g\|(\|g\| - 1) \leq 0$ y por tanto $\|g\| \leq 1$.

(Para $x \neq 0$, la norma es diferenciable y $\partial f(x) = \{x/\|x\|\}$, por la Proposición 7.10 más abajo.)

El siguiente ejemplo es el más importante para la optimización con restricciones: conecta el subdiferencial con la geometría de conjuntos convexos y define un objeto que reaparecerá como protagonista en las condiciones de Karush–Kuhn–Tucker (KKT).

Definición 7.5 (Función indicatriz y cono normal). Sea $C \subseteq \mathbb{R}^n$ un conjunto convexo no vacío.

- La **función indicatriz** (*indicator function*) de C es

$$\delta_C(x) = \begin{cases} 0 & \text{si } x \in C, \\ +\infty & \text{si } x \notin C. \end{cases}$$

Es convexa (su epígrafo es $C \times [0, +\infty)$, un convexo) y codifica la restricción “ $x \in C$ ”: minimizar f sobre C equivale a minimizar $f + \delta_C$ sobre todo $\mathbb{R}^n$.

- El **cono normal** (*normal cone*) a C en $x \in C$ es

$$N_C(x) = \{g \in \mathbb{R}^n : \langle g, y - x \rangle \leq 0 \quad \forall y \in C\}.$$

Lee la definición de $N_C(x)$ con calma: g es normal a C en x si g forma ángulo obtuso (o recto) con *toda* dirección $y - x$ que apunte desde x hacia el conjunto. Es decir, g “apunta hacia afuera” de C desde x . Es inmediato verificar que $N_C(x)$ es un cono convexo cerrado que contiene a 0.

Ejemplo 7.6 (Subdiferencial de la indicatriz). Para $C \subseteq \mathbb{R}^n$ convexo y $x \in C$:

$$\partial\delta_C(x) = N_C(x).$$

Demostración desde la definición. $g \in \partial\delta_C(x)$ significa

$$\delta_C(y) \geq \delta_C(x) + \langle g, y - x \rangle = \langle g, y - x \rangle \quad \forall y \in \mathbb{R}^n.$$

Si $y \notin C$, el lado izquierdo es $+\infty$ y la desigualdad es automática: los puntos fuera de C no imponen ninguna condición. Si $y \in C$, el lado izquierdo es 0 y la condición se vuelve $\langle g, y - x \rangle \leq 0$. Por lo tanto, $g \in \partial\delta_C(x)$ si y solo si $\langle g, y - x \rangle \leq 0$ para todo $y \in C$, que es exactamente la definición de $N_C(x)$. $\square$

Casos concretos. (i) Si $x \in \text{int } C$, entonces $N_C(x) = \{0\}$: para cualquier $g \neq 0$ podemos movernos un poco desde x en la dirección de g sin salir de C , y ese y viola la desigualdad. (ii) Si $C = [a, b] \subset \mathbb{R}$ y $x = b$, entonces $y - b \leq 0$ para todo $y \in [a, b]$, así que $N_C(b) = [0, +\infty)$: en el borde derecho, las normales apuntan a la derecha. Análogamente $N_C(a) = (-\infty, 0]$ y $N_C(x) = \{0\}$ para $x \in (a, b)$.

Intuición

La igualdad $\partial\delta_C = N_C$ es un pequeño milagro de contabilidad: convierte una *restricción geométrica* (x debe estar en C) en un *objeto de cálculo* (un conjunto de “gradientes generalizados”). Cuando en KKT aparezca la condición $0 \in \nabla f(x^*) + N_C(x^*)$, será literalmente la regla de Fermat generalizada aplicada a $f + \delta_C$: los multiplicadores de Lagrange son las coordenadas de un elemento del cono normal. Guarda este ejemplo: es el puente entre este capítulo y el de optimalidad.

7.3. Propiedades básicas del subdiferencial [P3]

Proposición 7.7 (Estructura del subdiferencial). Para toda $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa y todo $x \in \text{dom } f$, el conjunto $\partial f(x)$ es convexo y cerrado (posiblemente vacío).

Demostración. Para cada $y \in \mathbb{R}^n$ fijo, el conjunto

$$H_y = \{g \in \mathbb{R}^n : \langle g, y - x \rangle \leq f(y) - f(x)\}$$

es un semiespacio cerrado en la variable g (o todo $\mathbb{R}^n$, si $y - x = 0$ o si $f(y) = +\infty$): la función $g \mapsto \langle g, y - x \rangle$ es lineal en g , y un conjunto de la forma $\{g : \text{lineal}(g) \leq \text{constante}\}$ es un semiespacio cerrado, que es convexo y cerrado. Por definición,

$$\partial f(x) = \bigcap_{y \in \mathbb{R}^n} H_y,$$

y una intersección arbitraria de conjuntos convexos y cerrados es convexa y cerrada (resultados del cap. 2). $\square$

La pregunta delicada es la *no vacuidad*: ¿siempre existe al menos un subgradiente? En el interior del dominio, sí, y la demostración es una aplicación directa del teorema del hiperplano soporte del cap. 4, aplicado al epígrafo. Este es el resultado central del capítulo.

Teorema 7.8 (Existencia de subgradientes en el interior). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa y propia, y sea $x \in \text{int}(\text{dom } f)$. Entonces $\partial f(x) \neq \emptyset$.*

Demostración. La idea: el punto $(x, f(x))$ está en la frontera del convexo $\text{epi } f$; apoyamos un hiperplano soporte ahí; verificamos que no es vertical; su pendiente es el subgradiente buscado.

Paso 1: hiperplano soporte al epígrafo. El epígrafo $\text{epi } f = \{(y, t) \in \mathbb{R}^n \times \mathbb{R} : t \geq f(y)\}$ es convexo (cap. 5) y el punto $(x, f(x))$ pertenece a su frontera: está en $\text{epi } f$, pero los puntos $(x, f(x) - \varepsilon)$ con $\varepsilon > 0$ no. Por el teorema del hiperplano soporte (cap. 4), existe $(a, \beta) \in \mathbb{R}^n \times \mathbb{R}$ con $(a, \beta) \neq (0, 0)$ tal que

$$\langle a, y \rangle + \beta t \leq \langle a, x \rangle + \beta f(x) \quad \text{para todo } (y, t) \in \text{epi } f. \quad (7.3)$$

Paso 2: $\beta \leq 0$. Fijemos $y = x$ y dejemos $t \rightarrow +\infty$ (los puntos (x, t) con $t \geq f(x)$ están todos en $\text{epi } f$: el epígrafo es “infinito hacia arriba”). Si fuera $\beta > 0$, el lado izquierdo de (7.3) tendería a $+\infty$, violando la cota. Luego $\beta \leq 0$.

Paso 3: $\beta \neq 0$ (aquí se usa la interioridad). Supongamos por contradicción que $\beta = 0$. Entonces (7.3) se reduce a $\langle a, y - x \rangle \leq 0$ para todo $y \in \text{dom } f$. Como $x \in \text{int}(\text{dom } f)$, existe $r > 0$ tal que $x + z \in \text{dom } f$ para todo $\|z\| \leq r$; tomando $y = x + \frac{r}{2} \frac{a}{\|a\|}$ (si $a \neq 0$) obtenemos $\frac{r}{2} \|a\| \leq 0$, absurdo. Luego $a = 0$, pero entonces $(a, \beta) = (0, 0)$, contradiciendo el teorema de soporte. Concluimos $\beta < 0$. Geométricamente: un hiperplano soporte *vertical* solo puede ocurrir en la frontera del dominio; en el interior, el hiperplano tiene que “inclinarse”.

Paso 4: construcción del subgradiente. Definamos $g = a/(-\beta)$ (bien definido pues $\beta < 0$). Dividiendo (7.3) entre $-\beta > 0$ y tomando $t = f(y)$ para $y \in \text{dom } f$:

$$\langle g, y \rangle - f(y) \leq \langle g, x \rangle - f(x),$$

que reordenada es $f(y) \geq f(x) + \langle g, y - x \rangle$ para todo $y \in \text{dom } f$; para $y \notin \text{dom } f$ la desigualdad es trivial porque $f(y) = +\infty$. Por lo tanto $g \in \partial f(x)$. $\square$

Cuidado (error común)

En la *frontera* del dominio el subdiferencial puede ser vacío aunque la función sea finita ahí. El ejemplo canónico: $f(x) = -\sqrt{x}$ para $x \geq 0$ y $f(x) = +\infty$ para $x < 0$. Es convexa y $f(0) = 0$ es finito, pero $\partial f(0) = \emptyset$: un subgradiente g en 0 debería cumplir $-\sqrt{y} \geq g y$ para todo $y > 0$, es decir $g \leq -1/\sqrt{y}$, y haciendo $y \rightarrow 0^+$ obtenemos $g \leq -\infty$, imposible. La “pendiente” en 0 es vertical y ningún hiperplano no vertical soporta al epígrafo ahí. Moraleja: los enunciados de este capítulo suelen pedir $x \in \text{int}(\text{dom } f)$ o alguna condición de calificación; no son adornos técnicos, son necesarios. Esta misma patología reaparecerá al estudiar dualidad y estabilidad.

Observación 7.9. En el interior del dominio se puede decir más: $\partial f(x)$ es además *acotado* (y por tanto compacto, al ser cerrado). La razón de fondo es que una función convexa es localmente Lipschitz en el interior de su dominio, y las pendientes de las minorantes afines exactas en x quedan controladas por la constante de Lipschitz local. Puedes ver [6], secciones 2.5–2.6, o [3] para los detalles.

El siguiente resultado cierra el círculo con el cap. 5: el subdiferencial *generaliza* al gradiente, no lo reemplaza.

Proposición 7.10 (Caso diferenciable). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa y diferenciable en $x \in \text{int}(\text{dom } f)$. Entonces*

$$\partial f(x) = \{\nabla f(x)\}.$$

Demostración. ($\supseteq$) La caracterización de primer orden del cap. 5 dice exactamente que $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ para todo y ; comparando con (7.2), esto es $\nabla f(x) \in \partial f(x)$.

($\subseteq$) Sea $g \in \partial f(x)$ y fijemos una dirección $d \in \mathbb{R}^n$ arbitraria. Aplicando (7.2) con $y = x + td$, $t > 0$ pequeño:

$$f(x + td) \geq f(x) + t \langle g, d \rangle \quad \implies \quad \frac{f(x + td) - f(x)}{t} \geq \langle g, d \rangle.$$

Haciendo $t \rightarrow 0^+$, la diferenciable da $\langle \nabla f(x), d \rangle \geq \langle g, d \rangle$, es decir $\langle \nabla f(x) - g, d \rangle \geq 0$. Como d es *arbitraria*, podemos tomar también $-d$, lo que da la desigualdad opuesta. Luego $\langle \nabla f(x) - g, d \rangle = 0$ para toda d ; eligiendo $d = \nabla f(x) - g$ obtenemos $\|\nabla f(x) - g\|^2 = 0$, es decir $g = \nabla f(x)$. $\square$

Vale también el recíproco: si $\partial f(x)$ consta de un solo punto en un punto interior, entonces f es diferenciable en x (puedes ver [6]). Así, “subdiferencial unipuntual” y “diferenciable” son sinónimos para funciones convexas en el interior del dominio.

7.4. Derivadas direccionales [P2]

Aunque una función convexa no tenga gradiente, siempre podemos preguntar por su tasa de cambio *en una dirección dada*, acercándonos por un solo lado.

Definición 7.11 (Derivada direccional). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa, $x \in \text{dom } f$ y $d \in \mathbb{R}^n$. La **derivada direccional** (*directional derivative*) de f en x en la dirección d es

$$f'(x; d) = \lim_{t \rightarrow 0^+} \frac{f(x + td) - f(x)}{t},$$

siempre que el límite exista en $\mathbb{R} \cup \{\pm\infty\}$.

Para funciones arbitrarias este límite puede no existir. Para funciones convexas, *siempre* existe, y la razón es una monotonía elemental pero poderosa del cociente incremental.

Lema 7.12 (Monotonía del cociente incremental). Sea f convexa, $x \in \text{dom } f$ y $d \in \mathbb{R}^n$. La función

$$t \mapsto \varphi(t) = \frac{f(x + td) - f(x)}{t}$$

es no decreciente en $t > 0$. En consecuencia, el límite de la Definición 7.11 existe y

$$f'(x; d) = \inf_{t > 0} \frac{f(x + td) - f(x)}{t} \in \mathbb{R} \cup \{\pm\infty\}.$$

Si $x \in \text{int}(\text{dom } f)$, el valor $f'(x; d)$ es finito para todo d .

Demostración. Sean $0 < s < t$. El punto $x + sd$ es una combinación convexa de x y de $x + td$: en efecto,

$$x + sd = \left(1 - \frac{s}{t}\right)x + \frac{s}{t}(x + td), \quad \frac{s}{t} \in (0, 1).$$

Aplicando la definición de convexidad de f a esta combinación:

$$f(x + sd) \leq \left(1 - \frac{s}{t}\right)f(x) + \frac{s}{t}f(x + td).$$

Restando $f(x)$ a ambos lados:

$$f(x + sd) - f(x) \leq \frac{s}{t}(f(x + td) - f(x)),$$

y dividiendo entre $s > 0$ obtenemos $\varphi(s) \leq \varphi(t)$: el cociente incremental crece con el paso. Una función no decreciente de t tiene límite cuando $t \rightarrow 0^+$, igual a su ínfimo sobre $t > 0$ (posiblemente $-\infty$). Finalmente, si x es interior, fijemos $t_0 > 0$ con $x - t_0d \in \text{dom } f$ y llamemos $\psi(t) = (f(x - td) - f(x))/t$, que por lo ya probado (con dirección $-d$) es no decreciente en $t > 0$. La convexidad de f en el segmento de $x - td$ a $x + td$ da $\varphi(t) \geq -\psi(t)$, y la monotonía de ψ da $-\psi(t) \geq -\psi(t_0)$ para $0 < t \leq t_0$. Luego $\varphi(t) \geq -\psi(t_0) > -\infty$ para todo t pequeño: el ínfimo es finito. $\square$

Intuición

La monotonía del cociente incremental es la propiedad de trabajo de las funciones convexas en una variable: “las cuerdas se empinan al alargarse”. De ella salen casi gratis la existencia de derivadas laterales, la monotonía de la derivada, y, como ahora veremos, el vínculo entre derivada direccional y subdiferencial. Cuando en Milgrom–Segal [11] aparecen derivadas laterales de la función de valor, es exactamente este lema el que garantiza su existencia.

El vínculo con el subdiferencial es una identidad elegante: la derivada direccional es la *función soporte* del subdiferencial (recuerda del cap. 5: la función soporte de un conjunto S es $\sigma_S(d) = \sup\{\langle g, d \rangle : g \in S\}$).

Teorema 7.13 (Fórmula del máximo). *Sea f convexa y $x \in \text{int}(\text{dom } f)$. Entonces, para todo $d \in \mathbb{R}^n$,*

$$f'(x; d) = \max\{\langle g, d \rangle : g \in \partial f(x)\},$$

y el máximo se alcanza.

Idea de la demostración. (Desigualdad $\geq$, fácil.) Si $g \in \partial f(x)$, la desigualdad de subgradiente con $y = x + td$ da $\frac{f(x+td)-f(x)}{t} \geq \langle g, d \rangle$ para todo $t > 0$; tomando el ínfimo en t (Lema 7.12), $f'(x; d) \geq \langle g, d \rangle$. Luego $f'(x; d) \geq \sup_{g \in \partial f(x)} \langle g, d \rangle$.

(Desigualdad $\leq$, la sustancia.) Se demuestra que la función $d \mapsto f'(x; d)$ es convexa y positivamente homogénea (hereda ambas cosas del Lema 7.12 y de la convexidad de f). A una función así se le puede aplicar el teorema de existencia (Teorema 7.8) en la dirección d fija: existe una minorante lineal $\langle g, \cdot \rangle$ de $f'(x; \cdot)$ exacta en d , y se verifica que tal g pertenece a $\partial f(x)$ (porque $f(y) - f(x) \geq f'(x; y-x) \geq \langle g, y-x \rangle$, donde la primera desigualdad es la monotonía del cociente con $t = 1$). Ese g alcanza el supremo, que resulta ser máximo. Los detalles completos están en [6], sección 2.5, y en [3]. $\square$

En particular, $\partial f(x)$ (convexo, cerrado y acotado en el interior) queda *completamente determinado* por las derivadas direccionales: dos descripciones del mismo objeto, una analítica y otra geométrica. En $\mathbb{R}$, la fórmula dice simplemente que $\partial f(x) = [f'(x; -1) \cdot (-1), f'(x; 1)] = [f'_-(x), f'_+(x)]$: el intervalo entre las derivadas laterales, confirmando el patrón de los Ejemplos 7.2 y 7.3.

7.5. La regla de Fermat generalizada [P3]

Llegamos al motivo por el que todo este aparato existe. En cálculo clásico, la condición necesaria de mínimo interior es $\nabla f(x^*) = 0$ (regla de Fermat), pero para funciones convexas no diferenciables esa condición ni siquiera se puede escribir. Su generalización correcta es de una elegancia notable: la demostración cabe en dos líneas porque la definición de subgradiente ya contiene toda la optimización global.

Teorema 7.14 (Regla de Fermat generalizada). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa y propia. Entonces $x^* \in \text{dom } f$ es un minimizador global de f si y solo si*

$$0 \in \partial f(x^*).$$

Demostración. Por definición, $0 \in \partial f(x^*)$ significa

$$f(y) \geq f(x^*) + \langle 0, y - x^* \rangle = f(x^*) \quad \text{para todo } y \in \mathbb{R}^n,$$

que es *literalmente* la afirmación de que x^* minimiza f sobre $\mathbb{R}^n$. $\square$

Detente un momento en lo que acaba de pasar. En cálculo clásico, $\nabla f(x^*) = 0$ es solo una condición *necesaria y local*, y hay que trabajar más (segundo orden, convexidad) para concluir algo global. Aquí la condición $0 \in \partial f(x^*)$ es necesaria *y suficiente*, y global, sin hipótesis adicionales: la convexidad ya está incorporada en la propia definición del subdiferencial. Además el enunciado no pide diferenciabilidad en ninguna parte. Toda la dificultad se traslada, claro, a *calcular* ∂f ; de eso se ocupa la siguiente sección.

Ejemplo 7.15 (Minimización con valor absoluto). Minimicemos en $\mathbb{R}$ la función

$$f(x) = |x - 1| + \frac{x^2}{2},$$

convexa por ser suma de convexas. Como $x^2/2$ es diferenciable en todo punto, el subdiferencial de la suma es la suma del gradiente y el subdiferencial (lo justificamos en la Sección 7.6; con un sumando diferenciable la regla vale sin condiciones adicionales):

$$\partial f(x) = x + \partial |\cdot - 1|(x) = \begin{cases} \{x - 1\} & \text{si } x < 1, \\ [1 - 1, 1 + 1] = [0, 2] & \text{si } x = 1, \\ \{x + 1\} & \text{si } x > 1. \end{cases}$$

Buscamos x^* con $0 \in \partial f(x^*)$, examinando los tres casos:

- *Caso* $x < 1$: necesitamos $x - 1 = 0$, es decir $x = 1$, que *no* pertenece a la región $x < 1$. Sin candidatos.
- *Caso* $x > 1$: necesitamos $x + 1 = 0$, es decir $x = -1$, que no pertenece a la región $x > 1$. Sin candidatos.
- *Caso* $x = 1$: necesitamos $0 \in [0, 2]$, lo cual es *cierto* (el 0 es el extremo izquierdo del intervalo).

Por la regla de Fermat generalizada, $x^* = 1$ es el minimizador global, con valor $f(1) = 1/2$. Observa el fenómeno típico: el mínimo ocurre *exactamente en el quiebre*, donde ninguna “derivada por casos” se anula, pero el intervalo de subgradiantes captura al cero. Si hubiéramos buscado ingenuamente puntos con $f'(x) = 0$ por regiones, habríamos concluido (erróneamente) que no hay mínimo.

Estrategia de examen

Receta para minimizar funciones convexas “por pedazos” en $\mathbb{R}$ (muy frecuente en exámenes y en modelos con tramos):

1. Identifica los puntos de quiebre y las regiones suaves entre ellos.
2. En cada región suave, calcula la derivada clásica y busca ceros *dentro de la región* (verifica siempre la pertenencia: un cero fuera de su región no vale).
3. En cada quiebre $\bar{x}$, calcula $\partial f(\bar{x}) = [f'_-(\bar{x}), f'_+(\bar{x})]$: el intervalo entre la derivada por la izquierda y por la derecha (para sumas: suma la parte suave a cada extremo).

4. El minimizador es el punto (región o quiebre) donde 0 cae en el subdiferencial. Por convexidad, cuando la derivada pasa de negativa a positiva, el cero queda atrapado ahí, y no hace falta comparar valores.

En $\mathbb{R}^n$ la lógica es idéntica pero el paso 3 usa las fórmulas de cálculo de la Sección 7.6 (suma, composición afín, máximo puntual).

7.6. Cálculo de subdiferenciales [P3]

Para que la regla de Fermat sea operativa necesitamos un “cálculo” de subdiferenciales análogo a las reglas de derivación: suma, composición y máximo. La regla de la suma es el resultado más famoso y más sutil.

Teorema 7.16 (Moreau–Rockafellar: subdiferencial de la suma). *Sean $f_1, f_2 : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexas y propias, y sea $x \in \text{dom } f_1 \cap \text{dom } f_2$.*

1. *Siempre vale la inclusión*

$$\partial f_1(x) + \partial f_2(x) \subseteq \partial(f_1 + f_2)(x),$$

donde la suma de conjuntos es $A + B = \{a + b : a \in A, b \in B\}$.

2. *Si además se cumple la **condición de calificación** (constraint qualification)*

$$\text{ri}(\text{dom } f_1) \cap \text{ri}(\text{dom } f_2) \neq \emptyset$$

(basta, por ejemplo, con que exista un punto de $\text{dom } f_2$ en el que f_1 sea finita y continua), entonces vale la igualdad:

$$\partial(f_1 + f_2)(x) = \partial f_1(x) + \partial f_2(x).$$

Demostración de la inclusión fácil (1). Sean $g_1 \in \partial f_1(x)$ y $g_2 \in \partial f_2(x)$. Para todo $y \in \mathbb{R}^n$ tenemos, por definición,

$$f_1(y) \geq f_1(x) + \langle g_1, y - x \rangle, \quad f_2(y) \geq f_2(x) + \langle g_2, y - x \rangle.$$

Sumando las dos desigualdades:

$$(f_1 + f_2)(y) \geq (f_1 + f_2)(x) + \langle g_1 + g_2, y - x \rangle,$$

que es exactamente la afirmación $g_1 + g_2 \in \partial(f_1 + f_2)(x)$. La demostración de la inclusión recíproca bajo la calificación es más profunda (requiere un argumento de separación entre epígrafos apropiados); puedes ver [6], sección 2.6, o [3]. $\square$

¿Por qué hace falta la condición de calificación? Porque la inclusión recíproca puede *fallar* cuando los dominios solo se tocan en la frontera, justo donde (recuerda la alerta) los subdiferenciales pueden esfumarse.

Ejemplo 7.17 (La igualdad puede fallar sin calificación). En $\mathbb{R}$, sean

$$f_1(x) = \begin{cases} -\sqrt{x} & x \geq 0 \\ +\infty & x < 0 \end{cases}, \quad f_2(x) = \delta_{(-\infty, 0]}(x).$$

Ambas son convexas y $\text{dom } f_1 \cap \text{dom } f_2 = \{0\}$: los dominios $[0, +\infty)$ y $(-\infty, 0]$ se tocan solo en la frontera común, así que $\text{ri}(\text{dom } f_1) \cap \text{ri}(\text{dom } f_2) = (0, \infty) \cap (-\infty, 0) = \emptyset$ y la calificación falla. Ahora bien, $f_1 + f_2 = \delta_{\{0\}}$ (vale 0 en $x = 0$ e $+\infty$ en el resto), de modo que, por el Ejemplo 7.6,

$$\partial(f_1 + f_2)(0) = N_{\{0\}}(0) = \mathbb{R}.$$

Pero $\partial f_1(0) = \emptyset$ (pendiente vertical, como vimos en la alerta), así que, aunque $\partial f_2(0) = N_{(-\infty, 0]}(0) = [0, +\infty)$, la suma de conjuntos con un sumando vacío es vacía: $\partial f_1(0) + \partial f_2(0) = \emptyset$. La inclusión fácil $\emptyset \subseteq \mathbb{R}$ se cumple, pero la igualdad falla estrepitosamente: el subdiferencial de la suma es todo $\mathbb{R}$ y la suma de subdiferenciales es vacía. La calificación de Moreau–Rockafellar impide exactamente este tipo de colapso fronterizo.

Observación 7.18. Un caso especial utilísimo: si f_2 es convexa y *diferenciable* en todo $\mathbb{R}^n$ (dominio completo), la calificación se cumple automáticamente y

$$\partial(f_1 + f_2)(x) = \partial f_1(x) + \{\nabla f_2(x)\} = \partial f_1(x) + \nabla f_2(x).$$

Esta es la regla que usamos en el Ejemplo 7.15: sumar la parte suave “desplaza” el subdiferencial de la parte no suave.

Proposición 7.19 (Composición afín). Sea $f : \mathbb{R}^m \rightarrow \mathbb{R}$ convexa y finita, A una matriz $m \times n$ y $b \in \mathbb{R}^m$. Entonces $h(x) = f(Ax + b)$ es convexa y

$$\partial h(x) = A^\top \partial f(Ax + b) = \{A^\top g : g \in \partial f(Ax + b)\}.$$

La inclusión $\supseteq$ es de nuevo directa desde la definición: si $g \in \partial f(Ax + b)$, entonces para todo y ,

$$h(y) = f(Ay + b) \geq f(Ax + b) + \langle g, Ay - Ax \rangle = h(x) + \langle A^\top g, y - x \rangle,$$

usando la identidad $\langle g, Az \rangle = \langle A^\top g, z \rangle$ (definición de traspuesta). La igualdad requiere, como siempre, una condición de calificación que aquí se cumple por ser f finita en todo $\mathbb{R}^m$. Esta regla es la que hace tratable la regresión LAD: $\beta \mapsto |y_i - x_i^\top \beta|$ es la composición del valor absoluto con una función afín de β .

Teorema 7.20 (Máximo puntual de funciones suaves). Sean $f_1, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$ convexas y diferenciables, y $f(x) = \max\{f_1(x), \dots, f_m(x)\}$. Definamos el **conjunto activo** (active set) en x :

$$I(x) = \{i \in \{1, \dots, m\} : f_i(x) = f(x)\}.$$

Entonces

$$\partial f(x) = \text{conv}\{\nabla f_i(x) : i \in I(x)\} :$$

el subdiferencial es la cápsula convexa de los gradientes de las funciones activas (las que alcanzan el máximo en x). En particular, si solo una es activa, f es diferenciable en x con $\nabla f(x) = \nabla f_i(x)$.

La inclusión $\supseteq$ se demuestra igual que en el Ejemplo 7.3: cada $\nabla f_i(x)$ con i activo es subgradiente porque $f \geq f_i$ con igualdad en x (así $f(y) \geq f_i(y) \geq f_i(x) + \langle \nabla f_i(x), y - x \rangle = f(x) + \langle \nabla f_i(x), y - x \rangle$), y $\partial f(x)$ es convexo (Proposición 7.7), de modo que contiene a la cápsula convexa. La inclusión $\subseteq$ usa la fórmula del máximo (Teorema 7.13); puedes ver [6] o [2], donde esta fórmula es la base de los métodos de haces y del análisis de funciones máx.

Ejemplo 7.21 (Cálculo con la fórmula del máximo). Sea $f(x) = \max\{x^2, x\}$ en $\mathbb{R}$. Las dos piezas empatan cuando $x^2 = x$, es decir en $x = 0$ y $x = 1$; entre ellas ($0 < x < 1$) gana x , y fuera gana x^2 . Entonces:

- Si $x < 0$ o $x > 1$: activa solo x^2 , así que $\partial f(x) = \{2x\}$.
- Si $0 < x < 1$: activa solo x , así que $\partial f(x) = \{1\}$.
- En $x = 0$: activas ambas, con gradientes $2 \cdot 0 = 0$ y 1 ; luego $\partial f(0) = \text{conv}\{0, 1\} = [0, 1]$.
- En $x = 1$: activas ambas, con gradientes $2 \cdot 1 = 2$ y 1 ; luego $\partial f(1) = \text{conv}\{2, 1\} = [1, 2]$.

De paso, la regla de Fermat: $0 \in \partial f(x)$ ocurre en $x = 0$ (pues $0 \in [0, 1]$), y en ningún otro punto; el minimizador global es $x^* = 0$ con $f(0) = 0$.

7.7. Aplicaciones económicas [P3]

Función de gasto y demanda hicksiana: el lema de Shephard general

Recordemos el problema de minimización del gasto del consumidor: dados precios $p \in \mathbb{R}_{++}^n$ y un nivel de utilidad u ,

$$e(p, u) = \min\{ \langle p, x \rangle : u(x) \geq u, x \geq 0 \},$$

con conjunto de soluciones $h(p, u)$ (la **demanda hicksiana** o compensada). Un resultado del cap. 5 (mínimo de funciones lineales en p , indexadas por x factible) es que $p \mapsto e(p, u)$ es cóncava y positivamente homogénea de grado 1.

Como $e(\cdot, u)$ es cóncava, el objeto natural es el *superdiferencial*: g es un **supergradiente** de una función cóncava ϕ en p si $\phi(q) \leq \phi(p) + \langle g, q - p \rangle$ para todo q (las desigualdades se invierten; equivalentemente, g es supergradiente de ϕ si y solo si $-g$ es subgradiente de la función convexa $-\phi$). Toda la teoría de este capítulo se traduce sin cambios, espejo mediante.

Teorema 7.22 (Lema de Shephard, versión general). *Fijemos u y supongamos $e(\cdot, u)$ finita en un entorno de $p \in \mathbb{R}_{++}^n$. Entonces la demanda hicksiana es exactamente el superdiferencial de la función de gasto:*

$$h(p, u) = \partial_p e(p, u) \quad (\text{superdiferencial en } p).$$

En particular, $e(\cdot, u)$ es diferenciable en p si y solo si la demanda hicksiana es única en p , y en ese caso $h(p, u) = \{\nabla_p e(p, u)\}$, que es el enunciado clásico del lema de Shephard [9, 10].

Idea de la demostración (inclusión principal). Sea $x^* \in h(p, u)$: canasta óptima a precios p , con $e(p, u) = \langle p, x^* \rangle$. Para cualquier otro vector de precios q , la canasta x^* sigue siendo *factible* (alcanza la utilidad u ; la factibilidad no depende de los precios), aunque quizá ya no óptima. Por lo tanto

$$e(q, u) \leq \langle q, x^* \rangle = \langle p, x^* \rangle + \langle x^*, q - p \rangle = e(p, u) + \langle x^*, q - p \rangle,$$

que es exactamente la desigualdad de supergradiente: $x^* \in \partial_p e(p, u)$. El argumento es puro “sobre-presupuesto”: a precios nuevos, comprar la canasta vieja cuesta $\langle q, x^* \rangle$ y eso acota el gasto mínimo por arriba. La inclusión recíproca (todo supergradiente es una demanda óptima) usa la homogeneidad y la estructura del problema; puedes ver [9] (cap. 3) y, para el argumento de envolvente general, [11]. $\square$

Ejemplo 7.23 (Sustitutos perfectos: quiebre y demanda múltiple). Sea $u(x_1, x_2) = x_1 + x_2$ (sustitutos perfectos). El consumidor compra solo el bien más barato, así que

$$e(p, u) = u \cdot \min\{p_1, p_2\},$$

cóncava en p (mínimo de dos lineales) y con un *quiebre* en la diagonal $p_1 = p_2$. Calculemos el superdiferencial en un punto de quiebre $p_1 = p_2 = \bar{p}$ usando (la versión cóncava de) el Teorema 7.20: las dos piezas lineales $u p_1$ y $u p_2$ están activas, con gradientes $(u, 0)$ y $(0, u)$, de modo que

$$\partial_p e(\bar{p}, \bar{p}, u) = \text{conv}\{(u, 0), (0, u)\} = \{(\lambda u, (1 - \lambda)u) : \lambda \in [0, 1]\}.$$

Y en efecto, cuando $p_1 = p_2$ el consumidor es indiferente entre todas las canastas con $x_1 + x_2 = u$: la demanda hicksiana es exactamente el segmento $\{(\lambda u, (1 - \lambda)u) : \lambda \in [0, 1]\}$. El Teorema 7.22 se verifica al pie de la letra: *el conjunto de demandas es el superdiferencial en el quiebre*. Fuera de la diagonal, la demanda es única (todo al bien barato) y e es diferenciable: $\nabla_p e = (u, 0)$ si $p_1 < p_2$, confirmando el Shephard clásico.

Lo mismo ocurre, palabra por palabra, con la función de costo de la firma $c(w, y) = \min\{\langle w, z \rangle : F(z) \geq y\}$ (w precios de insumos): es cóncava en w , las demandas condicionadas de factores son su superdiferencial, y cuando hay tecnologías con insumos sustituibles linealmente aparecen quiebres con demandas múltiples. Y con la función de beneficio $\pi(p)$ (convexa en p): el lema de Hotelling general dice que la oferta neta es $\partial \pi(p)$.

Otras dos apariciones que verás pronto

Contratos y mecanismos. En un mecanismo directo, la utilidad de equilibrio de un agente de tipo θ es $U(\theta) = \max_{\hat{\theta}} [\text{asignación lineal en } \hat{\theta}]$: un máximo de funciones afines de θ , luego convexa y típicamente con quiebres donde el agente es indiferente entre dos reportes. El teorema de la envolvente de Milgrom–Segal [11] caracteriza U mediante sus derivadas laterales, que existen por el Lema 7.12, y la condición de monotonía de la asignación es precisamente la monotonía de las pendientes (los subgradientes) de U .

Econometría: LAD y regresión cuantílica. El estimador de mínimas desviaciones absolutas (*least absolute deviations*) resuelve

$$\min_{\beta \in \mathbb{R}^k} \sum_{i=1}^N |y_i - x_i^\top \beta|,$$

una función convexa no diferenciable (suma de composiciones afines de $|\cdot|$, Proposición 7.19). Sus condiciones de optimalidad son $0 \in \partial(\cdot)$, no un sistema de ecuaciones: por eso la mediana (caso $k = 1$ con $x_i = 1$) puede ser un *intervalo* de soluciones, y por eso la regresión cuantílica se estudia con las herramientas de este capítulo (mira el Ejercicio 7.28).

7.8. Resumen y ejercicios [P3]

Resumen del capítulo

- **Subgradiente:** $g \in \partial f(x)$ si $f(y) \geq f(x) + \langle g, y - x \rangle$ para todo y : la pendiente de una minorante afín exacta en x ; geométricamente, un hiperplano soporte no vertical del epígrafo en $(x, f(x))$.
- **Ejemplos base:** $\partial|x|(0) = [-1, 1]$; $\partial\|\cdot\|(0) = \bar{B}(0, 1)$; $\partial\delta_C(x) = N_C(x)$ (cono normal); en un quiebre de máx de afines, la cápsula convexa de las pendientes activas.
- **Propiedades:** $\partial f(x)$ es siempre convexo y cerrado; es no vacío (y compacto) si $x \in \text{int}(\text{dom } f)$, vía hiperplano soporte al epígrafo; puede ser vacío en la frontera (pendiente vertical). Si f es diferenciable en x , $\partial f(x) = \{\nabla f(x)\}$.
- **Derivada direccional:** para convexas siempre existe ($\varphi(t)$ monótona) y $f'(x; d) = \max\{\langle g, d \rangle : g \in \partial f(x)\}$: la función soporte del subdiferencial. En $\mathbb{R}$: $\partial f(x) = [f'_-(x), f'_+(x)]$.
- **Fermat generalizado:** x^* minimiza f (globalmente) si y solo si $0 \in \partial f(x^*)$. Necesario, suficiente, sin diferenciabilidad.
- **Cálculo:** $\partial(f_1 + f_2) = \partial f_1 + \partial f_2$ bajo la calificación $\text{ri}(\text{dom } f_1) \cap \text{ri}(\text{dom } f_2) \neq \emptyset$ (Moreau–Rockafellar; la inclusión $\supseteq$ es siempre cierta y gratis); $\partial f(A \cdot + b)(x) = A^\top \partial f(Ax + b)$; $\partial \max_i f_i(x) = \text{conv}\{\nabla f_i(x) : i \text{ activo}\}$.
- **Economía:** demanda hicksiana = superdiferencial de la función de gasto (Shephard general); oferta = subdiferencial del beneficio (Hotelling general); utilidades de agentes en mecanismos son máx de afines y se analizan con derivadas laterales (Milgrom–Segal); LAD/cuantílica en econometría.

Referencias: [6] (secs. 2.5–2.6), [3], [1], [2]; para las aplicaciones, [9], [10], [11].

Ejercicio 7.24. Sea $f(x) = |x| + |x - 1|$ en $\mathbb{R}$. Calcula $\partial f(x)$ en todos los puntos y encuentra *todos* los minimizadores globales de f .

Solución. Escribimos $f = f_1 + f_2$ con $f_1 = |\cdot|$ y $f_2 = |\cdot - 1|$; ambas son finitas en todo $\mathbb{R}$, así que

Moreau–Rockafellar aplica con igualdad (la calificación es automática: $\text{ri}(\text{dom } f_1) \cap \text{ri}(\text{dom } f_2) = \mathbb{R}$). Usando $\partial|\cdot|$ del Ejemplo 7.2 (trasladado para f_2):

$$\partial f(x) = \begin{cases} \{-1\} + \{-1\} = \{-2\} & x < 0, \\ [-1, 1] + \{-1\} = [-2, 0] & x = 0, \\ \{1\} + \{-1\} = \{0\} & 0 < x < 1, \\ \{1\} + [-1, 1] = [0, 2] & x = 1, \\ \{1\} + \{1\} = \{2\} & x > 1. \end{cases}$$

Buscamos $0 \in \partial f(x)$: falla para $x < 0$ y $x > 1$; se cumple en $x = 0$ (pues $0 \in [-2, 0]$), en todo $x \in (0, 1)$ (pues $\partial f(x) = \{0\}$) y en $x = 1$ (pues $0 \in [0, 2]$). Por Fermat generalizado, el conjunto de minimizadores es *todo el intervalo* $[0, 1]$, con valor óptimo $f(x) = 1$ en él. (Comprobación directa: entre 0 y 1, $|x| + |x - 1| = x + (1 - x) = 1$; fuera, la suma crece.) Este es el fenómeno de “mediana”: con dos puntos, cualquier punto entre ellos minimiza la suma de distancias. $\square$

Ejercicio 7.25. Sea $f(x_1, x_2) = |x_1| + |x_2|$ (la norma $\|\cdot\|_1$ en $\mathbb{R}^2$). Demuestra desde la definición que $\partial f(0, 0) = [-1, 1] \times [-1, 1]$, y calcula $\partial f(3, 0)$.

Solución. $g = (g_1, g_2) \in \partial f(0, 0)$ si y solo si

$$|y_1| + |y_2| \geq g_1 y_1 + g_2 y_2 \quad \forall (y_1, y_2) \in \mathbb{R}^2.$$

(Necesidad.) Tomando $y = (\pm 1, 0)$ obtenemos $1 \geq \pm g_1$, es decir $|g_1| \leq 1$; tomando $y = (0, \pm 1)$, $|g_2| \leq 1$. Luego $g \in [-1, 1]^2$. (Suficiencia.) Si $|g_1| \leq 1$ y $|g_2| \leq 1$, entonces $g_1 y_1 + g_2 y_2 \leq |g_1||y_1| + |g_2||y_2| \leq |y_1| + |y_2|$ para todo y . Concluimos $\partial f(0, 0) = [-1, 1]^2$ (el “cuadrado unitario”, que es la bola unitaria de la norma dual $\|\cdot\|_\infty$: un patrón general para normas).

Para $(3, 0)$: la primera coordenada está en zona suave ($\partial|\cdot|(3) = \{1\}$) y la segunda en el quiebre ($\partial|\cdot|(0) = [-1, 1]$). Como f es una suma separable de funciones de cada coordenada (finitas en todo $\mathbb{R}$), Moreau–Rockafellar da

$$\partial f(3, 0) = \{1\} \times [-1, 1],$$

un segmento vertical: unipuntual en la coordenada suave, intervalo en la quebrada. $\square$

Ejercicio 7.26. Sea $f(x) = e^{|x|}$ en $\mathbb{R}$. (a) Justifica que f es convexa. (b) Calcula $\partial f(0)$. (c) Encuentra el minimizador global.

Solución. (a) $f = \phi \circ |\cdot|$ donde $\phi(t) = e^t$ es convexa y *no decreciente* en $[0, \infty)$ y $|\cdot|$ es convexa; la composición de una convexa no decreciente con una convexa es convexa (regla de composición del cap. 5).

(b) Como f es suave en $x \neq 0$, en $\mathbb{R}$ basta el patrón $\partial f(0) = [f'_-(0), f'_+(0)]$ (Teorema 7.13 en una variable). Para $x > 0$, $f(x) = e^x$ y $f'(x) = e^x \rightarrow 1$ cuando $x \rightarrow 0^+$, así que $f'_+(0) = 1$; para $x < 0$, $f(x) = e^{-x}$ y $f'(x) = -e^{-x} \rightarrow -1$, así que $f'_-(0) = -1$. Por lo tanto $\partial f(0) = [-1, 1]$.

Verificación desde la definición (necesidad): si $e^{|y|} \geq 1 + gy$ para todo y , con $y = t > 0$ pequeño, $g \leq (e^t - 1)/t \rightarrow 1$; con $y = -t$, $g \geq -(e^t - 1)/t \rightarrow -1$. (Suficiencia): si $|g| \leq 1$,

entonces $1 + gy \leq 1 + |y| \leq e^{|y|}$, usando la desigualdad clásica $1 + u \leq e^u$ con $u = |y| \geq 0$.

(c) $0 \in \partial f(x)$: para $x \neq 0$ el subgradiente único es $\pm e^{|x|} \neq 0$; en $x = 0$, $0 \in [-1, 1]$. Por Fermat generalizado, el minimizador global es $x^* = 0$, con $f(0) = 1$. $\square$

Ejercicio 7.27. Verifica en detalle la afirmación del Ejemplo 7.17: para $f(x) = -\sqrt{x}$ si $x \geq 0$ (y $+\infty$ si $x < 0$), se tiene $\partial f(0) = \emptyset$, mientras que $\partial f(x) = \{-1/(2\sqrt{x})\}$ para $x > 0$. ¿Contradice esto el Teorema 7.8?

Solución. En $x = 0$: $g \in \partial f(0)$ exigiría $-\sqrt{y} \geq 0 + g(y - 0)$ para todo $y \geq 0$ (para $y < 0$ es trivial). Con $y > 0$, dividiendo entre y : $g \leq -\sqrt{y}/y = -1/\sqrt{y}$. Haciendo $y \rightarrow 0^+$, el lado derecho tiende a $-\infty$, y ningún número real g satisface $g \leq -\infty$. Luego $\partial f(0) = \emptyset$.

En $x > 0$: f es diferenciable ahí con $f'(x) = -1/(2\sqrt{x})$, y f es convexa en su dominio (su segunda derivada $\frac{1}{4}x^{-3/2}$ es positiva); por la Proposición 7.10, $\partial f(x) = \{-1/(2\sqrt{x})\}$.

No hay contradicción con el Teorema 7.8: este garantiza no vacuidad solo en $\text{int}(\text{dom } f) = (0, \infty)$, y 0 es un punto de *frontera* del dominio. El ejemplo muestra que la hipótesis de interioridad es indispensable: en 0 el único candidato a hiperplano soporte del epígrafo es vertical, y los hiperplanos verticales no definen subgradientes. $\square$

Ejercicio 7.28. (Mediana como estimador LAD.) Sean $a_1 < a_2 < a_3$ números reales y

$$f(x) = |x - a_1| + |x - a_2| + |x - a_3|.$$

Usando subdiferenciales y la regla de Fermat generalizada, demuestra que el único minimizador global es la mediana $x^* = a_2$.

Solución. Cada sumando es finito en todo $\mathbb{R}$, así que $\partial f(x) = \sum_{i=1}^3 \partial|\cdot - a_i|(x)$ (Moreau–Rockafellar con calificación automática), donde cada $\partial|\cdot - a_i|(x)$ vale $\{-1\}$ si $x < a_i$, $[-1, 1]$ si $x = a_i$ y $\{+1\}$ si $x > a_i$. Recorramos la recta:

$$\partial f(x) = \begin{cases} \{-3\} & x < a_1, \\ [-3, -1] & x = a_1, \\ \{-1\} & a_1 < x < a_2, \\ [-1, 1] & x = a_2, \\ \{1\} & a_2 < x < a_3, \\ [1, 3] & x = a_3, \\ \{3\} & x > a_3. \end{cases}$$

(Por ejemplo, en $x = a_1$: $[-1, 1] + \{-1\} + \{-1\} = [-3, -1]$; en $a_1 < x < a_2$: $\{1\} + \{-1\} + \{-1\} = \{-1\}$; en $x = a_2$: $\{1\} + [-1, 1] + \{-1\} = [-1, 1]$.) El único punto donde $0 \in \partial f(x)$ es $x = a_2$, pues $0 \in [-1, 1]$ y en ningún otro caso el conjunto contiene al cero. Por Fermat generalizado, $x^* = a_2$ es el único minimizador global.

Lectura econométrica: este es el caso más simple de regresión LAD (regresión solo con intercepto): el estimador es la mediana muestral. Con un número par de observaciones, el mismo cálculo produce un *intervalo* de minimizadores (como en el Ejercicio 7.24): la “mediana” del

estadístico elemental es en realidad un subdiferencial que atrapa al cero en todo un tramo. La regresión cuantílica reemplaza $|u|$ por la función de pérdida asimétrica $\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\})$, también convexa y no diferenciable, y se analiza igual. $\square$

Ejercicio 7.29. (Shephard con quiebre.) Un consumidor tiene utilidad $u(x_1, x_2) = x_1 + 2x_2$ y quiere alcanzar $u = 6$. (a) Calcula la función de gasto $e(p_1, p_2, 6)$. (b) Determina en qué precios e no es diferenciable. (c) En $p = (2, 4)$, calcula el superdiferencial $\partial_p e(p, 6)$ y verifica que coincide con el conjunto de demandas hicksianas.

Solución. (a) Con utilidad lineal $x_1 + 2x_2 \geq 6$, el consumidor compra un solo bien: si compra solo bien 1 necesita $x_1 = 6$ (costo $6p_1$); si compra solo bien 2 necesita $x_2 = 3$ (costo $3p_2$). Elige lo más barato y no hay combinación interior que mejore ambas esquinas (la restricción y el objetivo son lineales, el mínimo está en un vértice):

$$e(p, 6) = \min\{6p_1, 3p_2\}.$$

(b) e es un mínimo de dos funciones lineales de p : cóncava, y no diferenciable exactamente donde ambas piezas empatan, $6p_1 = 3p_2$, es decir sobre el rayo $p_2 = 2p_1$. (Es el locus de precios donde el precio *por unidad de utilidad* es igual entre bienes: $p_1/1 = p_2/2$.)

(c) En $p = (2, 4)$ estamos justo en el quiebre ($6 \cdot 2 = 12 = 3 \cdot 4$). Las piezas activas son $6p_1$ y $3p_2$, con gradientes $(6, 0)$ y $(0, 3)$. Por la versión cóncava del Teorema 7.20,

$$\partial_p e(p, 6) = \text{conv}\{(6, 0), (0, 3)\} = \{(6\lambda, 3(1 - \lambda)) : \lambda \in [0, 1]\}.$$

Demandas hicksianas en $p = (2, 4)$: cualquier canasta sobre la recta $x_1 + 2x_2 = 6$ con $x_1 \in [0, 6]$ cuesta $2x_1 + 4x_2 = 2x_1 + 2(6 - x_1) = 12$: ¡todas cuestan lo mismo! El conjunto de soluciones es $\{(x_1, x_2) : x_1 + 2x_2 = 6, x_1, x_2 \geq 0\} = \{(6\lambda, 3(1 - \lambda)) : \lambda \in [0, 1]\}$, exactamente el superdiferencial calculado. El lema de Shephard general (Teorema 7.22) se cumple: en el quiebre de la función de gasto vive, como conjunto, toda la indeterminación de la demanda. $\square$

Capítulo 8

Optimización sin restricciones: condiciones de optimalidad, proyección y distancia [P2]

Semanas 5–6 del cronograma. Bibliografía: Nocedal y Wright [5]; Ruszczyński [6]; Aragón et al. [1].

¿Para qué sirve esto en Microeconomía?

Este capítulo es, probablemente, el que más veces usarás sin darte cuenta en Microeconomía. Las *condiciones de primer y segundo orden* son el pan de cada día del curso:

- **Teoría de la firma (MWG cap. 5):** el problema de maximización de beneficios $\max_z pf(z) - w^\top z$ se resuelve igualando el gradiente a cero y verificando concavidad. Veremos además por qué con retornos crecientes a escala el máximo puede *no existir* [9].
- **Juegos y subastas (MWG caps. 7–9 y 23):** la *mejor respuesta* de Cournot se obtiene de una condición de primer orden (FOC), y en subastas la puja óptima de cada postor resuelve una FOC; el equilibrio es un sistema de FOCs [10].
- **Riesgo moral y principal–agente (MWG cap. 14):** el *enfoque de primer orden* (*first-order approach*, Rogerson 1985) reemplaza la restricción de compatibilidad de incentivos del agente por su FOC; su validez depende exactamente de las condiciones de este capítulo (que la FOC caracterice el óptimo global del agente) [11].
- **El puente clave:** la convexidad (concavidad, para maximización) convierte condiciones *locales* en *globales*. Eso es lo que justifica la frase, repetida mil veces en micro, “resolvemos la condición de primer orden”.
- **Proyección:** la proyección sobre un convexo cerrado aparece en demostraciones del segundo teorema del bienestar (vía separación, como vimos en el capítulo de separación) y en econometría: el estimador de mínimos cuadrados ordinarios (MCO) es una proyección ortogonal.

En los capítulos anteriores construimos el lenguaje (conjuntos y funciones convexas, separación, subdiferencial). Ahora lo usamos para responder la pregunta central de todo el curso: dado un problema

$$\min_{x \in \mathbb{R}^n} f(x),$$

¿cómo sabemos si tiene solución?, ¿cómo encontramos los candidatos a solución?, y ¿cómo certificamos que un candidato es realmente un mínimo? Seguimos principalmente a [1] (capítulo 3), [5] (capítulo 2) y [7] (capítulo 1).

8.1. Planteamiento del problema y existencia de soluciones [P2]

8.1.1. Mínimos locales y globales

Definición 8.1 (Mínimo global, local y estricto). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y sea $x^* \in \mathbb{R}^n$.

(a) x^* es un **mínimo global** (*global minimizer*) de f si

$$f(x^*) \leq f(x) \quad \text{para todo } x \in \mathbb{R}^n.$$

(b) x^* es un **mínimo local** (*local minimizer*) de f si existe $\varepsilon > 0$ tal que

$$f(x^*) \leq f(x) \quad \text{para todo } x \text{ con } \|x - x^*\| < \varepsilon.$$

Es decir, x^* gana la comparación solo contra sus *vecinos cercanos*.

(c) El mínimo (global o local) es **estricto** (*strict*) si la desigualdad es estricta, $f(x^*) < f(x)$, para todo $x \neq x^*$ en el conjunto correspondiente.

El valor $f(x^*)$ se llama *valor mínimo*, y el conjunto de todos los mínimos globales se denota $\arg \min_x f(x)$.

Observación 8.2 (Maximizar es minimizar). Todo lo que digamos para mínimos se traduce a máximos cambiando f por $-f$: x^* maximiza f si y solo si minimiza $-f$, y $\max_x f(x) = -\min_x (-f(x))$. Además, f es cóncava si y solo si $-f$ es convexa. Por eso en micro (donde maximizamos utilidades y beneficios, funciones cóncavas) y en optimización (donde por convención se minimiza) se demuestran *los mismos teoremas*. En este capítulo minimizamos; traduce tú mentalmente: “Hessiana definida positiva en un mínimo” $\leftrightarrow$ “Hessiana definida negativa en un máximo”.

Ejemplo 8.3. En $\mathbb{R}$: (i) $f(x) = x^2$ tiene un único mínimo global estricto en $x^* = 0$. (ii) $f(x) = e^x$ no tiene mínimo: $\inf_x e^x = 0$ pero ningún x alcanza ese valor (el ínfimo no se *alcanza*). (iii) $f(x) = x^3$ no tiene mínimo local ni global ($f(x) \rightarrow -\infty$). (iv) $f(x) = (x^2 - 1)^2$ tiene dos mínimos globales, en $x = 1$ y $x = -1$ (el mínimo global no es único, aunque cada uno de los dos es un mínimo local estricto), y un máximo local en $x = 0$.

El ejemplo (ii) muestra que la primera pregunta seria es la de *existencia*: antes de derivar e igualar a cero, hay que saber que hay algo que encontrar.

8.1.2. Existencia: Weierstrass y coercividad

Recordemos el teorema clásico de análisis (lo usamos ya en el capítulo de preliminares):

Teorema 8.4 (Weierstrass). *Si $K \subseteq \mathbb{R}^n$ es no vacío, cerrado y acotado (es decir, compacto) y $f : K \rightarrow \mathbb{R}$ es continua, entonces f alcanza su mínimo y su máximo en K : existen $x^*, x^{**} \in K$ tales que $f(x^*) \leq f(x) \leq f(x^{**})$ para todo $x \in K$.*

El problema es que en optimización sin restricciones el dominio es todo $\mathbb{R}^n$, que no es acotado, así que Weierstrass no se aplica directamente. La salida es una condición sobre f que “recree” la compacidad: exigir que la función crezca hacia infinito en todas las direcciones, de modo que la búsqueda del mínimo pueda confinarse a una región acotada.

Definición 8.5 (Función coerciva). Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es **coerciva** (*coercive*) si

$$\lim_{\|x\| \rightarrow \infty} f(x) = +\infty,$$

es decir: para todo $M \in \mathbb{R}$ existe $R > 0$ tal que $f(x) > M$ siempre que $\|x\| > R$. Equivalentemente, para toda sucesión (x_k) con $\|x_k\| \rightarrow \infty$ se cumple $f(x_k) \rightarrow +\infty$.

Ejemplo 8.6. (i) $f(x) = \|x\|^2$ es coerciva. (ii) $f(x) = e^x$ en $\mathbb{R}$ no es coerciva: cuando $x \rightarrow -\infty$, $|x| \rightarrow \infty$ pero $f(x) \rightarrow 0$. (iii) $f(x, y) = x^2$ en $\mathbb{R}^2$ no es coerciva: a lo largo de la sucesión $(0, k)$ la norma explota pero f vale siempre 0. La coercividad exige crecer *en todas las direcciones*, no solo en algunas. (iv) $f(x, y) = x^4 + y^4 - 3xy$ es coerciva (lo demostraremos en el Ejercicio 8.37): los términos de cuarto grado dominan al término cruzado.

Teorema 8.7 (Existencia bajo coercividad). *Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es continua y coerciva, entonces f alcanza un mínimo global en $\mathbb{R}^n$: el conjunto $\arg \min_x f(x)$ es no vacío (y compacto).*

Demostración. La idea es reducir el problema a un compacto y aplicar Weierstrass.

Paso 1: confinar la búsqueda. Fijemos cualquier punto $x_0 \in \mathbb{R}^n$ (por ejemplo $x_0 = 0$) y consideremos el conjunto de subnivel

$$S = \{x \in \mathbb{R}^n : f(x) \leq f(x_0)\}.$$

S es no vacío porque $x_0 \in S$.

Paso 2: S es cerrado. S es la preimagen del intervalo cerrado $(-\infty, f(x_0)]$ bajo la función continua f , y la preimagen de un cerrado bajo una función continua es cerrada.

Paso 3: S es acotado. Supongamos que no. Entonces existiría una sucesión $(x_k) \subseteq S$ con $\|x_k\| \rightarrow \infty$. Por coercividad, $f(x_k) \rightarrow +\infty$. Pero cada x_k está en S , así que $f(x_k) \leq f(x_0)$ para todo k , lo que impide que $f(x_k)$ diverja. Contradicción. Luego S es acotado.

Paso 4: Weierstrass. S es no vacío, cerrado y acotado, es decir, compacto, y f es continua sobre S . Por el Teorema 8.4, existe $x^* \in S$ con $f(x^*) \leq f(x)$ para todo $x \in S$.

Paso 5: el mínimo sobre S es global. Sea $x \in \mathbb{R}^n$ arbitrario. Si $x \in S$, ya sabemos $f(x^*) \leq f(x)$. Si $x \notin S$, entonces $f(x) > f(x_0) \geq f(x^*)$ (la última desigualdad porque $x_0 \in S$). En ambos casos $f(x^*) \leq f(x)$, así que x^* es mínimo global. Finalmente, $\arg \min f = \{x : f(x) \leq f(x^*)\}$ es cerrado y acotado por los mismos argumentos de los pasos 2 y 3, luego compacto. $\square$

Intuición

La coercividad es una “muralla al infinito”: como la función sube sin tope lejos del origen, ningún candidato a mínimo puede escaparse hacia afuera, y todo ocurre dentro de una bola. Dentro de la bola manda Weierstrass. Nota la división de trabajo: *continuidad* garantiza que el ínfimo se alcanza en compactos; *coercividad* garantiza que podemos trabajar en un compacto. Sin la primera falla el ejemplo de una función con un “hueco” en el punto bueno; sin la segunda falla e^x , cuyo ínfimo se escapa hacia el borde infinito del dominio (cuando $x \rightarrow -\infty$) y nunca se alcanza.

Ejemplo 8.8 (Por qué el beneficio de la firma puede no alcanzar máximo). Considera una firma competitiva con un insumo, tecnología $f(z) = z^\alpha$ con $\alpha > 0$, precio del producto $p > 0$ y precio del insumo $w > 0$. Su beneficio es

$$\pi(z) = pz^\alpha - wz, \quad z \geq 0.$$

Maximizar π equivale a minimizar $-\pi(z) = wz - pz^\alpha$.

- **Retornos decrecientes** ($\alpha < 1$): $-\pi$ es coerciva en $[0, \infty)$, pues wz crece linealmente y pz^α solo sublinealmente, de modo que $-\pi(z) \rightarrow +\infty$ cuando $z \rightarrow \infty$. Por el argumento del Teorema 8.7 (adaptado al cerrado $[0, \infty)$), el máximo de π existe.
- **Retornos crecientes** ($\alpha > 1$): ahora $\pi(z) = pz^\alpha - wz \rightarrow +\infty$: duplicar la escala más que duplica el ingreso, y el problema de la firma *no tiene solución*; el supremo del beneficio es $+\infty$. La FOC puede tener solución (¡un punto crítico!), pero es un *mínimo* interior del beneficio, no un máximo.
- **Retornos constantes** ($\alpha = 1$): si $p > w$ el beneficio crece sin tope; si $p = w$ todo z es óptimo con beneficio 0; si $p < w$ el óptimo es $z = 0$.

¿Qué “repara” la existencia? O bien supuestos sobre la tecnología que hagan coercivo a $-\pi$ (retornos decrecientes, costos convexos que crecen más rápido que el ingreso), o bien *compactificar* el conjunto factible (capacidad instalada finita, insumos limitados: $z \in [0, \bar{z}]$ y Weierstrass hace el resto). Esta discusión es exactamente la de [9] sobre la no existencia del óptimo con retornos no decrecientes.

Estrategia de examen

Ante cualquier problema de optimización, en el examen (de este curso o de micro) sigue siempre este orden:

1. **Existencia:** ¿el dominio es compacto (Weierstrass)? ¿La función objetivo es coerciva (o $-f$ lo es, si maximizas)? Si no puedes garantizar existencia, dilo: puede ser justamente lo que preguntan (retornos crecientes).
2. **Candidatos:** resuelve $\nabla f(x) = 0$. No olvides puntos de no diferenciabilidad si los hay (ahí el candidato es $0 \in \partial f$).
3. **Clasificación local:** Hessiana en cada candidato (definida positiva $\Rightarrow$ mínimo local

estricto; definida negativa $\Rightarrow$ máximo local estricto; indefinida $\Rightarrow$ silla; semidefinida $\Rightarrow$ el test no decide, analiza a mano).

4. **Globalidad:** ¿es f convexa (o cóncava)? Entonces el punto crítico es óptimo *global* y terminaste. Si no, compara valores entre candidatos y estudia el comportamiento en el infinito.

Escribir estos cuatro pasos, aunque alguno sea trivial, ordena la solución y suele valer puntos por sí mismo.

8.2. Condición necesaria de primer orden [P1]

Supondremos en esta sección que f es diferenciable. Recordemos del capítulo de preliminares que el *gradiente* $\nabla f(x)$ es el vector de derivadas parciales y que la *derivada direccional* de f en x en la dirección $d \in \mathbb{R}^n$ es

$$f'(x; d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} = \langle \nabla f(x), d \rangle,$$

la tasa instantánea de cambio de f al moverse desde x en la dirección d .

Teorema 8.9 (Condición necesaria de primer orden, Fermat). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en x^* . Si x^* es un mínimo local de f , entonces*

$$\nabla f(x^*) = 0.$$

Demostración. Fijemos una dirección arbitraria $d \in \mathbb{R}^n$ y consideremos la función de una variable

$$g(t) = f(x^* + td),$$

que “recorre” f a lo largo de la recta que pasa por x^* con dirección d . Como x^* es mínimo local, existe $\varepsilon > 0$ tal que $f(x^*) \leq f(x)$ para todo x con $\|x - x^*\| < \varepsilon$. Si $d \neq 0$ y $0 < t < \varepsilon / \|d\|$, el punto $x^* + td$ está en esa vecindad, así que

$$f(x^* + td) - f(x^*) \geq 0 \quad \Rightarrow \quad \frac{f(x^* + td) - f(x^*)}{t} \geq 0,$$

donde dividir por $t > 0$ conserva el sentido de la desigualdad. Tomando el límite cuando $t \downarrow 0$ (los límites conservan desigualdades no estrictas):

$$\langle \nabla f(x^*), d \rangle = \lim_{t \downarrow 0} \frac{f(x^* + td) - f(x^*)}{t} \geq 0.$$

Esto vale para *toda* dirección d . En particular, aplicándolo a la dirección $d = -\nabla f(x^*)$:

$$\langle \nabla f(x^*), -\nabla f(x^*) \rangle = -\|\nabla f(x^*)\|^2 \geq 0,$$

lo que fuerza $\|\nabla f(x^*)\|^2 \leq 0$. Como una norma al cuadrado es siempre ≥ 0 , concluimos $\|\nabla f(x^*)\| = 0$, es decir, $\nabla f(x^*) = 0$. $\square$

Intuición

La demostración dice dos cosas. Primero: en un mínimo local, moverse en *cualquier* dirección no puede hacer bajar la función a primer orden ($f'(x^*; d) \geq 0$ para todo d). Segundo: si el gradiente no fuera cero, la dirección $-\nabla f(x^*)$ (la de *máximo descenso*, la que usan los algoritmos de gradiente [5, 8]) haría bajar estrictamente la función, contradiciendo la minimalidad. En una frase: en el fondo del valle, el terreno es plano.

Definición 8.10 (Punto crítico). Un punto x con $\nabla f(x) = 0$ se llama **punto crítico** o **estacionario** (*critical / stationary point*) de f .

Cuidado (error común)

El Teorema 8.9 es una condición **necesaria**, no suficiente. La implicación correcta es:

$$x^* \text{ mínimo local} \implies \nabla f(x^*) = 0, \quad \text{y no al revés.}$$

Errores clásicos de examen:

- Resolver $\nabla f = 0$ y declarar “óptimo” sin verificar segundo orden ni globalidad: el punto puede ser un máximo, una silla, o nada (ejemplo: $x = 0$ para $f(x) = x^3$).
- Olvidar la existencia: la FOC puede no tener solución ($f(x) = e^x$: $f'(x) = e^x \neq 0$ siempre) o tenerla sin que exista el óptimo (la firma con retornos crecientes del Ejemplo 8.8).
- Confundir “necesaria bajo diferenciabilidad”: $f(x) = |x|$ tiene mínimo en 0 con “gradiente” inexistente; ahí la condición correcta es $0 \in \partial f(0)$ (Sección 8.4).

La única situación en que “FOC $\implies$ óptimo global” sin más trabajo es cuando f es convexa (Teorema 8.23); esa es la razón profunda por la que en micro casi siempre se supone concavidad.

Ejemplo 8.11 (Punto de silla). Sea $f(x, y) = x^2 - y^2$. Su gradiente es $\nabla f(x, y) = (2x, -2y)$, que se anula únicamente en $(0, 0)$. ¿Es un óptimo? Miremos f a lo largo de los ejes:

$$f(x, 0) = x^2 \geq 0 = f(0, 0) \quad \text{y} \quad f(0, y) = -y^2 \leq 0 = f(0, 0).$$

A lo largo del eje x , el origen parece un mínimo; a lo largo del eje y , un máximo. En *toda* vecindad de $(0, 0)$ hay puntos donde f es mayor y puntos donde es menor: $(0, 0)$ no es ni mínimo ni máximo local. Un punto crítico así se llama **punto de silla** (*saddle point*), por la forma de silla de montar de la gráfica. La Hessiana es

$$\nabla^2 f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix},$$

con autovalores 2 y -2 : *indefinida*, la firma algebraica de una silla, como formalizamos a continuación.

8.3. Condiciones de segundo orden [P1]

La FOC filtra candidatos; el segundo orden los clasifica. La herramienta es el desarrollo de Taylor de segundo orden (capítulo de preliminares): si f es dos veces diferenciable en x^* , para $h \rightarrow 0$,

$$f(x^* + h) = f(x^*) + \langle \nabla f(x^*), h \rangle + \frac{1}{2} h^\top \nabla^2 f(x^*) h + o(\|h\|^2), \quad (8.1)$$

donde $\nabla^2 f(x^*)$ es la matriz Hessiana (simétrica, por el teorema de Schwarz cuando f es de clase C^2) y $o(\|h\|^2)$ denota un resto que cumple $o(\|h\|^2)/\|h\|^2 \rightarrow 0$ cuando $h \rightarrow 0$. Recordemos también del capítulo de preliminares: una matriz simétrica A es *semidefinida positiva* (PSD) si $d^\top A d \geq 0$ para todo d , y *definida positiva* (PD) si $d^\top A d > 0$ para todo $d \neq 0$.

Teorema 8.12 (Condición necesaria de segundo orden). *Sea f dos veces diferenciable en x^* . Si x^* es un mínimo local de f , entonces $\nabla f(x^*) = 0$ y la Hessiana $\nabla^2 f(x^*)$ es semidefinida positiva.*

Demostración. Que $\nabla f(x^*) = 0$ es el Teorema 8.9. Fijemos una dirección $d \in \mathbb{R}^n$, $d \neq 0$, y tomemos $h = td$ con $t > 0$ pequeño en (8.1). Como el término de primer orden se anula:

$$f(x^* + td) - f(x^*) = \frac{t^2}{2} d^\top \nabla^2 f(x^*) d + o(t^2).$$

Para t suficientemente pequeño, $x^* + td$ cae en la vecindad donde x^* es mínimo, así que el lado izquierdo es ≥ 0 . Dividiendo entre $t^2 > 0$:

$$\frac{1}{2} d^\top \nabla^2 f(x^*) d + \frac{o(t^2)}{t^2} \geq 0.$$

Tomando $t \downarrow 0$, el término $o(t^2)/t^2$ tiende a 0 (esa es la definición de $o(t^2)$), y queda $d^\top \nabla^2 f(x^*) d \geq 0$. Como d era arbitraria, $\nabla^2 f(x^*)$ es semidefinida positiva. $\square$

Teorema 8.13 (Condición suficiente de segundo orden). *Sea f dos veces diferenciable en x^* , con*

$$\nabla f(x^*) = 0 \quad \text{y} \quad \nabla^2 f(x^*) \text{ definida positiva.}$$

Entonces x^ es un mínimo local estricto de f .*

Demostración. Denotemos $H = \nabla^2 f(x^*)$ y sea $\lambda_{\min} > 0$ su autovalor más pequeño (es positivo precisamente porque H es definida positiva).

Paso 1: cota inferior cuadrática. Como H es simétrica, el teorema espectral (capítulo de preliminares) da una base ortonormal de autovectores $v_1, \dots, v_n$ con autovalores $\lambda_1 \geq \dots \geq \lambda_n = \lambda_{\min}$. Escribiendo $h = \sum_i c_i v_i$ (con $\|h\|^2 = \sum_i c_i^2$ por ortonormalidad):

$$h^\top H h = \sum_{i=1}^n \lambda_i c_i^2 \geq \lambda_{\min} \sum_{i=1}^n c_i^2 = \lambda_{\min} \|h\|^2 \quad \text{para todo } h \in \mathbb{R}^n.$$

Es decir: la forma cuadrática no puede ser más plana que su autovalor mínimo.

Paso 2: Taylor. Con $\nabla f(x^*) = 0$, la expansión (8.1) y el Paso 1 dan

$$f(x^* + h) - f(x^*) = \frac{1}{2} h^\top H h + o(\|h\|^2) \geq \frac{\lambda_{\min}}{2} \|h\|^2 + o(\|h\|^2).$$

Paso 3: el resto no arruina la cota. Por definición de $o(\|h\|^2)$, existe $\delta > 0$ tal que si $0 < \|h\| < \delta$ entonces

$$|o(\|h\|^2)| \leq \frac{\lambda_{\min}}{4} \|h\|^2.$$

(Estamos usando la definición de límite con $\varepsilon = \lambda_{\min}/4 > 0$.) Entonces, para $0 < \|h\| < \delta$,

$$f(x^* + h) - f(x^*) \geq \frac{\lambda_{\min}}{2} \|h\|^2 - \frac{\lambda_{\min}}{4} \|h\|^2 = \frac{\lambda_{\min}}{4} \|h\|^2 > 0.$$

Luego $f(x^* + h) > f(x^*)$ para todo $h \neq 0$ con $\|h\| < \delta$: x^* es mínimo local estricto. $\square$

Intuición

El argumento es una competencia entre el término cuadrático (que empuja hacia arriba con fuerza al menos $\lambda_{\min} \|h\|^2/2$) y el resto de Taylor (que es *despreciable frente a* $\|h\|^2$ cerca de x^*). Como el empuje cuadrático tiene una tasa fija positiva y el resto tiene tasa que tiende a cero, cerca de x^* gana el cuadrático. Aquí es esencial que $\lambda_{\min} > 0$ sea un número fijo: si H fuera solo semidefinida positiva, alguna dirección tendría $\lambda = 0$, el término cuadrático no empujaría nada en esa dirección, y el resto (de signo desconocido) decidiría el resultado. Por eso PSD no basta como condición suficiente.

Ejemplo 8.14 (El caso frontera: cuando el test no decide). En $\mathbb{R}$, considera $f(x) = x^4$ y $g(x) = x^3$. Ambas cumplen $f'(0) = g'(0) = 0$ y $f''(0) = g''(0) = 0$: en ambos casos la “Hessiana” 1×1 es la matriz nula, que es semidefinida positiva (y también semidefinida negativa). Sin embargo:

- $x = 0$ es mínimo global estricto de $f(x) = x^4$ ($x^4 > 0$ para $x \neq 0$);
- $x = 0$ no es ni mínimo ni máximo local de $g(x) = x^3$ (g cambia de signo: es un punto de inflexión).

Conclusiones: (1) la condición necesaria (PSD) no es suficiente, como muestra x^3 ; (2) la condición suficiente (PD) no es necesaria, como muestra x^4 (mínimo estricto con Hessiana no PD). Cuando la Hessiana en un punto crítico es semidefinida pero no definida, el test de segundo orden **no concluye nada** y hay que analizar la función directamente (términos de orden superior, convexidad, o inspección).

8.3.1. Ejemplos resueltos de clasificación

Ejemplo 8.15 (Una cuadrática). Clasificar los puntos críticos de

$$f(x, y) = 2x^2 + y^2 + xy - 4x - 2y.$$

Paso 1 (FOC). $\nabla f(x, y) = (4x + y - 4, 2y + x - 2) = (0, 0)$ da el sistema lineal

$$4x + y = 4, \quad x + 2y = 2.$$

De la primera, $y = 4 - 4x$; sustituyendo en la segunda: $x + 8 - 8x = 2 \Rightarrow -7x = -6 \Rightarrow x^* = 6/7$, y entonces $y^* = 4 - 24/7 = 4/7$. Único punto crítico: $(6/7, 4/7)$.

Paso 2 (SOC). La Hessiana es constante:

$$\nabla^2 f = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}.$$

Sus menores principales líderes son $4 > 0$ y $\det = 4 \cdot 2 - 1 \cdot 1 = 7 > 0$: por el criterio de Sylvester (capítulo de preliminares), es definida positiva. Por el Teorema 8.13, $(6/7, 4/7)$ es mínimo local estricto.

Paso 3 (globalidad). Como la Hessiana es PD en todo punto, f es (estrictamente) convexa (capítulo de funciones convexas), y por el Teorema 8.23 más abajo, el punto es el mínimo global, además único. El valor mínimo es $f(6/7, 4/7) = -16/7$ (verificación directa).

Ejemplo 8.16 (Varios puntos críticos). Clasificar los puntos críticos de

$$f(x, y) = x^3 - 3x + y^2.$$

FOC. $\nabla f = (3x^2 - 3, 2y) = (0, 0)$ da $x^2 = 1$ e $y = 0$: dos puntos críticos, $(1, 0)$ y $(-1, 0)$.

$$\text{SOC. } \nabla^2 f(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 2 \end{pmatrix}.$$

- En $(1, 0)$: $\text{diag}(6, 2)$, autovalores $6, 2 > 0$, definida positiva $\Rightarrow$ **mínimo local estricto**, con $f(1, 0) = -2$.
- En $(-1, 0)$: $\text{diag}(-6, 2)$, autovalores $-6 < 0 < 2$, **indefinida** $\Rightarrow$ **punto de silla** (a lo largo del eje y la función sube; a lo largo del eje x , baja).

Globalidad. $(1, 0)$ no es mínimo global: $f(x, 0) = x^3 - 3x \rightarrow -\infty$ cuando $x \rightarrow -\infty$, así que $\inf f = -\infty$ y no existe mínimo global. Moraleja: la clasificación local no dice nada sobre lo global sin convexidad o coercividad.

Ejemplo 8.17 (Monopolista con demanda lineal y costo cuadrático). Un monopolista enfrenta la demanda inversa $p(q) = a - bq$ (con $a, b > 0$) y tiene costo $C(q) = cq + \frac{d}{2}q^2$ (con $0 \leq c < a$, $d \geq 0$): un costo marginal $c + dq$ creciente en la escala. Su beneficio es

$$\pi(q) = p(q)q - C(q) = (a - bq)q - cq - \frac{d}{2}q^2 = (a - c)q - \left(b + \frac{d}{2}\right)q^2.$$

Existencia. $-\pi(q) = (b + d/2)q^2 - (a - c)q$ es coerciva (el término cuadrático con coeficiente positivo domina), así que el máximo existe (Teorema 8.7).

FOC. $\pi'(q) = (a - c) - (2b + d)q = 0$, de donde

$$q^* = \frac{a - c}{2b + d} > 0.$$

Económicamente, la FOC es la igualdad *ingreso marginal = costo marginal*: $a - 2bq = c + dq$.

SOC. $\pi''(q) = -(2b + d) < 0$ para todo q : π es estrictamente cóncava (equivalentemente, $-\pi$ es estrictamente convexa), así que q^* no solo es máximo local estricto sino **máximo global único** (Teorema 8.23 aplicado a $-\pi$). El precio de monopolio es $p^* = a - bq^* = \frac{a(b + d) + bc}{2b + d}$, que se verifica mayor que el costo marginal en q^* (poder de mercado).

Ejemplo 8.18 (Mejor respuesta de Cournot). Dos firmas producen un bien homogéneo con costo marginal constante $c \in (0, a)$; el precio de mercado es $p = a - b(q_1 + q_2)$. Dada la cantidad $q_2 \geq 0$ de la rival, la firma 1 resuelve

$$\max_{q_1 \geq 0} \pi_1(q_1) = (a - b(q_1 + q_2))q_1 - cq_1.$$

FOC. $\pi'_1(q_1) = a - 2bq_1 - bq_2 - c = 0$, de donde la **función de mejor respuesta** (*best response*):

$$q_1 = BR_1(q_2) = \frac{a - c - bq_2}{2b} \quad (\text{y } q_1 = 0 \text{ si } q_2 \geq (a - c)/b).$$

SOC. $\pi''_1(q_1) = -2b < 0$: π_1 es estrictamente cóncava en q_1 , así que la FOC caracteriza el máximo global. *Esto es lo que valida el procedimiento estándar de la teoría de juegos*: “derivar, igualar a cero, despejar la mejor respuesta”. En el equilibrio de Nash simétrico, $q_1 = q_2 = q^*$ resuelve $q^* = (a - c - bq^*)/(2b)$, es decir,

$$q^* = \frac{a - c}{3b}, \quad Q^* = \frac{2(a - c)}{3b}, \quad p^* = \frac{a + 2c}{3}.$$

El mismo esquema FOC + concavidad valida la puja de equilibrio en subastas de primer precio y el enfoque de primer orden en riesgo moral [10, 11].

8.4. Minimización de funciones convexas [P1]

Aquí ocurre la magia que hace especial a este curso: para funciones convexas, todas las patologías anteriores (mínimos locales que no son globales, puntos críticos que son sillas) desaparecen. Recordemos del capítulo de funciones convexas: $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es **convexa** si para todos x, y y $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y),$$

y **estrictamente convexa** si la desigualdad es estricta cuando $x \neq y$ y $\lambda \in (0, 1)$.

Teorema 8.19 (Todo mínimo local es global). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Si x^* es un mínimo local de f , entonces x^* es un mínimo global.*

Demostración. Por contradicción: supongamos que x^* es mínimo local pero no global. Entonces existe $y \in \mathbb{R}^n$ con $f(y) < f(x^*)$. Consideremos los puntos del segmento entre x^* e y :

$$x_\lambda = (1 - \lambda)x^* + \lambda y, \quad \lambda \in (0, 1].$$

Por convexidad,

$$f(x_\lambda) \leq (1 - \lambda)f(x^*) + \lambda f(y) < (1 - \lambda)f(x^*) + \lambda f(x^*) = f(x^*),$$

donde la desigualdad estricta usa $f(y) < f(x^*)$ y $\lambda > 0$. Es decir, *todo* punto del segmento (salvo x^*) tiene valor estrictamente menor que $f(x^*)$. Pero $\|x_\lambda - x^*\| = \lambda \|y - x^*\| \rightarrow 0$ cuando $\lambda \downarrow 0$: hay puntos x_λ *arbitrariamente cerca* de x^* con $f(x_\lambda) < f(x^*)$. Esto contradice que x^* sea

mínimo local (ninguna vecindad de x^* puede satisfacer $f(x^*) \leq f$). Luego no existe tal y , y x^* es mínimo global. $\square$

Intuición

Si hubiera un punto mejor en otra parte, la “cuerda” que une el valle local con ese punto mejor estaría, por convexidad, por encima de la gráfica; al caminar por el segmento hacia el punto mejor, la función baja *desde el primer paso*. Un valle local del que se puede salir cuesta abajo no es un valle. En una función convexa no hay valles falsos.

Teorema 8.20 (El conjunto de minimizadores es convexo). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Entonces $\arg \min_x f(x)$ es un conjunto convexo (posiblemente vacío).*

Demostración. Si $\arg \min f$ es vacío o tiene un solo punto, es convexo trivialmente. Sean $x, y \in \arg \min f$, ambos con el valor mínimo $p^* = f(x) = f(y)$, y sea $\lambda \in [0, 1]$. Por convexidad,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) = \lambda p^* + (1 - \lambda)p^* = p^*.$$

Pero p^* es el valor mínimo de f , así que también $f(\lambda x + (1 - \lambda)y) \geq p^*$. Luego $f(\lambda x + (1 - \lambda)y) = p^*$ y el punto $\lambda x + (1 - \lambda)y$ pertenece a $\arg \min f$. (De hecho, $\arg \min f = \{x : f(x) \leq p^*\}$ es un conjunto de subnivel de una función convexa, y ya vimos en el capítulo de funciones convexas que estos son convexas.) $\square$

Teorema 8.21 (Unicidad bajo convexidad estricta). *Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es estrictamente convexa, entonces f tiene a lo sumo un minimizador global.*

Demostración. Supongamos que $x \neq y$ son ambos minimizadores globales, con valor $p^* = f(x) = f(y)$. Tomemos el punto medio $m = \frac{1}{2}x + \frac{1}{2}y$. Por convexidad *estricta* (con $\lambda = 1/2 \in (0, 1)$ y $x \neq y$):

$$f(m) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = p^*.$$

Esto contradice que p^* sea el valor mínimo. Luego no puede haber dos minimizadores distintos. $\square$

Observación 8.22. La convexidad estricta da *unicidad* pero no *existencia*: $f(x) = e^x$ es estrictamente convexa y no tiene minimizador. El paquete completo “existe y es único” requiere, por ejemplo, convexidad estricta + coercividad. En micro, este es el argumento estándar para que la demanda sea una *función* (no una correspondencia): utilidad estrictamente cuasicóncava $\Rightarrow$ elección óptima única [9, 10].

Teorema 8.23 (La FOC es suficiente bajo convexidad). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa y diferenciable. Entonces x^* es un mínimo global de f **si y solo si** $\nabla f(x^*) = 0$.*

Demostración. $(\Rightarrow)$ Es el Teorema 8.9 (un mínimo global es en particular local).

$(\Leftarrow)$ Usamos la *caracterización de primer orden de la convexidad* demostrada en el capítulo de funciones convexas: f convexa y diferenciable satisface, para todos x, y ,

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle,$$

es decir, la tangente en cualquier punto queda por debajo de la gráfica (es un *minorante global*). Aplicándola en $x = x^*$ con $\nabla f(x^*) = 0$:

$$f(y) \geq f(x^*) + \langle 0, y - x^* \rangle = f(x^*) \quad \text{para todo } y \in \mathbb{R}^n,$$

que es exactamente la definición de mínimo global. $\square$

Observación 8.24 (Versión no diferenciable: el subdiferencial). Si f es convexa pero no diferenciable (piensa en $f(x) = |x|$ o en $\|\cdot\|_1$, omnipresente en estadística), la condición de optimalidad correcta usa el subdiferencial del capítulo anterior:

$$x^* \in \arg \min_x f(x) \iff 0 \in \partial f(x^*).$$

La demostración es inmediata desde la definición de subgradiente: $0 \in \partial f(x^*)$ significa $f(y) \geq f(x^*) + \langle 0, y - x^* \rangle = f(x^*)$ para todo y , que es la optimalidad global; y recíprocamente, si x^* es mínimo global esa misma desigualdad dice que 0 es un subgradiente. La regla de Fermat $\nabla f(x^*) = 0$ es el caso particular en que $\partial f(x^*) = \{\nabla f(x^*)\}$. Puedes ver [6] (capítulo 3) y [3].

8.4.1. Ejemplo estrella: mínimos cuadrados ordinarios

Ejemplo 8.25 (MCO / OLS). Este es el problema de optimización más resuelto de la historia de la economía. Tenemos m observaciones de una variable dependiente, $y \in \mathbb{R}^m$, y una matriz de regresores $X \in \mathbb{R}^{m \times n}$ (cada columna es una variable explicativa; $m \geq n$). Buscamos el vector de coeficientes $\beta \in \mathbb{R}^n$ que minimiza la suma de cuadrados de los residuos:

$$\min_{\beta \in \mathbb{R}^n} f(\beta) = \|y - X\beta\|^2.$$

Paso 1: expandir. Usando $\|v\|^2 = v^\top v$ y las reglas de transposición:

$$f(\beta) = (y - X\beta)^\top (y - X\beta) = y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X \beta.$$

(El término cruzado aparece dos veces, $y^\top X\beta$ y $\beta^\top X^\top y$, y ambos son el mismo escalar.)

Paso 2: gradiente. Con las reglas de derivación matricial del capítulo de preliminares ($\nabla_\beta(b^\top \beta) = b$ y $\nabla_\beta(\beta^\top A\beta) = 2A\beta$ para A simétrica; aquí $A = X^\top X$ es simétrica):

$$\nabla f(\beta) = -2X^\top y + 2X^\top X\beta.$$

La FOC $\nabla f(\beta) = 0$ da las célebres **ecuaciones normales** (*normal equations*):

$$X^\top X \beta = X^\top y. \tag{8.2}$$

Paso 3: convexidad. La Hessiana es $\nabla^2 f(\beta) = 2X^\top X$, constante. Para cualquier $d \in \mathbb{R}^n$,

$$d^\top (2X^\top X) d = 2(Xd)^\top (Xd) = 2\|Xd\|^2 \geq 0 :$$

$X^\top X$ es siempre semidefinida positiva, así que f es **convexa** y, por el Teorema 8.23, *toda*

solución de (8.2) es un mínimo global. No hace falta comprobar nada más: la FOC basta.

Paso 4: unicidad. Si X tiene *rango de columnas completo* (rango $X = n$, es decir, sin colinealidad perfecta entre regresores), entonces $Xd = 0$ implica $d = 0$, así que $\|Xd\|^2 > 0$ para $d \neq 0$: $X^\top X$ es definida positiva, f es estrictamente convexa, la solución es única (Teorema 8.21) e invertible el sistema:

$$\hat{\beta} = (X^\top X)^{-1} X^\top y.$$

Nota para el economista. Esta es exactamente la fórmula del estimador MCO de econometría. El supuesto de “no multicolinealidad perfecta” de los cursos de econometría es, matemáticamente, la condición de convexidad estricta que garantiza unicidad. Y en la Sección 8.6 veremos que $\hat{\beta}$ tiene además una lectura geométrica: $X\hat{\beta}$ es la *proyección* de y sobre el espacio generado por las columnas de X .

8.5. Distancia a un conjunto y función proyección [P2]

Cambiamos ahora de una pregunta “libre” (minimizar f en todo $\mathbb{R}^n$) a la más geométrica de todas las preguntas de optimización: dado un conjunto C y un punto x fuera de él, ¿cuál es el punto de C más cercano a x ? Este problema es en sí mismo un problema de optimización (minimizar la función $y \mapsto \|x - y\|$ sobre C), y su solución, la *proyección*, es una de las herramientas más usadas del análisis convexo: en el capítulo de separación la usamos (enunciada sin demostración completa) para construir hiperplanos separadores; aquí la desarrollamos con todos los detalles.

Definición 8.26 (Distancia a un conjunto). Sea $C \subseteq \mathbb{R}^n$ no vacío. La **función distancia** (*distance function*) a C es

$$d_C(x) = \inf_{y \in C} \|x - y\|, \quad x \in \mathbb{R}^n.$$

Usamos $\inf$ (la mayor cota inferior, que siempre existe porque las normas son ≥ 0) y no $\min$ porque, en general, el punto más cercano puede no existir: si $C = (0, 1)$ en $\mathbb{R}$ y $x = 2$, entonces $d_C(x) = 1$ pero ningún $y \in C$ cumple $|2 - y| = 1$ (el candidato sería $y = 1 \notin C$). El problema es que C no es cerrado. Cerrado sí basta:

Proposición 8.27 (Existencia del punto más cercano). Si $C \subseteq \mathbb{R}^n$ es no vacío y cerrado, entonces para todo $x \in \mathbb{R}^n$ el ínfimo se alcanza: existe $\bar{y} \in C$ con $\|x - \bar{y}\| = d_C(x)$.

Demostración. Fijemos x y un punto cualquiera $y_0 \in C$, y sea $r = \|x - y_0\|$. Los puntos de C a distancia mayor que r de x no pueden ser los más cercanos, así que

$$\inf_{y \in C} \|x - y\| = \inf_{y \in K} \|x - y\|, \quad \text{donde } K = C \cap \{y : \|x - y\| \leq r\}.$$

El conjunto K es no vacío ($y_0 \in K$), cerrado (intersección de dos cerrados: C y una bola cerrada) y acotado (está dentro de la bola de radio r centrada en x): es compacto. La función $y \mapsto \|x - y\|$ es continua (consecuencia de la desigualdad triangular). Por Weierstrass (Teorema 8.4), el ínfimo sobre K se alcanza en algún $\bar{y} \in K \subseteq C$. $\square$

Nota la misma jugada que en el Teorema 8.7: recortar el problema a un compacto y dejar que Weierstrass trabaje. Es un patrón que conviene reconocer.

Proposición 8.28 (La distancia a un convexo es convexa). *Si $C \subseteq \mathbb{R}^n$ es no vacío y convexo, entonces $d_C : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa.*

Demostración. Sean $x_1, x_2 \in \mathbb{R}^n$, $\lambda \in [0, 1]$ y $x_\lambda = \lambda x_1 + (1 - \lambda)x_2$. Fijemos $\varepsilon > 0$ arbitrario. Por definición de ínfimo, existen $y_1, y_2 \in C$ “casi óptimos”:

$$\|x_1 - y_1\| \leq d_C(x_1) + \varepsilon, \quad \|x_2 - y_2\| \leq d_C(x_2) + \varepsilon.$$

Como C es convexo, el punto $y_\lambda = \lambda y_1 + (1 - \lambda)y_2$ pertenece a C , y por lo tanto es un candidato admisible en el ínfimo que define $d_C(x_\lambda)$:

$$\begin{aligned} d_C(x_\lambda) &\leq \|x_\lambda - y_\lambda\| = \|\lambda(x_1 - y_1) + (1 - \lambda)(x_2 - y_2)\| \\ &\leq \lambda \|x_1 - y_1\| + (1 - \lambda) \|x_2 - y_2\| && \text{(desigualdad triangular y homogeneidad)} \\ &\leq \lambda d_C(x_1) + (1 - \lambda)d_C(x_2) + \varepsilon. \end{aligned}$$

Como $\varepsilon > 0$ es arbitrario, dejando $\varepsilon \downarrow 0$ obtenemos $d_C(x_\lambda) \leq \lambda d_C(x_1) + (1 - \lambda)d_C(x_2)$: d_C es convexa. (Observa dónde se usó cada hipótesis: la convexidad de C para que $y_\lambda \in C$; las propiedades de la norma para partir la distancia.) $\square$

8.5.1. El teorema de la proyección

Definición 8.29 (Proyección sobre un conjunto). Sea $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo. La **proyección** (*projection*) de $x \in \mathbb{R}^n$ sobre C , denotada $\text{proy}_C(x)$, es el punto de C más cercano a x :

$$\text{proy}_C(x) = \arg \min_{y \in C} \|x - y\|.$$

El siguiente teorema justifica el artículo determinado “el punto”: la proyección existe y es única, así que $\text{proy}_C : \mathbb{R}^n \rightarrow C$ es una función bien definida.

Teorema 8.30 (Teorema de la proyección). *Sea $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo, y sea $x \in \mathbb{R}^n$. Entonces:*

- (a) **(Existencia)** *Existe al menos un punto de C más cercano a x .*
- (b) **(Unicidad)** *Ese punto es único; lo denotamos $\text{proy}_C(x)$.*
- (c) **(Caracterización variacional)** *Un punto $p \in C$ es la proyección de x si y solo si*

$$\langle x - p, y - p \rangle \leq 0 \quad \text{para todo } y \in C. \quad (8.3)$$

Demostración. **(a) Existencia.** Es la Proposición 8.27 (solo requiere C cerrado y no vacío; la convexidad aún no interviene).

(b) Unicidad. Aquí entra la convexidad, vía la *identidad del paralelogramo*, válida para la norma euclídea:

$$\|a + b\|^2 + \|a - b\|^2 = 2\|a\|^2 + 2\|b\|^2 \quad \text{para todos } a, b \in \mathbb{R}^n$$

(se comprueba expandiendo $\|a \pm b\|^2 = \|a\|^2 \pm 2\langle a, b \rangle + \|b\|^2$ y sumando). Supongamos que $p_1, p_2 \in C$ son ambos puntos más cercanos: $\|x - p_1\| = \|x - p_2\| = d$, donde $d = d_C(x)$. Apliquemos la identidad con $a = x - p_1$ y $b = x - p_2$:

$$\|2x - p_1 - p_2\|^2 + \|p_2 - p_1\|^2 = 2\|x - p_1\|^2 + 2\|x - p_2\|^2 = 4d^2.$$

El primer término es $\|2x - p_1 - p_2\|^2 = 4\|x - m\|^2$ donde $m = \frac{1}{2}(p_1 + p_2)$ es el punto medio. Despejando:

$$\|x - m\|^2 = d^2 - \frac{1}{4}\|p_1 - p_2\|^2.$$

Por convexidad de C , $m \in C$, así que $\|x - m\| \geq d$ (nadie en C está más cerca que d). Combinando:

$$d^2 \leq \|x - m\|^2 = d^2 - \frac{1}{4}\|p_1 - p_2\|^2 \implies \|p_1 - p_2\|^2 \leq 0 \implies p_1 = p_2.$$

(Geométricamente: si hubiera dos puntos más cercanos distintos, su punto medio, que también está en C , estaría *estrictamente* más cerca de x ; imposible.)

(c) Caracterización. ($\Rightarrow$) Sea $p = \text{proy}_C(x)$ y sea $y \in C$ arbitrario. Para $t \in (0, 1]$, el punto $p_t = p + t(y - p) = (1 - t)p + ty$ está en C por convexidad. Como p minimiza la distancia (y por tanto la distancia al cuadrado):

$$\|x - p\|^2 \leq \|x - p_t\|^2 = \|(x - p) - t(y - p)\|^2 = \|x - p\|^2 - 2t\langle x - p, y - p \rangle + t^2\|y - p\|^2.$$

Cancelando $\|x - p\|^2$ y dividiendo entre $t > 0$:


$$0 \leq -2\langle x - p, y - p \rangle + t\|y - p\|^2.$$

Tomando $t \downarrow 0$ queda $\langle x - p, y - p \rangle \leq 0$. (Compara con la demostración del Teorema 8.9: es el mismo argumento de “derivada direccional ≥ 0 ”, ahora con movimientos que permanecen en C .)

($\Leftarrow$) Supongamos que $p \in C$ satisface (8.3). Para cualquier $y \in C$, expandimos:

$$\begin{aligned} \|x - y\|^2 &= \|(x - p) - (y - p)\|^2 \\ &= \|x - p\|^2 - 2\langle x - p, y - p \rangle + \|y - p\|^2 \\ &\geq \|x - p\|^2 + \|y - p\|^2 && (\text{por (8.3), } -2\langle \cdot, \cdot \rangle \geq 0) \\ &\geq \|x - p\|^2. \end{aligned}$$

Luego p es el punto de C más cercano a x , es decir, $p = \text{proy}_C(x)$. Nota que la primera desigualdad da además la información cuantitativa $\|x - y\|^2 \geq \|x - p\|^2 + \|y - p\|^2$, una “desigualdad de Pitágoras” que dice que p no solo es el más cercano sino por cuánto. $\square$



La caracterización (8.3): el ángulo en p entre $x - p$ y cualquier $y - p$ con $y \in C$ es obtuso (coseno ≤ 0).

Intuición

La desigualdad $\langle x - p, y - p \rangle \leq 0$ dice que, parados en la proyección p y mirando hacia x , todo el conjunto C queda “a nuestras espaldas”: el ángulo entre la dirección hacia x y la dirección hacia cualquier otro punto de C es de al menos 90 grados. Dicho de otro modo, el hiperplano que pasa por p con normal $x - p$ deja a C de un lado y a x del otro. **Esta es exactamente la construcción que usamos en el capítulo de separación:** para separar un punto $x \notin C$ de un convexo cerrado C , el hiperplano separador se fabrica con la proyección ($a = x - \text{proj}_C(x)$ como vector normal). Allí el teorema de la proyección fue el motor escondido; aquí ya tienes todas sus piezas demostradas.

Teorema 8.31 (No expansividad de la proyección). *Sea $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo. Entonces la función proj_C es no expansiva (nonexpansive):*

$$\|\text{proj}_C(x) - \text{proj}_C(z)\| \leq \|x - z\| \quad \text{para todos } x, z \in \mathbb{R}^n.$$

En particular, proj_C es continua (de hecho, Lipschitz con constante 1).

Demostración. Escribamos $p = \text{proj}_C(x)$ y $q = \text{proj}_C(z)$. Aplicamos la caracterización (8.3) dos veces, cruzando los puntos (nota que $q \in C$ y $p \in C$, así que cada uno es un “ y ” válido para el otro):

$$\langle x - p, q - p \rangle \leq 0, \quad \langle z - q, p - q \rangle \leq 0.$$

En la segunda, $\langle z - q, p - q \rangle = -\langle z - q, q - p \rangle$, así que $\langle q - z, q - p \rangle \leq 0$. Sumando esta con la primera:

$$\langle (x - p) + (q - z), q - p \rangle \leq 0 \iff \langle x - z, q - p \rangle + \langle q - p, q - p \rangle \leq 0,$$

donde reagrupamos $(x - p) + (q - z) = (x - z) + (q - p)$. Por lo tanto,

$$\|q - p\|^2 \leq \langle x - z, p - q \rangle \leq \|x - z\| \|p - q\|,$$

usando en el último paso la desigualdad de Cauchy–Schwarz. Si $p = q$ no hay nada que probar; si $p \neq q$, dividimos entre $\|p - q\| > 0$ y obtenemos $\|p - q\| \leq \|x - z\|$. $\square$

Observación 8.32. La no expansividad dice que proyectar *no separa* puntos: dos puntos cercanos tienen proyecciones cercanas. Esta propiedad es la base de los algoritmos de *gradiente proyectado* para optimización con restricciones [5, 2]: alternar un paso de gradiente con una proyección sobre el conjunto factible nunca amplifica errores.

8.5.2. Proyecciones que se pueden calcular a mano

Ejemplo 8.33 (Proyección sobre una bola). Sea $C = \{y \in \mathbb{R}^n : \|y\| \leq r\}$ la bola cerrada de radio $r > 0$ centrada en el origen. Afirmamos que

$$\text{proy}_C(x) = \begin{cases} x, & \text{si } \|x\| \leq r, \\ \frac{r}{\|x\|} x, & \text{si } \|x\| > r, \end{cases}$$

es decir: si estás dentro no te mueves; si estás fuera, te “encoges” radialmente hasta la superficie.

Verificación con la caracterización (8.3) para el caso $\|x\| > r$: sea $p = (r/\|x\|)x$, de modo que $x - p = (1 - \frac{r}{\|x\|})x = \alpha x$ con $\alpha = 1 - r/\|x\| > 0$. Para cualquier $y \in C$:

$$\langle x - p, y - p \rangle = \alpha \langle x, y \rangle - \alpha \langle x, p \rangle = \alpha (\langle x, y \rangle - r \|x\|) \leq \alpha (\|x\| \|y\| - r \|x\|) = \alpha \|x\| (\|y\| - r) \leq 0,$$

usando $\langle x, p \rangle = (r/\|x\|) \|x\|^2 = r \|x\|$, Cauchy–Schwarz y $\|y\| \leq r$. Por la parte (c) del Teorema 8.30, $p = \text{proy}_C(x)$. Ejemplo numérico: con $r = 2$ y $x = (3, 4)$, $\|x\| = 5$ y $\text{proy}_C(x) = \frac{2}{5}(3, 4) = (6/5, 8/5)$.

Ejemplo 8.34 (Proyección sobre una caja). Sea $C = [a_1, b_1] \times \cdots \times [a_n, b_n]$ un producto de intervalos (una “caja”). El problema $\min_{y \in C} \|x - y\|^2 = \sum_i (x_i - y_i)^2$ se *separa* en n problemas unidimensionales independientes: minimizar $(x_i - y_i)^2$ con $y_i \in [a_i, b_i]$. La solución de cada uno es recortar x_i al intervalo:

$$(\text{proy}_C(x))_i = \min\{\max\{x_i, a_i\}, b_i\} = \begin{cases} a_i, & x_i < a_i, \\ x_i, & a_i \leq x_i \leq b_i, \\ b_i, & x_i > b_i. \end{cases}$$

Caso particular importante: el **ortante no negativo** $\mathbb{R}_+^n = \{y : y_i \geq 0\}$ (una caja con $a_i = 0$, $b_i = +\infty$):

$$(\text{proy}_{\mathbb{R}_+^n}(x))_i = \max\{x_i, 0\} =: x_i^+,$$

la *parte positiva* componente a componente. Este es el conjunto factible natural de la economía (cantidades no negativas), y su proyección es simplemente “poner en cero lo negativo”.

Ejemplo 8.35 (Proyección sobre un hiperplano: fórmula paso a paso). Sea $H = \{y \in \mathbb{R}^n : \langle a, y \rangle = b\}$ un hiperplano, con $a \neq 0$. Deduciremos la fórmula de $\text{proy}_H(x)$ desde cero.

Paso 1: forma del candidato. Geométricamente, el camino más corto de x al hiperplano debe ser *perpendicular* a él, es decir, paralelo al vector normal a . Busquemos entonces la proyección de la forma

$$p = x - t a \quad \text{para algún escalar } t \in \mathbb{R}.$$

Paso 2: imponer factibilidad. p debe estar en H :

$$\langle a, p \rangle = \langle a, x \rangle - t \langle a, a \rangle = \langle a, x \rangle - t \|a\|^2 = b \quad \implies \quad t = \frac{\langle a, x \rangle - b}{\|a\|^2}.$$

Paso 3: fórmula.

$$\text{proy}_H(x) = x - \frac{\langle a, x \rangle - b}{\|a\|^2} a. \quad (8.4)$$

Paso 4: verificación rigurosa. Nuestro “argumento geométrico” del Paso 1 fue heurístico; certifiquémoslo con la caracterización (8.3). Con p dado por (8.4), $x - p = ta$. Para cualquier $y \in H$, como $\langle a, y \rangle = b = \langle a, p \rangle$, se tiene $\langle a, y - p \rangle = 0$, y por tanto

$$\langle x - p, y - p \rangle = t \langle a, y - p \rangle = 0 \leq 0. \quad \checkmark$$

(En un hiperplano la desigualdad se cumple con *igualdad*: la proyección es ortogonal en el sentido clásico.) De paso, la distancia al hiperplano sale gratis:

$$d_H(x) = \|x - p\| = |t| \|a\| = \frac{|\langle a, x \rangle - b|}{\|a\|},$$

la fórmula de “distancia punto–plano” de la geometría analítica. Ejemplo numérico: para $H = \{y \in \mathbb{R}^3 : y_1 + y_2 + y_3 = 3\}$ (es decir, $a = (1, 1, 1)$, $b = 3$) y $x = 0$: $t = (0 - 3)/3 = -1$ y $\text{proy}_H(0) = 0 - (-1)(1, 1, 1) = (1, 1, 1)$, con $d_H(0) = \sqrt{3}$. Nota económica: un hiperplano $\langle p, y \rangle = w$ es una *recta presupuestaria* en $\mathbb{R}^n$; proyectar sobre él es encontrar la canasta que agota el presupuesto más parecida a una canasta dada.

8.6. Aplicaciones económicas de la proyección [P3]

8.6.1. MCO es una proyección ortogonal

Volvamos al Ejemplo 8.25 con otros ojos. El problema $\min_{\beta} \|y - X\beta\|^2$ puede leerse en dos espacios distintos:

- En el espacio de *parámetros* $\mathbb{R}^n$: buscamos el mejor vector de coeficientes β . Así lo resolvimos antes.
- En el espacio de *observaciones* $\mathbb{R}^m$: los vectores de la forma $X\beta$ recorren el subespacio

$$\text{col}(X) = \{X\beta : \beta \in \mathbb{R}^n\} \subseteq \mathbb{R}^m,$$

el *espacio de columnas* de X (todas las combinaciones lineales de los regresores). Entonces

$$\min_{\beta \in \mathbb{R}^n} \|y - X\beta\|^2 = \min_{v \in \text{col}(X)} \|y - v\|^2 :$$

¡estamos calculando la **proyección de y sobre $\text{col}(X)$** ! Un subespacio vectorial es un convexo cerrado, así que el Teorema 8.30 garantiza que el vector de *valores ajustados* $\hat{y} = X\hat{\beta}$ existe y es único (aunque $\hat{\beta}$ no sea único si hay colinealidad: la proyección $\hat{y}$ lo es siempre).

La caracterización (8.3) sobre un subespacio V se convierte en *ortogonalidad*: si $v \in V$ entonces también $p \pm v \in V$, y aplicando la desigualdad a $y' = p + v$ y a $y' = p - v$ se obtiene $\langle y - p, v \rangle \leq 0$ y $\langle y - p, v \rangle \geq 0$, es decir,

$$\langle y - \hat{y}, v \rangle = 0 \quad \text{para todo } v \in \text{col}(X).$$

Tomando como v cada columna de X : $X^\top(y - X\hat{\beta}) = 0$, que son *exactamente las ecuaciones normales* (8.2). En econometría esto se enuncia como “los residuos son ortogonales a los regresores” (y con constante en la regresión, suman cero). Con rango completo, $\hat{y} = X(X^\top X)^{-1}X^\top y = Py$, donde $P = X(X^\top X)^{-1}X^\top$ es la *matriz de proyección* o “matriz sombrero” (*hat matrix*), simétrica e idempotente ($P^2 = P$: proyectar dos veces es proyectar una). Toda la geometría de MCO (ajustados, residuos, R^2 como coseno al cuadrado del ángulo entre y centrado y su proyección) es el Teorema 8.30 en acción [2].

8.6.2. Racionamiento: la cesta factible más cercana a la deseada

Un consumidor desea la canasta $x^* \in \mathbb{R}^n$ (su óptimo sin restricciones adicionales), pero enfrenta *racionamiento*: cuotas máximas q_i para cada bien y no negatividad, de modo que su conjunto factible es la caja

$$C = [0, q_1] \times \cdots \times [0, q_n].$$

Si su criterio para elegir es minimizar la “distancia de malestar” cuadrática $\|x - x^*\|^2$ (una aproximación de segundo orden de la pérdida de utilidad alrededor del óptimo, vía Taylor), su elección es exactamente la proyección sobre la caja del Ejemplo 8.34:

$$x_i^{\text{elegido}} = \min\{\max\{x_i^*, 0\}, q_i\} :$$

consume lo deseado de los bienes no racionados y se “pega” a la cuota en los racionados. La no expansividad (Teorema 8.31) da un resultado de *estática comparativa* gratis: si el deseo x^* cambia poco, la elección racionada cambia a lo más en la misma magnitud. Y la misma lógica de “punto factible más cercano” aparece en las demostraciones del **segundo teorema del bienestar** [9]: para sostener un óptimo de Pareto como equilibrio se separa el conjunto (convexo) de asignaciones preferidas del conjunto factible, y el hiperplano separador (construido con la proyección, como vimos) entrega el vector de precios de soporte.

Resumen

Resumen del capítulo

Existencia. Weierstrass: continua + compacto $\Rightarrow$ el óptimo se alcanza. Sin compacidad: f continua y *coerciva* ($f \rightarrow +\infty$ cuando $\|x\| \rightarrow \infty$) alcanza mínimo global (Teorema 8.7). En economía: retornos crecientes $\Rightarrow$ el beneficio puede no tener máximo.

Primer orden. x^* mínimo local y f diferenciable $\Rightarrow \nabla f(x^*) = 0$ (Fermat, Teorema 8.9). Necesaria, no suficiente: hay sillars ($x^2 - y^2$) e inflexiones (x^3).

Segundo orden. Necesaria: en un mínimo local, $\nabla^2 f(x^*)$ es PSD (Teorema 8.12). Suficiente: $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*)$ PD $\Rightarrow$ mínimo local estricto (Teorema 8.13, vía Taylor + autovalor mínimo). PSD sin PD: el test no decide (x^4 vs. x^3).

Convexidad = licencia para la FOC. Si f es convexa: todo mínimo local es global (Teorema 8.19); $\arg \min f$ es convexo (Teorema 8.20); con convexidad estricta el minimizador es único (Teorema 8.21); y $\nabla f(x^*) = 0 \Leftrightarrow x^*$ mínimo global (Teorema 8.23). Sin di-

ferenciabilidad: $0 \in \partial f(x^*)$. Ejemplo estrella: MCO, ecuaciones normales $X^\top X\beta = X^\top y$, único con rango completo.

Distancia y proyección. $d_C(x) = \inf_{y \in C} \|x - y\|$; el ínfimo se alcanza si C es cerrado; d_C es convexa si C lo es. Sobre un convexo cerrado, la proyección existe, es única y se caracteriza por $\langle x - \text{proy}_C(x), y - \text{proy}_C(x) \rangle \leq 0$ para todo $y \in C$ (Teorema 8.30); es no expansiva (Teorema 8.31). Fórmulas: bola (encoger radialmente), caja e $\mathbb{R}_+^n$ (recortar componente a componente), hiperplano $(x - \frac{\langle a, x \rangle - b}{\|a\|^2} a)$. MCO es la proyección de y sobre $\text{col}(X)$; la separación del capítulo anterior y el segundo teorema del bienestar se apoyan en este teorema.

Referencias principales: [1] (cap. 3), [5] (cap. 2), [7] (cap. 1), [6] (cap. 3), [3].

Ejercicios tipo examen

Ejercicio 8.36 (Clasificación completa de puntos críticos). Encuentra y clasifica todos los puntos críticos de

$$f(x, y) = x^3 + y^3 - 3xy.$$

¿Tiene f mínimo global?

Solución. FOC. $\nabla f = (3x^2 - 3y, 3y^2 - 3x) = (0, 0)$ da el sistema $y = x^2, x = y^2$. Sustituyendo: $x = (x^2)^2 = x^4$, es decir, $x(x^3 - 1) = 0$, con soluciones reales $x = 0$ y $x = 1$. Puntos críticos: $(0, 0)$ y $(1, 1)$.

SOC. La Hessiana es $\nabla^2 f(x, y) = \begin{pmatrix} 6x & -3 \\ -3 & 6y \end{pmatrix}$.

- En $(0, 0)$: $\begin{pmatrix} 0 & -3 \\ -3 & 0 \end{pmatrix}$, con determinante $-9 < 0$. Una matriz simétrica 2×2 con determinante negativo tiene autovalores de signos opuestos (el determinante es su producto): *indefinida*. Por lo tanto $(0, 0)$ es un **punto de silla** (no puede ser mínimo por el Teorema 8.12 ni máximo por el resultado análogo).
- En $(1, 1)$: $\begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix}$, con menores líderes $6 > 0$ y $36 - 9 = 27 > 0$: definida positiva por Sylvester. Por el Teorema 8.13, $(1, 1)$ es un **mínimo local estricto**, con $f(1, 1) = 1 + 1 - 3 = -1$.

Globalidad. No hay mínimo global: a lo largo del eje x , $f(x, 0) = x^3 \rightarrow -\infty$ cuando $x \rightarrow -\infty$, así que $\inf f = -\infty$. (Observa que f no es coerciva ni convexa; el mínimo local en $(1, 1)$ es genuinamente solo local.) $\square$

Ejercicio 8.37 (Coercividad y existencia). Demuestra que $f(x, y) = x^4 + y^4 - 3xy$ es coerciva y concluye que alcanza un mínimo global en $\mathbb{R}^2$. (Sugerencia: acota $|xy|$ con $\frac{1}{2}(x^2 + y^2)$ y usa $t^4 \geq 2t^2 - 1$.)

Solución. Paso 1: dos desigualdades auxiliares. (i) De $(|x| - |y|)^2 \geq 0$ se obtiene $2|x||y| \leq x^2 + y^2$, luego $|xy| \leq \frac{1}{2}(x^2 + y^2)$ y por tanto $-3xy \geq -\frac{3}{2}(x^2 + y^2)$. (ii) De $(t^2 - 1)^2 \geq 0$ se obtiene $t^4 - 2t^2 + 1 \geq 0$, es decir, $t^4 \geq 2t^2 - 1$ para todo $t \in \mathbb{R}$.

Paso 2: cota inferior coerciva. Aplicando (ii) a x y a y , y luego (i):

$$f(x, y) \geq (2x^2 - 1) + (2y^2 - 1) - \frac{3}{2}(x^2 + y^2) = \frac{1}{2}(x^2 + y^2) - 2 = \frac{1}{2}\|(x, y)\|^2 - 2.$$

Cuando $\|(x, y)\| \rightarrow \infty$, el lado derecho tiende a $+\infty$, y por comparación $f(x, y) \rightarrow +\infty$: f es coerciva.

Paso 3: existencia. f es un polinomio, luego continua. Por el Teorema 8.7, f alcanza un mínimo global en $\mathbb{R}^2$. (Como complemento: la FOC $4x^3 = 3y$, $4y^3 = 3x$ tiene las soluciones $(0, 0)$ y $\pm(\sqrt{3}/2, \sqrt{3}/2)$; comparando valores, los mínimos globales son los dos puntos simétricos no nulos, y $(0, 0)$ es una silla.) $\square$

Ejercicio 8.38 (Cournot con costos cuadráticos). Dos firmas compiten a la Cournot con demanda inversa $p = a - (q_1 + q_2)$ y costos $C_i(q_i) = \frac{c}{2}q_i^2$, con $a, c > 0$. (a) Plantea el problema de la firma 1 dado q_2 , verifica que tiene solución y que la FOC la caracteriza. (b) Halla la mejor respuesta $BR_1(q_2)$. (c) Calcula el equilibrio de Nash simétrico.

Solución. (a) La firma 1 maximiza $\pi_1(q_1) = (a - q_1 - q_2)q_1 - \frac{c}{2}q_1^2$ sobre $q_1 \geq 0$. Es un polinomio cuadrático con coeficiente principal $-(1 + \frac{c}{2}) < 0$, así que $-\pi_1$ es coerciva y estrictamente convexa: el máximo existe y es único (Teoremas 8.7 y 8.21). Como $\pi_1''(q_1) = -(2 + c) < 0$ en todo punto, π_1 es estrictamente cóncava y, por el Teorema 8.23 aplicado a $-\pi_1$, la FOC caracteriza el máximo global (en el interior; en la esquina $q_1 = 0$ se verifica el signo de $\pi_1'(0) = a - q_2$).

(b) FOC: $\pi_1'(q_1) = a - 2q_1 - q_2 - cq_1 = 0$, de donde

$$BR_1(q_2) = \frac{a - q_2}{2 + c} \quad \text{si } q_2 \leq a, \quad BR_1(q_2) = 0 \quad \text{si } q_2 > a.$$

(c) Por simetría, $q_1 = q_2 = q^*$ con $q^* = \frac{a - q^*}{2 + c}$, es decir, $(2 + c)q^* = a - q^*$, luego

$$q^* = \frac{a}{3 + c}, \quad p^* = a - 2q^* = \frac{a(1 + c)}{3 + c}.$$

Comprobación de cordura: con $c = 0$ recuperamos el Cournot clásico $q^* = a/3$. La concavidad estricta en (a) es lo que valida todo el procedimiento: sin ella, “resolver la FOC” no identificaría la mejor respuesta. $\square$

Ejercicio 8.39 (Regresión con contracción (ridge)). Sea $a \in \mathbb{R}^n$ fijo y $\lambda > 0$. Considera

$$f(x) = \|x - a\|^2 + \lambda \|x\|^2.$$

(a) Demuestra que f es estrictamente convexa y coerciva. (b) Encuentra su único minimizador. (c) Interpreta el resultado cuando λ crece.

Solución. (a) Expandiendo, $f(x) = (1 + \lambda)\|x\|^2 - 2\langle a, x \rangle + \|a\|^2$. Su Hessiana es $\nabla^2 f(x) = 2(1 + \lambda)I$, con único autovalor $2(1 + \lambda) > 0$: definida positiva en todo punto, luego f es estrictamente convexa (caracterización de segundo orden del capítulo de funciones convexas). Coercividad: por Cauchy-Schwarz, $f(x) \geq (1 + \lambda)\|x\|^2 - 2\|a\|\|x\| \rightarrow +\infty$ cuando $\|x\| \rightarrow \infty$ (el término cuadrático domina al lineal).

(b) Existencia y unicidad: Teoremas 8.7 y 8.21. FOC (suficiente por convexidad, Teorema 8.23):

$$\nabla f(x) = 2(x - a) + 2\lambda x = 0 \implies (1 + \lambda)x = a \implies x^* = \frac{a}{1 + \lambda}.$$

(c) El minimizador es el objetivo a encogido hacia el origen por el factor $1/(1 + \lambda)$: cuando $\lambda \rightarrow 0$, $x^* \rightarrow a$ (sin penalización, quédate con a); cuando $\lambda \rightarrow \infty$, $x^* \rightarrow 0$ (la penalización domina). Es la lógica del estimador *ridge* de econometría, $\hat{\beta}_{\text{ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$: la penalización $\lambda \|\beta\|^2$ vuelve el problema estrictamente convexo (útil justo cuando $X^\top X$ es singular por colinealidad) y “contrae” los coeficientes hacia cero. $\square$

Ejercicio 8.40 (Cálculo de proyecciones). Calcula: (a) $\text{proy}_C(2, -1)$ para la caja $C = [0, 1] \times [0, 2]$; (b) $\text{proy}_H(1, 2, 3)$ para el hiperplano $H = \{y \in \mathbb{R}^3 : y_1 + 2y_2 + 2y_3 = 3\}$, y verifica la caracterización (8.3) en este caso; (c) $\text{proy}_B(3, 4)$ para la bola $B = \{y \in \mathbb{R}^2 : \|y\| \leq 1\}$.

Solución. (a) Componente a componente (Ejemplo 8.34): la primera coordenada $2 > 1$ se recorta a 1; la segunda $-1 < 0$ se recorta a 0. Luego $\text{proy}_C(2, -1) = (1, 0)$.

(b) Con $a = (1, 2, 2)$, $b = 3$, $x = (1, 2, 3)$: $\|a\|^2 = 1 + 4 + 4 = 9$ y $\langle a, x \rangle = 1 + 4 + 6 = 11$. Por (8.4), $t = (11 - 3)/9 = 8/9$ y

$$\text{proy}_H(x) = (1, 2, 3) - \frac{8}{9}(1, 2, 2) = \left(\frac{1}{9}, \frac{2}{9}, \frac{11}{9}\right).$$

Comprobación de factibilidad: $\frac{1}{9} + \frac{4}{9} + \frac{22}{9} = \frac{27}{9} = 3$. $\checkmark$ Verificación de (8.3): aquí $x - p = \frac{8}{9}a$, y para cualquier $y \in H$ se tiene $\langle a, y - p \rangle = \langle a, y \rangle - \langle a, p \rangle = 3 - 3 = 0$, luego $\langle x - p, y - p \rangle = \frac{8}{9} \langle a, y - p \rangle = 0 \leq 0$. $\checkmark$

(c) $\|(3, 4)\| = 5 > 1$, así que (Ejemplo 8.33) $\text{proy}_B(3, 4) = \frac{1}{5}(3, 4) = (3/5, 4/5)$, y la distancia de $(3, 4)$ a la bola es $5 - 1 = 4$. $\square$

Ejercicio 8.41 (La distancia es 1-Lipschitz). Sea $C \subseteq \mathbb{R}^n$ no vacío (no hace falta que sea convexo ni cerrado). Demuestra que la función distancia satisface

$$|d_C(x) - d_C(z)| \leq \|x - z\| \quad \text{para todos } x, z \in \mathbb{R}^n.$$

Concluye que d_C es continua en todo $\mathbb{R}^n$.

Solución. Sean $x, z \in \mathbb{R}^n$ y $\varepsilon > 0$. Por definición de ínfimo existe $y \in C$ con $\|z - y\| \leq d_C(z) + \varepsilon$. Como ese mismo y es candidato en el ínfimo que define $d_C(x)$, la desigualdad triangular da

$$d_C(x) \leq \|x - y\| \leq \|x - z\| + \|z - y\| \leq \|x - z\| + d_C(z) + \varepsilon.$$

Como $\varepsilon > 0$ es arbitrario, $d_C(x) - d_C(z) \leq \|x - z\|$. Intercambiando los papeles de x y z (el argumento es simétrico) se obtiene $d_C(z) - d_C(x) \leq \|z - x\| = \|x - z\|$. Las dos desigualdades juntas dan $|d_C(x) - d_C(z)| \leq \|x - z\|$.

Continuidad: dado $\varepsilon > 0$, basta tomar $\delta = \varepsilon$ en la definición: si $\|x - z\| < \delta$ entonces $|d_C(x) - d_C(z)| < \varepsilon$. (Una función Lipschitz es uniformemente continua.) Nota: compara con la

Proposición 8.28 y el Teorema 8.31: la *distancia* es 1-Lipschitz para cualquier C ; la *convexidad* de d_C y la no expansividad de proy_C sí requieren que C sea convexo. $\square$

Capítulo 9

Optimización con restricciones: Lagrange y las condiciones de Karush–Kuhn–Tucker [P1]

Semana 7 del cronograma. Bibliografía: Ruszczyński [6]; Nocedal y Wright [5], Cap. 12; Aragón et al. [1].

¿Para qué sirve esto en Microeconomía?

Este es, sin exagerar, **el capítulo más importante del cuaderno para tu curso de Microeconomía**: toda la microeconomía moderna es optimización con restricciones. En la teoría de la decisión individual (MWG, caps. 1–5), el consumidor resuelve el problema de maximización de utilidad (UMP), esto es, maximizar $u(x)$ sujeto a la restricción presupuestaria $p \cdot x \leq m$ y a $x \geq 0$, y su problema dual de minimización del gasto (EMP); la firma maximiza beneficios o minimiza costos sujeta a su restricción tecnológica (la función de producción). Cada demanda marshalliana o hicksiana que aparece en [9] o [10] es la solución de un sistema KKT. En los modelos de contratos e información asimétrica (MWG, caps. 13–14), el principal maximiza su beneficio esperado sujeto a la *restricción de participación* (IR, *individual rationality*) y a la *restricción de compatibilidad de incentivos* (IC, *incentive compatibility*); el análisis de qué restricción “muere” en el óptimo (¿la IR se satura?, ¿cuáles IC son relevantes?) es **exactamente** el análisis de holgura complementaria de KKT que hacen Holmström en riesgo moral o Baron–Myerson en regulación con información asimétrica. En diseño de mecanismos y subastas (MWG, cap. 23), el mecanismo óptimo de Myerson resuelve un problema con un *continuo* de restricciones IC (una por cada par de tipos), y la técnica estándar consiste en identificar cuáles se saturan (las “locales”) y descartar las demás: de nuevo, análisis de casos KKT. Finalmente, los multiplicadores de Lagrange son *precios sombra*: la utilidad marginal del ingreso en la UMP, el costo marginal en el problema de la firma, el costo para el principal de mejorar la utilidad de reserva del agente. Saber (i) escribir el lagrangiano con los signos correctos, (ii) listar las condiciones KKT completas, (iii) organizar el análisis por casos según qué restricciones están activas, y (iv) leer los multiplicadores económicamente, es **la** destreza

operativa del curso de micro. Dedícale a este capítulo el tiempo que haga falta.

En el capítulo 8 aprendimos a resolver $\min_{x \in \mathbb{R}^n} f(x)$ sin restricciones: la condición de primer orden es $\nabla f(x^*) = 0$. Pero casi ningún problema económico es así: el consumidor no puede gastar más que su ingreso, la firma no puede producir sin insumos, las cantidades no pueden ser negativas. Este capítulo desarrolla la teoría de optimalidad cuando hay restricciones: primero la geometría (conos tangente y normal), luego el teorema clásico de Lagrange para restricciones de igualdad, y finalmente el teorema central del curso: las **condiciones de Karush–Kuhn–Tucker (KKT)**, con su demostración vía el lema de Farkas que probamos en el capítulo de separación. Cerramos con un manual de resolución paso a paso y una batería de ejemplos económicos resueltos con todo detalle. Referencias principales: [1] (caps. 3–4), [6] (cap. 3), [2] (cap. 5), [5] (cap. 12) y el apéndice M de [9].

9.1. El problema general y las convenciones de signos [P1]

9.1.1. El problema no lineal estándar

Definición 9.1 (Problema no lineal con restricciones). Sean $f, g_1, \dots, g_m, h_1, \dots, h_p : \mathbb{R}^n \rightarrow \mathbb{R}$ funciones (que supondremos diferenciables cuando haga falta). El *problema no lineal (nonlinear programming problem, NLP) en forma estándar* es

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sueto a} \quad & g_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{9.1}$$

La función f se llama *función objetivo (objective function)*; las g_i son las *restricciones de desigualdad (inequality constraints)* y las h_j las *restricciones de igualdad (equality constraints)*. El conjunto

$$X = \{ x \in \mathbb{R}^n : g_i(x) \leq 0 \ \forall i, \ h_j(x) = 0 \ \forall j \}$$

se llama *conjunto factible (feasible set)*, y sus elementos son los *puntos factibles*. Un punto $x^* \in X$ es un *mínimo global* si $f(x^*) \leq f(x)$ para todo $x \in X$, y un *mínimo local* si existe $\varepsilon > 0$ tal que $f(x^*) \leq f(x)$ para todo $x \in X$ con $\|x - x^*\| < \varepsilon$.

Observación 9.2. Antes de buscar condiciones de optimalidad conviene recordar *cuándo existe* un óptimo: por el teorema de Weierstrass (capítulo 1), si f es continua y X es compacto (cerrado y acotado) y no vacío, el mínimo global existe. En los problemas económicos típicos (conjunto presupuestario con precios positivos e ingreso finito) el conjunto factible es compacto, así que la existencia está garantizada y el trabajo real es *caracterizar* el óptimo. Las condiciones de este capítulo hacen precisamente eso.

9.1.2. Restricciones activas e inactivas

Definición 9.3 (Restricción activa). Sea $x \in X$ un punto factible del problema (9.1). Decimos que la restricción de desigualdad g_i está *activa (active o binding)*; en la jerga económica, que

“muerde” o “se satura”) en x si

$$g_i(x) = 0,$$

y que está *inactiva* (*inactive* o *slack*, “con holgura”) si $g_i(x) < 0$. El conjunto de índices activos en x es

$$A(x) = \{i \in \{1, \dots, m\} : g_i(x) = 0\}.$$

Las restricciones de igualdad están, por definición, siempre activas en todo punto factible.

Intuición

La distinción activa/inactiva es la idea organizadora de todo el capítulo. Si $g_i(x^*) < 0$ en el óptimo, entonces cerca de x^* la restricción i ni se entera de lo que hacemos: hay una bolita alrededor de x^* donde g_i sigue siendo negativa (por continuidad), así que *localmente* es como si esa restricción no existiera. Solo las restricciones activas pueden “empujar” al óptimo lejos de donde estaría sin ellas. Ejemplo económico: si el consumidor tiene ingreso de sobra y no lo gasta todo, la restricción presupuestaria está inactiva y su “precio” (el multiplicador, como veremos) es cero; si gasta hasta el último sol, la restricción muerde y el ingreso adicional tiene valor marginal positivo. Todo el análisis KKT consiste en averiguar, caso por caso, *qué subconjunto de restricciones está activo en el óptimo*.

9.1.3. Convenciones de signos: cómo traducir entre libros

Aquí está la fuente número uno de errores cuando un estudiante pasa de un libro de optimización (que minimiza con ≤ 0) a un libro de microeconomía como [9] (que maximiza con $\geq$). Detengámonos con calma.

El problema (9.1) es una *convención*, no una restricción de la teoría. Cualquier problema de optimización se puede llevar a esa forma con las siguientes traducciones mecánicas:

- (I) **Maximizar** $\leftrightarrow$ **minimizar**. Maximizar f es lo mismo que minimizar $-f$, y los puntos óptimos coinciden:

$$\arg \max_{x \in X} f(x) = \arg \min_{x \in X} (-f(x)), \quad \max_{x \in X} f(x) = -\min_{x \in X} (-f(x)).$$

- (II) **Desigualdades** $\geq \leftrightarrow \leq$. La restricción $g(x) \geq 0$ equivale a $-g(x) \leq 0$. La restricción $g(x) \leq b$ equivale a $g(x) - b \leq 0$.

- (III) **Igualdades como pares de desigualdades**. $h(x) = 0$ equivale al par $h(x) \leq 0$ y $-h(x) \leq 0$. (Esto es útil en demostraciones; en la práctica las igualdades se tratan directamente con multiplicadores sin signo, como veremos.)

- (IV) **No negatividad**. La restricción $x_k \geq 0$ es simplemente la desigualdad $g(x) = -x_k \leq 0$, con gradiente $\nabla g = -e_k$ (menos el k -ésimo vector canónico). No es una restricción “especial”: entra al sistema KKT como cualquier otra.

Por ejemplo, el problema del consumidor tal como aparece en [9],

$$\max_{x \in \mathbb{R}^n} u(x) \quad \text{s.a.} \quad p \cdot x \leq m, \quad x \geq 0,$$

se escribe en forma estándar (9.1) como

$$\min_{x \in \mathbb{R}^n} -u(x) \quad \text{s.a.} \quad g_0(x) = p \cdot x - m \leq 0, \quad g_k(x) = -x_k \leq 0 \quad (k = 1, \dots, n).$$

Cuidado (error común)

Los signos de los multiplicadores dependen de la convención. Este es el error más frecuente en exámenes. Grábate la regla y de dónde sale:

- En la forma estándar (**min** con $g_i \leq 0$), el lagrangiano es $L = f + \sum_i \mu_i g_i$ y los multiplicadores de desigualdad cumplen $\mu_i \geq 0$.
- En la forma “de economista” (**max** con $g_i(x) \leq 0$, p.ej. $p \cdot x - m \leq 0$), el lagrangiano se escribe $L = f - \sum_i \lambda_i g_i$ (¡con signo menos!) y de nuevo $\lambda_i \geq 0$. Ambas recetas son la misma: maximizar f es minimizar $-f$, y $(-f) + \sum \lambda_i g_i = -(f - \sum \lambda_i g_i)$.
- Si escribes la restricción como $\geq$ ($u(x) \geq \bar{u}$, típico en el EMP o en una restricción de participación dentro de un problema de *maximización*), conviértela primero a $\leq$ ($\bar{u} - u(x) \leq 0$) o, equivalentemente, súmala con signo $+$: $L = f + \lambda(u(x) - \bar{u})$ con $\lambda \geq 0$.
- Los multiplicadores de las restricciones de *igualdad* no tienen signo restringido en ninguna convención.

La forma segura de no equivocarse jamás: *convierte todo a la forma estándar (9.1) antes de escribir el lagrangiano*, aplica KKT tal cual, y al final traduce de vuelta. Con práctica podrás trabajar directamente en la forma max, pero mientras tanto la conversión mecánica te salva. Un chequeo infalible de coherencia: en el óptimo, el multiplicador de una restricción de recurso ($p \cdot x \leq m$) debe salir ≥ 0 y debe poder interpretarse como el valor marginal del recurso; si te sale negativo, te comiste un signo.

Ejemplo 9.4 (Traducción completa de convenciones). El problema de minimización del gasto (EMP) de [9] es

$$\min_{x \geq 0} p \cdot x \quad \text{s.a.} \quad u(x) \geq \bar{u}.$$

Escribámoslo en forma estándar: el objetivo ya es un mínimo, $f(x) = p \cdot x$. Las restricciones: $u(x) \geq \bar{u}$ se convierte en $g_0(x) = \bar{u} - u(x) \leq 0$, y $x_k \geq 0$ en $g_k(x) = -x_k \leq 0$. El lagrangiano estándar es

$$L(x, \mu) = p \cdot x + \mu_0 (\bar{u} - u(x)) - \sum_{k=1}^n \mu_k x_k, \quad \mu_0, \mu_1, \dots, \mu_n \geq 0.$$

La condición de estacionariedad en la coordenada k es $p_k - \mu_0 \partial u / \partial x_k - \mu_k = 0$. En una solución interior ($x_k > 0$, luego $\mu_k = 0$ por holgura complementaria, como veremos) queda $p_k = \mu_0 \partial u / \partial x_k$: el precio del bien es igual a su utilidad marginal valorada al precio sombra μ_0 de la restricción de utilidad, que es exactamente el inverso de la utilidad marginal del ingreso. Compara: en muchos textos de micro verás $L = p \cdot x - \lambda(u(x) - \bar{u})$; es *el mismo* lagrangiano con $\lambda = \mu_0 \geq 0$.

9.2. Geometría de la optimalidad: conos tangente y normal [P1]

Antes de cualquier teorema, construyamos la imagen mental. Toda la teoría KKT es la formalización de un dibujo en 2D que debes poder reproducir con los ojos cerrados.

9.2.1. La imagen en dos dimensiones

Considera mín $f(x_1, x_2)$ sujeto a una sola restricción $g(x_1, x_2) \leq 0$, y supón que en el candidato a óptimo x^* la restricción está *activa*: $g(x^*) = 0$, es decir, x^* está en la frontera de la región factible.

Recuerda del capítulo 8 dos hechos sobre gradientes:

- $-\nabla f(x^*)$ es la dirección de *máximo descenso* de f : moverse un poquito en una dirección d reduce f si y solo si $\langle \nabla f(x^*), d \rangle < 0$ (a primer orden).
- $\nabla g(x^*)$ es perpendicular a la curva de nivel $\{g = 0\}$ y apunta hacia donde g *crece*, es decir, hacia *afuera* de la región factible $\{g \leq 0\}$.

Ahora razona: si x^* es un mínimo local, no debe existir ninguna dirección que sea a la vez *factible* (que no nos saque de la región) y *de descenso* (que reduzca f). Las direcciones factibles en x^* son, a primer orden, las que forman ángulo obtuso o recto con $\nabla g(x^*)$ (las que no aumentan g): $\langle \nabla g(x^*), d \rangle \leq 0$. Las de descenso son las que forman ángulo obtuso con $\nabla f(x^*)$. Que no haya intersección entre ambos conjuntos de direcciones fuerza a que $-\nabla f(x^*)$ y $\nabla g(x^*)$ apunten en *la misma dirección*:

$$-\nabla f(x^*) = \mu \nabla g(x^*) \quad \text{para algún } \mu \geq 0, \quad \text{es decir,} \quad \nabla f(x^*) + \mu \nabla g(x^*) = 0. \quad (9.2)$$

Geométricamente: en el óptimo, *la curva de nivel de f es tangente a la frontera de la región factible*, y los dos gradientes son colineales con el signo correcto.




Figura 9.1: Una restricción activa: en el óptimo x^* , la curva de nivel de f (líneas discontinuas) es tangente a la frontera $\{g = 0\}$ y $-\nabla f(x^*)$ es un múltiplo no negativo de $\nabla g(x^*)$. El mínimo sin restricciones queda fuera de la región factible.

¿Y si hay *dos* restricciones activas, $g_1(x^*) = g_2(x^*) = 0$ (el óptimo está en una “esquina” de la región factible)? Entonces ya no hace falta tangencia exacta con ninguna de las dos fronteras: basta con que $-\nabla f(x^*)$ quede “atrapado” *entre* los dos gradientes, es decir, en el cono que generan:

$$-\nabla f(x^*) = \mu_1 \nabla g_1(x^*) + \mu_2 \nabla g_2(x^*), \quad \mu_1, \mu_2 \geq 0. \quad (9.3)$$

Si $-\nabla f(x^*)$ se saliera de ese cono, habría una dirección que entra a la región factible y a la vez desciende f , y x^* no sería óptimo.




Figura 9.2: Dos restricciones activas (solución de esquina): la optimalidad exige que $-\nabla f(x^*)$ esté en el cono generado por $\nabla g_1(x^*)$ y $\nabla g_2(x^*)$ (región sombreada). Ya no hay tangencia con ninguna frontera individual.

Las ecuaciones (9.2) y (9.3) *ya son* las condiciones KKT; el resto del capítulo las enuncia en general, las demuestra y las explota. Pero para hacerlo con rigor necesitamos dos objetos del capítulo 3 adaptados a este contexto: el cono de direcciones que “no salen” de la región factible (cono tangente) y su cono polar (cono normal).

9.2.2. Direcciones factibles y de descenso

Definición 9.5 (Dirección de descenso). Sea f diferenciable en x . Un vector $d \in \mathbb{R}^n$ es una *dirección de descenso* (*descent direction*) de f en x si $\langle \nabla f(x), d \rangle < 0$.

Por la expansión de Taylor de primer orden, si d es de descenso entonces $f(x + td) = f(x) + t \langle \nabla f(x), d \rangle + o(t) < f(x)$ para todo $t > 0$ suficientemente pequeño: moverse un poco en la dirección d estrictamente reduce el valor de f .

Definición 9.6 (Cono de direcciones factibles). Sea $X \subseteq \mathbb{R}^n$ y $x \in X$. Un vector $d \in \mathbb{R}^n$ es una *dirección factible* (*feasible direction*) de X en x si existe $\bar{t} > 0$ tal que $x + td \in X$ para todo $t \in [0, \bar{t}]$. El conjunto de direcciones factibles en x , que denotamos $D_X(x)$, es un cono (si d es factible, αd también lo es para $\alpha > 0$).

Con estas dos nociones ya podemos enunciar el principio básico, que es una generalización inmediata del argumento del capítulo 8:

Proposición 9.7 (No hay direcciones factibles de descenso en un mínimo local). *Si x^* es un mínimo local de f sobre X y f es diferenciable en x^* , entonces*

$$\langle \nabla f(x^*), d \rangle \geq 0 \quad \text{para toda } d \in D_X(x^*).$$

Demostración. Sea $d \in D_X(x^*)$. Entonces $x^* + td \in X$ para $t \in [0, \bar{t}]$, y como x^* es mínimo local, $f(x^* + td) \geq f(x^*)$ para $t > 0$ pequeño. Por lo tanto

$$\langle \nabla f(x^*), d \rangle = \lim_{t \downarrow 0} \frac{f(x^* + td) - f(x^*)}{t} \geq 0. \quad \square$$

El problema con $D_X(x)$ es que puede ser demasiado pequeño cuando la frontera de X es *curva*. Con el disco $X = \{x \in \mathbb{R}^2 : x_1^2 + x_2^2 \leq 1\}$ y $x = (1, 0)$ todavía nos va bien: el disco es convexo, así que todo segmento que apunta hacia adentro se queda en X y $D_X(x)$ es un semiplano razonable. Pero cambia el disco por la *circunferencia* $X = \{x_1^2 + x_2^2 = 1\}$ y el desastre es total: ningún segmento recto se queda sobre la curva, de modo que $D_X(x) = \{0\}$ y la proposición 9.7 no dice absolutamente nada. Como toda restricción de igualdad produce exactamente esa patología, necesitamos un cono más generoso, que admita acercamientos por *curvas* y no solo por segmentos rectos: el cono tangente.

9.2.3. El cono tangente

Definición 9.8 (Cono tangente). Sea $X \subseteq \mathbb{R}^n$ y $x \in X$. Un vector $d \in \mathbb{R}^n$ es una *dirección tangente* a X en x si existen una sucesión de puntos $(x^k)_{k \in \mathbb{N}} \subseteq X$ y una sucesión de escalares $t_k \downarrow 0$ (positivos y convergentes a cero) tales que

$$x^k \rightarrow x \quad \text{y} \quad \frac{x^k - x}{t_k} \rightarrow d.$$

El conjunto de todas las direcciones tangentes se llama *cono tangente* (*tangent cone*, o cono de Bouligand) de X en x y se denota $T_X(x)$.

La definición dice: d es tangente si podemos acercarnos a x *desde adentro de X* a lo largo de una trayectoria (discreta) cuya dirección límite es d . No exige que el segmento $x + td$ esté en X : basta con que haya puntos factibles “asintóticamente alineados” con d .

Proposición 9.9 (Propiedades básicas del cono tangente). *Para todo X y $x \in X$: (i) $T_X(x)$ es un cono cerrado que contiene a 0; (ii) $D_X(x) \subseteq T_X(x)$; (iii) si $x \in \text{int } X$, entonces $T_X(x) = \mathbb{R}^n$; (iv) si X es convexo, entonces $T_X(x) = \text{cl}\{\alpha(y - x) : y \in X, \alpha \geq 0\}$, la clausura del cono generado por las direcciones hacia otros puntos de X .*

Demostración (esbozo). (i) $0 \in T_X(x)$ tomando $x^k = x$. Si $d \in T_X(x)$ y $\alpha > 0$, las mismas sucesiones con $t'_k = t_k/\alpha$ dan $\alpha d \in T_X(x)$; la cerradura se obtiene con un argumento diagonal estándar. (ii) Si $d \in D_X(x)$, toma $t_k = \bar{t}/k$ y $x^k = x + t_k d \in X$; entonces $(x^k - x)/t_k = d$ exactamente. (iii) Si x es interior, para cualquier d los puntos $x + t_k d$ están en X para t_k pequeño. (iv) Si X es convexo e $y \in X$, el segmento $x + t(y - x)$ está en X para $t \in [0, 1]$, así que $y - x \in D_X(x) \subseteq T_X(x)$; con (i) se obtiene “ $\supseteq$ ”. La inclusión recíproca sale directamente de la definición: si $(x^k - x)/t_k \rightarrow d$ con $x^k \in X$, cada cociente es un múltiplo positivo de $x^k - x$ con $x^k \in X$, luego d está en la clausura del cono descrito. Detalles en [6], sec. 3.1. $\square$

Ejemplo 9.10 (Conos tangentes calculados). Calculemos $T_X(x)$ con la definición en tres casos que reaparecerán todo el tiempo.

(a) *El ortante no negativo en el origen.* $X = \mathbb{R}_+^2 = \{x : x_1 \geq 0, x_2 \geq 0\}$, $x = (0, 0)$. Afirmamos que $T_X(0) = \mathbb{R}_+^2$. Si $d \geq 0$, entonces $x^k = t_k d \in X$ para cualquier $t_k \downarrow 0$ y $(x^k - 0)/t_k = d$, luego $d \in T_X(0)$. Recíprocamente, si $d \in T_X(0)$, entonces $d = \lim(x^k - 0)/t_k$ con $x^k \in \mathbb{R}_+^2$ y $t_k > 0$; cada cociente tiene ambas coordenadas ≥ 0 , y el límite de números no negativos es no negativo, así que $d \geq 0$. Conclusión: en una esquina del ortante, las direcciones tangentes son exactamente las que no vuelven negativa ninguna coordenada.

(b) *El ortante en un punto con una coordenada positiva.* $X = \mathbb{R}_+^2$, $x = (a, 0)$ con $a > 0$. Ahora la restricción $x_1 \geq 0$ está *inactiva* y no estorba: $T_X(x) = \mathbb{R} \times \mathbb{R}_+ = \{d : d_2 \geq 0\}$. La primera coordenada de d puede ser cualquiera porque para t_k pequeño, $a + t_k d_1$ sigue siendo positivo. Observa el patrón: *solo las restricciones activas restringen el cono tangente*.

(c) *Una circunferencia (restricción de igualdad).* $X = \{x \in \mathbb{R}^2 : x_1^2 + x_2^2 = 1\}$, $x = (1, 0)$. Aquí $D_X(x) = \{0\}$ (ningún segmento recto se queda en la circunferencia), pero el cono tangente es la recta tangente: $T_X(x) = \{d : d_1 = 0\} = \{0\} \times \mathbb{R}$. Verifiquemos la inclusión “ $\supseteq$ ” con la definición: sea $d = (0, \delta)$. Toma $x^k = (\cos(\delta/k), \sin(\delta/k)) \in X$ y $t_k = 1/k$. Entonces $x^k \rightarrow (1, 0)$ y

$$\frac{x^k - x}{t_k} = \left(k(\cos(\delta/k) - 1), k \sin(\delta/k) \right) \rightarrow (0, \delta) = d,$$

usando $\cos \varepsilon - 1 = O(\varepsilon^2)$ y $\sin \varepsilon \approx \varepsilon$. Para “ $\subseteq$ ”: si $(x^k - x)/t_k \rightarrow d$, de $\|x^k\| = \|x\| = 1$ sale $0 = \|x^k\|^2 - \|x\|^2 = 2 \langle x, x^k - x \rangle + \|x^k - x\|^2$; dividiendo por t_k y pasando al límite (el segundo término es $o(t_k)$ porque $\|x^k - x\|/t_k \rightarrow \|d\|$ y $\|x^k - x\| \rightarrow 0$), queda $\langle x, d \rangle = d_1 = 0$. Este cálculo ilustra por qué la definición con sucesiones es la correcta: captura las direcciones a lo largo de la *curva*, que es lo que necesitan las restricciones de igualdad.

Con el cono tangente, la proposición 9.7 se refuerza:

Teorema 9.11 (Condición necesaria geométrica de primer orden). *Si x^* es un mínimo local de f sobre X y f es diferenciable en x^* , entonces*

$$\langle \nabla f(x^*), d \rangle \geq 0 \quad \text{para toda } d \in T_X(x^*). \quad (9.4)$$

Demostración. Sea $d \in T_X(x^*)$, con sucesiones $x^k \in X$, $x^k \rightarrow x^*$, $t_k \downarrow 0$, $(x^k - x^*)/t_k \rightarrow d$. Como x^* es mínimo local y $x^k \rightarrow x^*$ con $x^k \in X$, para k grande vale $f(x^k) \geq f(x^*)$. Por diferenciability,

$$0 \leq f(x^k) - f(x^*) = \langle \nabla f(x^*), x^k - x^* \rangle + o(\|x^k - x^*\|).$$

Dividimos entre $t_k > 0$:

$$0 \leq \left\langle \nabla f(x^*), \frac{x^k - x^*}{t_k} \right\rangle + \frac{o(\|x^k - x^*\|)}{\|x^k - x^*\|} \cdot \frac{\|x^k - x^*\|}{t_k}.$$

El primer término tiende a $\langle \nabla f(x^*), d \rangle$; en el segundo, el primer factor tiende a 0 y el segundo a $\|d\|$ (finito), así que todo el segundo término tiende a 0. (Si $x^k = x^*$ para infinitos k , entonces $d = 0$ y no hay nada que probar.) Tomando límite, $\langle \nabla f(x^*), d \rangle \geq 0$. $\square$

9.2.4. El cono normal y la condición $-\nabla f(x^*) \in N_X(x^*)$

La condición (9.4) dice que $\nabla f(x^*)$ forma ángulo no obtuso con *todas* las direcciones tangentes. Eso es exactamente decir que $-\nabla f(x^*)$ pertenece al cono *polar* del cono tangente. Este polar merece nombre propio; ya lo encontraste en el capítulo 7 para conjuntos convexos, y aquí lo usamos en esa misma versión.

Definición 9.12 (Cono normal). Sea $X \subseteq \mathbb{R}^n$ y $x \in X$. El *cono normal* (*normal cone*) de X en x es el polar del cono tangente:

$$N_X(x) = (T_X(x))^\circ = \{v \in \mathbb{R}^n : \langle v, d \rangle \leq 0 \quad \forall d \in T_X(x)\}.$$

Cuando X es convexo, esta definición coincide (por la proposición 9.9(iv)) con la del capítulo 7:

$$N_X(x) = \{v \in \mathbb{R}^n : \langle v, y - x \rangle \leq 0 \quad \forall y \in X\}.$$

Ejemplo 9.13. De los cálculos del ejemplo 9.10: (a) $N_{\mathbb{R}_+^2}(0) = -\mathbb{R}_+^2 = \mathbb{R}_-^2$ (los vectores con ambas coordenadas ≤ 0); (b) en $x = (a, 0)$ con $a > 0$, $N_{\mathbb{R}_+^2}(x) = \{0\} \times \mathbb{R}_-$ (solo se puede “apuntar hacia afuera” por la restricción activa); (c) para la circunferencia en $(1, 0)$, $N_X(x) = \mathbb{R} \times \{0\}$, *toda* la recta normal (con ambos signos), reflejando que una igualdad restringe por los dos lados. En un punto interior, $T_X(x) = \mathbb{R}^n$ y $N_X(x) = \{0\}$: la condición $-\nabla f(x^*) \in N_X(x^*)$ colapsa a $\nabla f(x^*) = 0$, la condición sin restricciones del capítulo 8. Todo cuadra.

Teorema 9.14 (Condición geométrica; necesaria siempre, suficiente en el caso convexo). Sea f diferenciable en $x^* \in X$.

- (a) Si x^* es un mínimo local de f sobre X , entonces $-\nabla f(x^*) \in N_X(x^*)$.
- (b) Si además X es convexo y f es convexa, la condición es también suficiente: si $-\nabla f(x^*) \in N_X(x^*)$, entonces x^* es mínimo global de f sobre X .

Demostración. (a) Es una reformulación del teorema 9.11: para toda $d \in T_X(x^*)$ vale $\langle \nabla f(x^*), d \rangle \geq 0$, es decir, $\langle -\nabla f(x^*), d \rangle \leq 0$; por definición de polar, $-\nabla f(x^*) \in (T_X(x^*))^\circ = N_X(x^*)$.

(b) Sea $y \in X$ arbitrario. Como X es convexo, $y - x^* \in T_X(x^*)$ (proposición 9.9(iv)), y la hipótesis $-\nabla f(x^*) \in N_X(x^*)$ da

$$\langle \nabla f(x^*), y - x^* \rangle \geq 0.$$

Como f es convexa y diferenciable, su gráfica queda por encima de su plano tangente (desigualdad del gradiente, capítulo de funciones convexas):

$$f(y) \geq f(x^*) + \langle \nabla f(x^*), y - x^* \rangle \geq f(x^*).$$

Como $y \in X$ era arbitrario, x^* es mínimo global. □

Intuición

El teorema 9.14 es *toda* la teoría de optimización con restricciones comprimida en una línea: **en el óptimo, menos el gradiente del objetivo debe ser una “normal exterior” a la región factible**. Si $-\nabla f(x^*)$ tuviera una componente que apunta hacia adentro de X (o a lo largo de X), podríamos movernos un poco en esa dirección sin salirnos y reducir f . La fuerza que “empuja” hacia abajo del objetivo ($-\nabla f$) debe estar exactamente compensada por las “paredes” de la región factible, y las paredes solo pueden empujar en la dirección de sus normales. Lo que harán Lagrange y KKT es darle a esta condición geométrica una forma *algebraica computable*: expresar $N_X(x^*)$ en términos de los gradientes de las restricciones activas. Todo el asunto de las cualificaciones de restricciones (sección 9.4) es precisamente cuándo esa expresión algebraica del cono normal es correcta.

9.3. El teorema de Lagrange: restricciones de igualdad [P1]

Empezamos por el caso históricamente primero y técnicamente más limpio: solo restricciones de igualdad. Es el que usarás cuando la teoría económica te garantice de antemano que las restricciones se saturan (por ejemplo, preferencias monótonas $\Rightarrow$ la restricción presupuestaria se cumple con igualdad).

Definición 9.15 (Lagrangiano y punto regular). Para el problema $\min f(x)$ s.a. $h_j(x) = 0$, $j = 1, \dots, p$, con f, h_j de clase $\mathcal{C}^1$, la *función lagrangiana* (o *lagrangiano*) es

$$L(x, \lambda) = f(x) + \sum_{j=1}^p \lambda_j h_j(x), \quad \lambda = (\lambda_1, \dots, \lambda_p) \in \mathbb{R}^p.$$

Los escalares λ_j se llaman *multiplicadores de Lagrange*. Un punto factible x es *regular* si los gradientes de las restricciones son linealmente independientes en x :

$$\text{rango}(\nabla h_1(x), \dots, \nabla h_p(x)) = p.$$

Teorema 9.16 (Lagrange, 1788). Sea x^* un mínimo (o máximo) local de f sujeto a $h_j(x) = 0$, $j = 1, \dots, p$, con $f, h_j \in \mathcal{C}^1$ en un entorno de x^* . Si x^* es un punto regular, entonces existe un único vector de multiplicadores $\lambda^* \in \mathbb{R}^p$ tal que

$$\nabla_x L(x^*, \lambda^*) = \nabla f(x^*) + \sum_{j=1}^p \lambda_j^* \nabla h_j(x^*) = 0. \quad (9.5)$$

Es decir: $\nabla f(x^*)$ es combinación lineal de los gradientes de las restricciones. Los multiplicadores λ_j^* no tienen restricción de signo.

Demostración (esquema detallado vía función implícita). La idea es reducir el problema restringido a uno *sin* restricciones sobre una parametrización local de la superficie factible, y aplicar allí la condición $\nabla = 0$ del capítulo 8.

Paso 1: parametrizar la superficie factible. Sea $M = \{x : h(x) = 0\}$ con $h = (h_1, \dots, h_p) : \mathbb{R}^n \rightarrow \mathbb{R}^p$. Por regularidad, la matriz jacobiana $Dh(x^*) \in \mathbb{R}^{p \times n}$ tiene rango p ; reordenando coordenadas, podemos escribir $x = (y, z)$ con $y \in \mathbb{R}^{n-p}$, $z \in \mathbb{R}^p$, de modo que el bloque $D_z h(x^*) \in \mathbb{R}^{p \times p}$ sea invertible. El *teorema de la función implícita* (capítulo 1) garantiza entonces que, cerca de x^* , la superficie M es la gráfica de una función $\mathcal{C}^1$: existe $\varphi : U \subseteq \mathbb{R}^{n-p} \rightarrow \mathbb{R}^p$ con

$$h(y, \varphi(y)) = 0 \quad \forall y \in U, \quad x^* = (y^*, \varphi(y^*)).$$

Derivando la identidad $h(y, \varphi(y)) \equiv 0$ con la regla de la cadena: $D_y h + D_z h \cdot D\varphi(y^*) = 0$, o sea $D\varphi(y^*) = -(D_z h)^{-1} D_y h$ (todo evaluado en x^*).

Paso 2: optimizar sin restricciones en los parámetros. La función $F(y) = f(y, \varphi(y))$ tiene un mínimo local *sin restricciones* en y^* (porque los puntos $(y, \varphi(y))$ recorren exactamente los factibles cercanos). Luego $\nabla F(y^*) = 0$, y por la regla de la cadena:

$$0 = \nabla_y f + (D\varphi(y^*))^\top \nabla_z f = \nabla_y f - (D_y h)^\top (D_z h)^{-\top} \nabla_z f.$$

Paso 3: leer los multiplicadores. Define $\lambda^* = -(D_z h)^{-\top} \nabla_z f \in \mathbb{R}^p$. La ecuación del paso 2 dice $\nabla_y f + (D_y h)^\top \lambda^* = 0$, y la definición de λ^* dice $\nabla_z f + (D_z h)^\top \lambda^* = 0$. Juntas, estas dos son exactamente (9.5) escrita por bloques: $\nabla f(x^*) + Dh(x^*)^\top \lambda^* = 0$. La *unicidad* de λ^* sale de la independencia lineal de los $\nabla h_j(x^*)$: si dos vectores de multiplicadores funcionaran, su diferencia daría una combinación lineal nula no trivial de los gradientes. Detalles completos en [1] o [5], cap. 12. $\square$

Observación 9.17 (Lectura geométrica). El conjunto de direcciones tangentes a $M = \{h = 0\}$ en un punto regular es el núcleo del jacobiano, $T_M(x^*) = \{d : Dh(x^*)d = 0\}$ (la demostración de esta igualdad es esencialmente el paso 1 anterior: la función implícita permite construir curvas factibles con cualquier velocidad inicial del núcleo). La condición (9.4) exige $\langle \nabla f(x^*), d \rangle \geq 0$ en un subespacio, que al ser simétrico (d y $-d$ tangentes) fuerza $\langle \nabla f(x^*), d \rangle = 0$: el gradiente del objetivo es *ortogonal al espacio tangente*. Y el complemento ortogonal del núcleo de Dh es la imagen de $Dh^\top$, es decir, el espacio generado por los ∇h_j . Eso es (9.5). Nota que aquí el “cono” normal es todo un subespacio (por eso los λ_j no tienen signo), mientras que con desigualdades será un cono genuino y aparecerán los signos $\mu_i \geq 0$.

9.3.1. El ejemplo canónico: Cobb–Douglas con presupuesto

Ejemplo 9.18 (UMP Cobb–Douglas por Lagrange, paso a paso). Resolvamos el problema favorito de todos los cursos de micro:

$$\max_{x, y > 0} u(x, y) = x^\alpha y^\beta \quad \text{s.a.} \quad px + qy = m,$$

con $\alpha, \beta > 0$, precios $p, q > 0$ e ingreso $m > 0$. (Trabajamos con la restricción en igualdad: como u es estrictamente creciente en ambos bienes, en el óptimo se gasta todo el ingreso; en la sección 9.7 rehacemos este problema con desigualdades y KKT completo. Y como u se anula en los ejes mientras que hay canastas factibles con utilidad positiva, el óptimo es interior, así que ignorar $x, y \geq 0$ es legítimo.)

Paso 1: forma y lagrangiano. Es un problema de máximo con una igualdad $h(x, y) = px + qy - m = 0$. Usamos el lagrangiano “de economista”

$$L(x, y, \lambda) = x^\alpha y^\beta - \lambda (px + qy - m).$$

(En forma estándar minimizaríamos $-x^\alpha y^\beta$ con $+\lambda h$; los candidatos son los mismos y λ solo cambia de nombre.)

Paso 2: verificar regularidad. $\nabla h = (p, q) \neq (0, 0)$: todo punto factible es regular. El teorema de Lagrange aplica sin letra chica.

Paso 3: condiciones de primer orden.

$$\frac{\partial L}{\partial x} = \alpha x^{\alpha-1} y^\beta - \lambda p = 0 \implies \alpha x^{\alpha-1} y^\beta = \lambda p, \quad (9.6)$$

$$\frac{\partial L}{\partial y} = \beta x^\alpha y^{\beta-1} - \lambda q = 0 \implies \beta x^\alpha y^{\beta-1} = \lambda q, \quad (9.7)$$

$$\frac{\partial L}{\partial \lambda} = -(px + qy - m) = 0 \implies px + qy = m. \quad (9.8)$$

Paso 4: resolver el sistema. Dividimos (9.6) entre (9.7) (legítimo porque en un candidato interior $x, y, \lambda > 0$):

$$\frac{\alpha x^{\alpha-1} y^\beta}{\beta x^\alpha y^{\beta-1}} = \frac{\alpha}{\beta} \cdot \frac{y}{x} = \frac{p}{q} \implies qy = \frac{\beta}{\alpha} px.$$

Esta es la famosa condición de tangencia: *la tasa marginal de sustitución iguala al cociente de precios*, $TMS = \frac{u_x}{u_y} = \frac{\alpha y}{\beta x} = \frac{p}{q}$. Sustituyendo en el presupuesto (9.8):

$$px + \frac{\beta}{\alpha} px = m \implies px \frac{\alpha + \beta}{\alpha} = m \implies \boxed{x^* = \frac{\alpha}{\alpha + \beta} \cdot \frac{m}{p}, \quad y^* = \frac{\beta}{\alpha + \beta} \cdot \frac{m}{q}.$$

La lectura clásica: el consumidor Cobb–Douglas gasta la fracción fija $\alpha/(\alpha + \beta)$ de su ingreso en el bien x y $\beta/(\alpha + \beta)$ en el bien y , sin importar los precios.

Paso 5: el multiplicador y su interpretación. De (9.6),

$$\lambda^* = \frac{\alpha (x^*)^{\alpha-1} (y^*)^\beta}{p} = \frac{u(x^*, y^*) (\alpha + \beta)}{m},$$

donde la última igualdad sale de sustituir las demandas (haz la cuenta: es un buen ejercicio de álgebra). El significado: λ^* es la *utilidad marginal del ingreso*. Si defines la función de utilidad indirecta $v(p, q, m) = u(x^*(m), y^*(m))$ y derivas respecto de m , obtienes exactamente $\partial v / \partial m = \lambda^*$; lo demostraremos en general en el capítulo 11 (teorema de la envolvente), y lo verificamos numéricamente en la sección 9.8. Un sol adicional de ingreso relaja la restricción y compra λ^* “útiles” extra: por eso λ^* es el *precio sombra* del ingreso.

Cuidado (error común)

Dos errores clásicos con Lagrange. **(1) Olvidar la condición de rango.** La conclusión del teorema 9.16 puede fallar en puntos no regulares: el óptimo puede existir y no satisfacer (9.5) para ningún λ (veremos el fenómeno análogo con desigualdades en la sección 9.4). En un examen, verifica la regularidad (suele ser una línea, como en el paso 2 de arriba) antes de invocar el teorema. **(2) Creer que resolver el sistema de primer orden basta.** Las condiciones de Lagrange son *necesarias*, no suficientes: sus soluciones son *candidatos* (pueden ser máximos, mínimos o puntos de silla sobre la restricción). Necesitas un argumento adicional: existencia por Weierstrass + comparación de candidatos, concavidad/convexidad (sección 9.6), o condiciones de segundo orden (sección 9.9).

9.4. Cualificaciones de restricciones: por qué se necesitan [P1]

Antes de enunciar KKT en general, hay que entender su letra chica. La condición geométrica $-\nabla f(x^*) \in N_X(x^*)$ (teorema 9.14) es necesaria *siempre*. El paso delicado es *algebraico*: queremos reemplazar el cono normal geométrico por el cono generado por los gradientes de las restricciones activas,

$$N_X(x^*) \stackrel{?}{=} \left\{ \sum_{i \in A(x^*)} \mu_i \nabla g_i(x^*) + \sum_{j=1}^p \lambda_j \nabla h_j(x^*) : \mu_i \geq 0, \lambda_j \in \mathbb{R} \right\}.$$

Esa igualdad puede *fallar*: los gradientes pueden describir mal la geometría local de la región factible. Una *cualificación de restricciones* (*constraint qualification*, CQ) es cualquier hipótesis que garantice que la descripción algebraica es fiel. Veamos primero el fracaso en vivo.

9.4.1. Un contraejemplo completo: la cúspide

Ejemplo 9.19 (KKT falla sin cualificación de restricciones). Considera el problema en $\mathbb{R}^2$:

$$\min_{x \in \mathbb{R}^2} f(x) = x_1 \quad \text{s.a.} \quad g_1(x) = x_2 - x_1^3 \leq 0, \quad g_2(x) = -x_2 - x_1^3 \leq 0.$$

Paso 1: entender la región factible. Las dos restricciones juntas dicen $x_2 \leq x_1^3$ y $-x_2 \leq x_1^3$, es decir, $|x_2| \leq x_1^3$. Para que exista algún x_2 que las cumpla hace falta $x_1^3 \geq 0$, o sea $x_1 \geq 0$. La región factible es

$$X = \{x : x_1 \geq 0, |x_2| \leq x_1^3\},$$

una “lengua” delgadísima pegada al semieje positivo de x_1 , con una *cúspide* (punta afilada) en el origen: cerca de 0, la región tiene ancho $2x_1^3$, que se aplasta mucho más rápido que cualquier cono.

Paso 2: encontrar el óptimo a mano. Queremos el menor x_1 posible, y todo punto factible tiene $x_1 \geq 0$. El valor $x_1 = 0$ se alcanza solo en $x^* = (0, 0)$ (pues $|x_2| \leq 0$). Conclusión: $x^* = (0, 0)$ es el *mínimo global*, sin discusión.

Paso 3: intentar KKT en x^ .* Ambas restricciones están activas en el origen ($g_1(0) = g_2(0) =$

0). Calculamos gradientes:

$$\nabla f(x) = (1, 0), \quad \nabla g_1(x) = (-3x_1^2, 1), \quad \nabla g_2(x) = (-3x_1^2, -1),$$

y en $x^* = (0, 0)$:

$$\nabla f(x^*) = (1, 0), \quad \nabla g_1(x^*) = (0, 1), \quad \nabla g_2(x^*) = (0, -1).$$

La condición de estacionariedad KKT pediría $\mu_1, \mu_2 \geq 0$ con

$$\nabla f(x^*) + \mu_1 \nabla g_1(x^*) + \mu_2 \nabla g_2(x^*) = 0 \iff (1, 0) + \mu_1(0, 1) + \mu_2(0, -1) = (0, 0).$$

La primera coordenada exige $1 = 0$: **imposible**. No existen multiplicadores. KKT *falla en el mínimo global*.

Paso 4: diagnóstico geométrico. ¿Qué salió mal? Los gradientes activos generan el cono $\text{cono}\{(0, 1), (0, -1)\} = \{0\} \times \mathbb{R}$, el eje vertical: según el álgebra, el cono de direcciones permitidas cerca de 0 sería $\{d : d_2 \leq 0\} \cap \{d : -d_2 \leq 0\} = \mathbb{R} \times \{0\}$, ¡el eje horizontal completo, incluyendo $d = (-1, 0)$! Pero la geometría real es otra: el cono tangente verdadero es

$$T_X(0) = \mathbb{R}_+ \times \{0\}$$

(solo se puede entrar a la lengua por la derecha: si $x^k \in X$ y $x^k/t_k \rightarrow d$, de $x_1^k \geq 0$ sale $d_1 \geq 0$, y de $|x_2^k| \leq (x_1^k)^3$ sale $|d_2| = \lim |x_2^k|/t_k \leq \lim (x_1^k)^3/t_k = \lim (x_1^k/t_k) (x_1^k)^2 = d_1 \cdot 0 = 0$). El cono “linealizado” que ven los gradientes es estrictamente más grande que el tangente real, el cono normal verdadero $N_X(0) = \mathbb{R}_- \times \mathbb{R}$ es más grande que el generado por los gradientes, y $-\nabla f(0) = (-1, 0)$ vive en el primero pero no en el segundo. *La linealización miente* porque la cúspide es un objeto de orden cúbico que los gradientes (objetos de primer orden) no pueden ver. Las cualificaciones de restricciones son exactamente las condiciones que prohíben este tipo de patología.

Observación 9.20. Una versión unidimensional aún más corta del mismo fenómeno: mín x s.a. $g(x) = x^2 \leq 0$. El único punto factible es $x^* = 0$ (luego es el mínimo), pero $\nabla f(0) = 1$ y $\nabla g(0) = 0$, y la ecuación $1 + \mu \cdot 0 = 0$ no tiene solución. Aquí el gradiente de la restricción activa se *anula* y no aporta ninguna información direccional: caso extremo de gradientes que describen mal la geometría.

9.4.2. Las tres cualificaciones que debes conocer

Definición 9.21 (LICQ). El punto factible x satisface la *cualificación de independencia lineal* (*linear independence constraint qualification*, LICQ) si los gradientes de **todas las restricciones activas** en x (las g_i con $i \in A(x)$ y todas las h_j) son linealmente independientes:

$$\{\nabla g_i(x) : i \in A(x)\} \cup \{\nabla h_j(x) : j = 1, \dots, p\} \text{ es linealmente independiente.}$$

Definición 9.22 (Condición de Slater). Un problema *convexo* (f y las g_i convexas, las h_j afines)




Figura 9.3: La cúspide del ejemplo 9.19. El cono tangente verdadero en el origen es el semieje horizontal positivo, pero los gradientes activos (verticales) generan un cono que “no ve” la punta: $-\nabla f$ no puede escribirse como combinación no negativa de ∇g_1 y ∇g_2 , y KKT falla en el mínimo global.

satisface la *condición de Slater* si existe un punto estrictamente factible: algún $\hat{x} \in \mathbb{R}^n$ con

$$g_i(\hat{x}) < 0 \quad \forall i, \quad h_j(\hat{x}) = 0 \quad \forall j.$$

Es decir, la región factible tiene un punto donde *ninguna* desigualdad muerde. A diferencia de LICQ, es una condición *global* del problema (no de cada punto) y casi trivial de verificar.

Definición 9.23 (Mangasarian–Fromovitz). El punto factible x satisface la *cualificación de Mangasarian–Fromovitz* (MFCQ) si (i) los gradientes $\{\nabla h_j(x)\}_{j=1}^p$ son linealmente independientes, y (ii) existe una dirección $d \in \mathbb{R}^n$ con

$$\langle \nabla g_i(x), d \rangle < 0 \quad \forall i \in A(x), \quad \langle \nabla h_j(x), d \rangle = 0 \quad \forall j.$$

Intuitivamente: hay una dirección que “entra estrictamente” a la región factible, alejándose a la vez de todas las fronteras activas.

Teorema 9.24 (Jerarquía de cualificaciones). *En un punto factible x :*

$$LICQ \implies MFCQ \implies CQ \text{ de Abadie} \implies (\text{el teorema KKT vale en } x),$$

donde la cualificación de Abadie es la igualdad entre el cono tangente y el cono linealizado que veremos en la definición 9.27 y en el lema 9.28. En un problema convexo, Slater entrega la dirección de entrada estricta que pide MFCQ en todo punto factible (y, con igualdades afines de gradientes linealmente independientes, MFCQ completa); además, si todas las restricciones son afines (lineales), el teorema KKT vale sin ninguna hipótesis adicional. Bajo LICQ los multiplicadores son únicos; bajo MFCQ o Slater existen pero pueden no ser únicos.

Demostración (solo LICQ $\Rightarrow$ MFCQ). Sean $v_1, \dots, v_k$ los gradientes activos (desigualdades) y $w_1, \dots, w_p$ los de igualdades, todos linealmente independientes. La aplicación lineal

$$d \mapsto (\langle v_1, d \rangle, \dots, \langle v_k, d \rangle, \langle w_1, d \rangle, \dots, \langle w_p, d \rangle)$$

de $\mathbb{R}^n$ a $\mathbb{R}^{k+p}$ es *sobreyectiva* (su matriz tiene filas linealmente independientes), así que existe d con imagen $(-1, \dots, -1, 0, \dots, 0)$: exactamente lo que pide MFCQ. Las demás implicaciones se prueban en [5], cap. 12, y [6], sec. 3.2; la de Slater la tocamos en la sección 9.6. $\square$

Ejemplo 9.25 (Diagnóstico del contraejemplo). Verifiquemos que la cúspide del ejemplo 9.19 viola todas las cualificaciones en $x^* = 0$. *LICQ*: $\nabla g_1(0) = (0, 1)$ y $\nabla g_2(0) = (0, -1)$ son colineales ($\nabla g_2 = -\nabla g_1$): falla. *MFCQ*: necesitaríamos d con $\langle (0, 1), d \rangle = d_2 < 0$ y $\langle (0, -1), d \rangle = -d_2 < 0$ a la vez: imposible, falla. *Slater*: aquí sí existe un punto estrictamente factible, por ejemplo $\hat{x} = (1, 0)$, donde $g_1(\hat{x}) = g_2(\hat{x}) = -1 < 0$; y sin embargo KKT falla. ¡No hay contradicción!: g_1 y g_2 no son convexas (contienen $-x_1^3$), así que el problema no es convexo y la condición de Slater sencillamente no es aplicable. La moraleja es doble: *Slater es un privilegio de los problemas convexos*, y con g_i no convexas exhibir un punto interior no garantiza nada. En cambio, en el ejemplo unidimensional mín x s.a. $x^2 \leq 0$, la restricción sí es convexa pero no existe $\hat{x}$ con $\hat{x}^2 < 0$: Slater falla, y con ella KKT.

Estrategia de examen

¿Cuál cualificación uso en la práctica? Regla de decisión para el examen (y para la vida):

1. **¿Todas las restricciones son lineales/afines?** (presupuestos, no negatividad, recursos): KKT vale automáticamente, no verifiques nada. Este es el caso de la UMP estándar. Escribe una línea: “las restricciones son afines, por lo que no se requiere cualificación adicional”.
2. **¿El problema es convexo con alguna restricción no lineal?** (EMP con utilidad cóncava, es decir $\bar{u} - u(x)$ convexa; minimización de costos con requerimiento de producción cóncava): verifica **Slater** exhibiendo UN punto estrictamente factible. Suele ser trivial: “con $\hat{x}$ grande, $u(\hat{x}) > \bar{u}$ estrictamente”.
3. **¿Problema no convexo?** Verifica **LICQ** en los candidatos: calcula los gradientes activos y comprueba independencia lineal (con una o dos restricciones activas, esto es solo “ningún gradiente activo es cero” y “no son colineales”).

MFCQ es la herramienta teórica intermedia: la citas cuando LICQ falla pero aún hay dirección estrictamente entrante; en exámenes de micro casi nunca la necesitarás, pero debes poder enunciarla.

9.5. El teorema de Karush–Kuhn–Tucker [P1]

Llegamos al corazón del capítulo y del curso. Fijemos el problema estándar (9.1) y definamos el lagrangiano completo:

$$L(x, \mu, \lambda) = f(x) + \sum_{i=1}^m \mu_i g_i(x) + \sum_{j=1}^p \lambda_j h_j(x), \quad \mu \in \mathbb{R}_+^m, \lambda \in \mathbb{R}^p.$$

Teorema 9.26 (Condiciones necesarias de Karush–Kuhn–Tucker). *Sea x^* un mínimo local del problema (9.1), con f, g_i, h_j de clase C^1 en un entorno de x^* . Supón que en x^* se cumple alguna cualificación de restricciones (por ejemplo LICQ, o MFCQ, o que el problema sea convexo con Slater, o que todas las restricciones sean afines). Entonces existen vectores de multiplicadores $\mu^* \in \mathbb{R}^m$ y $\lambda^* \in \mathbb{R}^p$ tales que:*

$$(E) \text{ Estacionariedad:} \quad \nabla f(x^*) + \sum_{i=1}^m \mu_i^* \nabla g_i(x^*) + \sum_{j=1}^p \lambda_j^* \nabla h_j(x^*) = 0; \quad (9.9)$$

$$(FP) \text{ Factibilidad primal:} \quad g_i(x^*) \leq 0, \quad h_j(x^*) = 0 \quad \forall i, j; \quad (9.10)$$

$$(FD) \text{ Factibilidad dual:} \quad \mu_i^* \geq 0 \quad \forall i; \quad (9.11)$$

$$(HC) \text{ Holgura complementaria:} \quad \mu_i^* g_i(x^*) = 0 \quad \forall i. \quad (9.12)$$

Un punto x^* para el que existen tales (μ^*, λ^*) se llama punto KKT. Los λ_j^* no tienen signo restringido.

Antes de la demostración, asegurémonos de leer bien las cuatro condiciones:

- **(E)** dice que x^* es un punto crítico del lagrangiano en x : $\nabla_x L(x^*, \mu^*, \lambda^*) = 0$. Geométricamente, es $-\nabla f(x^*) \in \text{cono}\{\nabla g_i(x^*) : i \in A(x^*)\} + \text{span}\{\nabla h_j(x^*)\}$: la versión algebraica de $-\nabla f(x^*) \in N_X(x^*)$.
- **(FP)** solo recuerda que el candidato debe ser factible. En exámenes se olvida con una frecuencia asombrosa: un “candidato” que viola una restricción no es candidato.
- **(FD)** es el signo de los multiplicadores de desigualdad, que viene de la geometría: las paredes solo empujan hacia adentro (figura 9.1).
- **(HC)** es la condición estrella para el economista, tanto que le dedicamos la subsección 9.5.2 completa: para cada i , o la restricción está activa ($g_i(x^*) = 0$) o su multiplicador es cero ($\mu_i^* = 0$), o ambas cosas.

9.5.1. Demostración vía linealización y el lema de Farkas

La demostración es una joya: combina la condición geométrica (teorema 9.11) con el lema de Farkas que demostramos en el capítulo de separación. La estructura es:

$$\begin{array}{ccc} \text{óptimo local} & \xrightarrow{(1)} & \nabla f \text{ no ve descensos en } T_X(x^*) \xrightarrow{(2), \text{CQ}} \text{ni en el cono linealizado} \\ & & \xrightarrow{(3), \text{Farkas}} \text{multiplicadores.} \end{array}$$

Definición 9.27 (Cono linealizado). El *cono linealizado* (o cono de direcciones factibles linealizadas) del problema (9.1) en un punto factible x es

$$L_X(x) = \{ d \in \mathbb{R}^n : \langle \nabla g_i(x), d \rangle \leq 0 \quad \forall i \in A(x), \quad \langle \nabla h_j(x), d \rangle = 0 \quad \forall j \}.$$

Es el cono tangente del problema “linealizado” en x : reemplaza cada restricción activa por su aproximación de primer orden.

Lema 9.28. En todo punto factible, $T_X(x) \subseteq L_X(x)$. Bajo LICQ (o MFCQ) vale la igualdad $T_X(x) = L_X(x)$.

Demostración (inclusión siempre válida; igualdad esbozada). Sea $d \in T_X(x)$, con $x^k \in X$, $t_k \downarrow 0$, $(x^k - x)/t_k \rightarrow d$. Para $i \in A(x)$, por diferenciabilidad y $g_i(x) = 0$:

$$0 \geq g_i(x^k) = \underbrace{g_i(x)}_{=0} + \langle \nabla g_i(x), x^k - x \rangle + o(\|x^k - x\|).$$

Dividiendo entre t_k y tomando límite (mismo manejo del residuo que en el teorema 9.11): $\langle \nabla g_i(x), d \rangle \leq 0$. Para las igualdades, el mismo argumento aplicado a $h_j \leq 0$ y $-h_j \leq 0$ da $\langle \nabla h_j(x), d \rangle = 0$. Luego $d \in L_X(x)$.

La inclusión recíproca bajo LICQ es el paso técnico (donde la cúspide del ejemplo 9.19 queda excluida): dado $d \in L_X(x)$, hay que *construir* una sucesión factible con dirección límite d . La herramienta es de nuevo el teorema de la función implícita: gracias a la independencia lineal de los gradientes activos, el sistema de restricciones activas se puede resolver localmente y “proyectar” la trayectoria recta $x + td$ de vuelta a la región factible con un error $o(t)$, obteniendo puntos factibles $x(t) = x + td + o(t)$. La construcción detallada está en [5], lema 12.2, y [6], lema 3.13. $\square$

Lema 9.29 (Farkas, versión con igualdades). Sean $c, a_1, \dots, a_k, b_1, \dots, b_p \in \mathbb{R}^n$. Exactamente una de las siguientes alternativas es cierta:

- (I) existe $d \in \mathbb{R}^n$ con $\langle a_i, d \rangle \leq 0 \quad \forall i$, $\langle b_j, d \rangle = 0 \quad \forall j$, y $\langle c, d \rangle > 0$;
- (II) existen $\mu \in \mathbb{R}_+^k$ y $\lambda \in \mathbb{R}^p$ con $c = \sum_{i=1}^k \mu_i a_i + \sum_{j=1}^p \lambda_j b_j$.

Es decir: o bien c pertenece al cono generado por los a_i más el subespacio generado por los b_j , o bien existe un “certificado” d que lo delata.

Demostración. Primero, las dos alternativas son *incompatibles*: si valen (I) y (II) a la vez,

$$0 < \langle c, d \rangle = \sum_i \mu_i \underbrace{\langle a_i, d \rangle}_{\leq 0} + \sum_j \lambda_j \underbrace{\langle b_j, d \rangle}_{=0} \leq 0,$$

absurdo (aquí se usa $\mu_i \geq 0$; los λ_j pueden tener cualquier signo porque multiplican a cero).

Que al menos una valga es el lema de Farkas del capítulo de separación (teorema 4.23), en la versión con filas: o bien c es combinación no negativa de las filas de una matriz A , o bien existe d con $Ad \leq 0$ y $\langle c, d \rangle > 0$. Aplícalo a la matriz A cuyas filas son

$$a_1, \dots, a_k, \quad b_1, \dots, b_p, \quad -b_1, \dots, -b_p$$

(cada igualdad se desdobra en dos desigualdades). La primera alternativa da pesos $\mu_i \geq 0$, $\lambda_j^+ \geq 0$, $\lambda_j^- \geq 0$ con $c = \sum_i \mu_i a_i + \sum_j (\lambda_j^+ - \lambda_j^-) b_j$; definiendo $\lambda_j = \lambda_j^+ - \lambda_j^- \in \mathbb{R}$ (¡sin signo!) se obtiene (II). La segunda alternativa, $Ad \leq 0$ con $\langle c, d \rangle > 0$, dice exactamente $\langle a_i, d \rangle \leq 0$, $\langle b_j, d \rangle \leq 0$ y $\langle -b_j, d \rangle \leq 0$, es decir, $\langle b_j, d \rangle = 0$: eso es (I). Nota cómo el desdoblamiento de las igualdades explica de raíz por qué los λ_j no tienen signo restringido: son la diferencia de dos multiplicadores no negativos. $\square$

Demostración del teorema 9.26. Paso 1 (geometría). Por el teorema 9.11, al ser x^* mínimo local, $\langle \nabla f(x^*), d \rangle \geq 0$ para toda $d \in T_X(x^*)$.

Paso 2 (cualificación). La cualificación de restricciones garantiza $T_X(x^*) = L_X(x^*)$ (lema 9.28; para Slater y restricciones afines el argumento es distinto pero la conclusión relevante es la misma, ver [6], sec. 3.2). Por lo tanto:

$$\text{no existe } d \text{ con } \langle \nabla g_i(x^*), d \rangle \leq 0 \quad \forall i \in A(x^*), \quad \langle \nabla h_j(x^*), d \rangle = 0 \quad \forall j, \quad \langle -\nabla f(x^*), d \rangle > 0.$$

(Escribimos $\langle -\nabla f(x^*), d \rangle > 0$, es decir, “ d es dirección de descenso”: si tal d existiera, estaría en $L_X(x^*) = T_X(x^*)$ y violaría el paso 1.)

Paso 3 (Farkas). La no existencia de tal d es exactamente la negación de la alternativa (I) del lema 9.29 con $c = -\nabla f(x^*)$, $a_i = \nabla g_i(x^*)$ para $i \in A(x^*)$, $b_j = \nabla h_j(x^*)$. Luego vale la alternativa (II): existen $\mu_i^* \geq 0$ ($i \in A(x^*)$) y $\lambda_j^* \in \mathbb{R}$ con

$$-\nabla f(x^*) = \sum_{i \in A(x^*)} \mu_i^* \nabla g_i(x^*) + \sum_{j=1}^p \lambda_j^* \nabla h_j(x^*),$$

que es (9.9) restringida a los índices activos.

Paso 4 (completar y verificar HC). Define $\mu_i^* = 0$ para todo $i \notin A(x^*)$. Entonces (9.9) vale con todas las sumas completas (los términos añadidos son nulos), (9.11) vale por construcción, (9.10) vale porque x^* es factible, y la holgura complementaria (9.12) se verifica índice por índice: si $i \in A(x^*)$, entonces $g_i(x^*) = 0$ y el producto $\mu_i^* g_i(x^*)$ es cero; si $i \notin A(x^*)$, entonces $\mu_i^* = 0$ y el producto también es cero. La holgura complementaria no es una hipótesis extra: es la contabilidad de que las restricciones inactivas no participan en la geometría del óptimo. $\square$

Intuición

Vale la pena recapitular la demostración en una frase por paso, porque su lógica es la del propio análisis económico. (1) En el óptimo no hay dirección que sea factible y mejore el objetivo (si la hubiera, no estaríamos en el óptimo). (2) La cualificación de restricciones permite chequear “factible” con las derivadas de las restricciones en lugar de con la región verdadera. (3) El lema de Farkas convierte “no existe tal dirección” (un enunciado sobre *infinitas* direcciones, imposible de verificar una por una) en “existen multiplicadores” (un sistema *finito* de ecuaciones y signos, que sí se puede resolver). Ese salto de lo universal-negativo a lo existencial-positivo es todo el valor computacional de KKT: en lugar de demostrar que ningún desvío mejora, resuelves un sistema. Compáralo con el truco del primer teorema del bienestar o con los argumentos de no-arbitraje en finanzas: “no hay mejora posible” $\Leftrightarrow$ “existen precios que sostienen la asignación”. Los multiplicadores *son* esos precios.

9.5.2. Holgura complementaria: la condición del economista

La condición (9.12), $\mu_i^* g_i(x^*) = 0$ para cada i , merece una subsección propia porque es la que organiza *todo* el trabajo práctico y la que más contenido económico tiene.

Qué dice exactamente. Como $\mu_i^* \geq 0$ y $g_i(x^*) \leq 0$, el producto $\mu_i^* g_i(x^*)$ es siempre ≤ 0 ; pedir que sea cero equivale a pedir que *para cada restricción, al menos uno de los dos factores se anule*:

$$\begin{array}{lcl} \underbrace{g_i(x^*) < 0}_{\text{restricción con holgura}} & \implies & \mu_i^* = 0, \\ \text{para cada } i : & & \\ \text{equivalentemente} & & \mu_i^* > 0 \implies g_i(x^*) = 0. \end{array}$$

Ojo con lo que *no* dice: es perfectamente posible que $g_i(x^*) = 0$ y $\mu_i^* = 0$ a la vez (restricción activa “de casualidad”, que toca la frontera sin ejercer presión; se llama caso *degenerado* y aparece en el ejercicio 9.51).

Por qué es intuitiva. Piensa en μ_i^* como el *precio sombra* de la restricción i : cuánto mejoraría el valor óptimo si relajáramos la restricción marginalmente (sección 9.8). Si la restricción no muerde ($g_i(x^*) < 0$), relajarla un poquito no cambia nada (el óptimo ni siquiera la toca), así que su precio sombra debe ser cero: *un recurso que sobra es gratis*. Recíprocamente, si el recurso tiene precio positivo ($\mu_i^* > 0$), es porque se está usando hasta el tope ($g_i(x^*) = 0$). Es la misma lógica de mercado que ya conoces: un bien en exceso de oferta tiene precio de equilibrio cero (ley de Walras con desigualdades, condición de “free goods”). En contratos: si la restricción de participación del agente no se satura, el principal le está pagando renta de más y podría reducir el pago; en el óptimo, o la IR se satura o su multiplicador es nulo, y el análisis de Holmström consiste en descubrir cuál.

Cómo organiza el análisis por casos. La holgura complementaria convierte el sistema KKT (que mezcla ecuaciones, desigualdades y productos) en una *disyunción finita de sistemas*

de ecuaciones. Para cada restricción de desigualdad hay dos posibilidades exhaustivas (activa o con multiplicador nulo), de modo que con m desigualdades hay a lo sumo 2^m “régimenes” o casos:

$$\text{para cada } i, \text{ elegir: } \begin{cases} \text{Caso A}_i : & g_i(x) = 0 \quad (\mu_i \text{ libre } \geq 0), \\ \text{Caso B}_i : & \mu_i = 0 \quad (g_i(x) \text{ libre } \leq 0). \end{cases}$$

En cada régimen, el sistema restante es de ecuaciones (estacionariedad + las igualdades elegidas) y se resuelve con álgebra; después se *verifican* las desigualdades pendientes ($\mu_i \geq 0$ en los casos A, $g_i \leq 0$ en los casos B) y los casos inconsistentes se descartan. La sección 9.7 convierte esto en una receta y la teoría económica en un podador de casos: monotonidad $\Rightarrow$ el presupuesto se satura; Inada $\Rightarrow$ las no negatividades no se saturan; etc. Sin esas podas, 2^m explota rápido; con ellas, los problemas de examen se reducen a dos o tres casos.

Observación 9.30 (KKT generaliza todo lo anterior). Si no hay restricciones ($m = p = 0$), KKT se reduce a $\nabla f(x^*) = 0$ (capítulo 8). Si solo hay igualdades, se reduce al teorema de Lagrange 9.16. Si en el óptimo ninguna desigualdad está activa, la holgura complementaria anula todos los μ_i^* y de nuevo queda $\nabla f(x^*) = 0$: un óptimo interior no se entera de las restricciones. Las ecuaciones (9.2) y (9.3) de la motivación son los casos de una y dos restricciones activas. Una sola teoría para todo.

9.6. KKT bajo convexidad: necesidad y suficiencia [P1]

Hasta aquí, KKT es *necesaria*: filtra candidatos. La joya del caso convexo es que también es *suficiente*: todo punto KKT es óptimo global. Para el economista esto es oro: en la UMP con utilidad cóncava o en el EMP, encontrar UN punto KKT *termina* el problema.

Definición 9.31 (Problema convexo). El problema (9.1) es *convexo* si f es convexa, cada g_i es convexa y cada h_j es afín ($h_j(x) = \langle a_j, x \rangle - b_j$). En ese caso el conjunto factible X es convexo (intersección de subniveles de funciones convexas, que son convexas por el capítulo de funciones convexas, e hiperplanos). En la versión “de economista”: maximizar una función *cóncava* con restricciones $g_i(x) \leq 0$ convexas es un problema convexo tras el cambio mín $-f$.

Teorema 9.32 (Suficiencia de KKT en problemas convexas). *Considera el problema (9.1) convexo con f, g_i diferenciables. Si (x^*, μ^*, λ^*) satisface las cuatro condiciones KKT (9.9)–(9.12), entonces x^* es un mínimo global. No se necesita ninguna cualificación de restricciones para esta dirección.*

Demostración. La demostración es corta y elegante; cada paso usa exactamente una hipótesis. Sea $x \in X$ un punto factible cualquiera; queremos $f(x) \geq f(x^*)$.

Paso 1: convexidad de f (desigualdad del gradiente).

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle.$$

Paso 2: estacionariedad (9.9). Sustituimos $\nabla f(x^*) = -\sum_i \mu_i^* \nabla g_i(x^*) - \sum_j \lambda_j^* \nabla h_j(x^*)$:

$$f(x) \geq f(x^*) - \sum_{i=1}^m \mu_i^* \langle \nabla g_i(x^*), x - x^* \rangle - \sum_{j=1}^p \lambda_j^* \langle \nabla h_j(x^*), x - x^* \rangle.$$

Paso 3: las igualdades afines desaparecen. Como h_j es afín, $\langle \nabla h_j(x^*), x - x^* \rangle = h_j(x) - h_j(x^*) = 0 - 0 = 0$ (ambos puntos son factibles). Todo el tercer sumando se anula.

Paso 4: convexidad de las g_i y factibilidad dual. Por la desigualdad del gradiente aplicada a g_i : $\langle \nabla g_i(x^*), x - x^* \rangle \leq g_i(x) - g_i(x^*)$. Multiplicando por $\mu_i^* \geq 0$ (¡aquí se usa el signo!) y sumando:

$$\sum_i \mu_i^* \langle \nabla g_i(x^*), x - x^* \rangle \leq \sum_i \mu_i^* g_i(x) - \sum_i \mu_i^* g_i(x^*).$$

Paso 5: holgura complementaria y factibilidad primal. Por (9.12), $\sum_i \mu_i^* g_i(x^*) = 0$. Y como x es factible ($g_i(x) \leq 0$) y $\mu_i^* \geq 0$, tenemos $\sum_i \mu_i^* g_i(x) \leq 0$. Luego $\sum_i \mu_i^* \langle \nabla g_i(x^*), x - x^* \rangle \leq 0$, y volviendo al paso 2:

$$f(x) \geq f(x^*) - \underbrace{\sum_i \mu_i^* \langle \nabla g_i(x^*), x - x^* \rangle}_{\leq 0} \geq f(x^*).$$

Como $x \in X$ era arbitrario, x^* es mínimo global. $\square$

Corolario 9.33 (Caracterización completa en el caso convexo). *En un problema convexo diferenciable que satisface la condición de Slater, x^* es mínimo global si y solo si existen (μ^*, λ^*) tales que (x^*, μ^*, λ^*) satisface KKT. (Necesidad: teorema 9.26 con Slater como CQ; suficiencia: teorema 9.32.) En particular, resolver el sistema KKT resuelve el problema: este es el modo de operación estándar en toda la microeconomía con preferencias cóncavas.*

9.6.1. Más allá de la concavidad: Arrow–Enthoven

En micro es frecuente que la utilidad sea solo *cuasicóncava* (curvas de indiferencia convexas), no cóncava; recuerda del capítulo de cuasiconcavidad que la cuasiconcavidad no se lleva bien con sumas ni con desigualdades de gradiente. Aun así, la suficiencia de KKT sobrevive con hipótesis sorprendentemente débiles:

Teorema 9.34 (Arrow–Enthoven, 1961; enunciado). *Considera $\max f(x)$ s.a. $g_i(x) \leq 0$, $x \geq 0$, donde f es diferenciable y cuasicóncava, y cada g_i es diferenciable y cuasiconvexa. Sea (x^*, μ^*) un punto KKT del problema. Si además se cumple alguna de las siguientes condiciones:*

- (a) *f es pseudocóncava en x^* ; en particular, basta con que f sea cuasicóncava, dos veces diferenciable en un entorno de x^* y con $\nabla f(x^*) \neq 0$ (la condición de Arrow–Enthoven que se verifica en micro: algún bien es deseable al margen); o*
- (b) *f es cóncava (caso ya cubierto),*

entonces x^ es un máximo global. Recuerda del capítulo de cuasiconcavidad: pseudocóncava significa que $\langle \nabla f(x), y - x \rangle \leq 0$ implica $f(y) \leq f(x)$; toda cóncava diferenciable es pseudocóncava, y toda pseudocóncava es cuasicóncava. La moraleja práctica: para utilidades cuasicóncavas monótonas (gradiente no nulo), como casi todas las de micro, KKT sigue siendo suficiente. Enunciado y demostración completos en [1] y en el apéndice M de [9].*

Observación 9.35. Cobb–Douglas $u = x^\alpha y^\beta$ con $\alpha + \beta > 1$ no es cóncava, pero sí es cuasicóncava con gradiente no nulo en el ortante positivo: Arrow–Enthoven garantiza que el punto KKT de la UMP es el máximo global también en ese caso. Otra salida práctica: maximizar $\ln u =$

$\alpha \ln x + \beta \ln y$, que sí es cóncava y tiene los mismos maximizadores por ser $\ln$ estrictamente creciente (una transformación monótona no cambia el $\arg\max$, aunque sí puede cambiar la concavidad). Este truco de “concavificar” con una transformación monótona es estándar en micro y conviene tenerlo siempre a mano.

9.7. Manual de resolución de problemas KKT [P1]

Esta sección es una receta, deliberadamente mecánica, para resolver problemas KKT en examen, seguida de cuatro ejemplos económicos resueltos con *todos* los casos analizados. La receta primero:

Estrategia de examen

Protocolo KKT en siete pasos (para un problema de examen):

- P1. Normaliza.** Escribe el problema en una forma fija (recomiendo: máx con restricciones $g_i(x) \leq 0$, lagrangiano $L = f - \sum_i \mu_i g_i$; o convierte todo a la forma estándar min). Identifica cada restricción, incluidas las de no negatividad. Anota cuántas desigualdades hay: ese es tu universo de casos.
- P2. Justifica el método.** Una línea sobre existencia (Weierstrass si el factible es compacto) y una línea sobre cualificación/suficiencia: ¿restricciones afines? ¿Slater? ¿objetivo cóncavo o cuasicóncavo (Arrow–Enthoven)? Esto decide si el punto KKT que encuentres es *el* óptimo o solo un candidato.
- P3. Escribe el lagrangiano y las condiciones completas:** estacionariedad (una ecuación por variable), factibilidad primal, $\mu_i \geq 0$, y holgura complementaria (una ecuación-producto por desigualdad). Escríbelas TODAS: la mitad de los puntos del examen suele estar aquí.
- P4. Poda casos con economía.** Antes de enumerar 2^m casos, usa la estructura: monotonidad $\Rightarrow$ presupuesto activo; condiciones de Inada ($u_x \rightarrow \infty$ cuando $x \rightarrow 0$) $\Rightarrow$ no negatividad inactiva; $\lambda > 0$ deducido de estacionariedad $\Rightarrow$ su restricción activa. Documenta cada poda con una frase.
- P5. Enumera y resuelve los casos restantes.** En cada caso, las elecciones “activa” ($g_i = 0$) o “precio nulo” ($\mu_i = 0$) convierten el sistema en ecuaciones puras. Resuélvelo.
- P6. Verifica y descarta.** En cada caso resuelto, chequea las condiciones que no usaste: signos de multiplicadores y factibilidad de las restricciones supuestas inactivas. Un caso se descarta *mostrando* la violación (p.ej. “ $\mu_2 = -3 < 0$, contradicción”). Nunca lo descartes por corazonada.
- P7. Concluye e interpreta.** Reporta el óptimo, el valor óptimo y los multiplicadores con su lectura económica (precios sombra). Si el paso P2 dio suficiencia, declara optimalidad global; si no, compara valores entre los candidatos supervivientes.

9.7.1. Ejemplo 1: UMP Cobb–Douglas con no negatividad (solución interior)

Ejemplo 9.36 (UMP completa con KKT).

$$\max_{x,y} u(x,y) = x^\alpha y^\beta \quad \text{s.a.} \quad px + qy \leq m, \quad x \geq 0, \quad y \geq 0,$$

con $\alpha, \beta \in (0, 1)$, $\alpha + \beta \leq 1$, y $p, q, m > 0$.

P1 (normalizar). Tres desigualdades: $g_0 = px + qy - m \leq 0$, $g_1 = -x \leq 0$, $g_2 = -y \leq 0$. Universo: $2^3 = 8$ casos posibles.

P2 (justificar). El conjunto presupuestario es compacto (cerrado, y acotado porque $p, q > 0$) y u es continua: el máximo existe (Weierstrass). Las tres restricciones son *afines*: KKT es necesaria sin más requisitos. Con $\alpha + \beta \leq 1$, u es cóncava en $\mathbb{R}_+^2$ (y en general es cuasicóncava con gradiente no nulo en el interior, así que Arrow–Enthoven cubre el caso $\alpha + \beta > 1$): KKT será también suficiente.

P3 (lagrangiano y condiciones). Con multiplicadores $\lambda, \mu_1, \mu_2 \geq 0$:

$$L = x^\alpha y^\beta - \lambda(px + qy - m) + \mu_1 x + \mu_2 y.$$

Condiciones KKT:

$$(E_x) \quad \alpha x^{\alpha-1} y^\beta - \lambda p + \mu_1 = 0,$$

$$(E_y) \quad \beta x^\alpha y^{\beta-1} - \lambda q + \mu_2 = 0,$$

$$(FP) \quad px + qy \leq m, \quad x \geq 0, \quad y \geq 0,$$

$$(FD) \quad \lambda \geq 0, \quad \mu_1 \geq 0, \quad \mu_2 \geq 0,$$

$$(HC) \quad \lambda(px + qy - m) = 0, \quad \mu_1 x = 0, \quad \mu_2 y = 0.$$

P4 (podar). *Poda 1: las esquinas de los ejes no son óptimas.* Si $x = 0$ o $y = 0$, entonces $u = 0$, mientras que el punto factible $(\frac{m}{2p}, \frac{m}{2q})$ da utilidad positiva. Luego el óptimo tiene $x^* > 0$ e $y^* > 0$, y por holgura complementaria $\mu_1 = \mu_2 = 0$. (Cuidado técnico: en $x = 0$ con $\alpha < 1$ la derivada $\alpha x^{\alpha-1}$ ni siquiera es finita; el argumento por comparación directa de valores esquiva limpiamente el problema, y es el que recomiendo en examen.) Esto elimina de golpe los 6 casos con alguna esquina. *Poda 2: el presupuesto se satura.* Supón $px + qy < m$ en el óptimo; por (HC), $\lambda = 0$; con $\mu_1 = 0$, (E_x) daría $\alpha x^{\alpha-1} y^\beta = 0$, imposible con $x, y > 0$. Contradicción: por lo tanto $px^* + qy^* = m$. (Lectura económica: la utilidad marginal es positiva, así que dejar ingreso sin gastar no puede ser óptimo.) Quedó UN caso.

P5 (resolver el caso interior con presupuesto activo). Con $\mu_1 = \mu_2 = 0$, (E_x) y (E_y) son exactamente las condiciones (9.6)–(9.7) del ejemplo 9.18; dividiéndolas y usando el presupuesto:

$$x^* = \frac{\alpha}{\alpha + \beta} \cdot \frac{m}{p}, \quad y^* = \frac{\beta}{\alpha + \beta} \cdot \frac{m}{q}, \quad \lambda^* = \frac{\alpha(x^*)^{\alpha-1}(y^*)^\beta}{p} > 0.$$

P6 (verificar). $x^*, y^* > 0$ ✓; presupuesto exacto por construcción ✓; $\lambda^* > 0$ ✓; $\mu_1 = \mu_2 = 0 \geq 0$ ✓. Todas las condiciones KKT se cumplen y no queda ningún otro caso.

P7 (concluir). Por suficiencia (problema cóncavo/cuasicóncavo con restricciones afines), (x^*, y^*) es el máximo global. Nota cómo KKT *redescubre* la solución de Lagrange del ejemplo 9.18, pero ahora con la saturación del presupuesto y la interioridad *demostradas* en lugar de supuestas: eso es lo que aporta el aparato de desigualdades.

9.7.2. Ejemplo 2: solución de esquina con utilidad cuasilineal

Ejemplo 9.37 (Cuasilineal: la holgura complementaria detecta la esquina).

$$\max_{x,y} u(x,y) = \ln x + y \quad \text{s.a.} \quad px + y \leq m, \quad x \geq 0, \quad y \geq 0,$$

con $p > 0$, $m > 0$ (el precio de y está normalizado a 1). Este es el ejemplo perfecto para ver a KKT trabajando de verdad: según el nivel de ingreso, la solución es interior o de esquina, y es la *holgura complementaria* la que lo descubre sola.

P1–P2. Desigualdades: $g_0 = px + y - m \leq 0$, $g_1 = -x \leq 0$, $g_2 = -y \leq 0$. Restricciones afines (KKT necesaria sin CQ extra); u es cóncava (suma de cóncavas: $\ln x$ estrictamente cóncava, y lineal), así que KKT es suficiente. Dominio efectivo: $x > 0$ (pues $\ln x \rightarrow -\infty$ cuando $x \downarrow 0$: la esquina $x = 0$ es infinitamente mala y queda podada de inmediato; formalmente, $u \rightarrow -\infty$ garantiza que el supremo no se alcanza en $x = 0$). Por tanto $\mu_1 = 0$ siempre.

P3. Lagrangiano y condiciones ($\lambda, \mu_2 \geq 0$):

$$L = \ln x + y - \lambda(px + y - m) + \mu_2 y,$$

$$(E_x) \quad \frac{1}{x} - \lambda p = 0 \quad \implies \quad \lambda = \frac{1}{px} > 0,$$

$$(E_y) \quad 1 - \lambda + \mu_2 = 0 \quad \implies \quad \mu_2 = \lambda - 1,$$

$$(HC) \quad \lambda(px + y - m) = 0, \quad \mu_2 y = 0,$$

más factibilidad primal y dual.

P4 (podar). De (E_x) , $\lambda > 0$ automáticamente; por (HC) , *el presupuesto siempre se satura*: $px + y = m$. Quedan solo dos casos, gobernados por la restricción $y \geq 0$:

P5, Caso A: $y > 0$ (interior). Por (HC) , $\mu_2 = 0$; por (E_y) , $\lambda = 1$; por (E_x) , $x = 1/(\lambda p) = 1/p$. El presupuesto da $y = m - px = m - 1$. *Verificación (P6):* necesitamos $y > 0$, es decir, $\boxed{m > 1}$. Si $m > 1$, todo cuadra:

$$x^* = \frac{1}{p}, \quad y^* = m - 1, \quad \lambda^* = 1, \quad \mu_2^* = 0.$$

Observa la propiedad cuasilineal clásica: la demanda de x no depende del ingreso; todo ingreso adicional se va al bien lineal y , y la utilidad marginal del ingreso es constante ($\lambda^* = 1$).

P5, Caso B: $y = 0$ (esquina). El presupuesto saturado da $x = m/p$. De (E_x) : $\lambda = 1/(px) = 1/m$. De (E_y) : $\mu_2 = \lambda - 1 = \frac{1}{m} - 1 = \frac{1-m}{m}$. *Verificación (P6):* necesitamos $\mu_2 \geq 0$, es decir,

$m \leq 1$. Si $m < 1$:

$$x^* = \frac{m}{p}, \quad y^* = 0, \quad \lambda^* = \frac{1}{m} > 1, \quad \mu_2^* = \frac{1-m}{m} > 0.$$

P7 (concluir e interpretar). Los dos casos se *reparten* el espacio de parámetros sin superponerse (salvo la frontera $m = 1$, donde ambos dan la misma solución $x^* = 1/p$, $y^* = 0$ con $\mu_2^* = 0$: el caso degenerado “activa con precio cero”). La lectura económica de la esquina: cuando el ingreso es bajo ($m < 1$), el consumidor querría “vender” bien y para comprar más x (la tangencia interior pediría $y = m - 1 < 0$), pero no puede: la restricción $y \geq 0$ *muerde*, y su multiplicador $\mu_2^* = (1 - m)/m > 0$ mide cuánta utilidad ganaría el consumidor si se le permitiera un y marginalmente negativo (endeudarse en el bien numerario). Además $\lambda^* = 1/m > 1$: el ingreso es más valioso cuando eres pobre, exactamente como dicta la concavidad. Fíjate en el flujo lógico: *no adivinamos* la esquina; la holgura complementaria organizó los casos y las verificaciones de signo ($y > 0$ vs. $\mu_2 \geq 0$) dijeron exactamente para qué parámetros vale cada régimen. Así se resuelven también los problemas de contratos: los regímenes de Baron–Myerson (“la IR muere para el tipo bajo, la IC para el tipo alto”) son casos KKT verificados de esta misma manera.

9.7.3. Ejemplo 3: minimización de costos de la firma (el dual de la producción)

Ejemplo 9.38 (Costo mínimo con tecnología Cobb–Douglas). La firma quiere producir al menos $q > 0$ unidades al menor costo:

$$\min_{K,L} wL + rK \quad \text{s.a.} \quad F(K, L) = K^{1/2}L^{1/2} \geq q, \quad K \geq 0, \quad L \geq 0,$$

con salario $w > 0$ y renta del capital $r > 0$.

P1. Forma estándar: $f = wL + rK$; $g_0 = q - K^{1/2}L^{1/2} \leq 0$; $g_1 = -K \leq 0$; $g_2 = -L \leq 0$.

P2. El objetivo es lineal (convexo). F es cóncava en $\mathbb{R}_+^2$ (Cobb–Douglas con rendimientos constantes), así que $g_0 = q - F$ es convexa: *problema convexo*. Slater: el punto $\hat{K} = \hat{L} = 2q$ da $F = 2q > q$ y $\hat{K}, \hat{L} > 0$: existe punto estrictamente factible ✓. Por el corolario 9.33, KKT caracteriza el óptimo global. (Existencia: el factible no es compacto, pero podemos restringir a $\{wL + rK \leq wL_0 + rK_0\}$ para cualquier punto factible (K_0, L_0) y aplicar Weierstrass en la intersección, que sí es compacta.)

P3. Con $\mu, \mu_K, \mu_L \geq 0$ (y llamando $\mathcal{L}$ al lagrangiano, porque aquí la letra L ya es el trabajo):

$$\mathcal{L}(K, L, \mu, \mu_K, \mu_L) = wL + rK + \mu(q - K^{1/2}L^{1/2}) - \mu_K K - \mu_L L,$$

$$(E_K) \quad r - \frac{\mu}{2} K^{-1/2} L^{1/2} - \mu_K = 0,$$

$$(E_L) \quad w - \frac{\mu}{2} K^{1/2} L^{-1/2} - \mu_L = 0,$$

$$(HC) \quad \mu(q - K^{1/2}L^{1/2}) = 0, \quad \mu_K K = 0, \quad \mu_L L = 0.$$

P4 (podar). Para producir $q > 0$ hacen falta ambos insumos ($F = 0$ si $K = 0$ o $L = 0$): en

cualquier punto factible $K, L > 0$, luego $\mu_K = \mu_L = 0$. ¿Puede ser $\mu = 0$? Entonces (E_K) daría $r = 0$, contradicción. Luego $\mu > 0$ y, por holgura complementaria, *la restricción de producción se satura*: $K^{1/2}L^{1/2} = q$. (Economía: producir de más cuesta y no aporta; el requerimiento muerde y el multiplicador, que resultará ser el costo marginal, es positivo.) De nuevo un solo caso sobrevive.

P5 (resolver). Dividiendo (E_K) entre (E_L) :

$$\frac{r}{w} = \frac{K^{-1/2}L^{1/2}}{K^{1/2}L^{-1/2}} = \frac{L}{K} \quad \implies \quad L = \frac{r}{w}K.$$

Es la condición de tangencia de la firma: la tasa marginal de sustitución técnica ($TMST = F_L/F_K = K/L$) iguala el precio relativo de los insumos w/r . Sustituyendo en $K^{1/2}L^{1/2} = q$:

$$K^{1/2}\left(\frac{r}{w}K\right)^{1/2} = q \implies K\sqrt{\frac{r}{w}} = q \implies \boxed{K^* = q\sqrt{\frac{w}{r}}, \quad L^* = q\sqrt{\frac{r}{w}}}.$$

El costo mínimo (la *función de costos*) es

$$C(w, r, q) = wL^* + rK^* = wq\sqrt{\frac{r}{w}} + rq\sqrt{\frac{w}{r}} = 2q\sqrt{wr},$$

y el multiplicador sale de (E_L) , que con $\mu_L = 0$ dice $w = \frac{\mu}{2} K^{1/2}L^{-1/2}$; despejando μ y evaluando en el óptimo:

$$\mu^* = \frac{w}{\frac{1}{2}(K^*)^{1/2}(L^*)^{-1/2}} = 2w\sqrt{\frac{L^*}{K^*}} = 2w\sqrt{\frac{r}{w}} = 2\sqrt{wr}.$$

P6. $K^*, L^* > 0$ ✓, producción exacta ✓, $\mu^* > 0$ ✓.

P7. Verificación reveladora: $\partial C/\partial q = 2\sqrt{wr} = \mu^*$. *El multiplicador de la restricción de producción es el costo marginal*: el precio sombra de exigirle a la firma una unidad más de producto. Esta igualdad no es casualidad: es el teorema de la envolvente (capítulo 11) y reaparece en toda la teoría de la firma (la curva de oferta competitiva es $p = C'(q) = \mu^*$).

9.7.4. Ejemplo 4: mini principal–agente con información simétrica

Ejemplo 9.39 (Riesgo compartido óptimo: la IR muerde y el agente queda asegurado). Un *principal* neutral al riesgo contrata a un *agente* averso al riesgo. El producto es aleatorio: vale y_H con probabilidad $\pi \in (0, 1)$ e $y_L < y_H$ con probabilidad $1 - \pi$ (el esfuerzo no es problema aquí: información simétrica, sin riesgo moral). El contrato especifica salarios contingentes $w_H, w_L \geq 0$. El agente tiene utilidad Bernoulli $v(w)$ con $v' > 0$, $v'' < 0$ (estrictamente cóncava) y utilidad de reserva $\bar{v}$ (lo que obtiene en su mejor alternativa). El principal resuelve:

$$\max_{w_H, w_L} \pi(y_H - w_H) + (1 - \pi)(y_L - w_L) \quad \text{s.a.} \quad \underbrace{\pi v(w_H) + (1 - \pi)v(w_L)}_{(IR)} \geq \bar{v}.$$

(Suponemos parámetros tales que los salarios óptimos salen positivos, y omitimos $w \geq 0$ para centrarnos en la IR; el ejercicio 9.56 repite el análisis con una especificación concreta.)

P1–P2. Una sola desigualdad: $g(w_H, w_L) = \bar{v} - \pi v(w_H) - (1 - \pi)v(w_L) \leq 0$. Como v es cóncava, $-v$ es convexa y g es convexa; el objetivo (a minimizar: $-\pi(y_H - w_H) - (1 - \pi)(y_L - w_L)$),

lineal) es convexo: *problema convexo*. Slater: pagando salarios enormes, la utilidad esperada del agente supera $\bar{v}$ estrictamente $\checkmark$. KKT caracteriza el óptimo global.

P3. Con $\gamma \geq 0$ el multiplicador de la IR:

$$L = \pi(y_H - w_H) + (1 - \pi)(y_L - w_L) + \gamma [\pi v(w_H) + (1 - \pi)v(w_L) - \bar{v}],$$

$$(E_H) \quad -\pi + \gamma \pi v'(w_H) = 0 \implies \gamma v'(w_H) = 1, \quad (9.13)$$

$$(E_L) \quad -(1 - \pi) + \gamma (1 - \pi) v'(w_L) = 0 \implies \gamma v'(w_L) = 1, \quad (9.14)$$

$$(HC) \quad \gamma [\pi v(w_H) + (1 - \pi)v(w_L) - \bar{v}] = 0.$$

P4 (¿muere la IR?). Supón que no: $\gamma = 0$. Entonces (E_H) dice $-\pi = 0$: contradicción. Luego $\boxed{\gamma > 0}$ y, por holgura complementaria, *la IR se satura*:

$$\pi v(w_H) + (1 - \pi)v(w_L) = \bar{v}.$$

Economía pura: si al agente le sobrara utilidad, el principal podría recortar ambos salarios un poquito, seguir contratándolo, y ganar más. En el óptimo, el principal extrae todo el excedente y deja al agente exactamente en su utilidad de reserva. El multiplicador $\gamma > 0$ es el precio sombra de la IR: cuánto beneficio pierde el principal por cada útil adicional que haya que garantizarle al agente.

P5 (resolver: seguro total). De (9.13) y (9.14):

$$v'(w_H) = \frac{1}{\gamma} = v'(w_L).$$

Como $v'' < 0$, v' es estrictamente decreciente y por lo tanto *inyectiva*: $v'(w_H) = v'(w_L)$ implica

$$\boxed{w_H = w_L = \bar{w}}.$$

¡El salario óptimo no depende del estado! El principal (neutral al riesgo) absorbe todo el riesgo y *asegura completamente* al agente (averso al riesgo). Esta es la condición de reparto óptimo de riesgo de Borch y el *first best* del modelo principal-agente (MWG, cap. 14): con información simétrica, eficiencia = seguro total + extracción del excedente. La IR saturada determina el nivel: $v(\bar{w}) = \bar{v}$, es decir, $\bar{w} = v^{-1}(\bar{v})$, y el multiplicador queda $\gamma = 1/v'(\bar{w}) > 0$.

P6–P7. Verificaciones: $\gamma > 0$ $\checkmark$, IR con igualdad $\checkmark$; por convexidad, es el óptimo global. Beneficio del principal: $\pi y_H + (1 - \pi)y_L - v^{-1}(\bar{v})$. *Ilustración numérica*: $v(w) = \sqrt{w}$, $\bar{v} = 2$, $\pi = 1/2$, $y_H = 16$, $y_L = 8$. Entonces $\bar{w} = \bar{v}^2 = 4$, $\gamma = 1/v'(4) = 2\sqrt{4} = 4$, y el beneficio es $12 - 4 = 8$. Chequeo de envoltura: si $\bar{v}$ sube a 2.1, el nuevo salario es 4.41 y el beneficio 7.59; la caída $\approx 0.41 \approx \gamma \cdot 0.1 = 0.4$ $\checkmark$ (la diferencia es el término de segundo orden). Cuando agregues riesgo moral, la restricción IC romperá el seguro total ($w_H > w_L$ para incentivar); el andamiaje KKT (quién muere, qué signo tiene cada multiplicador) será idéntico a este.

Cuidado (error común)

Errores de examen más vistos en problemas como los anteriores:

- **Dividir entre algo que puede ser cero.** Antes de dividir (E_x) entre (E_y) , justifica que el denominador no se anula (interioridad, monotonicidad). En soluciones de esquina esa división es precisamente lo que *no* puedes hacer.
- **Olvidar casos.** “Supongamos solución interior” sin verificar después las condiciones del caso ni examinar los demás: pierdes exactamente los puntos que el problema quería evaluar (las esquinas). El protocolo P4–P6 existe para eso.
- **Concluir optimalidad sin suficiencia.** Un punto KKT de un problema no convexo puede ser un máximo local, un punto de silla restringido o hasta el peor punto de la región. Cita siempre tu razón: convexidad + Slater, Arrow–Enthoven, o comparación exhaustiva de candidatos con existencia por Weierstrass.
- **Multiplicador con signo cambiado** por mezclar convenciones min/max: revisa la sección 9.1.3 y haz el chequeo del precio sombra.

9.8. Interpretación económica de los multiplicadores: precios sombra [P1]

Hasta aquí los multiplicadores han sido un artificio algebraico: números que hacen que una combinación de gradientes se anule. Esta sección explica por qué son, de lejos, el objeto *económicamente* más interesante de todo el aparato. La frase que debes poder decir en un examen (y en un seminario) es:

el multiplicador de una restricción es el precio sombra del recurso que esa restricción raciona.

9.8.1. La función de valor y el enunciado formal

Partimos del problema de la definición 9.1, pero ahora *indexado* por el nivel de los recursos. Para $b = (b_1, \dots, b_m) \in \mathbb{R}^m$ considera

$$P(b) : \quad \max_{x \in \mathbb{R}^n} f(x) \quad \text{s.a.} \quad g_i(x) \leq b_i \quad (i = 1, \dots, m), \quad h_j(x) = 0 \quad (j = 1, \dots, p). \quad (9.15)$$

El problema original es $P(0)$. Aumentar b_i *relaja* la restricción i : el conjunto factible crece, y por lo tanto el valor óptimo no puede empeorar.

Definición 9.40 (Función de valor). La *función de valor* (*value function*) de la familia (9.15) es

$$V(b) = \sup \{f(x) : g_i(x) \leq b_i \ \forall i, \ h_j(x) = 0 \ \forall j\},$$

con la convención $V(b) = -\infty$ si $P(b)$ es infactible. En economía V recibe nombres propios según el contexto: *utilidad indirecta* $v(p, m)$ si el recurso es el ingreso, *función de costos* $C(w, q)$

si el recurso es el nivel de producción exigido, *beneficio máximo* $\pi(p)$, *valor del programa del principal* en teoría de contratos.

Definición 9.41 (Precio sombra). El *precio sombra* (*shadow price*) del recurso i en b es la tasa marginal a la que el valor óptimo responde a una dotación adicional de ese recurso, $\partial V(b)/\partial b_i$. Es un precio *implícito*: no lo cotiza ningún mercado, lo genera la escasez dentro del problema.

Teorema 9.42 (El multiplicador es el precio sombra). Sea $\bar{b} \in \mathbb{R}^m$ y supón que:

- (H1) f, g_i, h_j son de clase C^2 en un entorno de la solución;
- (H2) $P(\bar{b})$ tiene una única solución $x^*(\bar{b})$;
- (H3) en $x^*(\bar{b})$ se cumple LICQ (definición 9.21), de modo que los multiplicadores (μ^*, λ^*) del teorema 9.26 existen y son únicos (escritos en la convención de máximo de la sección 9.1.3: $L = f - \sum_i \mu_i (g_i - b_i)$ con $\mu_i \geq 0$);
- (H4) se cumplen la holgura complementaria estricta ($\mu_i^* > 0$ para toda restricción activa) y la condición suficiente de segundo orden (sección 9.9).

Entonces existe un entorno de $\bar{b}$ en el que $x^*(\cdot)$, $\mu^*(\cdot)$ y $\lambda^*(\cdot)$ son funciones C^1 , V es diferenciable, y

$$\frac{\partial V}{\partial b_i}(\bar{b}) = \mu_i^*(\bar{b}), \quad i = 1, \dots, m.$$

En particular $\mu_i^* \geq 0$ recupera la monotonía obvia (relajar no puede perjudicar) y $\mu_i^* = 0$ para las restricciones inactivas: un recurso que sobra tiene precio sombra cero, que es exactamente la holgura complementaria de la sección 9.5.2 leída al revés.

Cuidado (error común)

Signos: relajar frente a apretar. El enunciado está escrito para el problema de *máximo* (9.15), donde subir b_i *relaja* la restricción: por eso $\partial V/\partial b_i = +\mu_i^* \geq 0$. Si trabajas con la forma estándar de *minimización* (9.1) y perturbas igual ($g_i(x) \leq b_i$), relajar *baja* el valor óptimo y el mismo resultado se lee

$$\frac{\partial V_{\min}}{\partial b_i}(\bar{b}) = -\mu_i^* \leq 0,$$

como verificarás con números en el ejercicio 9.51(c). La regla que no falla, en cualquiera de las dos convenciones: $\mu_i^* \geq 0$ mide siempre *la mejora del objetivo por unidad de relajación*, o, lo que es lo mismo, el costo de *apretar* la restricción una unidad. Por eso en el ejemplo 9.38 el parámetro que se mueve es el requerimiento q (apretar) y sale $\partial C/\partial q = +\mu^*$.

La demostración (vía el teorema de la función implícita para diferenciar el sistema KKT, o vía el teorema de la envolvente en su versión con restricciones) se da en el capítulo 11; allí también verás las versiones que *no* requieren diferenciabilidad de V (con subgradiantes: $\mu^* \in \partial V(b)$ en el caso convexo, capítulo 10) y la versión de Milgrom–Segal para conjuntos de elección arbitrarios, que es la que se usa en diseño de mecanismos. Aquí nos interesa el enunciado, la lectura y la verificación numérica.

Cuidado (error común)

Las hipótesis (H2)–(H4) no son decorativas. Si la solución no es única, V puede tener un *quiebre* (kink) en $\bar{b}$ y solo existen derivadas direccionales; si el multiplicador no es único (falla LICQ, aunque valga MFCQ), lo que se obtiene es

$$\liminf_{t \downarrow 0} \frac{V(\bar{b} + te_i) - V(\bar{b})}{t} \geq \min_{\mu \in \Lambda^*} \mu_i, \quad \limsup_{t \downarrow 0} \frac{V(\bar{b} + te_i) - V(\bar{b})}{t} \leq \max_{\mu \in \Lambda^*} \mu_i,$$

donde Λ^* es el conjunto (compacto bajo MFCQ) de multiplicadores: acota las derivadas direccionales por ambos lados, pero no hay un número único. Y la interpretación es *marginal*: vale para perturbaciones pequeñas. Si duplicas b , $V(2b) \neq V(b) + \mu^{*\top} b$ salvo en casos especiales (por ejemplo, si V es lineal en b).

9.8.2. Lectura en el consumidor y en la firma

Consumidor: λ^* es la **utilidad marginal del ingreso**. En la UMP del ejemplo 9.36 el recurso es el ingreso m y la función de valor es la utilidad indirecta $v(p, q, m)$. El teorema 9.42 dice

$$\frac{\partial v}{\partial m}(p, q, m) = \lambda^*(p, q, m).$$

Un sol adicional de ingreso compra λ^* “útiles”. De ahí tres consecuencias que aparecen todo el tiempo en Microeconomía:

- La condición de tangencia $u_x/u_y = p/q$ se reescribe como $u_x/p = u_y/q = \lambda^*$: *en el óptimo, el último sol gastado en cada bien rinde la misma utilidad*. Esa es la ley de la utilidad marginal igualada, y el valor común es el multiplicador.
- λ^* es la unidad de conversión entre utilidad y dinero. Por eso en la identidad de Roy $x_k^* = -(\partial v / \partial p_k) / (\partial v / \partial m)$ aparece dividiendo: convierte “utilidad perdida por subir p_k ” en “soles”.
- Con utilidad cuasilineal $\lambda^* = 1$ en la región interior (ejemplo 9.37): la utilidad ya está medida en dinero y no hay efecto ingreso. Es exactamente la razón por la que la cuasilinealidad hace legítimo el análisis de excedente y domina la teoría de subastas y de mecanismos.

Firma: μ^* es el **costo marginal (o el valor marginal del insumo)**. En el ejemplo 9.38 el “recurso” es el requerimiento de producción q y obtuvimos $\mu^* = 2\sqrt{wr} = \partial C / \partial q$: el precio sombra de exigir una unidad más de producto es el costo marginal, la base de la curva de oferta competitiva $p = C'(q)$. Si en cambio la firma maximiza beneficio sujeta a una dotación fija de un insumo (capacidad instalada $\bar{K}$, cuota de importación, licencia, permiso de emisión), el multiplicador de esa restricción es *cuánto pagaría la firma por una unidad extra*: es su disposición a pagar, el precio al que alquilaría capacidad o compraría un permiso. En equilibrio general con mercados completos, los precios sombra de los recursos escasos coinciden con los precios de mercado: ese es el contenido operativo del primer teorema del bienestar, y la razón por la que un planificador que resuelve un problema de asignación “descubre” los precios competitivos como multiplicadores (ver la sección 9.6 y el capítulo 10, donde los multiplicadores son las variables duales).

9.8.3. Ejemplo numérico completo: comprobar el precio sombra

Ejemplo 9.43 (Verificación numérica de $\partial V/\partial b = \lambda^*$). Considera la UMP logarítmica con precios $p = 2$, $q = 1$ e ingreso b :

$$V(b) = \max_{x,y>0} \ln x + \ln y \quad \text{s.a.} \quad 2x + y \leq b.$$

Paso 1: resolver para b genérico. El objetivo es cóncavo, la restricción afín y Slater se cumple, así que KKT caracteriza el óptimo global (corolario 9.33). Con $L = \ln x + \ln y - \lambda(2x + y - b)$:

$$(E_x) \quad \frac{1}{x} = 2\lambda, \quad (E_y) \quad \frac{1}{y} = \lambda, \quad (\text{HC}) \quad \lambda(2x + y - b) = 0.$$

Como $1/x > 0$, necesariamente $\lambda > 0$ y el presupuesto se satura. De (E_x) y (E_y) : $x = 1/(2\lambda)$, $y = 1/\lambda$. Sustituyendo en $2x + y = b$:

$$\frac{1}{\lambda} + \frac{1}{\lambda} = b \implies \lambda^*(b) = \frac{2}{b}, \quad x^*(b) = \frac{b}{4}, \quad y^*(b) = \frac{b}{2}.$$

El valor óptimo es

$$V(b) = \ln \frac{b}{4} + \ln \frac{b}{2} = 2 \ln b - \ln 8.$$

Paso 2: dos valores concretos del recurso. Tomamos $b = 10$ y $b = 11$.

b	x^*	y^*	λ^*	$V(b) = 2 \ln b - \ln 8$
10	2.5	5	0.200000	2.525729
11	2.75	5.5	0.181818	2.716349

(Comprobación de la primera fila: $V(10) = \ln 2.5 + \ln 5 = 0.916291 + 1.609438$.)

Paso 3: comparar. El cambio exacto del valor óptimo es

$$V(11) - V(10) = 2 \ln \frac{11}{10} = 0.190620,$$

mientras que la predicción del precio sombra es $\lambda^*(10) \cdot \Delta b = 0.2 \cdot 1 = 0.2$. Coinciden hasta un error de 0.0094, que es puro efecto de segundo orden: $\Delta b = 1$ no es “marginal” para un ingreso de 10. Fíjate además en que $\lambda^*(11) = 0.1818 < 0.1906 < 0.2 = \lambda^*(10)$: el cambio verdadero está atrapado entre los dos precios sombra, porque V es cóncava en b y λ^* es decreciente (utilidad marginal del ingreso decreciente).

Paso 4: hacerlo de verdad marginal. Con $\Delta b = 0.1$:

$$V(10.1) - V(10) = 2 \ln(1.01) = 0.0199007 \quad \text{frente a} \quad \lambda^*(10) \cdot 0.1 = 0.02,$$

error 10^{-4} . Con $\Delta b = 0.01$ el error cae a 10^{-6} . Esto es lo que significa “derivada”: el precio sombra es exacto en el límite y una excelente aproximación para perturbaciones pequeñas. Verificación directa por cálculo: $V'(b) = 2/b = \lambda^*(b)$ ✓, que es el teorema 9.42 en este caso.

Estrategia de examen

El “chequeo del precio sombra” es la mejor herramienta de autocorrección que tienes en un examen. Cuando termines un problema: (i) mira el signo del multiplicador y pregúntate si relajar esa restricción *debería* mejorar el objetivo; si tu μ^* tiene el signo contrario al que dicta la economía, mezclaste convenciones (sección 9.1.3); (ii) si tienes el valor óptimo en forma cerrada, deriva respecto del parámetro y compáralo con el multiplicador: si no coinciden, hay un error algebraico en alguna parte. Este chequeo cuesta dos líneas y salva problemas completos.

9.8.4. Lectura en teoría de contratos: IR e IC

En un programa de principal–agente hay dos familias de restricciones y sus multiplicadores tienen nombres económicos precisos. Escribimos el problema del principal como

$$\begin{array}{ll} \max_{\text{contrato}} \Pi(\text{contrato}) & \text{s.a.} \\ & \underbrace{U(\text{contrato}) \geq \bar{u}}_{(\text{IR})} \\ & \underbrace{U(\text{contrato} \mid \text{acción deseada}) \geq U(\text{contrato} \mid \text{desviación})}_{(\text{IC})}. \end{array}$$

El multiplicador de la IR: el costo de la utilidad de reserva. Escribe la (IR) en forma estándar, $g(\text{contrato}) = \bar{u} - U \leq 0$, con multiplicador $\gamma \geq 0$ y lagrangiano $L = \Pi - \gamma(\bar{u} - U)$. Aquí el “recurso” perturbado es $-\bar{u}$, de modo que el teorema 9.42 da

$$\frac{\partial \Pi^*}{\partial \bar{u}} = -\gamma^* \leq 0 : \quad \text{subir } \bar{u} \text{ en } \varepsilon \text{ le cuesta al principal } \gamma^* \varepsilon.$$

(El signo es puro convenio: lo que importa es la magnitud y la dirección económica, que siempre es “un agente con mejores alternativas es más caro”.) Es literalmente el *precio del agente*: cuánto beneficio hay que ceder por cada útil adicional que el mercado laboral externo le garantiza. Si el agente tiene mejores alternativas (mayor $\bar{u}$), el principal gana menos, a razón de γ^* por útil. En el ejemplo 9.39 verificamos esto numéricamente: $\gamma = 4$ y subir $\bar{v}$ de 2 a 2.1 redujo el beneficio en ≈ 0.4 .

Que (IR) *muerda* ($\gamma^* > 0$) es la regla en el caso estándar: si le sobrara utilidad al agente, el principal recortaría el pago. Cuando (IR) *no* muerde para algún tipo de agente (y en modelos de selección adversa con varios tipos esto es lo normal para los tipos altos), ese agente obtiene un excedente estricto por encima de su alternativa externa: es la *renta informacional*.

El multiplicador de la IC: el precio de la información asimétrica. Si δ es el multiplicador de (IC), δ^* mide cuánto le cuesta al principal que la restricción de incentivos exista. La comparación clave es:

$$\underbrace{\Pi^{FB}}_{\text{sin (IC): información simétrica}} - \underbrace{\Pi^{SB}}_{\text{con (IC): información asimétrica}} = \text{costo de agencia},$$

y δ^* es su versión marginal: si relajas (IC) en una unidad (por ejemplo, porque una tecnología de monitoreo hace más difícil la desviación, o porque el diferencial de esfuerzo requerido baja), el principal gana δ^* . De ahí dos lecturas que reaparecen en todo modelo de principal-agente (MWG, cap. 14):

- *Riesgo moral*: $\delta^* > 0$ obliga a que el salario dependa del resultado observable; el sobrecosto respecto del *first best* es la prima de riesgo que hay que pagarle a un agente averso al riesgo por exponerlo a la aleatoriedad. Compara con el ejemplo 9.39, donde sin (IC) el contrato óptimo era seguro pleno ($w_H = w_L$): la (IC) es exactamente lo que rompe esa igualdad. El ejercicio 9.56 lo resuelve con números.
- *Selección adversa*: δ^* (el multiplicador de la IC del tipo eficiente, que quiere hacerse pasar por el ineficiente) es la fuente de la *renta informacional* y de la distorsión “no distorsión en la cima, distorsión hacia abajo”. La cadena es siempre la misma: (IC) muerde $\Rightarrow$ hay que dejar renta $\Rightarrow$ conviene distorsionar la cantidad del tipo bajo para abaratar esa renta.

Qué restricciones muerden es, por tanto, el resultado económico central de un modelo de contratos, y determinarlo es un ejercicio de holgura complementaria. Todo el capítulo se resume, para un economista teórico, en esa frase.

Intuición

El multiplicador es el precio de una etiqueta de racionamiento. Imagina que la restricción $g_i(x) \leq b_i$ es un cupo: solo puedes usar b_i toneladas de acero. Si el cupo sobra, una tonelada extra no vale nada: nadie pagaría por un cupón de acero. Si el cupo aprieta, cada tonelada extra vale algo muy concreto (el beneficio adicional que permitiría) y ese número es μ_i^* . Es el precio al que existiría un mercado secundario de cupones si lo dejáramos aparecer.

Tres consecuencias que valen para todo el curso:

1. **Holgura complementaria es “no se paga por lo que sobra”**: recurso libre $\Rightarrow$ precio cero; precio positivo $\Rightarrow$ recurso agotado.
2. **El lagrangiano es un problema de mercado.** En el caso convexo, maximizar $f(x) - \sum_i \mu_i^* (g_i(x) - b_i)$ *sin restricciones* da el mismo óptimo: en lugar de prohibir el exceso de recurso, lo cobras a su precio sombra y el agente se autorrationa. Esa es toda la idea de la dualidad (capítulo 10), de los impuestos pigouvianos y de los mercados de permisos de emisión.
3. **En contratos, el “recurso” es la utilidad del agente y la información.** El precio sombra de la IR es cuánto cuesta el agente; el de la IC, cuánto cuesta no poder observarlo. Cuando en un modelo de contratos leas “la restricción de participación del tipo bajo y la de incentivos del tipo alto son las que muerden”, estás leyendo el resultado de un análisis de casos KKT como los de este capítulo.

9.9. Condiciones de segundo orden con restricciones [P2]

KKT es una condición de *primer orden*: identifica candidatos. Cuando el problema es convexo (sección 9.6) eso basta y no hace falta nada más. Pero si el objetivo no es cóncavo, o las restricciones no definen un conjunto convexo, un punto KKT puede ser un máximo local, un mínimo local o un punto de silla restringido, y hay que mirar la curvatura. La pregunta correcta no es “¿cómo se curva f ?” sino “¿cómo se curva el *lagrangiano* a lo largo de las direcciones que la restricción permite?”. Dos ideas, y ambas son sutiles:

1. **Se examina la Hessiana de L , no la de f .** Las restricciones curvas “doblan” el conjunto factible, y esa doblez entra en el análisis a través de los $\nabla^2 g_i$, $\nabla^2 h_j$ que aparecen en $\nabla_{xx}^2 L$. Si la restricción es afín, ambos objetos coinciden; si no, no.
2. **Se examina solo en el subespacio (o cono) tangente crítico.** No importa lo que pase en direcciones que salen del conjunto factible: esas curvaturas son irrelevantes porque el problema no te deja moverte por allí.

9.9.1. El cono crítico y los enunciados

Trabajamos con el problema estándar de *minimización* (9.1) y el lagrangiano $L(x, \mu, \lambda) = f(x) + \sum_i \mu_i g_i(x) + \sum_j \lambda_j h_j(x)$ de la sección 9.5. Escribimos

$$\nabla_{xx}^2 L(x^*, \mu^*, \lambda^*) = \nabla^2 f(x^*) + \sum_{i=1}^m \mu_i^* \nabla^2 g_i(x^*) + \sum_{j=1}^p \lambda_j^* \nabla^2 h_j(x^*).$$

Definición 9.44 (Cono crítico). Sea (x^*, μ^*, λ^*) un punto KKT y $A(x^*)$ el conjunto de índices activos (definición 9.3). El *cono crítico* es

$$C(x^*, \mu^*) = \left\{ d \in \mathbb{R}^n : \begin{array}{ll} \nabla h_j(x^*)^\top d = 0 & \text{para todo } j, \\ \nabla g_i(x^*)^\top d = 0 & \text{para } i \in A(x^*) \text{ con } \mu_i^* > 0, \\ \nabla g_i(x^*)^\top d \leq 0 & \text{para } i \in A(x^*) \text{ con } \mu_i^* = 0 \end{array} \right\}.$$

La lógica de las tres líneas es transparente: las igualdades no dejan moverse fuera de su superficie de nivel; una desigualdad que muerde *con precio positivo* ($\mu_i^* > 0$) es, a efectos locales, una igualdad (moverse hacia adentro cambiaría el valor a primer orden, así que esas direcciones ya quedan descartadas por el primer orden); y una activa *degenerada* ($\mu_i^* = 0$) deja abierto un semiespacio. Nota que $C(x^*, \mu^*)$ es exactamente el conjunto de direcciones del cono linealizado (definición 9.27) sobre las que la derivada direccional del objetivo se anula: son las direcciones “neutras” a primer orden, las únicas donde la curvatura decide.

Teorema 9.45 (Condición necesaria de segundo orden). Sea x^* un mínimo local de (9.1) con f, g_i, h_j de clase C^2 , y supón que se cumple LICQ en x^* (definición 9.21), con multiplicadores (μ^*, λ^*) . Entonces

$$d^\top \nabla_{xx}^2 L(x^*, \mu^*, \lambda^*) d \geq 0 \quad \text{para todo } d \in C(x^*, \mu^*).$$

(Semidefinida positiva sobre el cono crítico.)

Teorema 9.46 (Condición suficiente de segundo orden). Sea (x^*, μ^*, λ^*) un punto que satisface las condiciones KKT (9.9)–(9.12) con f, g_i, h_j de clase $\mathcal{C}^2$. Si

$$d^\top \nabla_{xx}^2 L(x^*, \mu^*, \lambda^*) d > 0 \quad \text{para todo } d \in C(x^*, \mu^*), \quad d \neq 0,$$

entonces x^* es un mínimo local estricto de (9.1). Para máximos, todo se invierte: se exige $d^\top \nabla_{xx}^2 L d < 0$ sobre el cono crítico (definida negativa) y se obtiene máximo local estricto.

Comentario sobre la demostración. La idea es un desarrollo de Taylor de segundo orden a lo largo de curvas factibles $x(t)$ con $x(0) = x^*$, $\dot{x}(0) = d$: la factibilidad obliga a $h_j(x(t)) = 0$, y derivando dos veces esa identidad aparece precisamente el término $\lambda_j^* \nabla^2 h_j$ que convierte la Hessiana de f en la del lagrangiano. El argumento completo (con el uso de LICQ para construir las curvas en el caso necesario) está en [5, cap. 12, teoremas 12.5 y 12.6] y en [6, cap. 3]; la versión en notación económica, con Hessiano orlado, en [9, apéndice M.D–M.E]. $\square$

Cuidado (error común)

Cuatro errores clásicos con las condiciones de segundo orden:

- **Usar $\nabla^2 f$ en lugar de $\nabla_{xx}^2 L$.** Solo es válido si todas las restricciones son afines. Con restricciones curvas el resultado puede cambiar de signo.
- **Evaluar en todo $\mathbb{R}^n$ en lugar del cono crítico.** Es un error “conservador” que descarta óptimos legítimos: hay problemas con $\nabla_{xx}^2 L$ indefinida en $\mathbb{R}^n$ y definida positiva sobre el subespacio tangente, justamente el ejercicio 9.53.
- **Confundir necesaria con suficiente.** Necesaria: ≥ 0 . Suficiente: > 0 para $d \neq 0$. En el caso frontera (≥ 0 con algún d donde vale 0) el test no decide, igual que x^3 frente a x^4 en el caso sin restricciones (capítulo 8).
- **Olvidar que la suficiencia da optimalidad local.** Para global necesitas convexidad (teorema 9.32), Arrow–Enthoven (teorema 9.34) o comparación exhaustiva de candidatos con existencia garantizada.

9.9.2. El criterio del Hessiano orlado (caso de igualdades)

En la práctica (y en los exámenes de micro) el test se implementa con determinantes. Sea el problema con *solo* restricciones de igualdad

$$\max_{x \in \mathbb{R}^n} f(x) \quad \text{s.a.} \quad h_j(x) = 0, \quad j = 1, \dots, m, \quad m < n,$$

(en esta subsección, y solo aquí, m cuenta las restricciones de *igualdad*, como es tradicional en la literatura del Hessiano orlado), sea x^* un punto de Lagrange (teorema 9.16) con multiplicadores λ^* en la convención $L = f + \sum_j \lambda_j h_j$ (si escribes el lagrangiano “de economista” con signo menos, cambia λ_j por $-\lambda_j$ al formar H ; con restricciones afines da igual, porque $\nabla^2 h_j = 0$), y

llamemos

$$\begin{aligned} A &= [\nabla h_j(x^*)^\top]_{j=1,\dots,m} \in \mathbb{R}^{m \times n} \quad (\text{la jacobiana de las restricciones}), \\ H &= \nabla_{xx}^2 L(x^*, \lambda^*) \in \mathbb{R}^{n \times n}. \end{aligned}$$

Definición 9.47 (Hessiano orlado). El *Hessiano orlado* (*bordered Hessian*) es la matriz simétrica de orden $n + m$

$$\bar{H} = \begin{pmatrix} 0_{m \times m} & A \\ A^\top & H \end{pmatrix}.$$

Denotamos por $\bar{H}_k$ su submatriz principal de orden k (las primeras k filas y columnas) y por $D_k = \det \bar{H}_k$ el menor principal líder correspondiente.

Teorema 9.48 (Regla de signos del Hessiano orlado). *Supón que $\text{rango } A = m$ (LICQ). Solo importan los últimos $n - m$ menores principales líderes, es decir, $D_{2m+1}, D_{2m+2}, \dots, D_{n+m}$. Entonces:*

- **Máximo local estricto** (H definida negativa sobre $\{d : Ad = 0\}$) si esos $n - m$ menores alternan de signo, empezando por el signo de $(-1)^{m+1}$ en D_{2m+1} ; equivalentemente, si

$$\text{signo}(D_{2m+k}) = (-1)^{m+k}, \quad k = 1, \dots, n - m,$$

de modo que el último, D_{n+m} , tiene el signo de $(-1)^n$.

- **Mínimo local estricto** (H definida positiva sobre $\{d : Ad = 0\}$) si esos $n - m$ menores tienen todos el mismo signo, el de $(-1)^m$.
- Si algún menor tiene el signo “equivocado” (y no es cero), el punto no es óptimo local; si algún menor se anula, el criterio no decide.

Observación 9.49 (Casos que conviene memorizar). ■ $n = 2, m = 1$ (el caso de examen por excelencia: dos bienes, un presupuesto). Hay $n - m = 1$ menor relevante, el determinante completo $D_3 = \det \bar{H}$, de orden 3. Máximo: $D_3 > 0$ (signo de $(-1)^n = (-1)^2$). Mínimo: $D_3 < 0$ (signo de $(-1)^m = -1$).

- $n = 3, m = 1$. Dos menores, D_3 y D_4 . Máximo: $D_3 > 0, D_4 < 0$ (alternan). Mínimo: $D_3 < 0, D_4 < 0$ (ambos con el signo de $(-1)^1$).
- $m = 0$ (sin restricciones): la regla se reduce a la conocida del capítulo 8: todos los menores positivos para mínimo, alternando desde negativo para máximo.
- **Con desigualdades:** el criterio se aplica tratando las restricciones *activas con multiplicador positivo* como si fueran igualdades (y si hay activas degeneradas con $\mu_i^* = 0$, el orlado ya no basta: hay que volver al cono crítico de la definición 9.44).

Estrategia de examen

En examen, para $n = 2, m = 1$ es casi siempre más rápido *no* usar determinantes: parametriza el subespacio tangente. Con la restricción $a_1 d_1 + a_2 d_2 = 0$ toma $d = (a_2, -a_1)$

(un solo vector genera la recta tangente) y calcula el escalar

$$Q = d^\top H d = a_2^2 H_{11} - 2a_1 a_2 H_{12} + a_1^2 H_{22}.$$

$Q < 0 \Rightarrow$ máximo local estricto; $Q > 0 \Rightarrow$ mínimo local estricto. Es una línea de aritmética, no hay que recordar reglas de signos, y de hecho $\det \bar{H} = -Q$ en este caso, así que ambos caminos son el mismo cálculo. Usa el orlado cuando n sea grande o cuando el enunciado lo pida explícitamente.

9.9.3. Ejemplo resuelto 2×2

Ejemplo 9.50 (Verificar que el punto de tangencia es un máximo). Resuelve y verifica con condiciones de segundo orden:

$$\max_{x,y>0} u(x,y) = x^{1/2}y^{1/2} \quad \text{s.a.} \quad 2x + y = 12.$$

Paso 1: punto de Lagrange. Con $L = x^{1/2}y^{1/2} - \lambda(2x + y - 12)$:

$$(E_x) \quad \frac{1}{2}x^{-1/2}y^{1/2} = 2\lambda, \quad (E_y) \quad \frac{1}{2}x^{1/2}y^{-1/2} = \lambda.$$

Dividiendo (y ambas cantidades son positivas en el ortante positivo, así que la división es lícita):

$$\frac{y}{x} = 2 \implies y = 2x.$$

Sustituyendo en la restricción: $2x + 2x = 12$, luego

$$x^* = 3, \quad y^* = 6, \quad \lambda^* = \frac{1}{2}\sqrt{\frac{x^*}{y^*}} = \frac{1}{2} \cdot \frac{1}{\sqrt{2}} = \frac{\sqrt{2}}{4} \approx 0.35355, \quad u(x^*, y^*) = \sqrt{18} = 3\sqrt{2}.$$

Paso 2: la Hessiana del lagrangiano. La restricción es afín, así que $\nabla^2 h = 0$ y $\nabla_{xx}^2 L = \nabla^2 u$. Derivando:

$$u_{xx} = -\frac{1}{4}x^{-3/2}y^{1/2}, \quad u_{xy} = \frac{1}{4}x^{-1/2}y^{-1/2}, \quad u_{yy} = -\frac{1}{4}x^{1/2}y^{-3/2}.$$

En $(3, 6)$, escribiendo $k = \sqrt{2}/48 \approx 0.0294628$ para no arrastrar radicales:

$$u_{xx} = -\frac{\sqrt{2}}{12} = -4k, \quad u_{xy} = \frac{\sqrt{2}}{24} = 2k, \quad u_{yy} = -\frac{\sqrt{2}}{48} = -k, \quad H = \begin{pmatrix} -4k & 2k \\ 2k & -k \end{pmatrix}.$$

Observa que $\det H = 4k^2 - 4k^2 = 0$: la Hessiana es singular (semidefinida negativa, pero no definida). El test “sin restricciones” no concluiría nada. Es justo el tipo de situación en que hay que restringirse al espacio tangente.

Paso 3a: vía el subespacio tangente (recomendado). El espacio tangente a $2x + y = 12$

es $\{d : 2d_1 + d_2 = 0\}$, generado por $d = (1, -2)$. Entonces

$$d^\top H d = (-4k)(1)^2 + 2(2k)(1)(-2) + (-k)(-2)^2 = -4k - 8k - 4k = -16k = -\frac{\sqrt{2}}{3} \approx -0.4714 < 0.$$

Como el cono crítico es exactamente esta recta (no hay desigualdades) y la forma cuadrática es estrictamente negativa sobre ella, el teorema 9.46 da: $(3, 6)$ es un **máximo local estricto**.

Paso 3b: vía el Hessiano orlado (comprobación). Aquí $n = 2$, $m = 1$, $A = (2, 1)$ y

$$\bar{H} = \begin{pmatrix} 0 & 2 & 1 \\ 2 & -4k & 2k \\ 1 & 2k & -k \end{pmatrix},$$

de donde

$$\begin{aligned} D_3 = \det \bar{H} &= -2[(2)(-k) - (2k)(1)] + [(2)(2k) - (-4k)(1)] \\ &= -2(-4k) + 8k = 16k > 0. \end{aligned}$$

Solo hay $n - m = 1$ menor relevante (D_3), y para *máximo* debe tener el signo de $(-1)^n = (-1)^2 = +1$: se cumple ✓. Observa la relación anunciada: $D_3 = 16k = -d^\top H d$, los dos métodos son el mismo cálculo.

Paso 4: de local a global. $u = x^{1/2}y^{1/2}$ es cóncava en $\mathbb{R}_{++}^2$ (Cobb–Douglas con $\alpha + \beta = 1$) y la restricción es afín: el problema es convexo y el máximo local es global (teorema 9.32). En este ejemplo, entonces, la condición de segundo orden era *redundante*, y esa es justamente la moraleja: **si puedes invocar convexidad, hazlo, y ahórrate los determinantes**. Las condiciones de segundo orden ganan su sueldo cuando el problema *no* es convexo; el ejercicio 9.53 muestra un caso así, con $\nabla^2 f$ indefinida y sin embargo un mínimo estricto sobre la restricción.

Intuición

Piensa en una montaña (f) y en un sendero trazado sobre ella (la restricción). Las condiciones de primer orden dicen que en el óptimo el sendero es *plano*: no sube ni baja localmente. Las de segundo orden preguntan si esa planicie es la cima de una loma o el fondo de una hondonada *a lo largo del sendero*. Que la montaña suba en direcciones que salen del sendero es irrelevante (no puedes ir por ahí), y esa es la razón de restringirse al cono crítico. El término $\sum_j \lambda_j \nabla^2 h_j$ que convierte $\nabla^2 f$ en $\nabla_{xx}^2 L$ es la curvatura del *sendero* mismo: si el camino se curva, tu altura cambia aunque la montaña no lo haga, y hay que descontarlo.

Resumen

Resumen del capítulo

Problema estándar. mín $f(x)$ s.a. $g_i(x) \leq 0$ ($i \leq m$), $h_j(x) = 0$ ($j \leq p$); lagrangiano $L = f + \sum_i \mu_i g_i + \sum_j \lambda_j h_j$. Todo enunciado depende de la convención de signos: en la forma máx con $g_i \leq 0$ se usa $L = f - \sum_i \mu_i g_i$ y los $\mu_i \geq 0$ conservan su lectura de precio sombra (sección 9.1.3). *Antes de escribir nada, declara tu convención.* Restricción activa

en x^* : $g_i(x^*) = 0$.

1. Teorema de Lagrange (solo igualdades) (teorema 9.16). *Hipótesis exactas:* x^* óptimo local; $f, h_j \in \mathcal{C}^1$ en un entorno de x^* ; **los gradientes** $\nabla h_1(x^*), \dots, \nabla h_p(x^*)$ **son linealmente independientes** (x^* es punto regular). *Conclusión:* existe $\lambda^* \in \mathbb{R}^p$ **único** con $\nabla f(x^*) + \sum_j \lambda_j^* \nabla h_j(x^*) = 0$. Los λ_j^* *no tienen signo restringido*. Geometría: $\nabla f(x^*)$ pertenece al subespacio generado por los gradientes de las restricciones; equivalentemente, las curvas de nivel son tangentes.

2. KKT, necesidad (teorema 9.26). *Hipótesis exactas:* x^* mínimo local; $f, g_i, h_j \in \mathcal{C}^1$ cerca de x^* ; **y alguna cualificación de restricciones** (CQ). *Conclusión:* existen $\mu^* \in \mathbb{R}^m, \lambda^* \in \mathbb{R}^p$ con

- (I) **Estacionariedad:** $\nabla f(x^*) + \sum_i \mu_i^* \nabla g_i(x^*) + \sum_j \lambda_j^* \nabla h_j(x^*) = 0$;
- (II) **Factibilidad primal:** $g_i(x^*) \leq 0, h_j(x^*) = 0$;
- (III) **Factibilidad dual (no negatividad):** $\mu_i^* \geq 0$ (los λ_j^* libres);
- (IV) **Holgura complementaria:** $\mu_i^* g_i(x^*) = 0$ para todo i : o la restricción muerde, o su precio es cero, o ambas (caso degenerado).

3. Cualificaciones de restricciones (sección 9.4). Ninguna es sobre el óptimo: todas son sobre la *geometría del conjunto factible* en x^* .

- **LICQ:** $\{\nabla g_i(x^*)\}_{i \in A(x^*)} \cup \{\nabla h_j(x^*)\}_j$ linealmente independientes. Es la más fuerte de las usuales: implica MFCQ y da multiplicadores *únicos*.
- **Slater** (solo problemas convexos: f, g_i convexas, h_j afines): existe $\hat{x}$ con $g_i(\hat{x}) < 0$ para todo i (*estrictamente factible*) y $h_j(\hat{x}) = 0$. Es una condición *global* y fácil de verificar; no exige nada sobre gradientes.
- **MFCQ:** $\{\nabla h_j(x^*)\}$ linealmente independientes y existe d con $\nabla h_j(x^*)^\top d = 0$ y $\nabla g_i(x^*)^\top d < 0$ para toda activa (hay una dirección que entra estrictamente). Equivale a que el conjunto de multiplicadores sea no vacío y *acotado*.
- **Restricciones afines:** si todas las g_i y h_j son afines, KKT es necesaria *sin más hipótesis* (CQ de Abadie automática). Cubre presupuestos, recursos lineales y programación lineal.
- Jerarquía: LICQ $\Rightarrow$ MFCQ $\Rightarrow$ Abadie $\Rightarrow$ KKT necesaria (teorema 9.24).

4. El contraejemplo de la cúspide (ejemplo 9.19). Sirve para recordar *por qué* las CQ no son letra pequeña: en un punto donde el conjunto factible tiene una cúspide, el cono tangente es estrictamente menor que el cono linealizado, los gradientes activos son linealmente dependientes (falla LICQ y falla MFCQ) y el óptimo **no admite multiplicadores**: KKT es falsa allí. Moraleja de examen: KKT necesaria = “óptimo + CQ”; sin CQ puedes perder el óptimo. Y las CQ no dependen de f : solo de cómo se ve el conjunto factible.

5. KKT, suficiencia (teorema 9.32 y corolario 9.33). *Hipótesis exactas* (problema convexo): f **convexa**, cada g_i **convexa**, cada h_j **afín** (¡afín, no “convexa”!), todas diferenciables. *Conclusión*: si (x^*, μ^*, λ^*) cumple las cuatro condiciones KKT, entonces x^* es **mínimo global**. No se necesita ninguna CQ para la suficiencia. Con Slater además se tiene la caracterización completa: x^* óptimo $\iff x^*$ es punto KKT. En forma máx: f cóncava, g_i convexas (X convexo), h_j afines. *Variante Arrow–Enthoven* (teorema 9.34): basta con f **cuasicóncava** (en vez de cóncava) y g_i cuasiconvexas, más una condición técnica extra (por ejemplo $\nabla f(x^*) \neq 0$). Es lo que salva a Cobb–Douglas con rendimientos crecientes ($\alpha + \beta > 1$), que es cuasicóncava pero no cóncava. Truco alternativo: maximizar $\ln u$, monótona creciente de u .

6. Condiciones de segundo orden (sección 9.9). Se examina $\nabla_{xx}^2 L$ (¡no $\nabla^2 f$!) sobre el *cono crítico* $C(x^*, \mu^*)$: $\nabla h_j^\top d = 0$; $\nabla g_i^\top d = 0$ si $\mu_i^* > 0$; $\nabla g_i^\top d \leq 0$ si i activa con $\mu_i^* = 0$. *Necesaria* (con LICQ): $d^\top \nabla_{xx}^2 L d \geq 0$ en C , para mínimo. *Suficiente* (sin CQ): $d^\top \nabla_{xx}^2 L d > 0$ para todo $d \in C$, $d \neq 0 \Rightarrow$ mínimo local *estricto*. Máximos: al revés. *Hessiano orlado* (n variables, m igualdades, $m < n$): con $\bar{H} = \begin{pmatrix} 0 & A \\ A^\top & H \end{pmatrix}$ de orden $n + m$, importan los últimos $n - m$ menores principales líderes $D_{2m+1}, \dots, D_{n+m}$: para **máximo** deben alternar con $\text{signo}(D_{2m+k}) = (-1)^{m+k}$ (el último con el signo de $(-1)^n$); para **mínimo** todos con el signo de $(-1)^m$. Caso $n = 2$, $m = 1$: máximo si $\det \bar{H} > 0$, mínimo si $\det \bar{H} < 0$.

7. Precio sombra (teorema 9.42). Con $V(b)$ el valor óptimo de máx f s.a. $g_i(x) \leq b_i$, y bajo (i) $\mathcal{C}^2$, (ii) solución única, (iii) LICQ, (iv) holgura complementaria estricta + condición suficiente de segundo orden: $\partial V / \partial b_i = \mu_i^*$. Lecturas: λ^* de la UMP = utilidad marginal del ingreso ($\partial v / \partial m$); μ^* de la restricción de producción = costo marginal; multiplicador de la (IR) = costo para el principal de la utilidad de reserva del agente; multiplicador de la (IC) = costo marginal de la información asimétrica (renta informacional, prima de riesgo). La demostración general está en el capítulo 11; la versión no diferenciable con subgradiantes, en el capítulo 10.

8. Protocolo de examen (sección 9.7): normaliza $\rightarrow$ justifica existencia y CQ/suficiencia $\rightarrow$ escribe las cuatro condiciones completas $\rightarrow$ poda casos con argumentos económicos $\rightarrow$ enumera y resuelve los $2^{\#\text{desigualdades}}$ casos restantes $\rightarrow$ descarta *mostrando* la violación (factibilidad primal o signo del multiplicador) $\rightarrow$ concluye e interpreta los multiplicadores.

Referencias principales: [1, caps. 3–4], [6, cap. 3], [2, cap. 5], [5, cap. 12], [9, apéndice M], [10, cap. A2].

9.10. Ejercicios resueltos [P1]

Los seis ejercicios siguientes cubren, entre todos, el repertorio completo de lo que puede preguntarse: análisis exhaustivo de casos, soluciones de esquina con umbral, condiciones de segundo orden, fallo de la cualificación de restricciones, precios sombra verificados numéricamente y un programa de contratos. Todas las soluciones están completas: no hay ningún “se deja al lector”.

Intenta cada uno con papel antes de leer la solución; el valor está en el análisis de casos, no en la respuesta final.

Ejercicio 9.51 (Dos desigualdades: enumerar los cuatro casos). Considera el problema de proyectar el punto $(3, 4)$ sobre un conjunto factible definido por dos desigualdades:

$$\min_{x,y} f(x,y) = (x-3)^2 + (y-4)^2 \quad \text{s.a.} \quad x+y \leq 2, \quad x \geq 0.$$

(a) Escribe las condiciones KKT completas. (b) Enumera los cuatro casos de actividad, resuelve cada uno y descarta *mostrando* la violación correspondiente. (c) Justifica que el superviviente es el mínimo global. (d) Repite el problema cambiando el punto objetivo a $(0, 2)$ y explica qué tiene de particular la solución.

Solución. (a) **Planteamiento.** Forma estándar de minimización: $g_1(x,y) = x+y-2 \leq 0$ y $g_2(x,y) = -x \leq 0$, con gradientes constantes $\nabla g_1 = (1, 1)$, $\nabla g_2 = (-1, 0)$ y $\nabla f = (2(x-3), 2(y-4))$. Con $L = f + \mu_1 g_1 + \mu_2 g_2$:

$$\begin{aligned} (E_x) \quad & 2(x-3) + \mu_1 - \mu_2 = 0, \\ (E_y) \quad & 2(y-4) + \mu_1 = 0, \\ (FP) \quad & x+y \leq 2, \quad x \geq 0, \\ (FD) \quad & \mu_1 \geq 0, \quad \mu_2 \geq 0, \\ (HC) \quad & \mu_1(x+y-2) = 0, \quad \mu_2 x = 0. \end{aligned}$$

Antes de calcular: las dos restricciones son *afines*, luego KKT es necesaria sin ninguna hipótesis adicional, y f es convexa (suma de cuadrados; su Hessiana es $2I \succ 0$), luego KKT también será suficiente (teorema 9.32). Con $m = 2$ desigualdades hay $2^2 = 4$ casos.

(b) Los cuatro casos.

Caso 1: ninguna activa ($\mu_1 = \mu_2 = 0$). Las ecuaciones (E) dan el mínimo irrestricto $x = 3$, $y = 4$. Verificación de factibilidad primal: $x+y = 7 > 2$. **Descartado** por violar $g_1 \leq 0$.

Caso 2: g_1 activa, g_2 inactiva ($x+y = 2$, $\mu_2 = 0$, $x > 0$). De (E_x) y (E_y) con $\mu_2 = 0$:

$$\mu_1 = -2(x-3) = -2(y-4) \implies x-3 = y-4 \implies y = x+1.$$

Con $x+y = 2$: $2x+1 = 2$, es decir,

$$x^* = \frac{1}{2}, \quad y^* = \frac{3}{2}, \quad \mu_1 = -2\left(\frac{1}{2} - 3\right) = 5.$$

Verificación: $\mu_1 = 5 \geq 0 \checkmark$; $\mu_2 = 0 \geq 0 \checkmark$; $x^* = 1/2 > 0$, así que g_2 es efectivamente inactiva y (HC) se cumple $\checkmark$; $x^* + y^* = 2 \checkmark$. **Sobrevive.**

Caso 3: g_1 inactiva, g_2 activa ($x = 0$, $\mu_1 = 0$, $x+y < 2$). De (E_y) con $\mu_1 = 0$: $y = 4$. Pero entonces $x+y = 4 > 2$. **Descartado** por factibilidad primal (además contradice el supuesto $x+y < 2$).

Caso 4: ambas activas ($x = 0$ y $x+y = 2$, luego $y = 2$). De (E_y): $\mu_1 = -2(2-4) = 4$. De

(E_x): $2(0 - 3) + 4 - \mu_2 = 0$, es decir,

$$\mu_2 = -6 + 4 = -2 < 0.$$

Descartado por factibilidad dual ($\mu_2 \geq 0$ falla).

(c) Conclusión. El único punto KKT es $(x^*, y^*) = (1/2, 3/2)$ con $(\mu_1^*, \mu_2^*) = (5, 0)$, y el valor óptimo es

$$f(x^*, y^*) = \left(\frac{1}{2} - 3\right)^2 + \left(\frac{3}{2} - 4\right)^2 = \frac{25}{4} + \frac{25}{4} = 12.5, \quad \text{distancia} = \sqrt{12.5} \approx 3.5355.$$

Como el problema es convexo con restricciones afines, KKT es necesaria y suficiente: $(1/2, 3/2)$ es el mínimo global (y es único porque f es estrictamente convexa). Comprobación geométrica: el vector $(3, 4) - (1/2, 3/2) = (5/2, 5/2)$ es ortogonal a la recta $x + y = 2$, es decir, paralelo a $\nabla g_1 = (1, 1)$, exactamente la caracterización de la proyección sobre un hiperplano del capítulo 8. Además $\mu_1^* = 5$ es el precio sombra: si el recurso pasara de 2 a $2 + \varepsilon$ (restricción $x + y \leq 2 + \varepsilon$), la distancia *al cuadrado* bajaría a razón de 5 por unidad. Verifícalo: con recurso b , el punto óptimo es $(\frac{b-1}{2}, \frac{b+1}{2})$ y $V(b) = 2(\frac{7-b}{2})^2 = \frac{(7-b)^2}{2}$, luego $V'(2) = -(7-2) = -5 = -\mu_1^*$ (negativo porque *minimizamos*: relajar reduce el valor óptimo, y μ^* mide la mejora) ✓.

(d) El caso degenerado. Con punto objetivo $(0, 2)$, el problema es

$$\text{mín } x^2 + (y - 2)^2 \quad \text{s.a.} \quad x + y \leq 2, \quad x \geq 0.$$

El punto $(0, 2)$ *ya es factible* ($0 + 2 = 2 \leq 2$ y $x = 0 \geq 0$), así que la solución es él mismo, con valor 0. Sus multiplicadores: $\nabla f(0, 2) = (0, 0)$, de modo que (E_x) y (E_y) se satisfacen con

$$\mu_1^* = \mu_2^* = 0, \quad \text{pero ambas restricciones están activas.}$$

Este es el **caso degenerado** anunciado en la sección 9.5.2: holgura complementaria se cumple ($\mu_i g_i = 0$) porque se anulan *los dos* factores. Las restricciones tocan al óptimo pero no ejercen presión: relajar cualquiera de ellas no mejora nada, porque el mínimo irrestricto está justo en la esquina. Dos observaciones finas y muy examinables:

- Aquí *no* falla ninguna cualificación de restricciones: $\nabla g_1 = (1, 1)$ y $\nabla g_2 = (-1, 0)$ son linealmente independientes, así que LICQ se cumple y el multiplicador es único (el nulo). Lo que falla es la *holgura complementaria estricta*, la hipótesis (H4) del teorema 9.42.
- Consecuencia: la función de valor $V(b)$ (con recurso b en lugar de 2) tiene un *quiebre* en $b = 2$: $V(b) = 0$ para $b \geq 2$ y $V(b) = (2 - b)^2$ para $b < 2$ (con $b < 2$ el mínimo se alcanza en $x = 0$, $y = b$, porque la proyección sobre la recta $x + y = b$ tendría $x < 0$). Es diferenciable aquí por casualidad ($V'(2^-) = 0 = V'(2^+)$), pero en general la degeneración es la señal de alarma de que la derivada del valor óptimo puede no existir y solo haya derivadas direccionales.

□

Ejercicio 9.52 (Cuasilineal: umbral exacto entre esquina e interior). Un consumidor tiene

utilidad $u(x, y) = 2\sqrt{x} + y$, precios $p > 0$ para x y 1 para y , e ingreso $m > 0$:

$$\max_{x,y} 2\sqrt{x} + y \quad \text{s.a.} \quad px + y \leq m, \quad x \geq 0, \quad y \geq 0.$$

(a) Resuelve por KKT distinguiendo los regímenes interior y de esquina, y determina el **umbral exacto** de ingreso que los separa. (b) Escribe las demandas marshallianas y la utilidad indirecta en cada régimen, y verifica que $\partial v / \partial m = \lambda^*$. (c) Ilustra con $p = 1/4$ y los ingresos $m = 1$ y $m = 9$.

Solución. Preliminares (P1–P2). Desigualdades: $g_0 = px + y - m \leq 0$, $g_1 = -x \leq 0$, $g_2 = -y \leq 0$; todas afines, luego KKT es necesaria sin CQ adicional. u es cóncava ($2\sqrt{x}$ es cóncava, y es lineal), así que KKT también es suficiente. Existencia: el conjunto presupuestario es compacto y u continua.

Poda inmediata: $u_x = 1/\sqrt{x} \rightarrow +\infty$ cuando $x \downarrow 0$ (condición de Inada), de modo que la esquina $x = 0$ nunca es óptima: partiendo de $x = 0$, mover un ε de gasto de y hacia x aumenta la utilidad en $2\sqrt{\varepsilon/p} - \varepsilon$, que es positivo para ε pequeño. Por tanto $x^* > 0$ y $\mu_1 = 0$.

P3 (condiciones). Con $L = 2\sqrt{x} + y - \lambda(px + y - m) + \mu_2 y$:

$$(E_x) \quad \frac{1}{\sqrt{x}} - \lambda p = 0 \quad \implies \quad \lambda = \frac{1}{p\sqrt{x}} > 0,$$

$$(E_y) \quad 1 - \lambda + \mu_2 = 0 \quad \implies \quad \mu_2 = \lambda - 1,$$

$$(HC) \quad \lambda(px + y - m) = 0, \quad \mu_2 y = 0.$$

Como (E_x) fuerza $\lambda > 0$, la holgura complementaria implica que **el presupuesto siempre se satura**: $px + y = m$. Quedan dos casos, según $y \geq 0$.

Caso A (interior, $y > 0$). Por (HC), $\mu_2 = 0$; por (E_y) , $\lambda = 1$; por (E_x) ,

$$1 = \frac{1}{p\sqrt{x}} \implies \sqrt{x} = \frac{1}{p} \implies x^* = \frac{1}{p^2},$$

y el presupuesto da $y^* = m - px^* = m - \frac{1}{p}$. *Verificación:* el caso requiere $y^* > 0$, es decir,

$$\boxed{m > \frac{1}{p}} \quad (\text{régimen interior}).$$

Todos los demás signos se cumplen: $\lambda^* = 1 > 0$, $\mu_2^* = 0$, $x^* > 0$ ✓.

Caso B (esquina, $y = 0$). El presupuesto saturado da $x^* = m/p$. Entonces

$$\lambda^* = \frac{1}{p\sqrt{m/p}} = \frac{1}{\sqrt{pm}}, \quad \mu_2^* = \lambda^* - 1 = \frac{1}{\sqrt{pm}} - 1.$$

Verificación: el caso requiere $\mu_2^* \geq 0$, o sea $\sqrt{pm} \leq 1$, es decir,

$$\boxed{m \leq \frac{1}{p}} \quad (\text{régimen de esquina}).$$

Umbral. Los dos regímenes se reparten exactamente el espacio de parámetros y el umbral

es $\hat{m} = 1/p$. En $m = \hat{m}$ ambos coinciden: $x^* = 1/p^2 = m/p$, $y^* = 0$, $\lambda^* = 1$, $\mu_2^* = 0$ (caso degenerado: activa con precio cero, como en el ejercicio 9.51(d)).

(b) **Demandas y utilidad indirecta.**

$$x^*(p, m) = \begin{cases} \frac{m}{p}, & m \leq 1/p, \\ \frac{1}{p^2}, & m > 1/p, \end{cases} \quad y^*(p, m) = \begin{cases} 0, & m \leq 1/p, \\ m - \frac{1}{p}, & m > 1/p, \end{cases}$$

$$v(p, m) = \begin{cases} 2\sqrt{m/p}, & m \leq 1/p, \\ m + \frac{1}{p}, & m > 1/p. \end{cases}$$

Verificación del precio sombra en cada rama:

- Régimen interior: $\partial v / \partial m = 1 = \lambda^* \checkmark$. La utilidad marginal del ingreso es *constante*: la marca de fábrica de la cuasilinealidad, y la razón por la que no hay efectos ingreso sobre x (toda la renta adicional va al numerario y ; la curva de Engel de x es vertical).
- Régimen de esquina: $\frac{\partial}{\partial m} 2\sqrt{m/p} = \frac{1}{\sqrt{pm}} = \lambda^* \checkmark$. Aquí sí hay efecto ingreso, y $\lambda^* > 1$: cuando el consumidor es demasiado pobre para consumir numerario, el ingreso vale más que un “útil” por sol.

Nota además que v es continua y C^1 en el umbral ($v = 2/p$ y $\partial v / \partial m = 1$ por ambos lados): la función de valor pega suavemente aunque el régimen cambie.

(c) **Números con $p = 1/4$ (umbral $\hat{m} = 1/p = 4$).**

m	régimen	x^*	y^*	λ^*	μ_2^*
1	esquina ($m < 4$)	$m/p = 4$	0	$1/\sqrt{pm} = 2$	1
9	interior ($m > 4$)	$1/p^2 = 16$	$9 - 4 = 5$	1	0

Comprobaciones: con $m = 1$, $u = 2\sqrt{4} + 0 = 4 = 2\sqrt{m/p} = 2\sqrt{4} \checkmark$; con $m = 9$, $u = 2\sqrt{16} + 5 = 13 = m + 1/p = 9 + 4 \checkmark$; y el gasto es $\frac{1}{4} \cdot 16 + 5 = 9 = m \checkmark$. Lectura económica de $\mu_2^* = 1$ en el régimen pobre: el consumidor querría un y negativo (“endeudarse” en numerario para comprar más x); la restricción $y \geq 0$ se lo impide y su precio sombra vale 1 útil por unidad de y que se le permitiera vender. $\square$

Ejercicio 9.53 (Cuadrática con una igualdad y una desigualdad, con segundo orden). Considera

$$\min_{x,y} f(x, y) = x^2 - 4xy + y^2 \quad \text{s.a.} \quad x + y = 2, \quad x \geq 0.$$

- (a) Comprueba que f no es convexa. (b) Resuelve por KKT con análisis exhaustivo de casos. (c) Verifica las condiciones de segundo orden, primero sobre el subespacio tangente y luego con el Hessiano orlado. (d) ¿Es el punto un mínimo global del problema restringido?

Solución. (a) f no es convexa. Su Hessiana es constante,

$$\nabla^2 f = \begin{pmatrix} 2 & -4 \\ -4 & 2 \end{pmatrix},$$

con autovalores $2 - 4 = -2$ y $2 + 4 = 6$ (para una matriz $\begin{pmatrix} a & b \\ b & a \end{pmatrix}$ los autovalores son $a \pm b$, con autovectores $(1, 1)$ y $(1, -1)$). Hay un autovalor negativo: $\nabla^2 f$ es *indefinida* y f no es convexa (de hecho el origen es un punto de silla de f). Por tanto *no* podemos invocar el teorema 9.32: KKT dará candidatos y habrá que verificar con segundo orden.

(b) KKT. Forma estándar: $h(x, y) = x + y - 2 = 0$ y $g(x, y) = -x \leq 0$, con $\nabla h = (1, 1)$, $\nabla g = (-1, 0)$ y $\nabla f = (2x - 4y, -4x + 2y)$. Como ambas restricciones son afines, KKT es necesaria sin CQ adicional (y de paso: LICQ se cumple en todo punto factible, porque $(1, 1)$ y $(-1, 0)$ son linealmente independientes). Con $L = f + \lambda h + \mu g$:

$$(E_x) \quad 2x - 4y + \lambda - \mu = 0,$$

$$(E_y) \quad -4x + 2y + \lambda = 0,$$

$$(FP) \quad x + y = 2, \quad x \geq 0,$$

$$(FD) \quad \mu \geq 0, \quad \lambda \in \mathbb{R} \text{ libre},$$

$$(HC) \quad \mu x = 0.$$

Una sola desigualdad, luego dos casos.

Caso 1: g inactiva ($x > 0, \mu = 0$). Restando (E_y) de (E_x) :

$$(2x - 4y) - (-4x + 2y) = 6x - 6y = 0 \implies x = y.$$

Con $x + y = 2$: $x = y = 1$. Entonces $\lambda = 4x - 2y = 4 - 2 = 2$. *Verificación*: $x = 1 > 0$ ✓ (coherente con $\mu = 0$ y con (HC)), $\mu = 0 \geq 0$ ✓, restricción de igualdad satisfecha ✓.

Sobrevive: $(x^*, y^*) = (1, 1)$, $\lambda^* = 2$, $\mu^* = 0$, con $f(1, 1) = 1 - 4 + 1 = -2$.

Caso 2: g activa ($x = 0$). La igualdad da $y = 2$. De (E_y) : $\lambda = 4x - 2y = -4$. De (E_x) : $\mu = 2x - 4y + \lambda = -8 - 4 = -12 < 0$. **Descartado** por factibilidad dual.

(c) Segundo orden. Como todas las restricciones son afines, $\nabla_{xx}^2 L = \nabla^2 f$ (los términos $\lambda \nabla^2 h$ y $\mu \nabla^2 g$ son nulos). El *cono crítico* en $(1, 1)$: la igualdad impone $\nabla h^\top d = d_1 + d_2 = 0$; la desigualdad está *inactiva*, así que no impone nada. Luego

$$C = \{d : d_1 + d_2 = 0\} = \text{span}\{(1, -1)\},$$

una recta. Evaluamos la forma cuadrática en $d = (1, -1)$:

$$d^\top \nabla^2 f d = 2(1)^2 + 2(-4)(1)(-1) + 2(-1)^2 = 2 + 8 + 2 = 12 > 0.$$

Estrictamente positiva sobre $C \setminus \{0\}$: por el teorema 9.46, $(1, 1)$ es un **mínimo local estricto**. Observa lo esencial: en $\mathbb{R}^2$ la Hessiana es indefinida (en la dirección $(1, 1)$ da $2 + (-8) + 2 = -4 < 0$), pero esa dirección *sale* del conjunto factible, así que es irrelevante. Restringidos a la recta factible, la curvatura es positiva.

Con Hessiano orlado. Aquí $n = 2$, $m = 1$ (solo la igualdad orla; la desigualdad inactiva no

participa), $A = (1, 1)$ y

$$\bar{H} = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 2 & -4 \\ 1 & -4 & 2 \end{pmatrix}, \quad D_3 = \det \bar{H} = -1[(1)(2) - (-4)(1)] + [(1)(-4) - (2)(1)] = -6 - 6 = -12.$$

Hay $n - m = 1$ menor relevante y, para *mínimo*, debe tener el signo de $(-1)^m = -1$: $D_3 = -12 < 0$ ✓. Coincide con el cálculo anterior, como anticipaba la sección 9.9: $D_3 = -d^\top \nabla^2 f d = -12$.

(d) **Global.** Sí. Parametriza la restricción con $y = 2 - x$:

$$\varphi(x) = f(x, 2 - x) = x^2 - 4x(2 - x) + (2 - x)^2 = 6x^2 - 12x + 4,$$

una parábola *convexa* ($\varphi'' = 12 > 0$) con vértice en $\varphi'(x) = 12x - 12 = 0$, es decir, $x = 1$, y valor $\varphi(1) = -2$. Como el conjunto factible en esta parametrización es $\{x \geq 0\}$ y el vértice cae dentro, $(1, 1)$ es el *mínimo global* del problema restringido, con $f = -2$. Moraleja: una función no convexa puede ser convexa *sobre el conjunto factible*; eso es justo lo que miden las condiciones de segundo orden restringidas, y por eso son la herramienta correcta cuando el teorema de suficiencia convexa no aplica. $\square$

Ejercicio 9.54 (Cuando KKT falla: violación de la cualificación de restricciones). Considera

$$\max_{x,y} x \quad \text{s.a.} \quad y \leq (1 - x)^3, \quad x \geq 0, \quad y \geq 0.$$

(a) Encuentra el óptimo por razonamiento directo. (b) Demuestra que en ese óptimo **no existen multiplicadores KKT**. (c) Diagnostica qué cualificación falla y compara el cono tangente con el cono linealizado. (d) Muestra cómo una reescritura del mismo conjunto factible restaura KKT, y extrae la moraleja.

Solución. (a) **El óptimo.** Cualquier punto factible cumple $0 \leq y \leq (1 - x)^3$, lo que obliga a $(1 - x)^3 \geq 0$, es decir, $x \leq 1$. Luego el valor máximo posible del objetivo es $x = 1$, y se alcanza: con $x = 1$ la cadena $0 \leq y \leq 0$ fuerza $y = 0$, y el punto $(1, 0)$ es factible. Por tanto

$$(x^*, y^*) = (1, 0), \quad \text{valor óptimo} = 1.$$

(Existencia garantizada: el conjunto factible es compacto (cerrado y contenido en $[0, 1] \times [0, 1]$) y el objetivo continuo.)

(b) **No hay multiplicadores.** Pasemos a forma estándar de minimización, mín $-x$, con

$$g_1(x, y) = y - (1 - x)^3 \leq 0, \quad g_2(x, y) = -x \leq 0, \quad g_3(x, y) = -y \leq 0.$$

Actividad en $(1, 0)$: $g_1 = 0 - 0 = 0$ **activa**; $g_2 = -1 < 0$ **inactiva** (luego $\mu_2 = 0$ por holgura complementaria); $g_3 = 0$ **activa**. Gradientes:

$$\nabla f = (-1, 0), \quad \nabla g_1 = (3(1 - x)^2, 1)|_{(1,0)} = (0, 1), \quad \nabla g_3 = (0, -1).$$

La condición de estacionariedad exigiría $\mu_1, \mu_3 \geq 0$ con

$$(-1, 0) + \mu_1(0, 1) + \mu_3(0, -1) = (0, 0) \iff \begin{cases} -1 + 0 = 0 & \text{(primera componente),} \\ \mu_1 - \mu_3 = 0 & \text{(segunda componente).} \end{cases}$$

La primera ecuación es $-1 = 0$: **imposible**. No existe ningún par (μ_1, μ_3) , ni siquiera permitiendo signos arbitrarios. El óptimo global del problema *no* es un punto KKT. La razón intuitiva: todos los gradientes activos son verticales, así que ninguna combinación suya puede cancelar la componente horizontal de ∇f , y la componente horizontal es justamente la dirección en la que quisiéramos avanzar.

(c) Diagnóstico.

- **LICQ falla:** $\nabla g_1 = (0, 1)$ y $\nabla g_3 = (0, -1)$ son linealmente dependientes ($\nabla g_1 + \nabla g_3 = 0$).
- **MFCQ falla:** habría que encontrar d con $\nabla g_1^\top d = d_2 < 0$ y $\nabla g_3^\top d = -d_2 < 0$ simultáneamente, o sea $d_2 < 0$ y $d_2 > 0$. Imposible: no hay ninguna dirección que entre estrictamente al conjunto factible.
- **Slater no aplica:** el problema no es convexo. g_1 no es convexa (en x , $-(1-x)^3$ tiene segunda derivada $-6(1-x) < 0$ para $x < 1$: es cóncava), y el conjunto factible tampoco lo es: $(0, 1)$ y $(1, 0)$ son factibles, pero su punto medio $(\frac{1}{2}, \frac{1}{2})$ exigiría $\frac{1}{2} \leq (\frac{1}{2})^3 = \frac{1}{8}$, falso.
- **Conos.** El cono tangente en $(1, 0)$ es $T = \{d : d_1 \leq 0, d_2 = 0\}$: solo se puede salir hacia la izquierda, y no se puede subir, porque a lo largo de cualquier curva factible $y(t) \leq (1-x(t))^3 = O(t^3)$, de modo que $y(t)/t \rightarrow 0$. En cambio el cono linealizado (definición 9.27) es

$$L_X(x^*) = \{d : \nabla g_1^\top d \leq 0, \nabla g_3^\top d \leq 0\} = \{d : d_2 \leq 0, -d_2 \leq 0\} = \{d : d_2 = 0\},$$

que *no* restringe d_1 . Así $T \subsetneq L_X(x^*)$ estrictamente (lema 9.28 se cumple, pero con inclusión propia), y la dirección $d = (1, 0) \in L_X(x^*) \setminus T$ es una dirección de descenso del objetivo ($\nabla f^\top d = -1 < 0$). Exactamente esa es la brecha que rompe la demostración del teorema 9.26: el lema de Farkas (lema 9.29) se aplica al cono linealizado, y aquí el cono linealizado “ve” una mejora que el conjunto factible verdadero no permite.

Compara con el ejemplo 9.19: es el mismo fenómeno (frontera con contacto de orden superior, cúspide o tangencia degenerada) en otro disfraz.

(d) Reescritura que restaura KKT. El conjunto factible no cambia si añadimos la restricción *redundante* $g_4(x, y) = x - 1 \leq 0$ (ya vimos que toda solución factible cumple $x \leq 1$). Ahora en $(1, 0)$ hay tres activas y $\nabla g_4 = (1, 0)$, de modo que la estacionariedad

$$(-1, 0) + \mu_1(0, 1) + \mu_3(0, -1) + \mu_4(1, 0) = (0, 0)$$

se resuelve con $\mu_4 = 1$ y $\mu_1 = \mu_3$ (por ejemplo $\mu_1 = \mu_3 = 0$): todos ≥ 0 ✓. Con esta descripción, el cono linealizado pasa a ser $\{d : d_2 = 0, d_1 \leq 0\} = T$, es decir, se cumple la cualificación de Abadie y KKT vuelve a ser necesaria (aunque LICQ y MFCQ sigan fallando, y por eso el multiplicador no es único).

Moraleja de examen. Las cualificaciones de restricciones son propiedades de la *descripción*

algebraica del conjunto factible, no solo del conjunto. Dos sistemas de desigualdades que definen exactamente la misma región pueden diferir en si KKT es válida. Consecuencias prácticas: (i) nunca escribas “por KKT, el óptimo satisface...” sin verificar una CQ; (ii) si una restricción se puede escribir de forma afín, escríbela así; (iii) cuando el sistema KKT resulte incompatible, la sospecha número uno debe ser un fallo de CQ, no un error de álgebra. $\square$

Ejercicio 9.55 (Asignación de un recurso y precio sombra). Un planificador reparte un recurso escaso $R > 0$ entre dos usos, con beneficios

$$\max_{x_1, x_2} f(x_1, x_2) = 10x_1 - x_1^2 + 8x_2 - x_2^2 \quad \text{s.a.} \quad x_1 + x_2 \leq R, \quad x_1 \geq 0, \quad x_2 \geq 0.$$

(a) Resuelve por KKT para $R = 6$. (b) Interpreta el multiplicador como precio sombra y verifícalo numéricamente perturbando el recurso a $R = 6.1$ y a $R = 7$. (c) Obtén el mapa completo de regímenes: ¿para qué valores de R muere la restricción de recursos y para cuáles muere $x_2 \geq 0$? Escribe $V(R)$ y comprueba que $V'(R) = \lambda^*(R)$ en cada tramo.

Solución. (a) **Solución con $R = 6$.** El objetivo es cóncavo (Hessiana $-2I \prec 0$) y las restricciones son afines: KKT es necesaria y suficiente, y el máximo existe y es único. Con $L = f - \lambda(x_1 + x_2 - R) + \mu_1 x_1 + \mu_2 x_2$:

$$(E_1) \quad 10 - 2x_1 - \lambda + \mu_1 = 0,$$

$$(E_2) \quad 8 - 2x_2 - \lambda + \mu_2 = 0,$$

$$(HC) \quad \lambda(x_1 + x_2 - R) = 0, \quad \mu_1 x_1 = 0, \quad \mu_2 x_2 = 0,$$

$$(FD) \quad \lambda, \mu_1, \mu_2 \geq 0.$$

Poda. Con $R = 6$, si el recurso sobrara ($\lambda = 0$) tendríamos, con $\mu_i = 0$, $x_1 = 5$ y $x_2 = 4$, cuya suma $9 > 6$ es infactible: contradicción. Luego $\lambda > 0$ y el recurso se agota: $x_1 + x_2 = 6$. Supongamos también $x_1, x_2 > 0$ (lo verificaremos), de modo que $\mu_1 = \mu_2 = 0$. Entonces (E_1) y (E_2) igualan los *beneficios marginales*:

$$10 - 2x_1 = \lambda = 8 - 2x_2 \quad \implies \quad x_1 - x_2 = 1.$$

Junto con $x_1 + x_2 = 6$:

$$\boxed{x_1^* = 3.5, \quad x_2^* = 2.5, \quad \lambda^* = 10 - 2(3.5) = 3.}$$

Verificación: $x_1^*, x_2^* > 0$ ✓ (coherente con $\mu_1 = \mu_2 = 0$), $\lambda^* = 3 > 0$ ✓, recurso agotado ✓. Valor óptimo:

$$V(6) = 10(3.5) - 3.5^2 + 8(2.5) - 2.5^2 = 35 - 12.25 + 20 - 6.25 = 36.5.$$

(b) Precio sombra y verificación numérica. La lectura de $\lambda^* = 3$: una unidad adicional de recurso aumenta el beneficio total en aproximadamente 3. Es también el *beneficio marginal común* de los dos usos: en el óptimo el planificador iguala $\partial f / \partial x_1 = \partial f / \partial x_2 = \lambda^*$, que es la condición de eficiencia en la asignación (si un uso rindiera más al margen, convendría trasladarle recurso). En una economía descentralizada, λ^* sería el *precio de mercado* del recurso.

Resolviendo para R genérico con el mismo régimen: $x_1 = \frac{R+1}{2}$, $x_2 = \frac{R-1}{2}$, $\lambda^*(R) = 10 - (R + 1) = 9 - R$, y

$$V(R) = 10 \frac{R+1}{2} + 8 \frac{R-1}{2} - \frac{(R+1)^2 + (R-1)^2}{4} = (9R + 1) - \frac{R^2+1}{2} = -\frac{R^2}{2} + 9R + \frac{1}{2}.$$

R	x_1^*	x_2^*	λ^*	$V(R)$	ΔV frente a $\lambda^*(6) \Delta R$
6	3.5	2.5	3	36.5	.
6.1	3.55	2.55	2.9	36.795	0.295 vs. $3 \cdot 0.1 = 0.3$
7	4	3	2	39	2.5 vs. $3 \cdot 1 = 3$

Comprobaciones: $V(6.1) = -18.605 + 54.9 + 0.5 = 36.795$; $V(7) = -24.5 + 63 + 0.5 = 39$. El error de la aproximación lineal es exactamente el término de segundo orden: como $V'' = -1$,

$$V(R + \Delta) - V(R) = \lambda^* \Delta - \frac{1}{2} \Delta^2,$$

lo que da errores de $\frac{1}{2}(0.1)^2 = 0.005$ y $\frac{1}{2}(1)^2 = 0.5$: coinciden al céntimo con la tabla ✓. Y en efecto $V'(R) = -R + 9 = \lambda^*(R)$ ✓, que es el teorema 9.42. Observa la concavidad de V : el precio sombra *cae* conforme el recurso abunda ($\lambda^*(6) = 3 > \lambda^*(7) = 2$), lo cual es la ley de rendimientos marginales decrecientes vista desde la función de valor.

(c) Mapa completo de regímenes. El régimen anterior requiere $x_2 \geq 0$ y $\lambda \geq 0$, es decir, $R \geq 1$ y $R \leq 9$.

- **Recurso abundante**, $R \geq 9$. La restricción de recursos no muerde: $\lambda^* = 0$, $\mu_1 = \mu_2 = 0$, y el óptimo es el irrestricto $x_1^* = 5$, $x_2^* = 4$ (que es factible porque $9 \leq R$), con $V(R) = 25 + 16 = 41$ constante. Precio sombra cero: *lo que sobra es gratis*, holgura complementaria en estado puro. Observa la continuidad en $R = 9$: $-40.5 + 81 + 0.5 = 41$ ✓, y $V'(9) = 0 = \lambda^*(9)$ ✓.
- **Régimen interior**, $1 \leq R \leq 9$. El del apartado (a).
- **Recurso muy escaso**, $R \leq 1$. Aquí la fórmula daría $x_2 < 0$: muerde la no negatividad del segundo uso. Con $x_2 = 0$ y recurso agotado, $x_1 = R$; entonces (E₁) da $\lambda = 10 - 2R$ y (E₂) da $\mu_2 = \lambda - 8 = 2 - 2R \geq 0$ si y solo si $R \leq 1$ ✓ (consistencia del régimen). $V(R) = 10R - R^2$, y $V'(R) = 10 - 2R = \lambda^*(R)$ ✓. Economía: cuando el recurso es tan escaso que su precio sombra supera el beneficio marginal máximo del segundo uso (8), todo el recurso va al primero.

En $R = 1$ y $R = 9$ los regímenes empalman con continuidad de V y de λ^* ($\lambda^*(1) = 8$ por ambos lados; $\lambda^*(9) = 0$ por ambos lados): la función de valor es C^1 y cóncava, y su derivada es el precio sombra en todo tramo. □

Ejercicio 9.56 (Principal-agente con riesgo moral: IR, IC y sus multiplicadores). Un principal neutral al riesgo contrata a un agente averso al riesgo con utilidad $v(w) = \sqrt{w}$ y utilidad de reserva $\bar{u} = 1$. El agente elige esfuerzo $e \in \{A, B\}$ (alto o bajo). El producto vale 10 si hay éxito y 0 si hay fracaso, con probabilidad de éxito

$$p = \Pr(\text{éxito} \mid A) = 0.8, \quad q = \Pr(\text{éxito} \mid B) = 0.4.$$

El esfuerzo alto le cuesta al agente $c = 0.5$ en unidades de utilidad; el bajo, 0. La utilidad del agente es $\sqrt{w} - c(e)$. El principal observa el resultado pero *no* el esfuerzo, y quiere imple-

mentar $e = A$ al mínimo costo esperado con salarios contingentes w_S (éxito) y w_F (fracaso), $w_S, w_F \geq 0$. (a) Escribe el programa con las restricciones (IR) e (IC) y conviértelo en un problema convexo. (b) Escribe las condiciones KKT. (c) Determina cuáles muerden, resuelve y calcula los multiplicadores. (d) Interpreta γ (multiplicador de IR) y δ (multiplicador de IC), verificándolos numéricamente, y compara con el *first best*. (e) Comprueba que al principal le conviene implementar A .

Solución. (a) **El programa y el cambio de variable clave.** El principal minimiza el salario esperado sujeto a que el agente (i) acepte y (ii) prefiera esforzarse:

$$\min_{w_S, w_F \geq 0} p w_S + (1-p) w_F$$

$$(IR) \quad p\sqrt{w_S} + (1-p)\sqrt{w_F} - c \geq \bar{u}, \quad (IC) \quad p\sqrt{w_S} + (1-p)\sqrt{w_F} - c \geq q\sqrt{w_S} + (1-q)\sqrt{w_F}.$$

Tal cual está, el problema es feo: el objetivo es lineal pero las restricciones son cóncavas en w y el conjunto factible no es convexo en esas variables. El truco estándar (y examinable) es cambiar de variable a *utilidades* en vez de salarios:

$$u_S = \sqrt{w_S}, \quad u_F = \sqrt{w_F} \quad \Longleftrightarrow \quad w_S = u_S^2, \quad w_F = u_F^2, \quad u_S, u_F \geq 0.$$

Entonces el objetivo pasa a ser $p u_S^2 + (1-p) u_F^2$, *convexo*, y ambas restricciones se vuelven **lineales**. Simplificando la (IC): $p u_S + (1-p) u_F - c \geq q u_S + (1-q) u_F$ equivale a $(p-q)(u_S - u_F) \geq c$. Con los números ($p = 0.8$, $q = 0.4$, $c = 0.5$, $\bar{u} = 1$):

$$(IR) \quad 0.8 u_S + 0.2 u_F \geq 1.5, \quad (IC) \quad 0.4(u_S - u_F) \geq 0.5 \Longleftrightarrow u_S - u_F \geq 1.25.$$

Problema convexo con restricciones afines: KKT es necesaria y suficiente (corolario 9.33); Slater se cumple trivialmente (toma u_S grande y $u_F = 0$).

(b) **Condiciones KKT.** En forma estándar, $g_1 = \bar{u} + c - p u_S - (1-p) u_F \leq 0$ (IR) y $g_2 = c - (p-q)(u_S - u_F) \leq 0$ (IC), con multiplicadores $\gamma, \delta \geq 0$. Ignoramos de momento $u_S, u_F \geq 0$ y verificaremos al final que se cumplen. Con $L = p u_S^2 + (1-p) u_F^2 + \gamma g_1 + \delta g_2$:

$$(E_S) \quad 2p u_S - \gamma p - \delta(p-q) = 0 \quad \Longrightarrow \quad 2u_S = \gamma + \delta\left(1 - \frac{q}{p}\right),$$

$$(E_F) \quad 2(1-p) u_F - \gamma(1-p) + \delta(p-q) = 0 \quad \Longrightarrow \quad 2u_F = \gamma - \delta \frac{p-q}{1-p},$$

$$(HC) \quad \gamma g_1 = 0, \quad \delta g_2 = 0, \quad (FD) \quad \gamma \geq 0, \quad \delta \geq 0.$$

Estas dos ecuaciones son la *condición de Holmström*: como $1/v'(w) = 2\sqrt{w}$, dicen

$$\frac{1}{v'(w_s)} = \gamma + \delta \left(1 - \frac{\Pr(s|B)}{\Pr(s|A)}\right),$$

es decir, *el pago óptimo se ajusta según cuánto informa cada resultado sobre el esfuerzo* (el cociente de verosimilitudes). Con $p = 0.8$, $q = 0.4$: $1-q/p = 0.5$ para el éxito y $(p-q)/(1-p) = 2$ para el fracaso.

(c) **¿Cuáles muerden?** Cuatro casos, y tres caen de inmediato.

Caso $\delta = 0$ (IC holgada). Entonces (E_S) y (E_F) dan $2u_S = \gamma = 2u_F$, es decir, seguro pleno $u_S = u_F$. Pero entonces la (IC) exige $0.4 \cdot 0 = 0 \geq 0.5$: **falso**. Contradicción, luego $\boxed{\delta > 0}$ y la (IC) se satura. *Economía:* sin incentivos el agente no se esforzaría; con información asimétrica el contrato *debe* exponer al agente al riesgo. Compara con el ejemplo 9.39, donde sin (IC) el óptimo era exactamente el seguro pleno.

Caso $\gamma = 0$ (IR holgada). Entonces (E_F) daría $2u_F = -\delta(p - q)/(1 - p) = -2\delta < 0$, imposible porque $u_F = \sqrt{w_F} \geq 0$. Contradicción, luego $\boxed{\gamma > 0}$ y la (IR) se satura. (Argumento económico equivalente: si al agente le sobrara utilidad, el principal bajaría ambos salarios en la misma cantidad de utilidad, lo que no afecta a la (IC), que solo depende de la *diferencia*, y reduce el costo.)

Caso ambas holgadas: descartado por cualquiera de los dos argumentos anteriores. Queda un único caso: **ambas muerden**, y el sistema es lineal:

$$\begin{cases} u_S - u_F = 1.25, \\ 0.8u_S + 0.2u_F = 1.5. \end{cases}$$

Sustituyendo $u_F = u_S - 1.25$: $0.8u_S + 0.2u_S - 0.25 = 1.5$, luego

$$\boxed{u_S = 1.75, \quad u_F = 0.5, \quad w_S = u_S^2 = 3.0625, \quad w_F = u_F^2 = 0.25.}$$

Ambos ≥ 0 ✓ (la restricción de no negatividad que habíamos ignorado se cumple con holgura). Costo esperado del contrato:

$$C^{SB} = 0.8(3.0625) + 0.2(0.25) = 2.45 + 0.05 = 2.50.$$

Multiplicadores: de (E_S) y (E_F) ,

$$2(1.75) = 3.5 = \gamma + 0.5\delta, \quad 2(0.5) = 1 = \gamma - 2\delta.$$

Restando: $2.5 = 2.5\delta$, luego $\delta = 1$ y $\gamma = 1 + 2 = 3$. Ambos positivos ✓, consistente con que las dos restricciones muerdan.

(d) Interpretación y verificación numérica.

$\gamma = 3$: *el precio de la utilidad de reserva*. Es el costo marginal (en salario esperado) de garantizarle al agente un útil adicional. Verificación: sube $\bar{u}$ de 1 a 1.1. Las dos restricciones saturadas dan $u_S - u_F = 1.25$ y $0.8u_S + 0.2u_F = 1.6$, luego $u_S = 1.85$, $u_F = 0.6$ y

$$C = 0.8(1.85)^2 + 0.2(0.6)^2 = 2.738 + 0.072 = 2.81, \quad \Delta C = 0.31 \approx \gamma \cdot 0.1 = 0.3 \quad \checkmark$$

(la diferencia 0.01 es el término de segundo orden). Si el mercado laboral mejora para el agente, el principal paga: a razón de 3 soles esperados por útil.

$\delta = 1$: *el precio de la información asimétrica*. Es el costo marginal de que exista la restricción de incentivos. Verificación: endurece la (IC) exigiendo $(p - q)(u_S - u_F) \geq c + t$ con $t = 0.1$ (imagina que la desviación se vuelve más tentadora). Entonces $u_S - u_F = 0.6/0.4 = 1.5$ y, con la (IR)

intacta, $u_S = 1.8$, $u_F = 0.3$:

$$C = 0.8(1.8)^2 + 0.2(0.3)^2 = 2.592 + 0.018 = 2.61, \quad \Delta C = 0.11 \approx \delta \cdot 0.1 = 0.1 \checkmark$$

Comparación con el first best. Si el esfuerzo fuera observable (información simétrica), la (IC) desaparecería y solo quedaría la (IR): por el argumento del caso $\delta = 0$, el contrato óptimo sería **seguro pleno** $u_S = u_F = u$, con la (IR) saturada: $u = \bar{u} + c = 1.5$, es decir, $w_S = w_F = 2.25$ y

$$C^{FB} = 2.25 \quad \text{frente a} \quad C^{SB} = 2.50.$$

El **costo de agencia** es $C^{SB} - C^{FB} = 0.25$: es la *prima de riesgo* que hay que pagarle a un agente averso al riesgo por exponerlo a la lotería salarial $(3.0625, 0.25)$, cuya utilidad esperada es la misma que la del salario seguro 2.25, pero cuyo costo esperado es mayor por la desigualdad de Jensen. Observa la diferencia conceptual, que conviene tener clarísima al estudiar el problema principal-agente: aquí la (IR) muerde y el agente *no* obtiene renta alguna; el costo de la información asimétrica toma la forma de ineficiencia en el reparto del riesgo. En modelos de *selección adversa* (tipos privados en lugar de acción oculta), en cambio, la (IC) del tipo eficiente suele forzar que su (IR) quede holgada, y entonces el costo de la información asimétrica aparece como **renta informacional** pagada al tipo eficiente. En ambos casos, el diagnóstico “qué restricciones muerden” se obtiene con el mismo análisis de casos KKT.

(e) **¿Conviene implementar el esfuerzo alto?** Con esfuerzo alto, el producto esperado es $0.8 \cdot 10 = 8$ y el beneficio del principal $8 - C^{SB} = 8 - 2.50 = 5.50$. Si en cambio implementara el esfuerzo bajo, no necesitaría (IC) alguna (el esfuerzo bajo es el que el agente elige por defecto), así que el contrato óptimo sería un salario fijo w con $\sqrt{w} \geq \bar{u} = 1$, o sea $w = 1$; el producto esperado sería $0.4 \cdot 10 = 4$ y el beneficio $4 - 1 = 3.00 < 5.50$. Por lo tanto el principal implementa el esfuerzo alto $\checkmark$. (En el *first best*, el beneficio con esfuerzo alto habría sido $8 - 2.25 = 5.75$: el riesgo moral le cuesta al principal exactamente los 0.25 calculados arriba.) $\square$

Capítulo 10

Punto silla y dualidad lagrangiana

[P2]

Semana 8 del cronograma. Bibliografía: Boyd y Vandenberghe [2]; Brinkhuis [3]; Ruszczyński [6].

¿Para qué sirve esto en Microeconomía?

La dualidad es una de las ideas de este curso con más eco directo en Microeconomía:

- **Decisión individual (consumidor, MWG cap. 3):** la pareja UMP/EMP (maximizar utilidad sujeto a presupuesto, demanda marshalliana, versus minimizar gasto sujeto a utilidad, demanda hicksiana) es un reflejo de la dualidad lagrangiana: son problemas “inversos” (objetivo y restricción intercambian papeles) y sus multiplicadores son recíprocos. Las identidades de Roy y Shephard que las conectan viven en el capítulo de la envolvente, pero la estructura de fondo es la de este capítulo [9, 10].
- **Equilibrio general (bienestar, MWG caps. 16–18):** los multiplicadores del problema dual son *precios sombra* que sostienen asignaciones eficientes; el segundo teorema del bienestar, que afirma que toda asignación eficiente es un equilibrio con transferencias, es, en el fondo, un resultado de dualidad: los precios que “descentralizan” la asignación son las variables duales del problema del planificador [9].
- **Teoría de juegos (MWG cap. 8):** el teorema minimax de von Neumann para juegos de suma cero, la base histórica de toda la teoría de juegos, es exactamente un teorema de *punto silla*: el valor del juego existe porque el problema de cada jugador es el dual lineal del problema del otro.
- **Fallas de mercado (contratos e información, MWG caps. 13–14):** en el problema del principal con restricciones de compatibilidad de incentivos (IC) y participación (IR), el lagrangiano se analiza vía dualidad: los multiplicadores de las IC identifican *qué tipos “muerden”* (qué restricciones están activas) en Baron–Myerson y Mussa–Rosen, y los de las IR miden el costo de dejar renta al agente [11].

En el capítulo anterior definimos el lagrangiano y las condiciones KKT: dado un candidato

x^* , los multiplicadores certifican su optimalidad. En este capítulo cambiamos el punto de vista: en lugar de tratar los multiplicadores (λ, μ) como testigos auxiliares, los convertimos en *variables de decisión de un nuevo problema de optimización*, el **problema dual** (*dual problem*). Veremos que:

- (I) el dual siempre es un problema *cóncavo* (aunque el primal no sea convexo), y siempre da *cotas inferiores* del valor primal (dualidad débil);
- (II) bajo convexidad y una condición de regularidad (Slater), la cota es exacta (dualidad fuerte), y la solución conjunta primal–dual es un *punto silla* del lagrangiano;
- (III) las variables duales tienen una interpretación económica precisa: son los *precios* a los que un mercado valoraría los recursos escasos del problema.

Nuestra referencia principal es [2] (capítulo 5); también seguimos a [6] (capítulo 4), [3] y [1].

10.1. La función dual de Lagrange [P2]

10.1.1. El problema primal y su lagrangiano

Trabajamos con el mismo problema del capítulo de KKT, que ahora llamaremos **problema primal** (*primal problem*):

$$\begin{aligned} \min_{x \in X} \quad & f(x) \\ \text{s.a.} \quad & g_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned} \tag{10.1}$$

donde $f, g_1, \dots, g_m, h_1, \dots, h_p : \mathbb{R}^n \rightarrow \mathbb{R}$ y $X \subseteq \mathbb{R}^n$ es un conjunto no vacío (usualmente $X = \mathbb{R}^n$, aunque permitir un X general, por ejemplo $X = \mathbb{R}_+^n$ o un intervalo, será útil). Denotamos por p^* el **valor óptimo primal**:

$$p^* := \inf\{f(x) : x \in X, g_i(x) \leq 0, h_j(x) = 0\},$$

con la convención $p^* = +\infty$ si el problema es infactible.

El **lagrangiano** (*Lagrangian*) es, como antes,

$$L(x, \lambda, \mu) := f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x), \quad x \in X, \lambda \in \mathbb{R}_+^m, \mu \in \mathbb{R}^p.$$

La idea de la dualidad nace de una pregunta simple: en lugar de exigir las restricciones de forma rígida, ¿qué pasa si las *cobramos*? El término $\lambda_i g_i(x)$ es una *multa* lineal por violar la restricción i -ésima: si $g_i(x) > 0$ (violación) pagamos $\lambda_i g_i(x) > 0$; si $g_i(x) < 0$ (holgura) recibimos un premio. El lagrangiano es el costo original más las multas, y minimizarlo *sin restricciones* es más fácil que resolver el primal. La función que registra el resultado de esa minimización es el objeto central del capítulo.

Definición 10.1 (Función dual de Lagrange). La **función dual de Lagrange** (*Lagrange dual*

function) asociada al problema (10.1) es la función $q : \mathbb{R}_+^m \times \mathbb{R}^p \rightarrow \mathbb{R} \cup \{-\infty\}$ definida por

$$q(\lambda, \mu) := \inf_{x \in X} L(x, \lambda, \mu) = \inf_{x \in X} \left[f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x) \right].$$

Su **dominio efectivo** es $\text{dom}(q) := \{(\lambda, \mu) : q(\lambda, \mu) > -\infty\}$. El **problema dual** (*dual problem*) es

$$\max_{\lambda \geq 0, \mu \in \mathbb{R}^p} q(\lambda, \mu), \quad (10.2)$$

y su valor óptimo se denota d^* . Un par (λ, μ) con $\lambda \geq 0$ se dice **dual factible** (y es *útil* solo si además pertenece a $\text{dom}(q)$).

Dos observaciones inmediatas. Primero, el ínfimo se toma sobre *todo* X , ignorando las restricciones: por eso q suele ser calculable en forma cerrada. Segundo, q puede valer $-\infty$ para algunos (λ, μ) (el lagrangiano no está acotado por abajo); esos puntos no aportan información y por eso el dual se restringe, en la práctica, a $\text{dom}(q)$.

10.1.2. La concavidad del dual: gratis y siempre

Teorema 10.2 (La función dual es siempre cóncava). *Para cualquier problema (10.1), convexo o no, la función dual q es cóncava en (λ, μ) .*

Demostración. Fijemos $x \in X$ y miremos el lagrangiano como función de los multiplicadores:

$$(\lambda, \mu) \mapsto L(x, \lambda, \mu) = \underbrace{f(x)}_{\text{constante}} + \sum_{i=1}^m \underbrace{g_i(x)}_{\text{constante}} \lambda_i + \sum_{j=1}^p \underbrace{h_j(x)}_{\text{constante}} \mu_j.$$

Con x fijo, los valores $f(x), g_i(x), h_j(x)$ son números: la función es *afín* (lineal más constante) en (λ, μ) . Ahora recordemos, del capítulo de funciones convexas, una operación que preserva la convexidad: el supremo puntual de una familia de funciones convexas es convexo; por simetría, *el ínfimo puntual de una familia de funciones cóncavas es cóncavo*. Como toda función afín es cóncava, y

$$q(\lambda, \mu) = \inf_{x \in X} L(x, \lambda, \mu)$$

es el ínfimo puntual de la familia $\{L(x, \cdot, \cdot)\}_{x \in X}$ de funciones afines, q es cóncava. (Verificación directa, por si el argumento abstracto no convence: para $(\lambda^1, \mu^1), (\lambda^2, \mu^2)$ y $t \in [0, 1]$, la afinidad en (λ, μ) da, para cada x , $L(x, t\lambda^1 + (1-t)\lambda^2, t\mu^1 + (1-t)\mu^2) = tL(x, \lambda^1, \mu^1) + (1-t)L(x, \lambda^2, \mu^2) \geq tq(\lambda^1, \mu^1) + (1-t)q(\lambda^2, \mu^2)$; tomando ínfimo sobre x en el lado izquierdo se obtiene la desigualdad de concavidad.) $\square$

Intuición

El dual es cóncavo *por construcción*, no por hipótesis: q es un ínfimo de rectas (en dimensión 1) o de hiperplanos, y el mínimo puntual de una familia de funciones planas siempre se curva hacia abajo. Esto tiene una consecuencia práctica enorme: aunque el primal sea horrible (no convexo, no diferenciable, incluso combinatorio), *el dual es siempre un problema cóncavo de maximización*, es decir, un problema “bueno” donde máximos locales

son globales. La dualidad es una máquina de fabricar problemas convexos a partir de problemas arbitrarios; el precio que se paga es que, en general, el dual solo da una *cota* del primal, como veremos.

10.1.3. Dos ejemplos calculados por completo

Ejemplo 10.3 (Dual de un QP en una variable). Consideremos el problema cuadrático (QP, *quadratic program*)

$$\min_{x \in \mathbb{R}} x^2 \quad \text{s.a.} \quad x \geq 1,$$

que escribimos en forma estándar con $g(x) = 1 - x \leq 0$. A ojo: la solución es $x^* = 1$ con $p^* = 1$. Construyamos el dual paso a paso.

Paso 1: lagrangiano. $L(x, \lambda) = x^2 + \lambda(1 - x)$, con $\lambda \geq 0$.

Paso 2: minimizar en x . Para λ fijo, L es una parábola convexa en x ; su mínimo se encuentra con la condición de primer orden $\partial L / \partial x = 2x - \lambda = 0$, es decir $x(\lambda) = \lambda/2$. Sustituyendo:

$$q(\lambda) = \left(\frac{\lambda}{2}\right)^2 + \lambda \left(1 - \frac{\lambda}{2}\right) = \frac{\lambda^2}{4} + \lambda - \frac{\lambda^2}{2} = \lambda - \frac{\lambda^2}{4}.$$

Como anuncia el Teorema 10.2, q es cóncava (parábola invertida).

Paso 3: problema dual. $\max_{\lambda \geq 0} \lambda - \lambda^2/4$. La condición de primer orden da $1 - \lambda/2 = 0$, o sea $\lambda^* = 2 \geq 0$, con valor

$$d^* = q(2) = 2 - 1 = 1 = p^*.$$

No hay brecha: la mejor cota inferior del dual *alcanza* el valor primal. Además $x(\lambda^*) = \lambda^*/2 = 1 = x^*$: minimizar el lagrangiano con el multiplicador óptimo recupera la solución primal. Nota también que $\lambda^* = 2 > 0$ y la restricción está activa ($g(x^*) = 0$): holgura complementaria, como en KKT.

Ejemplo 10.4 (Dual de un problema lineal). Sea el problema lineal (LP, *linear program*) en forma estándar

$$\min_{x \in \mathbb{R}^n} c^\top x \quad \text{s.a.} \quad Ax = b, \quad x \geq 0,$$

con $A \in \mathbb{R}^{p \times n}$, $b \in \mathbb{R}^p$, $c \in \mathbb{R}^n$. Escribimos $x \geq 0$ como $-x_k \leq 0$ con multiplicadores $\lambda \in \mathbb{R}_+^n$, y $Ax = b$ con multiplicadores $\mu \in \mathbb{R}^p$ (usamos la forma $b - Ax = 0$ para que los signos queden cómodos):

$$L(x, \lambda, \mu) = c^\top x - \lambda^\top x + \mu^\top (b - Ax) = b^\top \mu + (c - A^\top \mu - \lambda)^\top x.$$

El lagrangiano es *afín en x* : su ínfimo sobre $x \in \mathbb{R}^n$ es $-\infty$ salvo que el vector de coeficientes sea exactamente cero. Por tanto,

$$q(\lambda, \mu) = \begin{cases} b^\top \mu & \text{si } c - A^\top \mu - \lambda = 0, \\ -\infty & \text{en otro caso.} \end{cases}$$

El dual maximiza q sobre $\lambda \geq 0$, μ libre. Como λ solo aparece en la condición $\lambda = c - A^\top \mu$,

exigir $\lambda \geq 0$ equivale a $A^\top \mu \leq c$, y λ desaparece como variable de holgura. El dual es entonces el LP

$$\max_{\mu \in \mathbb{R}^p} b^\top \mu \quad \text{s.a.} \quad A^\top \mu \leq c,$$

que es exactamente la *dualidad de programación lineal* clásica. Observa la simetría: el primal minimiza con restricciones de igualdad y variables no negativas; el dual maximiza con variables libres y restricciones de desigualdad. Los papeles de b y c se intercambian.

Estrategia de examen

Receta para calcular duales en el examen (y en la vida):

- (1) Escribe el problema en forma estándar de *minimización* con restricciones $g_i \leq 0$ y $h_j = 0$, decidiendo qué restricciones van al lagrangiano y cuáles se quedan en X (las cotas simples tipo $x \geq 0$ o $x \in [a, b]$ a veces conviene dejarlas en X).
- (2) Arma $L(x, \lambda, \mu)$ y *agrupa por potencias de x* : junta todos los términos lineales en x , los cuadráticos, etc.
- (3) Minimiza en x ignorando restricciones: si L es cuadrática convexa en x , usa la condición de primer orden; si es afín en x , el ínfimo es $-\infty$ salvo que el coeficiente de x se anule, y esa anulación se convierte en *restricción del dual*; si X es un intervalo y L es cóncava en x , el mínimo está en un extremo.
- (4) Escribe $\max q(\lambda, \mu)$ s.a. $\lambda \geq 0$ y las restricciones que aparecieron en el paso anterior. Verifica que q te salió cóncava: si no, hay un error de cálculo.

10.2. Dualidad débil y brecha de dualidad [P2]

El primer teorema de dualidad es tan corto que cabe en dos líneas, y sin embargo es la base de todo lo demás: *cualquier* valor de la función dual es una cota inferior del valor óptimo primal.

Teorema 10.5 (Dualidad débil (*weak duality*)). *Para todo $\lambda \in \mathbb{R}_+^m$ y todo $\mu \in \mathbb{R}^p$,*

$$q(\lambda, \mu) \leq p^*.$$

En consecuencia, $d^ \leq p^*$.*

Demostración. Sea $\bar{x}$ cualquier punto factible del primal: $\bar{x} \in X$, $g_i(\bar{x}) \leq 0$, $h_j(\bar{x}) = 0$. Entonces

$$q(\lambda, \mu) = \inf_{x \in X} L(x, \lambda, \mu) \leq L(\bar{x}, \lambda, \mu) = f(\bar{x}) + \sum_{i=1}^m \lambda_i g_i(\bar{x}) + \sum_{j=1}^p \mu_j h_j(\bar{x}) \leq f(\bar{x}).$$

Explicuemos cada desigualdad. La primera es la definición de ínfimo: el ínfimo sobre todos los $x \in X$ no supera el valor en el punto particular $\bar{x}$. La segunda usa la factibilidad y el signo de los multiplicadores: cada término $\lambda_i g_i(\bar{x})$ es el producto de un número ≥ 0 por uno ≤ 0 , luego es ≤ 0 ; y cada $\mu_j h_j(\bar{x}) = \mu_j \cdot 0 = 0$. Así $q(\lambda, \mu) \leq f(\bar{x})$ para *todo* factible $\bar{x}$; tomando ínfimo sobre los factibles, $q(\lambda, \mu) \leq p^*$. Finalmente, tomando supremo sobre (λ, μ) con $\lambda \geq 0$ se obtiene $d^* \leq p^*$. $\square$

Definición 10.6 (Brecha de dualidad). La cantidad $p^* - d^* \geq 0$ se llama **brecha de dualidad** (*duality gap*). Si $p^* = d^*$ decimos que hay **dualidad fuerte** (*strong duality*) o brecha cero.

Corolario 10.7 (Certificados de optimalidad). Si $\hat{x}$ es primal factible, $(\hat{\lambda}, \hat{\mu})$ es dual factible y

$$f(\hat{x}) = q(\hat{\lambda}, \hat{\mu}),$$

entonces $\hat{x}$ es óptimo primal, $(\hat{\lambda}, \hat{\mu})$ es óptimo dual y la brecha es cero.

Demostración. Por dualidad débil, $q(\hat{\lambda}, \hat{\mu}) \leq d^* \leq p^* \leq f(\hat{x})$. Si los extremos coinciden, toda la cadena son igualdades: $f(\hat{x}) = p^*$ ($\hat{x}$ óptimo primal) y $q(\hat{\lambda}, \hat{\mu}) = d^*$ ($(\hat{\lambda}, \hat{\mu})$ óptimo dual). $\square$

Intuición

El dual es una *fábrica de cotas inferiores certificables*. Supón que resolviste numéricamente un problema de minimización y obtuviste un punto factible $\hat{x}$ con $f(\hat{x}) = 10.02$. ¿Es bueno? No lo sabes... salvo que alguien te muestre un $(\hat{\lambda}, \hat{\mu})$ dual factible con $q(\hat{\lambda}, \hat{\mu}) = 10.00$: entonces *nadie* puede hacerlo mejor que 10.00, y tu solución está a lo más a 0.02 del óptimo, garantizado. El par dual es un certificado que cualquiera puede verificar con una evaluación de función, sin repetir la optimización. Esta lógica es el corazón de los solvers modernos (que reportan la brecha primal–dual como criterio de parada, ver [2, 5]) y también de la teoría: demostrar optimalidad es exhibir un dual factible sin brecha.

Observación 10.8. La dualidad débil vale con las convenciones habituales sobre infinitos: si el primal es infactible ($p^* = +\infty$), la cota es trivial; si el dual es no acotado ($d^* = +\infty$), entonces el primal es infactible; y si el primal es no acotado ($p^* = -\infty$), entonces $q \equiv -\infty$ (el dual es infactible en el sentido de $\text{dom}(q) = \emptyset$).

10.3. Interpretación económica del dual [P2]

Esta sección merece calma: la dualidad no es un truco algebraico, es una *teoría de precios*. La idea, en una frase: **el problema dual es el problema de un mercado que le pone precios a los recursos escasos del primal**, y la dualidad fuerte dice que ese mercado, con los precios correctos, replica exactamente la asignación óptima.

10.3.1. Multiplicadores como precios de recursos

Escribamos el primal como el problema de una firma que *asigna recursos*. La firma elige niveles de actividad $x \in X \subseteq \mathbb{R}_+^n$ (cuánto producir de cada bien) para maximizar un beneficio $R(x)$ (cóncavo), sujeta a que su consumo de recursos no exceda las dotaciones disponibles:

$$\max_{x \in X} R(x) \quad \text{s.a.} \quad G_i(x) \leq b_i, \quad i = 1, \dots, m, \quad (10.3)$$

donde $G_i(x)$ es la cantidad del recurso i (horas de trabajo, horas de máquina, materia prima) que consume el plan x , y b_i es la dotación. Para encajar con nuestro formato de minimización, el primal es $\min_{x \in X} -R(x)$ s.a. $G_i(x) - b_i \leq 0$, y el lagrangiano (cambiando el signo para leerlo

en términos de beneficio) es

$$L(x, \lambda) = R(x) + \sum_{i=1}^m \lambda_i (b_i - G_i(x)) = R(x) - \sum_{i=1}^m \lambda_i G_i(x) + \sum_{i=1}^m \lambda_i b_i.$$

Léelo como un estado de resultados: si el recurso i tiene precio λ_i , entonces L es el beneficio de producción $R(x)$, menos el *costo de los recursos utilizados* $\sum_i \lambda_i G_i(x)$, más el *valor de mercado de la dotación* $\sum_i \lambda_i b_i$ (la firma podría vender sus recursos en lugar de usarlos). La función dual

$$q(\lambda) = \sum_{i=1}^m \lambda_i b_i + \max_{x \in X} \left[R(x) - \sum_{i=1}^m \lambda_i G_i(x) \right]$$

es el mayor “valor total” que la firma puede obtener cuando los recursos se transan a precios λ : valor de la dotación más el beneficio neto de operar comprando recursos a esos precios. La dualidad débil (en versión maximización: $q(\lambda) \geq$ beneficio óptimo del primal, para todo $\lambda \geq 0$) dice que *ponerle precios a los recursos nunca subvalora a la firma*: con mercados de recursos, la firma siempre puede hacerlo al menos tan bien como autoabasteciéndose, porque conserva la opción de replicar su plan original. El problema dual,

$$\min_{\lambda \geq 0} q(\lambda),$$

busca los precios *más exigentes*: los que reducen esa valoración al mínimo. Son los precios que no regalan nada, y en el óptimo (con dualidad fuerte) la valoración de mercado coincide exactamente con el beneficio productivo: los precios duales λ^* son los **precios sombra** (*shadow prices*) de los recursos.

10.3.2. El caso lineal y la condición de no arbitraje

Con $R(x) = c^\top x$ y $G(x) = Gx$ (tecnología lineal, $X = \mathbb{R}_+^n$), la maximización interna es

$$\max_{x \geq 0} (c - G^\top \lambda)^\top x = \begin{cases} 0 & \text{si } G^\top \lambda \geq c, \\ +\infty & \text{si } (G^\top \lambda)_k < c_k \text{ para algún } k. \end{cases}$$

La lectura económica es exacta: $(G^\top \lambda)_k = \sum_i \lambda_i G_{ik}$ es el *costo en recursos* de una unidad de la actividad k a precios λ , y c_k es su ingreso unitario. Si alguna actividad rindiera un beneficio unitario estrictamente positivo ($c_k > (G^\top \lambda)_k$), la firma la escalaría sin límite: hay *arbitraje* y la valoración explota. El dual queda

$$\min_{\lambda \geq 0} b^\top \lambda \quad \text{s.a.} \quad G^\top \lambda \geq c,$$

es decir: **encontrar los precios de recursos más baratos (la valoración mínima de la dotación) tales que ninguna actividad sea estrictamente rentable**. Esta es la *condición de no arbitraje*: en equilibrio, cada actividad usada cubre exactamente su costo en recursos (holgura complementaria: $x_k^* > 0 \Rightarrow c_k = (G^\top \lambda^*)_k$) y cada recurso con precio positivo se agota ($\lambda_i^* > 0 \Rightarrow (Gx^*)_i = b_i$: un recurso sobrante es un bien libre, con precio cero).

Ejemplo 10.9 (Asignación de recursos de una firma). Una firma produce dos bienes con beneficios unitarios $c = (3, 2)$. Dispone de 4 horas de trabajo y 5 unidades de insumo; el bien 1 usa 1 hora y 2 insumos por unidad, el bien 2 usa 1 hora y 1 insumo. El primal:

$$\max_{x \geq 0} 3x_1 + 2x_2 \quad \text{s.a.} \quad x_1 + x_2 \leq 4 \text{ (trabajo)}, \quad 2x_1 + x_2 \leq 5 \text{ (insumo)}.$$

Solución primal. Con dos restricciones y beneficios positivos, el candidato natural es el vértice donde ambas se activan: $x_1 + x_2 = 4$ y $2x_1 + x_2 = 5$ dan $x^* = (1, 3)$, con beneficio $p^* = 3 + 6 = 9$.

Dual. Con precios λ_1 (trabajo) y λ_2 (insumo):

$$\min_{\lambda \geq 0} 4\lambda_1 + 5\lambda_2 \quad \text{s.a.} \quad \lambda_1 + 2\lambda_2 \geq 3, \quad \lambda_1 + \lambda_2 \geq 2.$$

La primera restricción dice: los recursos que usa una unidad del bien 1 (una hora, dos insumos) deben valer al menos su beneficio 3; igual la segunda. Como $x_1^*, x_2^* > 0$, la holgura complementaria exige ambas con igualdad: $\lambda_1 + 2\lambda_2 = 3$, $\lambda_1 + \lambda_2 = 2$, de donde $\lambda^* = (1, 1)$: una hora de trabajo vale 1 y una unidad de insumo vale 1. El valor dual es $d^* = 4(1) + 5(1) = 9 = p^*$: la valoración de la dotación a precios sombra agota exactamente el beneficio (“teorema del producto agotado”). Interpretación marginal: una hora adicional de trabajo aumentaría el beneficio en $\lambda_1^* = 1$; ese es el precio máximo que la firma pagaría por ella.

Intuición

Piensa en el dual como un *tasador adversarial*. El primal es el ingeniero: asigna recursos a actividades. El dual es el contador-mercado: no mira actividades, solo pone precios a los recursos, con dos reglas: no puede dejar arbitraje (ninguna actividad puede ser estrictamente rentable a sus precios) y quiere la valoración total más baja posible. La dualidad débil dice que cualquier tasación sin arbitraje es una cota superior del beneficio alcanzable; la dualidad fuerte dice que la mejor tasación es *exacta*. Este es el mismo mecanismo del segundo teorema del bienestar en equilibrio general: la asignación eficiente (primal del planificador) se puede *descentralizar* con precios (variables duales) que hacen que ningún agente quiera desviarse [9].

Observación 10.10 (Un poco de historia). Esta lectura no es una metáfora a posteriori: nació con la teoría. Leonid Kantorovich (1939), estudiando la planificación de la producción soviética, introdujo los multiplicadores como “valoraciones objetivamente determinadas” de los recursos, precios sombra en una economía sin mercados, y Tjalling Koopmans desarrolló en paralelo el análisis de actividades en Occidente; compartieron el premio Nobel de economía en 1975 por la teoría de la asignación óptima de recursos. La dualidad lineal formal cristalizó con von Neumann, Gale, Kuhn y Tucker hacia 1947–1951. Para un economista, la moraleja es que *programación lineal y teoría de precios son la misma matemática* [3].

10.4. Punto silla del lagrangiano [P2]

10.4.1. Definición y primera lectura

Hasta ahora primal y dual son dos problemas separados unidos por una desigualdad. El concepto que los suelda en uno solo es el de punto silla: un punto que es *mínimo en las variables primales y máximo en las duales, simultáneamente*.

Definición 10.11 (Punto silla). Un par $(x^*, (\lambda^*, \mu^*))$ con $x^* \in X$, $\lambda^* \in \mathbb{R}_+^m$, $\mu^* \in \mathbb{R}^p$ es un **punto silla** (*saddle point*) del lagrangiano L si

$$L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*) \quad \text{para todo } x \in X, \lambda \in \mathbb{R}_+^m, \mu \in \mathbb{R}^p.$$

Es decir: fijando $x = x^*$, los multiplicadores (λ^*, μ^*) *maximizan* L sobre $\lambda \geq 0$, μ libre; y fijando $(\lambda, \mu) = (\lambda^*, \mu^*)$, el punto x^* *minimiza* L sobre X .

El nombre viene de la geometría de una silla de montar: la superficie $(x, \lambda) \mapsto L(x, \lambda)$ sube en la dirección de x (mínimo) y baja en la dirección de λ (máximo), como la función $x^2 - \lambda^2$ en el origen. La lectura de juego es inmediata y volverá en el teorema minimax: un jugador elige x para minimizar, otro elige (λ, μ) para maximizar, y el punto silla es un par de estrategias del que ninguno quiere desviarse unilateralmente: un equilibrio.

10.4.2. El teorema central

Teorema 10.12 (Caracterización de puntos silla). *El par $(x^*, (\lambda^*, \mu^*))$ con $\lambda^* \geq 0$ es un punto silla del lagrangiano si y solo si se cumplen las tres condiciones:*

- (a) x^* es solución óptima del primal (10.1);
- (b) (λ^*, μ^*) es solución óptima del dual (10.2);
- (c) la brecha de dualidad es cero: $p^* = d^*$.

Demostración. $(\Rightarrow)$ **Supongamos que $(x^*, (\lambda^*, \mu^*))$ es punto silla.**

Paso 1: x^* es factible. La primera desigualdad de la silla dice que la función

$$(\lambda, \mu) \mapsto L(x^*, \lambda, \mu) = f(x^*) + \sum_i \lambda_i g_i(x^*) + \sum_j \mu_j h_j(x^*)$$

alcanza su supremo sobre $\lambda \geq 0$, $\mu \in \mathbb{R}^p$ en (λ^*, μ^*) , y en particular ese supremo es *finito*. Pero es una función afín de (λ, μ) : si algún $g_i(x^*) > 0$, mandando $\lambda_i \rightarrow +\infty$ el valor explota a $+\infty$; si algún $h_j(x^*) \neq 0$, eligiendo $\mu_j \rightarrow \pm\infty$ con el signo adecuado también explota. Para que el supremo sea finito necesitamos $g_i(x^*) \leq 0$ para todo i y $h_j(x^*) = 0$ para todo j : x^* es factible.

Paso 2: *holgura complementaria y valor de la silla.* Tomando $\lambda = 0$, $\mu = \mu^*$ en la primera desigualdad (y usando $h_j(x^*) = 0$):

$$f(x^*) = L(x^*, 0, \mu^*) \leq L(x^*, \lambda^*, \mu^*) = f(x^*) + \sum_i \lambda_i^* g_i(x^*) \leq f(x^*),$$

donde la última desigualdad usa $\lambda_i^* \geq 0$, $g_i(x^*) \leq 0$. Toda la cadena es igualdad, luego $\sum_i \lambda_i^* g_i(x^*) = 0$ (y como cada sumando es ≤ 0 , cada uno es cero: $\lambda_i^* g_i(x^*) = 0$, la holgura complementaria de KKT) y

$$L(x^*, \lambda^*, \mu^*) = f(x^*).$$

Paso 3: cerrar con dualidad débil. La segunda desigualdad de la silla dice que x^* minimiza $L(\cdot, \lambda^*, \mu^*)$ sobre X , es decir,

$$q(\lambda^*, \mu^*) = \inf_{x \in X} L(x, \lambda^*, \mu^*) = L(x^*, \lambda^*, \mu^*) = f(x^*).$$

Como x^* es factible, $p^* \leq f(x^*)$; y por dualidad débil (Teorema 10.5), $q(\lambda^*, \mu^*) \leq d^* \leq p^*$. Juntando:

$$p^* \leq f(x^*) = q(\lambda^*, \mu^*) \leq d^* \leq p^*,$$

así que todas son igualdades: $f(x^*) = p^*$ (x^* óptimo primal), $q(\lambda^*, \mu^*) = d^*$ ((λ^*, μ^*) óptimo dual) y $p^* = d^*$ (brecha cero).

($\Leftarrow$) **Supongamos (a), (b), (c).** Entonces

$$f(x^*) = p^* \stackrel{(c)}{=} d^* = q(\lambda^*, \mu^*) = \inf_{x \in X} L(x, \lambda^*, \mu^*) \leq L(x^*, \lambda^*, \mu^*) = f(x^*) + \sum_i \lambda_i^* g_i(x^*),$$

usando la factibilidad de x^* ($h_j(x^*) = 0$) en la última igualdad. Como $\lambda_i^* \geq 0$ y $g_i(x^*) \leq 0$, el último término es $\leq f(x^*)$. Luego toda la cadena es igualdad y obtenemos dos cosas:

- $\inf_{x \in X} L(x, \lambda^*, \mu^*) = L(x^*, \lambda^*, \mu^*)$: el ínfimo se alcanza en x^* , que es exactamente la *segunda* desigualdad de la silla;
- $\sum_i \lambda_i^* g_i(x^*) = 0$ y $L(x^*, \lambda^*, \mu^*) = f(x^*)$.

Para la *primera* desigualdad de la silla, sea $\lambda \geq 0$, μ cualquiera; por factibilidad de x^* ,

$$L(x^*, \lambda, \mu) = f(x^*) + \sum_i \lambda_i g_i(x^*) + \sum_j \mu_j \cdot 0 \leq f(x^*) = L(x^*, \lambda^*, \mu^*).$$

Ambas desigualdades valen: $(x^*, (\lambda^*, \mu^*))$ es punto silla. □

Observación 10.13. El teorema no requiere convexidad: es pura contabilidad de desigualdades. La convexidad entra en la *existencia* del punto silla (dualidad fuerte, sección 10.5): sin convexidad puede ocurrir que $p^* > d^*$ y entonces, por el teorema, *no existe ningún punto silla*, por más que el primal tenga solución.

10.4.3. Punto silla y KKT

Teorema 10.14 (Bajo convexidad, KKT equivale a punto silla). *Supongamos que en (10.1) las funciones $f, g_1, \dots, g_m$ son convexas y diferenciables, las h_j son afines, y $X = \mathbb{R}^n$. Entonces $(x^*, (\lambda^*, \mu^*))$ con $\lambda^* \geq 0$ es un punto silla del lagrangiano si y solo si satisface las condiciones KKT:*

$$(I) \text{ (estacionariedad) } \nabla_x L(x^*, \lambda^*, \mu^*) = \nabla f(x^*) + \sum_i \lambda_i^* \nabla g_i(x^*) + \sum_j \mu_j^* \nabla h_j(x^*) = 0;$$

(II) (factibilidad primal) $g_i(x^*) \leq 0$, $h_j(x^*) = 0$;

(III) (factibilidad dual) $\lambda^* \geq 0$;

(IV) (holgura complementaria) $\lambda_i^* g_i(x^*) = 0$ para todo i .

Demostración. (Silla $\Rightarrow$ KKT.) Del Paso 1 y el Paso 2 de la demostración del Teorema 10.12 salen directamente (ii), (iii) y (iv) (no usamos convexidad para eso). Para (i): la segunda desigualdad de la silla dice que x^* minimiza sobre *todo* $\mathbb{R}^n$ la función diferenciable $x \mapsto L(x, \lambda^*, \mu^*)$; por la condición necesaria de primer orden del capítulo de optimización sin restricciones, su gradiente en x^* se anula, que es (i).

(KKT $\Rightarrow$ silla.) Aquí sí usamos convexidad. Con $\lambda^* \geq 0$ fijo, la función $x \mapsto L(x, \lambda^*, \mu^*)$ es convexa: es suma de f (convexa), de las $\lambda_i^* g_i$ (convexas por ser $\lambda_i^* \geq 0$) y de las $\mu_j^* h_j$ (afines, convexas con cualquier signo). Para una función convexa diferenciable, gradiente nulo en x^* implica mínimo *global*: la condición (i) da entonces

$$L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*) \quad \text{para todo } x \in \mathbb{R}^n,$$

la segunda desigualdad de la silla. Para la primera, usamos (ii) y (iv): para cualquier $\lambda \geq 0$, μ ,

$$L(x^*, \lambda, \mu) = f(x^*) + \sum_i \lambda_i \underbrace{g_i(x^*)}_{\leq 0} + \sum_j \mu_j \underbrace{h_j(x^*)}_{=0} \leq f(x^*) = f(x^*) + \underbrace{\sum_i \lambda_i^* g_i(x^*)}_{=0 \text{ por (iv)}} = L(x^*, \lambda^*, \mu^*).$$

□

Cuidado (error común)

La equivalencia “KKT $\Leftrightarrow$ punto silla” **depende crucialmente de la convexidad** en la dirección KKT $\Rightarrow$ silla. Sin convexidad, un punto KKT puede no ser ni siquiera un mínimo local, y aunque x^* sea el óptimo global del primal puede no existir punto silla (habrá brecha de dualidad, ver el Ejemplo 10.17). El error típico de examen es invocar “KKT, luego óptimo” u “óptimo, luego existe λ^* que hace silla” sin verificar: (1) convexidad de f y las g_i , afinidad de las h_j , y (2) una cualificación de restricciones como Slater. Verifica siempre ambas antes de usar la dualidad fuerte.

10.5. Dualidad fuerte y condición de Slater [P2]

10.5.1. El enunciado

¿Cuándo es cero la brecha de dualidad? La respuesta clásica combina convexidad con una condición de regularidad que pide un punto *estrictamente* factible.

Definición 10.15 (Condición de Slater). El problema (10.1), con f, g_i convexas, h_j afines (escribimos las igualdades como $Ax = b$) y X convexo, satisface la **condición de Slater** (*Slater's condition*) si existe un punto $\hat{x} \in \text{ri}(X)$ tal que

$$g_i(\hat{x}) < 0 \quad \text{para todo } i = 1, \dots, m, \quad \text{y} \quad A\hat{x} = b.$$

Es decir: existe un punto estrictamente factible (las desigualdades se cumplen con holgura). Si algunas g_i son afines, basta pedirles $g_i(\hat{x}) \leq 0$ (versión refinada).

Teorema 10.16 (Dualidad fuerte (*strong duality*)). *Supongamos que el problema (10.1) es convexo (f, g_i convexas, h_j afines, X convexo) y satisface la condición de Slater. Entonces*

$$p^* = d^*,$$

y si $p^ > -\infty$ el valor dual se alcanza: existe (λ^*, μ^*) con $\lambda^* \geq 0$ y $q(\lambda^*, \mu^*) = d^* = p^*$. Si además el primal tiene solución x^* , el par $(x^*, (\lambda^*, \mu^*))$ es un punto silla del lagrangiano [2, 6].*

Nota la asimetría fina: Slater garantiza que el *dual* se alcanza (hay multiplicadores óptimos), pero no que el primal se alcance; y no hace falta que se alcance para que $p^* = d^*$.

10.5.2. La geometría: el conjunto de valores alcanzables

La demostración completa está en [2], sección 5.3.2; aquí damos el argumento esquemático, que es una aplicación directa del teorema de separación del capítulo de separación, y que conviene entender porque *la figura explica toda la dualidad*. Para aligerar la notación, supongamos una sola restricción de desigualdad ($m = 1$, sin igualdades).

El conjunto $\mathcal{A}$. Definimos el conjunto de pares (violación, costo) *alcanzables o peores*:

$$\mathcal{A} := \{(u, t) \in \mathbb{R}^2 : \exists x \in X \text{ con } g(x) \leq u, f(x) \leq t\}.$$


Un punto $(u, t) \in \mathcal{A}$ significa: “existe una decisión que viola la restricción a lo más en u y cuesta a lo más t ”. El conjunto $\mathcal{A}$ es cerrado hacia arriba y hacia la derecha (si un par es alcanzable, todo par peor también). Dos hechos clave:

- (1) **El valor primal se lee en el eje vertical:** $p^* = \inf\{t : (0, t) \in \mathcal{A}\}$, porque $(0, t) \in \mathcal{A}$ significa que hay un x factible ($g(x) \leq 0$) con $f(x) \leq t$.
- (2) **La función dual se lee con rectas de soporte:** para $\lambda \geq 0$,

$$q(\lambda) = \inf_{x \in X} [f(x) + \lambda g(x)] = \inf \{t + \lambda u : (u, t) \in \mathcal{A}\}.$$

Geométricamente: entre todas las rectas de pendiente $-\lambda$ (de la forma $t = -\lambda u + \beta$), $q(\lambda)$ es la mayor ordenada al origen β tal que la recta queda *por debajo* de $\mathcal{A}$. Es decir, cada $\lambda \geq 0$ define una recta que sostiene a $\mathcal{A}$ desde abajo, y $q(\lambda)$ es su intersección con el eje vertical $u = 0$.

La dualidad débil se ve: la recta soporte pasa por debajo de $\mathcal{A}$, en particular por debajo del punto $(0, p^*)$, así que su ordenada al origen cumple $q(\lambda) \leq p^*$. Y el problema dual consiste en *inclinarse la recta* (elegir λ) para empujar esa ordenada lo más arriba posible.



La recta de pendiente $-\lambda$ que sostiene a $\mathcal{A}$ por debajo corta el eje $u = 0$ en $q(\lambda) \leq p^*$; la distancia punteada es la pérdida de esa λ concreta. El dual inclina la recta buscando el mayor intercepto, que bajo convexidad y Slater llega justo hasta $(0, p^*)$.

Dónde entra la convexidad y Slater. Si el problema es convexo, $\mathcal{A}$ es un conjunto *convexo* (ejercicio instructivo: combinar dos puntos de $\mathcal{A}$ usando la convexidad de f , g y X). El punto $(0, p^*)$ está en la frontera de $\mathcal{A}$, así que por el teorema del hiperplano soporte (capítulo de separación) existe $(\nu_1, \nu_2) \neq (0, 0)$ con

$$\nu_1 u + \nu_2 t \geq \nu_2 p^* \quad \text{para todo } (u, t) \in \mathcal{A}.$$

Como $\mathcal{A}$ es ilimitado hacia arriba y hacia la derecha, se deduce $\nu_1 \geq 0$ y $\nu_2 \geq 0$ (si algún coeficiente fuera negativo, el lado izquierdo iría a $-\infty$). Quedan dos casos:

- Si $\nu_2 > 0$, normalizamos $\lambda := \nu_1/\nu_2$ y la desigualdad se convierte en $t + \lambda u \geq p^*$ sobre $\mathcal{A}$, o sea $q(\lambda) \geq p^*$; con la dualidad débil, $q(\lambda) = p^* = d^*$: dualidad fuerte, con multiplicador óptimo λ .
- Si $\nu_2 = 0$ (hiperplano *vertical*), la desigualdad dice $\nu_1 u \geq 0$ sobre $\mathcal{A}$ con $\nu_1 > 0$, es decir $u \geq 0$ para todo punto alcanzable. **Aquí es donde Slater salva el argumento:** el punto estrictamente factible $\hat{x}$ produce $(g(\hat{x}), f(\hat{x})) \in \mathcal{A}$ con $u = g(\hat{x}) < 0$, contradicción. Slater descarta el hiperplano vertical.

Sin convexidad, $\mathcal{A}$ puede tener una “muesca” no convexa sobre el eje vertical: ninguna recta soporte alcanza el punto $(0, p^*)$, y el mejor intercepto d^* se queda estrictamente abajo. Esa distancia vertical *es* la brecha de dualidad.

10.5.3. Brecha positiva sin convexidad: un contraejemplo calculado

Ejemplo 10.17 (Brecha de dualidad positiva). Consideremos el problema *no convexo* (el objetivo es cóncavo):

$$\min_{x \in X} -x^2 \quad \text{s.a.} \quad x - 1 \leq 0, \quad X = [0, 2].$$

Primal. Los puntos factibles son $x \in [0, 1]$; sobre ellos, $-x^2$ se minimiza empujando x al máximo: $x^* = 1$, $p^* = -1$.

Dual. $L(x, \lambda) = -x^2 + \lambda(x - 1)$. Para λ fijo, $L(\cdot, \lambda)$ es *cóncava* en x , así que su mínimo sobre el intervalo $[0, 2]$ se alcanza en un extremo (una función cóncava sobre un intervalo toma su

mínimo en la frontera):

$$L(0, \lambda) = -\lambda, \quad L(2, \lambda) = -4 + \lambda, \quad \implies \quad q(\lambda) = \min\{-\lambda, \lambda - 4\}.$$

Es el mínimo de dos rectas: cóncava y lineal a trozos (otra vez el Teorema 10.2 en acción). Su máximo sobre $\lambda \geq 0$ está donde las rectas se cruzan: $-\lambda = \lambda - 4$ da $\lambda^* = 2$ y

$$d^* = q(2) = -2 < -1 = p^*.$$

La brecha es $p^* - d^* = 1 > 0$. Por el Teorema 10.12, este lagrangiano *no tiene ningún punto silla*, aunque el primal tiene solución perfectamente definida. Geométricamente, el conjunto $\mathcal{A} = \{(u, t) : g(x) \leq u, f(x) \leq t, x \in [0, 2]\}$ tiene como frontera inferior la curva $t = -(1 + u)^2$ para $u \in [-1, 1]$ (parametrizada por $u = x - 1, t = -x^2$), que se curva *hacia abajo*: es la “muesca” no convexa. La mejor recta soporte por debajo toca la curva en los extremos y pasa por debajo del punto $(0, p^*) = (0, -1)$, cortando el eje en -2 .

Observación 10.18. En la práctica económica, Slater casi siempre es inofensivo: en el problema del consumidor basta un plan de consumo interior que no agote el presupuesto ($p^\top \hat{x} < w$, disponible si $w > 0$); en el del planificador, una asignación con holgura en todos los recursos. Por eso en micro se aplica la dualidad fuerte sin mencionarla, pero el Ejemplo 10.17 muestra que la *convexidad* sí es innegociable: con utilidades no cóncavas o conjuntos de producción no convexos (retornos crecientes), los “precios que descentralizan” pueden no existir, que es exactamente la falla conocida del segundo teorema del bienestar sin convexidad [9].

10.6. Tres ejemplos resueltos: consumidor, QP y minimax [P2]

10.6.1. El dual del problema del consumidor y la dualidad Marshall–Hicks

Ejemplo 10.19 (Dual del UMP). El problema de maximización de utilidad (UMP, *utility maximization problem*) del consumidor con utilidad u estrictamente creciente y cóncava, precios $p \gg 0$ y riqueza $w > 0$ es

$$\max_{x \in \mathbb{R}_+^n} u(x) \quad \text{s.a.} \quad p^\top x \leq w.$$

En forma de minimización: $\min_{x \in X} -u(x)$ s.a. $p^\top x - w \leq 0$, con $X = \mathbb{R}_+^n$. El lagrangiano y la función dual:

$$L(x, \lambda) = -u(x) + \lambda(p^\top x - w), \quad q(\lambda) = -\lambda w - \sup_{x \geq 0} [u(x) - \lambda p^\top x].$$

Fíjate en la estructura del supremo interno: es un “problema de beneficio” en el que el consumidor *vende utilidad a precio 1 y compra bienes a precios λp* . Hagámoslo concreto con la utilidad Cobb–Douglas en logaritmos, $u(x_1, x_2) = \alpha \ln x_1 + (1 - \alpha) \ln x_2$ con $\alpha \in (0, 1)$ (tomamos $X = \mathbb{R}_{++}^2$; la restricción $x \geq 0$ nunca se activa por las pendientes infinitas del logaritmo en cero).

Paso 1: el supremo interno. Es separable. Para el bien 1: $\max_{x_1 > 0} \alpha \ln x_1 - \lambda p_1 x_1$; la condición de primer orden $\alpha/x_1 = \lambda p_1$ da $x_1(\lambda) = \alpha/(\lambda p_1)$, con valor $\alpha \ln \frac{\alpha}{\lambda p_1} - \alpha$. Análogamente para el

bien 2. Entonces

$$q(\lambda) = -\lambda w - \alpha \ln \frac{\alpha}{\lambda p_1} - (1 - \alpha) \ln \frac{1 - \alpha}{\lambda p_2} + 1.$$

Paso 2: maximizar el dual. Derivando respecto de λ (usa que $-\alpha \ln \frac{\alpha}{\lambda p_1}$ aporta α/λ , y análogamente el otro término):

$$q'(\lambda) = -w + \frac{\alpha}{\lambda} + \frac{1 - \alpha}{\lambda} = \frac{1}{\lambda} - w = 0 \quad \Rightarrow \quad \lambda^* = \frac{1}{w}.$$

El multiplicador óptimo es la *utilidad marginal de la riqueza* (con u logarítmica, exactamente $1/w$).

Paso 3: recuperar el primal. Minimizar $L(\cdot, \lambda^*)$ (es decir, evaluar el supremo interno en λ^*) da

$$x_1^* = \frac{\alpha}{\lambda^* p_1} = \frac{\alpha w}{p_1}, \quad x_2^* = \frac{(1 - \alpha)w}{p_2},$$

las demandas marshallianas de Cobb–Douglas: gastar la fracción α de la riqueza en el bien 1. Se verifica $p^\top x^* = w$ (restricción activa, coherente con $\lambda^* > 0$) y, sustituyendo, $-q(\lambda^*)$ es exactamente la utilidad indirecta $v(p, w) = \alpha \ln \frac{\alpha w}{p_1} + (1 - \alpha) \ln \frac{(1 - \alpha)w}{p_2}$: brecha cero, como garantiza Slater (el plan $\hat{x} = (w/(3p_1), w/(3p_2))$ es estrictamente factible).

Observación 10.20 (Dualidad Marshall–Hicks, con precisión). En teoría del consumidor (MWG cap. 3) se llama “dualidad” a la relación entre el UMP y el problema de minimización del gasto (EMP, *expenditure minimization problem*):

$$\min_{x \geq 0} p^\top x \quad \text{s.a.} \quad u(x) \geq \bar{u},$$

cuyas soluciones son las demandas hicksianas. Seamos precisos sobre qué tipo de dualidad es esta, porque *no* es literalmente la dualidad lagrangiana: el dual de Lagrange del UMP es un problema en la variable escalar λ (el que acabamos de resolver), no el EMP. La relación correcta es la siguiente:

- UMP y EMP son **problemas inversos**: intercambian objetivo y restricción. El UMP maximiza u con el gasto acotado por w ; el EMP minimiza el gasto con u acotada por $\bar{u}$. Si $\bar{u} = v(p, w)$, ambos tienen la misma solución x^* (con u creciente y continua): $x^m(p, w) = x^h(p, v(p, w))$ y $e(p, v(p, w)) = w$ [9, 10].
- La dualidad lagrangiana es lo que enlaza sus multiplicadores. En el UMP, KKT da $\nabla u(x^*) = \lambda^* p$; en el EMP (con multiplicador ρ para $\bar{u} - u(x) \leq 0$), KKT da $p = \rho^* \nabla u(x^*)$. Comparando: $\rho^* = 1/\lambda^*$. El multiplicador del UMP es la utilidad marginal de la riqueza ($\partial v/\partial w = \lambda^*$, capítulo de la envolvente); el del EMP es el costo marginal de la utilidad ($\partial e/\partial \bar{u} = \rho^*$). Son recíprocos porque medir “utilidad por sol” y “soles por útil” son la misma tasa vista desde los dos lados.
- En ambos problemas, el par (solución, multiplicador) es un *punto silla* del lagrangiano respectivo (utilidad cóncava, restricciones lineales o convexas, Slater fácil), y las identidades de Roy y de Shephard que explotarás en teoría de la demanda son consecuencias de leer esos multiplicadores como derivadas de las funciones valor [11]. En el Ejemplo 10.19: $\lambda^* = 1/w = \partial v/\partial w$, exactamente.

Moraleja: la pareja Marshall–Hicks es una *manifestación* de la estructura primal–dual (restricción y objetivo intercambiados, precios sombra recíprocos, mismo punto silla) y por eso los textos la llaman dualidad, aunque el “dual formal” de cada problema sea el de Lagrange.

10.6.2. Dual de un QP con restricciones lineales

Ejemplo 10.21 (QP: cálculo completo). Resolvamos por dualidad el problema

$$\min_{x \in \mathbb{R}^2} \frac{1}{2}(x_1^2 + x_2^2) \quad \text{s.a.} \quad x_1 + x_2 \geq 2,$$

es decir $g(x) = 2 - x_1 - x_2 \leq 0$ (geométricamente: el punto del semiplano $x_1 + x_2 \geq 2$ más cercano al origen, una proyección, como en el capítulo de optimalidad).

Función dual. $L(x, \lambda) = \frac{1}{2}(x_1^2 + x_2^2) + \lambda(2 - x_1 - x_2)$, convexa y diferenciable en x ; las condiciones de primer orden $x_1 - \lambda = 0$, $x_2 - \lambda = 0$ dan $x(\lambda) = (\lambda, \lambda)$ y

$$q(\lambda) = \frac{1}{2}(\lambda^2 + \lambda^2) + \lambda(2 - 2\lambda) = 2\lambda - \lambda^2.$$

Dual. $\max_{\lambda \geq 0} 2\lambda - \lambda^2$: la condición de primer orden $2 - 2\lambda = 0$ da $\lambda^* = 1$, $d^* = 1$.

Recuperación y verificación. $x^* = x(\lambda^*) = (1, 1)$, factible ($1 + 1 = 2$), con $p^* = \frac{1}{2}(1 + 1) = 1 = d^*$: brecha cero (el problema es convexo y Slater se cumple con $\hat{x} = (2, 2)$). El par $((1, 1), 1)$ es punto silla, y $\lambda^* = 1$ es el precio sombra: relajar la restricción a $x_1 + x_2 \geq 2 - \varepsilon$ reduciría el costo óptimo a razón (marginal) de 1 por unidad de ε .

El caso general, para tu caja de herramientas. Para

$$\min_x \frac{1}{2}x^\top Qx + c^\top x \quad \text{s.a.} \quad Ax \leq b, \quad Q \text{ simétrica definida positiva,}$$

el mismo cálculo (resolver $\nabla_x L = Qx + c + A^\top \lambda = 0$, o sea $x(\lambda) = -Q^{-1}(c + A^\top \lambda)$, y sustituir) da la función dual cuadrática cóncava

$$q(\lambda) = -\frac{1}{2}(c + A^\top \lambda)^\top Q^{-1}(c + A^\top \lambda) - b^\top \lambda,$$

de modo que el dual de un QP es otro QP (cóncavo), pero con la restricción simple $\lambda \geq 0$ en lugar de $Ax \leq b$: por eso muchos algoritmos resuelven el dual [5, 2].

10.6.3. El teorema minimax de von Neumann

Cerramos con la joya histórica: los juegos de suma cero, donde la dualidad *es* el equilibrio. Considera un juego matricial: la jugadora fila elige una fila $i \in \{1, \dots, m\}$, el jugador columna elige una columna $k \in \{1, \dots, n\}$, y la columna paga a_{ik} a la fila (suma cero: lo que una gana, el otro lo pierde). Con *estrategias mixtas* $s \in \Delta_m := \{s \geq 0 : \sum_i s_i = 1\}$ para la fila y $y \in \Delta_n$ para la columna, el pago esperado es

$$s^\top Ay = \sum_{i,k} s_i a_{ik} y_k.$$

La fila quiere maximizarlo; la columna, minimizarlo. Si la fila mueve “primero” garantiza $\max_s \min_y s^\top Ay$; si mueve “segundo” puede aspirar a $\min_y \max_s s^\top Ay$. Siempre vale (¡es una dualidad débil!; ver el ejercicio 10.28)

$$\max_{s \in \Delta_m} \min_{y \in \Delta_n} s^\top Ay \leq \min_{y \in \Delta_n} \max_{s \in \Delta_m} s^\top Ay.$$

Teorema 10.22 (Minimax de von Neumann, 1928). *Para toda matriz $A \in \mathbb{R}^{m \times n}$,*

$$\max_{s \in \Delta_m} \min_{y \in \Delta_n} s^\top Ay = \min_{y \in \Delta_n} \max_{s \in \Delta_m} s^\top Ay =: v,$$

el valor del juego (value of the game). *Equivalentemente, existe un punto silla (s^*, y^*) de la función bilineal $(s, y) \mapsto s^\top Ay$ sobre $\Delta_m \times \Delta_n$:*

$$s^\top Ay^* \leq (s^*)^\top Ay^* \leq (s^*)^\top Ay \quad \text{para todo } s \in \Delta_m, y \in \Delta_n.$$

Idea de la demostración (vía dualidad lineal). Contra un s fijo, la columna minimiza una función lineal de y sobre el simplex, y el mínimo se alcanza en un vértice (una columna pura): $\min_{y \in \Delta_n} s^\top Ay = \min_k (A^\top s)_k$. Así, el problema de la fila es

$$\max_{s \in \Delta_m} \min_k (A^\top s)_k \iff \max_{s, v} v \quad \text{s.a.} \quad A^\top s \geq v \mathbf{1}, \quad s \in \Delta_m,$$

un problema *lineal* (el truco del epígrafe: subir una cota v por debajo de todas las componentes). El problema análogo de la columna, $\min_{y, w} w$ s.a. $Ay \leq w \mathbf{1}$, $y \in \Delta_n$, resulta ser *exactamente el dual de programación lineal* del problema de la fila (cálculo directo con el Ejemplo 10.4). Ambos LP son factibles y acotados, y la dualidad fuerte de programación lineal (que no necesita Slater: para restricciones afines la dualidad fuerte vale siempre que p^* sea finito, ver [2]) da la igualdad de valores. La equivalencia entre “valores iguales” y “existe punto silla” es el Teorema 10.12 en versión minimax. $\square$

Ejemplo 10.23 (Juego 2×2 resuelto por el par primal–dual). Sea el juego de suma cero con matriz de pagos (a la fila)

$$A = \begin{pmatrix} 3 & 1 \\ 0 & 2 \end{pmatrix}.$$

No hay punto silla en estrategias puras: el mejor garantizado puro de la fila es $\max_i \min_k a_{ik} = \max\{1, 0\} = 1$, y el de la columna es $\min_k \max_i a_{ik} = \min\{3, 2\} = 2$; como $1 < 2$, hace falta mezclar.

Problema de la fila (primal). Con $s = (\sigma, 1 - \sigma)$, el pago contra cada columna pura es

$$\text{col. 1: } 3\sigma + 0(1 - \sigma) = 3\sigma, \quad \text{col. 2: } \sigma + 2(1 - \sigma) = 2 - \sigma.$$

La fila garantiza $\min\{3\sigma, 2 - \sigma\}$, una función cóncava a trozos de σ que se maximiza donde las dos rectas se cruzan (si el cruce cae en $[0, 1]$): $3\sigma = 2 - \sigma$ da $\sigma^* = 1/2$, con valor garantizado $v = 3/2$. Estrategia óptima de la fila: $s^* = (1/2, 1/2)$.

Problema de la columna (dual). Con $y = (\tau, 1 - \tau)$, el pago contra cada fila pura es

$$\text{fila 1: } 3\tau + (1 - \tau) = 1 + 2\tau, \quad \text{fila 2: } 2(1 - \tau) = 2 - 2\tau.$$

La columna asegura pagar a lo más $\max\{1 + 2\tau, 2 - 2\tau\}$, convexa a trozos, minimizada en el cruce: $1 + 2\tau = 2 - 2\tau$ da $\tau^* = 1/4$, con valor $1 + 2(1/4) = 3/2$. Estrategia óptima: $y^* = (1/4, 3/4)$.

Verificación de punto silla. Ambos valores coinciden: $v = 3/2$ (brecha cero, como exige el teorema). Y $(s^*)^\top A y^* = \frac{1}{2}(1 + 2 \cdot \frac{1}{4}) + \frac{1}{2}(2 - 2 \cdot \frac{1}{4}) = \frac{1}{2} \cdot \frac{3}{2} + \frac{1}{2} \cdot \frac{3}{2} = \frac{3}{2}$. Contra y^* , cualquier mezcla de la fila rinde exactamente $3/2$ (ambas filas rinden $3/2$ contra y^*): la propiedad de *indiferencia* que usarás sin parar en teoría de juegos para calcular equilibrios mixtos es, aquí, la holgura complementaria del par primal–dual: las estrategias puras usadas con probabilidad positiva deben ser óptimas contra la mezcla rival.

Observación 10.24 (Nota para teoría de juegos). El teorema minimax es el caso “suma cero” del equilibrio de Nash, y fue demostrado por von Neumann (1928) casi dos décadas antes que el teorema de Nash (1950): históricamente, *la teoría de juegos empezó siendo un teorema de dualidad*. En MWG cap. 8 verás que en juegos de suma no cero el valor deja de existir y hace falta el teorema de punto fijo de Kakutani; pero para juegos estrictamente competitivos, todo lo que necesitas es este capítulo: valor del juego = valor común primal–dual, estrategias óptimas = soluciones primal y dual, indiferencia = holgura complementaria.

10.7. Perturbación: la geometría profunda de la dualidad [P2]

Terminamos con el punto de vista que unifica todo lo anterior y que prepara el capítulo de la envolvente: en lugar de resolver *un* problema, resolvemos toda una *familia* de problemas indexada por cuánto relajamos las restricciones, y estudiamos cómo cambia el valor.

Definición 10.25 (Función de perturbación o de valor). Para el problema (10.1) (sin igualdades, por simplicidad), la **función de perturbación** o **función valor** (*perturbation / value function*) es

$$p(u) := \inf \{f(x) : x \in X, g_i(x) \leq u_i, i = 1, \dots, m\}, \quad u \in \mathbb{R}^m,$$

con $p(u) = +\infty$ si no hay puntos factibles para ese u . Nota que $p(0) = p^*$ es el valor del problema original; $u_i > 0$ *relaja* la restricción i y $u_i < 0$ la *endurece*. Por construcción, p es no creciente en cada u_i (relajar nunca empeora).

Proposición 10.26 (Convexidad de la función valor). Si X es convexo y $f, g_1, \dots, g_m$ son convexas, entonces p es una función convexa de u .

Idea de la demostración. La gráfica “por encima” de p es esencialmente el conjunto $\mathcal{A} = \{(u, t) : \exists x \in X, g(x) \leq u, f(x) \leq t\}$ de la sección 10.5 (en efecto, $p(u) = \inf\{t : (u, t) \in \mathcal{A}\}$, así que $\text{epi}(p)$ y $\mathcal{A}$ coinciden salvo puntos frontera). Se verifica que $\mathcal{A}$ es convexo: si (u^1, t^1) y (u^2, t^2) están en $\mathcal{A}$ con testigos x^1, x^2 , entonces para $x_t = tx^1 + (1 - t)x^2 \in X$ la convexidad de g_i y de f da $g_i(x_t) \leq tu_i^1 + (1 - t)u_i^2$ y $f(x_t) \leq tt^1 + (1 - t)t^2$. Una función cuyo epígrafo es convexo es convexa (capítulo de funciones convexas). $\square$

Teorema 10.27 (Multiplicadores como subgradiientes de la función valor). *Supongamos el problema convexo con dualidad fuerte y multiplicador dual óptimo $\lambda^* \geq 0$. Entonces, para todo $u \in \mathbb{R}^m$,*

$$p(u) \geq p(0) - \langle \lambda^*, u \rangle,$$

es decir, $-\lambda^ \in \partial p(0)$: el vector $-\lambda^*$ es un subgradiente de la función valor en $u = 0$. Si además p es diferenciable en 0, entonces*

$$\lambda_i^* = -\frac{\partial p}{\partial u_i}(0), \quad i = 1, \dots, m :$$

el multiplicador i es exactamente la tasa a la que cae el costo óptimo cuando se relaja la restricción i : el precio sombra.

Demostración. Sea u fijo y x cualquier punto con $x \in X$, $g(x) \leq u$. Entonces

$$f(x) + \langle \lambda^*, u \rangle \geq f(x) + \langle \lambda^*, g(x) \rangle \geq \inf_{z \in X} L(z, \lambda^*) = q(\lambda^*) = p(0),$$

donde la primera desigualdad usa $\lambda^* \geq 0$ y $g(x) \leq u$ componente a componente, y la última igualdad es la dualidad fuerte. Tomando ínfimo sobre los x admisibles para u : $p(u) + \langle \lambda^*, u \rangle \geq p(0)$, que es la desigualdad del subgradiente. El caso diferenciable es inmediato: si p es diferenciable en 0, su único subgradiente es el gradiente (capítulo del subdiferencial), luego $\nabla p(0) = -\lambda^*$. $\square$

Intuición

Esta es la mejor manera de *recordar* toda la dualidad de una vez. La función valor $p(u)$ es una superficie convexa y decreciente; en $u = 0$ está el problema real. La función dual con multiplicador λ es la mejor cota afín con pendiente $-\lambda$ por debajo de esa superficie, y de hecho $q(\lambda) = \inf_u [p(u) + \langle \lambda, u \rangle]$: el dual “palpa” la función valor con hiperplanos. Dualidad fuerte = en $u = 0$ la superficie admite un hiperplano soporte no vertical, y su pendiente es $-\lambda^*$. Por eso el multiplicador *es* un precio: mide en el margen cuánto vale una unidad más de recurso (relajación). El capítulo de la envolvente convertirá esta observación en el teorema de la envolvente (las derivadas de funciones valor como $v(p, w)$ o $e(p, u)$ respecto de sus parámetros) que en micro produce Roy, Shephard y Hotelling [11]. Y la conexión con el Ejemplo 10.17: allí la función valor es $p(u) = -(1 + u)^2$ para $u \in [-1, 1]$, cóncava en vez de convexa; en $u = 0$ no hay soporte afín por debajo que la toque, y por eso hay brecha.

10.8. Resumen y ejercicios [P2]

Resumen del capítulo

- **Función dual:** $q(\lambda, \mu) = \inf_{x \in X} L(x, \lambda, \mu)$. Es *siempre cóncava* (ínfimo puntual de funciones afines en (λ, μ)), sea el primal convexo o no. El problema dual es $\max_{\lambda \geq 0, \mu} q(\lambda, \mu)$, con valor d^* .
- **Dualidad débil:** $q(\lambda, \mu) \leq p^*$ para todo $\lambda \geq 0$ (demostración: ínfimo $\leq$ valor en un

factible, y en un factible las multas son ≤ 0). Luego $d^* \leq p^*$; la diferencia $p^* - d^* \geq 0$ es la brecha de dualidad. Un par primal–dual factible con $f(\hat{x}) = q(\hat{\lambda}, \hat{\mu})$ certifica optimalidad de ambos.

- **Lectura económica:** los multiplicadores son precios sombra de los recursos; el dual es el problema de un mercado que busca la valoración mínima de las dotaciones sin dejar arbitraje (ninguna actividad estrictamente rentable). Kantorovich–Koopmans, Nobel 1975.
- **Punto silla:** $L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*)$. Teorema central: hay punto silla $\iff x^*$ óptimo primal + (λ^*, μ^*) óptimo dual + brecha cero (sin hipótesis de convexidad). Bajo convexidad y diferenciabilidad, punto silla $\iff$ KKT.
- **Dualidad fuerte:** problema convexo + Slater (un punto estrictamente factible) $\Rightarrow p^* = d^*$ y el dual se alcanza. Demostración vía hiperplano soporte al conjunto $\mathcal{A}$ de pares (violación, costo) alcanzables; Slater descarta el hiperplano vertical [2]. Sin convexidad la brecha puede ser positiva (Ejemplo 10.17: $p^* = -1 > d^* = -2$).
- **Casos resueltos:** dual de un LP = LP traspuesto (no arbitraje); dual de un QP definido positivo = QP cóncavo en $\lambda \geq 0$; UMP: λ^* = utilidad marginal de la riqueza, y la dualidad Marshall–Hicks es la estructura primal–dual con multiplicadores recíprocos; minimax de von Neumann = dualidad LP entre los problemas de los dos jugadores, valor del juego = valor común.
- **Perturbación:** $p(u) = \inf\{f : g \leq u\}$ es convexa si el problema lo es; $-\lambda^* \in \partial p(0)$, y con diferenciabilidad $\lambda_i^* = -\partial p / \partial u_i(0)$: puente directo al teorema de la envolvente.

Ejercicio 10.28. (Desigualdad max–min general.) Sea $F : S \times Y \rightarrow \mathbb{R}$ cualquier función y S, Y conjuntos no vacíos. Demuestra que

$$\sup_{s \in S} \inf_{y \in Y} F(s, y) \leq \inf_{y \in Y} \sup_{s \in S} F(s, y),$$

y explica por qué la dualidad débil (Teorema 10.5) es un caso particular.

Solución. Fijemos $s \in S$ y $y \in Y$ arbitrarios. Por definición de ínfimo, $\inf_{y'} F(s, y') \leq F(s, y)$; por definición de supremo, $F(s, y) \leq \sup_{s'} F(s', y)$. Encadenando,

$$\inf_{y'} F(s, y') \leq \sup_{s'} F(s', y) \quad \text{para todo } s, y.$$

El lado izquierdo no depende de y y el derecho no depende de s : tomando supremo sobre s a la izquierda (el lado derecho es una cota superior fija) y luego ínfimo sobre y a la derecha, se obtiene la desigualdad pedida. (Lema en palabras: *el que se mueve segundo tiene ventaja*.)

Para la dualidad débil, toma $F((\lambda, \mu), x) = L(x, \lambda, \mu)$ con $S = \mathbb{R}_+^m \times \mathbb{R}^p$ y $Y = X$. El lado izquierdo es $\sup_{\lambda \geq 0, \mu} \inf_x L = d^*$. Para el derecho, calcula el supremo interno: si x es factible, $\sup_{\lambda \geq 0, \mu} L(x, \lambda, \mu) = f(x)$ (las multas óptimas son cero); si x viola alguna restricción, ese supremo es $+\infty$ (multa infinita). Por tanto $\inf_x \sup_{\lambda, \mu} L = \inf\{f(x) : x \text{ factible}\} = p^*$, y

la desigualdad max–min es exactamente $d^* \leq p^*$. (De paso: esto muestra que el primal es el problema “ínf sup” y el dual el “sup ínf” del mismo lagrangiano, y que la dualidad fuerte es poder intercambiar el orden.) $\square$

Ejercicio 10.29. (Dual de un LP en forma de desigualdades.) Deriva el problema dual de

$$\min_{x \in \mathbb{R}^n} c^\top x \quad \text{s.a.} \quad Ax \geq b, \quad x \geq 0,$$

con $A \in \mathbb{R}^{m \times n}$, y da la interpretación de no arbitraje de sus restricciones.

Solución. Escribimos las restricciones como $b - Ax \leq 0$ (multiplicadores $\lambda \in \mathbb{R}_+^m$) y $-x \leq 0$ (multiplicadores $s \in \mathbb{R}_+^n$):

$$L(x, \lambda, s) = c^\top x + \lambda^\top (b - Ax) - s^\top x = b^\top \lambda + (c - A^\top \lambda - s)^\top x.$$

Afin en x : el ínfimo sobre $x \in \mathbb{R}^n$ es $-\infty$ salvo que $c - A^\top \lambda - s = 0$, en cuyo caso $q(\lambda, s) = b^\top \lambda$. Como $s \geq 0$ actúa de holgura, la condición equivale a $A^\top \lambda \leq c$. El dual es

$$\max_{\lambda \geq 0} b^\top \lambda \quad \text{s.a.} \quad A^\top \lambda \leq c.$$

Interpretación (lee x como niveles de actividades que deben cubrir requerimientos b , con costos unitarios c): λ_i es el precio sombra del requerimiento i ; la restricción dual $(A^\top \lambda)_k \leq c_k$ dice que el valor imputado a lo que produce una unidad de la actividad k no puede exceder su costo, es decir, ninguna actividad puede generar valor estrictamente mayor que su costo (no arbitraje), y el objetivo busca la valoración máxima de los requerimientos compatible con ello. En el óptimo, holgura complementaria: actividades usadas tienen imputación exacta, requerimientos con holgura tienen precio cero. $\square$

Ejercicio 10.30. (QP con igualdad.) Resuelve por dualidad el problema

$$\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2 \quad \text{s.a.} \quad x_1 + 2x_2 = 5 :$$

calcula la función dual $q(\mu)$, resuelve el dual, recupera x^* , verifica que no hay brecha y comprueba la interpretación de μ^* como precio sombra recalculando el valor óptimo con la restricción $x_1 + 2x_2 = 5 + \varepsilon$.

Solución. *Función dual.* Con multiplicador $\mu \in \mathbb{R}$ (libre: la restricción es de igualdad), $L(x, \mu) = x_1^2 + x_2^2 + \mu(5 - x_1 - 2x_2)$, convexa en x . Las condiciones de primer orden $2x_1 - \mu = 0$ y $2x_2 - 2\mu = 0$ dan $x(\mu) = (\mu/2, \mu)$, y

$$q(\mu) = \frac{\mu^2}{4} + \mu^2 + \mu \left(5 - \frac{\mu}{2} - 2\mu \right) = \frac{5\mu^2}{4} + 5\mu - \frac{5\mu^2}{2} = 5\mu - \frac{5\mu^2}{4},$$

cóncava, como debe ser.

Dual y recuperación. $q'(\mu) = 5 - \frac{5}{2}\mu = 0$ da $\mu^* = 2$ y $d^* = 10 - 5 = 5$. Entonces $x^* = x(\mu^*) = (1, 2)$, que es factible ($1 + 4 = 5$) con valor $p^* = 1 + 4 = 5 = d^*$: brecha cero (por el Corolario

10.7 esto certifica que x^* y μ^* son óptimos; para restricciones afines la dualidad fuerte estaba garantizada). Geométricamente, x^* es la proyección del origen sobre la recta.

Precio sombra. Con la restricción $x_1 + 2x_2 = 5 + \varepsilon$, el mismo cálculo (o la fórmula de proyección: el cuadrado de la distancia del origen a la recta $a^\top x = \beta$ es $\beta^2 / \|a\|^2$ con $a = (1, 2)$, $\|a\|^2 = 5$) da la función valor

$$p(\varepsilon) = \frac{(5 + \varepsilon)^2}{5}, \quad p'(0) = \frac{2 \cdot 5}{5} = 2 = \mu^*.$$

(Con nuestra convención de signos para igualdades, μ^* mide el *aumento* del costo al aumentar el lado derecho; el signo depende de cómo se escriba h , así que en un examen decláralo siempre.) La derivada de la función valor en el punto de interés coincide con el multiplicador: Teorema 10.27. $\square$

Ejercicio 10.31. (Brecha positiva.) Considera $\min_{x \in [0,1]} -x^2$ s.a. $x \leq \frac{1}{2}$ (es decir, $g(x) = x - \frac{1}{2} \leq 0$, $X = [0, 1]$). Calcula p^* , la función dual $q(\lambda)$, el valor dual d^* y la brecha. ¿Existe un punto silla del lagrangiano? Justifica con el teorema correspondiente.

Solución. *Primal.* Factibles: $x \in [0, \frac{1}{2}]$. Minimizar $-x^2$ empuja a $x^* = \frac{1}{2}$: $p^* = -\frac{1}{4}$.

Dual. $L(x, \lambda) = -x^2 + \lambda(x - \frac{1}{2})$ es cóncava en x , luego su mínimo sobre el intervalo $[0, 1]$ está en un extremo:

$$L(0, \lambda) = -\frac{\lambda}{2}, \quad L(1, \lambda) = -1 + \frac{\lambda}{2} \quad \implies \quad q(\lambda) = \min \left\{ -\frac{\lambda}{2}, \frac{\lambda}{2} - 1 \right\}.$$

La primera rama decrece y la segunda crece; el máximo está en el cruce $-\lambda/2 = \lambda/2 - 1$, es decir $\lambda^* = 1$, con $d^* = q(1) = -\frac{1}{2}$.

Brecha y punto silla. $p^* - d^* = -\frac{1}{4} + \frac{1}{2} = \frac{1}{4} > 0$. Por el Teorema 10.12, un punto silla existe si y solo si hay óptimos primal y dual *con brecha cero*; como la brecha es positiva, **no existe punto silla**, a pesar de que el primal tiene solución. La culpa es de la no convexidad del objetivo: la función valor $p(u) = -(\frac{1}{2} + u)^2$ (para $u \in [-\frac{1}{2}, \frac{1}{2}]$) es cóncava, y en $u = 0$ no admite minorante afín que la toque, que es exactamente lo que el multiplicador necesitaría ser. $\square$

Ejercicio 10.32. (Consumidor log-lineal.) Para $u(x_1, x_2) = \frac{1}{2} \ln x_1 + \frac{1}{2} \ln x_2$, precios $p_1, p_2 > 0$ y riqueza $w > 0$:

- plantea el UMP como problema de minimización y calcula su función dual $q(\lambda)$;
- resuelve el dual y muestra que $\lambda^* = 1/w$;
- recupera las demandas marshallianas minimizando $L(\cdot, \lambda^*)$ y verifica la ausencia de brecha;
- plantea el EMP con $\bar{u} = v(p, w)$ y comprueba que su multiplicador es $\rho^* = 1/\lambda^* = w$.

Solución. (a) El UMP es $\min_{x>0} \left[-\frac{1}{2} \ln x_1 - \frac{1}{2} \ln x_2 \right]$ s.a. $p^\top x - w \leq 0$. El lagrangiano $L(x, \lambda) = -\frac{1}{2} \ln x_1 - \frac{1}{2} \ln x_2 + \lambda(p^\top x - w)$ es convexo en x ; las condiciones de primer orden $\frac{1}{2x_k} = \lambda p_k$ dan $x_k(\lambda) = \frac{1}{2\lambda p_k}$. Sustituyendo,

$$q(\lambda) = \frac{1}{2} \ln(2\lambda p_1) + \frac{1}{2} \ln(2\lambda p_2) + \lambda \left(\frac{1}{2\lambda} + \frac{1}{2\lambda} \right) - \lambda w = \ln(2\lambda) + \frac{1}{2} \ln(p_1 p_2) + 1 - \lambda w.$$

(b) $q'(\lambda) = 1/\lambda - w = 0$ da $\lambda^* = 1/w (> 0)$, y q es cóncava en $\lambda > 0$ (segunda derivada $-1/\lambda^2 < 0$), así que es el máximo del dual.

(c) $x_k^* = x_k(\lambda^*) = \frac{w}{2p_k}$ para $k = 1, 2$: las demandas de Cobb–Douglas con participaciones $\frac{1}{2}$. Son factibles con igualdad: $p^\top x^* = \frac{w}{2} + \frac{w}{2} = w$. El valor primal es $-u(x^*) = -v(p, w)$ con $v(p, w) = \frac{1}{2} \ln \frac{w}{2p_1} + \frac{1}{2} \ln \frac{w}{2p_2} = \ln \frac{w}{2} - \frac{1}{2} \ln(p_1 p_2)$; y $q(\lambda^*) = \ln \frac{2}{w} + \frac{1}{2} \ln(p_1 p_2) + 1 - 1 = -v(p, w)$. Iguales: brecha cero (consistente con Slater: $\hat{x}$ con $p^\top \hat{x} < w$ existe porque $w > 0$).

(d) EMP: $\min_{x>0} p^\top x$ s.a. $\bar{u} - u(x) \leq 0$ con $\bar{u} = v(p, w)$. KKT: $p_k = \rho^* \cdot \frac{1}{2x_k^*}$, y la solución hicksiana coincide con x^* del inciso (c) (misma curva de indiferencia, misma tangencia). De $p_k = \rho^*/(2x_k^*)$ con $x_k^* = w/(2p_k)$ sale $\rho^* = 2p_k x_k^* = w$. En efecto $\rho^* = w = 1/\lambda^*$: multiplicadores recíprocos, como afirma la Observación 10.20: “utilidad extra por sol” ($1/w$) y “soles por útil extra” (w) son la misma tasa invertida. $\square$

Ejercicio 10.33. (Juego de suma cero.) La fila y la columna juegan el juego con matriz de pagos a la fila

$$A = \begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix}.$$

Muestra que no hay silla en puras, encuentra las estrategias mixtas óptimas s^*, y^* y el valor v del juego resolviendo el par primal–dual, y verifica la propiedad de indiferencia.

Solución. *Puras.* Garantía de la fila: $\max_i \min_k a_{ik} = \max\{0, 1\} = 1$ (fila 2). Garantía de la columna: $\min_k \max_i a_{ik} = \min\{2, 3\} = 2$ (columna 1). Como $1 < 2$, no hay punto silla puro.

Fila (primal). Con $s = (\sigma, 1 - \sigma)$: contra la columna 1 gana $2\sigma + (1 - \sigma) = 1 + \sigma$; contra la columna 2 gana $3(1 - \sigma) = 3 - 3\sigma$. Maximiza $\min\{1 + \sigma, 3 - 3\sigma\}$: el cruce $1 + \sigma = 3 - 3\sigma$ da $\sigma^* = \frac{1}{2}$, valor $v = \frac{3}{2}$. Luego $s^* = (\frac{1}{2}, \frac{1}{2})$.

Columna (dual). Con $y = (\tau, 1 - \tau)$: la fila 1 gana 2τ ; la fila 2 gana $\tau + 3(1 - \tau) = 3 - 2\tau$. La columna minimiza $\max\{2\tau, 3 - 2\tau\}$: cruce $2\tau = 3 - 2\tau$, o sea $\tau^* = \frac{3}{4}$, valor $2 \cdot \frac{3}{4} = \frac{3}{2}$. Luego $y^* = (\frac{3}{4}, \frac{1}{4})$.

Valor e indiferencia. Ambos problemas valen $v = \frac{3}{2}$: brecha cero, y por el Teorema 10.22 (s^*, y^*) es punto silla de $s^\top A y$. Indiferencia: contra $y^* = (\frac{3}{4}, \frac{1}{4})$, la fila 1 rinde $2 \cdot \frac{3}{4} = \frac{3}{2}$ y la fila 2 rinde $\frac{3}{4} + 3 \cdot \frac{1}{4} = \frac{3}{2}$, iguales, por eso la fila puede mezclar; contra $s^* = (\frac{1}{2}, \frac{1}{2})$, la columna 1 cuesta $\frac{1}{2}(2 + 1) = \frac{3}{2}$ y la columna 2 cuesta $\frac{1}{2}(0 + 3) = \frac{3}{2}$, iguales también. Toda estrategia pura usada con probabilidad positiva es mejor respuesta: holgura complementaria del par primal–dual, y el método estándar de la teoría de juegos para calcular equilibrios mixtos. $\square$

Capítulo 11

Teoremas de la envolvente y análisis de sensibilidad [P1]

Entre la dualidad lagrangiana y la conjugación de Fenchel. Bibliografía: Aragón et al. [1]; Milgrom y Segal [11].

¿Para qué sirve esto en Microeconomía?

El teorema de la envolvente (*envelope theorem*) es, posiblemente, el teorema más usado de toda la microeconomía. Lo vas a usar de forma constante y en todas las partes del curso. En **decisión individual** (consumidor y firma, MWG caps. 3 y 5) es la máquina que produce los tres resultados centrales de la dualidad: el *lema de Shephard* (derivar la función de gasto da la demanda hicksiana), el *lema de Hotelling* (derivar la función de beneficio da la oferta y las demandas de insumos) y la *identidad de Roy* (un cociente de derivadas de la utilidad indirecta da la demanda marshalliana); combinado con las propiedades de curvatura de las funciones de valor, entrega además la ley de la oferta y la matriz de Slutsky simétrica y semidefinida negativa. En **bienestar e incentivos** (diseño de mecanismos y subastas, MWG cap. 23), la versión integral de Milgrom–Segal (2002) es la que genera la *fórmula de pagos* y el *teorema de equivalencia de ingresos* (*revenue equivalence*) de Myerson: la utilidad de equilibrio de un postor es una integral de su probabilidad de ganar, y por lo tanto el ingreso esperado del subastador queda determinado por la regla de asignación. En **fallas de mercado** (contratos, riesgo moral y selección adversa, MWG caps. 13 y 14), la “renta informacional” del agente se caracteriza aplicando la envolvente a la restricción de compatibilidad de incentivos (IC): la utilidad del tipo θ es la integral de las derivadas parciales respecto del tipo. Finalmente, el *análisis de sensibilidad* (el multiplicador de Lagrange como *precio sombra*) es la lectura económica de las condiciones KKT del capítulo anterior: λ^* mide cuánto vale, en términos del objetivo, una unidad adicional de recurso. Domina este capítulo y habrás dominado la gramática con la que está escrita la micro moderna.

Este capítulo responde una pregunta que en apariencia es modesta:

¿Cómo cambia el valor óptimo de un problema de optimización cuando cambia un parámetro?

La respuesta, sorprendentemente simple, es que, al primer orden, *solo importa el efecto directo del parámetro*: el efecto indirecto, vía el reajuste de la solución óptima, es de segundo orden y desaparece. Esa observación, formalizada, es el teorema de la envolvente. Todo el capítulo es una explotación sistemática de esa idea.

11.1. Funciones de valor [P1]

11.1.1. Definición y ejemplos que ya conoces

Definición 11.1 (Función de valor). Sea $f : \mathbb{R}^n \times \Theta \rightarrow \mathbb{R}$ una función objetivo que depende de una variable de decisión $x \in \mathbb{R}^n$ y de un *parámetro* $\theta \in \Theta \subseteq \mathbb{R}^k$, y sea $\Gamma(\theta) \subseteq \mathbb{R}^n$ el conjunto factible (que puede depender del parámetro). La *función de valor* (*value function*) del problema

$$\max_x f(x, \theta) \quad \text{sujeto a} \quad x \in \Gamma(\theta)$$

es la función que asigna a cada parámetro el valor óptimo alcanzable:

$$V(\theta) := \sup_{x \in \Gamma(\theta)} f(x, \theta).$$

El conjunto de soluciones óptimas se denota $X^*(\theta) := \arg \max_{x \in \Gamma(\theta)} f(x, \theta)$ y se llama *correspondencia de solución* (*argmax correspondence*); cuando es un único punto para cada θ escribimos $x(\theta)$ y hablamos de la *función de política* (*policy function*).

Dos comentarios sobre la definición. Primero, usamos $\sup$ y no $\max$ porque en general el máximo podría no alcanzarse; cuando $\Gamma(\theta)$ es compacto y $f(\cdot, \theta)$ es continua, el teorema de Weierstrass (capítulo de preliminares) garantiza que el supremo se alcanza y podemos escribir $\max$ sin culpa. Segundo, la función de valor *no* depende de x : la variable de decisión ya fue “optimizada hacia afuera” (*maximized out*). V solo ve los parámetros.

La razón por la que este objeto es central en economía es que **ya conoces varias funciones de valor**, aunque quizá nunca las llamaste así:

Ejemplo 11.2 (Las cuatro funciones de valor de la microeconomía). Sea $p \in \mathbb{R}_{++}^n$ un vector de precios de bienes, $w \in \mathbb{R}_{++}^m$ un vector de precios de insumos, $m > 0$ el ingreso del consumidor, $u(\cdot)$ una función de utilidad y Y un conjunto de producción (o F una función de producción).

(a) **Utilidad indirecta** (*indirect utility*): el valor del problema del consumidor,

$$v(p, m) := \max_{x \geq 0} u(x) \quad \text{s.a.} \quad \langle p, x \rangle \leq m.$$

Aquí la decisión es la canasta x y los parámetros son (p, m) .

(b) **Función de gasto** (*expenditure function*): el valor del problema dual de minimizar el gasto para alcanzar la utilidad u ,

$$e(p, u) := \min_{x \geq 0} \langle p, x \rangle \quad \text{s.a.} \quad u(x) \geq u.$$

Es un problema de *minimización*, con parámetros (p, u) . Su solución óptima $h(p, u)$ es la *demanda hicksiana o compensada* (*Hicksian demand*).

- (c) **Función de beneficio** (*profit function*): para una firma con conjunto de producción $Y \subseteq \mathbb{R}^n$ (con la convención de signos: insumos negativos, productos positivos),

$$\pi(p) := \sup_{y \in Y} \langle p, y \rangle.$$

En la versión con función de producción de un solo producto: $\pi(p, w) = \max_{x \geq 0} p F(x) - \langle w, x \rangle$. Nota que $\pi(p) = \sup_{y \in Y} \langle p, y \rangle$ es exactamente la *función soporte* de Y que estudiamos en el capítulo de funciones convexas: la teoría de la firma competitiva es análisis convexo aplicado.

- (d) **Función de costo** (*cost function*): el valor de minimizar el costo de producir la cantidad y ,

$$c(w, y) := \min_{x \geq 0} \langle w, x \rangle \quad \text{s.a.} \quad F(x) \geq y.$$

Su solución $x(w, y)$ es la *demanda condicionada de insumos* (*conditional factor demand*): condicionada porque toma el nivel de producto y como dado.

Toda la “dualidad” de MWG caps. 3 y 5 [9] consiste en estudiar estas cuatro funciones de valor y extraer de ellas, por diferenciación, las funciones de demanda y oferta. El teorema de la envolvente es la herramienta que hace esa extracción.

Observación 11.3. Todo lo que digamos para problemas de maximización vale para minimización con los cambios de signo obvios: si $V(\theta) = \min_x f(x, \theta)$, entonces $V(\theta) = -\max_x [-f(x, \theta)]$, así que cada teorema tiene su versión “min”. En particular, una función de valor de un *máximo* de funciones afines del parámetro será *convexa*, y la de un *mínimo* de funciones afines será *cóncava*; esto explicará en la Sección 11.5 por qué π es convexa y c es cóncava.

11.1.2. ¿Por qué “envolvente”? La imagen geométrica

El nombre viene de una imagen que conviene grabarse. Fija cada decisión posible x y mira la función *del parámetro* que resulta de no reoptimizar nunca:

$$g_x(\theta) := f(x, \theta), \quad \theta \in \Theta.$$

Obtenemos una *familia de curvas* $\{g_x\}_x$, una por cada decisión congelada. Por definición de supremo,

$$V(\theta) = \sup_x g_x(\theta) :$$

en cada θ , la función de valor toma el valor de la curva más alta de la familia. Se dice entonces que V es la *envolvente superior* (*upper envelope*) de la familia: el grafo de V “envuelve” por arriba a todos los grafos g_x , tocando en cada punto a la curva que ahí es óptima.

Dos consecuencias geométricas inmediatas, que son el corazón de todo el capítulo:

- (i) **Dominancia:** $V(\theta) \geq g_x(\theta)$ para todo x y todo θ , con igualdad exactamente cuando x es óptimo en θ . Es decir, cada curva de la familia está *debajo* de la envolvente y la *toca* donde

esa decisión es la mejor.

- (II) **Tangencia:** si V y g_x son diferenciables y g_x toca a V en θ_0 (o sea, $x \in X^*(\theta_0)$), entonces la diferencia $V - g_x$ alcanza un mínimo (igual a cero) en θ_0 ; por la condición de primer orden de ese mínimo interior, $V'(\theta_0) = g'_x(\theta_0)$. *Las pendientes coinciden en el punto de contacto:* la envolvente es tangente a cada miembro de la familia donde lo toca.

La consecuencia (ii) *ya es* el teorema de la envolvente: la derivada de la función de valor es la derivada parcial del objetivo respecto del parámetro, *manteniendo la decisión fija en su nivel óptimo*. Lo formalizaremos en la Sección 11.2, pero primero un ejemplo completamente calculado.

Ejemplo 11.4 (Una envolvente calculada a mano). Sea $f(x, \theta) = \theta x - \frac{1}{2}x^2$ con $x, \theta \in \mathbb{R}$ (piénsalo como una firma que elige producción x con ingreso marginal θ y costo cuadrático). Para cada θ , la condición de primer orden $\partial f / \partial x = \theta - x = 0$ da $x(\theta) = \theta$ (es máximo global porque f es estrictamente cóncava en x). La función de valor es

$$V(\theta) = f(x(\theta), \theta) = \theta \cdot \theta - \frac{1}{2}\theta^2 = \frac{1}{2}\theta^2.$$

Ahora miremos la familia de curvas con decisión congelada: para cada x fijo,

$$g_x(\theta) = \theta x - \frac{1}{2}x^2$$

es una *recta* en θ , con pendiente x e intercepto $-\frac{1}{2}x^2$. La parábola $V(\theta) = \frac{1}{2}\theta^2$ es la envolvente superior de esta familia de rectas:

- *Dominancia:* $\frac{1}{2}\theta^2 - (\theta x - \frac{1}{2}x^2) = \frac{1}{2}(\theta - x)^2 \geq 0$, con igualdad si y solo si $x = \theta$. Cada recta está debajo de la parábola y la toca exactamente en $\theta = x$.
- *Tangencia:* en el punto de contacto $\theta_0 = x$, la pendiente de la recta es x y la pendiente de la parábola es $V'(\theta_0) = \theta_0 = x$. Coinciden.
- *Envolvente:* $V'(\theta) = \theta = x(\theta) = \frac{\partial f}{\partial \theta}(x(\theta), \theta)$. La derivada del valor óptimo es la derivada parcial del objetivo respecto de θ con la decisión congelada en su valor óptimo. (De paso: como V es el supremo de funciones afines de θ , es convexa; volveremos sobre esto.)

La Figura 11.1 muestra la parábola y cinco rectas de la familia.

Intuición

La imagen que hay que retener: **la función de valor es el “techo” de una familia de curvas, y en cada punto es tangente a la curva que la sostiene**. Por eso, para calcular la pendiente del techo en θ_0 no necesitas saber cómo se *mueve* la decisión óptima cuando θ cambia: basta la pendiente de la curva individual que toca el techo en θ_0 , es decir, la derivada parcial $\partial f / \partial \theta$ con x congelado en $x(\theta_0)$. El reajuste óptimo de x no aporta nada *al primer orden* precisamente porque $x(\theta_0)$ ya era óptimo: moverse desde un óptimo tiene efecto marginal nulo sobre el objetivo. Esa es la “lógica de la envolvente” y la vas a usar cientos de veces.




Figura 11.1: La función de valor $V(\theta) = \frac{1}{2}\theta^2$ (curva gruesa) como envolvente superior de la familia de rectas $g_x(\theta) = \theta x - \frac{1}{2}x^2$ (una recta por cada decisión congelada $x \in \{-2, -1, 0, 1, 2\}$). Cada recta queda debajo de V y la toca tangencialmente en $\theta = x$, donde esa decisión es la óptima.

11.2. El teorema de la envolvente sin restricciones [P1]

Formalicemos la discusión anterior en el caso más simple: optimización sin restricciones (o, lo que es lo mismo para nuestros fines, con solución en el interior del conjunto factible y restricciones que no dependen del parámetro).

Teorema 11.5 (Envolvente, caso sin restricciones). Sean $X \subseteq \mathbb{R}^n$ un abierto, $\Theta \subseteq \mathbb{R}$ un intervalo abierto y $f : X \times \Theta \rightarrow \mathbb{R}$ de clase C^1 . Supongamos que:

- (H1) para cada $\theta \in \Theta$ el problema $\max_{x \in X} f(x, \theta)$ tiene solución $x(\theta) \in X$ (solución interior, pues X es abierto);
- (H2) la selección $\theta \mapsto x(\theta)$ es diferenciable en $\theta_0 \in \Theta$.

Entonces la función de valor $V(\theta) = f(x(\theta), \theta)$ es diferenciable en θ_0 y

$$V'(\theta_0) = \frac{\partial f}{\partial \theta}(x(\theta_0), \theta_0).$$

Es decir: la derivada del valor óptimo es la derivada parcial del objetivo respecto del parámetro, evaluada en la solución óptima, sin término de reajuste.

Demostración. Damos cada paso. Como $x(\cdot)$ es diferenciable en θ_0 y f es C^1 , la función compuesta $V(\theta) = f(x(\theta), \theta)$ es diferenciable en θ_0 y la regla de la cadena (para la composición $\theta \mapsto (x(\theta), \theta) \mapsto f$) da

$$V'(\theta_0) = \underbrace{\langle \nabla_x f(x(\theta_0), \theta_0), x'(\theta_0) \rangle}_{\text{efecto indirecto: reajuste de } x} + \underbrace{\frac{\partial f}{\partial \theta}(x(\theta_0), \theta_0)}_{\text{efecto directo}}. \quad (*)$$

Ahora usamos la optimalidad. Como $x(\theta_0)$ maximiza $f(\cdot, \theta_0)$ sobre el abierto X y $f(\cdot, \theta_0)$ es diferenciable, la condición necesaria de primer orden para un máximo interior (capítulo de optimalidad) exige

$$\nabla_x f(x(\theta_0), \theta_0) = 0.$$

Sustituyendo en (*), el primer sumando se anula *cualquiera sea* el valor de $x'(\theta_0)$, y queda $V'(\theta_0) = \partial f / \partial \theta(x(\theta_0), \theta_0)$, como se afirmó. $\square$

Vale la pena dar también la demostración “geométrica” que no usa la regla de la cadena sobre $x(\cdot)$, porque es la que se generaliza a Milgrom–Segal:

Proposición 11.6 (Versión por comparación de tangentes). *Con la notación anterior, supongamos solamente que V es diferenciable en θ_0 , que $x_0 \in X^*(\theta_0)$ y que $\theta \mapsto f(x_0, \theta)$ es diferenciable en θ_0 . Entonces $V'(\theta_0) = \frac{\partial f}{\partial \theta}(x_0, \theta_0)$.*

Demostración. Definamos $\varphi(\theta) := V(\theta) - f(x_0, \theta)$. Por dominancia (V es el supremo sobre x), $\varphi(\theta) \geq 0$ para todo θ , y por optimalidad de x_0 en θ_0 , $\varphi(\theta_0) = 0$. Luego φ alcanza un *mínimo global* en el punto interior θ_0 . Como φ es diferenciable en θ_0 (diferencia de dos funciones diferenciables ahí), la condición de primer orden da $\varphi'(\theta_0) = 0$, es decir $V'(\theta_0) = \partial f / \partial \theta(x_0, \theta_0)$. $\square$

11.2.1. Discusión de las hipótesis

Ninguna hipótesis del Teorema 11.5 es decorativa; conviene saber qué falla si se retira cada una.

- (a) **Solución interior.** Si el óptimo está en la frontera del conjunto factible, la condición $\nabla_x f = 0$ deja de valer y el efecto indirecto en (*) no se anula por sí solo. La versión con restricciones (Sección 11.3) arregla esto: los términos de frontera quedan capturados por los multiplicadores.
- (b) **Diferenciabilidad de la selección $x(\cdot)$.** Es la hipótesis más incómoda, porque es sobre un objeto *endógeno*: no se supone sobre los datos del problema sino sobre su solución. En la práctica se garantiza con el teorema de la función implícita aplicado a la CPO $\nabla_x f(x, \theta) = 0$, lo que requiere $f \in C^2$ y Hessiano $\nabla_{xx}^2 f(x(\theta_0), \theta_0)$ no singular (por ejemplo, definido negativo: condición suficiente de segundo orden estricta). La Proposición 11.6 muestra que puede sustituirse por “ V diferenciable”, y los teoremas de Danskin y Milgrom–Segal (Secciones 11.7 y 11.6) la eliminan casi por completo.
- (c) **Unicidad (o buena selección).** Si $X^*(\theta_0)$ tiene varios puntos, distintas selecciones pueden dar distintas “derivadas candidatas” $\partial f / \partial \theta(x, \theta_0)$, $x \in X^*(\theta_0)$, y entonces V típicamente *no* es diferenciable en θ_0 : tiene un quiebre, con derivadas laterales dadas por la mayor y la menor de las candidatas. Lo veremos con precisión (y con subdiferenciales) en la Sección 11.7.
- (d) **Existencia del máximo.** Sin ella V es solo un supremo; la teoría sigue en pie en versión “desigualdades” pero las fórmulas exactas requieren que alguien alcance el techo.

Ejemplo 11.7 (Ejemplo numérico completo: beneficio de una firma). Una firma produce $y = 2\sqrt{x}$ con un insumo $x \geq 0$, vende a precio $p > 0$ y compra el insumo a precio $w > 0$. Su problema

es

$$\pi(p, w) = \max_{x>0} f(x; p, w), \quad f(x; p, w) = 2p\sqrt{x} - wx.$$

Paso 1: resolver. CPO: $\partial f/\partial x = p/\sqrt{x} - w = 0$, luego $\sqrt{x} = p/w$ y $x(p, w) = p^2/w^2$. Es máximo global porque f es estrictamente cóncava en x ($\partial^2 f/\partial x^2 = -\frac{p}{2}x^{-3/2} < 0$), y es interior ($x > 0$). La oferta es $y(p, w) = 2\sqrt{x(p, w)} = 2p/w$.

Paso 2: función de valor.

$$\pi(p, w) = 2p \cdot \frac{p}{w} - w \cdot \frac{p^2}{w^2} = \frac{2p^2}{w} - \frac{p^2}{w} = \frac{p^2}{w}.$$

Paso 3: verificar la envolvente respecto de p . Derivada directa de la función de valor: $\partial\pi/\partial p = 2p/w$. Derivada parcial del objetivo con x congelado: $\partial f/\partial p = 2\sqrt{x}$, que evaluada en $x(p, w) = p^2/w^2$ da $2p/w$. Coinciden, y además ambas son iguales a la oferta $y(p, w)$: acabamos de descubrir el lema de Hotelling en un caso concreto.

Paso 4: verificar respecto de w . Directa: $\partial\pi/\partial w = -p^2/w^2$. Congelada: $\partial f/\partial w = -x$, evaluada en el óptimo: $-p^2/w^2$. Coinciden, y ambas son *menos la demanda de insumo*.

Paso 5: ver qué se ignoró. Si hubiéramos derivado “con todo”, por la regla de la cadena: $\frac{d\pi}{dp} = (\frac{p}{\sqrt{x}} - w) \frac{\partial x}{\partial p} + 2\sqrt{x}$. El paréntesis es exactamente la CPO, que vale cero en el óptimo: el término de reajuste $\partial x/\partial p = 2p/w^2 \neq 0$ existe y no es pequeño, pero viene multiplicado por un cero. Eso es la envolvente en acción.

Intuición

¿Por qué el reajuste “no cuesta nada”? Porque en el óptimo la firma es *localmente indiferente* entre su elección y las elecciones vecinas: el beneficio marginal de mover x es cero (eso dice la CPO). Cuando p sube un poquito, la firma reajusta x , sí, pero ese reajuste la mueve entre opciones que valían *lo mismo al margen*; la ganancia de primer orden viene únicamente de que cada unidad que ya producía ahora vale más. En términos contables: ante dp , el beneficio sube en (unidades vendidas) $\times dp$ más un efecto reajuste de orden $(dp)^2$. Los economistas resumen: “a primer orden, evalúa los cambios de parámetros a comportamiento constante”.

11.3. El teorema de la envolvente con restricciones [P1]

En economía casi todos los problemas tienen restricciones que *dependen de los parámetros* (la restricción presupuestaria depende de p y m ; la restricción tecnológica, de y). El teorema anterior no aplica directamente porque la solución no es interior en el sentido requerido. La versión general dice algo muy elegante: **la derivada de la función de valor es la derivada parcial del lagrangiano respecto del parámetro, evaluada en el punto óptimo (con sus multiplicadores óptimos).**

Consideremos el problema parametrizado

$$V(\theta) = \max_{x \in \mathbb{R}^n} f(x, \theta) \quad \text{s.a.} \quad g_j(x, \theta) \leq 0, \quad j = 1, \dots, r, \quad (\text{P}_\theta)$$

con lagrangiano (*Lagrangian*)

$$L(x, \lambda, \theta) = f(x, \theta) - \sum_{j=1}^r \lambda_j g_j(x, \theta).$$

(Las restricciones de igualdad se tratan igual, sin la exigencia de signo sobre sus multiplicadores; para fijar ideas escribimos desigualdades, que es el caso KKT del capítulo anterior.)

Teorema 11.8 (Envolvente con restricciones, versión lagrangiana). *Sean $f, g_1, \dots, g_r$ de clase C^1 en (x, θ) . Supongamos que para cada θ en un entorno de θ_0 :*

(H1) *el problema (P_θ) tiene solución $x(\theta)$ con multiplicadores KKT $\lambda(\theta) \in \mathbb{R}_+^r$ (existe un calificador de restricciones, p. ej. Slater o independencia lineal de gradientes activos, según el capítulo de KKT);*

(H2) *las selecciones $x(\cdot)$ y $\lambda(\cdot)$ son diferenciables en θ_0 ;*

(H3) *holgura complementaria estricta: para cada j , o bien $g_j(x(\theta_0), \theta_0) < 0$ (inactiva), o bien $\lambda_j(\theta_0) > 0$ (activa con multiplicador positivo), de modo que el conjunto de restricciones activas es localmente constante.*

Entonces V es diferenciable en θ_0 y

$$V'(\theta_0) = \frac{\partial L}{\partial \theta}(x(\theta_0), \lambda(\theta_0), \theta_0) = \frac{\partial f}{\partial \theta}(x(\theta_0), \theta_0) - \sum_{j=1}^r \lambda_j(\theta_0) \frac{\partial g_j}{\partial \theta}(x(\theta_0), \theta_0).$$

Demostración. Abreviemos $x_0 = x(\theta_0)$, $\lambda_0 = \lambda(\theta_0)$ y omitamos los puntos de evaluación cuando sea claro. La prueba tiene cuatro pasos.

Paso 1 (el valor coincide con el lagrangiano). Por holgura complementaria (condición KKT del capítulo anterior), $\lambda_j(\theta) g_j(x(\theta), \theta) = 0$ para todo j y todo θ cercano a θ_0 : si la restricción está inactiva su multiplicador es cero, y si el multiplicador es positivo la restricción se cumple con igualdad. Sumando,

$$V(\theta) = f(x(\theta), \theta) = f(x(\theta), \theta) - \sum_j \lambda_j(\theta) g_j(x(\theta), \theta) = L(x(\theta), \lambda(\theta), \theta).$$

Paso 2 (derivar con la regla de la cadena). Todas las piezas son diferenciables en θ_0 por hipótesis, así que

$$V'(\theta_0) = \langle \nabla_x L, x'(\theta_0) \rangle + \sum_j \frac{\partial L}{\partial \lambda_j} \lambda'_j(\theta_0) + \frac{\partial L}{\partial \theta},$$

con todo evaluado en $(x_0, \lambda_0, \theta_0)$.

Paso 3 (el término en x se anula). La condición de estacionariedad de KKT dice exactamente $\nabla_x L(x_0, \lambda_0, \theta_0) = \nabla_x f - \sum_j \lambda_{0j} \nabla_x g_j = 0$. Primer término: cero, cualquiera sea $x'(\theta_0)$.

Paso 4 (el término en λ se anula). Se tiene $\partial L / \partial \lambda_j = -g_j(x_0, \theta_0)$. Distingamos por holgura complementaria estricta. Si $g_j(x_0, \theta_0) < 0$ (inactiva), entonces por continuidad sigue inactiva cerca de θ_0 , con lo cual $\lambda_j(\theta) = 0$ en un entorno y $\lambda'_j(\theta_0) = 0$: el sumando $-g_j \cdot \lambda'_j$ es cero. Si en cambio $\lambda_{0j} > 0$ (activa), entonces $g_j(x_0, \theta_0) = 0$ y el factor $-g_j$ del sumando es cero. En ambos

casos el sumando j -ésimo muere. Queda entonces

$$V'(\theta_0) = \frac{\partial L}{\partial \theta}(x_0, \lambda_0, \theta_0) = \frac{\partial f}{\partial \theta}(x_0, \theta_0) - \sum_j \lambda_{0j} \frac{\partial g_j}{\partial \theta}(x_0, \theta_0),$$

que es la fórmula anunciada. $\square$

Observación 11.9. La regla práctica que hay que memorizar: *para derivar una función de valor respecto de un parámetro, escribe el lagrangiano, deriva parcialmente respecto del parámetro tratando x y λ como constantes, y evalúa en el óptimo.* Nada de derivar las políticas $x(\theta)$: todos esos términos se cancelan por estacionariedad y holgura complementaria, como acabamos de ver. Esta regla contiene al Teorema 11.5 como caso particular (sin restricciones, $L = f$).

Cuidado (error común)

Tres errores clásicos de examen con esta fórmula. **(1)** Olvidar el término de las restricciones: si el parámetro aparece en g_j , la derivada de V *no* es solo $\partial f / \partial \theta$; lleva el término $-\sum_j \lambda_j \partial g_j / \partial \theta$. Ejemplo: en el consumidor, p_i no aparece en $u(x)$ pero sí en la restricción presupuestaria; toda la acción está en el multiplicador (así sale la identidad de Roy). **(2)** El signo depende de cómo escribiste la restricción. Con $L = f - \lambda(g - b)$ y restricción $g(x) \leq b$ se obtiene $\partial V / \partial b = +\lambda$; si escribes la restricción como $b - g(x) \geq 0$ y cambias la convención del lagrangiano, los signos se mueven. Antes de derivar, fija tu convención y sé consistente. **(3)** Aplicar la fórmula en un punto donde la solución no es única o donde una restricción está justo “a punto de activarse” ($g_j = 0$ con $\lambda_j = 0$): ahí V puede tener un quiebre y solo existen derivadas laterales (Sección 11.7).

11.3.1. El multiplicador como precio sombra

El caso especial más importante del Teorema 11.8 es aquel en que el parámetro es la *dotación de un recurso* y entra solo en el lado derecho de una restricción.

Corolario 11.10 (El multiplicador es el precio sombra). *Consideremos $V(b) = \max_x f(x)$ s.a. $g(x) \leq b$, con las hipótesis del Teorema 11.8 (aquí $\theta = b$). Entonces*

$$V'(b) = \lambda^*(b),$$

donde $\lambda^*(b) \geq 0$ es el multiplicador KKT de la restricción en el óptimo.

Demostración. Escribimos la restricción en la forma estándar $\tilde{g}(x, b) := g(x) - b \leq 0$, con lagrangiano $L(x, \lambda, b) = f(x) - \lambda(g(x) - b)$. El objetivo f no depende de b y $\partial \tilde{g} / \partial b = -1$. El Teorema 11.8 da

$$V'(b) = \frac{\partial L}{\partial b} = \underbrace{\frac{\partial f}{\partial b}}_{=0} - \lambda^* \cdot \underbrace{\frac{\partial \tilde{g}}{\partial b}}_{=-1} = \lambda^*. \quad \square$$

Interpretación económica (léela dos veces). $V(b)$ es lo máximo que se puede lograr con b unidades de recurso; $V'(b) = \lambda^*$ dice que *una unidad marginal adicional del recurso vale exactamente λ^* unidades del objetivo*. Por eso λ^* se llama el *precio sombra* (*shadow price*) del

recurso: es el precio máximo que el optimizador estaría dispuesto a pagar (medido en unidades del objetivo) por relajar la restricción en una unidad marginal. Consecuencias que verás una y otra vez:

- En el problema del consumidor, el multiplicador de la restricción presupuestaria es $\lambda^* = \partial v / \partial m$: la *utilidad marginal del ingreso* (*marginal utility of income*). Un sol adicional vale λ^* “útiles”.
- Si una restricción está inactiva en el óptimo, su multiplicador es cero (holgura complementaria) y en efecto relajarla no vale nada: el recurso sobrante tiene precio sombra nulo. KKT y la envolvente cuentan la misma historia económica.
- En dualidad (capítulo anterior): el problema dual “pone precios” a las restricciones; la envolvente confirma que los precios duales óptimos son las sensibilidades del valor primal. Es la misma moneda vista por sus dos caras.
- En planificación y en finanzas: los precios sombra de las restricciones de capacidad son la base de la valoración de activos productivos y de los precios de transferencia internos de una organización [2, 3].

Ejemplo 11.11 (Verificación numérica del precio sombra). Problema: $V(b) = \max_{x_1, x_2 > 0} x_1 x_2$ s.a. $x_1 + x_2 \leq b$, con $b > 0$.

Resolver. Como el objetivo es creciente en cada variable, la restricción se satura: $x_1 + x_2 = b$ y $\lambda > 0$. Lagrangiano $L = x_1 x_2 - \lambda(x_1 + x_2 - b)$. CPO: $x_2 = \lambda$ y $x_1 = \lambda$, luego $x_1 = x_2$ y, con la restricción, $x_1 = x_2 = b/2$, $\lambda^* = b/2$. (Es máximo: sobre la recta presupuestaria el objetivo es $x_1(b - x_1)$, una parábola invertida con vértice en $b/2$.)

Función de valor explícita. $V(b) = \frac{b}{2} \cdot \frac{b}{2} = \frac{b^2}{4}$, de donde $V'(b) = \frac{b}{2} = \lambda^*(b)$. La fórmula del Corolario 11.10 se verifica exactamente.

Verificación con dos valores de b . Tomemos $b = 10$ y $b = 10.1$:

$$V(10) = \frac{100}{4} = 25, \quad V(10.1) = \frac{(10.1)^2}{4} = \frac{102.01}{4} = 25.5025.$$

El incremento real es $\Delta V = 0.5025$. La predicción del precio sombra es $\lambda^*(10) \cdot \Delta b = 5 \times 0.1 = 0.5$. El error, 0.0025, es exactamente el término de segundo orden $\frac{1}{2} V''(10)(\Delta b)^2 = \frac{1}{2} \cdot \frac{1}{2} \cdot (0.1)^2 = 0.0025$: la aproximación de primer orden con el multiplicador es tan buena como promete el cálculo.

Intuición

¿Por qué el planificador puede ignorar *cómo* repartirá la unidad extra de recurso? Otra vez la lógica de la envolvente: en el óptimo, el recurso ya está asignado de modo que su producto marginal es *igual en todos los usos* (si no, convendría reasignar). Esa productividad marginal común es λ^* . Una unidad extra puede entrar por cualquier uso (todos rinden lo mismo al margen) y por eso el valor de la unidad extra es simplemente λ^* , sin necesidad de resolver de nuevo el problema de asignación. El multiplicador comprime toda la complejidad del reparto óptimo en un solo número.

11.4. Las cuatro joyas de la microeconomía [P1]

Aplicamos ahora la maquinaria a las cuatro funciones de valor del Ejemplo 11.2. Cada resultado de esta sección es un teorema con nombre propio que usarás continuamente en Microeconomía; cada uno es un corolario de dos líneas del teorema de la envolvente, y esa es precisamente la moraleja: *la dualidad del consumidor y de la firma no es una colección de trucos, es un solo teorema aplicado cuatro veces* [9, 10].

A lo largo de la sección, para las verificaciones Cobb–Douglas usaremos la utilidad y la tecnología

$$u(x_1, x_2) = x_1^{1/2} x_2^{1/2}, \quad F(x_1, x_2) = x_1^{1/2} x_2^{1/2},$$

con precios de bienes $p = (p_1, p_2) \gg 0$, precios de insumos $w = (w_1, w_2) \gg 0$ e ingreso $m > 0$.

11.4.1. Joya 1: el lema de Hotelling

Teorema 11.12 (Lema de Hotelling (*Hotelling's lemma*)). Sea $\pi(p, w) = \max_{x \geq 0} p F(x) - \langle w, x \rangle$ la función de beneficio de una firma competitiva con un producto, y supongamos que en (p, w) la solución $x(p, w)$ es única, interior y diferenciable, con F de clase C^1 . Entonces π es diferenciable en (p, w) y

$$\frac{\partial \pi}{\partial p}(p, w) = F(x(p, w)) = y(p, w) \quad (\text{la oferta}),$$

$$\frac{\partial \pi}{\partial w_i}(p, w) = -x_i(p, w) \quad (\text{menos la demanda del insumo } i).$$

En la formulación con conjunto de producción, $\pi(p) = \sup_{y \in Y} \langle p, y \rangle$ y, si el plan óptimo $y(p)$ es único, $\nabla \pi(p) = y(p)$, la oferta neta.

Demostración. Es el Teorema 11.5 con objetivo $f(x; p, w) = p F(x) - \langle w, x \rangle$, problema sin restricciones (solución interior) y parámetros $\theta = (p, w)$, aplicado coordenada a coordenada. Para p : congelando x en su valor óptimo,

$$\frac{\partial \pi}{\partial p} = \frac{\partial f}{\partial p} \Big|_{x=x(p, w)} = F(x(p, w)) = y(p, w).$$

Para w_i : análogamente,

$$\frac{\partial \pi}{\partial w_i} = \frac{\partial f}{\partial w_i} \Big|_{x=x(p, w)} = -x_i(p, w).$$

En la versión con conjunto de producción, $f(y; p) = \langle p, y \rangle$ es lineal en p con $\partial f / \partial p_k = y_k$, y la misma envolvente da $\partial \pi / \partial p_k = y_k(p)$. $\square$

Interpretación. Si el precio del producto sube en dp , cada una de las y unidades que la firma ya vendía vale dp más; el reajuste de producción es de segundo orden. Por eso el beneficio marginal de p es exactamente la cantidad ofrecida. Simétricamente, si w_i sube, la firma paga dw_i más por cada una de las x_i unidades del insumo que ya usaba: de ahí el signo negativo. En la práctica empírica esto es oro: si conoces (o estimas) la función de beneficio, *derivándola* recuperas todo el comportamiento de la firma.

Ejemplo 11.13 (Hotelling en Cobb–Douglas, todos los cálculos). Con $F(x_1, x_2) = x_1^{1/2} x_2^{1/2}$ la función de beneficio no está bien definida (retornos constantes: beneficio 0 o $+\infty$), así que usamos su prima con retornos decrecientes $F(x) = x^{1/2}$, un solo insumo, como en el Ejemplo 11.7 pero sin el factor 2: $\pi(p, w) = \max_{x>0} p x^{1/2} - wx$. CPO: $\frac{p}{2} x^{-1/2} = w$, luego $x(p, w) = \frac{p^2}{4w^2}$ y $y(p, w) = x^{1/2} = \frac{p}{2w}$. La función de valor:

$$\pi(p, w) = p \cdot \frac{p}{2w} - w \cdot \frac{p^2}{4w^2} = \frac{p^2}{2w} - \frac{p^2}{4w} = \frac{p^2}{4w}.$$

Verificación de Hotelling:

$$\frac{\partial \pi}{\partial p} = \frac{2p}{4w} = \frac{p}{2w} = y(p, w) \checkmark, \quad \frac{\partial \pi}{\partial w} = -\frac{p^2}{4w^2} = -x(p, w) \checkmark.$$

Nota adicional: $\pi(p, w) = p^2/(4w)$ es convexa en p ($\partial^2 \pi / \partial p^2 = \frac{1}{2w} > 0$) y homogénea de grado 1 en (p, w) ; ambas propiedades son generales (Sección 11.5).

11.4.2. Joya 2: el lema de Shephard

Teorema 11.14 (Lema de Shephard (*Shephard's lemma*)). Sea $e(p, u) = \min_{x \geq 0} \langle p, x \rangle$ s.a. $u(x) \geq u$, con $u(\cdot)$ continua y localmente no saciada, y supongamos que en (p, u) la demanda hicksiana $h(p, u)$ es única y las hipótesis del Teorema 11.8 se cumplen. Entonces

$$\frac{\partial e}{\partial p_i}(p, u) = h_i(p, u) \quad \text{para } i = 1, \dots, n.$$

Derivar la función de gasto respecto de un precio da la demanda hicksiana de ese bien.

Demostración. Es un problema de *minimización*, así que aplicamos la versión “min” del Teorema 11.8 (Observación 11.3). El lagrangiano de minimización es

$$L(x, \mu; p, u) = \langle p, x \rangle - \mu(u(x) - u), \quad \mu \geq 0.$$

El parámetro p_i aparece *solo* en el objetivo $\langle p, x \rangle = \sum_k p_k x_k$, no en la restricción $u(x) \geq u$. Por la envolvente,

$$\frac{\partial e}{\partial p_i} = \frac{\partial L}{\partial p_i} \Big|_{x=h(p,u), \mu=\mu^*} = x_i \Big|_{x=h(p,u)} = h_i(p, u).$$

No hay término de multiplicador porque $\partial/\partial p_i$ de la restricción es cero. (De paso, derivando respecto del parámetro u : $\partial e/\partial u = \mu^* > 0$, el precio sombra de exigir más utilidad.) $\square$

Interpretación. Si p_i sube en dp_i , mantener el mismo nivel de vida cuesta $h_i dp_i$ más: al primer orden, el consumidor compensado no sustituye (el reajuste hacia otros bienes es de segundo orden), simplemente paga más caro lo que ya compraba. Este lema es la base de los *índices de costo de vida* y de la medición de cambios de bienestar (variación compensatoria y equivalente, teoría del consumidor, MWG cap. 3).

Ejemplo 11.15 (Shephard en Cobb–Douglas, todos los cálculos). Con $u(x_1, x_2) = x_1^{1/2} x_2^{1/2}$, calculemos primero e y h desde cero. Minimizar $p_1 x_1 + p_2 x_2$ s.a. $x_1^{1/2} x_2^{1/2} = u$ (la restricción se

satura por monotonicidad). CPO del lagrangiano $L = p_1x_1 + p_2x_2 - \mu(x_1^{1/2}x_2^{1/2} - u)$:

$$p_1 = \frac{\mu}{2}x_1^{-1/2}x_2^{1/2}, \quad p_2 = \frac{\mu}{2}x_1^{1/2}x_2^{-1/2}.$$

Dividiendo: $\frac{p_1}{p_2} = \frac{x_2}{x_1}$, es decir $x_2 = \frac{p_1}{p_2}x_1$. Sustituyendo en la restricción: $x_1^{1/2}(\frac{p_1}{p_2}x_1)^{1/2} = x_1(\frac{p_1}{p_2})^{1/2} = u$, de donde

$$h_1(p, u) = u \left(\frac{p_2}{p_1} \right)^{1/2}, \quad h_2(p, u) = u \left(\frac{p_1}{p_2} \right)^{1/2}.$$

La función de gasto:

$$e(p, u) = p_1h_1 + p_2h_2 = u p_1^{1/2} p_2^{1/2} + u p_1^{1/2} p_2^{1/2} = 2u \sqrt{p_1 p_2}.$$

Verificación de Shephard:

$$\frac{\partial e}{\partial p_1} = 2u \cdot \frac{1}{2} p_1^{-1/2} p_2^{1/2} = u \left(\frac{p_2}{p_1} \right)^{1/2} = h_1(p, u) \checkmark,$$

y simétricamente $\partial e / \partial p_2 = u(p_1/p_2)^{1/2} = h_2$. Nota que e es cóncava en p : por ejemplo con p_2 fijo, $\partial^2 e / \partial p_1^2 = -\frac{u}{2} p_1^{-3/2} p_2^{1/2} < 0$; la concavidad completa se demuestra en general en la Sección 11.5.

11.4.3. Joya 3: la identidad de Roy

Para la utilidad indirecta el parámetro p_i entra *en la restricción*, no en el objetivo, así que aquí la versión lagrangiana muestra toda su potencia.

Teorema 11.16 (Identidad de Roy (*Roy's identity*)). Sea $v(p, m) = \max_{x \geq 0} u(x)$ s.a. $\langle p, x \rangle \leq m$, con u de clase C^1 , localmente no saciada, solución marshalliana $x(p, m)$ única e interior, y las hipótesis del Teorema 11.8. Si $\partial v / \partial m > 0$, entonces

$$x_i(p, m) = - \frac{\partial v / \partial p_i}{\partial v / \partial m} \quad \text{para } i = 1, \dots, n.$$

Demostración. Lagrangiano: $L(x, \lambda; p, m) = u(x) - \lambda(\langle p, x \rangle - m)$. Aplicamos la envolvente dos veces, con el mismo punto óptimo $(x(p, m), \lambda^*(p, m))$.

(1) *Respecto de p_i .* El parámetro p_i aparece solo en la restricción, a través de $\langle p, x \rangle = \sum_k p_k x_k$:

$$\frac{\partial v}{\partial p_i} = \frac{\partial L}{\partial p_i} \Big|_{\text{ópt}} = -\lambda^* x_i(p, m). \quad (\text{R1})$$

(2) *Respecto de m .* También aparece solo en la restricción:

$$\frac{\partial v}{\partial m} = \frac{\partial L}{\partial m} \Big|_{\text{ópt}} = \lambda^*. \quad (\text{R2})$$

(R2) es el Corolario 11.10: el multiplicador es la utilidad marginal del ingreso. Como $\partial v / \partial m =$

$\lambda^* > 0$ por hipótesis, podemos dividir (R1) entre (R2):

$$\frac{\partial v / \partial p_i}{\partial v / \partial m} = \frac{-\lambda^* x_i}{\lambda^*} = -x_i(p, m),$$

que reordenada es la identidad de Roy. $\square$

Interpretación. (R1) dice: si p_i sube en dp_i , el consumidor pierde poder de compra por $x_i dp_i$ soles (paga más por lo que ya compraba), y cada sol perdido vale λ^* utiles; el daño en utilidad es $\lambda^* x_i dp_i$. La división entre λ^* convierte esa pérdida de “utiles” a soles, dejando la cantidad x_i . Roy es el puente que permite pasar de un objeto no observable (v , medida en utilidad) a uno observable (la demanda): por eso es la herramienta estándar para *recuperar demandas a partir de formas funcionales de utilidad indirecta* en trabajo aplicado.

Ejemplo 11.17 (Roy en Cobb–Douglas, todos los cálculos). Con $u = x_1^{1/2} x_2^{1/2}$, la demanda marshalliana es la conocida $x_i(p, m) = \frac{m}{2p_i}$ (cada bien se lleva la mitad del gasto; se obtiene de las CPO $\frac{\partial u / \partial x_1}{\partial u / \partial x_2} = \frac{x_2}{x_1} = \frac{p_1}{p_2}$ más la restricción). La utilidad indirecta:

$$v(p, m) = \left(\frac{m}{2p_1} \right)^{1/2} \left(\frac{m}{2p_2} \right)^{1/2} = \frac{m}{2\sqrt{p_1 p_2}}.$$

Calculamos las tres derivadas necesarias:

$$\frac{\partial v}{\partial p_1} = \frac{m}{2} \cdot \frac{\partial}{\partial p_1} (p_1^{-1/2} p_2^{-1/2}) = -\frac{m}{4} p_1^{-3/2} p_2^{-1/2}, \quad \frac{\partial v}{\partial m} = \frac{1}{2\sqrt{p_1 p_2}} = \frac{1}{2} p_1^{-1/2} p_2^{-1/2}.$$

Aplicando Roy:

$$-\frac{\partial v / \partial p_1}{\partial v / \partial m} = \frac{\frac{m}{4} p_1^{-3/2} p_2^{-1/2}}{\frac{1}{2} p_1^{-1/2} p_2^{-1/2}} = \frac{m}{4} \cdot \frac{2}{1} \cdot p_1^{-3/2+1/2} = \frac{m}{2p_1} = x_1(p, m) \checkmark.$$

Por simetría, $-(\partial v / \partial p_2) / (\partial v / \partial m) = m / (2p_2) = x_2$. También puedes verificar (R2): λ^* del problema del consumidor Cobb–Douglas resulta $\lambda^* = \frac{1}{2\sqrt{p_1 p_2}} = \partial v / \partial m$.

11.4.4. Joya 4: la derivada de la función de costo

Teorema 11.18 (Shephard para costos). Sea $c(w, y) = \min_{x \geq 0} \langle w, x \rangle$ s.a. $F(x) \geq y$, bajo las hipótesis análogas a las del Teorema 11.14. Entonces

$$\frac{\partial c}{\partial w_i}(w, y) = x_i(w, y),$$

la demanda condicionada del insumo i . Además $\partial c / \partial y = \mu^*$, el multiplicador de la restricción tecnológica, que es el costo marginal.

Demostración. Idéntica a la del lema de Shephard, cambiando nombres: lagrangiano de minimización $L = \langle w, x \rangle - \mu (F(x) - y)$; el parámetro w_i solo toca el objetivo, con $\partial L / \partial w_i = x_i$, y la envolvente evalúa en el óptimo: $\partial c / \partial w_i = x_i(w, y)$. Para y : aparece solo en la restricción, con $\partial L / \partial y = +\mu$, luego $\partial c / \partial y = \mu^* \geq 0$: el precio sombra de exigir una unidad más de producto es, por definición económica, el costo marginal. $\square$

Ejemplo 11.19 (Costos en Cobb–Douglas, todos los cálculos). Con $F(x_1, x_2) = x_1^{1/2} x_2^{1/2}$: minimizar $w_1 x_1 + w_2 x_2$ s.a. $x_1^{1/2} x_2^{1/2} = y$. Es el mismo problema del Ejemplo 11.15 con (p, u) renombrados como (w, y) , así que

$$x_1(w, y) = y \left(\frac{w_2}{w_1} \right)^{1/2}, \quad x_2(w, y) = y \left(\frac{w_1}{w_2} \right)^{1/2}, \quad c(w, y) = 2y\sqrt{w_1 w_2}.$$

Verificación: $\frac{\partial c}{\partial w_1} = y \left(\frac{w_2}{w_1} \right)^{1/2} = x_1(w, y) \checkmark$. Y $\partial c / \partial y = 2\sqrt{w_1 w_2}$ es el costo marginal (constante en y : retornos constantes a escala). La demanda condicionada de insumos es decreciente en su propio precio ($\partial x_1 / \partial w_1 = -\frac{y}{2} w_1^{-3/2} w_2^{1/2} < 0$), que es la versión “producción” de la ley de demanda compensada; en la siguiente sección veremos que esto no es una casualidad del ejemplo sino una consecuencia de la concavidad de c en w .

Estrategia de examen

Receta de examen para “derive la demanda/oferta a partir de la función de valor” (cae siempre, en este curso y en Microeconomía):

1. Identifica de qué problema es función de valor el objeto dado (π : max beneficio; e : min gasto; c : min costo; v : max utilidad).
2. Escribe el lagrangiano *con tu convención de signos fija* y localiza dónde aparece el parámetro de interés: ¿objetivo, restricción o ambos?
3. Aplica la regla de la Observación 11.9: deriva L parcialmente respecto del parámetro, congela (x, λ) en el óptimo. Si el parámetro está solo en el objetivo: derivada directa (Hotelling, Shephard). Si está solo en la restricción: aparece el multiplicador (Roy, precio sombra).
4. Si el resultado trae un λ^* indeseado, busca una segunda ecuación de envolvente que también lo traiga y divide para eliminarlo (así se cierra Roy).
5. Verifica signos con economía: $\partial \pi / \partial p > 0$, $\partial e / \partial p_i \geq 0$, $\partial v / \partial p_i \leq 0$, $\partial v / \partial m > 0$. Si un signo no cuadra, revisa la convención del lagrangiano.
6. Chequeos gratis: homogeneidad (grado 1 de e, c, π en precios; grado 0 de las demandas) y curvatura (Sección 11.5). En un examen, verificar tu respuesta con Cobb–Douglas toma dos minutos y detecta casi todos los errores.

11.5. Curvatura de las funciones de valor: sensibilidad de segundo orden [P1]

El teorema de la envolvente es un resultado de *primer orden*: da las derivadas de V . El análisis de sensibilidad de *segundo orden* pregunta por la curvatura de V , y la respuesta viene gratis de la estructura “envolvente de funciones afines”: recuerda del capítulo de funciones convexas que *el supremo puntual de funciones convexas (en particular, afines) es convexo, y el ínfimo puntual de funciones cóncavas (en particular, afines) es cóncavo*. Combinada con las joyas de la sección

anterior, la curvatura produce las leyes de comportamiento comparativo de la micro: ley de la oferta, ley de la demanda compensada y matriz de Slutsky.

Teorema 11.20 (Convexidad de la función de beneficio). *Para cualquier conjunto de producción $Y \subseteq \mathbb{R}^n$ (sin supuesto alguno de convexidad sobre Y), la función $\pi(p) = \sup_{y \in Y} \langle p, y \rangle$ es convexa y homogénea de grado 1 en p .*

Demostración. Sean p, p' con π finita, $t \in [0, 1]$ y $p_t = tp + (1 - t)p'$. Para cualquier $y \in Y$,

$$\langle p_t, y \rangle = t \langle p, y \rangle + (1 - t) \langle p', y \rangle \leq t \pi(p) + (1 - t) \pi(p'),$$

donde la desigualdad usa la definición de supremo dos veces: $\langle p, y \rangle \leq \pi(p)$ y $\langle p', y \rangle \leq \pi(p')$. Tomando supremo sobre $y \in Y$ en el lado izquierdo, $\pi(p_t) \leq t \pi(p) + (1 - t) \pi(p')$: convexidad. La homogeneidad es inmediata: $\pi(\alpha p) = \sup_y \langle \alpha p, y \rangle = \alpha \sup_y \langle p, y \rangle = \alpha \pi(p)$ para $\alpha > 0$. (Como anticipamos, π es la función soporte de Y , y las funciones soporte son siempre convexas y homogéneas de grado 1: es la “demostración de dos líneas vía supremo de lineales”). $\square$

Corolario 11.21 (Ley de la oferta). *Si π es dos veces diferenciable en p , entonces la matriz de sustitución de la firma*

$$D_p y(p) = \nabla^2 \pi(p)$$

es simétrica y semidefinida positiva. En particular, $\frac{\partial y_k}{\partial p_k} = \frac{\partial^2 \pi}{\partial p_k^2} \geq 0$ para cada k : las curvas de oferta tienen pendiente no negativa y las demandas (no condicionadas) de insumos pendiente no positiva, sin ningún supuesto sobre preferencias ni efectos ingreso.

Demostración. Por el lema de Hotelling (Teorema 11.12), $y(p) = \nabla \pi(p)$; derivando otra vez, $D_p y(p) = \nabla^2 \pi(p)$. Esta matriz es simétrica por el teorema de Schwarz (igualdad de derivadas cruzadas de una función C^2) y semidefinida positiva porque π es convexa (caracterización de segundo orden de la convexidad, capítulo de funciones convexas). Los elementos diagonales de una matriz semidefinida positiva son no negativos (toma $z = e_k$ en $\langle z, \nabla^2 \pi z \rangle \geq 0$). Para un insumo, $y_k = -x_k < 0$ es la oferta neta, así que $\partial(-x_k)/\partial p_k \geq 0$ significa que la demanda del insumo cae con su propio precio. $\square$

Teorema 11.22 (Concavidad de la función de gasto). *Para cualquier función de utilidad u (basta que el conjunto de contorno superior $\{x \geq 0 : u(x) \geq u\}$ sea no vacío), la función $e(p, u) = \inf\{\langle p, x \rangle : u(x) \geq u, x \geq 0\}$ es cóncava y homogénea de grado 1 en p . Lo mismo vale, con idéntica prueba, para la función de costo $c(w, y)$ en w .*

Demostración. Es el argumento espejo: ínfimo de funciones lineales de p . Sean $p, p' \gg 0$, $t \in [0, 1]$, $p_t = tp + (1 - t)p'$, y sea x_t (cualquier) solución del problema de gasto a precios p_t (si el ínfimo no se alcanza, toma x_t casi óptimo y pasa al límite). Entonces x_t es *factible* para los problemas a precios p y p' (la restricción $u(x) \geq u$ no involucra precios), luego por definición de ínfimo

$$\langle p, x_t \rangle \geq e(p, u) \quad \text{y} \quad \langle p', x_t \rangle \geq e(p', u).$$

Multiplicando por $t \geq 0$ y $(1 - t) \geq 0$ y sumando:

$$e(p_t, u) = \langle p_t, x_t \rangle = t \langle p, x_t \rangle + (1 - t) \langle p', x_t \rangle \geq t e(p, u) + (1 - t) e(p', u) :$$

concavidad. Homogeneidad: $e(\alpha p, u) = \inf \langle \alpha p, x \rangle = \alpha \inf \langle p, x \rangle = \alpha e(p, u)$ para $\alpha > 0$. $\square$

Intuición

La concavidad de e tiene una lectura económica preciosa. Imagina que p_1 sube y el consumidor *no pudiera sustituir*: su gasto para mantener u crecería *linealmente* en p_1 (pagaría la canasta vieja a precios nuevos: la recta $\langle p, h(p^0, u) \rangle$). Como *sí puede* sustituir, su gasto real queda *debajo* de esa recta: $e(\cdot, u)$ está siempre por debajo de sus rectas tangentes, que es exactamente concavidad. La curvatura de e mide cuánta capacidad de sustitución tiene el consumidor. El mismo razonamiento con signos invertidos explica la convexidad de π : la firma que puede reajustar su plan siempre queda *encima* de la recta “plan congelado”, y la curvatura de π mide su flexibilidad tecnológica.

Teorema 11.23 (Matriz de Slutsky: simetría y semidefinición negativa). *Si $e(\cdot, u)$ es dos veces diferenciable, la matriz de sustitución de Slutsky*

$$S(p, u) := D_p h(p, u) = \nabla_{pp}^2 e(p, u)$$

es simétrica y semidefinida negativa. En particular $\partial h_i / \partial p_i \leq 0$ (ley de la demanda compensada) y $\partial h_i / \partial p_j = \partial h_j / \partial p_i$ (simetría de los efectos cruzados compensados).

Esquema de la demostración. Por el lema de Shephard, $h(p, u) = \nabla_p e(p, u)$; derivando, $D_p h = \nabla_{pp}^2 e$. Simetría: Schwarz. Semidefinición negativa: caracterización de segundo orden de la concavidad de e en p (Teorema 11.22). Los detalles de regularidad (cuándo e es dos veces diferenciable) están en [9], cap. 3 y apéndice M. Es exactamente el mismo argumento del Corolario 11.21 con los signos volteados: *Shephard + concavidad = Slutsky NSD*, así como *Hotelling + convexidad = ley de la oferta*. $\square$

Proposición 11.24 (Ecuación de Slutsky). *Bajo las hipótesis anteriores, si además la dualidad del consumidor da $h_i(p, u) = x_i(p, e(p, u))$ para todo p (identidad hicksiana-marshalliana), entonces*

$$\underbrace{\frac{\partial x_i}{\partial p_j}}_{\text{efecto total}} = \underbrace{\frac{\partial h_i}{\partial p_j}}_{\text{efecto sustitución}} - \underbrace{x_j \frac{\partial x_i}{\partial m}}_{\text{efecto ingreso}} .$$

Demostración. Derivamos la identidad $h_i(p, u) = x_i(p, e(p, u))$ respecto de p_j con la regla de la cadena (el segundo argumento de x_i depende de p_j a través de e):

$$\frac{\partial h_i}{\partial p_j} = \frac{\partial x_i}{\partial p_j} + \frac{\partial x_i}{\partial m} \cdot \frac{\partial e}{\partial p_j} .$$

Por el lema de Shephard, $\partial e / \partial p_j = h_j(p, u)$, y evaluando en $u = v(p, m)$ (de modo que $e(p, u) =$

m y $h_j = x_j(p, m)$ por dualidad):

$$\frac{\partial h_i}{\partial p_j} = \frac{\partial x_i}{\partial p_j} + x_j \frac{\partial x_i}{\partial m}.$$

Despejando $\partial x_i / \partial p_j$ se obtiene la ecuación de Slutsky. Observa el papel de la envolvente: es Shephard quien convierte el término abstracto $\partial e / \partial p_j$ en el objeto observable x_j . $\square$

Teorema 11.25 (Cuasiconvexidad de la utilidad indirecta). *La utilidad indirecta $v(p, m) = \max\{u(x) : \langle p, x \rangle \leq m, x \geq 0\}$ es cuasiconvexa en (p, m) : para todo $\bar{v} \in \mathbb{R}$, el conjunto de contorno inferior $N(\bar{v}) = \{(p, m) : v(p, m) \leq \bar{v}\}$ es convexo.*

Demostración. Sean (p, m) y (p', m') en $N(\bar{v})$, $t \in [0, 1]$, y $(p'', m'') = t(p, m) + (1 - t)(p', m')$. Debemos probar $v(p'', m'') \leq \bar{v}$. Tomemos cualquier $x \geq 0$ factible en el problema con datos (p'', m'') , es decir $\langle p'', x \rangle \leq m''$. Afirmamos que x es factible en (p, m) o en (p', m') . Si no lo fuera en ninguno, tendríamos $\langle p, x \rangle > m$ y $\langle p', x \rangle > m'$; multiplicando la primera por t , la segunda por $(1 - t)$ y sumando:

$$\langle p'', x \rangle = t \langle p, x \rangle + (1 - t) \langle p', x \rangle > tm + (1 - t)m' = m'',$$

contradiciendo la factibilidad en (p'', m'') . Luego x es factible en al menos uno de los dos presupuestos originales, y por lo tanto $u(x) \leq \max\{v(p, m), v(p', m')\} \leq \bar{v}$. Tomando supremo sobre los x factibles en (p'', m'') : $v(p'', m'') \leq \bar{v}$. Así $N(\bar{v})$ es convexo y v es cuasiconvexa. (Geométricamente: el presupuesto “promedio” no contiene ninguna canasta que no estuviera ya en alguno de los presupuestos extremos; promediar precios e ingresos nunca puede ser estrictamente mejor que la mejor de las dos situaciones originales.) $\square$

Observación 11.26. Tabla mental para Microeconomía: $\pi(p)$ convexa y homogénea de grado 1 (sup de lineales); $e(p, u)$ y $c(w, y)$ cóncavas y homogéneas de grado 1 en precios (inf de lineales); $v(p, m)$ cuasiconvexa, homogénea de grado 0, decreciente en p , creciente en m . Estas propiedades, junto con las derivadas de las cuatro joyas, son *todas* las restricciones comprobables que la teoría impone a funciones estimadas empíricamente: son la base de los tests de “integrabilidad” (¿esta demanda estimada pudo venir de un consumidor racional?) [9, 10].

11.6. El teorema de la envolvente de Milgrom–Segal y sus aplicaciones a mecanismos [P1]

11.6.1. Motivación: cuando no se puede derivar en x

Todos los teoremas anteriores suponen estructura diferenciable en la variable de decisión: x vive en $\mathbb{R}^n$, f es C^1 en x , hay condiciones de primer orden. En diseño de mecanismos (MWG cap. 23) esto se derrumba: la “decisión” de un agente puede ser un *reporte* en un conjunto abstracto de mensajes, una *puja* en un conjunto de estrategias, o una elección en un menú discreto de contratos. No hay $\nabla_x f$, no hay CPO, y la solución $x(\theta)$ puede saltar discontinuamente con el tipo. Milgrom y Segal [11] demostraron que nada de eso importa: lo único que la envolvente

necesita es diferenciabilidad en el parámetro θ , que en mecanismos es el *tipo* del agente, sobre el cual sí es natural suponer suavidad.

Teorema 11.27 (Milgrom–Segal, versión integral). *Sea X un conjunto arbitrario (sin topología, sin estructura lineal) y $f : X \times [0, 1] \rightarrow \mathbb{R}$. Definamos $V(\theta) = \sup_{x \in X} f(x, \theta)$ y supongamos:*

(MS1) *para cada $x \in X$, la función $\theta \mapsto f(x, \theta)$ es diferenciable, y existe una función integrable $b : [0, 1] \rightarrow \mathbb{R}_+$ tal que $|\partial f(x, \theta)/\partial \theta| \leq b(\theta)$ para todo x y casi todo θ ;*

(MS2) *el supremo se alcanza: existe una selección $x(\theta) \in X^*(\theta)$ para cada θ .*

Entonces V es absolutamente continua (en particular, diferenciable en casi todo punto) y admite la representación integral

$$V(\theta) = V(0) + \int_0^\theta \frac{\partial f}{\partial \theta}(x(s), s) ds \quad \text{para todo } \theta \in [0, 1],$$

válida para cualquier selección medible $x(\cdot)$ del argmax. Además, en todo θ donde V es diferenciable y $x(\theta) \in X^(\theta)$, $V'(\theta) = \partial f(x(\theta), \theta)/\partial \theta$.*

Idea de la demostración (honestamente, siguiendo [11]). Paso 1: V es absolutamente continua. Para $\theta' > \theta$ y cualquier $\varepsilon > 0$, tomemos x ε -óptimo en θ' . Entonces

$$V(\theta') - V(\theta) \leq f(x, \theta') + \varepsilon - f(x, \theta) = \varepsilon + \int_\theta^{\theta'} \frac{\partial f}{\partial \theta}(x, s) ds \leq \varepsilon + \int_\theta^{\theta'} b(s) ds,$$

usando el teorema fundamental del cálculo en la variable θ (lícito porque $f(x, \cdot)$ es diferenciable con derivada dominada por b). Con el argumento simétrico, $|V(\theta') - V(\theta)| \leq \int_\theta^{\theta'} b(s) ds$. Como b es integrable, esto da la continuidad absoluta de V , y por el teorema fundamental del cálculo (versión Lebesgue), $V(\theta) = V(0) + \int_0^\theta V'(s) ds$ con V' definida en casi todo punto.

Paso 2: identificar V' en los puntos buenos. Sea s un punto donde V es diferenciable y tomemos $x(s) \in X^*(s)$. Este es exactamente el argumento de la Proposición 11.6, que no usó ninguna estructura sobre X : la función $\varphi(\theta) = V(\theta) - f(x(s), \theta)$ es no negativa, se anula en $\theta = s$ y es diferenciable ahí, luego $\varphi'(s) = 0$, es decir $V'(s) = \partial f(x(s), s)/\partial \theta$. Como esto vale en casi todo s , podemos sustituir $V'(s)$ dentro de la integral del Paso 1, y la fórmula queda demostrada. $\square$

Observación 11.28. Fíjate con cuidado en qué *no* se pidió: nada sobre la continuidad o diferenciabilidad de la selección $x(\cdot)$, nada sobre convexidad o siquiera estructura de X , nada de condiciones de primer orden en x . La selección óptima puede saltar de un punto de X a otro completamente distinto cuando θ cruza un umbral; en esos umbrales V simplemente tiene un punto no diferenciable (de medida cero), y la representación *integral* ni se entera: una integral no ve conjuntos de medida cero. Esta es la diferencia clave con el Teorema 11.5, cuya conclusión era puntual (“ $V'(\theta_0) = \dots$ ”) y por eso necesitaba hipótesis puntuales fuertes. Milgrom–Segal cambia una conclusión puntual por una integral y a cambio tira casi todas las hipótesis: un intercambio perfecto para la teoría de mecanismos.

11.6.2. Aplicación: subastas y equivalencia de ingresos

Consideremos una subasta (o, más en general, un mecanismo) con n postores. El postor que nos interesa tiene un *tipo privado* $\theta \in [0, 1]$ (su valoración del objeto), distribuido con cdf F continua. En el mecanismo, tras fijar las estrategias de equilibrio de los rivales, al elegir una acción o reporte $x \in X$ (su puja, su mensaje) el postor obtiene una probabilidad de ganar $q(x) \in [0, 1]$ y hace un pago esperado $t(x) \in \mathbb{R}$. Su utilidad esperada, si su tipo es θ , es *cuasilineal*:

$$f(x, \theta) = \theta q(x) - t(x).$$

Su utilidad de equilibrio (*equilibrium payoff*) es la función de valor

$$U(\theta) = \sup_{x \in X} [\theta q(x) - t(x)],$$

porque en equilibrio cada tipo elige óptimamente su acción dada la conducta de los demás (esta es exactamente la restricción de compatibilidad de incentivos IC del curso de micro).

Proposición 11.29 (Fórmula de la utilidad de equilibrio). *En el marco anterior, sea $x(\theta)$ una selección de acciones de equilibrio y denotemos $Q(\theta) := q(x(\theta))$ la probabilidad de ganar del tipo θ en equilibrio. Entonces U es convexa, absolutamente continua, y*

$$U(\theta) = U(0) + \int_0^\theta Q(s) ds.$$

En consecuencia, el pago esperado del tipo θ queda completamente determinado por la regla de asignación y por $U(0)$:

$$T(\theta) := t(x(\theta)) = \theta Q(\theta) - U(0) - \int_0^\theta Q(s) ds.$$

Demostración. Verificamos las hipótesis de Milgrom–Segal. Para cada x fijo, $f(x, \theta) = \theta q(x) - t(x)$ es *afín* en θ , luego diferenciable con $\partial f / \partial \theta = q(x) \in [0, 1]$: la cota (MS1) vale con $b \equiv 1$. Suponiendo que el óptimo se alcanza (MS2, cierto en equilibrio), el Teorema 11.27 da

$$U(\theta) = U(0) + \int_0^\theta \frac{\partial f}{\partial \theta}(x(s), s) ds = U(0) + \int_0^\theta q(x(s)) ds = U(0) + \int_0^\theta Q(s) ds.$$

(De paso, U es supremo de funciones afines de θ , luego convexa; y su derivada casi en todo punto es $Q(\theta)$, que por convexidad debe ser no decreciente: la *monotonidad de la asignación* es una condición necesaria de IC, otro resultado famoso que sale gratis.) La fórmula de pagos se obtiene despejando: como $U(\theta) = \theta Q(\theta) - T(\theta)$ en equilibrio, entonces $T(\theta) = \theta Q(\theta) - U(\theta) = \theta Q(\theta) - U(0) - \int_0^\theta Q(s) ds$. $\square$

Teorema 11.30 (Equivalencia de ingresos (*revenue equivalence*), Myerson). *Consideremos dos mecanismos de subasta cualesquiera con postores de tipos privados independientes, tales que en sus respectivos equilibrios: (i) la regla de asignación es la misma (por ejemplo, ambos asignan el objeto al postor de mayor tipo), y (ii) el tipo más bajo obtiene la misma utilidad (por ejemplo, $U(0) = 0$ en ambos). Entonces el pago esperado de cada tipo de cada postor es el mismo en*

ambos mecanismos y, por lo tanto, el ingreso esperado del subastador es idéntico.

Derivación esquemática (pero honesta). Por la Proposición 11.29, en cualquier mecanismo el pago esperado del tipo θ es $T(\theta) = \theta Q(\theta) - U(0) - \int_0^\theta Q(s)ds$, una expresión que solo involucra la función de asignación en equilibrio $Q(\cdot)$ y la constante $U(0)$. Si dos mecanismos comparten (i) la misma Q (en el caso simétrico con asignación eficiente, $Q(\theta) = F(\theta)^{n-1}$, la probabilidad de que los otros $n - 1$ tipos sean menores) y (ii) el mismo $U(0)$, entonces comparten $T(\theta)$ para todo θ . El ingreso esperado del subastador es la suma sobre postores de $\mathbb{E}_\theta[T(\theta)]$, luego coincide. Esto explica el resultado, a primera vista asombroso, de que la subasta de primer precio, la de segundo precio, la inglesa y la holandesa (con postores simétricos, neutrales al riesgo y tipos independientes) recaudan *exactamente lo mismo* en promedio: sus reglas de pago lucen distintas, pero la envoltente muestra que los pagos esperados están atados por la asignación. Los detalles finos (existencia de equilibrio, medibilidad de la selección) están en [11] y en el material de diseño de mecanismos (MWG cap. 23). $\square$

Intuición

¿Por qué la utilidad marginal del tipo es *la probabilidad de ganar* y nada más? Es la lógica de la envoltente en su forma más pura. Un postor de tipo $\theta + d\theta$ podría imitar perfectamente al de tipo θ (pujar igual): ganaría con la misma probabilidad $Q(\theta)$ y pagaría lo mismo. La única diferencia es que, cuando gana, el objeto vale $d\theta$ más para él: ganancia $Q(\theta) d\theta$. ¿Y el hecho de que en realidad pujará distinto (reoptimizará)? Efecto de segundo orden, porque parte de una estrategia óptima. Por eso $U'(\theta) = Q(\theta)$: *la pendiente de la renta del agente es lo que “transporta” su información privada*, y el principal no puede gravarla sin romper los incentivos. Exactamente el mismo argumento en screening (Mussa–Rosen, Baron–Myerson, MWG cap. 14): la utilidad del agente con tipo θ en cualquier contrato IC satisface $U(\theta) = U(\underline{\theta}) + \int_{\underline{\theta}}^\theta \frac{\partial u}{\partial \theta}(q(s), s)ds$; esa integral es la *renta informacional* (*information rent*) que el principal debe ceder a los tipos altos para que no se hagan pasar por bajos, y aparece restada en la función objetivo del principal, dando lugar a la “utilidad virtual” de Myerson.

11.7. Sensibilidad general: Berge, Danskin y soluciones múltiples [P2]

Cerramos con el panorama general: ¿qué se puede decir de V sin suponer unicidad ni selecciones diferenciables? La respuesta viene en tres niveles: continuidad (siempre, bajo compacidad), diferenciabilidad (bajo unicidad) y subdiferenciabilidad (en general).

Teorema 11.31 (Teorema del máximo de Berge (*Berge’s maximum theorem*)). Sea $f : \mathbb{R}^n \times \Theta \rightarrow \mathbb{R}$ continua y sea $\Gamma : \Theta \rightrightarrows \mathbb{R}^n$ una correspondencia continua (hemicontinua superior e inferiormente) con valores no vacíos y compactos. Entonces:

- (I) la función de valor $V(\theta) = \max_{x \in \Gamma(\theta)} f(x, \theta)$ es continua en Θ ;
- (II) la correspondencia de soluciones $X^*(\theta)$ tiene valores no vacíos y compactos y es hemicontinua superiormente; en particular, si $X^*(\theta)$ es un único punto $x(\theta)$ para cada θ , entonces

$x(\cdot)$ es una función continua.

No demostramos Berge aquí (es un ejercicio de análisis con sucesiones y compacidad; puedes ver [1] y el apéndice M de [9]); lo importante es saber *para qué se usa*: garantiza que $v(p, m)$, $e(p, u)$, $c(w, y)$ son continuas y que las demandas se mueven “sin explotar” cuando los precios se mueven, que las funciones de valor de programación dinámica son continuas, y que los pasos al límite en teoremas de existencia de equilibrio son legítimos. Berge es el seguro de continuidad que está detrás de casi toda la estática comparativa.

Teorema 11.32 (Danskin). *Sea $K \subseteq \mathbb{R}^n$ compacto, $f : K \times \Theta \rightarrow \mathbb{R}$ continua, con derivada parcial $\partial f / \partial \theta$ continua en (x, θ) , y $V(\theta) = \max_{x \in K} f(x, \theta)$ con $\Theta \subseteq \mathbb{R}$ abierto. Entonces V tiene derivadas direccionales en todo punto, dadas por*

$$V'(\theta; +1) = \max_{x \in X^*(\theta)} \frac{\partial f}{\partial \theta}(x, \theta), \quad V'(\theta; -1) = - \min_{x \in X^*(\theta)} \frac{\partial f}{\partial \theta}(x, \theta).$$

En particular, si $X^*(\theta) = \{x(\theta)\}$ es un único punto, V es diferenciable en θ con $V'(\theta) = \partial f(x(\theta), \theta) / \partial \theta$ (la fórmula de la envolvente) sin necesidad de suponer que $x(\cdot)$ sea diferenciable ni de usar condiciones de primer orden.

Danskin (ver [1, 6]; en optimización se usa constantemente para funciones max y para métodos minimax [5, 8]) es el punto medio perfecto entre el Teorema 11.5 (hipótesis fuertes, conclusión puntual) y Milgrom–Segal (hipótesis débiles, conclusión integral): con compacidad y continuidad, la unicidad del maximizador basta para derivar V .

11.7.1. Soluciones múltiples: quiebres y subdiferencial

¿Y si $X^*(\theta_0)$ tiene varios elementos? Danskin ya lo dice: las derivadas laterales de V existen pero pueden diferir, y entonces V tiene un *quiebre* (*kink*) en θ_0 . El ejemplo mínimo lo dice todo.

Ejemplo 11.33 (El quiebre más simple del mundo). Sea $X = \{-1, +1\}$ (¡dos puntos!, sin estructura diferenciable en x) y $f(x, \theta) = \theta x$. Entonces

$$V(\theta) = \max\{\theta, -\theta\} = |\theta|.$$

Para $\theta > 0$ el único óptimo es $x = +1$ y $V'(\theta) = +1 = \partial f / \partial \theta$; para $\theta < 0$ el único óptimo es $x = -1$ y $V'(\theta) = -1$. En $\theta_0 = 0$ ambas decisiones son óptimas, las derivadas candidatas son $\{-1, +1\}$, y $V = |\cdot|$ no es diferenciable: derivada lateral derecha $+1$ (el máximo de las candidatas, como dice Danskin), izquierda -1 . Como V es convexa (máximo de lineales), el capítulo de subdiferencial nos da el lenguaje exacto para el punto malo:

$$\partial V(0) = [-1, 1] = \text{conv} \left\{ \frac{\partial f}{\partial \theta}(x, 0) : x \in X^*(0) \right\}.$$

Este es el patrón general para V convexa (por ejemplo $\pi(p)$, o la $U(\theta)$ de las subastas): el subdiferencial de la función de valor es la cápsula convexa de las derivadas parciales sobre el conjunto de óptimos; hay derivada exactamente donde el óptimo es único. Para la firma: $\partial \pi(p) = \text{conv } Y^*(p)$, el conjunto de planes óptimos; si hay varios planes óptimos, la “oferta” es una correspondencia y π tiene una arista. La Figura 11.2 ilustra el quiebre.




Figura 11.2: Con dos decisiones posibles, la función de valor es el máximo de dos rectas. Donde el óptimo cambia de mano ($\theta = 0$, ambas decisiones empatan) la envolvente tiene un quiebre: no hay derivada, pero sí subdiferencial $\partial V(0) = [-1, 1]$, el intervalo generado por las pendientes de las dos rectas.

Resumen del capítulo

Lo esencial del capítulo.

- **Función de valor:** $V(\theta) = \max_{x \in \Gamma(\theta)} f(x, \theta)$. Es la envolvente superior de la familia $\{f(x, \cdot)\}_x$: domina a cada miembro y es tangente al que la toca. Ejemplos: $v(p, m)$, $e(p, u)$, $\pi(p, w)$, $c(w, y)$.
- **Envolvente sin restricciones:** $V'(\theta) = \frac{\partial f}{\partial \theta}(x(\theta), \theta)$. El reajuste de x no cuenta al primer orden porque $\nabla_x f = 0$ en el óptimo.
- **Envolvente con restricciones:** $V'(\theta) = \frac{\partial L}{\partial \theta}$ evaluado en el óptimo: deriva el lagrangiano respecto del parámetro con (x, λ) congelados. Caso clave: si el parámetro es el recurso b de $g(x) \leq b$, entonces $V'(b) = \lambda^*$: *el multiplicador es el precio sombra*.
- **Las cuatro joyas:** Hotelling ($\nabla_p \pi = y$, $\partial \pi / \partial w_i = -x_i$), Shephard ($\partial e / \partial p_i = h_i$), Roy ($x_i = -\frac{\partial v / \partial p_i}{\partial v / \partial m}$, vía $\partial v / \partial m = \lambda^*$), costo ($\partial c / \partial w_i = x_i$ condicionada, $\partial c / \partial y =$ costo marginal).
- **Curvatura:** π convexa (sup de lineales) $\Rightarrow$ ley de la oferta; e, c cóncavas (inf de lineales) $\Rightarrow$ Slutsky = $\nabla_{pp}^2 e$ simétrica y NSD, ley de demanda compensada; v cuasiconvexa. Ecuación de Slutsky = Shephard + dualidad.
- **Milgrom–Segal:** con X arbitrario, $V(\theta) = V(0) + \int_0^\theta f_\theta(x(s), s) ds$; no requiere que $x(\cdot)$ sea diferenciable. En subastas: $U'(\theta) = Q(\theta)$ (probabilidad de ganar) $\Rightarrow$ fórmula de pagos $\Rightarrow$ equivalencia de ingresos. En screening: renta informacional = integral de envolvente.
- **Panorama general:** Berge da continuidad de V y hemicontinuidad superior del argmax; Danskin da derivadas direccionales $V'(\theta; +1) = \max_{x \in X^*} f_\theta$ y diferenciabilidad bajo unicidad; con óptimos múltiples, V tiene quiebres y $\partial V(\theta) = \text{conv}\{f_\theta(x, \theta) : x \in X^*(\theta)\}$ en el caso convexo.

11.8. Ejercicios tipo examen [P1]

Ejercicio 11.34 (Precio sombra, verificación completa). Considera $V(b) = \max_{x_1, x_2 > 0} \ln x_1 + \ln x_2$ s.a. $2x_1 + x_2 \leq b$, con $b > 0$.

- (a) Resuelve el problema y halla $x(b)$ y $\lambda^*(b)$.
- (b) Calcula $V(b)$ explícitamente y verifica que $V'(b) = \lambda^*(b)$.
- (c) Compara $V(4.1) - V(4)$ con la predicción $\lambda^*(4) \cdot (0.1)$ y explica la discrepancia.

Solución. (a) El objetivo es creciente, así que la restricción se satura y $\lambda > 0$. Lagrangiano $L = \ln x_1 + \ln x_2 - \lambda(2x_1 + x_2 - b)$. CPO: $1/x_1 = 2\lambda$ y $1/x_2 = \lambda$, es decir $x_1 = \frac{1}{2\lambda}$, $x_2 = \frac{1}{\lambda}$. En la restricción: $2 \cdot \frac{1}{2\lambda} + \frac{1}{\lambda} = \frac{2}{\lambda} = b$, de donde $\lambda^*(b) = \frac{2}{b}$, $x_1(b) = \frac{b}{4}$, $x_2(b) = \frac{b}{2}$. (Es máximo: el objetivo es estrictamente cóncavo y la restricción lineal, así que KKT es suficiente, capítulo de KKT.)

(b) $V(b) = \ln \frac{b}{4} + \ln \frac{b}{2} = 2 \ln b - \ln 8$. Derivando directamente: $V'(b) = \frac{2}{b} = \lambda^*(b) \checkmark$, tal como predice el Corolario 11.10.

(c) $V(4.1) - V(4) = 2 \ln \frac{4.1}{4} = 2 \ln(1.025) \approx 2 \times 0.024693 = 0.049385$. La predicción lineal es $\lambda^*(4) \cdot 0.1 = \frac{2}{4} \cdot 0.1 = 0.05$. La diferencia (≈ -0.0006) es el término de segundo orden $\frac{1}{2} V''(4)(0.1)^2 = \frac{1}{2} \cdot (-\frac{2}{16}) \cdot 0.01 = -0.000625$: el precio sombra sobreestima ligeramente la ganancia porque V es cóncava en b (rendimientos marginales decrecientes del recurso). $\square$

Ejercicio 11.35 (Lema de Shephard en un caso Leontief). Un consumidor tiene preferencias Leontief $u(x_1, x_2) = \min\{x_1, x_2\}$.

- (a) Halla la demanda hicksiana $h(p, u)$ y la función de gasto $e(p, u)$ directamente (sin cálculo diferencial: piensa qué canasta es la más barata que garantiza u).
- (b) Verifica el lema de Shephard.
- (c) Verifica que e es cóncava y homogénea de grado 1 en p , y calcula la matriz de Slutsky $S = \nabla_{pp}^2 e$. Interpreta tu resultado: ¿cuánta sustitución hay?

Solución. (a) Para alcanzar $\min\{x_1, x_2\} \geq u$ se necesita $x_1 \geq u$ y $x_2 \geq u$; como los precios son positivos, lo más barato es exactamente $x_1 = x_2 = u$. Así $h_1(p, u) = h_2(p, u) = u$ (¡no depende de los precios!) y

$$e(p, u) = p_1 u + p_2 u = u(p_1 + p_2).$$

(b) $\frac{\partial e}{\partial p_1} = u = h_1(p, u) \checkmark$ y $\frac{\partial e}{\partial p_2} = u = h_2(p, u) \checkmark$. Nota que aquí el objetivo no es diferenciable en x y el óptimo está en una “esquina” de la curva de indiferencia; aun así Shephard funciona, porque lo que la envolvente necesita es suavidad en el parámetro p (el gasto $\langle p, x \rangle$ es lineal en p), no en la decisión: el espíritu de Milgrom–Segal (Observación 11.28).

(c) e es lineal en p , luego cóncava (y convexa a la vez: caso frontera) y claramente homogénea de grado 1: $e(\alpha p, u) = \alpha u(p_1 + p_2)$. La matriz de Slutsky es $S = \nabla_{pp}^2 e = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$: simétrica y semidefinida negativa (en el borde). Interpretación: Leontief es el caso de *sustitución nula*; el consumidor compensado no reacciona en absoluto a los precios relativos, y la concavidad de e

se degenera en linealidad. (Compara con el Ejemplo 11.15, donde $e = 2u\sqrt{p_1 p_2}$ es estrictamente cóncava: allí sí hay sustitución.) $\square$

Ejercicio 11.36 (Identidad de Roy con utilidad cuasilineal). Sea $u(x_1, x_2) = \ln x_1 + x_2$, con precios (p_1, p_2) e ingreso m suficientemente grande para que la solución sea interior (supón $m > p_2$).

- Resuelve el problema del consumidor y halla $x_1(p, m)$, $x_2(p, m)$ y $v(p, m)$.
- Recupera x_1 mediante la identidad de Roy y verifica la coincidencia.
- Calcula λ^* y confirma que $\partial v / \partial m = \lambda^*$. ¿Qué tiene de especial la utilidad marginal del ingreso en este caso y por qué los economistas aman la cuasilinealidad?

Solución. (a) Lagrangiano $L = \ln x_1 + x_2 - \lambda(p_1 x_1 + p_2 x_2 - m)$. CPO: $\frac{1}{x_1} = \lambda p_1$ y $1 = \lambda p_2$. De la segunda, $\lambda^* = \frac{1}{p_2}$; sustituyendo en la primera, $x_1(p, m) = \frac{p_2}{p_1}$. De la restricción (saturada, pues u es creciente en x_2): $x_2(p, m) = \frac{m - p_1 x_1}{p_2} = \frac{m}{p_2} - 1$ (interior porque $m > p_2$). La utilidad indirecta:

$$v(p, m) = \ln \frac{p_2}{p_1} + \frac{m}{p_2} - 1.$$

- (b) Calculamos las derivadas: $\frac{\partial v}{\partial p_1} = \frac{\partial}{\partial p_1} (\ln p_2 - \ln p_1) = -\frac{1}{p_1}$ y $\frac{\partial v}{\partial m} = \frac{1}{p_2}$. Roy:

$$x_1 = -\frac{\partial v / \partial p_1}{\partial v / \partial m} = -\frac{-1/p_1}{1/p_2} = \frac{p_2}{p_1} \checkmark,$$

que coincide con (a). (Ejercicio mental adicional: Roy para el bien 2 da $x_2 = -(\frac{1}{p_2} - \frac{m}{p_2^2})p_2 = \frac{m}{p_2} - 1$ $\checkmark$.)

(c) $\lambda^* = \frac{1}{p_2} = \partial v / \partial m$ $\checkmark$ (Corolario 11.10/ecuación (R2)). Lo especial: λ^* no depende de m : la utilidad marginal del ingreso es constante. Por eso con cuasilinealidad no hay efectos ingreso sobre el bien 1 ($\partial x_1 / \partial m = 0$), la demanda marshalliana y la hicksiana del bien 1 coinciden, y el excedente del consumidor es una medida exacta de bienestar. Es el supuesto favorito en organización industrial y en mecanismos (¡incluida la Sección 11.6.2!) precisamente porque hace que “útiles” y “soles” sean intercambiables a tasa fija. $\square$

Ejercicio 11.37 (Hotelling inverso: de la función de beneficio a la firma). Te informan que una firma competitiva de un producto y dos insumos tiene función de beneficio

$$\pi(p, w_1, w_2) = \frac{p^2}{4} \left(\frac{1}{w_1} + \frac{1}{w_2} \right).$$

- Recupera la oferta $y(p, w)$ y las demandas de insumos $x_1(p, w)$, $x_2(p, w)$ mediante el lema de Hotelling.
- Verifica que π es homogénea de grado 1 y convexa en (p, w) “en las direcciones propias” (comprueba al menos que $\partial^2 \pi / \partial p^2 \geq 0$ y $\partial^2 \pi / \partial w_i^2 \geq 0$), y confirma la ley de la oferta.
- Propón una tecnología que genere exactamente esta π .

Solución. (a) Por Hotelling (Teorema 11.12):

$$y = \frac{\partial \pi}{\partial p} = \frac{p}{2} \left(\frac{1}{w_1} + \frac{1}{w_2} \right), \quad x_1 = -\frac{\partial \pi}{\partial w_1} = \frac{p^2}{4w_1^2}, \quad x_2 = -\frac{\partial \pi}{\partial w_2} = \frac{p^2}{4w_2^2}.$$

(b) Homogeneidad: $\pi(tp, tw) = \frac{t^2 p^2}{4} \left(\frac{1}{tw_1} + \frac{1}{tw_2} \right) = t \pi(p, w)$ ✓ (grado 1, como toda función soporte). Curvaturas propias: $\partial^2 \pi / \partial p^2 = \frac{1}{2} \left(\frac{1}{w_1} + \frac{1}{w_2} \right) > 0$ y $\partial^2 \pi / \partial w_i^2 = \frac{p^2}{2w_i^3} > 0$ ✓. Ley de la oferta: $\partial y / \partial p = \partial^2 \pi / \partial p^2 > 0$ (oferta creciente en el precio) y $\partial x_i / \partial w_i = -\partial^2 \pi / \partial w_i^2 = -\frac{p^2}{2w_i^3} < 0$ (demanda de insumo decreciente en su precio), exactamente como exige el Corolario 11.21.

(c) La forma aditiva sugiere dos “plantas” independientes, cada una como la del Ejemplo 11.13: $F(x_1, x_2) = \sqrt{x_1} + \sqrt{x_2}$. Verificación rápida: $\max_x p(\sqrt{x_1} + \sqrt{x_2}) - w_1 x_1 - w_2 x_2$ se separa en dos problemas, cada uno con valor $p^2/(4w_i)$; sumando se obtiene exactamente la π dada ✓. $\square$

Ejercicio 11.38 (Milgrom–Segal en una subasta de primer precio). Dos postores neutrales al riesgo tienen valoraciones privadas independientes θ_1, θ_2 uniformes en $[0, 1]$. Considera la subasta de *primer precio* (gana la puja más alta y el ganador paga su puja) en su equilibrio simétrico y creciente $\beta(\theta)$, y supón $U(0) = 0$.

- Usa la Proposición 11.29 para calcular la utilidad de equilibrio $U(\theta)$ de un postor de tipo θ .
- Deduce la puja de equilibrio $\beta(\theta)$.
- Verifica la equivalencia de ingresos comparando con la subasta de segundo precio.

Solución. (a) En el equilibrio simétrico con β creciente gana el tipo más alto, así que la probabilidad de ganar del tipo θ es $Q(\theta) = \Pr(\theta_2 < \theta) = F(\theta) = \theta$ (uniforme, $n - 1 = 1$ rival). Por la fórmula de la envoltente de Milgrom–Segal (Proposición 11.29):

$$U(\theta) = U(0) + \int_0^\theta Q(s) ds = 0 + \int_0^\theta s ds = \frac{\theta^2}{2}.$$

Nota que no necesitamos conocer β para esto: la envoltente calcula la utilidad de equilibrio *antes* de conocer la estrategia.

(b) En primer precio, la utilidad del tipo θ que gana con probabilidad $Q(\theta) = \theta$ pagando $\beta(\theta)$ al ganar es $U(\theta) = (\theta - \beta(\theta))\theta$. Igualando con (a):

$$(\theta - \beta(\theta))\theta = \frac{\theta^2}{2} \implies \beta(\theta) = \theta - \frac{\theta}{2} = \frac{\theta}{2}.$$

Cada postor puja la mitad de su valoración (en general, con n postores uniformes, $\beta(\theta) = \frac{n-1}{n}\theta$: la esperanza del máximo rival condicional a ganar).

(c) Pago esperado (no condicional) del tipo θ en primer precio: $T^I(\theta) = Q(\theta)\beta(\theta) = \theta \cdot \frac{\theta}{2} = \frac{\theta^2}{2}$. En segundo precio, pujar la valoración es dominante y el ganador paga la puja rival: $T^{II}(\theta) = \Pr(\theta_2 < \theta) \cdot \mathbb{E}[\theta_2 \mid \theta_2 < \theta] = \theta \cdot \frac{\theta}{2} = \frac{\theta^2}{2}$. Igualmente tipo a tipo, como exige el Teorema 11.30 (misma asignación, mismo $U(0)$). Ingreso esperado del subastador en ambas: $\mathbb{E}[T(\theta_1) + T(\theta_2)] =$

$2 \int_0^1 \frac{\theta^2}{2} d\theta = \frac{1}{3}$, que es $\mathbb{E}[\min\{\theta_1, \theta_2\}]$: en promedio, el subastador recauda la segunda valoración más alta. Equivalencia de ingresos verificada $\checkmark$. $\square$

Ejercicio 11.39 (Quiebres, Danskin y subdiferencial). Sea $V(\theta) = \max_{x \in [0,1]} \theta x - x^2$, con $\theta \in \mathbb{R}$.

- (a) Halla $x(\theta)$ y $V(\theta)$ explícitamente para todo θ (cuidado con las esquinas del intervalo $[0, 1]$).
- (b) ¿En qué puntos es V diferenciable? Calcula V' donde exista usando la envolvente y verifica contra la fórmula explícita.
- (c) Modifica el problema a $\tilde{V}(\theta) = \max_{x \in \{0,1\}} \theta x - x^2$ (solo dos decisiones). Halla $\tilde{V}$, localiza su quiebre y calcula $\partial\tilde{V}$ en ese punto.

Solución. (a) El objetivo $x \mapsto \theta x - x^2$ es estrictamente cóncavo con máximo no restringido en $x = \theta/2$. Proyectando sobre $[0, 1]$ (capítulo de optimalidad: en problemas cóncavos unidimensionales, la solución restringida es la proyección de la no restringida):

$$x(\theta) = \begin{cases} 0, & \theta \leq 0, \\ \theta/2, & 0 \leq \theta \leq 2, \\ 1, & \theta \geq 2, \end{cases} \quad V(\theta) = \begin{cases} 0, & \theta \leq 0, \\ \theta^2/4, & 0 \leq \theta \leq 2, \\ \theta - 1, & \theta \geq 2. \end{cases}$$

(b) El maximizador es *único para todo* θ , así que por Danskin (Teorema 11.32, con $K = [0, 1]$ compacto) V es diferenciable en todo θ , con $V'(\theta) = \partial(\theta x - x^2)/\partial\theta|_{x=x(\theta)} = x(\theta)$. Verificación con la fórmula explícita: para $\theta < 0$, $V' = 0 = x(\theta)$; para $0 < \theta < 2$, $V' = \theta/2 = x(\theta)$; para $\theta > 2$, $V' = 1 = x(\theta)$; y en los puntos de empalme $\theta = 0, 2$ las derivadas laterales coinciden (0 y 1 respectivamente) $\checkmark$. Moraleja: aunque la *política* $x(\theta)$ tiene esquinas en $\theta = 0, 2$ (no es diferenciable ahí), la *función de valor* es C^1 : la unicidad del óptimo protege la suavidad de V , no la de x .

(c) Ahora $\tilde{V}(\theta) = \max\{0, \theta - 1\}$: la decisión $x = 0$ da 0 y la decisión $x = 1$ da $\theta - 1$. Para $\theta < 1$ el único óptimo es $x = 0$ y $\tilde{V} = 0$, $\tilde{V}' = 0$; para $\theta > 1$ el único óptimo es $x = 1$ y $\tilde{V}' = 1$. En $\theta = 1$ ambas decisiones son óptimas ($X^*(1) = \{0, 1\}$) y $\tilde{V}$ tiene un quiebre: derivadas laterales 0 (izquierda) y 1 (derecha), que son el mínimo y el máximo de $\{f_\theta(x, 1) : x \in X^*(1)\} = \{0, 1\}$, como dicta Danskin. Como $\tilde{V}$ es convexa (máximo de afines),

$$\partial\tilde{V}(1) = \text{conv}\{0, 1\} = [0, 1].$$

Es exactamente el patrón del Ejemplo 11.33: al discretizar la decisión, la multiplicidad de óptimos en el umbral produce el quiebre, y el subdiferencial (capítulo de subdiferencial) recoge todas las “pendientes candidatas”. $\square$

Capítulo 12

Conjugación en el sentido de Fenchel

[P3]

Semana 9 del cronograma. Bibliografía: Brinkhuis [3]; Ruszczyński [6]; Boyd y Vandenberghe [2].

¿Para qué sirve esto en Microeconomía?

La conjugación de Fenchel es el lenguaje matemático exacto de la *dualidad de la teoría de la producción* que verás en Microeconomía, dentro de la parte de decisión individual ([9], cap. 5). Tres conexiones concretas:

- **Beneficio y costo.** La función de beneficio de una firma es, literalmente, la *conjugada de Fenchel* de su función de costo: $\pi(p) = \sup_y \{py - c(y)\} = c^*(p)$. Toda la teoría dual de la firma (lema de Hotelling, lema de Shephard, recuperación de la tecnología) es un caso particular de los teoremas de este capítulo.
- **Recuperabilidad.** El teorema de Fenchel–Moreau ($f^{**} = \text{cl conv } f$) explica *exactamente* qué se puede recuperar de la tecnología a partir de la función de beneficio o de costo: la cápsula convexa cerrada. Por eso se dice que la dualidad “convexifica”: dos tecnologías con la misma envolvente convexa son indistinguibles con datos de mercado. Lo mismo ocurre entre utilidad indirecta y directa, y entre función de gasto y utilidad: son pares conjugados (salvo signos y monotonías).
- **Mecanismos y taxación (MWG cap. 23).** En *screening* y en taxación óptima a la Mirrlees, el *virtual surplus* se “plancha” (*ironing*, Mussa–Rosen, Myerson) reemplazando una función por su envolvente cóncava/convexa: eso es tomar una biconjugada. Entender f^{**} es entender por qué el ironing funciona.

Prioridad 3: no es lo primero que se examina, pero ilumina todo el material dual de Micro y reaparece en mecanismos.

En los capítulos anteriores aprendimos que un conjunto convexo cerrado queda completamente descrito por sus hiperplanos soporte (capítulo de separación) y que esa descripción se codifica en la *función soporte* (capítulo de funciones convexas). En este capítulo hacemos lo

mismo con *funciones*: describiremos una función convexa por sus rectas (o hiperplanos) soporte, y la contabilidad de esas rectas será una nueva función, la *conjugada de Fenchel*. La sorpresa económica es que esta construcción, aparentemente abstracta, es algo que ya conoces: el paso de la función de costo a la función de beneficio de una firma. La referencia central del curso para este tema es [3]; también son útiles [6] (sec. 2.6) y [2] (sec. 3.3).

12.1. Motivación: describir una función por sus rectas soporte [P3]

Empecemos en dimensión 1 y con calma. Una recta no vertical en el plano queda determinada por dos números: su *pendiente* p y su *ordenada al origen* b (el valor donde corta al eje vertical):

$$\ell_{p,b}(x) = px - b.$$

(Escribimos $-b$ en lugar de $+b$ por pura conveniencia: los signos saldrán más limpios; con esta convención, la recta corta al eje vertical en $-b$.)

Sea $f: \mathbb{R} \rightarrow \mathbb{R} \cup \{+\infty\}$ una función. Decimos que la recta $\ell_{p,b}$ es una **minorante afín** (*affine minorant*) de f si queda por debajo de la gráfica en todo punto:

$$px - b \leq f(x) \quad \text{para todo } x \in \mathbb{R}.$$

Si además toca a la gráfica en algún punto, decimos que es una **recta soporte** (*supporting line*) de f .

Fijemos ahora la pendiente p y hagamos la pregunta clave:

entre todas las rectas de pendiente p que quedan por debajo de f , ¿cuál es la más alta?

La recta $x \mapsto px - b$ queda por debajo de f si y solo si $b \geq px - f(x)$ para todo x , es decir, si y solo si

$$b \geq \sup_x \{px - f(x)\}.$$

El menor b admisible, el que da la recta más alta, es exactamente ese supremo. Ese número, que depende solo de la pendiente p , merece un nombre: será $f^*(p)$, la conjugada de f evaluada en p .

Geométricamente, $px - f(x)$ es la *distancia vertical con signo* entre la recta $y = px$ (que pasa por el origen) y la gráfica de f en la abscisa x : positiva donde la recta va por encima de f , negativa donde va por debajo. El supremo $f^*(p)$ es la *máxima ventaja vertical* que la recta de pendiente p le saca a f . La figura 12.1 lo muestra para $f(x) = x^2/2$ y $p = 1$.

Intuición

Piensa en f^* como un *cambio de coordenadas para describir la misma curva*. La descripción usual de f responde a la pregunta “en el punto x , ¿qué altura tiene la gráfica?”. La descripción conjugada responde a “para la pendiente p , ¿dónde corta al eje vertical la recta soporte de esa pendiente?” (la respuesta es $-f^*(p)$). Para funciones convexas cerradas ambas descripciones llevan la misma información: conociendo todas las rectas soporte se




Figura 12.1: La conjugada $f^*(p)$ es la brecha vertical máxima entre la recta $y = px$ y la gráfica de f ; se alcanza en el punto x^* donde la pendiente de f iguala a p . Al bajar la recta $y = px$ exactamente $f^*(p)$ unidades se obtiene la recta soporte de pendiente p (línea discontinua).

reconstruye la función como su supremo. Es el análogo funcional de describir un conjunto convexo cerrado por su función soporte.

La lectura económica que guiará todo el capítulo. Sea $c(y)$ la función de *costo* de una firma que produce la cantidad $y \geq 0$ de un bien cuyo precio es p (la firma es precio-aceptante). Su beneficio al producir y es el ingreso menos el costo, $py - c(y)$, y la firma elige y para maximizarlo. El beneficio máximo alcanzable es

$$\pi(p) = \sup_y \{ py - c(y) \},$$

que es *exactamente* la construcción anterior con $f = c$:

La función de beneficio es la conjugada de la función de costo: $\pi = c^*$.

Cada concepto geométrico tiene entonces una traducción económica: la pendiente p es el precio de venta; la brecha vertical $py - c(y)$ es el beneficio de producir y ; el supremo es la optimización de la firma; el punto x^* donde se alcanza es la oferta óptima $y(p)$; y la recta soporte $y \mapsto py - \pi(p)$ es la recta de isobeneficio máximo que “se apoya” en la curva de costo. Mantendremos este diccionario activo en todo el capítulo.

12.2. La conjugada de Fenchel: definición y primeras observaciones [P3]

Formalicemos en $\mathbb{R}^n$. Recuerda del capítulo de funciones convexas que trabajamos con funciones *extendidas* $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, que f es **propia** (*proper*) si no es idénticamente $+\infty$, que su **dominio efectivo** es $\text{dom } f = \{x : f(x) < +\infty\}$, y que f es **cerrada** (*closed*) si su epígrafo $\text{epi } f = \{(x, t) : t \geq f(x)\}$ es un conjunto cerrado (equivalentemente, f es semicontinua inferior).

Definición 12.1 (Conjugada de Fenchel). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propia. Su **conjugada de Fenchel** (*convex conjugate*), también llamada **transformada de Legendre–Fenchel**

(Legendre–Fenchel transform), es la función $f^*: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ definida por

$$f^*(p) = \sup_{x \in \mathbb{R}^n} \{ \langle p, x \rangle - f(x) \}.$$

La **biconjugada** es $f^{**} = (f^*)^*$, es decir $f^{**}(x) = \sup_p \{ \langle p, x \rangle - f^*(p) \}$.

Tres observaciones inmediatas para leer bien la definición.

Observación 12.2. (I) El supremo se toma de hecho sobre $x \in \text{dom } f$: fuera del dominio, $f(x) = +\infty$ y el término $\langle p, x \rangle - f(x) = -\infty$ no compite. Esta es la gran ventaja de las funciones extendidas: las restricciones ya vienen incorporadas.

(II) $f^*(p)$ puede valer $+\infty$ para algunos p (si ninguna recta de pendiente p queda por debajo de f), pero si f es propia y tiene al menos una minorante afín, entonces f^* nunca vale $-\infty$ y f^* es propia.

(III) La variable p vive en el *espacio dual*: si x son cantidades, p son precios; si x son posiciones, p son pendientes. El producto $\langle p, x \rangle$ debe tener “unidades de valor”.

Cuidado (error común)

Tres errores frecuentes al calcular conjugadas:

- (a) **Olvidar el análisis de casos.** El supremo $\sup_x \{ \langle p, x \rangle - f(x) \}$ *no* siempre se alcanza en un punto crítico interior. Hay que preguntarse, para *cada* valor de p : ¿el supremo es finito?, ¿se alcanza?, ¿se alcanza en la frontera del dominio o en el infinito? Un cálculo que solo iguala la derivada a cero y despeja suele dar una fórmula válida únicamente para *algunos* p , y la conjugada queda mal definida en el resto (compara los ejemplos 12.6 y 12.7).
- (b) **Confundir el argumento.** f^* es función de p , no de x . Tras optimizar en x , la variable x debe haber desaparecido de la fórmula final.
- (c) **Esperar que $f^{**} = f$ siempre.** Solo es cierto para f convexa, cerrada y propia (teorema de Fenchel–Moreau, sección 12.6). En general $f^{**} \leq f$ y la desigualdad puede ser estricta.

Estrategia de examen

Receta para calcular $f^*(p) = \sup_x \{ \langle p, x \rangle - f(x) \}$ en un examen:

1. Escribe $h_p(x) = \langle p, x \rangle - f(x)$ y fija p como parámetro.
2. Si f es diferenciable en el interior del dominio, busca puntos críticos: $\nabla f(x) = p$. Nota que h_p es *cóncava* cuando f es convexa, así que un punto crítico interior es un máximo global.
3. Determina para qué valores de p la ecuación $\nabla f(x) = p$ tiene solución en el dominio. Para esos p , sustituye y simplifica.
4. Para los demás p , estudia el comportamiento de h_p en la frontera de $\text{dom } f$ y cuando

$\|x\| \rightarrow \infty$: el supremo será un valor frontera o $+\infty$.

5. Verifica: f^* debe ser convexa, y debe cumplirse Fenchel–Young ($f(x) + f^*(p) \geq \langle p, x \rangle$) en algún punto de prueba fácil, por ejemplo $x = 0$ o $p = 0$. Con $p = 0$: $f^*(0) = -\inf_x f(x)$, una comprobación rapidísima.

12.3. Ejemplos calculados en detalle [P3]

Ejemplo 12.3 (La parábola es autoconjugada). Sea $f(x) = \frac{x^2}{2}$ en $\mathbb{R}$. Calculemos f^* paso a paso. Fijamos $p \in \mathbb{R}$ y estudiamos

$$h_p(x) = p x - \frac{x^2}{2}.$$

Es una parábola invertida en x (coeficiente cuadrático negativo), así que su supremo se alcanza en el único punto crítico:

$$h'_p(x) = p - x = 0 \iff x^* = p.$$

Aquí no hay casos: para *todo* $p \in \mathbb{R}$ la ecuación tiene solución. Sustituyendo,

$$f^*(p) = h_p(p) = p \cdot p - \frac{p^2}{2} = \frac{p^2}{2}.$$

Conclusión: $f^*(p) = p^2/2$. La función $x \mapsto x^2/2$ es **autoconjugada** (*self-conjugate*): $f^* = f$. Se puede probar que es la única función con esta propiedad.

Ejemplo 12.4 (Costo cuadrático y beneficio cuadrático). Traduzcamos el ejemplo anterior a economía. Una firma tiene costo $c(y) = y^2/2$ (costo marginal creciente $c'(y) = y$: la primera unidad es casi gratis, cada unidad adicional cuesta más). Su beneficio máximo al precio $p > 0$ es

$$\pi(p) = \sup_y \{p y - c(y)\} = c^*(p) = \frac{p^2}{2},$$

alcanzado en la *oferta* $y(p) = p$ (producir hasta que el costo marginal iguale al precio: $c'(y) = p$). Observa dos cosas que generalizaremos: (i) π es convexa en p aunque no lo hubiera sido c en y ; (ii) $\pi'(p) = p = y(p)$: *la derivada del beneficio respecto del precio es la oferta*. Esto es el lema de Hotelling, y en la sección 12.5 veremos que es un teorema general sobre conjugadas, no una casualidad del ejemplo.

Ejemplo 12.5 (Potencias y exponentes duales de Hölder). Sea $q > 1$ y $f(x) = \frac{1}{q}|x|^q$ en $\mathbb{R}$. Afirmamos que

$$f^*(p) = \frac{1}{q'} |p|^{q'}, \quad \text{donde } \frac{1}{q} + \frac{1}{q'} = 1 \quad (\text{es decir, } q' = \frac{q}{q-1}).$$

Los exponentes q y q' son los *conjugados de Hölder* (*Hölder conjugates*); la conjugación de Fenchel explica por qué aparecen juntos en tantas desigualdades.

Cálculo completo. Primero una simetría útil: f es par ($f(-x) = f(x)$), y para funciones pares $f^*(-p) = f^*(p)$ (cambia x por $-x$ dentro del supremo). Basta entonces calcular para $p \geq 0$.

Caso $p = 0$: $f^*(0) = \sup_x \{-f(x)\} = -\inf_x f(x) = 0$, pues $f \geq 0$ y $f(0) = 0$.

Caso $p > 0$: como $px - f(x) \leq px \leq 0$ para $x \leq 0$ y $h_p(0) = 0$, el supremo se busca en $x \geq 0$, donde $h_p(x) = px - \frac{1}{q}x^q$. Derivando,

$$h'_p(x) = p - x^{q-1} = 0 \iff x^* = p^{\frac{1}{q-1}} > 0.$$

Como h_p es cóncava en $[0, \infty)$ (su segunda derivada es $-(q-1)x^{q-2} \leq 0$), x^* es máximo global. Sustituimos, usando que $\frac{1}{q-1} + 1 = \frac{q}{q-1} = q'$:

$$f^*(p) = p \cdot p^{\frac{1}{q-1}} - \frac{1}{q} p^{\frac{q}{q-1}} = p^{q'} - \frac{1}{q} p^{q'} = \left(1 - \frac{1}{q}\right) p^{q'} = \frac{1}{q'} p^{q'}.$$

Por la simetría, $f^*(p) = \frac{1}{q'} |p|^{q'}$ para todo $p \in \mathbb{R}$.

Verificación con $q = 2$: entonces $q' = 2$ y recuperamos el ejemplo 12.3. La parábola $x^2/2$ es el punto fijo de la dualidad $q \leftrightarrow q'$.

Subproducto: la desigualdad de Fenchel–Young (teorema 12.10) aplicada a este par da la *desigualdad de Young*

$$px \leq \frac{|x|^q}{q} + \frac{|p|^{q'}}{q'},$$

base de la desigualdad de Hölder que usaste en el capítulo de preliminares.

Ejemplo 12.6 (Exponencial y entropía). Sea $f(x) = e^x$ en $\mathbb{R}$. Aquí el análisis de casos es obligatorio, porque la ecuación de punto crítico no siempre tiene solución. Fijamos p y estudiamos $h_p(x) = px - e^x$.

Caso $p < 0$: cuando $x \rightarrow -\infty$, el término $px \rightarrow +\infty$ (negativo por negativo) mientras $e^x \rightarrow 0$. Luego $h_p(x) \rightarrow +\infty$ y $f^*(p) = +\infty$: ninguna recta de pendiente negativa queda por debajo de e^x , porque e^x se aplasta contra el eje horizontal a la izquierda y cualquier recta decreciente termina por encima... y de hecho escapa hacia arriba.

Caso $p = 0$: $h_0(x) = -e^x < 0$ para todo x , pero $h_0(x) \rightarrow 0$ cuando $x \rightarrow -\infty$. El supremo es 0 y *no se alcanza*. Así $f^*(0) = 0$: el supremo de la definición puede ser finito sin alcanzarse.

Caso $p > 0$: h_p es cóncava ($h''_p = -e^x < 0$) y

$$h'_p(x) = p - e^x = 0 \iff x^* = \ln p,$$

que existe precisamente porque $p > 0$. Sustituyendo,

$$f^*(p) = p \ln p - e^{\ln p} = p \ln p - p.$$

En resumen,

$$f^*(p) = \begin{cases} p \ln p - p, & p > 0, \\ 0, & p = 0, \\ +\infty, & p < 0. \end{cases}$$

Nota que $p \ln p - p \rightarrow 0$ cuando $p \downarrow 0$, así que f^* es continua en $p = 0$ dentro de su dominio $[0, \infty)$: es una función cerrada, como debe ser (teorema 12.9). La función $p \ln p - p$ (y su prima $p \ln p$) es la **entropía negativa** (*negative entropy*); el par $(e^x, p \ln p - p)$ es central en teoría de la información, en grandes desviaciones y en los métodos de regularización entrópica que quizá encuentres en transporte óptimo.

Ejemplo 12.7 (Funciones afines: la conjugada es una indicatriz). Sea $f(x) = \langle a, x \rangle + b$ con $a \in \mathbb{R}^n$, $b \in \mathbb{R}$. Entonces

$$f^*(p) = \sup_x \{ \langle p, x \rangle - \langle a, x \rangle - b \} = \sup_x \langle p - a, x \rangle - b.$$

Si $p \neq a$, elegimos $x = t(p - a)$ con $t \rightarrow +\infty$ y $\langle p - a, x \rangle = t \|p - a\|^2 \rightarrow +\infty$: el supremo es $+\infty$. Si $p = a$, todos los términos $\langle p - a, x \rangle$ valen 0 y el supremo es $-b$. Por tanto

$$f^*(p) = \begin{cases} -b, & p = a, \\ +\infty, & p \neq a, \end{cases} \quad \text{es decir,} \quad f^* = \delta_{\{a\}} - b,$$

donde δ_C es la función indicatriz del capítulo de funciones convexas. Tiene sentido geométrico perfecto: una recta (hiperplano) solo admite rectas soporte de *su propia* pendiente a , y la mejor (la única) tiene ordenada al origen b , o sea $-f^*(a) = b$. Moraleja: cuanto más “plana” es f (menos pendientes distintas exhibe), más “concentrada” es f^* , y viceversa. Una función afín (un solo gradiente posible) tiene conjugada con dominio de un solo punto; en el otro extremo, una función con un pico (muchos subgradiantes en un mismo punto) tiene conjugada con un tramo plano (ejercicio 12.22).

Ejemplo 12.8 (La conjugada de la indicatriz es la función soporte). Sea $C \subseteq \mathbb{R}^n$ no vacío y δ_C su indicatriz ($\delta_C(x) = 0$ si $x \in C$, $+\infty$ si no). Entonces

$$\delta_C^*(p) = \sup_x \{ \langle p, x \rangle - \delta_C(x) \} = \sup_{x \in C} \langle p, x \rangle = \sigma_C(p),$$

la **función soporte** (*support function*) de C del capítulo de funciones convexas. La conjugación unifica así dos teorías: la dualidad conjuntos convexas $\leftrightarrow$ funciones soporte es el caso particular de la dualidad de Fenchel en que la función solo distingue “dentro/fuera”. En la teoría de la producción esto es la función de beneficio de una firma con conjunto de producción Y : $\pi(p) = \sup_{y \in Y} \langle p, y \rangle = \sigma_Y(p) = \delta_Y^*(p)$, con la convención de que las cantidades de insumo entran con signo negativo en y ([9], cap. 5).

12.4. Propiedades básicas de la conjugada [P3]

La primera propiedad es la más importante y la más barata: la conjugada *siempre* es convexa y cerrada, sin pedirle nada a f .

Teorema 12.9 (La conjugada siempre es convexa y cerrada). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propia. Entonces f^* es convexa y cerrada (semicontinua inferior), aunque f no sea ni convexa ni cerrada.

Demostración. Para cada $x \in \text{dom } f$ fijo, la función

$$p \mapsto \langle p, x \rangle - f(x)$$

es *afín en p* (lineal más constante: aquí x y $f(x)$ son constantes y la variable es p). Por definición,

$$f^* = \sup_{x \in \text{dom } f} [p \mapsto \langle p, x \rangle - f(x)],$$

un supremo puntual de funciones afines. En el capítulo de funciones convexas probamos que el supremo puntual de cualquier familia de funciones convexas es convexo (los epígrafos se intersecan, y la intersección de convexos es convexa) y que el supremo de funciones continuas es semicontinuo inferior (intersección de epígrafos cerrados es cerrada). Las funciones afines son convexas y continuas, luego f^* es convexa y cerrada. $\square$

Intuición

Este teorema es el corazón de la frase “la dualidad convexifica”. El proceso de conjugar solo mira las *minorantes afines* de f , y ese tipo de información es intrínsecamente convexa: da igual lo salvaje que sea f , lo que las rectas soporte ven de ella es un objeto convexo. En economía: la función de beneficio $\pi = c^*$ es convexa en precios *siempre*, incluso si la tecnología subyacente es horrible (no convexa, discontinua). Por eso en los datos (que registran respuestas a precios) la convexidad de π no es un supuesto sobre la tecnología: es una tautología de la maximización.

La segunda propiedad es una desigualdad de una línea con nombre propio.

Teorema 12.10 (Desigualdad de Fenchel–Young). *Para toda f propia, todo $x \in \mathbb{R}^n$ y todo $p \in \mathbb{R}^n$,*

$$f(x) + f^*(p) \geq \langle p, x \rangle.$$

Demostración. Por definición de supremo, $f^*(p) \geq \langle p, x \rangle - f(x)$ para el x dado (el supremo domina a cada término). Si $f(x) = +\infty$ la desigualdad es trivial; si no, sumamos $f(x)$ a ambos lados. $\square$

En términos económicos con $f = c$ y $f^* = \pi$: para cualquier plan de producción y y cualquier precio p ,

$$\pi(p) \geq p y - c(y),$$

el beneficio *máximo* domina al beneficio de cualquier plan concreto. La igualdad se da exactamente cuando y es una respuesta óptima al precio p ; ese caso de igualdad es tan importante que le dedicamos la sección 12.5.

Proposición 12.11 (La conjugación invierte el orden). *Si $f \leq g$ puntualmente (ambas propias), entonces $f^* \geq g^*$.*

Demostración. Para cada x : $\langle p, x \rangle - f(x) \geq \langle p, x \rangle - g(x)$, porque restar algo menor deja algo mayor. Tomando supremo en x a ambos lados (el supremo preserva desigualdades puntuales), $f^*(p) \geq g^*(p)$. $\square$

Económicamente: si la tecnología de la firma A es más barata que la de B ($c_A \leq c_B$), entonces A obtiene más beneficio a cualquier precio ($\pi_A \geq \pi_B$). La conjugación es un “espejo”: lo pequeño se vuelve grande.

Proposición 12.12 (Reglas de cálculo: traslaciones y escalamientos). *Sea f propia, $x_0, a \in \mathbb{R}^n$, $\beta \in \mathbb{R}$ y $\lambda > 0$. Entonces:*

<i>Transformación de f</i>	<i>Conjugada resultante</i>
$g(x) = f(x) + \beta$	$g^*(p) = f^*(p) - \beta$
$g(x) = f(x - x_0)$ (traslación horizontal)	$g^*(p) = f^*(p) + \langle p, x_0 \rangle$
$g(x) = f(x) + \langle a, x \rangle$ (inclinación afín)	$g^*(p) = f^*(p - a)$
$g(x) = \lambda f(x)$ (escala vertical)	$g^*(p) = \lambda f^*(p/\lambda)$
$g(x) = f(\lambda x)$ (escala horizontal)	$g^*(p) = f^*(p/\lambda)$

Demostración. Todas son sustituciones directas en la definición; probamos dos como modelo y dejamos las demás como ejercicio mental. *Traslación horizontal:* con el cambio de variable $z = x - x_0$ (biyección de $\mathbb{R}^n$, así que el supremo sobre x es el supremo sobre z),

$$g^*(p) = \sup_x \{ \langle p, x \rangle - f(x - x_0) \} = \sup_z \{ \langle p, z + x_0 \rangle - f(z) \} = \langle p, x_0 \rangle + f^*(p).$$

Escala vertical: con $\lambda > 0$,

$$g^*(p) = \sup_x \{ \langle p, x \rangle - \lambda f(x) \} = \lambda \sup_x \left\{ \left\langle \frac{p}{\lambda}, x \right\rangle - f(x) \right\} = \lambda f^*\left(\frac{p}{\lambda}\right). \quad \square$$

Ejemplo 12.13 (Uso de las reglas). Calculemos la conjugada de $g(x) = \frac{1}{2}(x - 3)^2 + 5x$ sin optimizar nada. Escribimos $g(x) = f(x - 3) + 5x$ con $f(x) = x^2/2$, cuya conjugada conocemos: $f^* = f$. Primero la inclinación afín: si $g_1(x) = f_1(x) + 5x$ entonces $g_1^*(p) = f_1^*(p - 5)$, con $f_1(x) = f(x - 3)$. Por la traslación, $f_1^*(p) = f^*(p) + 3p = \frac{p^2}{2} + 3p$. Componiendo,

$$g^*(p) = f_1^*(p - 5) = \frac{(p - 5)^2}{2} + 3(p - 5).$$

Comprobación por cálculo directo: g es convexa y diferenciable, así que resolvemos $g'(x) = x - 3 + 5 = p$, es decir $x^* = p - 2$, y sustituimos:

$$g^*(p) = p(p - 2) - g(p - 2) = (p - 2)(p - 5) - \frac{1}{2}(p - 5)^2 = (p - 5)\left(\frac{p+1}{2}\right),$$

que es exactamente $\frac{(p-5)^2}{2} + 3(p - 5)$ desarrollado (ambas expresiones se factorizan como $(p - 5)(p + 1)/2$). Las reglas y el cálculo directo coinciden, como debe ser.

12.5. Igualdad en Fenchel–Young y subdiferenciales [P3]

La desigualdad de Fenchel–Young se vuelve teoría profunda cuando preguntamos *cuándo es igualdad*. La respuesta conecta la conjugada con el subdiferencial del capítulo correspondiente y, en economía, es el lema de Hotelling.

Recuerda la definición: $p \in \partial f(x)$ (“ p es un subgradiente de f en x ”) si

$$f(z) \geq f(x) + \langle p, z - x \rangle \quad \text{para todo } z \in \mathbb{R}^n,$$

es decir, si la función afín $z \mapsto f(x) + \langle p, z - x \rangle$ es una minorante de f que toca a f en x : una *recta soporte en x con pendiente p* .

Teorema 12.14 (Caracterización de la igualdad en Fenchel–Young). *Sea f propia, $x \in \text{dom } f$ y $p \in \mathbb{R}^n$. Las siguientes afirmaciones son equivalentes:*

$$(I) \quad p \in \partial f(x);$$

$$(II) \quad f(x) + f^*(p) = \langle p, x \rangle \quad (\text{Fenchel–Young con igualdad});$$

$$(III) \quad x \in \arg \max_z \{ \langle p, z \rangle - f(z) \} \quad (\text{el supremo que define } f^*(p) \text{ se alcanza en } x).$$

Cualquiera de ellas implica

$$(IV) \quad x \in \partial f^*(p);$$

y si f es convexa, cerrada y propia, entonces (iv) también es equivalente a las anteriores: en tal caso

$$p \in \partial f(x) \iff x \in \partial f^*(p).$$

Demostración. (i) $\Leftrightarrow$ (iii). La condición $p \in \partial f(x)$ dice $f(z) \geq f(x) + \langle p, z - x \rangle$ para todo z . Reordenando (pasamos $f(z)$ y $\langle p, x \rangle$ de lado, operación legítima porque $f(x)$ es finito):

$$\langle p, x \rangle - f(x) \geq \langle p, z \rangle - f(z) \quad \text{para todo } z,$$

que dice exactamente que $z = x$ maximiza $z \mapsto \langle p, z \rangle - f(z)$. Cada paso es reversible, así que las dos condiciones son equivalentes.

(iii) $\Leftrightarrow$ (ii). Si el supremo se alcanza en x , entonces $f^*(p) = \langle p, x \rangle - f(x)$, que es (ii). Recíprocamente, si $f^*(p) = \langle p, x \rangle - f(x)$, el valor del supremo se logra en el punto x , que es (iii).

(ii) $\Rightarrow$ (iv). Aplicamos lo ya probado, pero con f^* en el papel de f . Queremos ver que $x \in \partial f^*(p)$, es decir, por la equivalencia (i) $\Leftrightarrow$ (ii) aplicada a f^* , que

$$f^*(p) + f^{**}(x) = \langle p, x \rangle.$$

Sabemos (ii): $f^*(p) + f(x) = \langle p, x \rangle$. Además, por Fenchel–Young aplicada al par (f^*, x) : $f^{**}(x) \geq \langle p, x \rangle - f^*(p) = f(x)$; y siempre $f^{**} \leq f$ (cada término $\langle p, x \rangle - f^*(p)$ es el valor en x de una minorante afín de f , y el supremo de minorantes no supera a f). Luego $f^{**}(x) = f(x)$ y sustituyendo se obtiene la igualdad deseada.

(iv) $\Rightarrow$ (ii) cuando f es convexa cerrada propia. En ese caso el teorema de Fenchel–Moreau (teorema 12.15, que probaremos sin usar esta implicación) da $f^{**} = f$. La condición (iv), vía la equivalencia (i) $\Leftrightarrow$ (ii) aplicada a f^* , dice $f^*(p) + f^{**}(x) = \langle p, x \rangle$; sustituyendo $f^{**}(x) = f(x)$ obtenemos (ii). $\square$

Intuición

La simetría $p \in \partial f(x) \Leftrightarrow x \in \partial f^*(p)$ dice que *los subdiferenciales de f y de f^* son la misma relación leída en espejo*: el “grafo” $\{(x, p) : p \in \partial f(x)\}$ de una función convexa cerrada y el de su conjugada son inversos uno del otro. Cuando f es diferenciable y estrictamente convexa esto se lee como: ∇f y ∇f^* son funciones inversas. En el ejemplo 12.3, $\nabla f(x) = x$ es su propia inversa: por eso $x^2/2$ es autoconjugada.

El lema de Hotelling es Fenchel–Young con igualdad. Apliquemos el teorema al par costo–beneficio, $f = c$ y $c^* = \pi$. La oferta óptima al precio p es, por definición,

$$y(p) \in \arg \max_y \{py - c(y)\},$$

que es la condición (iii). El teorema la hace equivalente a:

- (i) $p \in \partial c(y(p))$: en el óptimo, *el precio es un (sub)costo marginal*. Si c es diferenciable, $p = c'(y(p))$: la regla clásica “precio igual a costo marginal”. La versión con subdiferencial cubre costos con quiebres (tramos de capacidad, costos fijos por escalones), donde “el” costo marginal no existe pero el intervalo de subgradiantes sí.
- (iv) $y(p) \in \partial \pi(p)$: *la oferta es un subgradiente de la función de beneficio*. Si π es diferenciable en p ,

$$y(p) = \pi'(p),$$

que es el **lema de Hotelling** (*Hotelling’s lemma*). En el capítulo de la envolvente lo obtuvimos como teorema de la envolvente (con las hipótesis de [11]): $\pi(p) = \max_y \{py - c(y)\}$ y la derivada del valor óptimo respecto del parámetro p es la derivada parcial del objetivo evaluada en el óptimo, o sea $y(p)$. Ahora lo redescubrimos sin derivar nada: es pura conjugación. La versión de Fenchel es más general (no necesita unicidad del óptimo ni diferenciabilidad: si hay varias ofertas óptimas, *todas* son subgradiantes de π y $\partial \pi(p)$ es exactamente el conjunto de ofertas óptimas, cerradura convexa mediante).

Este es un patrón que conviene fijar: *teorema de la envolvente en problemas lineales en el parámetro = subdiferencial de una conjugada*. La función de gasto y el lema de Shephard admiten el mismo tratamiento con los signos adaptados (el gasto es una conjugada “cóncava” de la indicatriz del conjunto de canastas al menos tan buenas como u).

12.6. Biconjugada y teorema de Fenchel–Moreau [P3]

Si conjugar una vez traduce “alturas” a “rectas soporte”, conjugar dos veces debería devolvernos la función original. . . siempre que la función original fuera reconstruible desde sus rectas soporte. Veamos qué significa eso con precisión.

Desarrollemos f^{**} :

$$f^{**}(x) = \sup_p \{\langle p, x \rangle - f^*(p)\}.$$

Para cada p con $f^*(p) < +\infty$, la función $x \mapsto \langle p, x \rangle - f^*(p)$ es precisamente *la minorante afín*

de f de pendiente p más alta posible (así definimos $f^*(p)$ en la sección 12.1). Por lo tanto:

f^{**} es el supremo puntual de todas las minorantes afines de f .

Dos consecuencias inmediatas: $f^{**} \leq f$ (un supremo de minorantes de f no puede superar a f), y f^{**} es convexa y cerrada (supremo de afines, teorema 12.9). La pregunta es si el supremo llena todo lo que puede llenarse.

Teorema 12.15 (Fenchel–Moreau). *Sea $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propia con al menos una minorante afín. Entonces:*

(I) f^{**} es la mayor función convexa y cerrada que minoriza a f ; equivalentemente, $\text{epi } f^{**} = \text{cl conv}(\text{epi } f)$. Se dice que f^{**} es la **envolvente convexa cerrada** (closed convex hull / convexification) de f , y se escribe $f^{**} = \text{cl conv } f$.

(II) $f^{**} = f$ si y solo si f es convexa y cerrada.

Demostración (esquema, señalando dónde entra la separación). Sea $g = \text{cl conv } f$ la mayor minorante convexa cerrada de f (existe: es el supremo de todas las minorantes convexas cerradas, que es convexo y cerrado, y la hipótesis de la minorante afín garantiza que es propia). Queremos $f^{**} = g$.

Paso 1: $f^{**} \leq g$. Ya vimos que f^{**} es convexa, cerrada y $\leq f$; como g es la mayor con esas propiedades, $f^{**} \leq g$.

Paso 2: $g \leq f^{**}$, el paso donde entra la separación. Basta probar que toda función convexa cerrada propia es el supremo de sus minorantes afines; aplicado a g (cuyas minorantes afines son las mismas que las de f , pues una función afín queda debajo de f si y solo si queda debajo de g , por maximalidad de g), esto da $g = \sup\{\text{minorantes afines de } f\} = f^{**}$.

Sea pues g convexa cerrada propia, $x_0 \in \mathbb{R}^n$ y $t_0 < g(x_0)$ cualquier altura estrictamente por debajo de la gráfica. El punto $(x_0, t_0) \in \mathbb{R}^n \times \mathbb{R}$ no pertenece al conjunto $\text{epi } g$, que es convexo (porque g es convexa) y cerrado (porque g es cerrada). **Aquí se invoca el teorema de separación estricta** del capítulo de separación: existe un hiperplano en $\mathbb{R}^{n+1}$ que separa estrictamente el punto compacto $\{(x_0, t_0)\}$ del convexo cerrado $\text{epi } g$: hay $(q, s) \in \mathbb{R}^n \times \mathbb{R}$, $(q, s) \neq 0$, y $\alpha \in \mathbb{R}$ con

$$\langle q, x \rangle + s t > \alpha > \langle q, x_0 \rangle + s t_0 \quad \text{para todo } (x, t) \in \text{epi } g.$$

Como $\text{epi } g$ contiene rayos verticales hacia arriba ($t \rightarrow +\infty$ con x fijo), necesariamente $s \geq 0$ (si $s < 0$, el lado izquierdo se iría a $-\infty$ y violaría la desigualdad). Quedan dos casos:

- *Caso no vertical* ($s > 0$). Dividiendo entre s y reordenando, la desigualdad sobre los puntos $(x, g(x)) \in \text{epi } g$ da una función afín $a(x) = -\frac{1}{s} \langle q, x \rangle + \frac{\alpha}{s}$ con $a \leq g$ y $a(x_0) > t_0$: una minorante afín que supera la altura t_0 en x_0 .
- *Caso vertical* ($s = 0$). La desigualdad separa x_0 de $\text{dom } g$ en $\mathbb{R}^n$, lo que solo puede pasar si $x_0 \notin \text{cl}(\text{dom } g)$. Se toma entonces cualquier minorante afín a_0 de g (existe por ser g propia, convexa y cerrada, de nuevo por separación aplicada a un punto bajo la gráfica) y se le suma un múltiplo grande del término de separación vertical: $a_\mu(x) = a_0(x) + \mu(\alpha - \langle q, x \rangle)$ con el signo dispuesto para que $\alpha - \langle q, x \rangle \leq 0$ en $\text{dom } g$. Cada a_μ sigue siendo minorante afín de g ,

y en x_0 el término agregado es estrictamente positivo, así que con μ suficientemente grande $a_\mu(x_0) > t_0$.

En ambos casos existe una minorante afín de g cuyo valor en x_0 supera t_0 . Como $t_0 < g(x_0)$ era arbitrario, el supremo de las minorantes afines en x_0 es al menos $g(x_0)$; la otra desigualdad es obvia, y el Paso 2 queda probado.

Parte (ii). Si f es convexa y cerrada (y propia), entonces $\text{cl conv } f = f$ y (i) da $f^{**} = f$. Recíprocamente, si $f^{**} = f$, entonces f es convexa y cerrada por ser una biconjugada (teorema 12.9). $\square$




Figura 12.2: Una función no convexa f (trazo continuo) y su biconjugada f^{**} (trazo discontinuo): coinciden fuera de la “joroba” central, pero f^{**} la reemplaza por el segmento que la puentea. Ninguna recta soporte puede ver la joroba: por eso la conjugación la borra.

Intuición

f^{**} es lo que “ve” de f un observador que solo puede apoyar reglas rectas por debajo de la gráfica. Todo lo que sobresalga hacia adentro de una concavidad local es invisible: la regla la puentea. En la figura 12.2, ninguna recta puede tocar la cresta central de la W sin atravesar la gráfica; el proceso conjuguar-conjugar sustituye la cresta por el puente. Conjugar es un resumen *con pérdida* para funciones no convexas, y *sin pérdida* exactamente para las convexas cerradas.

12.6.1. Aplicación económica: recuperar la tecnología desde el beneficio o el costo

Esta subsección desarrolla la aplicación estrella para Microeconomía ([9], cap. 5; [10], cap. 3).

El problema. El econometrista no observa la tecnología de la firma (su función de costo c , o su conjunto de producción Y). Observa *comportamiento ante precios*: beneficios $\pi(p)$ y ofertas $y(p)$. ¿Puede reconstruir la tecnología? La respuesta de la conjugación es exacta:

Proposición 12.16 (Dualidad costo–beneficio). *Sea $c: \mathbb{R} \rightarrow \mathbb{R} \cup \{+\infty\}$ una función de costo propia con alguna minorante afín, y $\pi = c^*$ la función de beneficio. Entonces la “tecnología recuperada” por el procedimiento dual*

$$\hat{c}(y) = \pi^*(y) = \sup_p \{py - \pi(p)\}$$

*satisface $\hat{c} = c^{**} = \text{cl conv } c$. En consecuencia:*

- (I) si c es convexa y cerrada, la recuperación es perfecta: $\hat{c} = c$;
- (II) si no, se recupera la envolvente convexa cerrada, y cualquier otra función de costo $\tilde{c}$ con $\text{cl conv } \tilde{c} = \text{cl conv } c$ genera exactamente la misma función de beneficio y es indistinguible de c con datos de mercado.

Demostración. Es el teorema de Fenchel–Moreau aplicado a c : $\pi^* = (c^*)^* = c^{**} = \text{cl conv } c$. Para (ii), si $\text{cl conv } \tilde{c} = \text{cl conv } c$ entonces $\tilde{c}^* = (\text{cl conv } \tilde{c})^* = (\text{cl conv } c)^* = c^*$, donde usamos que conjugar una función y conjugar su envolvente convexa cerrada da lo mismo (las minorantes afines son las mismas). $\square$

En la versión con conjuntos de producción es todavía más geométrico: $\pi = \sigma_Y = \delta_Y^*$ (ejemplo 12.8), y el conjunto recuperado por el procedimiento dual

$$\hat{Y} = \{y \in \mathbb{R}^n : \langle p, y \rangle \leq \pi(p) \text{ para todo } p\}$$

es $\hat{Y} = \text{cl conv } Y$: la biconjugada de la indicatriz es la indicatriz de la cápsula convexa cerrada, que es el teorema “conjunto = intersección de semiespacios soporte” del capítulo de separación, ahora deducido como caso particular de Fenchel–Moreau.

Observación 12.17 (Por qué esto importa en la práctica). Supón que la tecnología tiene una *no convexidad*: un costo fijo, una zona de rendimientos crecientes, indivisibilidades. Entonces $c \neq \text{cl conv } c$ y la proposición dice dos cosas. Primero, la firma maximizadora *nunca elige* producir en la zona donde $c > \text{cl conv } c$ (la “joroba” de la figura 12.2): ante cualquier precio, le conviene saltar entre los extremos del puente (por ejemplo, alternar entre no producir y producir a gran escala) antes que operar en la zona intermedia. Segundo, precisamente por eso los datos jamás revelan la joroba: la observación de mercado identifica la tecnología *solo hasta su cápsula convexa*. Esto no es una limitación del econometrista sino de la información contenida en el comportamiento optimizador. La misma lógica gobierna el par gasto–utilidad: de la función de gasto se recupera la preferencia solo hasta convexificar las curvas de indiferencia.

Ironing en diseño de mecanismos. La otra aparición estelar de la biconjugada en la teoría económica: en *screening* (Mussa–Rosen) y en subastas óptimas (Myerson), el diseñador maximiza un *virtual surplus* que puede no ser monótono/cóncavo donde hace falta; la restricción de factibilidad (monotonidad de la asignación) obliga a reemplazar la función problemática por su envolvente cóncava (o su biconjugada cóncava, mirando la integral acumulada), un procedimiento bautizado *ironing* (“planchado”): se aplanan las jorobas igual que en la figura 12.2, y en los tramos planchados el mecanismo óptimo agrupa tipos distintos en la misma asignación (*bunching*). La maquinaria matemática es exactamente $f \mapsto f^{**}$ (con signos cóncavos). Lo mismo pasa en taxación óptima a la Mirrlees cuando la solución “relajada” viola monotonidad.

12.7. Dualidad de Fenchel [P4]

La conjugación genera su propia teoría de dualidad para problemas de optimización, paralela a la dualidad lagrangiana del capítulo correspondiente. El formato estándar considera un objetivo

partido en dos piezas convexas:

$$(P) \quad v_P = \inf_{x \in \mathbb{R}^n} \{ f(x) + g(x) \},$$

con $f, g: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propias y convexas. El formato es menos restrictivo de lo que parece: una restricción $x \in C$ se codifica tomando $g = \delta_C$ (¡de nuevo las indicatrices trabajando gratis!), y muchos problemas con estructura “objetivo suave + término no suave” (regularización, penalizaciones) ya vienen partidos así.

El **problema dual de Fenchel** (*Fenchel dual*) es

$$(D) \quad v_D = \sup_{p \in \mathbb{R}^n} \{ -f^*(p) - g^*(-p) \}.$$

Proposición 12.18 (Dualidad débil de Fenchel). *Siempre $v_P \geq v_D$.*

Demostración. Fija x y p cualesquiera. Fenchel–Young dos veces:

$$f(x) + f^*(p) \geq \langle p, x \rangle, \quad g(x) + g^*(-p) \geq \langle -p, x \rangle = -\langle p, x \rangle.$$

Sumando, los productos internos se cancelan: $f(x) + g(x) \geq -f^*(p) - g^*(-p)$. Tomando ínfimo en x a la izquierda y supremo en p a la derecha, $v_P \geq v_D$. $\square$

Teorema 12.19 (Dualidad fuerte de Fenchel). *Sean f, g propias y convexas, y supongamos la condición de calificación (constraint qualification)*

$$\text{ri}(\text{dom } f) \cap \text{ri}(\text{dom } g) \neq \emptyset$$

(basta, por ejemplo, que exista un punto donde ambas son finitas y una de ellas es continua). Entonces $v_P = v_D$ y, si v_P es finito, el supremo dual se alcanza: existe p^ óptimo del dual.*

Idea de la demostración. Se define la *función de perturbación* $\varphi(u) = \inf_x \{ f(x) + g(x+u) \}$: cuánto mejora el valor óptimo si a g se le permite evaluar en un punto desplazado u . Un cálculo directo muestra que φ es convexa (es una inf-convolución, ejercicio mental con la convexidad conjunta) y que $v_P = \varphi(0)$, mientras que el dual (D) equivale a evaluar la biconjugada: $v_D = \varphi^{**}(0)$. La brecha de dualidad es entonces la diferencia entre $\varphi(0)$ y su convexificación cerrada en 0. La condición de calificación garantiza que $0 \in \text{ri}(\text{dom } \varphi)$, y un teorema del capítulo de funciones convexas dice que una función convexa propia coincide con su cerradura en el interior relativo de su dominio y es subdiferenciable ahí; el subgradiente $p^* \in \partial\varphi(0)$ que produce la separación (otra vez el teorema de separación, aplicado a $\text{epi } \varphi$ en el punto $(0, \varphi(0))$) es exactamente una solución óptima del dual. Los detalles están en [6], sec. 2.6, y [3]. $\square$

Observación 12.20 (Fenchel y Lagrange: la misma teoría con distinto empaque). La dualidad lagrangiana del capítulo anterior y la de Fenchel son intercambiables:

- *De Lagrange a Fenchel.* El dual lagrangiano de $\inf \{ f_0(x) : Ax = b \}$ se obtiene escribiendo el problema como $\inf_x \{ f_0(x) + \delta_{\{b\}}(Ax) \}$ y aplicando la versión de Fenchel con composición lineal. Con la convención del capítulo anterior ($L(x, \lambda) = f_0(x) + \langle \lambda, b - Ax \rangle$) la función dual

lagrangiana resulta ser

$$q(\lambda) = \inf_x \{f_0(x) - \langle A^\top \lambda, x \rangle\} + \langle b, \lambda \rangle = \langle b, \lambda \rangle - f_0^*(A^\top \lambda).$$

Es decir: *la conjugada del objetivo es el bloque con que se construye la dual lagrangiana*. Si ya calculaste f_0^* , la dual sale gratis.

- *De Fenchel a Lagrange*. (P) se reescribe con una variable duplicada: $\inf\{f(x) + g(z) : x - z = 0\}$. El lagrangiano es $f(x) + g(z) + \langle p, z - x \rangle$, y minimizar por separado en x y en z da

$$q(p) = \inf_x \{f(x) - \langle p, x \rangle\} + \inf_z \{g(z) + \langle p, z \rangle\} = -f^*(p) - g^*(-p),$$

exactamente el objetivo dual de Fenchel. El multiplicador de la restricción artificial $x = z$ es la variable dual p .

Moral: no hay dos dualidades, hay una, y conviene dominar el diccionario porque los libros de optimización usan Fenchel ([6, 3]) y los de economía usan Lagrange o argumentos de soporte directos ([9]).

Ejemplo 12.21 (Un problema resuelto por ambos lados). Resolvamos

$$v_P = \inf_{x \in \mathbb{R}} \left\{ \frac{x^2}{2} + |x - 1| \right\}, \quad f(x) = \frac{x^2}{2}, \quad g(x) = |x - 1|.$$

Lado primal. Para $x \leq 1$: el objetivo es $\frac{x^2}{2} + 1 - x$, con derivada $x - 1 \leq 0$: decrece hasta $x = 1$. Para $x \geq 1$: es $\frac{x^2}{2} + x - 1$, con derivada $x + 1 > 0$: crece. El mínimo es $x^* = 1$ con $v_P = \frac{1}{2} + 0 = \frac{1}{2}$.

Lado dual. Necesitamos las conjugadas. Ya sabemos $f^*(p) = p^2/2$. Para $g(x) = |x - 1|$ usamos las reglas (proposición 12.12): $g(x) = h(x - 1)$ con $h(x) = |x|$, y la conjugada del valor absoluto es la indicatriz de $[-1, 1]$:

$$h^*(p) = \sup_x \{px - |x|\} = \begin{cases} 0, & |p| \leq 1 \\ +\infty, & |p| > 1 \end{cases} = \delta_{[-1, 1]}(p),$$

(para $|p| \leq 1$ cada término $px - |x| \leq 0$ con igualdad en $x = 0$; para $|p| > 1$ se toma $x = tp$, $t \rightarrow +\infty$, y $px - |x| = t(p^2 - |p|) \rightarrow +\infty$). Por la regla de traslación, $g^*(p) = h^*(p) + p \cdot 1 = p + \delta_{[-1, 1]}(p)$. El dual es

$$v_D = \sup_p \{-f^*(p) - g^*(-p)\} = \sup_{|p| \leq 1} \left\{ -\frac{p^2}{2} + p \right\},$$

donde usamos $g^*(-p) = -p + \delta_{[-1, 1]}(-p)$ y que $\delta_{[-1, 1]}(-p) = \delta_{[-1, 1]}(p)$. La función $p - \frac{p^2}{2}$ es cóncava con derivada $1 - p$, nula en $p = 1$, que está justo en el borde del intervalo admisible: el máximo es $p^* = 1$ con $v_D = 1 - \frac{1}{2} = \frac{1}{2}$.

Verificación de la teoría. $v_P = v_D = \frac{1}{2}$: dualidad fuerte, como garantiza el teorema 12.19 ($\text{dom } f = \text{dom } g = \mathbb{R}$, la calificación es automática). Además las condiciones de optimalidad tipo Fenchel–Young se cumplen: $p^* = 1 \in \partial f(x^*) = \{f'(1)\} = \{1\}$ y $-p^* = -1 \in \partial g(x^*) = \partial|\cdot - 1|(1) = [-1, 1]$. El par $(x^*, p^*) = (1, 1)$ certifica la optimalidad de ambos lados sin necesidad

de comparar valores.

12.8. Resumen y ejercicios [P3]

Resumen del capítulo

- **Conjugada:** $f^*(p) = \sup_x \{ \langle p, x \rangle - f(x) \}$. Lectura geométrica: $-f^*(p)$ es la ordenada al origen de la recta soporte de pendiente p . Lectura económica: si $f = c$ es un costo, $f^* = \pi$ es el beneficio; el beneficio es la conjugada del costo.
- **Siempre convexa y cerrada:** f^* es supremo de afines, luego convexa y cerrada aunque f no lo sea. Por eso las funciones de beneficio son convexas en precios sin supuestos sobre la tecnología.
- **Fenchel–Young:** $f(x) + f^*(p) \geq \langle p, x \rangle$, con igualdad si y solo si $p \in \partial f(x)$, si y solo si x resuelve el supremo, y (para f convexa cerrada) si y solo si $x \in \partial f^*(p)$. Caso económico: lema de Hotelling, $y(p) \in \partial \pi(p)$.
- **Pares para memorizar:** $(\frac{x^2}{2}, \frac{p^2}{2})$ (autoconjugada); $(\frac{|x|^q}{q}, \frac{|p|^{q'}}{q'})$ con $\frac{1}{q} + \frac{1}{q'} = 1$; $(e^x, p \ln p - p \text{ en } p \geq 0)$; afín $\leftrightarrow$ indicatriz de un punto; $\delta_C \leftrightarrow \sigma_C$; $|x| \leftrightarrow \delta_{[-1,1]}$.
- **Fenchel–Moreau:** $f^{**} = \text{cl conv } f$ (envolvente convexa cerrada); $f^{**} = f$ si y solo si f es convexa cerrada propia. La demostración separa un punto bajo el epígrafo con el teorema de separación. Económicamente: de π (o de la función de gasto) se recupera la tecnología (o la preferencia) solo hasta su cápsula convexa; el *ironing* de mecanismos es una biconjugación.
- **Dualidad de Fenchel:** $\inf \{ f + g \} \geq \sup_p \{ -f^*(p) - g^*(-p) \}$, con igualdad y dual alcanzado si $\text{ri}(\text{dom } f) \cap \text{ri}(\text{dom } g) \neq \emptyset$. Es la dualidad lagrangiana del problema $\inf \{ f(x) + g(z) : x = z \}$.

Ejercicio 12.22. Sea $a > 0$ y $f(x) = a|x|$ en $\mathbb{R}$. Calcula f^* con el análisis de casos completo y da su interpretación geométrica.

Solución. Fijamos p y estudiamos $h_p(x) = px - a|x|$.

Caso $|p| \leq a$: para todo x , por la desigualdad $px \leq |p||x|$ tenemos $h_p(x) \leq |p||x| - a|x| = (|p| - a)|x| \leq 0$, y en $x = 0$ vale $h_p(0) = 0$. El supremo es 0, alcanzado en $x = 0$.

Caso $|p| > a$: tomamos $x = tp$ con $t > 0$ y hacemos $t \rightarrow +\infty$:

$$h_p(tp) = tp^2 - a t|p| = t|p|(|p| - a) \rightarrow +\infty,$$

pues $|p| - a > 0$. El supremo es $+\infty$.

Conclusión:

$$f^*(p) = \begin{cases} 0, & |p| \leq a, \\ +\infty, & |p| > a, \end{cases} \quad \text{es decir,} \quad f^* = \delta_{[-a,a]}.$$

Geometría: las únicas pendientes que admiten recta soporte bajo la “V” de pendientes $\pm a$ son las del intervalo $[-a, a]$, y la mejor recta de cada una pasa por el origen (ordenada al origen 0). Nota

la dualidad de formas: una función con un “pico” (no diferenciable en 0, con $\partial f(0) = [-a, a]$) tiene conjugada con un “piso” plano exactamente sobre $[-a, a]$, y viceversa. $\square$

Ejercicio 12.23. Calcula la conjugada de la barrera logarítmica

$$f(x) = \begin{cases} -\ln x, & x > 0, \\ +\infty, & x \leq 0. \end{cases}$$

Solución. Por la observación 12.2, el supremo se toma sobre el dominio: $f^*(p) = \sup_{x>0} \{px + \ln x\}$.

Caso $p \geq 0$: cuando $x \rightarrow +\infty$ tenemos $px \geq 0$ y $\ln x \rightarrow +\infty$, luego $px + \ln x \rightarrow +\infty$ y $f^*(p) = +\infty$. Geométricamente: como $-\ln x \rightarrow -\infty$ cuando $x \rightarrow \infty$, la gráfica baja sin cota y ninguna recta de pendiente $p \geq 0$ (que no baja) puede quedar debajo de ella en todo el dominio.

Caso $p < 0$: la función $x \mapsto px + \ln x$ es cóncava en $(0, \infty)$ (segunda derivada $-1/x^2 < 0$) con derivada $p + \frac{1}{x}$, que se anula en $x^* = -\frac{1}{p} > 0$. Sustituyendo,

$$f^*(p) = p\left(-\frac{1}{p}\right) + \ln\left(-\frac{1}{p}\right) = -1 - \ln(-p).$$

Conclusión:

$$f^*(p) = \begin{cases} -1 - \ln(-p), & p < 0, \\ +\infty, & p \geq 0. \end{cases}$$

Salvo constantes y signos, la barrera logarítmica es (casi) autoconjugada: $f^*(p) = f(-p) - 1$. Esta simetría es la razón de su papel central en métodos de punto interior ([5], [2]). $\square$

Ejercicio 12.24. Una firma tiene función de costo

$$c(y) = \begin{cases} \frac{y^2}{2}, & y \geq 0, \\ +\infty, & y < 0 \end{cases}$$

(no puede producir cantidades negativas). Calcula la función de beneficio $\pi = c^*$ para todo $p \in \mathbb{R}$ (incluidos precios negativos), determina la oferta $y(p)$ y verifica el lema de Hotelling $y(p) = \pi'(p)$, incluso en $p = 0$.

Solución. $\pi(p) = \sup_{y \geq 0} \{py - \frac{y^2}{2}\}$.

Caso $p \leq 0$: para $y \geq 0$, ambos términos son ≤ 0 : $py \leq 0$ y $-y^2/2 \leq 0$. El supremo es 0, alcanzado en $y = 0$ (con $p < 0$ es el único maximizador; con $p = 0$ también es único porque $-y^2/2 < 0$ si $y > 0$). La firma no produce: $y(p) = 0$.

Caso $p > 0$: el punto crítico interior $y = p > 0$ es admisible y la función es cóncava, así que

$$\pi(p) = p \cdot p - \frac{p^2}{2} = \frac{p^2}{2}, \quad y(p) = p.$$

En resumen,

$$\pi(p) = \frac{(\max\{p, 0\})^2}{2}, \quad y(p) = \max\{p, 0\}.$$

Verificación de Hotelling: para $p > 0$, $\pi'(p) = p = y(p)$; para $p < 0$, $\pi'(p) = 0 = y(p)$. En $p = 0$, las derivadas laterales son $\lim_{h \uparrow 0} \frac{\pi(h) - 0}{h} = 0$ y $\lim_{h \downarrow 0} \frac{h^2/2}{h} = 0$: π es diferenciable también ahí, con $\pi'(0) = 0 = y(0)$. La función π es convexa, no decreciente y diferenciable, aunque la restricción $y \geq 0$ “se activa” en $p \leq 0$: la conjugación suaviza la esquina porque el maximizador cambia de manera continua. (Si el costo tuviera un tramo lineal, π sí tendría una esquina y la oferta sería una correspondencia: exactamente $\partial\pi(p)$.) $\square$

Ejercicio 12.25. Para $f(x) = e^x$ (ejemplo 12.6): (a) verifica numéricamente la desigualdad de Fenchel–Young en el punto $x = 0$, $p = 2$; (b) para $p = 1$, encuentra el x que da la igualdad y comprueba las tres condiciones equivalentes del teorema 12.14.

Solución. (a) $f(0) = e^0 = 1$ y $f^*(2) = 2 \ln 2 - 2 \approx -0.614$. Entonces

$$f(0) + f^*(2) \approx 1 - 0.614 = 0.386 \geq \langle 2, 0 \rangle = 0. \checkmark$$

La holgura 0.386 mide cuán lejos está $x = 0$ de ser respuesta óptima a la “pendiente” $p = 2$ (la respuesta óptima sería $x = \ln 2$).

(b) Con $p = 1$: la igualdad exige $p = f'(x) = e^x$, es decir $x = 0$. Comprobamos las tres condiciones:

- (ii) Igualdad: $f(0) + f^*(1) = 1 + (1 \cdot \ln 1 - 1) = 1 - 1 = 0 = \langle 1, 0 \rangle$. $\checkmark$
- (iii) Supremo alcanzado: $h_1(x) = x - e^x$ tiene derivada $1 - e^x$, positiva si $x < 0$ y negativa si $x > 0$: máximo global en $x = 0$. $\checkmark$
- (i) Subgradiente: f es diferenciable y convexa, así que $\partial f(0) = \{f'(0)\} = \{1\} \ni 1$. $\checkmark$

Además, (iv): $x = 0$ debe pertenecer a $\partial f^*(1)$. Como $(f^*)'(p) = \ln p$ para $p > 0$, en efecto $(f^*)'(1) = \ln 1 = 0$. Las aplicaciones $x \mapsto e^x$ y $p \mapsto \ln p$ son inversas: los gradientes de un par conjugado se invierten mutuamente. $\square$

Ejercicio 12.26. Sea $f(x) = \min\{(x+1)^2, (x-1)^2\} = (|x| - 1)^2$, la función en “W” de la figura 12.2 (dos escalas eficientes de operación, en $x = -1$ y $x = 1$, con una zona intermedia ineficiente). Demuestra que

$$f^{**}(x) = \begin{cases} 0, & |x| \leq 1, \\ (|x| - 1)^2, & |x| > 1, \end{cases}$$

y da la interpretación económica.

Solución. Llamemos h a la función candidata. Por el teorema de Fenchel–Moreau basta probar que $h = \text{cl conv } f$, es decir: (1) h es convexa y cerrada, (2) $h \leq f$, y (3) toda minorante convexa cerrada de f queda debajo de h (o sea, h es la *mayor*).

(1) h es continua (los tres tramos empalman con valor 0 en $x = \pm 1$), y es convexa: en cada tramo lo es, y en los empalmes la derivada es creciente: $h'(x) = 2(x+1) \leq 0$ en $x < -1$, $h' = 0$ en $(-1, 1)$, $h'(x) = 2(x-1) \geq 0$ en $x > 1$; h' es no decreciente en todo $\mathbb{R}$, lo que caracteriza convexidad para funciones continuas derivables por tramos.

(2) $h \leq f$: fuera de $[-1, 1]$ son iguales; dentro, $h = 0 \leq (|x| - 1)^2 = f$.

(3) Sea g convexa con $g \leq f$. En los minimizadores de f : $g(-1) \leq f(-1) = 0$ y $g(1) \leq f(1) = 0$. Todo $x \in [-1, 1]$ se escribe como combinación convexa $x = \lambda(-1) + (1 - \lambda)(1)$ con $\lambda = \frac{1-x}{2} \in [0, 1]$, y la convexidad de g da

$$g(x) \leq \lambda g(-1) + (1 - \lambda) g(1) \leq 0 = h(x).$$

Fuera de $[-1, 1]$, $g \leq f = h$ directamente. Luego $g \leq h$ en todo punto.

Por (1)–(3), h es la mayor minorante convexa cerrada de f : $f^{**} = \text{cl conv } f = h$.

Interpretación. Si f es (una versión estilizada de) un costo con dos escalas eficientes, la firma nunca opera en la zona intermedia: ante cualquier precio le conviene mezclar en el tiempo (o entre plantas) las escalas -1 y 1 , obteniendo el costo del segmento, que es 0 . El mercado solo revela f^{**} ; la joroba central de f es económicamente invisible. Este es también el mecanismo del *ironing*: reemplazar la función por su envolvente y aceptar *bunching* en el tramo aplanado. $\square$

Ejercicio 12.27. Usando solo los pares conocidos y la proposición 12.12, calcula la conjugada de la función de costo cuadrática general

$$c(y) = \frac{\alpha}{2} y^2 + \beta y, \quad \alpha > 0, \beta \geq 0,$$

e interpreta cada pieza del resultado (con β como costo marginal mínimo).

Solución. Escribimos $c(y) = \alpha f(y) + \beta y$ con $f(y) = y^2/2$, $f^* = f$. Primero la escala vertical: $(\alpha f)^*(p) = \alpha f^*(p/\alpha) = \alpha \cdot \frac{(p/\alpha)^2}{2} = \frac{p^2}{2\alpha}$. Después la inclinación afín ($g = \tilde{f} + \langle a, \cdot \rangle$ con $a = \beta$ da $g^*(p) = \tilde{f}^*(p - \beta)$):

$$\pi(p) = c^*(p) = \frac{(p - \beta)^2}{2\alpha}.$$

(Verificación directa: $c'(y) = \alpha y + \beta = p$ da la oferta $y(p) = \frac{p - \beta}{\alpha}$ y $\pi(p) = p y(p) - c(y(p)) = \frac{(p - \beta)^2}{2\alpha}$, tras simplificar.)

Interpretación: β es el costo marginal de la primera unidad; el beneficio solo empieza a crecer cuando p supera β (para $p < \beta$ esta fórmula da la rama con $y < 0$; si se impone $y \geq 0$ como en el ejercicio 12.24, el beneficio es 0 en $p \leq \beta$). Y α , la curvatura del costo, aparece *invertida* en el beneficio: costos muy convexos (gran α , oferta rígida) dan beneficios poco sensibles al precio, y viceversa. La conjugación intercambia curvaturas: es la misma inversión $\nabla c \leftrightarrow \nabla \pi$ del teorema 12.14, y el germen de por qué en Micro las matrices de sustitución salen de segundas derivadas de funciones de valor ([9], cap. 5; [10]). $\square$

Capítulo 13

Programación lineal y aplicaciones

[P3]

Semana 10 del cronograma. Bibliografía: Nocedal y Wright [5], Cap. 13; Aragón et al. [1]; Li [4].

¿Para qué sirve esto en Microeconomía?

La programación lineal (PL) es el *laboratorio más limpio* para entender dos ideas que reaparecen en todo el análisis microeconómico moderno: los **precios sombra** y la **holgura complementaria**. En PL estas nociones se calculan a mano, sin tecnicismos de regularidad, y por eso conviene dominarlas aquí antes de reencontrarlas en contextos más abstractos:

- **Fallas de mercado: contratos y screening (MWG cap. 14):** las condiciones de holgura complementaria (“una restricción inactiva tiene multiplicador cero”) son exactamente el argumento con que se determina *qué restricciones de incentivos amarran* en un problema de selección adversa con tipos finitos; de hecho, fijada la asignación, el problema en las transferencias es un programa lineal (Sección 13.7.3).
- **Teoría de juegos (MWG cap. 8):** los juegos matriciales de suma cero se resuelven como un *par primal-dual* de programas lineales; el teorema minimax de von Neumann es, literalmente, dualidad fuerte en PL (Sección 13.7.1).
- **Equilibrio general (MWG caps. 15–18):** el análisis de actividades de Koopmans y los modelos lineales de producción describen la tecnología como un poliedro; los precios de equilibrio que “valoran” los recursos son las variables duales del programa de producción [9].
- **Bienestar e incentivos: diseño de mecanismos y subastas (MWG cap. 23):** el problema de asignación (matching) entre compradores y objetos es un PL de transporte; su dual entrega los precios que sostienen la asignación eficiente.

Prioridad 3: no es el corazón técnico del curso de Microeconomía, pero es el mejor campo de entrenamiento para KKT y dualidad, que sí lo son.

13.1. Motivación: el caso lineal [P3]

En los capítulos anteriores estudiamos problemas de optimización generales: condiciones KKT, dualidad lagrangiana, calificaciones de restricciones como la condición de Slater. Este capítulo se especializa en el caso en que *todo es lineal*: la función objetivo es lineal y las restricciones son igualdades o desigualdades lineales. A este tipo de problema se le llama **programa lineal** (*linear program*, LP).

¿Por qué dedicarle un capítulo a un caso particular? Por tres razones.

1. **Todo se puede calcular.** En PL la función dual lagrangiana $q(\lambda)$ se calcula en forma cerrada, la dualidad fuerte vale sin hipótesis adicionales (basta que el problema sea factible), y la holgura complementaria permite recuperar la solución dual desde la primal con álgebra elemental. Es el único contexto donde *toda* la maquinaria de los capítulos previos se ve funcionar de principio a fin sin supuestos técnicos.
2. **La geometría es visible.** La región factible es un poliedro (intersección de semiespacios), y el óptimo, cuando existe, se alcanza en un *vértice*. Esto conecta directamente con el capítulo de conos y cápsulas: los vértices son los puntos extremos del poliedro, y ya demostramos que una función lineal alcanza su óptimo en un punto extremo.
3. **La economía lo usa por todas partes.** Producción con tecnología lineal, el problema de la dieta, transporte y asignación, juegos de suma cero, contratos con tipos finitos: todos son programas lineales o pares primal–dual de programas lineales.

Un ejemplo concreto que nos acompañará todo el capítulo:

Ejemplo 13.1 (Problema de producción). Una empresa fabrica dos bienes. El bien 1 se vende a 3 soles por unidad y el bien 2 a 5 soles por unidad. Producir requiere tres recursos escasos:

- horas de la planta A: cada unidad del bien 1 usa 1 hora; disponibles 4 horas;
- horas de la planta B: cada unidad del bien 2 usa 2 horas; disponibles 12 horas;
- horas de la planta C: cada unidad del bien 1 usa 3 horas y cada unidad del bien 2 usa 2 horas; disponibles 18 horas.

Si $x_1, x_2 \geq 0$ denotan las cantidades producidas, el problema de maximizar el ingreso es

$$\begin{aligned}
 \underset{x_1, x_2}{\text{máx}} \quad & 3x_1 + 5x_2 \\
 \text{s.a.} \quad & x_1 \leq 4, \\
 & 2x_2 \leq 12, \\
 & 3x_1 + 2x_2 \leq 18, \\
 & x_1 \geq 0, \ x_2 \geq 0.
 \end{aligned} \tag{13.1}$$

Lo resolveremos gráficamente en la Sección 13.3, armaremos su dual en la Sección 13.4 y lo interpretaremos económicamente en la Sección 13.5.

13.2. Formas estándar y canónica [P3]

Un programa lineal puede venir escrito de muchas maneras: minimizar o maximizar, con desigualdades $\leq$ o $\geq$, con igualdades, con variables que pueden ser negativas. Para la teoría y los algoritmos conviene fijar *formatos de referencia* y saber convertir cualquier LP a ellos.

Definición 13.2 (Forma estándar). Un LP está en **forma estándar** (*standard form*) si se escribe

$$\min_{x \in \mathbb{R}^n} \langle c, x \rangle \quad \text{s.a.} \quad Ax = b, \quad x \geq 0, \quad (13.2)$$

donde $c \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, A es una matriz $m \times n$, y $x \geq 0$ significa $x_j \geq 0$ para cada componente $j = 1, \dots, n$. Es decir: *minimización*, restricciones de *igualdad* y todas las variables *no negativas*.

Definición 13.3 (Forma canónica). Un LP está en **forma canónica** (*canonical form*) si se escribe

$$\max_{x \in \mathbb{R}^n} \langle c, x \rangle \quad \text{s.a.} \quad Ax \leq b, \quad x \geq 0, \quad (13.3)$$

esto es: *maximización*, restricciones de *desigualdad* $\leq$ y variables no negativas. (La desigualdad vectorial $Ax \leq b$ se lee fila por fila: $\langle a_i, x \rangle \leq b_i$ para $i = 1, \dots, m$, donde $a_i^\top$ es la fila i de A .)

La forma estándar es la que usan los algoritmos (símplex, puntos interiores); la canónica es la más cómoda para la dualidad y para las aplicaciones económicas. El problema de producción (13.1) ya está en forma canónica con

$$c = \begin{pmatrix} 3 \\ 3 \\ 5 \end{pmatrix}, \quad A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 3 & 2 \end{pmatrix}, \quad b = \begin{pmatrix} 4 \\ 12 \\ 18 \end{pmatrix}.$$

Conversión entre formas: las cuatro operaciones

Cualquier LP se convierte a forma estándar (o canónica) con cuatro trucos mecánicos. Conviene memorizarlos porque se usan constantemente.

(T1) De max a min (y viceversa). Maximizar $\langle c, x \rangle$ equivale a minimizar $\langle -c, x \rangle$; los óptimos x^* son los mismos y los valores óptimos difieren en el signo: $\max \langle c, x \rangle = -\min \langle -c, x \rangle$.

(T2) De desigualdad a igualdad: variables de holgura. La restricción $\langle a_i, x \rangle \leq b_i$ equivale a

$$\langle a_i, x \rangle + s_i = b_i, \quad s_i \geq 0,$$

donde s_i es una nueva variable llamada **de holgura** (*slack variable*): mide cuánto “sobra” del recurso i . Para $\langle a_i, x \rangle \geq b_i$ se resta una variable de **excedente** (*surplus variable*): $\langle a_i, x \rangle - e_i = b_i$ con $e_i \geq 0$.

(T3) De igualdad a desigualdades. La igualdad $\langle a_i, x \rangle = b_i$ equivale al par $\langle a_i, x \rangle \leq b_i$ y $-\langle a_i, x \rangle \leq -b_i$.

(T4) Variables libres como diferencia de no negativas. Si x_j no tiene restricción de signo

(variable *libre*), se reemplaza por

$$x_j = x_j^+ - x_j^-, \quad x_j^+ \geq 0, \quad x_j^- \geq 0.$$

Todo número real es diferencia de dos no negativos (por ejemplo, $-7 = 0 - 7$), así que no se pierde ninguna solución.

Ejemplo 13.4 (Conversión a forma estándar, paso a paso). Conviertamos a forma estándar el problema

$$\max_{x_1, x_2} 2x_1 - x_2 \quad \text{s.a.} \quad x_1 + x_2 \leq 5, \quad x_1 - 3x_2 \geq -2, \quad x_1 \geq 0,$$

donde x_2 es libre (puede ser negativa).

Paso 1 ($\max \rightarrow \min$, T1). El problema equivale a $\min(-2x_1 + x_2)$ con las mismas restricciones.

Paso 2 (variable libre, T4). Escribimos $x_2 = u - v$ con $u, v \geq 0$. El objetivo queda $-2x_1 + u - v$ y las restricciones

$$x_1 + u - v \leq 5, \quad x_1 - 3u + 3v \geq -2, \quad x_1, u, v \geq 0.$$

Paso 3 (desigualdades $\rightarrow$ igualdades, T2). Introducimos la holgura $s_1 \geq 0$ en la primera restricción y el excedente $e_2 \geq 0$ en la segunda:

$$x_1 + u - v + s_1 = 5, \quad x_1 - 3u + 3v - e_2 = -2.$$

Paso 4 (ensamblar). Con el vector de variables $z = (x_1, u, v, s_1, e_2)^\top \in \mathbb{R}^5$, el problema en forma estándar (13.2) tiene

$$c = (-2, 1, -1, 0, 0)^\top, \quad A = \begin{pmatrix} 1 & 1 & -1 & 1 & 0 \\ 1 & -3 & 3 & 0 & -1 \end{pmatrix}, \quad b = \begin{pmatrix} 5 \\ -2 \end{pmatrix}.$$

Observa que las variables auxiliares tienen costo cero: no cambian el valor óptimo, solo “reformatan” el problema. Si el valor óptimo del problema en forma estándar es p^* , el del problema original (de maximización) es $-p^*$ por (T1).

Observación 13.5. Las conversiones (T1)–(T4) preservan el conjunto de soluciones en el siguiente sentido: hay una correspondencia entre puntos factibles de un formato y del otro que preserva el valor del objetivo (salvo el signo en T1). Por eso “resolver el LP en forma estándar” resuelve el problema original. El precio es aumentar la dimensión: el Ejemplo 13.4 pasó de 2 variables a 5.

Cuidado (error común)

Tres errores frecuentes al convertir:

- **Olvidar el signo del valor óptimo con (T1).** El $\arg \max$ y el $\arg \min$ coinciden, pero el *valor* cambia de signo. Si el examen pide el valor óptimo del problema original,

recuerda deshacer el cambio.

- **Poner la holgura con el signo equivocado.** En $\langle a, x \rangle \leq b$ la holgura se *suma* ($\langle a, x \rangle + s = b$); en $\langle a, x \rangle \geq b$ se *resta*. Un truco de verificación: la variable auxiliar siempre debe ser ≥ 0 en un punto factible. Si con tu signo saldría negativa, lo escribiste al revés.
- **Tratar una variable libre como si fuera no negativa.** Si el enunciado no dice $x_j \geq 0$, la variable es libre y hay que aplicar (T4); ignorarlo puede eliminar precisamente al óptimo.

13.3. Geometría: poliedros y vértices [P3]

13.3.1. La región factible es un poliedro

Definición 13.6 (Poliedro). Un **poliedro** (*polyhedron*) es un conjunto de la forma

$$P = \{x \in \mathbb{R}^n : Ax \leq b\},$$

es decir, una intersección finita de semiespacios cerrados $\{x : \langle a_i, x \rangle \leq b_i\}$. Un poliedro acotado se llama **politopo** (*polytope*).

Como cada semiespacio es convexo y cerrado, y la intersección de convexos cerrados es convexa y cerrada (capítulo de conjuntos convexos), todo poliedro es *convexo y cerrado*. La región factible de cualquier LP es un poliedro: las igualdades $\langle a_i, x \rangle = b_i$ se escriben como dos desigualdades, y las condiciones $x_j \geq 0$ son desigualdades lineales.

Definición 13.7 (Vértice o punto extremo). Un punto $v \in P$ es un **vértice** (*vertex*) o **punto extremo** de P si no puede escribirse como combinación convexa estricta de otros dos puntos de P : no existen $y, z \in P$ con $y \neq z$ y $\lambda \in (0, 1)$ tales que $v = \lambda y + (1 - \lambda)z$. (Es la misma definición de punto extremo del capítulo de conos y cápsulas, aplicada al convexo P .)

13.3.2. Soluciones básicas: el álgebra de los vértices

Los vértices tienen una descripción puramente algebraica que es la base del método símplex. Trabajemos con la forma estándar: sea

$$P = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\},$$

donde A es $m \times n$ con $\text{rango}(A) = m$ (si hubiera filas redundantes, se eliminan) y $m \leq n$.

Definición 13.8 (Base, solución básica, solución básica factible). Denotemos por $A_j \in \mathbb{R}^m$ la columna j de A .

- Una **base** (*basis*) es un conjunto de índices $B \subseteq \{1, \dots, n\}$ con $|B| = m$ tal que las columnas $\{A_j : j \in B\}$ son linealmente independientes (equivalentemente, la submatriz A_B formada por esas columnas es invertible).

- La **solución básica** (*basic solution*) asociada a B es el único $x \in \mathbb{R}^n$ que cumple $Ax = b$ con $x_j = 0$ para todo $j \notin B$. Concretamente: $x_B = A_B^{-1}b$ y $x_N = 0$, donde N es el complemento de B . Las variables x_j con $j \in B$ se llaman **básicas**; las demás, **no básicas**.
- Si además $x_B \geq 0$ (o sea, $x \in P$), decimos que x es una **solución básica factible** (*basic feasible solution*, SBF).

Ejemplo 13.9 (Enumeración completa de soluciones básicas). Consideremos la región en $\mathbb{R}^2$ dada por

$$x_1 + x_2 \leq 4, \quad x_1 + 3x_2 \leq 6, \quad x_1, x_2 \geq 0.$$

En forma estándar, con holguras $s_1, s_2 \geq 0$:

$$A = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 3 & 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 4 \\ 6 \end{pmatrix}, \quad x = (x_1, x_2, s_1, s_2)^\top \geq 0.$$

Aquí $m = 2$, $n = 4$: cada base elige 2 de las 4 columnas. Hay a lo más $\binom{4}{2} = 6$ bases posibles. Vamos una por una (para cada base fijamos en cero las variables no básicas y resolvemos el sistema 2×2):

- $B = \{3, 4\}$ (las dos holguras): $s_1 = 4$, $s_2 = 6$. Solución $(0, 0, 4, 6)$: **SBF**, corresponde al origen $(x_1, x_2) = (0, 0)$.
- $B = \{1, 4\}$: $x_1 = 4$ (de la primera ecuación) y $s_2 = 6 - 4 = 2$. Solución $(4, 0, 0, 2)$: **SBF**, punto $(4, 0)$.
- $B = \{1, 2\}$: sistema $x_1 + x_2 = 4$, $x_1 + 3x_2 = 6$. Restando: $2x_2 = 2$, luego $x_2 = 1$, $x_1 = 3$. Solución $(3, 1, 0, 0)$: **SBF**, punto $(3, 1)$.
- $B = \{2, 3\}$: de la segunda ecuación $3x_2 = 6$, o sea $x_2 = 2$; de la primera, $s_1 = 4 - 2 = 2$. Solución $(0, 2, 2, 0)$: **SBF**, punto $(0, 2)$.
- $B = \{2, 4\}$: de la primera ecuación $x_2 = 4$; entonces $s_2 = 6 - 12 = -6 < 0$. Solución básica $(0, 4, 0, -6)$: *no factible* (el punto $(0, 4)$ viola $x_1 + 3x_2 \leq 6$).
- $B = \{1, 3\}$: de la segunda ecuación $x_1 = 6$; entonces $s_1 = 4 - 6 = -2 < 0$. Solución básica $(6, 0, -2, 0)$: *no factible* (el punto $(6, 0)$ viola $x_1 + x_2 \leq 4$).

Las cuatro SBF corresponden exactamente a los cuatro vértices del polígono factible en el plano: $(0, 0)$, $(4, 0)$, $(3, 1)$ y $(0, 2)$. Las otras dos soluciones básicas son intersecciones de rectas de restricción que caen *fuera* de la región. Este patrón es general, como dice el siguiente teorema.

Teorema 13.10 (Vértices = soluciones básicas factibles). Sea $P = \{x : Ax = b, x \geq 0\}$ con $\text{rango}(A) = m$. Un punto $x \in P$ es un vértice de P si y solo si las columnas $\{A_j : x_j > 0\}$ son linealmente independientes, es decir, si y solo si x es una solución básica factible para alguna base B .

Demostración. ($\Leftarrow$) Sea x una SBF con soporte $S = \{j : x_j > 0\}$ y columnas $\{A_j\}_{j \in S}$ linealmente independientes. Supongamos $x = \lambda y + (1 - \lambda)z$ con $y, z \in P$, $\lambda \in (0, 1)$. Para $j \notin S$ tenemos $x_j = 0$; como $y_j, z_j \geq 0$ y $\lambda y_j + (1 - \lambda)z_j = 0$ con $\lambda \in (0, 1)$, forzosamente $y_j = z_j = 0$.

Entonces y y z tienen soporte contenido en S , y de $Ay = Az = b$ se sigue $A(y - z) = 0$, o sea $\sum_{j \in S} (y_j - z_j)A_j = 0$. Por independencia lineal, $y_j = z_j$ para todo $j \in S$, luego $y = z$. Así x no es combinación convexa estricta de puntos distintos: es vértice.

($\Rightarrow$) Por contrarrecíproco: supongamos que las columnas $\{A_j\}_{j \in S}$ son linealmente *dependientes*. Entonces existe $d \neq 0$ con soporte en S tal que $Ad = 0$. Para $\varepsilon > 0$ pequeño, los puntos $y = x + \varepsilon d$ y $z = x - \varepsilon d$ cumplen $Ay = Az = b$, y como $x_j > 0$ para $j \in S$ (y $d_j = 0$ fuera de S), también $y, z \geq 0$ si ε es suficientemente chico. Pero $x = \frac{1}{2}y + \frac{1}{2}z$ con $y \neq z$, así que x no es vértice. (Si $|S| < m$, las columnas independientes de S se completan a una base con otras columnas de A , lo que muestra que todo vértice es SBF de alguna base.) $\square$

Intuición

Un vértice es un punto donde “se acaban los grados de libertad”: hay tantas restricciones activas linealmente independientes como dimensiones. En forma estándar, cada variable no básica en cero es una restricción $x_j \geq 0$ activa; junto con las m ecuaciones $Ax = b$, el punto queda completamente determinado. Por eso una SBF tiene a lo más m componentes positivas: el sistema “se cierra” y no queda dirección alguna en la que moverse sin salir de P . La demostración del teorema es exactamente esa idea: si hay dependencia lineal, sobra un grado de libertad (d con $Ad = 0$) y el punto puede “deslizarse” en dos sentidos, luego no es extremo.

Observación 13.11 (Degeneración). Distintas bases pueden producir la *misma* SBF: ocurre cuando alguna variable básica vale cero (más de n restricciones activas pasan por el mismo punto, como tres rectas concurrentes en el plano). Una SBF así se llama **degenerada** (*degenerate*). La degeneración no afecta la teoría pero complica al método símplex (Sección 13.6).

13.3.3. El teorema fundamental de la programación lineal

Teorema 13.12 (Teorema fundamental de la PL). *Considera el LP en forma estándar (13.2) con región factible $P = \{x : Ax = b, x \geq 0\} \neq \emptyset$.*

(I) *P tiene al menos un vértice.*

(II) *Si el valor óptimo es finito, entonces existe un vértice de P que es solución óptima.*

En consecuencia, para resolver un LP basta examinar el conjunto finito de soluciones básicas factibles.

Demostración. (i) P está contenido en el ortante $x \geq 0$, así que *no contiene rectas completas* (una recta tiene puntos con alguna coordenada tan negativa como se quiera). Por el resultado del capítulo de conos y cápsulas, todo convexo cerrado no vacío que no contiene rectas posee al menos un punto extremo; en un poliedro, los puntos extremos son sus vértices.

(ii) Por el teorema de representación de poliedros (Minkowski–Weyl, visto en el capítulo de conos y cápsulas), P se descompone como

$$P = \text{conv}\{v^1, \dots, v^k\} + \text{cono}\{r^1, \dots, r^p\},$$

donde $v^1, \dots, v^k$ son los vértices de P y $r^1, \dots, r^p$ generan su cono de recesión. Todo $x \in P$ se escribe entonces como

$$x = \sum_{i=1}^k \lambda_i v^i + \sum_{\ell=1}^p \mu_\ell r^\ell, \quad \lambda_i \geq 0, \sum_i \lambda_i = 1, \mu_\ell \geq 0.$$

Si el valor óptimo $p^* = \inf_{x \in P} \langle c, x \rangle$ es finito, entonces $\langle c, r^\ell \rangle \geq 0$ para todo rayo ℓ (si algún $\langle c, r^\ell \rangle < 0$, moverse por ese rayo haría $\langle c, x \rangle \rightarrow -\infty$, contradiciendo que p^* es finito). Luego, para todo $x \in P$,

$$\langle c, x \rangle = \sum_i \lambda_i \langle c, v^i \rangle + \sum_\ell \mu_\ell \langle c, r^\ell \rangle \geq \sum_i \lambda_i \langle c, v^i \rangle \geq \min_{1 \leq i \leq k} \langle c, v^i \rangle,$$

porque un promedio ponderado nunca es menor que el mínimo de los términos. Tomando el ínfimo sobre $x \in P$ resulta $p^* \geq \min_i \langle c, v^i \rangle$; y como cada v^i es factible, también $p^* \leq \min_i \langle c, v^i \rangle$. Por lo tanto el mínimo se alcanza en el vértice v^{i^*} que minimiza $\langle c, v^i \rangle$. $\square$

Intuición

Una función lineal no tiene “curvatura”: sobre un segmento, su valor es un promedio de los valores en los extremos, así que nunca le conviene quedarse en el interior. Empujando siempre hacia donde el objetivo mejora, se termina en la frontera; dentro de la frontera (una cara del poliedro), el mismo argumento empuja hacia una cara de dimensión menor, y así sucesivamente hasta llegar a una cara de dimensión cero: un vértice. Este es el mismo principio que en Micro hace que, con tecnología lineal, la producción óptima “se especialice” en actividades extremas en lugar de mezclar todo un poco.

13.3.4. Resolución gráfica de un LP en dos variables

Para LP con dos variables, el Teorema 13.12 da un método gráfico completo:

Estrategia de examen

Receta para resolver un LP 2D gráficamente (y cómo presentarla en un examen):

1. Dibuja cada recta de restricción $\langle a_i, x \rangle = b_i$ y sombrea el semiplano factible (evalúa en un punto de prueba, típicamente el origen).
2. Identifica la región factible (intersección de los semiplanos) y calcula *todos* sus vértices resolviendo los sistemas 2×2 de las rectas que se cortan (verifica que el punto de corte sea factible).
3. Dibuja una curva de nivel del objetivo $\langle c, x \rangle = k$ y determina la dirección de crecimiento: es el vector gradiente c , perpendicular a las curvas de nivel.
4. Desliza la curva de nivel en la dirección de mejora hasta el último punto de contacto con la región: ese contacto es el óptimo (un vértice, o toda una arista si la curva de nivel es paralela a ella).

5. *Verificación*: evalúa el objetivo en todos los vértices; el mejor valor debe coincidir con el del paso 4. En un examen, esta tabla de vértices es la forma más segura de justificar la respuesta.

Si la región es no acotada, revisa además si el objetivo mejora indefinidamente a lo largo de algún rayo de la región: en ese caso el LP es *no acotado* y no hay óptimo.

Ejemplo 13.13 (Resolución gráfica del problema de producción). Resolvamos (13.1): $\max 3x_1 + 5x_2$ sujeto a $x_1 \leq 4$, $2x_2 \leq 12$, $3x_1 + 2x_2 \leq 18$, $x \geq 0$.

Paso 1–2: región y vértices. Las rectas relevantes son $x_1 = 4$, $x_2 = 6$ y $3x_1 + 2x_2 = 18$. Intersecando por pares (y descartando cortes no factibles) se obtienen los vértices:


$$(0, 0), \quad (4, 0), \quad (4, 3), \quad (2, 6), \quad (0, 6).$$

Por ejemplo, $(4, 3)$ resuelve $x_1 = 4$ y $3x_1 + 2x_2 = 18$ (pues $12 + 2x_2 = 18$ da $x_2 = 3$), y $(2, 6)$ resuelve $x_2 = 6$ y $3x_1 + 2x_2 = 18$ (pues $3x_1 + 12 = 18$ da $x_1 = 2$). El corte de $x_1 = 4$ con $x_2 = 6$ es $(4, 6)$, que viola $3(4) + 2(6) = 24 > 18$: no es vértice de la región.

Paso 3–5: curvas de nivel y tabla de vértices. Las curvas de nivel $3x_1 + 5x_2 = k$ son rectas de pendiente $-3/5$; el objetivo crece en la dirección $c = (3, 5)$. Evaluamos:

vértice	$z = 3x_1 + 5x_2$
$(0, 0)$	0
$(4, 0)$	12
$(4, 3)$	27
$(2, 6)$	36
$(0, 6)$	30

El máximo es $z^* = 36$ en $x^* = (2, 6)$: producir 2 unidades del bien 1 y 6 del bien 2. En el óptimo, las restricciones de las plantas B y C están *activas* ($2 \cdot 6 = 12$ y $3 \cdot 2 + 2 \cdot 6 = 18$), mientras que la planta A tiene holgura: se usan $2 < 4$ horas. Guardemos este dato: será clave para la dualidad.



La figura muestra la región factible (sombreada), tres curvas de nivel del objetivo (discontinuas)

y el óptimo: la curva de nivel $z = 36$ toca la región por última vez exactamente en el vértice $(2, 6)$.

13.4. Dualidad en programación lineal [P2]

13.4.1. El dual desde la dualidad lagrangiana

En el capítulo de dualidad lagrangiana definimos, para un problema general de minimización, la función dual $q(\lambda) = \inf_x L(x, \lambda)$ y el problema dual $\max_{\lambda} q(\lambda)$. Apliquemos esa construcción, *sin atajos*, al LP en forma estándar

$$p^* = \min_x \langle c, x \rangle \quad \text{s.a.} \quad Ax = b, \quad x \geq 0.$$

Tratamos las igualdades $Ax = b$ con un multiplicador libre $\lambda \in \mathbb{R}^m$ (uno por ecuación, sin restricción de signo, como corresponde a igualdades) y mantenemos la restricción sencilla $x \geq 0$ dentro del ínfimo. El lagrangiano es

$$L(x, \lambda) = \langle c, x \rangle + \langle \lambda, b - Ax \rangle = \langle b, \lambda \rangle + \langle c - A^\top \lambda, x \rangle,$$

donde usamos $\langle \lambda, Ax \rangle = \langle A^\top \lambda, x \rangle$ (definición de transpuesta). La función dual es

$$q(\lambda) = \inf_{x \geq 0} L(x, \lambda) = \langle b, \lambda \rangle + \inf_{x \geq 0} \langle c - A^\top \lambda, x \rangle.$$

Calculemos ese ínfimo componente por componente. El término es $\sum_{j=1}^n (c_j - (A^\top \lambda)_j) x_j$ con cada $x_j \geq 0$ independiente:

- si $c_j - (A^\top \lambda)_j < 0$ para algún j , tomando $x_j \rightarrow +\infty$ el término va a $-\infty$: el ínfimo es $-\infty$;
- si $c_j - (A^\top \lambda)_j \geq 0$ para todo j , lo mejor es $x = 0$ y el ínfimo vale 0.

Por lo tanto

$$q(\lambda) = \begin{cases} \langle b, \lambda \rangle & \text{si } A^\top \lambda \leq c, \\ -\infty & \text{en otro caso.} \end{cases} \quad (13.4)$$

El problema dual $\max_{\lambda} q(\lambda)$ descarta automáticamente los λ con $q(\lambda) = -\infty$ (nunca son óptimos), así que queda

$$d^* = \max_{\lambda \in \mathbb{R}^m} \langle b, \lambda \rangle \quad \text{s.a.} \quad A^\top \lambda \leq c. \quad (13.5)$$

El dual de un LP es otro LP: objetivo lineal $\langle b, \lambda \rangle$, restricciones lineales $A^\top \lambda \leq c$, variables libres. Los datos se intercambian de papel: el vector de recursos b pasa al objetivo, el vector de costos c pasa a las restricciones, y la matriz se transpone.

El mismo cálculo aplicado a la forma canónica (útil para las aplicaciones económicas) da el par simétrico que usaremos de aquí en adelante:

$$\boxed{\begin{array}{ll} \text{(P)} & \max \langle c, x \rangle \quad \text{s.a. } Ax \leq b, \quad x \geq 0, \\ \text{(D)} & \min \langle b, y \rangle \quad \text{s.a. } A^\top y \geq c, \quad y \geq 0, \end{array}} \quad (13.6)$$

con una variable dual $y_i \geq 0$ por cada restricción primal $\langle a_i, x \rangle \leq b_i$ y una restricción dual por

cada variable primal. (El signo $y_i \geq 0$ proviene de que en un problema de maximización con restricción $\leq$, relajar la restricción solo puede ayudar; es el mismo convenio de signos de KKT.) Un cálculo directo (o aplicar dos veces la construcción lagrangiana) muestra que *el dual del dual es el primal*: la dualidad en PL es una involución perfecta.

13.4.2. Reglas de construcción del dual

En la práctica los LP vienen mezclados: algunas restricciones de igualdad, otras de desigualdad, variables libres y no negativas. Las reglas generales (que se deducen todas con el mismo cálculo lagrangiano de arriba) se resumen en la tabla siguiente. Léela por filas: cada objeto del primal genera un objeto del dual.

Primal: máx $\langle c, x \rangle$	Dual: mín $\langle b, y \rangle$
restricción i : $\langle a_i, x \rangle \leq b_i$	variable $y_i \geq 0$
restricción i : $\langle a_i, x \rangle \geq b_i$	variable $y_i \leq 0$
restricción i : $\langle a_i, x \rangle = b_i$	variable y_i libre
variable $x_j \geq 0$	restricción j : $\langle A_j, y \rangle \geq c_j$
variable $x_j \leq 0$	restricción j : $\langle A_j, y \rangle \leq c_j$
variable x_j libre	restricción j : $\langle A_j, y \rangle = c_j$

Aquí $a_i^\top$ es la fila i de A y A_j la columna j . Regla mnemotécnica: en el sentido máx $\rightarrow$ mín, restricciones “naturales” ($\leq$ en el max) generan variables “naturales” ($y_i \geq 0$), las igualdades generan variables libres, y viceversa para las variables. Si el primal es de minimización, se leen las filas de derecha a izquierda.

Ejemplo 13.14 (Dual del problema de producción). El problema (13.1) es un max con tres restricciones $\leq$ y dos variables ≥ 0 . Su dual tiene tres variables $y_1, y_2, y_3 \geq 0$ (una por planta) y dos restricciones (una por bien):

$$\begin{aligned}
 &\min_y \quad 4y_1 + 12y_2 + 18y_3 \\
 &\text{s.a.} \quad y_1 + 3y_3 \geq 3, \quad (\text{columna del bien 1}) \\
 &\quad \quad 2y_2 + 2y_3 \geq 5, \quad (\text{columna del bien 2}) \\
 &\quad \quad y_1, y_2, y_3 \geq 0.
 \end{aligned} \tag{13.7}$$

Verifica cómo se armó: la columna del bien 1 en A es $(1, 0, 3)^\top$ y su costo es 3, de ahí $1 \cdot y_1 + 0 \cdot y_2 + 3 \cdot y_3 \geq 3$. Resolveremos este dual sin ningún cálculo adicional en el Ejemplo 13.19, usando holgura complementaria.

13.4.3. Dualidad débil y fuerte

Teorema 13.15 (Dualidad débil). Sean x factible para el primal (P) de (13.6) y y factible para el dual (D) . Entonces

$$\langle c, x \rangle \leq \langle b, y \rangle.$$

En consecuencia: (i) el valor óptimo primal nunca supera al dual ($p^* \leq d^*$); (ii) si $\langle c, x \rangle = \langle b, y \rangle$ para un par factible, entonces x es óptimo primal e y es óptimo dual; (iii) si el primal es no acotado, el dual es infactible, y si el dual es no acotado (hacia $-\infty$), el primal es infactible.

Demostración. Todo sale de encadenar dos desigualdades de productos escalares con vectores no negativos. Como $y \geq 0$ y $Ax \leq b$ (componente a componente),

$$\langle y, Ax \rangle \leq \langle y, b \rangle = \langle b, y \rangle.$$

Como $x \geq 0$ y $A^\top y \geq c$,

$$\langle c, x \rangle \leq \langle A^\top y, x \rangle = \langle y, Ax \rangle.$$

Juntando: $\langle c, x \rangle \leq \langle y, Ax \rangle \leq \langle b, y \rangle$, que es lo afirmado. Las consecuencias (i)–(iii) son inmediatas: (ii) porque ningún punto factible primal puede superar $\langle b, y \rangle$ y x ya lo alcanza (y simétricamente para y); (iii) porque si existiera un punto factible del otro problema, acotaría al primero. $\square$

Teorema 13.16 (Dualidad fuerte en PL). *Si el primal (P) tiene solución óptima x^* , entonces el dual (D) tiene solución óptima y^* y los valores coinciden:*

$$\langle c, x^* \rangle = \langle b, y^* \rangle.$$

Más aún, si ambos problemas son factibles, ambos tienen solución óptima y $p^* = d^*$. La brecha de dualidad (duality gap) en PL solo puede ser distinta de cero cuando alguno de los dos problemas es infactible.

No damos la demostración completa (puede hacerse con el lema de Farkas del capítulo de separación, o constructivamente con el método símplex: al terminar, el símplex entrega los multiplicadores óptimos como subproducto; puedes ver [5], cap. 13, y [1]). Lo importante es el contraste con el caso no lineal:

Observación 13.17 (En PL no hace falta Slater). En programación convexa general, la dualidad fuerte requiere una *calificación de restricciones* como la condición de Slater (existencia de un punto estrictamente factible). En PL **no**: basta que el problema sea factible, aunque toda la región tenga interior vacío (por ejemplo, si hay igualdades). La razón de fondo es que las restricciones lineales no pueden “curvarse” y generar los fenómenos de frontera que rompen la dualidad en el caso no lineal; técnicamente, la separación de poliedros siempre puede hacerse de manera *propia* (lema de Farkas), sin necesidad de puntos interiores. Este es un hecho que conviene citar con precisión en un examen: “*las calificaciones de restricciones se satisfacen automáticamente cuando las restricciones son afines*”.

13.4.4. Holgura complementaria

Teorema 13.18 (Holgura complementaria). *Sean x^* factible para (P) e y^* factible para (D) en (13.6). Entonces x^* e y^* son óptimos de sus respectivos problemas si y solo si*

$$y_i^* \cdot (b_i - \langle a_i, x^* \rangle) = 0 \quad \text{para todo } i = 1, \dots, m, \quad (13.8)$$

$$x_j^* \cdot (\langle A_j, y^* \rangle - c_j) = 0 \quad \text{para todo } j = 1, \dots, n. \quad (13.9)$$

En palabras: (i) si una restricción primal tiene holgura, su precio dual es cero; si un precio dual es positivo, su restricción está activa. (ii) si una variable primal es positiva, su restricción dual está activa; si una restricción dual tiene holgura, la variable primal correspondiente es cero.

Demostración. Recorramos la cadena de la dualidad débil con lupa:

$$\langle c, x^* \rangle \stackrel{(\alpha)}{\leq} \langle A^\top y^*, x^* \rangle = \langle y^*, Ax^* \rangle \stackrel{(\beta)}{\leq} \langle b, y^* \rangle.$$

La brecha total es la suma de dos términos no negativos:

$$\langle b, y^* \rangle - \langle c, x^* \rangle = \underbrace{\langle y^*, b - Ax^* \rangle}_{\text{brecha } (\beta)} + \underbrace{\langle A^\top y^* - c, x^* \rangle}_{\text{brecha } (\alpha)} = \sum_{i=1}^m y_i^* (b_i - \langle a_i, x^* \rangle) + \sum_{j=1}^n x_j^* (\langle A_j, y^* \rangle - c_j).$$

Cada sumando es producto de dos números no negativos (por factibilidad de x^* e y^*), luego es ≥ 0 .

($\Rightarrow$) Si x^* e y^* son óptimos, la dualidad fuerte (Teorema 13.16) da $\langle b, y^* \rangle - \langle c, x^* \rangle = 0$: una suma de términos no negativos que vale cero obliga a que *cada* término sea cero. Eso es exactamente (13.8)–(13.9).

($\Leftarrow$) Si valen (13.8)–(13.9), todos los sumandos son cero, luego $\langle c, x^* \rangle = \langle b, y^* \rangle$, y por la parte (ii) de la dualidad débil ambos puntos son óptimos. $\square$

Intuición

Piensa en y_i^* como el *precio sombra* del recurso i . La holgura complementaria dice dos cosas muy razonables:

- **Recurso sobrante, precio cero.** Si en el óptimo sobra recurso i ($\langle a_i, x^* \rangle < b_i$), tener un poco más de ese recurso no aumentaría el ingreso: su valor marginal es $y_i^* = 0$. Es la lógica de los bienes libres en equilibrio general: lo que abunda no tiene precio.
- **Actividad usada, costo justo.** Si la actividad j se realiza ($x_j^* > 0$), el costo de los recursos que consume, valuados a precios sombra, es exactamente igual a su ingreso unitario ($\langle A_j, y^* \rangle = c_j$): la actividad no deja ni ganancia ni pérdida contable. Si en cambio los recursos que consumiría valen más de lo que genera ($\langle A_j, y^* \rangle > c_j$), la actividad no se usa ($x_j^* = 0$).

Esta es la misma condición de holgura complementaria de KKT ($\mu_i g_i(x^*) = 0$), pero en PL se puede *explotar algebraicamente* para calcular una solución a partir de la otra, como muestra el siguiente ejemplo.

Ejemplo 13.19 (Recuperar la solución dual desde la primal). Ya sabemos (Ejemplo 13.13) que el óptimo primal del problema de producción es $x^* = (2, 6)$ con valor 36. Usemos la holgura complementaria para hallar $y^* = (y_1^*, y_2^*, y_3^*)$ del dual (13.7) *sin resolver el dual directamente*.

Paso 1: ¿qué restricciones primales tienen holgura? En $x^* = (2, 6)$:

$$x_1^* = 2 < 4 \quad (\text{holgura } 2), \quad 2x_2^* = 12 = 12 \quad (\text{activa}), \quad 3x_1^* + 2x_2^* = 18 = 18 \quad (\text{activa}).$$

Por (13.8), la primera restricción tiene holgura positiva, así que su precio es cero:

$$y_1^* = 0.$$

Paso 2: ¿qué variables primales son positivas? Ambas: $x_1^* = 2 > 0$ y $x_2^* = 6 > 0$. Por (13.9), las dos restricciones duales deben estar activas (cumplirse con igualdad):

$$y_1^* + 3y_3^* = 3, \quad 2y_2^* + 2y_3^* = 5.$$

Paso 3: resolver el sistema. Con $y_1^* = 0$, la primera ecuación da $3y_3^* = 3$, es decir $y_3^* = 1$. Sustituyendo en la segunda: $2y_2^* + 2 = 5$, o sea $y_2^* = 3/2$. Así

$$y^* = \left(0, \frac{3}{2}, 1\right).$$

Paso 4: verificación completa. (a) Factibilidad dual: $y^* \geq 0$; $0 + 3(1) = 3 \geq 3$ y $2(3/2) + 2(1) = 5 \geq 5$. (b) Valor dual:

$$4(0) + 12\left(\frac{3}{2}\right) + 18(1) = 0 + 18 + 18 = 36 = \langle c, x^* \rangle.$$

Los valores coinciden, así que por dualidad débil (parte (ii) del Teorema 13.15) ambos puntos son óptimos. Hemos resuelto dos programas lineales al precio de uno.

Cuidado (error común)

Al usar holgura complementaria para recuperar la solución dual:

- Las implicaciones van en un solo sentido: “holgura positiva $\Rightarrow$ precio cero”, pero *no* “restricción activa $\Rightarrow$ precio positivo”. Puede ocurrir $y_i^* = 0$ con la restricción i activa (degeneración dual). Por eso el sistema que arma la holgura complementaria puede tener varias soluciones: cualquiera que además sea *factible dual* sirve, y siempre debes verificar factibilidad y coincidencia de valores al final.
- No mezcles los papeles: (13.8) relaciona restricciones *primales* con variables *duales*; (13.9), variables *primales* con restricciones *duales*. Un error típico de examen es imponer “restricción dual con holgura $\Rightarrow$ precio dual cero”, que no significa nada.

13.5. Interpretación económica de la dualidad [P2]

13.5.1. El dual valora los recursos: precios sombra

Volvamos al problema de producción (13.1) y su dual (13.7), con óptimos $x^* = (2, 6)$ e $y^* = (0, 3/2, 1)$. La lectura económica del dual es la siguiente.

- **Las variables duales son precios de los recursos.** y_i^* es el **precio sombra** (*shadow price*) del recurso i : el valor marginal, en unidades del objetivo, de una unidad adicional de ese recurso. Aquí: una hora extra en la planta B vale 3/2 soles de ingreso adicional; una hora extra en la planta C vale 1 sol; una hora extra en la planta A no vale nada ($y_1^* = 0$), porque

ya sobran horas. Formalmente, si $V(b)$ denota el valor óptimo como función del vector de recursos, entonces $y_i^* = \partial V / \partial b_i$ donde la derivada exista; este es el teorema de la envolvente en su versión más limpia [11].

- **El objetivo dual es el valor contable de la dotación.** $\langle b, y \rangle = 4y_1 + 12y_2 + 18y_3$ es lo que valen *todos* los recursos de la empresa a los precios y . El dual busca los precios que *minimizan* el valor imputado de la dotación, sujeto a que ningún producto quede subvaluado.
- **Las restricciones duales son condiciones de no arbitraje.** La restricción $\langle A_j, y \rangle \geq c_j$ dice: *el costo imputado de los recursos que consume una unidad de la actividad j debe cubrir su ingreso unitario*. Si existiera un producto con $\langle A_j, y \rangle < c_j$, los precios y subvaluarían los recursos: alguien podría “comprar” los insumos a esos precios, producir el bien j y obtener ganancia pura. Los precios sombra óptimos eliminan toda oportunidad de arbitraje, y por holgura complementaria las actividades efectivamente usadas ($x_j^* > 0$) tienen ganancia contable exactamente cero: $\langle A_j, y^* \rangle = c_j$.
- **Dualidad fuerte = agotamiento del producto.** La igualdad $\langle c, x^* \rangle = \langle b, y^* \rangle$ dice que el ingreso máximo de la empresa es exactamente el valor de su dotación de recursos a precios sombra: todo el ingreso se “imputa” a los recursos, sin residuo. Es el análogo lineal del teorema de agotamiento del producto con rendimientos constantes a escala, y la puerta de entrada al análisis de actividades de Koopmans en equilibrio general [9].

Intuición

Una manera de fijar la historia: imagina que un *comprador externo* ofrece alquilar todos los recursos de la empresa, pagando y_i por unidad del recurso i . Para que a la empresa le convenga aceptar en lugar de producir, cada actividad que podría realizar debe rendirle, vendiendo sus insumos, al menos lo que rendiría produciendo: $\langle A_j, y \rangle \geq c_j$ para todo j . El comprador, por su parte, quiere pagar lo mínimo: $\min \langle b, y \rangle$. La dualidad fuerte dice que en el óptimo el comprador paga *exactamente* el ingreso máximo de la empresa: los precios sombra transfieren todo el valor, ni más ni menos. El dual no es un truco algebraico: es el problema de *valorar la empresa por sus recursos*.

13.5.2. El problema de la dieta

El ejemplo dual clásico, propuesto por Stigler en los años cuarenta, invierte los papeles de costos y requerimientos.

Ejemplo 13.20 (Problema de la dieta (*diet problem*)). Hay n alimentos con precios $c_1, \dots, c_n$ y m nutrientes. El alimento j aporta N_{ij} unidades del nutriente i por unidad consumida, y una dieta saludable requiere al menos r_i unidades del nutriente i . El consumidor busca la dieta más barata:

$$\min_{x \geq 0} \langle c, x \rangle \quad \text{s.a.} \quad Nx \geq r.$$

Por las reglas de la tabla (léidas en el sentido $\min \rightarrow \max$), el dual es

$$\max_{y \geq 0} \langle r, y \rangle \quad \text{s.a.} \quad N^\top y \leq c.$$

Interpretación: y_i es el *precio por unidad del nutriente i* . Imagina un vendedor de píldoras de nutrientes puros que quiere reemplazar la comida: elige precios $y_i \geq 0$ para maximizar el ingreso de vender la canasta requerida r , pero con la restricción competitiva de que “reconstruir” cualquier alimento j con píldoras no cueste más que el alimento mismo ($\sum_i N_{ij}y_i \leq c_j$); si costara más, nadie le compraría. La dualidad fuerte dice que el gasto mínimo en comida coincide con el ingreso máximo del vendedor de píldoras: los nutrientes, no los alimentos, son lo que de verdad se está comprando, y el dual revela sus precios implícitos. La holgura complementaria completa el cuadro: los alimentos que *no* entran en la dieta óptima son exactamente los que, a precios de nutrientes, están sobrevaluados ($\sum_i N_{ij}y_i^* < c_j$), y los nutrientes consumidos en exceso del requerimiento tienen precio cero.

13.5.3. Análisis de sensibilidad: validez de los precios sombra

El precio sombra y_i^* mide el efecto de una unidad *marginal* de recurso, pero solo mientras el cambio en b_i no altere *qué* restricciones están activas en el óptimo (es decir, mientras la base óptima no cambie). El **análisis de sensibilidad** (*sensitivity analysis*) calcula el rango $[b_i - \Delta^-, b_i + \Delta^+]$ en el que el precio sombra sigue siendo válido; fuera de ese rango, la función valor $V(b)$, que es cóncava y lineal a trozos en b , cambia de pendiente y el precio sombra salta a un valor menor.

Ejemplo 13.21 (Sensibilidad en el problema de producción). En (13.1), aumentemos las horas de la planta B: $12 + \Delta$. Mientras las restricciones activas sigan siendo las de B y C, el óptimo se mueve al corte de $2x_2 = 12 + \Delta$ con $3x_1 + 2x_2 = 18$:

$$x_2 = 6 + \frac{\Delta}{2}, \quad x_1 = \frac{18-12-\Delta}{3} = 2 - \frac{\Delta}{3},$$

con valor $z(\Delta) = 3(2 - \Delta/3) + 5(6 + \Delta/2) = 36 + \frac{3}{2}\Delta$: efectivamente cada hora extra vale $y_2^* = 3/2$. Pero esto exige $x_1 \geq 0$ (o sea $\Delta \leq 6$) y $x_1 \leq 4$ (o sea $\Delta \geq -6$): el precio sombra $3/2$ vale en el rango $\Delta \in [-6, 6]$, es decir, para $b_2 \in [6, 18]$. Con $\Delta > 6$ la producción del bien 1 llegaría a cero, la base óptima cambia y horas adicionales de B pasan a valer menos.

13.6. Algoritmos: símplex y puntos interiores [P4]

Esta sección es conceptual: interesa la *idea* de cada algoritmo y su conexión con la teoría, no la mecánica de tablas. La referencia detallada es [5], cap. 13; ver también [4] para ejemplos trabajados y [8] para el contexto general.

13.6.1. El método símplex: caminar por los vértices

El Teorema 13.12 reduce el LP a un problema finito: examinar las soluciones básicas factibles. Pero enumerarlas todas es inviable ($\binom{n}{m}$ crece explosivamente). El **método símplex** (*simplex method*, Dantzig, 1947) organiza la búsqueda:

1. **Empezar** en una SBF (un vértice). Si no se conoce ninguna, una *fase I* auxiliar la encuentra resolviendo otro LP cuyo vértice inicial es obvio.

2. **Moverse a un vértice vecino que mejore el objetivo.** Dos vértices son vecinos si sus bases difieren en una sola columna: el paso consiste en dejar entrar a la base una variable no básica cuyo *costo reducido* indica mejora, y sacar la variable básica que primero llega a cero al moverse por la arista correspondiente.
3. **Detenerse** cuando ningún vecino mejora. Por convexidad del problema, ese vértice es óptimo global: en un LP, un óptimo local sobre los vértices es global (la verificación de optimalidad del simplex equivale a exhibir una solución dual factible con el mismo valor, es decir, un certificado de dualidad).

¿Por qué termina? En cada paso el objetivo mejora estrictamente (si no hay degeneración), y hay un número finito de vértices, así que ninguno se repite y el proceso acaba en un óptimo o detecta que el problema es no acotado (una arista infinita por la que el objetivo mejora sin cota). Con **degeneración** (Observación 13.11) puede haber pasos que cambian de base sin moverse del vértice ni mejorar el objetivo, y en teoría el método podría *ciclar* visitando las mismas bases; reglas de selección cuidadosas (como la regla de Bland, que elige siempre el índice elegible más pequeño) garantizan la terminación. En la práctica el simplex es notablemente rápido, aunque existen ejemplos contruidos a propósito (cubo de Klee–Minty) donde visita exponencialmente muchos vértices.

Un subproducto valioso: al terminar, el simplex entrega *gratis* la solución dual óptima $y^* = (A_B^{-1})^\top c_B$ (los “multiplicadores simplex” de la base final), lo que da una demostración constructiva de la dualidad fuerte.

13.6.2. Puntos interiores: atravesar el poliedro

La alternativa moderna (Karmarkar, 1984) renuncia a los vértices y viaja por el *interior* de la región factible. La conexión con los capítulos de penalización y barreras es directa: se reemplaza la restricción $x \geq 0$ por una **barrera logarítmica** (*log barrier*) que castiga acercarse a la frontera:

$$\min_x \langle c, x \rangle - \mu \sum_{j=1}^n \ln x_j \quad \text{s.a.} \quad Ax = b,$$

con parámetro $\mu > 0$. Para cada μ el problema es *estrictamente convexo* en el interior y tiene un único minimizador $x(\mu)$; la curva $\{x(\mu) : \mu > 0\}$ se llama **trayectoria central** (*central path*). Cuando $\mu \downarrow 0$, la barrera pesa cada vez menos y $x(\mu)$ converge a una solución óptima del LP. El algoritmo sigue la trayectoria numéricamente: para el μ actual da uno o dos pasos de Newton hacia $x(\mu)$, reduce μ , y repite. Las condiciones de optimalidad del problema con barrera son exactamente las condiciones KKT del LP con la holgura complementaria *perturbada*: $x_j s_j = \mu$ en lugar de $x_j s_j = 0$ (donde $s = c - A^\top \lambda$ es la holgura dual), lo que muestra que el método resuelve simultáneamente el primal y el dual, cerrando la brecha de dualidad a medida que $\mu \rightarrow 0$. A diferencia del simplex, los métodos de puntos interiores tienen complejidad polinomial garantizada y son los más eficientes en problemas muy grandes y ralos [5, 2].

Observación 13.22. Para un economista, la moraleja algorítmica es doble. El simplex formaliza la intuición de “comparar esquinas”: con tecnología lineal, las soluciones óptimas son especializadas y se encuentran intercambiando una actividad por otra en el margen. Los puntos interiores

formalizan la intuición de “precios que se ajustan gradualmente”: la trayectoria central es una familia de asignaciones aproximadamente óptimas cuyos multiplicadores convergen a los precios sombra. Ambas lecturas reaparecen en los algoritmos de cómputo de equilibrios.

13.7. Aplicaciones [P3]

13.7.1. Juegos matriciales de suma cero

Un **juego matricial de suma cero** (*two-person zero-sum game*) se describe por una matriz A de tamaño $m \times n$: si el jugador fila elige la fila i y el jugador columna elige la columna j , la fila recibe a_{ij} y la columna paga a_{ij} . Una **estrategia mixta** (*mixed strategy*) de la fila es un vector de probabilidades $x \in \Delta_m = \{x \in \mathbb{R}^m : x \geq 0, \sum_i x_i = 1\}$; análogamente $y \in \Delta_n$ para la columna. El pago esperado es $x^\top Ay = \sum_{i,j} x_i a_{ij} y_j$.

El problema del jugador fila. La fila quiere garantizarse un pago alto *contra lo peor que pueda hacer la columna*. Si la fila juega x , la columna responderá con la columna j que minimice el pago esperado $\sum_i x_i a_{ij} = (A^\top x)_j$. La fila resuelve entonces

$$\max_{x \in \Delta_m} \min_{1 \leq j \leq n} (A^\top x)_j.$$

El truco estándar convierte este max–min en un LP: se introduce una variable v (el pago garantizado) y se exige que *todas* las columnas rindan al menos v :

$$\begin{aligned} \max_{x,v} \quad & v \\ \text{s.a.} \quad & \sum_{i=1}^m a_{ij} x_i \geq v, \quad j = 1, \dots, n, \\ & \sum_{i=1}^m x_i = 1, \quad x \geq 0, \quad v \text{ libre.} \end{aligned} \tag{13.10}$$

Proposición 13.23 (El dual es el problema del jugador columna). *El dual del LP (13.10) es*

$$\begin{aligned} \min_{y,w} \quad & w \\ \text{s.a.} \quad & \sum_{j=1}^n a_{ij} y_j \leq w, \quad i = 1, \dots, m, \\ & \sum_{j=1}^n y_j = 1, \quad y \geq 0, \quad w \text{ libre,} \end{aligned} \tag{13.11}$$

que es exactamente el problema del jugador columna: $\min_{y \in \Delta_n} \max_i (Ay)_i$, garantizarse pagar poco contra la mejor respuesta de la fila.

Demostración. Escribimos (13.10) con las restricciones en formato $\leq$: $v - \sum_i a_{ij} x_i \leq 0$ para cada j , más la igualdad $\sum_i x_i = 1$. Aplicamos la tabla de reglas: cada desigualdad j genera una variable dual $y_j \geq 0$; la igualdad genera una variable libre w . El objetivo dual es $\langle b, (y, w) \rangle = 0 \cdot y + 1 \cdot w = w$ (los lados derechos de las desigualdades son cero y el de la igualdad es uno). Las restricciones duales, una por variable primal: la variable $x_i \geq 0$ (coeficiente 0 en el objetivo, $-a_{ij}$ en la desigualdad j , 1 en la igualdad) genera $\sum_j (-a_{ij}) y_j + w \geq 0$, es decir $\sum_j a_{ij} y_j \leq w$; la variable libre v (coeficiente 1 en el objetivo y 1 en cada desigualdad) genera la igualdad $\sum_j y_j = 1$. Eso es (13.11). $\square$

Teorema 13.24 (Teorema minimax de von Neumann). *Todo juego matricial tiene un **valor** v^* y estrategias mixtas óptimas $x^* \in \Delta_m$, $y^* \in \Delta_n$:*

$$\max_{x \in \Delta_m} \min_{y \in \Delta_n} x^\top A y = \min_{y \in \Delta_n} \max_{x \in \Delta_m} x^\top A y = v^*.$$

Demostración. El LP (13.10) es factible (cualquier $x \in \Delta_m$ con v suficientemente negativo) y acotado (con $\sum_i x_i = 1$, ninguna columna puede rendir más que $\max_{ij} a_{ij}$, así que $v \leq \max_{ij} a_{ij}$). Por el Teorema 13.16 (dualidad fuerte), el primal (13.10) y el dual (13.11) tienen soluciones óptimas con el mismo valor $v^* = w^*$. Además, el mínimo de $x^\top A y$ sobre $y \in \Delta_n$ se alcanza siempre en una columna pura (una función lineal sobre el simplex se minimiza en un vértice, de nuevo el Teorema 13.12 en miniatura), y análogamente el máximo sobre $x \in \Delta_m$ se alcanza en una fila pura; por eso el valor óptimo del primal es el max–min y el del dual es el min–max. La igualdad de ambos es el teorema. $\square$

Ejemplo 13.25 (Un juego 2×2 resuelto por completo). Sea el juego con matriz de pagos (a la fila)

$$A = \begin{pmatrix} 3 & -1 \\ -2 & 2 \end{pmatrix}.$$

No hay equilibrio en estrategias puras. El mejor pago garantizado puro es

$$\max\{\min(3, -1), \min(-2, 2)\} = -1 \quad (\text{fila}), \quad \min\{\max(3, -2), \max(-1, 2)\} = 2 \quad (\text{columna});$$

como $-1 < 2$, hay que mezclar.

Jugador fila. Con $x = (p, 1-p)$, los pagos esperados contra cada columna pura son

$$\text{col. 1: } 3p - 2(1-p) = 5p - 2, \quad \text{col. 2: } -p + 2(1-p) = 2 - 3p.$$

El LP (13.10) maximiza $v = \min\{5p - 2, 2 - 3p\}$. Como una recta crece en p y la otra decrece, el máximo del mínimo está donde se cruzan (si el cruce cae en $[0, 1]$, cosa que hay que verificar):

$$5p - 2 = 2 - 3p \implies 8p = 4 \implies p = \frac{1}{2}, \quad v^* = 5 \cdot \frac{1}{2} - 2 = \frac{1}{2}.$$

Estrategia óptima $x^* = (1/2, 1/2)$, valor del juego $v^* = 1/2$.

Jugador columna (vía el dual). Con $y = (q, 1-q)$, los pagos esperados de cada fila pura son

$$\text{fila 1: } 3q - (1-q) = 4q - 1, \quad \text{fila 2: } -2q + 2(1-q) = 2 - 4q.$$

El dual (13.11) minimiza $w = \max\{4q - 1, 2 - 4q\}$:

$$4q - 1 = 2 - 4q \implies q = \frac{3}{8}, \quad w^* = 4 \cdot \frac{3}{8} - 1 = \frac{1}{2}.$$

Estrategia óptima $y^* = (3/8, 5/8)$ y $w^* = 1/2 = v^*$: los valores primal y dual coinciden, confirmando la dualidad fuerte.

Lectura por holgura complementaria. Ambas variables $x_i^* > 0$, así que ambas restricciones duales están activas: contra y^* , las dos filas rinden exactamente $1/2$ (verifícalo: $4 \cdot 3/8 - 1 = 1/2$

y $2 - 4 \cdot 3/8 = 1/2$). Y ambas $y_j^* > 0$, así que contra x^* ambas columnas rinden exactamente $1/2$. Esta es la *condición de indiferencia* de los equilibrios mixtos en teoría de juegos: cada jugador mezcla solo entre acciones que le dan el mismo pago esperado, y esa condición es holgura complementaria del par primal–dual.

13.7.2. Transporte y asignación

Ejemplo 13.26 (Problema de transporte). Hay m orígenes (plantas) con ofertas $s_1, \dots, s_m$ y n destinos (mercados) con demandas $d_1, \dots, d_n$, con $\sum_i s_i = \sum_j d_j$ (mercado balanceado). Enviar una unidad de i a j cuesta c_{ij} . Si $x_{ij} \geq 0$ es la cantidad enviada de i a j , el planificador resuelve

$$\min_{x \geq 0} \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \quad \text{s.a.} \quad \sum_{j=1}^n x_{ij} = s_i \quad \forall i, \quad \sum_{i=1}^m x_{ij} = d_j \quad \forall j.$$

Es un LP con mn variables y $m + n$ restricciones de igualdad. Su dual, con variables libres u_i (una por origen) y v_j (una por destino), es

$$\max_{u, v} \sum_{i=1}^m s_i u_i + \sum_{j=1}^n d_j v_j \quad \text{s.a.} \quad u_i + v_j \leq c_{ij} \quad \forall i, j.$$

Interpretación económica: $-u_i$ es el precio del bien en el origen i y v_j su precio en el destino j (los niveles absolutos son indeterminados: sumar una constante a todos los u y restarla a todos los v no cambia nada; solo los *diferenciales* importan). La restricción dual $u_i + v_j \leq c_{ij}$ es de nuevo *no arbitraje espacial*: el margen que se gana comprando en i y vendiendo en j no puede exceder el costo de transporte; y por holgura complementaria, las rutas efectivamente usadas ($x_{ij}^* > 0$) cumplen $u_i^* + v_j^* = c_{ij}$: en las rutas activas, el diferencial de precios cubre exactamente el flete. Es el modelo básico de integración de mercados y la versión finita del problema de transporte óptimo.

Observación 13.27 (Asignación y matching). El caso particular $m = n$, $s_i = d_j = 1$ es el **problema de asignación** (*assignment problem*): asignar n trabajadores a n tareas (o compradores a objetos) minimizando el costo total, con $x_{ij} \in \{0, 1\}$. A primera vista es un problema *entero*, pero la relajación lineal ($0 \leq x_{ij}$, con las igualdades de oferta y demanda) tiene una propiedad notable: sus vértices son exactamente las matrices de permutación (teorema de Birkhoff–von Neumann: el politopo de matrices doblemente estocásticas es la cápsula convexa de las permutaciones). Por el Teorema 13.12, resolver el LP ya entrega una asignación entera: la linealidad “regala” la integralidad. Las variables duales (u_i, v_j) son los salarios/precios que *sostienen* el matching eficiente: cada pareja asignada cumple $u_i^* + v_j^* = c_{ij}$ y ninguna pareja no asignada podría bloquear. Esta estructura es la base del modelo de matching con transferencias (Shapley–Shubik, Becker) y de las subastas de objetos múltiples en diseño de mecanismos [9].

13.7.3. Screening con tipos finitos como programa lineal

En los modelos de selección adversa (*screening*) con un número finito de tipos (el monopolista que diseña un menú de contratos, el regulador frente a una firma con costo desconocido [10, 9]),

el principal elige, para cada tipo θ_k ($k = 1, \dots, K$), una asignación q_k y una transferencia t_k , sujeto a restricciones de *participación* (IR) y de *compatibilidad de incentivos* (IC):

$$\theta_k v(q_k) - t_k \geq 0 \quad \forall k, \quad \theta_k v(q_k) - t_k \geq \theta_k v(q_\ell) - t_\ell \quad \forall k, \ell.$$

Observa la estructura: *fijadas las asignaciones* $(q_1, \dots, q_K)$, tanto el objetivo del principal (esperanza de las transferencias menos costos) como todas las restricciones IR e IC son *lineales en las transferencias* $(t_1, \dots, t_K)$. El problema de extraer el máximo pago dado el menú de cantidades es, por lo tanto, un *programa lineal*, y toda la tecnología de este capítulo aplica:

- la solución está en un vértice del poliedro de transferencias factibles, es decir, en un punto donde “suficientes” restricciones IR/IC están activas (Teorema 13.10);
- la holgura complementaria del LP identifica *cuáles* amarran: con las condiciones usuales de orden en los tipos, resultan activas la IR del tipo más bajo y las IC “hacia abajo” adyacentes, exactamente el patrón que se enseña en teoría de contratos; las demás restricciones tienen multiplicador cero y pueden ignorarse;
- los multiplicadores duales de las IC miden el costo marginal (en renta informacional) de cada restricción de incentivos, y alimentan la fórmula de distorsión “virtual” del óptimo.

En cursos avanzados este enfoque se explota computacionalmente: los problemas de diseño de mecanismos con tipos finitos se resuelven literalmente con un solver de PL.

13.8. Resumen y ejercicios [P3]

Resumen del capítulo

- **Formas.** Todo LP se lleva a forma estándar (mín $\langle c, x \rangle$, $Ax = b$, $x \geq 0$) o canónica (máx $\langle c, x \rangle$, $Ax \leq b$, $x \geq 0$) con cuatro trucos: cambiar signo del objetivo, holguras/excedentes, partir igualdades, y variables libres como $x_j^+ - x_j^-$.
- **Geometría.** La región factible es un poliedro; sus vértices son las soluciones básicas factibles ($x_B = A_B^{-1}b \geq 0$, $x_N = 0$). Teorema fundamental: si el óptimo es finito, se alcanza en un vértice; por eso los LP 2D se resuelven evaluando el objetivo en los vértices.
- **Dualidad.** La función dual lagrangiana del LP estándar es $q(\lambda) = \langle b, \lambda \rangle$ si $A^\top \lambda \leq c$ y $-\infty$ si no: el dual de un LP es otro LP. Dualidad débil: $\langle c, x \rangle \leq \langle b, \lambda \rangle$ para cualquier x factible. Dualidad fuerte: en PL basta factibilidad (no se necesita Slater). Holgura complementaria: $y_i^*(b_i - \langle a_i, x^* \rangle) = 0$ y $x_j^*(\langle A_j, y^* \rangle - c_j) = 0$; permite recuperar la solución dual desde la primal resolviendo un sistema lineal.
- **Economía.** Las variables duales son precios sombra de los recursos ($y_i^* = \partial V / \partial b_i$ dentro de un rango); las restricciones duales son condiciones de no arbitraje (el costo imputado cubre el ingreso); dualidad fuerte = agotamiento del producto.
- **Algoritmos.** Simplex: caminar por vértices vecinos mejorando; termina por finitud

(con reglas anticiclado si hay degeneración). Puntos interiores: seguir la trayectoria central de la barrera logarítmica; holgura complementaria perturbada $x_j s_j = \mu$.

- **Aplicaciones.** Juegos de suma cero = par primal-dual (minimax = dualidad fuerte; indiferencia = holgura complementaria); transporte/asignación (precios duales que sostienen el matching); screening con tipos finitos = LP en las transferencias.

Referencias: [1], [5] cap. 13, [2] cap. 4, [4], [3].

Ejercicio 13.28 (Conversión a forma estándar). Lleva a forma estándar el problema

$$\min_{x_1, x_2, x_3} x_1 - 2x_2 + x_3 \quad \text{s.a.} \quad x_1 + x_2 + x_3 = 10, \quad x_1 - x_2 \geq 3, \quad x_1 \geq 0, \quad x_3 \geq 0,$$

donde x_2 es libre. Indica las dimensiones finales de A , b y c .

Solución. Ya es un problema de minimización, así que no hace falta (T1).

Variable libre (T4): $x_2 = u - v$, con $u, v \geq 0$. El objetivo queda $x_1 - 2u + 2v + x_3$; las restricciones:

$$x_1 + u - v + x_3 = 10, \quad x_1 - u + v \geq 3.$$

Desigualdad a igualdad (T2): en la segunda restricción ($\geq$) se *resta* un excedente $e \geq 0$:

$$x_1 - u + v - e = 3.$$

Ensamblar: con $z = (x_1, u, v, x_3, e)^T \in \mathbb{R}^5$,

$$c = (1, -2, 2, 1, 0)^T, \quad A = \begin{pmatrix} 1 & 1 & -1 & 1 & 0 \\ 1 & -1 & 1 & 0 & -1 \end{pmatrix}, \quad b = \begin{pmatrix} 10 \\ 3 \end{pmatrix},$$

y el problema es $\min \langle c, z \rangle$ s.a. $Az = b$, $z \geq 0$: A es 2×5 , $b \in \mathbb{R}^2$, $c \in \mathbb{R}^5$. El valor óptimo coincide con el original, y de una solución z^* se recupera $x^* = (z_1^*, z_2^* - z_3^*, z_4^*)$. $\square$

Ejercicio 13.29 (LP 2D gráfico + dual + holgura complementaria). Considera el problema

$$\max_{x_1, x_2} 2x_1 + 3x_2 \quad \text{s.a.} \quad x_1 + x_2 \leq 6, \quad x_1 + 2x_2 \leq 8, \quad x_1, x_2 \geq 0.$$


(a) Resuélvelo gráficamente, calculando todos los vértices. (b) Escribe su dual. (c) Recupera la solución dual óptima mediante holgura complementaria y verifica la dualidad fuerte.

Solución. (a) *Vértices.* Las rectas son $x_1 + x_2 = 6$ y $x_1 + 2x_2 = 8$, junto con los ejes. Cortes factibles: $(0, 0)$; $(6, 0)$ (eje 1 con la primera recta; el corte $(8, 0)$ de la segunda viola la primera); $(0, 4)$ (eje 2 con la segunda recta; el corte $(0, 6)$ viola la segunda); y la intersección de ambas

rectas: restando, $x_2 = 2$, luego $x_1 = 4$: el punto $(4, 2)$. Tabla de vértices:

vértice	$z = 2x_1 + 3x_2$
$(0, 0)$	0
$(6, 0)$	12
$(4, 2)$	14
$(0, 4)$	12

Óptimo: $x^* = (4, 2)$ con $z^* = 14$.



(b) *Dual*. Max con dos restricciones $\leq$ y variables ≥ 0 : el dual tiene $y_1, y_2 \geq 0$ y una restricción por variable primal:

$$\min_{y \geq 0} 6y_1 + 8y_2 \quad \text{s.a.} \quad y_1 + y_2 \geq 2, \quad y_1 + 2y_2 \geq 3.$$

(c) *Holgura complementaria*. En $x^* = (4, 2)$ ambas restricciones primales están activas ($4 + 2 = 6$, $4 + 4 = 8$), así que (13.8) no fuerza ningún $y_i^* = 0$. Ambas variables primales son positivas, así que por (13.9) ambas restricciones duales están activas:

$$y_1^* + y_2^* = 2, \quad y_1^* + 2y_2^* = 3.$$

Restando: $y_2^* = 1$; luego $y_1^* = 1$. Ambos son ≥ 0 : factible dual. Valor dual: $6(1) + 8(1) = 14 = z^*$. Dualidad fuerte verificada; los precios sombra son $y^* = (1, 1)$: una unidad más de cualquiera de los dos recursos aumentaría el objetivo en una unidad. $\square$

Ejercicio 13.30 (Soluciones básicas). Para la región $x_1 + 2x_2 \leq 6$, $2x_1 + x_2 \leq 6$, $x_1, x_2 \geq 0$ en forma estándar (con holguras s_1, s_2), enumera *todas* las soluciones básicas, indica cuáles son factibles y da el vértice de $\mathbb{R}^2$ al que corresponde cada SBF.

Solución. La forma estándar tiene

$$A = \begin{pmatrix} 1 & 2 & 1 & 0 \\ 2 & 1 & 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 6 \\ 6 \end{pmatrix}, \quad x = (x_1, x_2, s_1, s_2)^\top.$$

Hay $\binom{4}{2} = 6$ elecciones de base; en cada una, las variables fuera de la base se fijan en cero:

- $B = \{s_1, s_2\}$: $(0, 0, 6, 6)$. **Factible**: vértice $(0, 0)$.

- $B = \{x_1, s_1\}$: de la fila 2, $2x_1 = 6$, $x_1 = 3$; de la fila 1, $s_1 = 6 - 3 = 3$. $(3, 0, 3, 0)$. **Factible**: vértice $(3, 0)$.
- $B = \{x_1, s_2\}$: de la fila 1, $x_1 = 6$; de la fila 2, $s_2 = 6 - 12 = -6 < 0$. *No factible* (el punto $(6, 0)$ viola la segunda restricción).
- $B = \{x_2, s_1\}$: de la fila 2, $x_2 = 6$; de la fila 1, $s_1 = 6 - 12 = -6 < 0$. *No factible*.
- $B = \{x_2, s_2\}$: de la fila 1, $2x_2 = 6$, $x_2 = 3$; de la fila 2, $s_2 = 6 - 3 = 3$. $(0, 3, 0, 3)$. **Factible**: vértice $(0, 3)$.
- $B = \{x_1, x_2\}$: sistema $x_1 + 2x_2 = 6$, $2x_1 + x_2 = 6$. Multiplicando la primera por 2 y restando: $3x_2 = 6$, $x_2 = 2$, $x_1 = 2$. $(2, 2, 0, 0)$. **Factible**: vértice $(2, 2)$.

Cuatro SBF (los vértices $(0, 0)$, $(3, 0)$, $(0, 3)$, $(2, 2)$ del polígono) y dos soluciones básicas no factibles, que son cortes de rectas fuera de la región. Ninguna SBF es degenerada: todas tienen exactamente $m = 2$ componentes positivas. $\square$

Ejercicio 13.31 (Dualidad débil y no acotación). Usando solo la dualidad débil (Teorema 13.15), demuestra: si el primal (P) de (13.6) es no acotado ($\sup \langle c, x \rangle = +\infty$), entonces el dual (D) es infactible. Da un ejemplo en $\mathbb{R}$ (una variable, una restricción) donde *ambos* problemas son infactibles (esto muestra que la recíproca es falsa).

Solución. Supongamos, por contradicción, que el dual tiene un punto factible y^0 . Por dualidad débil, *todo* x factible del primal cumple $\langle c, x \rangle \leq \langle b, y^0 \rangle < +\infty$: el número fijo $\langle b, y^0 \rangle$ es cota superior del objetivo primal, contradiciendo que $\sup \langle c, x \rangle = +\infty$. Luego el dual no tiene puntos factibles.

Ejemplo con ambos infactibles. Tomemos $n = m = 1$, $c = 1$, $A = (0)$, $b = -1$:

$$(P) \quad \max x \quad \text{s.a.} \quad 0 \cdot x \leq -1, \quad x \geq 0; \quad (D) \quad \min (-1)y \quad \text{s.a.} \quad 0 \cdot y \geq 1, \quad y \geq 0.$$

El primal exige $0 \leq -1$: infactible. El dual exige $0 \geq 1$: infactible. Así, “dual infactible” no implica “primal no acotado”: la tercera posibilidad es que ambos sean infactibles a la vez. $\square$

Ejercicio 13.32 (Juego de suma cero 2×2). Resuelve el juego matricial con pagos a la fila

$$A = \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} :$$

plantea el LP del jugador fila, encuentra las estrategias mixtas óptimas de ambos jugadores y el valor del juego, y verifica la coincidencia de valores primal y dual.

Solución. No hay solución en puras: el max-min puro es $\max\{\min(2, -1), \min(-1, 1)\} = -1$ y el min-max puro es $\min\{\max(2, -1), \max(-1, 1)\} = 1$.

Fila. Con $x = (p, 1 - p)$, el LP (13.10) es maximizar $v = \min\{2p - (1 - p), -p + (1 - p)\} = \min\{3p - 1, 1 - 2p\}$. Una recta crece y la otra decrece; el cruce:

$$3p - 1 = 1 - 2p \implies 5p = 2 \implies p = \frac{2}{5}, \quad v^* = 3 \cdot \frac{2}{5} - 1 = \frac{1}{5}.$$

Como $p = 2/5 \in [0, 1]$, es admisible: $x^* = (2/5, 3/5)$ y valor $v^* = 1/5$.

Columna (dual). Con $y = (q, 1 - q)$, minimizar $w = \max\{2q - (1 - q), -q + (1 - q)\} = \max\{3q - 1, 1 - 2q\}$:

$$3q - 1 = 1 - 2q \implies q = \frac{2}{5}, \quad w^* = \frac{1}{5}.$$

Así $y^* = (2/5, 3/5)$ y $w^* = 1/5 = v^*$: dualidad fuerte confirmada, el valor del juego es $1/5$ (el juego favorece a la fila). Comprobación de indiferencia (holgura complementaria): contra y^* , la fila 1 rinde $2(2/5) - 3/5 = 1/5$ y la fila 2 rinde $-2/5 + 3/5 = 1/5$; contra x^* , ambas columnas rinden también $1/5$. $\square$

Ejercicio 13.33 (Precios sombra y decisión de inversión). En el problema de producción (13.1), la empresa puede contratar una hora adicional en *una sola* de las tres plantas, a un costo de 1.2 soles la hora. (a) ¿En qué planta conviene contratarla, y cuál es la ganancia neta? (b) ¿Cambiaría la respuesta si el costo fuera de 1.8 soles? (c) ¿Por qué la respuesta de (a) solo es válida “localmente”?

Solución. (a) Los precios sombra (Ejemplo 13.19) son $y^* = (0, 3/2, 1)$: una hora extra vale 0 en la planta A, 1.5 soles en la B y 1 sol en la C. Al costo de 1.2, solo la planta B da ganancia neta positiva: $1.5 - 1.2 = 0.3$ soles. Conviene contratar en B.

(b) Con costo $1.8 > 1.5$, ninguna planta rinde más de lo que cuesta la hora (1.5 es el mayor precio sombra): no conviene contratar en ninguna.

(c) Porque el precio sombra es una derivada de la función valor, válida solo mientras la base óptima no cambie. Por el Ejemplo 13.21, el precio $3/2$ de la planta B vale para $b_2 \in [6, 18]$; si la empresa contratara muchas horas (más de 6 adicionales), la restricción $x_1 \geq 0$ pasaría a ser el cuello de botella, la base cambiaría y las horas adicionales de B valdrían menos que $3/2$. Para una hora, el cálculo de (a) es exacto porque $13 \in [6, 18]$. $\square$

Capítulo 14

Máquinas de vectores soporte (Support Vector Machines) [P5]

Semana 11 del cronograma. Bibliografía: Wright y Recht [8]; Li [4].

¿Para qué sirve esto en Microeconomía?

Seamos honestos: las máquinas de vectores soporte *no aparecen* en el temario de Microeconomía. No habrá una pregunta de examen sobre SVM. Entonces, ¿por qué dedicarle un capítulo? Por tres razones:

- (I) **Es el repaso integrador perfecto.** El SVM es un solo problema que usa *todo* lo que hemos construido: separación de conjuntos convexos (capítulo de separación), condiciones KKT con holgura complementaria (capítulo de KKT) y dualidad lagrangiana con dualidad fuerte vía Slater (capítulo de dualidad). Resolver un SVM a mano es la mejor auditoría posible de si dominas esos tres capítulos.
- (II) **Econometría y aprendizaje automático aplicado a economía.** Los métodos de clasificación son hoy herramientas estándar en economía aplicada: predicción de incumplimiento crediticio (*default*), clasificación de hogares pobres/no pobres con datos de encuestas o imágenes satelitales, y análisis de texto como dato (*text-as-data*) en documentos de política monetaria. El SVM es uno de los clasificadores clásicos que conviene entender desde la optimización, no como caja negra.
- (III) **Es un excelente tema de exposición final del curso.** Combina teoría limpia (convexidad, KKT, dualidad) con una implementación computacional accesible en Python o Julia. Al final del capítulo damos una sugerencia concreta de proyecto.

14.1. El problema de clasificación binaria [P5]

14.1.1. Datos, etiquetas y clasificadores lineales

Hasta ahora hemos optimizado funciones que venían de la teoría económica (utilidad, beneficio, costo). Cambiemos de escenario: ahora los datos mandan.

Definición 14.1 (Problema de clasificación binaria). Se dispone de una *muestra de entrenamiento* (*training sample*)

$$\{(x_i, y_i)\}_{i=1}^m, \quad x_i \in \mathbb{R}^n, \quad y_i \in \{-1, +1\},$$

donde x_i es un vector de *características* (*features*) y y_i es la *etiqueta* (*label*) que indica a cuál de dos clases pertenece la observación i . El objetivo es construir una función $f: \mathbb{R}^n \rightarrow \{-1, +1\}$, llamada *clasificador* (*classifier*), que prediga correctamente la etiqueta de observaciones nuevas.

Ejemplo 14.2 (Scoring crediticio). Un banco observa, para cada cliente pasado i , un vector $x_i = (\text{ingreso}_i, \text{deuda}_i, \text{antigüedad laboral}_i, \dots) \in \mathbb{R}^n$ y una etiqueta $y_i = +1$ si pagó su crédito y $y_i = -1$ si incumplió. Quiere una regla que, ante un solicitante nuevo con características x , prediga si pagará. Eso es exactamente un problema de clasificación binaria.

La familia más simple de clasificadores es la de los *clasificadores lineales*: reglas que trazan un hiperplano en $\mathbb{R}^n$ y asignan una clase a cada lado.

Definición 14.3 (Clasificador lineal). Dados $w \in \mathbb{R}^n$, $w \neq 0$, y $b \in \mathbb{R}$, el *clasificador lineal* asociado al hiperplano $H = \{x \in \mathbb{R}^n : \langle w, x \rangle = b\}$ es

$$f(x) = \text{sgn}(\langle w, x \rangle - b) = \begin{cases} +1 & \text{si } \langle w, x \rangle - b > 0, \\ -1 & \text{si } \langle w, x \rangle - b < 0. \end{cases}$$

El vector w es el *vector normal* al hiperplano y b el *sesgo* o *intercepto* (*bias*).

Observa una manera compacta de decir “el clasificador acierta en el punto i ”: como $y_i \in \{-1, +1\}$, el punto x_i queda del lado correcto del hiperplano si y solo si

$$y_i(\langle w, x_i \rangle - b) > 0. \quad (14.1)$$

En efecto: si $y_i = +1$ necesitamos $\langle w, x_i \rangle - b > 0$, y si $y_i = -1$ necesitamos $\langle w, x_i \rangle - b < 0$; multiplicar por y_i unifica ambos casos en una sola desigualdad. Este pequeño truco algebraico se usará constantemente en todo el capítulo.

14.1.2. Separabilidad lineal y el teorema de separación

Definición 14.4 (Separabilidad lineal). La muestra $\{(x_i, y_i)\}_{i=1}^m$ es *linealmente separable* (*linearly separable*) si existen $w \in \mathbb{R}^n$, $w \neq 0$, y $b \in \mathbb{R}$ tales que

$$y_i(\langle w, x_i \rangle - b) > 0 \quad \text{para todo } i = 1, \dots, m.$$

¿Cuándo existe tal hiperplano? Aquí entra en escena, con todo protagonismo, el teorema de separación de conjuntos convexos que estudiamos en el capítulo de separación. Definamos los conjuntos de puntos de cada clase,

$$P = \{x_i : y_i = +1\}, \quad N = \{x_i : y_i = -1\},$$

y sus cápsulas convexas $\text{conv}(P)$ y $\text{conv}(N)$ (el menor conjunto convexo que contiene a cada clase; recuerda que la cápsula convexa de finitos puntos es el conjunto de todas sus combinaciones convexas, un politopo compacto).

Teorema 14.5 (Separabilidad = separación de cápsulas convexas). *La muestra es linealmente separable si y solo si $\text{conv}(P) \cap \text{conv}(N) = \emptyset$.*

Demostración. ($\Leftarrow$) Supongamos $\text{conv}(P) \cap \text{conv}(N) = \emptyset$. Ambos conjuntos son cápsulas convexas de finitos puntos, luego son convexas y compactos (cerrados y acotados). Por el teorema de separación *estricta* de un convexo compacto y un convexo cerrado disjuntos (visto en el capítulo de separación; ver también [2, sec. 2.5]), existen $w \neq 0$ y $b \in \mathbb{R}$ tales que

$$\langle w, u \rangle > b \quad \forall u \in \text{conv}(P), \quad \langle w, v \rangle < b \quad \forall v \in \text{conv}(N).$$

En particular, para cada x_i con $y_i = +1$ vale $\langle w, x_i \rangle - b > 0$, y para cada x_i con $y_i = -1$ vale $\langle w, x_i \rangle - b < 0$. Por (14.1), el hiperplano $\{x : \langle w, x \rangle = b\}$ separa la muestra.

($\Rightarrow$) Supongamos que existe (w, b) con $y_i(\langle w, x_i \rangle - b) > 0$ para todo i . Sea $u \in \text{conv}(P)$ cualquiera: $u = \sum_{i: y_i = +1} \lambda_i x_i$ con $\lambda_i \geq 0$, $\sum \lambda_i = 1$. Como la función $x \mapsto \langle w, x \rangle - b$ es afín,


$$\langle w, u \rangle - b = \sum_{i: y_i = +1} \lambda_i (\langle w, x_i \rangle - b) > 0,$$

porque es un promedio ponderado de cantidades estrictamente positivas (y algún $\lambda_i > 0$). Análogamente, $\langle w, v \rangle - b < 0$ para todo $v \in \text{conv}(N)$. Si existiera $z \in \text{conv}(P) \cap \text{conv}(N)$, tendríamos simultáneamente $\langle w, z \rangle - b > 0$ y $\langle w, z \rangle - b < 0$, absurdo. Luego las cápsulas son disjuntas. $\square$

Intuición

El Teorema 14.5 es el puente conceptual del capítulo: *clasificar con una recta es separar dos conjuntos convexas*. Toda la maquinaria geométrica que desarrollamos (hiperplanos soporte, separación estricta de compactos) deja de ser abstracta y se vuelve un algoritmo de predicción. Además anticipa la geometría de la solución: el mejor hiperplano pasará “por el medio” del pasillo que queda entre las dos cápsulas convexas, y solo los puntos en la frontera de ese pasillo importarán. Esos puntos serán los *vectores soporte*.

Si la muestra es separable, hay *infinitos* hiperplanos separadores: cualquier recta dentro del “pasillo” entre las nubes sirve. ¿Cuál elegir? La respuesta del SVM: el que deja la *franja de seguridad más ancha* a ambos lados. Formalizar esa idea requiere medir distancias de puntos a hiperplanos, que es el tema de la siguiente sección.



Dos clases separables, el hiperplano de margen máximo (línea sólida), las rectas canónicas (discontinuas) y, encerrados en círculos, los vectores soporte.

14.2. Margen y el problema primal [P5]

14.2.1. Distancia de un punto a un hiperplano

Necesitamos una fórmula para la distancia de un punto a un hiperplano. La deducimos desde cero.

Lema 14.6 (Distancia punto–hiperplano). Sea $H = \{x \in \mathbb{R}^n : \langle a, x \rangle = \beta\}$ con $a \neq 0$, y sea $x_0 \in \mathbb{R}^n$. Entonces

$$\text{dist}(x_0, H) = \min_{x \in H} \|x_0 - x\| = \frac{|\langle a, x_0 \rangle - \beta|}{\|a\|}.$$

Demostración. Paso 1 (geometría). El punto de H más cercano a x_0 es la proyección ortogonal de x_0 sobre H , y el segmento que los une es paralelo al vector normal a . Busquemos entonces el punto de la forma

$$x^* = x_0 - t a, \quad t \in \mathbb{R},$$

que pertenezca a H : nos movemos desde x_0 en la dirección de $-a$ hasta tocar el hiperplano.

Paso 2 (calcular t). Imponemos $\langle a, x^* \rangle = \beta$:

$$\langle a, x_0 - t a \rangle = \langle a, x_0 \rangle - t \langle a, a \rangle = \langle a, x_0 \rangle - t \|a\|^2 = \beta \implies t = \frac{\langle a, x_0 \rangle - \beta}{\|a\|^2}.$$

Paso 3 (calcular la distancia). Como $x_0 - x^* = t a$,

$$\|x_0 - x^*\| = |t| \cdot \|a\| = \frac{|\langle a, x_0 \rangle - \beta|}{\|a\|^2} \cdot \|a\| = \frac{|\langle a, x_0 \rangle - \beta|}{\|a\|}.$$

Paso 4 (verificar que es el mínimo). Para cualquier otro $x \in H$, por la desigualdad de Cauchy–Schwarz,

$$\|a\| \cdot \|x_0 - x\| \geq |\langle a, x_0 - x \rangle| = |\langle a, x_0 \rangle - \underbrace{\langle a, x \rangle}_{=\beta}| = |\langle a, x_0 \rangle - \beta|,$$

de donde $\|x_0 - x\| \geq |\langle a, x_0 \rangle - \beta| / \|a\|$ para todo $x \in H$, con igualdad en x^* . Esto prueba la fórmula. $\square$

14.2.2. Margen funcional, margen geométrico y normalización canónica

Definición 14.7 (Márgenes). Sea (w, b) un hiperplano separador de la muestra $\{(x_i, y_i)\}_{i=1}^m$. Para cada punto i :

- el *margen funcional* (*functional margin*) es $\hat{\gamma}_i = y_i(\langle w, x_i \rangle - b)$;
- el *margen geométrico* (*geometric margin*) es la distancia del punto al hiperplano, $\gamma_i = \frac{y_i(\langle w, x_i \rangle - b)}{\|w\|} = \frac{\hat{\gamma}_i}{\|w\|}$.

El *margen (geométrico) de la muestra* es $\gamma = \min_{i=1, \dots, m} \gamma_i$: la distancia del punto más cercano al hiperplano.

Nota que en γ_i usamos el Lema 14.6 con $a = w$, $\beta = b$: como el hiperplano separa, el signo de $\langle w, x_i \rangle - b$ coincide con y_i , así que $y_i(\langle w, x_i \rangle - b) = |\langle w, x_i \rangle - b|$ y γ_i es exactamente la distancia (positiva) de x_i al hiperplano.

Cuidado (error común)

El margen funcional $\hat{\gamma}_i$ es **ilusorio**: si multiplicas (w, b) por 10, el hiperplano geométrico $\{x : \langle w, x \rangle = b\}$ no se mueve ni un milímetro, pero $\hat{\gamma}_i$ se multiplica por 10. “Agrandar el margen funcional” reescalando no mejora nada. Por eso el objeto con significado geométrico es $\gamma_i = \hat{\gamma}_i / \|w\|$, que es *invariante* ante reescalamientos $(w, b) \mapsto (tw, tb)$ con $t > 0$. Esta invariancia es también la que nos permitirá, en un momento, fijar una normalización cómoda sin perder generalidad. No confundas ambos márgenes: es el error conceptual más común al estudiar SVM por primera vez.

El SVM de margen duro elige, entre todos los hiperplanos separadores, el que *maximiza el margen geométrico de la muestra*:

$$\max_{w \neq 0, b} \min_{i=1, \dots, m} \frac{y_i(\langle w, x_i \rangle - b)}{\|w\|}. \quad (14.2)$$

Tal como está escrito, (14.2) es feo: un max–min, no diferenciable, no convexo (el cociente con $\|w\|$ estropea todo). La magia del SVM es que una normalización astuta lo convierte en un problema cuadrático convexo impecable.

14.2.3. Derivación: del margen máximo al programa cuadrático

Proposición 14.8 (Formulación primal del SVM de margen duro). *Si la muestra es linealmente separable, el problema (14.2) es equivalente al programa cuadrático (quadratic program, QP)*

$$\begin{aligned} \min_{w \in \mathbb{R}^n, b \in \mathbb{R}} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.a.} \quad & y_i(\langle w, x_i \rangle - b) \geq 1, \quad i = 1, \dots, m, \end{aligned} \quad (14.3)$$

en el sentido de que ambos tienen el mismo hiperplano óptimo, y el margen máximo vale $\gamma^* = 1/\|w^*\|$, donde w^* resuelve (14.3).

Derivación paso a paso. Paso 1: introducir el margen como variable. El problema (14.2) equivale a maximizar una cota inferior γ de todos los márgenes geométricos:

$$\max_{w \neq 0, b, \gamma > 0} \gamma \quad \text{s.a.} \quad \frac{y_i(\langle w, x_i \rangle - b)}{\|w\|} \geq \gamma, \quad i = 1, \dots, m.$$

(Maximizar el mínimo de unas cantidades es lo mismo que maximizar una cota inferior común: en el óptimo, γ sube hasta pegarse al mínimo.)

Paso 2: eliminar la ambigüedad de escala. Ya vimos que si (w, b) es factible, también lo es (tw, tb) para todo $t > 0$, con el mismo margen geométrico: hay una familia entera de representaciones del mismo hiperplano. Rompamos esa redundancia eligiendo el representante que satisface la *normalización canónica*

$$\min_{i=1, \dots, m} y_i(\langle w, x_i \rangle - b) = 1,$$

es decir, escalamos (w, b) para que el margen *funcional* mínimo valga exactamente 1. Esto siempre es posible: si el mínimo margen funcional de (w, b) es $\hat{\gamma} > 0$ (positivo por separabilidad), basta reemplazar (w, b) por $(w/\hat{\gamma}, b/\hat{\gamma})$.

Paso 3: reescribir el margen. Con la normalización canónica, el margen geométrico de la muestra es

$$\gamma = \min_i \frac{y_i(\langle w, x_i \rangle - b)}{\|w\|} = \frac{1}{\|w\|} \cdot \underbrace{\min_i y_i(\langle w, x_i \rangle - b)}_{=1} = \frac{1}{\|w\|}.$$

Entonces maximizar γ es maximizar $1/\|w\|$, que a su vez es minimizar $\|w\|$.

Paso 4: relajar la normalización a desigualdad. La restricción “ $\min_i y_i(\langle w, x_i \rangle - b) = 1$ ” es incómoda (involucra un mínimo). Reemplacémosla por las m desigualdades

$$y_i(\langle w, x_i \rangle - b) \geq 1, \quad i = 1, \dots, m,$$

y minimicemos $\|w\|$. ¿Perdemos algo? No: en el óptimo, *alguna* de las desigualdades debe estar activa (valer con igualdad). Si todas fueran estrictas, es decir $\min_i y_i(\langle w, x_i \rangle - b) = c > 1$, podríamos reescalar $(w, b) \mapsto (w/c, b/c)$: seguiría siendo factible y $\|w\|$ bajaría, contradiciendo optimalidad. Luego el mínimo con desigualdades coincide con el mínimo con la normalización exacta.

Paso 5: cosmética final. Minimizar $\|w\|$ y minimizar $\frac{1}{2}\|w\|^2$ tienen las mismas soluciones, porque $t \mapsto \frac{1}{2}t^2$ es estrictamente creciente en $t \geq 0$. Preferimos $\frac{1}{2}\|w\|^2 = \frac{1}{2}\langle w, w \rangle$ porque es diferenciable con gradiente lineal ($\nabla_w = w$): el $\frac{1}{2}$ está ahí solo para que la derivada quede limpia. Obtenemos exactamente (14.3), y el margen óptimo es $1/\|w^*\|$. $\square$

Intuición

Lee el problema (14.3) con ojos de economista: es un problema de “costo mínimo sujeto a niveles mínimos de servicio”. Cada dato i exige estar clasificado con margen funcional al menos 1 (su “restricción de participación”), y el planificador elige el hiperplano de *norma mínima* que cumple con todos. Como el margen geométrico es $1/\|w\|$, norma pequeña

= pasillo ancho. Y como en toda economía con restricciones, cada restricción tendrá su “precio sombra” $\alpha_i \geq 0$: los datos con precio sombra positivo son los que de verdad restringen al planificador, y esos serán los vectores soporte.

14.3. El SVM de margen duro: convexidad y KKT [P5]

14.3.1. Es un QP convexo con Slater

Proposición 14.9 (Convexidad del primal). *El problema (14.3) es un problema de optimización convexa: objetivo convexo y restricciones de desigualdad afines. Si la muestra es linealmente separable, se cumple además la condición de Slater y el problema tiene solución; la componente w^* es única.*

Demostración. Objetivo. $f(w, b) = \frac{1}{2} \|w\|^2 = \frac{1}{2} w^\top w$ es una forma cuadrática con matriz hessiana $\nabla^2 f = \begin{pmatrix} I_n & 0 \\ 0 & 0 \end{pmatrix} \succeq 0$ (semidefinida positiva: bloque identidad en w , cero en b), luego f es convexa (y estrictamente convexa en w).

Restricciones. Cada restricción $g_i(w, b) = 1 - y_i(\langle w, x_i \rangle - b) \leq 0$ es *afín* en (w, b) : es una constante más una función lineal de las variables (x_i e y_i son datos, no variables). Restricciones afines definen un poliedro, que es convexo.

Slater. Para restricciones afines, la condición de Slater solo pide factibilidad; pero aquí tenemos más: si la muestra es separable, por el Teorema 14.5 existe (w_0, b_0) con $y_i(\langle w_0, x_i \rangle - b_0) > 0$ para todo i , y reescalando por un factor grande obtenemos un punto que cumple todas las restricciones de (14.3) *estrictamente*. Así que Slater se cumple con holgura.

Existencia y unicidad de w^ .* El conjunto factible es cerrado, no vacío, y podemos restringir la búsqueda al conjunto compacto donde $\|w\| \leq \|w_0\|$ (fuera de él, el objetivo ya supera el valor en w_0); un argumento estándar de Weierstrass da existencia. Si $w_1 \neq w_2$ fueran dos óptimos con el mismo valor, el punto medio sería factible (conjunto convexo) y, por convexidad *estricta* de $w \mapsto \frac{1}{2} \|w\|^2$, tendría objetivo estrictamente menor: contradicción. Luego w^* es único. $\square$

Conclusión operativa: por el capítulo de KKT, en un problema convexo con Slater las condiciones KKT son *necesarias y suficientes* para optimalidad global, y por el capítulo de dualidad hay *dualidad fuerte* (el dual alcanza el mismo valor óptimo). Tenemos luz verde para resolver el SVM enteramente vía KKT.

14.3.2. Lagrangiano y condiciones KKT, paso a paso

Asociamos un multiplicador $\alpha_i \geq 0$ a cada restricción $1 - y_i(\langle w, x_i \rangle - b) \leq 0$. El *lagrangiano* es

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\langle w, x_i \rangle - b)), \quad \alpha = (\alpha_1, \dots, \alpha_m) \geq 0. \quad (14.4)$$

Teorema 14.10 (KKT para el SVM de margen duro). *(w^*, b^*) resuelve (14.3) si y solo si existe $\alpha^* \in \mathbb{R}^m$ tal que:*

$$(a) \text{ **Estacionariedad en } w**: } \nabla_w L = w^* - \sum_{i=1}^m \alpha_i^* y_i x_i = 0 \iff w^* = \sum_{i=1}^m \alpha_i^* y_i x_i.$$

- (b) **Estacionariedad en b :** $\frac{\partial L}{\partial b} = \sum_{i=1}^m \alpha_i^* y_i = 0$.
- (c) **Factibilidad primal:** $y_i(\langle w^*, x_i \rangle - b^*) \geq 1$ para todo i .
- (d) **Factibilidad dual:** $\alpha_i^* \geq 0$ para todo i .
- (e) **Holgura complementaria:** $\alpha_i^*(1 - y_i(\langle w^*, x_i \rangle - b^*)) = 0$ para todo i .

Verificación de los cálculos. La equivalencia KKT $\Leftrightarrow$ óptimo es el teorema general del capítulo de KKT (convexidad + Slater, Proposición 14.9). Aquí solo verificamos las derivadas. Escribiendo $L = \frac{1}{2} \langle w, w \rangle + \sum_i \alpha_i - \sum_i \alpha_i y_i \langle w, x_i \rangle + b \sum_i \alpha_i y_i$: el gradiente en w del primer término es w (regla $\nabla_w \frac{1}{2} \langle w, w \rangle = w$); el del término $-\sum_i \alpha_i y_i \langle w, x_i \rangle$ es $-\sum_i \alpha_i y_i x_i$ (gradiente de una función lineal); los demás no dependen de w . La derivada en b solo ve el último término y vale $\sum_i \alpha_i y_i$. Igualando a cero se obtienen (a) y (b). $\square$

14.3.3. Vectores soporte

La condición (e), holgura complementaria, es la que da nombre al método.

Definición 14.11 (Vector soporte). Un punto x_i de la muestra es un *vector soporte* (*support vector*) si su multiplicador óptimo es positivo: $\alpha_i^* > 0$. Por holgura complementaria, todo vector soporte satisface su restricción con igualdad,

$$y_i(\langle w^*, x_i \rangle - b^*) = 1,$$

es decir, está exactamente sobre una de las dos rectas canónicas $\langle w^*, x \rangle - b^* = \pm 1$, a distancia exactamente $1/\|w^*\|$ del hiperplano: en el borde del pasillo.

Cuidado (error común)

La implicación va en un solo sentido: $\alpha_i^* > 0 \Rightarrow$ restricción activa. El recíproco es falso en general: puede haber puntos *sobre* el borde del pasillo con $\alpha_i^* = 0$ (restricción activa pero multiplicador nulo, un caso degenerado). Lo que sí es siempre cierto, por holgura complementaria leída al revés: si la restricción está *inactiva* ($y_i(\langle w^*, x_i \rangle - b^*) > 1$, punto estrictamente dentro de su región), entonces $\alpha_i^* = 0$.

Teorema 14.12 (Representación por vectores soporte). Sea $S = \{i : \alpha_i^* > 0\}$ el conjunto de índices de vectores soporte. Entonces:

- (I) $w^* = \sum_{i \in S} \alpha_i^* y_i x_i$: el vector normal óptimo es combinación lineal solo de los vectores soporte.
- (II) $S \neq \emptyset$, y hay vectores soporte de ambas clases.
- (III) Para cualquier $j \in S$: $b^* = \langle w^*, x_j \rangle - y_j$.
- (IV) El clasificador se evalúa usando solo productos internos con los vectores soporte: $f(x) = \text{sgn}\left(\sum_{i \in S} \alpha_i^* y_i \langle x_i, x \rangle - b^*\right)$.

Demostración. (i) Es la condición (a) del Teorema 14.10, donde los sumandos con $\alpha_i^* = 0$ desaparecen.

(ii) Si $S = \emptyset$ entonces $w^* = 0$ por (i); pero $w = 0$ hace imposible la restricción $y_i(\langle 0, x_i \rangle - b) = -y_i b \geq 1$ para puntos de ambas clases a la vez (exigiría $-b \geq 1$ y $b \geq 1$). Luego $S \neq \emptyset$. Además, si todos los vectores soporte fueran de la clase $+1$, la condición (b) daría $0 = \sum_{i \in S} \alpha_i^* y_i = \sum_{i \in S} \alpha_i^* > 0$, absurdo; igual con la clase -1 . Hay soporte en ambas clases.

(iii) Si $j \in S$, por holgura complementaria $y_j(\langle w^*, x_j \rangle - b^*) = 1$. Multiplicando ambos lados por y_j y usando $y_j^2 = 1$: $\langle w^*, x_j \rangle - b^* = y_j$, de donde $b^* = \langle w^*, x_j \rangle - y_j$. (En la práctica numérica se promedia esta fórmula sobre todos los $j \in S$ para reducir error de redondeo.)

(iv) Sustituir (i) en $f(x) = \text{sgn}(\langle w^*, x \rangle - b^*)$ y usar linealidad del producto interno. $\square$

Intuición

Solo la frontera importa. Si borras de la muestra todos los puntos que no son vectores soporte y vuelves a entrenar, obtienes *exactamente el mismo* hiperplano: esos puntos tenían multiplicador cero, no “empujaban” la solución. Es el análogo exacto de los precios sombra en economía: una restricción inactiva (recurso no agotado) tiene precio sombra cero y eliminarla no cambia el óptimo. El SVM comprime toda la muestra en unos pocos puntos frontera, igual que el equilibrio de un mercado queda determinado por los agentes marginales, no por los inframarginales.

14.4. El problema dual y el truco del kernel [P5]

14.4.1. Derivación completa de la función dual

Siguiendo el capítulo de dualidad, la *función dual* es

$$q(\alpha) = \inf_{w \in \mathbb{R}^n, b \in \mathbb{R}} L(w, b, \alpha), \quad \alpha \geq 0,$$

y el problema dual es maximizar q . Calculemos el ínfimo *explícitamente*, eliminando w y b .

Paso 1: minimizar en b . En (14.4), b aparece solo en el término lineal $b \sum_i \alpha_i y_i$. Una función lineal no constante no está acotada por abajo, así que:

$$\inf_b L = \begin{cases} (\text{sigue el cálculo en } w) & \text{si } \sum_i \alpha_i y_i = 0, \\ -\infty & \text{si } \sum_i \alpha_i y_i \neq 0. \end{cases}$$

Los α con $\sum_i \alpha_i y_i \neq 0$ dan $q(\alpha) = -\infty$ y quedan descartados del dual: la condición $\sum_i \alpha_i y_i = 0$ aparece como *restricción del dual*.

Paso 2: minimizar en w . Supuesto $\sum_i \alpha_i y_i = 0$, el lagrangiano como función de w es

$$w \mapsto \frac{1}{2} \|w\|^2 - \left\langle \sum_i \alpha_i y_i x_i, w \right\rangle + \sum_i \alpha_i,$$

una cuadrática estrictamente convexa. Su mínimo se alcanza donde el gradiente se anula:

$$w - \sum_i \alpha_i y_i x_i = 0 \quad \implies \quad w(\alpha) = \sum_{i=1}^m \alpha_i y_i x_i.$$

(La misma fórmula de la condición KKT (a): no es coincidencia, el ínfimo del lagrangiano se

alcanza en el punto estacionario.)

Paso 3: sustituir. Denotemos $v = \sum_i \alpha_i y_i x_i$, de modo que $w(\alpha) = v$. Evaluamos término a término:

$$\frac{1}{2} \|w(\alpha)\|^2 = \frac{1}{2} \|v\|^2, \quad \left\langle \sum_i \alpha_i y_i x_i, w(\alpha) \right\rangle = \langle v, v \rangle = \|v\|^2,$$

por lo tanto

$$q(\alpha) = \frac{1}{2} \|v\|^2 - \|v\|^2 + \sum_i \alpha_i = \sum_{i=1}^m \alpha_i - \frac{1}{2} \|v\|^2.$$

Paso 4: expandir $\|v\|^2$ en productos internos. Por bilinealidad del producto interno,

$$\|v\|^2 = \left\langle \sum_i \alpha_i y_i x_i, \sum_j \alpha_j y_j x_j \right\rangle = \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle.$$

Hemos probado:

Teorema 14.13 (Dual del SVM de margen duro). *El problema dual de (14.3) es*

$$\begin{aligned} \max_{\alpha \in \mathbb{R}^m} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{s.a.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, \dots, m. \end{aligned} \tag{14.5}$$

Si la muestra es separable, vale la dualidad fuerte: los valores óptimos de (14.3) y (14.5) coinciden, el dual alcanza su máximo en algún α^* , y las soluciones se conectan por

$$w^* = \sum_{i=1}^m \alpha_i^* y_i x_i, \quad b^* = \langle w^*, x_j \rangle - y_j \quad \text{para cualquier } j \text{ con } \alpha_j^* > 0.$$

Demostración. La derivación de q está arriba. La dualidad fuerte es el teorema del capítulo de dualidad: problema convexo + condición de Slater (Proposición 14.9) implican salto de dualidad cero y existencia de multiplicadores óptimos. La recuperación de (w^*, b^*) es el Teorema 14.12. $\square$

Observación 14.14 (El dual es otro QP, y a menudo más manejable). Definiendo la matriz $Q \in \mathbb{R}^{m \times m}$ con entradas $Q_{ij} = y_i y_j \langle x_i, x_j \rangle$ (la *matriz de Gram* etiquetada), el dual es $\max_{\alpha} \mathbf{1}^\top \alpha - \frac{1}{2} \alpha^\top Q \alpha$ sujeto a restricciones lineales simples. Q es semidefinida positiva ($\alpha^\top Q \alpha = \|\sum_i \alpha_i y_i x_i\|^2 \geq 0$), así que el dual es un QP *cóncavo* en maximización: de nuevo convexo. El dual tiene m variables (una por dato) mientras el primal tiene $n+1$ (una por característica); cuál conviene computacionalmente depende de si hay más datos o más características [8, 5].

14.4.2. El truco del kernel

Mira con cuidado (14.5) y la fórmula de predicción del Teorema 14.12(iv). Hay algo notable:

Observación 14.15 (Los datos solo entran vía productos internos). Ni el problema dual ni el clasificador final necesitan los vectores x_i individualmente: *solo* necesitan los productos internos $\langle x_i, x_j \rangle$ (para entrenar) e $\langle x_i, x \rangle$ (para predecir).

Esta observación abre una puerta enorme. Supongamos que los datos no son linealmente separables en $\mathbb{R}^n$, pero sí lo serían tras transformarlos con una aplicación no lineal $\phi: \mathbb{R}^n \rightarrow \mathbb{R}^N$ a un espacio de dimensión mayor (incluso muchísimo mayor). Para entrenar el SVM en el espacio transformado solo necesitaríamos los números $\langle \phi(x_i), \phi(x_j) \rangle$. El *truco del kernel* (*kernel trick*) consiste en elegir ϕ de modo que ese producto interno tenga una fórmula cerrada barata

$$K(x, z) = \langle \phi(x), \phi(z) \rangle,$$

y entonces *nunca calcular ϕ explícitamente*: en (14.5) se reemplaza cada $\langle x_i, x_j \rangle$ por $K(x_i, x_j)$ y todo lo demás queda igual. La función K se llama *kernel* (o núcleo).

Ejemplo 14.16 (Kernel polinomial). En $\mathbb{R}^2$, sea $K(x, z) = \langle x, z \rangle^2 = (x_1 z_1 + x_2 z_2)^2$. Expandiendo el cuadrado:

$$K(x, z) = x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 = \langle (x_1^2, \sqrt{2} x_1 x_2, x_2^2), (z_1^2, \sqrt{2} z_1 z_2, z_2^2) \rangle,$$

es decir, $K(x, z) = \langle \phi(x), \phi(z) \rangle$ con $\phi(x) = (x_1^2, \sqrt{2} x_1 x_2, x_2^2) \in \mathbb{R}^3$. Un SVM con este kernel busca un hiperplano en $\mathbb{R}^3$ de coordenadas cuadráticas, que visto en $\mathbb{R}^2$ es una *cónica*: el clasificador ya no es una recta. El kernel polinomial general es $K(x, z) = (1 + \langle x, z \rangle)^d$, cuyo espacio de llegada tiene dimensión combinatoria en n y d , pero evaluar K cuesta lo mismo que un producto interno ordinario.

Ejemplo 14.17 (Kernel gaussiano o RBF). $K(x, z) = \exp(-\|x - z\|^2 / (2\sigma^2))$. Puede mostrarse que corresponde a un ϕ con valores en un espacio de dimensión *infinita*. La intuición: $K(x, z)$ mide *similitud* (vale 1 si $x = z$ y decae a 0 si están lejos), y el clasificador resultante $f(x) = \text{sgn}(\sum_{i \in S} \alpha_i^* y_i K(x_i, x) - b^*)$ es un “votante ponderado”: cada vector soporte vota por su clase con peso proporcional a su cercanía al punto nuevo. El parámetro σ controla el alcance del voto. La teoría general de qué funciones K son kernels válidos (espacios de Hilbert de núcleo reproductor, RKHS) excede este cuaderno; para nosotros basta la idea operativa. Puedes ver [8] para el enunciado preciso y [4] para la optimización asociada.

Estrategia de examen

Guion de repaso con el SVM (repaso integrador ideal antes de cualquier evaluación del curso):

1. *Separación*: dibuja dos nubes de puntos; pregúntate si $\text{conv}(P) \cap \text{conv}(N) = \emptyset$ y qué teorema de separación aplica (Teorema 14.5).
2. *Modelado*: deriva (14.3) desde el margen sin mirar el libro; el paso clave es la normalización canónica (Paso 2 de la Proposición 14.8).
3. *KKT*: escribe el lagrangiano y las cinco condiciones de memoria; identifica qué significa cada una geométricamente.
4. *Dualidad*: elimina w y b para obtener (14.5); verifica Slater y enuncia la dualidad fuerte.

5. *Cierre numérico*: resuelve el Ejemplo 14.22 a mano y comprueba que primal y dual dan el mismo valor.

Si puedes hacer los cinco pasos sin ayuda, dominas los capítulos de separación, KKT y dualidad.

14.5. Margen blando: datos no separables [P5]

14.5.1. Variables de holgura y el parámetro C

En datos reales casi nunca hay separabilidad perfecta: hay ruido, errores de medición, clases que se solapan. Si $\text{conv}(P) \cap \text{conv}(N) \neq \emptyset$, el problema (14.3) es *infactible* y el SVM de margen duro simplemente no existe. La solución: permitir que algunos puntos violen su restricción, pero cobrando por ello.

Definición 14.18 (SVM de margen blando). Dado un parámetro $C > 0$, el *SVM de margen blando* (*soft-margin SVM*) es el problema

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.a.} \quad & y_i (\langle w, x_i \rangle - b) \geq 1 - \xi_i, \quad i = 1, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, \dots, m, \end{aligned} \tag{14.6}$$

donde ξ_i es la *variable de holgura* (*slack variable*) del punto i : mide cuánto le falta al punto para alcanzar el margen funcional 1. Si $0 < \xi_i \leq 1$, el punto está dentro del pasillo pero bien clasificado; si $\xi_i > 1$, está mal clasificado.


El problema (14.6) sigue siendo un QP convexo (objetivo convexo: suma de una cuadrática convexa y un término lineal en ξ ; restricciones afines) y es *siempre factible*: dado cualquier (w, b) , basta tomar $\xi_i = \max\{0, 1 - y_i(\langle w, x_i \rangle - b)\}$. Slater se cumple trivialmente (tomar ξ_i aún más grandes da holgura estricta), así que KKT y dualidad fuerte aplican igual que antes.

Intuición

El parámetro C es un *precio*: cada unidad de violación del margen cuesta C . Es la disyuntiva clásica sesgo-varianza escrita como un problema de planificación:

- C grande: violar es carísimo; el óptimo imita al margen duro, se ajusta mucho a la muestra (riesgo de *sobreajuste* a datos ruidosos).
- C pequeño: violar es barato; el óptimo prefiere $\|w\|$ pequeña (pasillo ancho) aunque varios puntos queden dentro o mal clasificados (más *regularización*, frontera más estable).

Cuando $C \rightarrow \infty$ y los datos son separables, se recupera el margen duro. En la práctica, C se elige por validación cruzada.



Margen blando: un punto de la clase -1 invade el pasillo; su holgura ξ_i mide la profundidad de la invasión, penalizada a precio C .

14.5.2. Equivalencia con la pérdida bisagra

Proposición 14.19 (Formulación con pérdida bisagra). *El problema (14.6) es equivalente al problema sin restricciones*

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max\{0, 1 - y_i(\langle w, x_i \rangle - b)\}, \quad (14.7)$$

donde $t \mapsto \max\{0, 1-t\}$ es la pérdida bisagra (hinge loss). *Equivalente significa: mismos (w^*, b^*) óptimos y mismo valor óptimo.*

Demostración. Fijemos (w, b) y preguntémonos por el mejor ξ factible en (14.6) para ese (w, b) . Las restricciones sobre ξ_i son

$$\xi_i \geq 1 - y_i(\langle w, x_i \rangle - b) \quad \text{y} \quad \xi_i \geq 0,$$

o sea $\xi_i \geq \max\{0, 1 - y_i(\langle w, x_i \rangle - b)\}$. Como el objetivo es *creciente* en cada ξ_i (coeficiente $C > 0$), lo óptimo es tomar cada ξ_i en su cota inferior:

$$\xi_i^*(w, b) = \max\{0, 1 - y_i(\langle w, x_i \rangle - b)\}.$$

Sustituyendo este $\xi^*(w, b)$ en el objetivo de (14.6) se obtiene exactamente el objetivo de (14.7). Minimizar primero en ξ (con (w, b) fijo) y luego en (w, b) da el mismo resultado que minimizar en conjunto, así que ambos problemas comparten óptimos y valor óptimo. $\square$

Observación 14.20 (Lectura estadística). La forma (14.7) revela al SVM como un método de *minimización de riesgo empírico regularizado*: pérdida bisagra (una aproximación convexa de la pérdida 0–1 “¿me equivoqué o no?”) más penalización $\frac{1}{2} \|w\|^2$ (regularización de Tikhonov / ridge). La pérdida bisagra no es diferenciable en el codo $t = 1$, pero sí es convexa: los métodos de subgradiente del capítulo correspondiente aplican directamente, y así es como se entrena a gran escala [8].

Teorema 14.21 (Dual del margen blando, enunciado). *El dual lagrangiano de (14.6) es*

$$\begin{aligned} \max_{\alpha \in \mathbb{R}^m} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{s. a.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, m, \end{aligned} \quad (14.8)$$

y vale la dualidad fuerte. Es idéntico al dual de margen duro (14.5) salvo por las cotas superiores $\alpha_i \leq C$ (box constraints).

La derivación repite la de la Sección 14.4 con un multiplicador extra $\mu_i \geq 0$ para cada $\xi_i \geq 0$; la estacionariedad en ξ_i da $C - \alpha_i - \mu_i = 0$, y eliminar $\mu_i = C - \alpha_i \geq 0$ produce la cota $\alpha_i \leq C$. Los detalles quedan como ejercicio guiado (Ejercicio 14.26). La interpretación de las cotas es elegante: todo punto con $\xi_i^* > 0$ (los que pagan multa) tiene $\alpha_i^* = C$, pues la holgura complementaria de $\mu_i \xi_i = 0$ fuerza $\mu_i^* = 0$ y por tanto $\alpha_i^* = C$ (el recíproco puede fallar en casos degenerados, igual que con los vectores soporte); el precio sombra de cada dato está *topado* por el precio C de la violación, porque siempre existe la opción de “comprar holgura”.

14.6. Un SVM resuelto a mano, de principio a fin [P5]

Ejemplo 14.22 (SVM en $\mathbb{R}^2$ con cuatro puntos). Considera la muestra en $\mathbb{R}^2$:

i	1	2	3	4
x_i	(2, 0)	(4, 0)	(0, 0)	(-1, 2)
y_i	+1	+1	-1	-1

Encontrar el hiperplano de margen máximo, los vectores soporte, los multiplicadores y el margen; verificar con el dual.

Solución. Paso 0: conjetura geométrica. Dibuja los puntos: los positivos están a la derecha ($x_{(1)} \geq 2$), los negativos a la izquierda ($x_{(1)} \leq 0$), donde $x_{(1)}$ denota la primera coordenada. El par de puntos más cercano entre clases es $x_1 = (2, 0)$ y $x_3 = (0, 0)$, a distancia 2. Conjetura: el hiperplano óptimo es la mediatriz vertical $x_{(1)} = 1$, es decir w^* proporcional a $(1, 0)$, con margen $\gamma^* = 1$. Ahora lo *demostramos* con KKT (recuerda: en un problema convexo con Slater, encontrar un punto KKT es certificar el óptimo global).

Paso 1: candidato primal. Si el margen es 1, entonces $\|w^*\| = 1/\gamma^* = 1$, y con dirección $(1, 0)$: $w^* = (1, 0)$. El hiperplano $\langle w^*, x \rangle = b^*$ debe ser $x_{(1)} = 1$, así que $b^* = 1$. Verifiquemos factibilidad primal (condición (c)), calculando $y_i(\langle w^*, x_i \rangle - b^*)$:

$$\begin{aligned} i = 1: & (+1)(2 - 1) = 1 \geq 1 \quad (\text{activa}) \\ i = 2: & (+1)(4 - 1) = 3 \geq 1 \quad (\text{inactiva, holgura } 2) \\ i = 3: & (-1)(0 - 1) = 1 \geq 1 \quad (\text{activa}) \\ i = 4: & (-1)(-1 - 1) = 2 \geq 1 \quad (\text{inactiva, holgura } 1) \end{aligned}$$

Factible, con restricciones activas exactamente en $i \in \{1, 3\}$.

Paso 2: holgura complementaria. Por la condición (e), los puntos inactivos deben tener multiplicador cero: $\alpha_2^* = \alpha_4^* = 0$. Los candidatos a vectores soporte son x_1 y x_3 .

Paso 3: estacionariedad. La condición (a) exige

$$w^* = \sum_i \alpha_i^* y_i x_i = \alpha_1^* (2, 0) - \alpha_3^* (0, 0) = (2\alpha_1^*, 0).$$

Igualando a $w^* = (1, 0)$: $2\alpha_1^* = 1$, luego $\alpha_1^* = \frac{1}{2}$. La condición (b) exige $\sum_i \alpha_i^* y_i = \alpha_1^* - \alpha_3^* = 0$,

luego $\alpha_3^* = \frac{1}{2}$. (Fíjate que $x_3 = (0, 0)$ aporta el vector nulo a la suma de (a), pero su multiplicador es imprescindible para equilibrar la condición (b): ¡también es vector soporte!)

Paso 4: factibilidad dual. $\alpha^* = (\frac{1}{2}, 0, \frac{1}{2}, 0) \geq 0$. Las cinco condiciones KKT se cumplen; como el problema es convexo con Slater, $(w^*, b^*) = ((1, 0), 1)$ es el óptimo global, con vectores soporte $S = \{1, 3\}$, margen $\gamma^* = 1/\|w^*\| = 1$ y valor primal $\frac{1}{2}\|w^*\|^2 = \frac{1}{2}$.

Paso 5: verificación por el dual. Resolvamos (14.5) directamente. Guiados por el primal, busquemos el óptimo dual con $\alpha_2 = \alpha_4 = 0$ y parametricemos $\alpha_1 = \alpha_3 = a \geq 0$ (esto impone la restricción $\alpha_1 y_1 + \alpha_3 y_3 = a - a = 0$, factible). Los productos internos relevantes son

$$\langle x_1, x_1 \rangle = 4, \quad \langle x_1, x_3 \rangle = 0, \quad \langle x_3, x_3 \rangle = 0.$$

El objetivo dual queda

$$q(a) = (a + a) - \frac{1}{2}[a^2 y_1 y_1(4) + 2a^2 y_1 y_3(0) + a^2 y_3 y_3(0)] = 2a - 2a^2.$$

Es una parábola cóncava; su máximo está en $q'(a) = 2 - 4a = 0$, o sea $a^* = \frac{1}{2}$, con valor $q(a^*) = 1 - \frac{1}{2} = \frac{1}{2}$. El valor dual coincide con el primal ($\frac{1}{2} = \frac{1}{2}$): *salto de dualidad cero*, como predice la dualidad fuerte. Recuperamos además $w^* = \frac{1}{2}(2, 0) - \frac{1}{2}(0, 0) = (1, 0)$ y, usando el vector soporte $j = 1$: $b^* = \langle w^*, x_1 \rangle - y_1 = 2 - 1 = 1$. Todo cuadra.

Moraleja. Los puntos $x_2 = (4, 0)$ y $x_4 = (-1, 2)$ pueden eliminarse de la muestra sin alterar la solución: no son vectores soporte. El clasificador final es $f(x) = \text{sgn}(x_{(1)} - 1)$. $\square$

14.7. Nota aplicada: SVM en economía y sugerencia de exposición final [P5]

SVM en economía aplicada. Tres familias de aplicaciones donde el SVM (o sus variantes kernelizadas) aparece en la literatura empírica:

- *Riesgo de crédito:* clasificar solicitantes en pagará/incumplirá a partir de historial, ingresos y variables sociodemográficas (Ejemplo 14.2). Los bancos centrales y supervisores usan clasificadores de este tipo en alerta temprana de quiebras bancarias y de crisis.
- *Focalización de pobreza:* predecir si un hogar es pobre/no pobre combinando encuestas (ENAH en el caso peruano) con variables proxy baratas, incluidas características extraídas de imágenes satelitales nocturnas o de techos de viviendas; el clasificador permite focalizar programas sociales donde no hay censo reciente.
- *Texto como dato:* clasificar comunicados de política monetaria en restrictivos/expansivos (*hawkish/dovish*), noticias en positivas/negativas para índices de incertidumbre, o descripciones ocupacionales en categorías; cada documento se convierte en un vector de frecuencias de palabras (n enorme, motivo por el que el dual y los kernels importan).

Sugerencia concreta de exposición final del curso. Un proyecto redondo y factible en dos semanas:

1. *Teoría* (10 minutos): presentar la cadena separación $\rightarrow$ margen $\rightarrow$ QP primal $\rightarrow$ KKT $\rightarrow$ dual $\rightarrow$ kernel, con el Ejemplo 14.22 resuelto en pizarra.

2. *Implementación* (Python con `cvxpy` + `scikit-learn`, o Julia con `JuMP`): resolver el primal (14.6) y el dual (14.8) como QPs explícitos sobre un dataset económico público (por ejemplo, un dataset de riesgo crediticio, o pobreza de hogares construido desde una encuesta); verificar numéricamente (i) que primal y dual dan el mismo valor (dualidad fuerte), (ii) la holgura complementaria, e (iii) identificar los vectores soporte y contar cuántos son ($|S| \ll m$ típicamente).
3. *Extensión* (5 minutos): repetir con kernel gaussiano y comentar el efecto de C y σ sobre la frontera.

Como referencias del proyecto: el capítulo de SVM de [8] (formulaciones primal/dual, entrenamiento a gran escala y pérdida bisagra), [4] para el marco de dualidad y KKT en dimensión finita con el rigor de este cuaderno, y [2, sec. 8.6] para la familia de problemas de clasificación como optimización convexa (incluyendo variantes robustas y logísticas).

Resumen del capítulo

- **Clasificar es separar:** una muestra etiquetada es linealmente separable si y solo si las cápsulas convexas de las dos clases son disjuntas (Teorema 14.5); el clasificador lineal es un hiperplano separador.
- **Margen:** la distancia de x_0 al hiperplano $\langle a, x \rangle = \beta$ es $|\langle a, x_0 \rangle - \beta| / \|a\|$ (Lema 14.6). Maximizar el margen geométrico, tras la normalización canónica $\min_i y_i (\langle w, x_i \rangle - b) = 1$, equivale al QP convexo $\min \frac{1}{2} \|w\|^2$ s.a. $y_i (\langle w, x_i \rangle - b) \geq 1$; el margen óptimo es $1 / \|w^*\|$.
- **KKT:** estacionariedad da $w^* = \sum_i \alpha_i^* y_i x_i$ y $\sum_i \alpha_i^* y_i = 0$; holgura complementaria define los *vectores soporte* ($\alpha_i^* > 0 \Rightarrow$ restricción activa). Solo ellos determinan w^* y $b^* = \langle w^*, x_j \rangle - y_j$, $j \in S$.
- **Dual:** $\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle$ s.a. $\sum_i \alpha_i y_i = 0$, $\alpha \geq 0$; dualidad fuerte por Slater. El dual solo ve productos internos $\Rightarrow$ *kernel trick*: reemplazar $\langle x_i, x_j \rangle$ por $K(x_i, x_j)$ (polinomial, gaussiano) clasifica no linealmente sin calcular el mapa ϕ .
- **Margen blando:** con holguras ξ_i y precio C , el problema $\min \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$ siempre es factible; equivale a minimizar pérdida bisagra regularizada (Proposición 14.19); su dual solo agrega las cotas $0 \leq \alpha_i \leq C$.
- **Método de trabajo:** conjeturar el hiperplano geométricamente, verificar las cinco condiciones KKT y confirmar con el dual que el salto de dualidad es cero (Ejemplo 14.22).

14.8. Ejercicios [P5]

Ejercicio 14.23 (Distancias y márgenes). Considera el hiperplano $H = \{x \in \mathbb{R}^2 : 3x_{(1)} + 4x_{(2)} = 10\}$ y la muestra $x_1 = (2, 2)$ con $y_1 = +1$ y $x_2 = (0, 0)$ con $y_2 = -1$. (a) Calcula la distancia de cada punto a H . (b) Calcula el margen funcional y el margen geométrico de cada punto respecto

de $(w, b) = ((3, 4), 10)$. (c) Reescala (w, b) a la normalización canónica para esta muestra y comprueba que los márgenes geométricos no cambian.

Solución. (a) Con $a = (3, 4)$, $\|a\| = \sqrt{9+16} = 5$ y $\beta = 10$ (Lema 14.6):

$$\text{dist}(x_1, H) = \frac{|3(2) + 4(2) - 10|}{5} = \frac{|14 - 10|}{5} = \frac{4}{5}, \quad \text{dist}(x_2, H) = \frac{|0 - 10|}{5} = 2.$$

(b) Márgenes funcionales: $\hat{\gamma}_1 = (+1)(14 - 10) = 4$ y $\hat{\gamma}_2 = (-1)(0 - 10) = 10$; ambos positivos, así que el hiperplano clasifica bien ambos puntos. Márgenes geométricos: $\gamma_1 = \hat{\gamma}_1 / \|w\| = 4/5$ y $\gamma_2 = 10/5 = 2$, que coinciden con las distancias de (a), como debe ser. (c) El mínimo margen funcional es $\hat{\gamma} = \min\{4, 10\} = 4$; el representante canónico es $(w, b)/4 = ((\frac{3}{4}, 1), \frac{10}{4})$. Con él: margen funcional de x_1 igual a $4/4 = 1$ (el mínimo, como exige la normalización) y de x_2 igual a $10/4$; y $\|w/4\| = 5/4$, de modo que los márgenes geométricos son $1/(5/4) = 4/5$ y $(10/4)/(5/4) = 2$: idénticos a (b). El margen geométrico es invariante al reescalamiento; el funcional no. $\square$

Ejercicio 14.24 (SVM diminuto resuelto por KKT). Resuelve a mano, vía KKT, el SVM de margen duro para los tres puntos de $\mathbb{R}^2$:

$$x_1 = (1, 1), y_1 = +1; \quad x_2 = (-1, 1), y_2 = -1; \quad x_3 = (-2, -1), y_3 = -1.$$

Da w^* , b^* , los vectores soporte, el margen y el valor óptimo, y verifica todas las condiciones KKT.

Solución. *Conjetura.* El punto positivo es $x_1 = (1, 1)$; el punto negativo más cercano es $x_2 = (-1, 1)$, a distancia 2 (misma altura). Mediatriz: la recta vertical $x_{(1)} = 0$. Candidato: $w^* = (1, 0)$, $b^* = 0$, margen 1.

Factibilidad primal. $y_1(\langle w^*, x_1 \rangle - 0) = 1 \geq 1$ (activa); $y_2(\langle w^*, x_2 \rangle - 0) = (-1)(-1) = 1 \geq 1$ (activa); $y_3(\langle w^*, x_3 \rangle - 0) = (-1)(-2) = 2 \geq 1$ (inactiva).

Holgura complementaria. x_3 inactivo $\Rightarrow \alpha_3^* = 0$.

Estacionariedad en w . $w^* = \alpha_1^*(1, 1) - \alpha_2^*(-1, 1) = (\alpha_1^* + \alpha_2^*, \alpha_1^* - \alpha_2^*)$. Igualando a $(1, 0)$: $\alpha_1^* + \alpha_2^* = 1$ y $\alpha_1^* - \alpha_2^* = 0$, de donde $\alpha_1^* = \alpha_2^* = \frac{1}{2}$.

Estacionariedad en b . $\sum_i \alpha_i^* y_i = \frac{1}{2} - \frac{1}{2} - 0 = 0$. Se cumple.

Factibilidad dual. $\alpha^* = (\frac{1}{2}, \frac{1}{2}, 0) \geq 0$.

Las cinco condiciones KKT valen y el problema es convexo con Slater: óptimo global certificado. Vectores soporte $S = \{1, 2\}$; margen $1/\|w^*\| = 1$; valor óptimo $\frac{1}{2}\|w^*\|^2 = \frac{1}{2}$. Verificación dual rápida: con $\alpha_1 = \alpha_2 = a$ y $\alpha_3 = 0$, los productos internos son $\langle x_1, x_1 \rangle = 2$, $\langle x_1, x_2 \rangle = -1 + 1 = 0$ y $\langle x_2, x_2 \rangle = 2$, de modo que

$$\sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle = a^2(2) - 2a^2(0) + a^2(2) = 4a^2, \quad q(a) = 2a - 2a^2,$$

maximizada en $a = \frac{1}{2}$ con valor $q(\frac{1}{2}) = \frac{1}{2}$: salto de dualidad cero, en concordancia con el valor primal. $\square$

Ejercicio 14.25 (SVM sin intercepto). Considera la variante del SVM de margen duro en la que el hiperplano pasa obligatoriamente por el origen (sin intercepto, $b = 0$): $\min_w \frac{1}{2} \|w\|^2$ s.a. $y_i \langle w, x_i \rangle \geq 1, i = 1, \dots, m$. Deriva su dual completo. ¿Qué restricción del dual (14.5) desaparece y por qué?

Solución. Lagrangiano: $L(w, \alpha) = \frac{1}{2} \|w\|^2 + \sum_i \alpha_i (1 - y_i \langle w, x_i \rangle)$ con $\alpha \geq 0$. Ahora no hay variable b , así que el único paso de minimización es en w : es una cuadrática estrictamente convexa cuyo mínimo satisface $w(\alpha) = \sum_i \alpha_i y_i x_i$. Sustituyendo, exactamente como en los Pasos 3–4 de la Sección 14.4:

$$q(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle,$$

y el dual es $\max_{\alpha \geq 0} q(\alpha)$, sin la restricción $\sum_i \alpha_i y_i = 0$. La razón: esa restricción provenía de exigir que el lagrangiano no fuera $-\infty$ al minimizar sobre b (el coeficiente de b debía anularse). Sin b en el problema, no hay término lineal que domar y la restricción de igualdad desaparece. Moraleja: cada restricción del dual es la huella de una variable del primal (y viceversa). $\square$

Ejercicio 14.26 (Dual del margen blando). Deriva el dual (14.8) del problema de margen blando (14.6). Indicación: asigna multiplicadores $\alpha_i \geq 0$ a las restricciones de margen y $\mu_i \geq 0$ a las restricciones $\xi_i \geq 0$, y minimiza el lagrangiano en (w, b, ξ) .

Solución. El lagrangiano es

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_i \xi_i + \sum_i \alpha_i (1 - \xi_i - y_i (\langle w, x_i \rangle - b)) - \sum_i \mu_i \xi_i,$$

con $\alpha, \mu \geq 0$. Minimizamos por bloques:

En w : igual que antes, $w(\alpha) = \sum_i \alpha_i y_i x_i$.

En b : coeficiente $\sum_i \alpha_i y_i$; para no caer a $-\infty$, restricción dual $\sum_i \alpha_i y_i = 0$.

En ξ_i : el coeficiente de ξ_i en L es $C - \alpha_i - \mu_i$. Como ξ_i recorre todo $\mathbb{R}$ en la minimización del lagrangiano (las restricciones ya están incorporadas vía μ), si $C - \alpha_i - \mu_i \neq 0$ el ínfimo es $-\infty$; luego el dual exige

$$C - \alpha_i - \mu_i = 0 \quad \Longleftrightarrow \quad \mu_i = C - \alpha_i.$$

Con esta condición, todos los términos en ξ se cancelan y el resto de la sustitución es idéntico al caso duro: $q(\alpha, \mu) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle$. Finalmente, eliminamos μ : la factibilidad dual $\mu_i \geq 0$ se convierte en $C - \alpha_i \geq 0$, o sea $\alpha_i \leq C$. Junto con $\alpha_i \geq 0$ obtenemos las cotas de caja $0 \leq \alpha_i \leq C$ y el problema (14.8). Como (14.6) es convexo y cumple Slater (tomar ξ grande), hay dualidad fuerte. $\square$

Ejercicio 14.27 (Un kernel explícito). Sea $K(x, z) = (1 + \langle x, z \rangle)^2$ para $x, z \in \mathbb{R}^2$. Encuentra explícitamente una aplicación $\phi: \mathbb{R}^2 \rightarrow \mathbb{R}^6$ tal que $K(x, z) = \langle \phi(x), \phi(z) \rangle$. ¿Qué tipo de fronteras de decisión puede producir un SVM con este kernel en $\mathbb{R}^2$?

Solución. Expandimos con $\langle x, z \rangle = x_1 z_1 + x_2 z_2$:

$$K(x, z) = (1 + x_1 z_1 + x_2 z_2)^2 = 1 + x_1^2 z_1^2 + x_2^2 z_2^2 + 2x_1 z_1 + 2x_2 z_2 + 2x_1 z_1 x_2 z_2.$$

Agrupando cada sumando como producto de un factor en x por el mismo factor en z :

$$\phi(x) = (1, x_1^2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1x_2) \in \mathbb{R}^6,$$

y se comprueba directamente que $\langle \phi(x), \phi(z) \rangle$ reproduce los seis sumandos de la expansión (los $\sqrt{2}$ generan los factores 2 al multiplicarse consigo mismos). Un hiperplano en $\mathbb{R}^6$ sobre estas coordenadas es, visto en $\mathbb{R}^2$, una ecuación general de segundo grado

$$c_0 + c_1 x_1^2 + c_2 x_2^2 + c_3 x_1 + c_4 x_2 + c_5 x_1 x_2 = 0,$$

es decir, una *cónica*: elipses, parábolas, hipérbolas o pares de rectas. El SVM con kernel cuadrático puede, por ejemplo, encerrar una clase dentro de una elipse, algo imposible para un clasificador lineal en $\mathbb{R}^2$; y todo ello resolviendo el mismo QP dual (14.5) con K en lugar del producto interno. $\square$

Capítulo 15

Métodos de optimización de primer orden [P4]

Bloque de métodos numéricos, en la parte final del curso. Bibliografía: Nocedal y Wright [5], Caps. 3 y 5; Wright y Recht [8], Caps. 3–4; Snyman y Wilke [7], Caps. 1–2.

¿Para qué sirve esto en Microeconomía?

Seamos honestos: en el examen de Microeconomía *nadie* va a pedirte que ejecutes un descenso de gradiente. Los teoremas que se evalúan allí son los de los capítulos anteriores (concavidad, KKT, envolvente, dualidad). Entonces, ¿por qué estudiar este capítulo? Por tres razones muy concretas. (i) Estos métodos son el *motor* de la economía computacional y de la econometría estructural: estimar un modelo *es* minimizar una función objetivo (la log-verosimilitud negativa en MLE, el criterio cuadrático en GMM, la distancia entre momentos simulados y observados al calibrar un modelo de equilibrio general) y esa minimización la hace, en la práctica, un algoritmo iterativo como los de este capítulo. (ii) El ajuste walrasiano de precios (*tatonnement*) que aparece en [9], cap. 17, es literalmente una dinámica de gradiente sobre el exceso de demanda: los precios suben donde hay exceso de demanda y bajan donde hay exceso de oferta; entender el descenso de gradiente es entender por qué (y cuándo) ese proceso converge al equilibrio. (iii) Son el tema ideal para los trabajos prácticos computacionales y la exposición final del curso: se pueden implementar en veinte líneas de Python o Julia, se visualizan muy bien, y las demostraciones de convergencia son elementales pero elegantes. Referencias: [5] caps. 3 y 5, [8] caps. 3–4, [7] caps. 1–2, [6] cap. 5, [2] cap. 9.

15.1. Panorama: por qué métodos iterativos [P4]

15.1.1. No hay fórmulas cerradas

En los capítulos anteriores aprendimos a *caracterizar* las soluciones de un problema de optimización: si f es convexa y diferenciable, x^* minimiza f en $\mathbb{R}^n$ si y solo si $\nabla f(x^*) = 0$; con restricciones, las condiciones KKT juegan ese papel. Pero caracterizar no es lo mismo que *calcular*. El sistema $\nabla f(x) = 0$ es un sistema de n ecuaciones (en general no lineales) con n incógnitas,

y salvo casos muy especiales (funciones cuadráticas, problemas con mucha estructura) *no existe una fórmula cerrada* para su solución. Piensa en la log-verosimilitud de un modelo probit con 20 regresores: nadie puede despejar el estimador “a mano”.

La salida es construir una **sucesión de aproximaciones** $x_0, x_1, x_2, \dots$ que converja a la solución. Casi todos los métodos de este capítulo tienen la misma estructura general:

$$x_{k+1} = x_k + t_k d_k, \quad (15.1)$$

donde:

- $d_k \in \mathbb{R}^n$ es la **dirección de búsqueda** (*search direction*): hacia dónde nos movemos;
- $t_k > 0$ es el **tamaño de paso** (*step size* o, por tradición del aprendizaje automático, *learning rate*): cuánto nos movemos.

Un método queda especificado al decir cómo elige d_k y cómo elige t_k . Se llaman métodos *de primer orden* (*first-order methods*) porque solo usan valores de f y de su gradiente ∇f ; los métodos *de segundo orden* (como Newton) usan además la Hessiana, que en dimensiones grandes puede ser carísima de calcular y almacenar.

15.1.2. Direcciones de descenso

Queremos que cada paso *mejore* el valor objetivo. Eso motiva la siguiente definición.

Definición 15.1 (Dirección de descenso). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $x \in \mathbb{R}^n$. Un vector $d \in \mathbb{R}^n$ es una **dirección de descenso** (*descent direction*) de f en x si existe $\delta > 0$ tal que

$$f(x + td) < f(x) \quad \text{para todo } t \in (0, \delta).$$

Es decir: moverse desde x en la dirección d , con paso suficientemente pequeño, *estrictamente* reduce el valor de f .

¿Cómo reconocer una dirección de descenso sin evaluar f en infinitos puntos? Con el gradiente: basta que d forme un ángulo obtuso con $\nabla f(x)$.

Proposición 15.2 (Caracterización por el gradiente). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en x . Si

$$\langle \nabla f(x), d \rangle < 0,$$

entonces d es una dirección de descenso de f en x . En particular, si $\nabla f(x) \neq 0$, la elección $d = -\nabla f(x)$ siempre es una dirección de descenso, pues $\langle \nabla f(x), -\nabla f(x) \rangle = -\|\nabla f(x)\|^2 < 0$.

Demostración. Definamos la función de una variable $\varphi(t) = f(x + td)$, que “rebana” a f a lo largo de la recta que pasa por x con dirección d . Por la regla de la cadena (que vimos en el capítulo de preliminares), φ es derivable en $t = 0$ y

$$\varphi'(0) = \langle \nabla f(x), d \rangle < 0.$$

Ahora usamos la definición de derivada como límite:

$$\lim_{t \rightarrow 0^+} \frac{\varphi(t) - \varphi(0)}{t} = \varphi'(0) < 0.$$

Como el límite es un número estrictamente negativo, existe $\delta > 0$ tal que el cociente incremental es negativo para todo $t \in (0, \delta)$ (si no, habría una sucesión $t_j \rightarrow 0^+$ con cociente ≥ 0 , y el límite sería ≥ 0 , contradicción). Para esos t , como $t > 0$,

$$\frac{\varphi(t) - \varphi(0)}{t} < 0 \implies \varphi(t) < \varphi(0),$$

es decir $f(x + td) < f(x)$. Eso es exactamente la Definición 15.1. □

Intuición

El gradiente $\nabla f(x)$ apunta en la dirección de *máximo crecimiento* local de f (lo vimos al estudiar derivadas direccionales: $f'(x; d) = \langle \nabla f(x), d \rangle$ se maximiza sobre $\|d\| = 1$ cuando d es paralelo a $\nabla f(x)$). Por lo tanto $-\nabla f(x)$ apunta en la dirección de *máximo descenso* local: es la dirección en la que “el terreno baja más rápido”. La condición $\langle \nabla f(x), d \rangle < 0$ dice que d tiene una componente positiva a lo largo de $-\nabla f(x)$: no hace falta bajar por la máxima pendiente, basta con que la trayectoria apunte “cuesta abajo”. Un esquiador miope que solo ve la pendiente bajo sus pies puede elegir cualquier dirección que descienda; el descenso de gradiente es el esquiador que siempre elige la más empinada.

15.1.3. Criterio de parada

Un algoritmo iterativo necesita saber cuándo detenerse. Como en un minimizador interior se cumple $\nabla f(x^*) = 0$, el criterio natural es parar cuando el gradiente es “casi cero”:

$$\|\nabla f(x_k)\| \leq \varepsilon,$$

para una tolerancia $\varepsilon > 0$ fijada de antemano (por ejemplo $\varepsilon = 10^{-6}$). Otros criterios usados en la práctica: el progreso relativo $|f(x_{k+1}) - f(x_k)| \leq \varepsilon(1 + |f(x_k)|)$, el desplazamiento $\|x_{k+1} - x_k\| \leq \varepsilon$, o un número máximo de iteraciones como salvaguarda. Para funciones convexas veremos algo mejor: se pueden dar *garantías a priori* del tipo “después de k iteraciones, el error $f(x_k) - f^*$ es a lo más tanto”; estas cotas son el corazón teórico del capítulo.

15.2. Suavidad y convexidad fuerte [P4]

Para poder *demostrar* que un método converge, y a qué velocidad, necesitamos hipótesis cuantitativas sobre f . Las dos hipótesis estrella son: una cota *superior* a la curvatura (suavidad) y una cota *inferior* (convexidad fuerte).

15.2.1. Gradiente Lipschitz y el lema de descenso

Definición 15.3 (Función L -suave). Sea $L > 0$. Una función diferenciable $f: \mathbb{R}^n \rightarrow \mathbb{R}$ es L -suave (L -smooth), o tiene **gradiente L -Lipschitz**, si

$$\|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\| \quad \text{para todos } x, y \in \mathbb{R}^n.$$

La condición dice que el gradiente no puede cambiar arbitrariamente rápido: si me muevo una distancia pequeña, la “pendiente” cambia poco. Si f es dos veces diferenciable, ser L -suave equivale a que todos los autovalores de la Hessiana $\nabla^2 f(x)$ estén acotados por L en valor absoluto (en el caso convexo: $0 \preceq \nabla^2 f(x) \preceq LI$ para todo x). Por ejemplo, para una cuadrática $f(x) = \frac{1}{2}x^\top Qx - b^\top x$ con Q simétrica semidefinida positiva, $\nabla f(x) = Qx - b$ y

$$\|\nabla f(y) - \nabla f(x)\| = \|Q(y - x)\| \leq \lambda_{\max}(Q) \|y - x\|,$$

así que $L = \lambda_{\max}(Q)$, el mayor autovalor de Q (y es la mejor constante posible: basta tomar $y - x$ igual al autovector asociado).

La consecuencia clave de la L -suavidad es que f queda atrapada *por debajo* de una parábola: es el llamado *lema de descenso*, la herramienta más usada de todo el capítulo.

Lema 15.4 (Lema de descenso (*descent lemma*)). Si $f: \mathbb{R}^n \rightarrow \mathbb{R}$ es L -suave, entonces para todos $x, y \in \mathbb{R}^n$:

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2. \quad (15.2)$$

Demostración. La idea: recorrer el segmento de x a y , escribir el cambio de f como la integral de su derivada a lo largo del segmento, y controlar cuánto puede desviarse esa derivada de su valor inicial usando la condición de Lipschitz.

Paso 1 (parametrizar el segmento). Definimos $g(s) = f(x + s(y - x))$ para $s \in [0, 1]$; así $g(0) = f(x)$ y $g(1) = f(y)$. Por la regla de la cadena,

$$g'(s) = \langle \nabla f(x + s(y - x)), y - x \rangle.$$

Paso 2 (teorema fundamental del cálculo). Como g es derivable con derivada continua,

$$f(y) - f(x) = g(1) - g(0) = \int_0^1 g'(s) ds = \int_0^1 \langle \nabla f(x + s(y - x)), y - x \rangle ds.$$

Paso 3 (sumar y restar el término lineal). Queremos comparar con $\langle \nabla f(x), y - x \rangle$, que es una constante respecto de s y por tanto $\int_0^1 \langle \nabla f(x), y - x \rangle ds = \langle \nabla f(x), y - x \rangle$. Restando:

$$f(y) - f(x) - \langle \nabla f(x), y - x \rangle = \int_0^1 \langle \nabla f(x + s(y - x)) - \nabla f(x), y - x \rangle ds.$$

Paso 4 (acotar el integrando). Para cada s fijo, aplicamos primero la desigualdad de Cauchy–Schwarz y luego la L -suavidad al par de puntos $x + s(y - x)$ y x , cuya distancia es $s\|y - x\|$:

$$\langle \nabla f(x + s(y - x)) - \nabla f(x), y - x \rangle \leq \|\nabla f(x + s(y - x)) - \nabla f(x)\| \cdot \|y - x\| \leq L s \|y - x\|^2.$$

Paso 5 (integrar la cota). Como $\int_0^1 s \, ds = \frac{1}{2}$,

$$f(y) - f(x) - \langle \nabla f(x), y - x \rangle \leq L \|y - x\|^2 \int_0^1 s \, ds = \frac{L}{2} \|y - x\|^2,$$

que es exactamente (15.2). □

Intuición

Compara (15.2) con la caracterización de convexidad por el gradiente: $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ dice que la gráfica de f está *por encima* de su tangente; el lema de descenso dice que está *por debajo* de la tangente más una corrección cuadrática $\frac{L}{2} \|y - x\|^2$. Es decir, en cada punto x podemos “techar” a f con una parábola de curvatura L que la toca en x . Esto es oro puro para diseñar algoritmos: si no sé minimizar f , minimizo la parábola techo (¡eso sí se hace con una fórmula!) y me garantizo bajar. Veremos que minimizar el techo en y da exactamente el paso de gradiente $y = x - \frac{1}{L} \nabla f(x)$.

15.2.2. Convexidad fuerte y número de condición

Definición 15.5 (Convexidad fuerte). Sea $m > 0$. Una función diferenciable $f: \mathbb{R}^n \rightarrow \mathbb{R}$ es **fuertemente convexa** (*strongly convex*) con módulo m (o *m-fuertemente convexa*) si para todos $x, y \in \mathbb{R}^n$:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{m}{2} \|y - x\|^2. \quad (15.3)$$

Equivalentemente: la función $x \mapsto f(x) - \frac{m}{2} \|x\|^2$ es convexa. Si f es dos veces diferenciable, equivale a $\nabla^2 f(x) \succeq mI$ para todo x (todos los autovalores de la Hessiana son $\geq m$).

Mientras la L -suavidad pone un *techo* parabólico, la convexidad fuerte pone un *piso* parabólico: la función tiene curvatura mínima m en todas las direcciones, sus conjuntos de nivel son “ovalados” y acotados, y el minimizador existe y es único (el piso parabólico crece a infinito, así que f es coerciva; la unicidad sale de la convexidad estricta). Para una cuadrática con matriz $Q \succ 0$, el módulo óptimo es $m = \lambda_{\min}(Q)$.

Cuando f es a la vez m -fuertemente convexa y L -suave (necesariamente $m \leq L$), el cociente

$$\kappa = \frac{L}{m} \geq 1 \quad (15.4)$$

se llama **número de condición** (*condition number*) de f . Para una cuadrática, $\kappa = \lambda_{\max}(Q)/\lambda_{\min}(Q)$.

Intuición

Geométricamente, κ mide qué tan “alargadas” son las curvas de nivel. Para $f(x, y) = x^2 + 10y^2$ las curvas de nivel son elipses cuyo semieje en x es $\sqrt{10} \approx 3.16$ veces el semieje en y : un valle angosto y largo. Aquí $Q = \text{diag}(2, 20)$, de modo que $m = 2$, $L = 20$ y $\kappa = 10$. Si $\kappa = 1$ ($L = m$), las curvas de nivel son *circunferencias* y el antigradiente apunta exactamente al minimizador: el descenso de gradiente llega en un paso. Cuanto mayor es κ , más se desalinean el antigradiente (perpendicular a la curva de nivel) y la dirección al

óptimo (a lo largo del valle), y más lento e “histérico” se vuelve el método, como veremos con precisión. En econometría, un κ enorme aparece cuando dos parámetros están casi colineales (identificación débil): la verosimilitud tiene un valle plano y los optimizadores sufren.

15.3. Descenso de gradiente [P4]

15.3.1. El algoritmo

El **descenso de gradiente** (*gradient descent*) es el método (15.1) con la dirección de máximo descenso local, $d_k = -\nabla f(x_k)$:

$$x_{k+1} = x_k - t_k \nabla f(x_k). \quad (15.5)$$

Ejemplo 15.6 (El algoritmo, paso a paso). Descripción completa del método, en forma de receta:

1. **Entrada:** punto inicial $x_0 \in \mathbb{R}^n$, tolerancia $\varepsilon > 0$, regla para elegir el paso t_k .
2. **Para** $k = 0, 1, 2, \dots$:
3. Calcular $g_k = \nabla f(x_k)$.
4. **Si** $\|g_k\| \leq \varepsilon$: **parar** y devolver x_k (el gradiente es casi nulo, estamos cerca de un punto estacionario; si f es convexa, de un minimizador global).
5. Elegir el tamaño de paso $t_k > 0$ (ver abajo).
6. Actualizar $x_{k+1} = x_k - t_k g_k$.

Cada iteración cuesta *una* evaluación de gradiente y $O(n)$ operaciones aritméticas: por eso el método escala a problemas con millones de variables.

15.3.2. Elección del paso

Todo el arte está en t_k . Las tres reglas clásicas:

(a) **Paso fijo** $t_k = 1/L$. Si f es L -suave, el lema de descenso nos dice exactamente cuánto bajamos. Sustituyendo $y = x_k - t g_k$ (con $g_k = \nabla f(x_k)$) en (15.2), y usando $\langle g_k, -t g_k \rangle = -t \|g_k\|^2$:

$$f(x_k - t g_k) \leq f(x_k) - t \|g_k\|^2 + \frac{Lt^2}{2} \|g_k\|^2 = f(x_k) - t \left(1 - \frac{Lt}{2}\right) \|g_k\|^2.$$

El miembro derecho es una parábola en t que se minimiza en $t = 1/L$; con esa elección,

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2. \quad (15.6)$$

Conclusión: con paso $1/L$ el método *siempre* desciende, y desciende tanto más cuanto mayor es el gradiente. La desigualdad (15.6) se llama *descenso suficiente* (*sufficient decrease*) y es el ladrillo de todas las demostraciones que siguen. Nota que cualquier $t \in (0, 2/L)$ garantiza descenso estricto (el factor $1 - Lt/2$ es positivo si $t < 2/L$); con $t > 2/L$ el método puede *divergir* (Ejercicio 15.27).

(b) **Búsqueda lineal exacta.** Elegir el mejor paso posible en la dirección actual:

$$t_k \in \arg \min_{t \geq 0} f(x_k + t d_k).$$

Es un problema de una sola variable, pero en general no tiene fórmula cerrada... salvo para cuadráticas, donde la deduciremos completa en la Sección 15.4.

(c) **Retroceso con condición de Armijo (*backtracking line search*).** En la práctica no conocemos L , y la búsqueda exacta es cara. El compromiso estándar: probar un paso “optimista” e irlo reduciendo hasta que el descenso obtenido sea una fracción razonable del descenso que promete la aproximación lineal. Fijamos parámetros $c_1 \in (0, 1)$ (típicamente $c_1 = 10^{-4}$ o 0.3) y $\beta \in (0, 1)$ (típicamente $\beta = 1/2$):

1. Empezar con $t = t_{\text{ini}}$ (por ejemplo $t_{\text{ini}} = 1$).

2. **Mientras** no se cumpla la *condición de Armijo*

$$f(x_k + t d_k) \leq f(x_k) + c_1 t \langle \nabla f(x_k), d_k \rangle, \quad (15.7)$$

reemplazar $t \leftarrow \beta t$ (“retroceder”).

3. Tomar $t_k = t$.

¿Qué dice (15.7)? La aproximación de Taylor de primer orden predice un cambio $t \langle \nabla f(x_k), d_k \rangle < 0$; Armijo exige materializar al menos la fracción c_1 de esa promesa. ¿Por qué el bucle *termina*? Porque, siendo d_k dirección de descenso,

$$\lim_{t \rightarrow 0^+} \frac{f(x_k + t d_k) - f(x_k)}{t} = \langle \nabla f(x_k), d_k \rangle < c_1 \langle \nabla f(x_k), d_k \rangle,$$

donde la desigualdad final usa que multiplicar un número *negativo* por $c_1 < 1$ lo agranda. Por definición de límite, existe $\bar{t} > 0$ tal que para todo $t \in (0, \bar{t})$ el cociente es menor que $c_1 \langle \nabla f(x_k), d_k \rangle$; multiplicando por $t > 0$ se obtiene (15.7). Como el retroceso multiplica t por $\beta < 1$ cada vez, en un número finito de reducciones cae dentro de $(0, \bar{t})$ y el bucle se detiene. Además puede probarse (ver [5], cap. 3) que el paso aceptado no es demasiado pequeño: si f es L -suave, el retroceso con $d_k = -g_k$ acepta algún $t_k \geq \min\{t_{\text{ini}}, \beta 2(1 - c_1)/L\}$, de modo que se conservan (con otras constantes) todas las garantías del paso $1/L$.

Cuidado (error común)

El tamaño de paso no es un detalle de implementación: es la diferencia entre converger y explotar. Con t demasiado grande, el paso “salta al otro lado del valle” cada vez más lejos y $f(x_k) \rightarrow +\infty$ (en la cuadrática unidimensional $f(x) = \frac{L}{2}x^2$, el mapa es $x_{k+1} = (1 - tL)x_k$, que diverge si $t > 2/L$; ver Ejercicio 15.27). Con t demasiado pequeño, el método converge pero a paso de tortuga. Y cuidado con un error de principiante: comparar gradientes de variables con *unidades* distintas (precios en soles, cantidades en toneladas) sin reescalar; eso infla artificialmente κ y arruina al método. Reescalar las variables para que tengan magnitudes comparables es, en la práctica, la mejora número uno.

15.3.3. Convergencia en el caso convexo: tasa $O(1/k)$

Teorema 15.7 (Descenso de gradiente, caso convexo L -suave). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ convexa y L -suave, con minimizador x^* y valor óptimo $f^* = f(x^*)$. El descenso de gradiente con paso fijo $t_k = 1/L$ satisface, para todo $k \geq 1$:

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|^2}{2k}.$$

En particular $f(x_k) \rightarrow f^*$, con tasa sublineal $O(1/k)$: para garantizar un error $\leq \varepsilon$ bastan $k \approx L \|x_0 - x^*\|^2 / (2\varepsilon)$ iteraciones.

Demostración. La demostración es larga pero completamente mecánica: cada paso usa una sola herramienta. La hacemos con calma. Escribimos $g_k = \nabla f(x_k)$ y $t = 1/L$.

Paso 1: cuánto bajamos en una iteración. Es (15.6), consecuencia directa del lema de descenso:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|g_k\|^2.$$

Paso 2: comparar $f(x_k)$ con f^* vía convexidad. La caracterización de primer orden de la convexidad, aplicada en el punto x_k y evaluada en $y = x^*$, da $f(x^*) \geq f(x_k) + \langle g_k, x^* - x_k \rangle$, es decir

$$f(x_k) \leq f^* + \langle g_k, x_k - x^* \rangle.$$

(El valor en x_k no supera al valor óptimo más lo que “recupera” el plano tangente al ir de x^* a x_k .)

Paso 3: combinar. Sustituyendo el Paso 2 en el Paso 1:

$$f(x_{k+1}) - f^* \leq \langle g_k, x_k - x^* \rangle - \frac{1}{2L} \|g_k\|^2.$$

Paso 4: la identidad de completar el cuadrado. Afirmamos que el miembro derecho es exactamente

$$\frac{L}{2} \left(\|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} g_k\|^2 \right) = \frac{L}{2} \left(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right),$$

donde en la última igualdad usamos que $x_{k+1} = x_k - \frac{1}{L} g_k$. Verifiquémoslo expandiendo el cuadrado (con $a = x_k - x^*$):

$$\left\| a - \frac{1}{L} g_k \right\|^2 = \|a\|^2 - \frac{2}{L} \langle a, g_k \rangle + \frac{1}{L^2} \|g_k\|^2,$$

luego

$$\frac{L}{2} \left(\|a\|^2 - \left\| a - \frac{1}{L} g_k \right\|^2 \right) = \frac{L}{2} \left(\frac{2}{L} \langle a, g_k \rangle - \frac{1}{L^2} \|g_k\|^2 \right) = \langle g_k, a \rangle - \frac{1}{2L} \|g_k\|^2. \checkmark$$

Por lo tanto:

$$f(x_{k+1}) - f^* \leq \frac{L}{2} \left(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right). \quad (15.8)$$

Observa lo que logramos: el error en *valor* está controlado por la caída de la *distancia al óptimo*. Y las distancias forman una suma telescópica.

Paso 5: telescopar. Sumamos (15.8) para $i = 0, 1, \dots, k-1$:

$$\sum_{i=0}^{k-1} (f(x_{i+1}) - f^*) \leq \frac{L}{2} \sum_{i=0}^{k-1} (\|x_i - x^*\|^2 - \|x_{i+1} - x^*\|^2) = \frac{L}{2} (\|x_0 - x^*\|^2 - \|x_k - x^*\|^2),$$

porque en la suma de la derecha cada término aparece una vez con signo $+$ y otra con signo $-$, salvo el primero y el último. Descartando el término negativo:

$$\sum_{i=0}^{k-1} (f(x_{i+1}) - f^*) \leq \frac{L}{2} \|x_0 - x^*\|^2.$$

Paso 6: la última iteración es la mejor. Por el Paso 1 la sucesión $f(x_i)$ es no creciente, así que cada sumando es $\geq f(x_k) - f^*$ y la suma (que tiene k términos) satisface

$$k(f(x_k) - f^*) \leq \sum_{i=0}^{k-1} (f(x_{i+1}) - f^*) \leq \frac{L}{2} \|x_0 - x^*\|^2.$$

Dividiendo entre k se obtiene la cota del enunciado. $\square$

15.3.4. Convergencia con convexidad fuerte: tasa lineal

Con curvatura mínima $m > 0$ el panorama mejora drásticamente: el error se multiplica por un factor fijo menor que 1 en *cada* iteración (convergencia *lineal* o *geométrica*). Lo demostramos con todo detalle para cuadráticas, donde los autovalores hacen transparente el mecanismo, y enunciamos el caso general.

Teorema 15.8 (Tasa lineal en cuadráticas). *Sea $f(x) = \frac{1}{2}x^\top Qx - b^\top x$ con Q simétrica y $mI \preceq Q \preceq LI$, $m > 0$; sea $x^* = Q^{-1}b$ su minimizador. El descenso de gradiente con paso fijo $t \in (0, 2/L)$ satisface*

$$\|x_k - x^*\| \leq \rho(t)^k \|x_0 - x^*\|, \quad \rho(t) = \max\{|1 - tm|, |1 - tL|\} < 1.$$

En particular, con $t = 1/L$: $\rho = 1 - m/L = 1 - 1/\kappa$; y el paso óptimo $t = 2/(m + L)$ da $\rho = (\kappa - 1)/(\kappa + 1)$.

Demostración. Como $\nabla f(x) = Qx - b$ y $b = Qx^*$, la iteración se escribe

$$x_{k+1} - x^* = x_k - t(Qx_k - b) - x^* = (I - tQ)(x_k - x^*).$$

El error obedece una recursión *lineal* con matriz $I - tQ$. Sea $Q = \sum_{i=1}^n \lambda_i v_i v_i^\top$ la descomposición espectral de Q (autovalores $\lambda_i \in [m, L]$, autovectores ortonormales v_i ; la vimos en preliminares). Entonces $I - tQ$ tiene los mismos autovectores con autovalores $1 - t\lambda_i$. Expandiendo el error inicial en la base ortonormal, $x_0 - x^* = \sum_i c_i v_i$, obtenemos

$$x_k - x^* = (I - tQ)^k (x_0 - x^*) = \sum_{i=1}^n c_i (1 - t\lambda_i)^k v_i,$$

y por el teorema de Pitágoras (los v_i son ortonormales):

$$\|x_k - x^*\|^2 = \sum_{i=1}^n c_i^2 (1 - t\lambda_i)^{2k} \leq \left(\max_i |1 - t\lambda_i| \right)^{2k} \sum_i c_i^2 = \rho(t)^{2k} \|x_0 - x^*\|^2,$$

donde $\rho(t) = \max_i |1 - t\lambda_i|$. Como la función $\lambda \mapsto |1 - t\lambda|$ es convexa en λ , su máximo sobre $[m, L]$ se alcanza en un extremo: $\rho(t) = \max\{|1 - tm|, |1 - tL|\}$. Si $t \in (0, 2/L)$ entonces $|1 - t\lambda_i| < 1$ para todo i , luego $\rho(t) < 1$. Con $t = 1/L$: $|1 - m/L| = 1 - 1/\kappa$ y $|1 - tL| = 0$, así que $\rho = 1 - 1/\kappa$. El paso óptimo equilibra los dos extremos: se elige t tal que $1 - tm = -(1 - tL)$, es decir $t = 2/(m + L)$, y entonces $\rho = 1 - \frac{2m}{m+L} = \frac{L-m}{L+m} = \frac{\kappa-1}{\kappa+1}$. $\square$

Teorema 15.9 (Caso general fuertemente convexo; enunciado). *Sea f m -fuertemente convexa y L -suave. El descenso de gradiente con paso $t = 1/L$ satisface*

$$\|x_k - x^*\|^2 \leq \left(1 - \frac{m}{L}\right)^k \|x_0 - x^*\|^2 \quad y \quad f(x_k) - f^* \leq \left(1 - \frac{m}{L}\right)^k (f(x_0) - f^*).$$

Para llevar el error bajo ε bastan $k \approx \kappa \log(1/\varepsilon)$ iteraciones: el costo crece con el logaritmo de la precisión (compara con el $1/\varepsilon$ del caso meramente convexo), pero es proporcional al número de condición κ . La demostración general combina el lema de descenso con (15.3); puede verse en [8], cap. 3, o [2], sec. 9.3.

15.3.5. Ejemplo a mano: el efecto del condicionamiento

Ejemplo 15.10 (Iteraciones a mano con paso $1/L$). Sea $f(x, y) = x^2 + 10y^2$, con $\nabla f(x, y) = (2x, 20y)$, Hessiana $\text{diag}(2, 20)$, y por tanto $m = 2$, $L = 20$, $\kappa = 10$, $x^* = (0, 0)$, $f^* = 0$. Tomamos $x_0 = (1, 1)$ y paso fijo $t = 1/L = 0.05$.

Iteración 1. $g_0 = \nabla f(1, 1) = (2, 20)$.

$$x_1 = (1, 1) - 0.05 (2, 20) = (1 - 0.1, 1 - 1) = (0.9, 0).$$

Iteración 2. $g_1 = \nabla f(0.9, 0) = (1.8, 0)$.

$$x_2 = (0.9, 0) - 0.05 (1.8, 0) = (0.81, 0).$$

Iteración 3. $g_2 = (1.62, 0)$, y $x_3 = (0.729, 0)$.

Los valores objetivo: $f(x_0) = 11$, $f(x_1) = 0.81$, $f(x_2) = 0.6561$, $f(x_3) \approx 0.5314$. Observa el patrón: la coordenada *rígida* y (curvatura $20 = L$) se aniquila en un solo paso, porque $1 - tL = 0$; pero la coordenada *blanda* x (curvatura $2 = m$) solo se contrae por el factor $1 - tm = 0.9$ por iteración, exactamente la tasa $1 - 1/\kappa$ del Teorema 15.8. Para reducir el error en x a la mitad hacen falta $\log(2)/\log(1/0.9) \approx 6.6$ iteraciones. El paso está *dictado* por la dirección más curvada (si fuera mayor, divergiríamos en y), pero el *progreso* está limitado por la más plana: esa tensión es el condicionamiento. Con búsqueda lineal exacta el mismo problema exhibe el famoso zigzag, que analizamos a continuación.

15.4. Descenso más pronunciado en cuadráticas [P4]

El **descenso más pronunciado** (*steepest descent*) es el descenso de gradiente con *búsqueda lineal exacta*. En una cuadrática, el paso exacto tiene fórmula cerrada, y eso permite entender con lupa el comportamiento del método.

Proposición 15.11 (Paso exacto en una cuadrática). *Sea $f(x) = \frac{1}{2}x^\top Qx - b^\top x$ con $Q \succ 0$, y sea $g = \nabla f(x) = Qx - b \neq 0$. El problema unidimensional $\min_{t \geq 0} f(x - tg)$ tiene solución única*

$$t^{ex} = \frac{g^\top g}{g^\top Q g} = \frac{\|g\|^2}{\langle g, Qg \rangle}. \quad (15.9)$$

Demostración. Definimos $\varphi(t) = f(x - tg)$ y derivamos con la regla de la cadena:

$$\varphi'(t) = \langle \nabla f(x - tg), -g \rangle.$$

Calculamos el gradiente en el punto desplazado usando la linealidad de $\nabla f(\cdot) = Q(\cdot) - b$:

$$\nabla f(x - tg) = Q(x - tg) - b = (Qx - b) - tQg = g - tQg.$$

Entonces

$$\varphi'(t) = \langle g - tQg, -g \rangle = -\|g\|^2 + t \langle g, Qg \rangle.$$

Como $Q \succ 0$ y $g \neq 0$, se tiene $\langle g, Qg \rangle > 0$: φ es una parábola estrictamente convexa en t , y su mínimo se obtiene igualando $\varphi'(t) = 0$, lo que da (15.9) (que es positivo, como debe ser). $\square$

Una consecuencia estructural inmediata explica el zigzag: en el mínimo de la búsqueda lineal, $0 = \varphi'(t_k) = \langle \nabla f(x_{k+1}), -g_k \rangle$, es decir,

$$\langle \nabla f(x_{k+1}), \nabla f(x_k) \rangle = 0 : \quad (15.10)$$

cada gradiente es ortogonal al anterior. El método avanza en zigzag de noventa grados; en un valle alargado eso significa cruzar el valle una y otra vez avanzando poquito hacia la salida (esta ortogonalidad vale para *cualquier* f con búsqueda exacta, no solo cuadráticas; se pide demostrarlo en el Ejercicio 15.26).

Ejemplo 15.12 (Zigzag calculado a mano). De nuevo $f(x, y) = x^2 + 10y^2$, es decir $Q = \text{diag}(2, 20)$, $b = 0$, $x^* = (0, 0)$; ahora $x_0 = (10, 1)$ y búsqueda exacta.

Iteración 1. $g_0 = (2 \cdot 10, 20 \cdot 1) = (20, 20)$. Entonces $\|g_0\|^2 = 400 + 400 = 800$ y $\langle g_0, Qg_0 \rangle = 2 \cdot 20^2 + 20 \cdot 20^2 = 800 + 8000 = 8800$, luego $t_0 = 800/8800 = 1/11$. Por tanto

$$x_1 = (10, 1) - \frac{1}{11}(20, 20) = \left(\frac{110-20}{11}, \frac{11-20}{11}\right) = \left(\frac{90}{11}, -\frac{9}{11}\right) = \frac{9}{11}(10, -1).$$


Iteración 2. Por la forma tan simétrica de x_1 , el cálculo se repite a escala: $g_1 = \frac{9}{11}(20, -20)$, y como el paso (15.9) es invariante a escalar g , de nuevo $t_1 = 1/11$, con lo cual

$$x_2 = \frac{9}{11} \left[(10, -1) - \frac{1}{11}(20, -20) \right] = \left(\frac{9}{11}\right)^2 (10, 1).$$

En general: $x_k = \left(\frac{9}{11}\right)^k (10, (-1)^k)$: el método rebota entre las semirrectas por $(10, 1)$ y $(10, -1)$, acercándose al origen con razón exacta $9/11$ por iteración, y

$$f(x_k) = \left(\frac{9}{11}\right)^{2k} f(x_0) = \left(\frac{81}{121}\right)^k \cdot 110 \approx (0.669)^k \cdot 110.$$

Numéricamente: $x_1 \approx (8.18, -0.82)$, $x_2 \approx (6.69, 0.67)$, $x_3 \approx (5.48, -0.55)$; f cae $110 \rightarrow 73.6 \rightarrow 49.3 \rightarrow 33.0$. Nada mal, pero nota que con $\kappa = 10$ la razón $9/11 = (\kappa - 1)/(\kappa + 1)$: este punto inicial realiza el *peor caso* del teorema siguiente.



Zigzag del descenso más pronunciado sobre las curvas de nivel elípticas de $f(x, y) = x^2 + 10y^2$: cada paso es ortogonal al anterior.

Teorema 15.13 (Cota de convergencia; enunciado). Para $f(x) = \frac{1}{2}x^\top Qx - b^\top x$ con $Q \succ 0$ y $\kappa = \lambda_{\max}(Q)/\lambda_{\min}(Q)$, el descenso más pronunciado con búsqueda exacta satisface

$$f(x_{k+1}) - f^* \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^2 (f(x_k) - f^*).$$

La demostración usa la desigualdad de Kantorovich; puedes verla en [5], teorema 3.3, o [7], cap. 2.

Intuición

Lee la cota así: si $\kappa = 1$ (niveles circulares), el factor es 0 y el método aterriza en x^* en un paso, porque el antigradiente apunta al centro. Si $\kappa = 10$, el factor es $(9/11)^2 \approx 0.67$: se pierde un tercio del error por iteración, aceptable. Si $\kappa = 1000$ (nada raro en econometría con regresores correlacionados), el factor es $(999/1001)^2 \approx 0.9960$: harían falta unas 173 iteraciones para reducir el error a la mitad, porque $\log(1/2)/\log(0.9960) \approx 173$. Lo frustrante es que la búsqueda exacta (el mejor paso posible en la dirección elegida) no cura nada: el problema no es el paso sino la *dirección*, que olvida todo lo aprendido en iteraciones anteriores y por eso repite el mismo error transversal una y otra vez. La cura es darle memoria al método: eso es el gradiente conjugado.

15.5. Método de gradiente conjugado [P4]

15.5.1. Motivación: arreglar el zigzag con memoria

En el zigzag, cada nueva dirección deshace parte del trabajo de la anterior: tras minimizar a lo largo de d_0 , el paso siguiente vuelve a introducir error en la dirección d_0 . La idea del **método de gradiente conjugado** (*conjugate gradient method*, CG) de Hestenes y Stiefel es elegir direcciones que *no interfieran entre sí*: una vez minimizado a lo largo de d_0 , ningún

paso futuro vuelve a estropear esa dirección. La noción correcta de “no interferencia” no es la ortogonalidad usual, sino la ortogonalidad medida con la geometría de la propia cuadrática.

Trabajamos en esta sección con

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} x^\top Q x - b^\top x, \quad Q \succ 0 \text{ simétrica,}$$

cuyo minimizador único x^* resuelve $Qx^* = b$. Denotamos el *residuo* $r_k = b - Qx_k = -\nabla f(x_k)$ (el antigradiente).

Definición 15.14 (Direcciones Q -conjugadas). Los vectores no nulos $d_0, d_1, \dots, d_m$ son Q -conjugados (Q -conjugate) si

$$d_i^\top Q d_j = 0 \quad \text{para todos } i \neq j.$$

Es la ortogonalidad respecto del producto interno $\langle u, v \rangle_Q = u^\top Q v$ (que es un producto interno legítimo porque $Q \succ 0$).

Lema 15.15 (Conjugadas $\implies$ linealmente independientes). Si $d_0, \dots, d_m$ son no nulos y Q -conjugados con $Q \succ 0$, entonces son linealmente independientes. En particular, en $\mathbb{R}^n$ hay a lo más n direcciones Q -conjugadas.

Demostración. Supongamos $\sum_{i=0}^m c_i d_i = 0$. Fijamos un índice j y multiplicamos la igualdad por la izquierda por $d_j^\top Q$:

$$0 = d_j^\top Q \left(\sum_i c_i d_i \right) = \sum_i c_i d_j^\top Q d_i = c_j d_j^\top Q d_j,$$

porque la conjugación anula todos los términos con $i \neq j$. Como $Q \succ 0$ y $d_j \neq 0$, se tiene $d_j^\top Q d_j > 0$, luego $c_j = 0$. Como j era arbitrario, todos los coeficientes son nulos. $\square$

Teorema 15.16 (n direcciones conjugadas resuelven en n pasos). Sean $d_0, \dots, d_{n-1}$ direcciones Q -conjugadas no nulas en $\mathbb{R}^n$. Desde cualquier x_0 , el método de direcciones conjugadas

$$x_{k+1} = x_k + \alpha_k d_k, \quad \alpha_k = \frac{d_k^\top r_k}{d_k^\top Q d_k} \quad (\text{el paso de búsqueda lineal exacta a lo largo de } d_k),$$

alcanza $x_n = x^*$: la solución exacta en a lo más n pasos.

Demostración. **Paso 1: expandir el desplazamiento total al óptimo.** Por el Lema 15.15, $\{d_0, \dots, d_{n-1}\}$ es una base de $\mathbb{R}^n$, así que existe una única expansión

$$x^* - x_0 = \sum_{i=0}^{n-1} \sigma_i d_i.$$

Para despejar σ_j usamos el truco del lema: multiplicamos por $d_j^\top Q$ y la conjugación mata todos los términos salvo el j -ésimo:

$$d_j^\top Q (x^* - x_0) = \sigma_j d_j^\top Q d_j \implies \sigma_j = \frac{d_j^\top Q (x^* - x_0)}{d_j^\top Q d_j}. \quad (15.11)$$

Paso 2: el algoritmo calcula exactamente esos coeficientes. Tras k pasos, $x_k - x_0 = \sum_{i=0}^{k-1} \alpha_i d_i$ es una combinación de las direcciones *anteriores*, de modo que, por conjugación,

$$d_k^\top Q(x_k - x_0) = \sum_{i=0}^{k-1} \alpha_i d_k^\top Q d_i = 0.$$

Por lo tanto, en el numerador de (15.11) podemos cambiar x_0 por x_k sin alterar nada:

$$d_k^\top Q(x^* - x_0) = d_k^\top Q(x^* - x_k) + \underbrace{d_k^\top Q(x_k - x_0)}_{=0} = d_k^\top (\underbrace{Qx^*}_{=b} - Qx_k) = d_k^\top r_k.$$

Es decir, $\sigma_k = \frac{d_k^\top r_k}{d_k^\top Q d_k} = \alpha_k$: el paso de búsqueda exacta coincide con el coeficiente de la expansión (que α_k es el paso exacto se comprueba igual que en la Proposición 15.11, derivando $\varphi(\alpha) = f(x_k + \alpha d_k)$ e igualando a cero).

Paso 3: conclusión. Después de n pasos,

$$x_n = x_0 + \sum_{k=0}^{n-1} \alpha_k d_k = x_0 + \sum_{k=0}^{n-1} \sigma_k d_k = x_0 + (x^* - x_0) = x^*. \quad \square$$

Intuición

En la geometría del producto interno $\langle \cdot, \cdot \rangle_Q$, las elipses de nivel de f se vuelven *esferas*, y direcciones Q -conjugadas son simplemente direcciones perpendiculares en ese mundo. El teorema dice entonces algo obvio: para llegar a un punto de $\mathbb{R}^n$ basta ajustar una vez cada una de n coordenadas perpendiculares, como quien primero camina todo lo necesario hacia el este y luego todo lo necesario hacia el norte, sin volver jamás sobre sus pasos. El zigzag del descenso más pronunciado ocurre precisamente porque sus direcciones (los gradientes sucesivos) son ortogonales en el mundo *equivocado*: el euclidiano, no el de Q .

15.5.2. El algoritmo CG

Falta saber *de dónde sacar* las direcciones conjugadas sin diagonalizar Q (eso costaría más que resolver el sistema). La genialidad del CG: construirlas sobre la marcha, tomando en cada paso el antigradiente actual y “corrigiéndolo” con un múltiplo de la dirección anterior para restaurar la conjugación. Una recursión cortísima basta.

Ejemplo 15.17 (Algoritmo CG para cuadráticas). Datos: $Q \succ 0$, b , punto inicial x_0 .

1. Inicializar $r_0 = b - Qx_0$ (antigradiente) y $d_0 = r_0$ (el primer paso es puro descenso de gradiente).
2. **Para** $k = 0, 1, 2, \dots$ mientras $r_k \neq 0$:
3. Paso exacto a lo largo de d_k : $\alpha_k = \frac{r_k^\top r_k}{d_k^\top Q d_k}$.
4. Avanzar: $x_{k+1} = x_k + \alpha_k d_k$.

5. Actualizar el residuo: $r_{k+1} = r_k - \alpha_k Qd_k$ (equivale a $r_{k+1} = b - Qx_{k+1}$, pero reutiliza el producto Qd_k ya calculado).
6. Coeficiente de corrección: $\beta_{k+1} = \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}$.
7. Nueva dirección: $d_{k+1} = r_{k+1} + \beta_{k+1} d_k$.

Comentarios sobre las fórmulas. (i) La expresión de α_k es el paso de búsqueda exacta $d_k^\top r_k / d_k^\top Qd_k$ del Teorema 15.16: puede probarse por inducción que $d_k^\top r_k = r_k^\top r_k$ (los residuos son ortogonales a todas las direcciones pasadas). (ii) El coeficiente β_{k+1} es exactamente el que hace $d_{k+1}^\top Qd_k = 0$; lo notable (y no evidente, puedes verlo en [5], teorema 5.3) es que con esa *única* corrección la nueva dirección resulta conjugada también con *todas* las anteriores. (iii) Cada iteración cuesta un solo producto matriz-vector Qd_k : el CG nunca forma ni factoriza Q , por eso es el método estándar para sistemas lineales enormes y dispersos.

Teorema 15.18 (Terminación finita; enunciado). *Aplicado a una cuadrática con $Q \succ 0$ en $\mathbb{R}^n$, el CG genera direcciones Q -conjugadas y residuos mutuamente ortogonales, y por lo tanto alcanza la solución exacta $x^* = Q^{-1}b$ en a lo más n iteraciones. Más aún, si Q tiene solo $s < n$ autovalores distintos, termina en a lo más s iteraciones, y mucho antes de terminar ya satisface la cota*

$$f(x_k) - f^* \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2k} (f(x_0) - f^*) :$$

la dependencia en el condicionamiento mejora de κ a $\sqrt{\kappa}$ (ver [5], cap. 5).

Ejemplo 15.19 (CG a mano en $\mathbb{R}^2$). Resolvamos $\min f(x) = \frac{1}{2}x^\top Qx - b^\top x$ con

$$Q = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad x_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

La solución exacta de $Qx = b$ es $x^* = \frac{1}{11}(1, 7)^\top$ (verificalo: $4 \cdot \frac{1}{11} + \frac{7}{11} = 1$, $\frac{1}{11} + 3 \cdot \frac{7}{11} = 2$). Veamos que el CG la encuentra en exactamente 2 pasos.

Inicialización. $r_0 = b - Qx_0 = (1, 2)^\top = d_0$.

Iteración 1. $Qd_0 = (4 + 2, 1 + 6)^\top = (6, 7)^\top$; $r_0^\top r_0 = 1 + 4 = 5$; $d_0^\top Qd_0 = 1 \cdot 6 + 2 \cdot 7 = 20$. Luego $\alpha_0 = 5/20 = 1/4$ y

$$x_1 = (0, 0)^\top + \frac{1}{4}(1, 2)^\top = \left(\frac{1}{4}, \frac{1}{2}\right)^\top, \quad r_1 = r_0 - \frac{1}{4}Qd_0 = (1, 2)^\top - \left(\frac{6}{4}, \frac{7}{4}\right)^\top = \left(-\frac{1}{2}, \frac{1}{4}\right)^\top.$$

Iteración 2. $r_1^\top r_1 = \frac{1}{4} + \frac{1}{16} = \frac{5}{16}$, así que $\beta_1 = \frac{5/16}{5} = \frac{1}{16}$ y

$$d_1 = r_1 + \frac{1}{16}d_0 = \left(-\frac{1}{2} + \frac{1}{16}, \frac{1}{4} + \frac{2}{16}\right)^\top = \frac{1}{16}(-7, 6)^\top.$$

(Comprobación de conjugación: $d_0^\top Qd_1 = (6, 7) \cdot \frac{1}{16}(-7, 6)^\top = \frac{1}{16}(-42 + 42) = 0$. ✓) Ahora $Qd_1 = \frac{1}{16}(-28 + 6, -7 + 18)^\top = \frac{1}{16}(-22, 11)^\top$, $d_1^\top Qd_1 = \frac{1}{256}(154 + 66) = \frac{220}{256} = \frac{55}{64}$, y

$$\alpha_1 = \frac{5/16}{55/64} = \frac{5}{16} \cdot \frac{64}{55} = \frac{4}{11}, \quad x_2 = \left(\frac{1}{4}, \frac{1}{2}\right)^\top + \frac{4}{11} \cdot \frac{1}{16}(-7, 6)^\top = \left(\frac{11-7}{44}, \frac{22+6}{44}\right)^\top = \left(\frac{1}{11}, \frac{7}{11}\right)^\top = x^*.$$

Dos variables, dos pasos, solución *exacta*: la terminación finita en acción. El descenso de gradiente

con paso fijo, en cambio, solo se *aproxima* a x^* geométricamente y nunca llega en tiempo finito.

15.5.3. CG no lineal

Para minimizar una f general (no cuadrática), el método de **Fletcher–Reeves** imita la recursión reemplazando el residuo por el antigradiente: $d_{k+1} = -\nabla f(x_{k+1}) + \beta_{k+1}^{FR} d_k$ con

$$\beta_{k+1}^{FR} = \frac{\|\nabla f(x_{k+1})\|^2}{\|\nabla f(x_k)\|^2},$$

y calcula α_k con una búsqueda lineal (Armijo reforzado con condiciones de Wolfe). Variantes como Polak–Ribière suelen funcionar mejor en la práctica. Cerca del mínimo, donde f se parece a su modelo cuadrático de Taylor, el CG no lineal hereda la rapidez del caso cuadrático; los detalles están en [5], cap. 5.

15.6. Método de gradiente proyectado [P4]

15.6.1. Motivación y algoritmo

Hasta aquí minimizamos sobre todo $\mathbb{R}^n$. Pero los problemas económicos casi siempre traen restricciones: cantidades no negativas, presupuestos, probabilidades que suman uno. Consideremos

$$\min_{x \in C} f(x), \quad C \subseteq \mathbb{R}^n \text{ convexo, cerrado y no vacío, } f \text{ convexa y diferenciable.}$$

Si damos un paso de gradiente desde $x_k \in C$, el punto $x_k - t\nabla f(x_k)$ puede caerse de C . La reparación natural: devolverlo a C con la *proyección* proy_C que estudiamos en el capítulo de proyección sobre convexos (recordemos: $\text{proy}_C(z)$ es el punto de C más cercano a z , existe y es único por la convexidad cerrada de C). Nace así el **método de gradiente proyectado** (*projected gradient method*):

$$x_{k+1} = \text{proy}_C(x_k - t_k \nabla f(x_k)). \quad (15.12)$$

El método es práctico exactamente cuando C es *simple*: una caja, una bola, un hiperplano o semiespacio, el simplex... conjuntos para los que tenemos fórmulas (o algoritmos rápidos) de proyección. Si proyectar sobre C es tan difícil como el problema original, el método no ayuda.

Ejemplo 15.20 (El algoritmo, paso a paso). 1. **Entrada:** $x_0 \in C$, paso $t > 0$ (si f es L -suave, $t = 1/L$), tolerancia $\varepsilon > 0$.

2. **Para** $k = 0, 1, 2, \dots$:

3. Paso de gradiente: $y_k = x_k - t \nabla f(x_k)$.

4. Reparación: $x_{k+1} = \text{proy}_C(y_k)$.

5. **Si** $\|x_{k+1} - x_k\| \leq \varepsilon$: **parar** (ya casi somos punto fijo; por el Teorema 15.21, casi óptimos).

Nota que el criterio de parada ya no puede ser $\|\nabla f(x_k)\| \approx 0$: en un óptimo de frontera el gradiente *no* se anula (KKT nos lo enseñó); lo que se anula es el desplazamiento del algoritmo.

15.6.2. Por qué funciona

Dos propiedades sostienen al método. La primera la demostramos en el capítulo de proyección: la proyección *no expande* distancias,

$$\|\text{proy}_C(u) - \text{proy}_C(v)\| \leq \|u - v\| \quad \text{para todos } u, v \in \mathbb{R}^n.$$

Gracias a ella, proyectar nunca estropea el progreso del paso de gradiente: todas las estimaciones de descenso y contracción de las secciones anteriores sobreviven a la proyección. La segunda es que los *puntos fijos* de la iteración son exactamente las soluciones del problema; la demostramos ahora.

Teorema 15.21 (Puntos fijos = soluciones). *Sea f convexa y diferenciable, C convexo cerrado no vacío y $t > 0$ cualquiera. Para $x^* \in C$ son equivalentes:*

- (i) $x^* = \text{proy}_C(x^* - t \nabla f(x^*))$ (x^* es punto fijo de la iteración);
- (ii) $\langle \nabla f(x^*), y - x^* \rangle \geq 0$ para todo $y \in C$ (desigualdad variacional de optimalidad);
- (iii) $-\nabla f(x^*)$ pertenece al cono normal de C en x^* , $N_C(x^*)$;
- (iv) x^* minimiza f sobre C .

Demostración. Recordemos la caracterización variacional de la proyección (capítulo de proyección sobre convexos): para $z \in \mathbb{R}^n$ y $\bar{z} \in C$,

$$\bar{z} = \text{proy}_C(z) \iff \langle z - \bar{z}, y - \bar{z} \rangle \leq 0 \text{ para todo } y \in C. \quad (15.13)$$

(“El vector que va de la proyección al punto proyectado forma ángulo obtuso con cualquier dirección que entre a C .”)

(i) $\Leftrightarrow$ (ii). Apliquemos (15.13) con $z = x^* - t \nabla f(x^*)$ y candidato a proyección $\bar{z} = x^*$ (que está en C). Como $z - \bar{z} = -t \nabla f(x^*)$, la condición de la derecha se lee: para todo $y \in C$,

$$\langle -t \nabla f(x^*), y - x^* \rangle \leq 0 \iff \langle \nabla f(x^*), y - x^* \rangle \geq 0,$$

donde dividimos entre $t > 0$ y cambiamos el signo. Eso es exactamente (ii), y la equivalencia (15.13) nos da (i) $\Leftrightarrow$ (ii).

(ii) $\Leftrightarrow$ (iii). Por definición, el cono normal es $N_C(x^*) = \{v : \langle v, y - x^* \rangle \leq 0 \ \forall y \in C\}$; la condición (ii) dice $\langle -\nabla f(x^*), y - x^* \rangle \leq 0$ para todo $y \in C$, es decir $-\nabla f(x^*) \in N_C(x^*)$. Son la misma frase con distinta notación.

(ii) $\Rightarrow$ (iv). Por convexidad de f , para cualquier $y \in C$: $f(y) \geq f(x^*) + \langle \nabla f(x^*), y - x^* \rangle \geq f(x^*)$, usando (ii) en la última desigualdad. Luego x^* es minimizador global en C .

(iv) $\Rightarrow$ (ii). Sea $y \in C$. Por convexidad de C , el punto $x^* + s(y - x^*)$ está en C para $s \in [0, 1]$, y por optimalidad $\varphi(s) = f(x^* + s(y - x^*))$ tiene un mínimo en $s = 0$; su derivada lateral debe ser no negativa: $0 \leq \varphi'(0^+) = \langle \nabla f(x^*), y - x^* \rangle$. $\square$

El teorema es la versión algorítmica de la condición de optimalidad geométrica que ya conocíamos ($-\nabla f(x^*) \in N_C(x^*)$, el antigradiente “empuja hacia afuera” de C): la iteración (15.12)

se queda quieta exactamente en los óptimos. La convergencia hereda las tasas del caso sin restricciones:

Teorema 15.22 (Convergencia del gradiente proyectado; enunciado). *Si f es convexa y L -suave sobre C , y x^* minimiza f en C , el método (15.12) con paso fijo $t = 1/L$ satisface*

$$f(x_k) - f(x^*) \leq \frac{L \|x_0 - x^*\|^2}{2k},$$

y si además f es m -fuertemente convexa, la convergencia es lineal con razón $1 - m/L$. Las demostraciones calcan las de la Sección 15.3, insertando la no expansividad de proy_C donde haga falta; ver [6], cap. 5, y [8], cap. 4.

15.6.3. Ejemplo completo sobre una caja

Ejemplo 15.23 (Gradiente proyectado sobre una caja). Consideremos

$$\min_{(x,y) \in C} f(x,y) = (x-2)^2 + (y-1)^2, \quad C = [0,1] \times [0,1].$$


El mínimo sin restricciones es $(2,1) \notin C$. Recordemos del capítulo de proyección que proyectar sobre una caja es *recortar* coordenada a coordenada: $\text{proy}_{[0,1]}(z) = \min\{\max\{z, 0\}, 1\}$. Aquí $\nabla f(x,y) = (2(x-2), 2(y-1))$ y la Hessiana es $2I$, así que $L = 2$; tomemos, para ver varias iteraciones, $t = 1/4$ (con $t = 1/L = 1/2$ el ejemplo termina en un solo paso; compruébalo). El paso de gradiente es entonces, coordenada a coordenada, $x - \frac{1}{4} \cdot 2(x-2) = \frac{x}{2} + 1$ y $y - \frac{1}{4} \cdot 2(y-1) = \frac{y}{2} + \frac{1}{2}$. Partimos de $x_0 = (0,0)$.

Iteración 1. $y_0 = (\frac{0}{2} + 1, \frac{0}{2} + \frac{1}{2}) = (1, 0.5) \in C$: la proyección no actúa, $x_1 = (1, 0.5)$.

Iteración 2. $y_1 = (\frac{1}{2} + 1, \frac{0.5}{2} + \frac{1}{2}) = (1.5, 0.75) \notin C$. Recortamos: la primera coordenada $1.5 \mapsto 1$; la segunda queda. $x_2 = (1, 0.75)$.

Iteración 3. $y_2 = (1.5, 0.875)$, y de nuevo $x_3 = (1, 0.875)$.

La primera coordenada ya se pegó a la pared $x = 1$ (restricción activa) y la segunda reduce a la mitad su distancia a 1 en cada paso $(0, 0.5, 0.75, 0.875, \dots)$: $x_k \rightarrow x^* = (1, 1)$. Y $(1, 1)$ tenía que ser el óptimo, porque f es la distancia al cuadrado al punto $(2, 1)$, de modo que minimizarla sobre C es exactamente proyectar: $x^* = \text{proy}_C(2, 1) = (1, 1)$. Verifiquemos la optimalidad con el Teorema 15.21(iii): $\nabla f(1, 1) = (-2, 0)$, y el cono normal de la caja en el vértice $(1, 1)$ es $N_C(1, 1) = \{(u, v) : u \geq 0, v \geq 0\}$ (los vectores que apuntan “hacia afuera” por las dos caras que se cruzan ahí). Como $-\nabla f(1, 1) = (2, 0) \in N_C(1, 1)$, en efecto $(1, 1)$ es el óptimo.



Gradiente proyectado en la caja: el paso de gradiente (flecha azul) sale de C ; la proyección (flecha discontinua) lo devuelve a la cara $x = 1$.

15.6.4. Ejemplo completo sobre el simplex

El simplex de probabilidad

$$\Delta_n = \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}$$

aparece por doquier en economía: loterías y estrategias mixtas, portafolios sin ventas en corto, participaciones de mercado. Proyectar sobre Δ_n es un problema interesante *en sí mismo*: no hay fórmula de una línea, pero sí una casi-fórmula. Puede demostrarse (con KKT, ¡buen ejercicio de repaso!) que

$$\text{proy}_{\Delta_n}(z) = ((z_1 - \tau)_+, \dots, (z_n - \tau)_+), \quad (u)_+ = \max\{u, 0\},$$

donde el umbral $\tau \in \mathbb{R}$ es el único número tal que $\sum_i (z_i - \tau)_+ = 1$: se resta a todos la misma cantidad y se recortan los negativos, eligiendo el descuento para que el total sea 1 (como un impuesto de suma fija con responsabilidad limitada). Para hallar τ se ordenan las coordenadas y se prueba qué subconjunto queda positivo: un algoritmo de $O(n \log n)$.

Ejemplo 15.24 (Gradiente proyectado sobre el simplex). Minimicemos la función lineal

$$f(x) = 3x_1 + 2x_2 + x_3 \quad \text{sobre } \Delta_3,$$

cuyo óptimo evidente es el vértice $e_3 = (0, 0, 1)$ (todo el peso al coeficiente más barato). Aunque f es lineal (no fuertemente convexa), el método funciona; tomemos $t = \frac{1}{2}$, $x_0 = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ y $\nabla f = c = (3, 2, 1)$ constante.

Iteración 1. Paso de gradiente:

$$y_0 = x_0 - \frac{1}{2}(3, 2, 1) = \left(\frac{1}{3} - \frac{3}{2}, \frac{1}{3} - 1, \frac{1}{3} - \frac{1}{2}\right) = \left(-\frac{7}{6}, -\frac{2}{3}, -\frac{1}{6}\right).$$

Proyectamos: buscamos τ con $\sum_i (y_{0,i} - \tau)_+ = 1$. Probemos que las coordenadas 2 y 3 quedan positivas y la 1 se recorta: entonces $(-\frac{2}{3} - \tau) + (-\frac{1}{6} - \tau) = 1$ da $\tau = -\frac{11}{12}$. Verificación: $y_{0,2} - \tau = -\frac{8}{12} + \frac{11}{12} = \frac{3}{12} > 0$, $y_{0,3} - \tau = -\frac{2}{12} + \frac{11}{12} = \frac{9}{12} > 0$, y $y_{0,1} - \tau = -\frac{14}{12} + \frac{11}{12} = -\frac{3}{12} < 0$: consistente. Luego

$$x_1 = \text{proy}_{\Delta_3}(y_0) = \left(0, \frac{1}{4}, \frac{3}{4}\right).$$

Iteración 2.

$$y_1 = \left(0 - \frac{3}{2}, \frac{1}{4} - 1, \frac{3}{4} - \frac{1}{2}\right) = \left(-\frac{3}{2}, -\frac{3}{4}, \frac{1}{4}\right).$$

Probemos soporte $\{3\}$: τ resuelve $\frac{1}{4} - \tau = 1$, o sea $\tau = -\frac{3}{4}$; entonces $y_{1,2} - \tau = 0$ y $y_{1,1} - \tau = -\frac{3}{4} < 0$: solo la tercera coordenada queda positiva, y

$$x_2 = (0, 0, 1) = e_3.$$

¡Llegamos al óptimo en dos pasos! Comprobación de punto fijo (Teorema 15.21(ii)): para todo $y \in \Delta_3$, $\langle c, y - e_3 \rangle = 3y_1 + 2y_2 + y_3 - 1 \geq y_1 + y_2 + y_3 - 1 = 0$, como exige la desigualdad variacional. (En general el método no termina en tiempo finito; aquí lo hace porque el óptimo es un vértice y los pasos son grandes.)

Estrategia de examen

Ante un problema de optimización con restricciones que quieras resolver *numéricamente*, sigue este orden de preguntas. (1) ¿Es C de proyección simple (caja, bola, hiperplano, semiespacio, simplex)? Si sí, gradiente proyectado; recicla las fórmulas del capítulo de proyección. (2) ¿Conoces L (por ejemplo $\lambda_{\max}$ de la Hessiana, o una cota)? Usa paso $1/L$; si no, backtracking–Armijo, que no requiere conocer nada. (3) ¿El problema es sin restricciones, cuadrático o casi cuadrático, con n grande? Gradiente conjugado. (4) ¿Mal condicionado? Reescala variables (o “precondiciona”) *antes* de culpar al algoritmo. (5) Para verificar tu implementación, pruébala primero en una cuadrática pequeña cuya solución conozcas exactamente, y comprueba las tasas teóricas: si el error no cae como $(1 - 1/\kappa)^k$, hay un bug. Este protocolo es, tal cual, un buen guion para el trabajo computacional del curso.

15.7. Nota aplicada: economía computacional [P4]**15.7.1. Tatonnement walrasiano como dinámica de gradiente**

En el modelo de equilibrio general, el subastador walrasiano ajusta el vector de precios $p \in \mathbb{R}_{++}^n$ según la ley del mercado: sube el precio de los bienes con exceso de demanda y baja el de los bienes con exceso de oferta. Si $z(p) \in \mathbb{R}^n$ es la función de *exceso de demanda agregada* (demanda menos oferta a los precios p), el *tatonnement* en tiempo discreto es

$$p_{k+1} = p_k + t z(p_k),$$

¡formalmente idéntico a un *ascenso* de gradiente (15.1) con dirección $d_k = z(p_k)$! Un equilibrio walrasiano p^* cumple $z(p^*) = 0$: es exactamente un “punto estacionario” de la dinámica. Cuando el exceso de demanda deriva de un potencial (por ejemplo, en economías con demandas agregables donde $z(p) = \nabla W(p)$ para alguna función W cóncava), el *tatonnement* es un ascenso de gradiente sobre W y los teoremas de este capítulo dan su convergencia y su velocidad. Sin potencial, el argumento clásico usa una función de Lyapunov: bajo *sustituibilidad bruta* (*gross substitutes*) la distancia $\|p_k - p^*\|^2$ decrece a lo largo del ajuste (el mismo esquema de demostración del Teorema 15.7, con la distancia al óptimo como cantidad monótona) y el *tatonnement* converge globalmente ([9], cap. 17). La lección algorítmica también viaja en sentido inverso: sin hipótesis tipo sustituibilidad (el análogo de la convexidad), el ajuste puede ciclar o divergir, como en los ejemplos de Scarf.

15.7.2. Estimación estructural y aprendizaje automático

En econometría estructural, el estimador es el minimizador de un criterio:

$$\hat{\theta} = \arg \min_{\theta \in \Theta} Q_n(\theta),$$

con Q_n la log-verosimilitud negativa (MLE), la forma cuadrática de momentos $g_n(\theta)^\top W g_n(\theta)$ (GMM), o una distancia entre momentos simulados y observados (calibración/SMM). Todo lo aprendido aplica directamente: la Hessiana de Q_n cerca de $\hat{\theta}$ (la matriz de información, en MLE) determina κ y por tanto la dificultad numérica; parámetros débilmente identificados = valle plano = κ gigante; y las restricciones naturales (θ en una caja, varianzas no negativas, probabilidades en el simplex) se manejan con gradiente proyectado. En aprendizaje automático y en modelos con datos masivos, $Q_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell_i(\theta)$ es un promedio de millones de términos, y evaluar el gradiente completo es prohibitivo: el *descenso de gradiente estocástico* (*stochastic gradient descent*, SGD) reemplaza ∇Q_n por el gradiente de *unos pocos* sumandos elegidos al azar (un estimador insesgado y barato del gradiente verdadero) y aún así converge (en esperanza, con pasos decrecientes). SGD es hoy el algoritmo que entrena desde regresiones logísticas gigantes hasta redes neuronales; ver [8], cap. 5.

15.7.3. Sugerencias para el trabajo computacional

Ideas concretas, calibradas para una exposición final del curso:

1. Implementar descenso de gradiente (paso fijo, Armijo) y CG, y compararlos sobre cuadráticas con $\kappa \in \{10, 100, 1000\}$: graficar $\log(f(x_k) - f^*)$ contra k y verificar las tasas teóricas (rectas de pendientes $\log(1 - 1/\kappa)$ y mucho más empinadas para CG).
2. Reproducir el zigzag del Ejemplo 15.12 y el efecto de preconditionar (cambio de variables $\tilde{x} = Q^{1/2}x$).
3. Estimar un logit o probit por máxima verosimilitud con gradiente descendente propio, comparando contra el optimizador de la librería.
4. Programar la proyección al simplex y usar gradiente proyectado para un problema de portafolio de mínima varianza sin ventas en corto: $\min_{x \in \Delta_n} x^\top \Sigma x$.
5. Simular un tatonnement en una economía de intercambio CES con dos o tres bienes, y exhibir un caso convergente (sustitutos brutos) y el ciclo de Scarf.

15.8. Resumen y ejercicios [P4]

Resumen del capítulo

Esquema general: $x_{k+1} = x_k + t_k d_k$; d es dirección de descenso si $\langle \nabla f(x), d \rangle < 0$ (Proposición 15.2).

Suavidad: f es L -suave si ∇f es L -Lipschitz; entonces vale el lema de descenso $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$ (techo parabólico). **Convexidad fuerte** (módulo m): piso parabólico. **Número de condición:** $\kappa = L/m$, mide lo alargado de las curvas de nivel; en cuadráticas, $\lambda_{\max}/\lambda_{\min}$.

Descenso de gradiente $x_{k+1} = x_k - t_k \nabla f(x_k)$: con $t = 1/L$ garantiza $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2$; sin conocer L , backtracking-Armijo. Tasas: convexo L -suave, $f(x_k) - f^* \leq L \|x_0 - x^*\|^2 / (2k)$ (sublineal, $O(1/k)$); fuertemente convexo, lineal con razón $1 - 1/\kappa$

($t = 1/L$).

Descenso más pronunciado (búsqueda exacta): en cuadráticas $t^{\text{ex}} = \|g\|^2 / \langle g, Qg \rangle$; gradientes sucesivos ortogonales $\Rightarrow$ zigzag; razón de peor caso $(\frac{\kappa-1}{\kappa+1})^2$ en f .

Gradiente conjugado: direcciones con $d_i^\top Q d_j = 0$ ($i \neq j$) no interfieren; n de ellas resuelven la cuadrática en n pasos exactos (Teorema 15.16); el CG las construye al vuelo con $\alpha_k = \frac{r_k^\top r_k}{d_k^\top Q d_k}$, $\beta_{k+1} = \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}$, $d_{k+1} = r_{k+1} + \beta_{k+1} d_k$; dependencia $\sqrt{\kappa}$ del condicionamiento; versión no lineal: Fletcher-Reeves.

Gradiente proyectado: $x_{k+1} = \text{proy}_C(x_k - t \nabla f(x_k))$ para C convexo de proyección simple; funciona porque proy_C no expande y porque punto fijo $\Leftrightarrow \langle \nabla f(x^*), y - x^* \rangle \geq 0 \ \forall y \in C \Leftrightarrow -\nabla f(x^*) \in N_C(x^*) \Leftrightarrow$ óptimo (Teorema 15.21); mismas tasas que sin restricciones.

Para economistas: tatonnement = dinámica de gradiente sobre el exceso de demanda; estimar (MLE, GMM, calibración) = minimizar; SGD para datos masivos; identificación débil = mal condicionamiento.

Ejercicio 15.25. Sea $f(x, y) = \frac{1}{2}(x^2 + 9y^2)$. (a) Calcula ∇f , la Hessiana, m , L y κ . (b) Desde $x_0 = (9, 1)$, ejecuta a mano tres iteraciones de descenso de gradiente con paso fijo $t = 1/L$, reportando x_k y $f(x_k)$. (c) Identifica la razón de contracción observada y compárala con la teórica del Teorema 15.8.

Solución. (a) $\nabla f(x, y) = (x, 9y)$ y $\nabla^2 f = \text{diag}(1, 9)$, constante. Los autovalores son 1 y 9, luego $m = 1$, $L = 9$ y $\kappa = 9$. El paso es $t = 1/9$.

(b) La iteración es $x_{k+1} = x_k - \frac{1}{9}(x_k, 9y_k) = (\frac{8}{9}x_k, 0 \cdot y_k)$; hagámosla explícita.

Iteración 1: $g_0 = (9, 9)$, así que $x_1 = (9, 1) - \frac{1}{9}(9, 9) = (9 - 1, 1 - 1) = (8, 0)$.

Iteración 2: $g_1 = (8, 0)$, así que $x_2 = (8, 0) - \frac{1}{9}(8, 0) = (\frac{64}{9}, 0) \approx (7.111, 0)$.

Iteración 3: $g_2 = (\frac{64}{9}, 0)$, así que $x_3 = \frac{8}{9} \cdot \frac{64}{9}(1, 0) = (\frac{512}{81}, 0) \approx (6.321, 0)$.

Valores: $f(x_0) = \frac{1}{2}(81 + 9) = 45$; $f(x_1) = \frac{1}{2} \cdot 64 = 32$; $f(x_2) = \frac{1}{2}(\frac{64}{9})^2 = \frac{2048}{81} \approx 25.28$; $f(x_3) = \frac{1}{2}(\frac{512}{81})^2 \approx 19.98$.

(c) La coordenada rígida y (curvatura $L = 9$) muere en el primer paso porque $1 - tL = 0$; a partir de ahí el error está solo en x y se contrae exactamente por $1 - tm = 8/9 \approx 0.889$ por iteración ($8 \rightarrow 64/9 \rightarrow 512/81$). Es la razón teórica $1 - m/L = 1 - 1/\kappa$ del Teorema 15.8: el peor autovalor manda. $\square$

Ejercicio 15.26. Demuestra que si t_k se elige por búsqueda lineal *exacta* a lo largo de una dirección de descenso d_k (y el mínimo se alcanza en un $t_k \in (0, \infty)$), entonces $\langle \nabla f(x_{k+1}), d_k \rangle = 0$. Concluye que en el descenso más pronunciado los gradientes sucesivos son ortogonales, y explica en una frase por qué esto produce el zigzag.

Solución. Sea $\varphi(t) = f(x_k + t d_k)$, que es diferenciable con $\varphi'(t) = \langle \nabla f(x_k + t d_k), d_k \rangle$ por la regla de la cadena. Por definición de búsqueda exacta, t_k minimiza φ sobre $[0, \infty)$, y como t_k es interior ($t_k > 0$), la condición de primer orden de un mínimo interior da $\varphi'(t_k) = 0$, es decir

$$\langle \nabla f(x_k + t_k d_k), d_k \rangle = \langle \nabla f(x_{k+1}), d_k \rangle = 0.$$

En el descenso más pronunciado $d_k = -\nabla f(x_k)$, así que $\langle \nabla f(x_{k+1}), \nabla f(x_k) \rangle = 0$: cada nueva dirección es perpendicular a la anterior. Como el método solo puede girar en ángulos rectos, en un valle alargado avanza cruzando el valle de lado a lado (componente transversal grande, componente longitudinal pequeña): ese es el zigzag del Ejemplo 15.12. $\square$

Ejercicio 15.27. Considera $f(x) = \frac{L}{2}x^2$ en $\mathbb{R}$ (una sola variable), que es L -suave con constante exacta L . (a) Escribe la iteración del descenso de gradiente con paso fijo t como $x_{k+1} = c x_k$ y determina c . (b) ¿Para qué valores de t el método converge a $x^* = 0$ desde cualquier x_0 ? ¿Para cuáles diverge? (c) ¿Qué pasa exactamente en $t = 2/L$?

Solución. (a) $f'(x) = Lx$, luego $x_{k+1} = x_k - tLx_k = (1 - tL)x_k$: es una recursión geométrica con $c = 1 - tL$, así que $x_k = (1 - tL)^k x_0$.

(b) $|x_k| = |1 - tL|^k |x_0| \rightarrow 0$ si y solo si $|1 - tL| < 1$, es decir $0 < t < 2/L$: converge para todo paso en $(0, 2/L)$ (monótonamente si $t \leq 1/L$, oscilando alrededor de 0 si $1/L < t < 2/L$). Si $t > 2/L$ entonces $|1 - tL| > 1$ y $|x_k| \rightarrow \infty$ para todo $x_0 \neq 0$: el método *diverge geoméricamente*, saltando a lados alternos del mínimo cada vez más lejos.

(c) Con $t = 2/L$, $c = -1$: la iteración rebota para siempre entre x_0 y $-x_0$, sin converger ni divergir. Esto muestra que el umbral $2/L$ de la teoría es exacto, no un artefacto de la demostración. $\square$

Ejercicio 15.28. Sea $f(x) = \frac{1}{2}x^\top Qx$ con $Q = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$. (a) Calcula los autovalores de Q , las constantes m y L , y el número de condición κ . (b) Da el paso fijo “seguro” $1/L$ y la razón de convergencia que garantiza el Teorema 15.8. (c) Da el paso óptimo $2/(m + L)$ y su razón. (d) ¿En qué direcciones iniciales x_0 converge el método en una sola iteración con $t = 1/L$?

Solución. (a) El polinomio característico es $\det(Q - \lambda I) = (3 - \lambda)^2 - 1 = 0$, de donde $3 - \lambda = \pm 1$: $\lambda_1 = 2$ y $\lambda_2 = 4$, con autovectores $v_1 = \frac{1}{\sqrt{2}}(1, -1)^\top$ y $v_2 = \frac{1}{\sqrt{2}}(1, 1)^\top$. Así $m = 2$, $L = 4$, $\kappa = 2$.

(b) $t = 1/L = 1/4$, con razón $\rho = 1 - m/L = 1 - 1/\kappa = 1/2$: el error en norma se reduce al menos a la mitad por iteración.

(c) $t = 2/(m + L) = 2/6 = 1/3$, con razón $\rho = (\kappa - 1)/(\kappa + 1) = 1/3$: algo mejor que $1/2$.

(d) El error evoluciona como $x_{k+1} = (I - \frac{1}{4}Q)x_k$, y $I - \frac{1}{4}Q$ tiene autovalores $1 - \frac{2}{4} = \frac{1}{2}$ (dirección v_1) y $1 - \frac{4}{4} = 0$ (dirección v_2). Por tanto, si x_0 es proporcional a $v_2 = (1, 1)^\top$ (la dirección del autovalor máximo), un solo paso lo aniquila: $x_1 = 0 = x^*$. En cualquier otra dirección sobrevive la componente en v_1 y la convergencia es geométrica con razón $1/2$. $\square$

Ejercicio 15.29. Aplica el método de gradiente conjugado a $f(x) = \frac{1}{2}x^\top Qx - b^\top x$ con $Q = \text{diag}(1, 4)$, $b = (1, 2)^\top$, desde $x_0 = (0, 0)^\top$. Reporta α_0 , x_1 , r_1 , β_1 , d_1 , α_1 y x_2 , y verifica que x_2 resuelve $Qx = b$ y que $d_0^\top Qd_1 = 0$.

Solución. *Inicialización:* $r_0 = b - Qx_0 = (1, 2)^\top = d_0$.

Iteración 1: $Qd_0 = (1, 8)^\top$; $r_0^\top r_0 = 1 + 4 = 5$; $d_0^\top Qd_0 = 1 + 16 = 17$. Entonces $\alpha_0 = 5/17$ y

$$x_1 = \frac{5}{17}(1, 2)^\top = \left(\frac{5}{17}, \frac{10}{17}\right)^\top, \quad r_1 = r_0 - \frac{5}{17}(1, 8)^\top = \left(\frac{12}{17}, -\frac{6}{17}\right)^\top.$$

Iteración 2: $r_1^\top r_1 = \frac{144+36}{289} = \frac{180}{289}$, luego $\beta_1 = \frac{180/289}{5} = \frac{36}{289}$ y

$$d_1 = r_1 + \frac{36}{289}(1, 2)^\top = \left(\frac{204+36}{289}, \frac{-102+72}{289}\right)^\top = \frac{30}{289}(8, -1)^\top.$$

Conjugación: $d_0^\top Qd_1 = (1, 8) \cdot \frac{30}{289}(8, -1)^\top = \frac{30}{289}(8 - 8) = 0$. ✓ Ahora $Qd_1 = \frac{30}{289}(8, -4)^\top$ y $d_1^\top Qd_1 = \left(\frac{30}{289}\right)^2(64 + 4) = \frac{900 \cdot 68}{289^2}$, de modo que

$$\alpha_1 = \frac{180/289}{900 \cdot 68/289^2} = \frac{180 \cdot 289}{900 \cdot 68} = \frac{17}{20}, \quad x_2 = x_1 + \frac{17}{20} \cdot \frac{30}{289}(8, -1)^\top = x_1 + \frac{3}{34}(8, -1)^\top.$$

Como $\frac{3}{34}(8, -1)^\top = \left(\frac{12}{17}, -\frac{3}{34}\right)^\top$,

$$x_2 = \left(\frac{5}{17} + \frac{12}{17}, \frac{10}{17} - \frac{3}{34}\right)^\top = \left(1, \frac{20-3}{34}\right)^\top = \left(1, \frac{1}{2}\right)^\top.$$

Verificación: $Qx_2 = (1 \cdot 1, 4 \cdot \frac{1}{2})^\top = (1, 2)^\top = b$. ✓ Terminación en $n = 2$ pasos, como promete el Teorema 15.18. $\square$

Ejercicio 15.30. Considera $\min_{(x,y) \in C} f(x,y) = (x-3)^2 + (y+1)^2$ con $C = [0, 2] \times [0, 2]$. (a) Ejecuta una iteración de gradiente proyectado desde $x_0 = (0, 0)$ con paso $t = 1/2$. (b) Comprueba que el punto obtenido es un punto fijo de la iteración. (c) Certifica su optimalidad mediante la condición del cono normal del Teorema 15.21.

Solución. (a) $\nabla f(x, y) = (2(x-3), 2(y+1))$, así que $\nabla f(0, 0) = (-6, 2)$ y el paso de gradiente da

$$y_0 = (0, 0) - \frac{1}{2}(-6, 2) = (3, -1),$$

que es justamente el minimizador libre, fuera de C (con $t = 1/L = 1/2$ y f cuadrática de Hessiana $2I$, el paso de gradiente siempre aterriza en el minimizador libre). Proyectamos recortando coordenadas a $[0, 2]$: $3 \mapsto 2$ y $-1 \mapsto 0$, luego $x_1 = (2, 0)$.

(b) $\nabla f(2, 0) = (-2, 2)$, así que el punto tentativo es $(2, 0) - \frac{1}{2}(-2, 2) = (3, -1)$, cuya proyección vuelve a ser $(2, 0)$: en efecto $x_2 = x_1$, punto fijo.

(c) En $x^* = (2, 0)$ están activas la cota superior de x ($x = 2$) y la cota inferior de y ($y = 0$); el cono normal de la caja ahí es

$$N_C(2, 0) = \{(u, v) : u \geq 0, v \leq 0\}$$

(hacia afuera: a la derecha por la cara $x = 2$, hacia abajo por la cara $y = 0$). Como $-\nabla f(2, 0) = (2, -2)$ tiene $u = 2 \geq 0$ y $v = -2 \leq 0$, se cumple $-\nabla f(x^*) \in N_C(x^*)$ y, por el Teorema 15.21, $x^* = (2, 0)$ minimiza f sobre C . (Vale la pena visualizarlo: el antigradiente apunta hacia el minimizador libre $(3, -1)$, que queda “afuera” cruzando exactamente por la esquina $(2, 0)$.) $\square$

Capítulo 16

Métodos de penalización y lagrangiano aumentado [P5]

Semana 14 del cronograma. Bibliografía: Boyd y Vandenberghe [2]; Nocedal y Wright [5], Cap. 17; Ruszczyński [6], Caps. 6–7.

¿Para qué sirve esto en Microeconomía?

Seamos honestos: este capítulo *no* se pregunta directamente en Microeconomía. Pero la idea económica que hay detrás del lagrangiano aumentado es demasiado hermosa como para saltársela: el algoritmo coordina decisiones descentralizadas *actualizando precios* (el multiplicador de Lagrange) hasta que la “restricción de mercado” se vacía: exactamente el espíritu del subastador walrasiano del **equilibrio general** (MWG caps. 15–18): si hay exceso de demanda, sube el precio; si hay exceso de oferta, bájalo. La versión ADMM que veremos al final es, literalmente, un *segundo teorema del bienestar computacional*: agentes que resuelven problemas privados y un coordinador que solo toca precios alcanzan juntos el óptimo social. Además, el lagrangiano aumentado es *la* herramienta computacional con la que se resuelven en la práctica los modelos de equilibrio general computable y los problemas de portafolio (Markowitz, que desarrollamos con todo detalle), y es un tema fuerte para la **exposición final del curso**: los programas suelen llamarlo “método de gradiente aumentado” y ubicarlo dentro de los métodos numéricos de optimización con restricciones.

En los capítulos anteriores aprendimos a *caracterizar* soluciones de problemas con restricciones (condiciones KKT, dualidad lagrangiana, puntos silla) y a *calcular* soluciones de problemas sin restricciones o con restricciones muy simples (método del gradiente y gradiente proyectado). Queda el caso más importante en economía aplicada: ¿cómo se calcula, con un computador, la solución de un problema con restricciones generales de igualdad y desigualdad?

La idea unificadora de este capítulo es sencilla de enunciar: *convertir las restricciones en costos*. En lugar de prohibir la infactibilidad, la *cobramos*: quien viola una restricción paga una multa que crece con la violación. Así el problema restringido se transforma en una sucesión de problemas *sin* restricciones, que ya sabemos resolver con los métodos del capítulo anterior. Veremos tres formas de cobrar esa multa, de la más ingenua a la más sofisticada:

- (I) la **penalización cuadrática**, que multa la violación pero necesita multas infinitas para ser exacta;
- (II) la **barrera logarítmica**, que cobra un peaje creciente por *acercarse* a la frontera desde adentro;
- (III) el **lagrangiano aumentado**, que combina la multa cuadrática con un *precio* (el multiplicador de Lagrange) que se actualiza iterativamente, y logra exactitud con multas finitas.

Las referencias principales son [5] (cap. 17), [6] (caps. 6–7), [7] y, para ADMM y sus aplicaciones distribuidas, [2] y [8]. Del cuaderno usaremos las condiciones KKT, la función dual $q(\lambda) = \min_x L(x, \lambda)$ y la noción de ascenso en gradiente.

16.1. De restricciones a costos: la penalización cuadrática [P5]

16.1.1. Motivación: multar la infactibilidad

Consideremos el problema con restricciones de igualdad

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{sujeto a} \quad h_j(x) = 0, \quad j = 1, \dots, m, \quad (16.1)$$

donde $f, h_1, \dots, h_m : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones diferenciables. Escribimos $h(x) = (h_1(x), \dots, h_m(x)) \in \mathbb{R}^m$ para el vector de restricciones, de modo que la factibilidad es $h(x) = 0$.

La dificultad computacional de (16.1) es que el conjunto factible $\{x : h(x) = 0\}$ suele ser una superficie “delgada” en $\mathbb{R}^n$ (de dimensión $n - m$): un método de gradiente que dé pasos libres se sale de ella inmediatamente. La primera idea es eliminar la restricción y reemplazarla por un *costo*: si estar en x con $h(x) \neq 0$ cuesta caro, el minimizador libre se acercará solo a la superficie factible. La multa más natural es proporcional al *cuadrado* de la violación (cuadrática para que sea diferenciable y para que multas pequeñas cerca de la factibilidad no distorsionen demasiado).

Definición 16.1 (Función de penalización cuadrática). Para el problema (16.1) y un parámetro de penalización (*penalty parameter*) $\rho > 0$, la *función de penalización cuadrática* (*quadratic penalty function*) es

$$Q(x; \rho) = f(x) + \frac{\rho}{2} \sum_{j=1}^m h_j(x)^2 = f(x) + \frac{\rho}{2} \|h(x)\|^2.$$

Si el problema tiene además restricciones de desigualdad $g_i(x) \leq 0$, $i = 1, \dots, p$, se agregan los términos $\frac{\rho}{2} \sum_{i=1}^p (\max\{0, g_i(x)\})^2$: solo se multa la parte *violada* de cada desigualdad (si $g_i(x) \leq 0$ el término vale cero).

El *método de penalización cuadrática* consiste en:

1. Elegir un valor inicial $\rho_0 > 0$ (por ejemplo $\rho_0 = 1$), un punto inicial x^0 y una tolerancia $\varepsilon > 0$.

2. En la iteración k : minimizar $Q(x; \rho_k)$ *sin restricciones* (con gradiente, Newton, etc.), partiendo del punto anterior x^{k-1} como semilla; llamar x^k al minimizador (aproximado) obtenido.
3. Si $\|h(x^k)\| \leq \varepsilon$, detenerse y devolver x^k .
4. Si no, aumentar la penalización, $\rho_{k+1} = \tau \rho_k$ con $\tau > 1$ (típicamente $\tau = 10$), y volver al paso 2.

Intuición

Piensa en ρ como el tamaño de la *multa por contaminar*. Una empresa (el minimizador de Q) compara el beneficio privado de violar la norma (f baja si se sale de la restricción) con la multa $\frac{\rho}{2} \|h\|^2$. Con multas pequeñas, contamina bastante; conforme el regulador endurece la multa, la empresa se acerca al comportamiento exigido, pero, y este es el punto clave que cuantificaremos ahora, *mientras la multa sea finita, siempre le conviene violar la norma un poquito*, porque cerca de $h = 0$ la multa marginal ρh es pequeña comparada con el beneficio marginal de desviarse. La factibilidad exacta solo se alcanza en el límite $\rho \rightarrow \infty$.

16.1.2. Un ejemplo 1D resuelto por completo

Ejemplo 16.2 (La penalización nunca es exactamente factible). Consideremos el problema en una variable

$$\min_{x \in \mathbb{R}} \frac{1}{2}x^2 \quad \text{s.a.} \quad h(x) = x - 1 = 0.$$

La solución es obvia: el único punto factible es $x^* = 1$, con valor $f(x^*) = \frac{1}{2}$. Su multiplicador de Lagrange sale de la condición de primer orden del lagrangiano $L(x, \lambda) = \frac{1}{2}x^2 + \lambda(x - 1)$:

$$\frac{\partial L}{\partial x} = x + \lambda = 0 \quad \text{en } x^* = 1 \quad \implies \quad \lambda^* = -1.$$

Apliquemos ahora la penalización cuadrática. La función penalizada es

$$Q(x; \rho) = \frac{1}{2}x^2 + \frac{\rho}{2}(x - 1)^2.$$

Es una suma de dos parábolas convexas, luego es estrictamente convexa y su minimizador es el único punto crítico. Derivamos e igualamos a cero:

$$Q'(x; \rho) = x + \rho(x - 1) = (1 + \rho)x - \rho = 0 \quad \implies \quad x(\rho) = \frac{\rho}{1 + \rho}.$$

Analicemos esta fórmula con cuidado; contiene toda la teoría del método.

- (a) **Convergencia al óptimo restringido.** Cuando $\rho \rightarrow \infty$, $x(\rho) = \rho/(1 + \rho) \rightarrow 1 = x^*$. Con $\rho = 1$ obtenemos $x = 1/2$; con $\rho = 10$, $x = 10/11 \approx 0.909$; con $\rho = 100$, $x = 100/101 \approx 0.990$.
- (b) **Pero nunca es factible con ρ finito.** El error (la violación de la restricción) es exacta-

mente

$$h(x(\rho)) = x(\rho) - 1 = \frac{\rho}{1+\rho} - \frac{1+\rho}{1+\rho} = -\frac{1}{1+\rho} \neq 0 \quad \text{para todo } \rho < \infty.$$


La violación decae como $1/\rho$: para reducir el error a la mitad hay que *duplicar* la multa; para ganar un dígito decimal de factibilidad hay que multiplicarla por diez.

(c) **La violación “recuerda” al multiplicador.** Multipliquemos la violación por ρ :

$$\rho h(x(\rho)) = \rho \cdot \left(-\frac{1}{1+\rho}\right) = -\frac{\rho}{1+\rho} \xrightarrow{\rho \rightarrow \infty} -1 = \lambda^*.$$

¡El producto $\rho h(x(\rho))$ converge al multiplicador de Lagrange! No es coincidencia: la condición de primer orden de Q es $f'(x(\rho)) + \rho h(x(\rho)) h'(x(\rho)) = 0$, que es exactamente la condición KKT $f'(x) + \lambda h'(x) = 0$ con el “multiplicador implícito” $\lambda = \rho h(x(\rho))$. La penalización cuadrática estima el multiplicador *sin habérselo propuesto*. Esta observación es la semilla del lagrangiano aumentado.

La figura siguiente muestra las parábolas $Q(\cdot; \rho)$ para ρ creciente: el mínimo (punto grueso) se acerca a la línea factible $x = 1$ pero nunca la alcanza.



El fenómeno del ejemplo es completamente general; lo enunciamos como teorema.

Teorema 16.3 (Convergencia de la penalización cuadrática). *Supongamos que f y h son continuas, que cada $Q(\cdot; \rho_k)$ alcanza su mínimo global en x^k , y que $\rho_k \rightarrow \infty$. Entonces todo punto de acumulación de la sucesión $\{x^k\}$ es un minimizador global del problema restringido (16.1). Si además f, h son diferenciables, los x^k son minimizadores aproximados con precisión creciente y la sucesión converge a un punto x^* regular (el jacobiano $\nabla h(x^*)$ tiene rango m), entonces*

$$\lambda^k = \rho_k h(x^k) \rightarrow \lambda^*,$$

donde λ^* es el vector de multiplicadores de Lagrange de x^* .

Esquema de demostración. Para la primera parte: sea $\bar{x}$ factible cualquiera. Como x^k minimiza $Q(\cdot; \rho_k)$,

$$f(x^k) + \frac{\rho_k}{2} \|h(x^k)\|^2 \leq f(\bar{x}) + \frac{\rho_k}{2} \|h(\bar{x})\|^2 = f(\bar{x}),$$

pues $h(\bar{x}) = 0$. De aquí, $\frac{\rho_k}{2} \|h(x^k)\|^2 \leq f(\bar{x}) - f(x^k)$ está acotado, y como $\rho_k \rightarrow \infty$ se obtiene $\|h(x^k)\| \rightarrow 0$: los límites son factibles. La misma desigualdad da $f(x^k) \leq f(\bar{x})$, luego el límite es

óptimo. Para la segunda parte, la condición de primer orden $\nabla f(x^k) + \nabla h(x^k)^\top [\rho_k h(x^k)] = 0$ identifica a $\rho_k h(x^k)$ como estimador del multiplicador; la regularidad de x^* permite despejarlo y pasar al límite. Los detalles están en [5] (Teoremas 17.1 y 17.2) y [6] (cap. 6). $\square$

16.1.3. El precio numérico: mal condicionamiento

Si la penalización converge, ¿por qué no usarla siempre con ρ gigante y listo? Porque el subproblema $\min_x Q(x; \rho)$ se vuelve *numéricamente intratable* cuando ρ crece. Veamos por qué. La matriz hessiana de Q (con h de componentes h_j) es

$$\nabla^2 Q(x; \rho) = \nabla^2 f(x) + \rho \nabla h(x)^\top \nabla h(x) + \rho \sum_{j=1}^m h_j(x) \nabla^2 h_j(x).$$

Cerca de la solución, $h_j(x) \approx 0$ y el último término es despreciable; domina el término $\rho \nabla h(x)^\top \nabla h(x)$, una matriz simétrica semidefinida positiva de rango m (uno por restricción). En consecuencia:

- en las m direcciones *normales* a la superficie factible (las filas de ∇h), la curvatura de Q es de orden ρ : autovalores $\approx \rho \cdot (\text{constante})$, enormes;
- en las $n-m$ direcciones *tangentes* a la superficie factible, la curvatura es la de f : autovalores de orden 1.

El *número de condición* (cociente entre el autovalor mayor y el menor) de la hessiana crece entonces como ρ : el “valle” de Q es un cañón larguísimo y de paredes casi verticales. Sabemos del capítulo anterior que, con κ el número de condición, el descenso de gradiente con paso $1/L$ contrae el error a razón $1 - 1/\kappa$ y el descenso más pronunciado a razón $(\frac{\kappa-1}{\kappa+1})^2$ en el valor objetivo (Teorema 15.13): con $\rho = 10^6$, cada iteración casi no avanza, y además los errores de redondeo en aritmética de punto flotante se amplifican al resolver los sistemas lineales de Newton.

Cuidado (error común)

La tentación de “poner $\rho = 10^9$ y minimizar una sola vez” es un error clásico. Con ρ enorme: (i) la hessiana de Q tiene número de condición de orden ρ y los métodos de primer orden se arrastran; (ii) el término $\frac{\rho}{2} \|h\|^2$ aplasta numéricamente a f (con precisión doble, sumar 1 y 10^{16} pierde el 1); (iii) aun en aritmética exacta, el minimizador sigue siendo infactible ($h \neq 0$). Por eso el método aumenta ρ *gradualmente*, usando cada solución como semilla de la siguiente; y por eso, en última instancia, se inventó el lagrangiano aumentado, que no necesita $\rho \rightarrow \infty$.

16.2. Métodos de barrera y la trayectoria central [P4]

16.2.1. La idea: un peaje por acercarse a la frontera

La penalización multa la infactibilidad *desde afuera*. Los métodos de barrera (*barrier methods*) hacen lo contrario: trabajan siempre *estrictamente dentro* del conjunto factible y cobran un peaje que tiende a infinito conforme el punto se acerca a la frontera, de modo que el iterando

jamás la cruza. Se aplican a problemas con desigualdades,

$$\min_x f(x) \quad \text{s.a.} \quad g_i(x) \leq 0, \quad i = 1, \dots, p,$$

cuyo interior factible $\{x : g_i(x) < 0 \forall i\}$ se supone no vacío (condición de Slater, que ya conoces del capítulo de dualidad).

Definición 16.4 (Barrera logarítmica y trayectoria central). La *función barrera logarítmica* (*logarithmic barrier*) con parámetro $\mu > 0$ es

$$B(x; \mu) = f(x) - \mu \sum_{i=1}^p \log(-g_i(x)),$$

definida solo donde $g_i(x) < 0$ para todo i . Su minimizador $x(\mu)$ (cuando existe y es único, por ejemplo si el problema es convexo con Slater) describe, al variar $\mu > 0$, una curva llamada *trayectoria central* (*central path*). El método de barrera sigue esa curva: se minimiza $B(\cdot; \mu_k)$ partiendo de la solución anterior y se reduce $\mu_{k+1} = \mu_k/\tau$, $\tau > 1$, hasta que μ es pequeño.

Observa la lógica del signo: si $g_i(x) < 0$ (holgura positiva), $-g_i(x) > 0$ y el logaritmo está definido; cuando x se acerca a la frontera $g_i = 0$, $-\log(-g_i(x)) \rightarrow +\infty$: el peaje explota. Con μ grande, el peaje domina y $x(\mu)$ se queda cerca del “centro” del conjunto factible; con $\mu \rightarrow 0^+$, el peaje se apaga y $x(\mu)$ converge al óptimo restringido, deslizándose por dentro del conjunto. Esta es la base de los célebres *métodos de puntos interiores* (*interior-point methods*) que resuelven programas lineales y convexos en tiempo polinomial [2].

Ejemplo 16.5 (Barrera en 1D, calculado). Resolvamos

$$\min_x x \quad \text{s.a.} \quad -x \leq 0 \quad (\text{es decir, } x \geq 0).$$

La solución es $x^* = 0$. El multiplicador KKT sale de $1 - \lambda = 0$ (gradiente de $x + \lambda(-x)$), o sea $\lambda^* = 1$, con complementariedad $\lambda^* g(x^*) = 0$ satisfecha porque $g(x^*) = 0$. La función barrera es

$$B(x; \mu) = x - \mu \log x, \quad x > 0,$$

que es estrictamente convexa en $(0, \infty)$ (su segunda derivada es $\mu/x^2 > 0$). Su punto crítico:

$$B'(x; \mu) = 1 - \frac{\mu}{x} = 0 \quad \implies \quad x(\mu) = \mu.$$

La trayectoria central es, literalmente, $x(\mu) = \mu$: con $\mu = 1$, $x = 1$; con $\mu = 0.1$, $x = 0.1$; y $x(\mu) \rightarrow 0 = x^*$ cuando $\mu \rightarrow 0^+$, siempre desde el interior $x > 0$. Además, el *multiplicador implícito de barrera*

$$\lambda(\mu) = \frac{\mu}{-g(x(\mu))} = \frac{\mu}{x(\mu)} = 1 = \lambda^*$$

acierta el multiplicador exacto (en general solo converge a λ^* ; aquí lo clava para todo μ por la linealidad del problema). Y la brecha $f(x(\mu)) - f(x^*) = \mu - 0 = \mu$ es exactamente el valor del parámetro: una regla general, como enuncia el siguiente teorema.

Teorema 16.6 (La trayectoria central da pares primal–dual aproximados). *Sea el problema convexo (f y todas las g_i convexas y diferenciables) con la condición de Slater, y sea $x(\mu)$ un punto de la trayectoria central. Definamos*

$$\lambda_i(\mu) = \frac{\mu}{-g_i(x(\mu))} > 0, \quad i = 1, \dots, p.$$

Entonces el par $(x(\mu), \lambda(\mu))$ satisface: (i) $x(\mu)$ es estrictamente factible; (ii) $\lambda(\mu) \geq 0$ y $x(\mu)$ minimiza el lagrangiano ordinario $L(x, \lambda(\mu)) = f(x) + \sum_i \lambda_i(\mu) g_i(x)$, de modo que $\lambda(\mu)$ es factible para el problema dual con valor dual $q(\lambda(\mu)) = f(x(\mu)) - p\mu$; y por lo tanto (iii) la brecha de dualidad (duality gap) es

$$f(x(\mu)) - q(\lambda(\mu)) = p\mu,$$

así que $f(x(\mu)) - f(x^) \leq p\mu$: basta llevar μ hasta ε/p para garantizar precisión ε .*

Esquema de demostración. La condición de primer orden de la barrera es

$$\nabla f(x(\mu)) + \sum_i \frac{\mu}{-g_i(x(\mu))} \nabla g_i(x(\mu)) = 0,$$

que con la definición de $\lambda_i(\mu)$ se lee $\nabla_x L(x(\mu), \lambda(\mu)) = 0$: como $L(\cdot, \lambda(\mu))$ es convexa, $x(\mu)$ la minimiza globalmente y entonces

$$q(\lambda(\mu)) = L(x(\mu), \lambda(\mu)) = f(x(\mu)) + \sum_i \lambda_i(\mu) g_i(x(\mu)) = f(x(\mu)) - p\mu,$$

pues cada sumando vale $\lambda_i(\mu) g_i(x(\mu)) = -\mu$. La cota final es dualidad débil. Ver [2] (sección 11.2). $\square$

Intuición

La trayectoria central es una *complementariedad relajada*: en lugar de exigir $\lambda_i(-g_i) = 0$ (KKT exacto), exige $\lambda_i(-g_i) = \mu$ para todo i . Es como un mercado donde el producto “precio sombra $\times$ holgura” no es cero sino un margen uniforme μ que el regulador va apretando hacia cero: cada punto de la curva es un cuasi-equilibrio, y el límite $\mu \rightarrow 0$ es el equilibrio KKT exacto. Nota la dualidad de temperamentos: la penalización *empuja desde afuera* hacia la factibilidad; la barrera *retiene adentro* y suelta gradualmente. Ambas comparten el mismo defecto: exactitud solo en el límite ($\rho \rightarrow \infty$ o $\mu \rightarrow 0$), con hessianas cada vez peor condicionadas. El lagrangiano aumentado rompe ese destino.

16.3. El lagrangiano aumentado y el método de multiplicadores [P5]

16.3.1. Dos defectos, una cura

Recapitulemos los dos hallazgos de la sección 16.1. Primero, la penalización pura es *siempre infactible* con ρ finito: en el Ejemplo 16.2 el error era $-1/(1+\rho)$. Segundo, la cantidad $\rho h(x(\rho))$

estima el multiplicador λ^* . La idea genial de Hestenes y Powell (1969) fue combinar ambas: si la penalización nos regala una estimación del precio λ , ¿por qué no *incorporar ese precio explícitamente* en la función objetivo, como en el lagrangiano, y quedarnos con la multa cuadrática solo como refuerzo? El precio hace el trabajo fino de centrar el mínimo en el lugar exacto; la multa hace el trabajo grueso de dar curvatura.

Definición 16.7 (Lagrangiano aumentado). Para el problema (16.1), el *lagrangiano aumentado* (*augmented Lagrangian*) con parámetro $\rho > 0$ es

$$L_\rho(x, \lambda) = f(x) + \sum_{j=1}^m \lambda_j h_j(x) + \frac{\rho}{2} \|h(x)\|^2 = f(x) + \langle \lambda, h(x) \rangle + \frac{\rho}{2} \|h(x)\|^2.$$

Es el lagrangiano ordinario $L(x, \lambda)$ más la multa cuadrática; o, si se prefiere, la función penalizada $Q(x; \rho)$ más el término de precios $\langle \lambda, h(x) \rangle$. Con $\rho = 0$ recuperamos el lagrangiano; con $\lambda = 0$, la penalización pura.

La motivación es doble y conviene tener ambas caras presentes:

- (I) **Arregla la infactibilidad.** El término lineal $\langle \lambda, h(x) \rangle$ “inclina” la función penalizada. Recordemos el Ejemplo 16.2: el mínimo de Q quedaba corto ($x(\rho) < 1$) porque bajar f empujaba hacia 0. Si sumamos $\lambda(x - 1)$ con λ *negativo* (el signo correcto, $\lambda^* = -1$), premiamos moverse hacia $x > 1$ y compensamos exactamente ese sesgo. Veremos que con $\lambda = \lambda^*$ la compensación es perfecta: el mínimo de $L_\rho(\cdot, \lambda^*)$ es *exactamente* x^* , con ρ finito.
- (II) **Convexifica localmente.** La hessiana en x es

$$\nabla_{xx}^2 L_\rho = \nabla_{xx}^2 L(x, \lambda) + \rho \nabla h(x)^\top \nabla h(x) + \rho \sum_j h_j(x) \nabla^2 h_j(x).$$

En problemas restringidos, la teoría de segundo orden solo garantiza que $\nabla_{xx}^2 L(x^*, \lambda^*)$ sea definida positiva *sobre el subespacio tangente* $\{d : \nabla h(x^*)d = 0\}$; en las direcciones normales puede haber curvatura negativa y el lagrangiano ordinario puede no tener mínimo en x (solo punto silla). El término $\rho \nabla h^\top \nabla h$ agrega curvatura $\rho \|\nabla h(x^*)d\|^2 > 0$ precisamente en esas direcciones normales, sin tocar las tangentes: para ρ suficientemente grande (pero *finito*) la hessiana completa se vuelve definida positiva y el punto silla se convierte en mínimo local genuino, minimizable con los métodos del capítulo anterior.

16.3.2. El algoritmo de Hestenes–Powell

El *método de multiplicadores* (*method of multipliers*), o método del lagrangiano aumentado (también llamado “método de gradiente aumentado”) es:

1. Elegir $\lambda^0 \in \mathbb{R}^m$ (por ejemplo $\lambda^0 = 0$), $\rho > 0$, un punto inicial x^{-1} y una tolerancia $\varepsilon > 0$.
2. En la iteración $k = 0, 1, 2, \dots$: resolver el subproblema *sin restricciones*

$$x^k \in \arg \min_x L_\rho(x, \lambda^k),$$

usando x^{k-1} como semilla.

3. Actualizar el multiplicador con la regla de Hestenes–Powell:

$$\lambda^{k+1} = \lambda^k + \rho h(x^k).$$

4. Si $\|h(x^k)\| \leq \varepsilon$ y $\|\lambda^{k+1} - \lambda^k\| \leq \rho\varepsilon$, detenerse; si no, volver al paso 2. (Opcional: si la factibilidad no mejora lo suficiente entre iteraciones, aumentar ρ moderadamente.)

¿De dónde sale la regla del paso 3? No es un truco: es *ascenso en gradiente sobre la función dual*, y la derivación conecta todo lo que sabemos de dualidad. Hagámosla con calma.

La actualización de λ es ascenso dual. Definamos la *función dual aumentada*

$$q_\rho(\lambda) = \min_x L_\rho(x, \lambda),$$

que es la función dual ordinaria del problema *equivalente*

$$\min_x f(x) + \frac{\rho}{2} \|h(x)\|^2 \quad \text{s.a.} \quad h(x) = 0,$$

pues sumar $\frac{\rho}{2} \|h\|^2$ no cambia ni el conjunto factible ni el valor de f sobre él (ahí vale cero): mismo problema, mismo óptimo, mismos multiplicadores. Del capítulo de dualidad sabemos dos cosas sobre cualquier función dual: es *cóncava* en λ (mínimo puntual de funciones afines en λ), y su gradiente, cuando el minimizador interior $x(\lambda)$ es único, se obtiene por el teorema de la envolvente (*envelope theorem*, [11]): se deriva respecto de λ *sin* derivar $x(\lambda)$, porque el término $\nabla_x L_\rho \cdot \partial x / \partial \lambda$ se anula en el minimizador. Así,

$$\nabla q_\rho(\lambda) = \frac{\partial}{\partial \lambda} \left[f(x) + \langle \lambda, h(x) \rangle + \frac{\rho}{2} \|h(x)\|^2 \right]_{x=x(\lambda)} = h(x(\lambda)).$$

El gradiente de la dual es, simplemente, *la violación de la restricción en el minimizador actual*. Maximizar la dual por ascenso en gradiente con tamaño de paso α da $\lambda^{k+1} = \lambda^k + \alpha h(x^k)$; la regla de Hestenes–Powell es exactamente esto con $\alpha = \rho$.

¿Por qué el paso $\alpha = \rho$ y no otro? Dos razones, una algebraica y una de convergencia.

(a) *El nuevo multiplicador hace “KKT-compatible” al punto actual.* En el minimizador x^k del subproblema, la condición de primer orden es

$$0 = \nabla_x L_\rho(x^k, \lambda^k) = \nabla f(x^k) + \nabla h(x^k)^\top \underbrace{[\lambda^k + \rho h(x^k)]}_{= \lambda^{k+1}}.$$

Léelo con atención: agrupando el término de precios y el de multa, el punto x^k satisface *exactamente* la condición KKT $\nabla f + \nabla h^\top \lambda = 0$ con el multiplicador λ^{k+1} . Es decir, la regla de actualización es la única que convierte cada iterando en un punto estacionario del lagrangiano ordinario con el precio nuevo; solo falta que la factibilidad $h(x^k) = 0$ se logre en el límite. (Compara con la sección 16.1: allí el estimador era ρh ; aquí es $\lambda^k + \rho h$, que acumula la información de todas las iteraciones en vez de empezar de cero.)

- (b) Es el paso “seguro” del ascenso. Puede probarse que q_ρ es la regularización de Moreau de la dual ordinaria q : suavizarla con la multa hace que ∇q_ρ sea Lipschitz con constante $1/\rho$. Del capítulo de métodos de gradiente sabemos que para una función con gradiente $1/\rho$ -Lipschitz el paso natural es el recíproco de la constante, o sea ρ : garantiza ascenso monótono de la dual sin sobrepasarse. Mientras mayor la multa, más suave la dual y más agresivo puede ser el paso en precios [6, 8].

Intuición

Interpretación económica: λ es un vector de *precios* y $h(x)$ un vector de *excesos de demanda* (violaciones de las restricciones de recursos). El subproblema del paso 2 es la respuesta óptima de la “economía” a los precios vigentes; el paso 3 es un *subastador walrasiano*: donde hay exceso de demanda ($h_j(x^k) > 0$), sube el precio λ_j ; donde hay exceso de oferta, lo baja; y la sensibilidad del ajuste es ρ . El proceso de tâtonnement se detiene cuando el mercado se vacía ($h = 0$): en ese punto los precios ya no se mueven y tenemos un par KKT, es decir, un punto silla del lagrangiano: el “equilibrio”. La multa cuadrática es el ingrediente moderno: hace que la respuesta de la economía a los precios sea única y estable (convexifica), cosa que el tâtonnement clásico no garantizaba.

16.3.3. Exactitud con penalización finita: el teorema central

La superioridad del lagrangiano aumentado sobre la penalización pura se resume en un enunciado: *con el precio correcto no hace falta multa infinita*.

Teorema 16.8 (Exactitud del lagrangiano aumentado, caso cuadrático-lineal). *Consideremos el problema cuadrático con restricciones lineales*

$$\min_x \frac{1}{2}x^\top Qx + c^\top x \quad \text{s.a.} \quad Ax = b,$$

con $Q \in \mathbb{R}^{n \times n}$ simétrica, $A \in \mathbb{R}^{m \times n}$ de rango m , y supongamos la condición suficiente de segundo orden: $d^\top Qd > 0$ para todo $d \neq 0$ con $Ad = 0$. Sea (x^*, λ^*) el par KKT, es decir,

$$Qx^* + c + A^\top \lambda^* = 0, \quad Ax^* = b.$$

Entonces existe $\bar{\rho} \geq 0$ tal que para todo $\rho > \bar{\rho}$, la función $x \mapsto L_\rho(x, \lambda^*)$ es estrictamente convexa y su único minimizador global es exactamente x^* . Ninguna multa infinita, ningún error residual: con el multiplicador verdadero, el problema restringido se resuelve de un solo golpe sin restricciones.

Demostración. Aquí $h(x) = Ax - b$, así que

$$L_\rho(x, \lambda^*) = \frac{1}{2}x^\top Qx + c^\top x + (\lambda^*)^\top (Ax - b) + \frac{\rho}{2} \|Ax - b\|^2,$$

una función cuadrática en x . Verificamos las dos condiciones de un mínimo global de una cuadrática: gradiente nulo y hessiana definida positiva.

Paso 1: x^* es punto estacionario para todo $\rho \geq 0$. Calculamos el gradiente (usando $\nabla_x \frac{1}{2} \|Ax - b\|^2 = A^\top(Ax - b)$) y lo evaluamos en x^* :

$$\nabla_x L_\rho(x^*, \lambda^*) = \underbrace{Qx^* + c + A^\top \lambda^*}_{=0 \text{ (KKT)}} + \rho A^\top \underbrace{(Ax^* - b)}_{=0 \text{ (factibilidad)}} = 0.$$

Nota el reparto de tareas: la estacionariedad KKT anula el bloque lagrangiano y la factibilidad anula el bloque de multa. Esto vale para *cualquier* ρ , incluso $\rho = 0$.

Paso 2: la hessiana $H_\rho = Q + \rho A^\top A$ es definida positiva para ρ grande. Supongamos, por contradicción, que no existe tal $\bar{\rho}$: entonces hay una sucesión $\rho_k \rightarrow \infty$ y vectores unitarios d^k ($\|d^k\| = 1$) con

$$(d^k)^\top Q d^k + \rho_k \|A d^k\|^2 \leq 0. \quad (*)$$

Como la esfera unitaria de $\mathbb{R}^n$ es compacta, una subsucesión cumple $d^k \rightarrow d$ con $\|d\| = 1$. De (*), $\|A d^k\|^2 \leq -(d^k)^\top Q d^k / \rho_k \rightarrow 0$ (el numerador está acotado por continuidad), luego $A d = 0$: la dirección límite es tangente. Pero también de (*), $(d^k)^\top Q d^k \leq 0$ para todo k , y pasando al límite $d^\top Q d \leq 0$, contradiciendo la hipótesis de segundo orden $d^\top Q d > 0$ en direcciones tangentes no nulas. Por lo tanto existe $\bar{\rho}$ finito con $H_\rho \succ 0$ para $\rho > \bar{\rho}$.

Conclusión. Para $\rho > \bar{\rho}$, $L_\rho(\cdot, \lambda^*)$ es una cuadrática estrictamente convexa con punto estacionario x^* ; ese punto es su único minimizador global. $\square$

Observación 16.9. Si Q es semidefinida positiva en todo $\mathbb{R}^n$ (problema convexo), sirve cualquier $\rho > 0$, es decir $\bar{\rho} = 0$: la cuadrática $H_\rho = Q + \rho A^\top A$ es definida positiva apenas Q sea definida positiva sobre $\ker A$ y $\rho > 0$. El teorema tiene versión no lineal general: si (x^*, λ^*) satisface las condiciones suficientes de segundo orden del problema (16.1), entonces para ρ mayor que un umbral finito, x^* es un minimizador local estricto de $L_\rho(\cdot, \lambda^*)$, y el método de multiplicadores converge localmente con tasa lineal de razón proporcional a $1/\rho$ si λ^0 está cerca de λ^* ; ver [5] (Teorema 17.5 y sección 17.3) y [6] (cap. 6). En la práctica no conocemos λ^* , pero el algoritmo lo *aprende*: cada actualización acerca λ^k al precio verdadero, y la exactitud del teorema explica por qué el método termina con ρ moderado, sin heredar el mal condicionamiento de la penalización pura.

16.3.4. Ejemplo numérico completo: tres iteraciones a mano

Ejemplo 16.10 (Método de multiplicadores paso a paso). Resolvamos con el método de multiplicadores el problema

$$\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2 \quad \text{s.a.} \quad h(x) = x_1 + x_2 - 1 = 0.$$

Solución exacta (para comparar). El lagrangiano es $L = x_1^2 + x_2^2 + \lambda(x_1 + x_2 - 1)$; las condiciones KKT:

$$2x_1 + \lambda = 0, \quad 2x_2 + \lambda = 0, \quad x_1 + x_2 = 1.$$

Las dos primeras dan $x_1 = x_2 = -\lambda/2$; sustituyendo en la tercera, $-\lambda = 1$, o sea $\lambda^* = -1$ y $x^* = (\frac{1}{2}, \frac{1}{2})$, con valor óptimo $\frac{1}{2}$. (Geométricamente: el punto de la recta $x_1 + x_2 = 1$ más cercano

al origen.)

El subproblema en forma cerrada. El lagrangiano aumentado es

$$L_\rho(x, \lambda) = x_1^2 + x_2^2 + \lambda(x_1 + x_2 - 1) + \frac{\rho}{2}(x_1 + x_2 - 1)^2.$$

Condición de primer orden en x (derivando respecto de cada coordenada):

$$2x_1 + \lambda + \rho(x_1 + x_2 - 1) = 0, \quad 2x_2 + \lambda + \rho(x_1 + x_2 - 1) = 0.$$

Restando ambas ecuaciones: $2x_1 - 2x_2 = 0$, luego $x_1 = x_2 = t$. Sustituyendo: $2t + \lambda + \rho(2t - 1) = 0$, de donde

$$t(\lambda) = \frac{\rho - \lambda}{2(1 + \rho)}, \quad h(x(\lambda)) = 2t(\lambda) - 1 = \frac{\rho - \lambda}{1 + \rho} - 1 = \frac{-1 - \lambda}{1 + \rho}.$$

(La hessiana es $2I + \rho \mathbf{1}\mathbf{1}^\top \succ 0$, así que es mínimo global, como garantiza la Observación 16.9.)

Tomemos $\rho = 1$ y $\lambda^0 = 0$, y ejecutemos tres iteraciones exactas.

Iteración $k = 0$ ($\lambda^0 = 0$):

$$t_0 = \frac{1 - 0}{2 \cdot 2} = \frac{1}{4}, \quad x^0 = \left(\frac{1}{4}, \frac{1}{4}\right), \quad h(x^0) = \frac{1}{2} - 1 = -\frac{1}{2}.$$

El punto se queda corto (la multa sola no basta, como en la penalización pura). Actualizamos el precio:

$$\lambda^1 = \lambda^0 + \rho h(x^0) = 0 + 1 \cdot \left(-\frac{1}{2}\right) = -\frac{1}{2}.$$

Iteración $k = 1$ ($\lambda^1 = -\frac{1}{2}$):

$$t_1 = \frac{1 - (-\frac{1}{2})}{4} = \frac{3/2}{4} = \frac{3}{8}, \quad x^1 = \left(\frac{3}{8}, \frac{3}{8}\right), \quad h(x^1) = \frac{3}{4} - 1 = -\frac{1}{4},$$

$$\lambda^2 = -\frac{1}{2} + 1 \cdot \left(-\frac{1}{4}\right) = -\frac{3}{4}.$$

Iteración $k = 2$ ($\lambda^2 = -\frac{3}{4}$):

$$t_2 = \frac{1 - (-\frac{3}{4})}{4} = \frac{7/4}{4} = \frac{7}{16}, \quad x^2 = \left(\frac{7}{16}, \frac{7}{16}\right), \quad h(x^2) = \frac{7}{8} - 1 = -\frac{1}{8},$$

$$\lambda^3 = -\frac{3}{4} + 1 \cdot \left(-\frac{1}{8}\right) = -\frac{7}{8}.$$

Resumamos la evidencia numérica:

k	x^k	$h(x^k)$	λ^{k+1}
0	(0.25, 0.25)	-0.5	-0.5
1	(0.375, 0.375)	-0.25	-0.75
2	(0.4375, 0.4375)	-0.125	-0.875

Todo converge a la solución exacta: $x^k \rightarrow (0.5, 0.5)$, $\lambda^k \rightarrow -1$, y *cada error se divide exactamente por 2 en cada iteración*. No es casualidad: de las fórmulas cerradas,

$$\lambda^{k+1} = \lambda^k + \rho \cdot \frac{-1 - \lambda^k}{1 + \rho} = \frac{\lambda^k - \rho}{1 + \rho} \quad \implies \quad \lambda^{k+1} - \lambda^* = \lambda^{k+1} + 1 = \frac{\lambda^k + 1}{1 + \rho},$$

es decir, convergencia *lineal* con razón $\frac{1}{1+\rho}$ (aquí $\frac{1}{2}$). Sube la multa a $\rho = 9$ y la razón cae a $\frac{1}{10}$: un dígito decimal por iteración. El parámetro ρ ya no necesita irse a infinito; solo gradúa la *velocidad* del aprendizaje de precios. Compara con la penalización pura del Ejemplo 16.2, donde la precisión final estaba atada al valor de ρ .

Estrategia de examen

Para ejecutar el método de multiplicadores a mano (en un examen o en la exposición final), sigue siempre este guion: (1) resuelve primero el problema exacto por KKT para conocer (x^*, λ^*) , que te sirve de control; (2) escribe L_ρ y obtén el minimizador del subproblema *en función de λ* (en problemas cuadrático-lineales es un sistema lineal; explota simetrías como hicimos al restar las ecuaciones); (3) itera la recursión $\lambda^{k+1} = \lambda^k + \rho h(x^k)$ en una tabla con columnas $k, x^k, h(x^k), \lambda^{k+1}$; (4) cierra identificando la razón de convergencia $\frac{1}{1+\rho}$ (o su análoga) restando λ^* : mostrar la recursión del error impresiona más que tres filas de números. Errores típicos a evitar: olvidar el factor ρ en la actualización, equivocarse el signo de h (define siempre $h = \text{“lado izquierdo menos lado derecho”}$), y actualizar λ con el x de la iteración anterior en vez del recién calculado.

16.4. Desigualdades y ADMM: descentralización vía precios [P4]

16.4.1. Lagrangiano aumentado con desigualdades

¿Y si el problema tiene desigualdades $g_i(x) \leq 0, i = 1, \dots, p$? La receta estándar las convierte en igualdades con variables de holgura ($g_i(x) + s_i = 0, s_i \geq 0$), aplica el lagrangiano aumentado de igualdades y minimiza en las holguras *analíticamente* (lo harás tú mismo en el Ejercicio 16.16). El resultado es la fórmula siguiente.

Proposición 16.11 (Lagrangiano aumentado para desigualdades). *Para el problema $\min f(x)$ s.a. $g_i(x) \leq 0, i = 1, \dots, p$, el lagrangiano aumentado es*

$$L_\rho(x, \lambda) = f(x) + \frac{1}{2\rho} \sum_{i=1}^p \left[(\max\{0, \lambda_i + \rho g_i(x)\})^2 - \lambda_i^2 \right],$$

y la actualización de multiplicadores del método es

$$\lambda_i^{k+1} = \max\{0, \lambda_i^k + \rho g_i(x^k)\}, \quad i = 1, \dots, p.$$

La fórmula parece complicada pero su lógica es transparente. Fijemos una restricción i y distingamos dos regímenes:

- **Régimen activo** ($\lambda_i + \rho g_i(x) > 0$: la restricción aprieta o el precio es alto). El término i vale $\lambda_i g_i(x) + \frac{\rho}{2} g_i(x)^2$ (desarrolla el cuadrado y verifica que los λ_i^2 se cancelan): exactamente el tratamiento de una *igualdad*, precio más multa.
- **Régimen inactivo** ($\lambda_i + \rho g_i(x) \leq 0$: holgura amplia y precio bajo). El máximo vale 0 y el término se reduce a la constante $-\lambda_i^2/(2\rho)$: la restricción *desaparece* de la optimización

en x , como manda la complementariedad KKT ($\lambda_i^* = 0$ si $g_i(x^*) < 0$).

La actualización con $\max\{0, \cdot\}$ es el mismo subastador de antes, pero que respeta el piso $\lambda_i \geq 0$: los precios sombra de las desigualdades no pueden ser negativos, y si el ajuste walrasiano pide bajar de cero, el precio se queda en cero (bien libre, restricción inactiva). Nota la coherencia con el gradiente proyectado del capítulo anterior: la actualización es un *paso de ascenso proyectado* sobre el ortante $\lambda \geq 0$, que es donde vive la variable dual.

16.4.2. ADMM: el método de dirección alternada de multiplicadores

Muchos problemas de economía y de estadística tienen estructura *separable*: el objetivo es una suma de piezas que pertenecen a agentes distintos, acopladas solo por una restricción lineal común. El *método de dirección alternada de multiplicadores* (ADMM, *alternating direction method of multipliers*) explota exactamente esa estructura [2]. El problema modelo es

$$\min_{x,z} f(x) + g(z) \quad \text{s.a.} \quad Ax + Bz = c,$$

con f, g convexas. El lagrangiano aumentado es

$$L_\rho(x, z, \lambda) = f(x) + g(z) + \langle \lambda, Ax + Bz - c \rangle + \frac{\rho}{2} \|Ax + Bz - c\|^2.$$

El método de multiplicadores puro exigiría minimizar en (x, z) *conjuntamente*; el término cuadrático mezcla x con z y arruina la separabilidad. ADMM renuncia a la minimización conjunta y alterna, estilo Gauss–Seidel:

1. Inicializar z^0, λ^0 y $\rho > 0$.
2. Paso en x : $x^{k+1} \in \arg \min_x L_\rho(x, z^k, \lambda^k)$ (con z y λ congelados).
3. Paso en z : $z^{k+1} \in \arg \min_z L_\rho(x^{k+1}, z, \lambda^k)$ (usando ya el x nuevo).
4. Paso dual: $\lambda^{k+1} = \lambda^k + \rho(Ax^{k+1} + Bz^{k+1} - c)$.
5. Repetir 2–4 hasta que el residuo primal $\|Ax^{k+1} + Bz^{k+1} - c\|$ y el residuo dual $\rho \|B(z^{k+1} - z^k)\|$ sean pequeños.

Bajo convexidad de f y g y existencia de un punto silla, ADMM converge para *cualquier* $\rho > 0$ (valor objetivo al óptimo, residuo primal a cero, λ^k al multiplicador óptimo); la demostración, vía monotonía del operador punto-silla, está en [2] (sección 3.2) y en la literatura que revisa [8] (cap. 10).


16.4.3. Lectura económica: planificación descentralizada por precios

Aquí está la joya conceptual del capítulo. Considera una economía con J agentes que comparten un recurso: el agente j elige $x_j \in \mathbb{R}^n$ (su plan de consumo o producción) con costo privado $f_j(x_j)$, y el balance de mercado exige

$$\min_{x_1, \dots, x_J} \sum_{j=1}^J f_j(x_j) \quad \text{s.a.} \quad \sum_{j=1}^J x_j = d$$

(demanda agregada igual a la dotación d ; es el *problema de intercambio* de [2], sección 7.3). Este es el problema del *planificador social*. Resolverlo centralizadamente exigiría que alguien conozca *todas* las funciones f_j : exactamente la crítica informacional clásica a la planificación central. Apliquemos en cambio el lagrangiano aumentado con actualización alternada (una variante de ADMM con promedios; esbozamos la versión más simple, el método de multiplicadores con subproblemas separables aproximados):

1. El coordinador anuncia un precio $\lambda^k \in \mathbb{R}^n$ (y el desequilibrio vigente del mercado).
2. Cada agente j , en paralelo y en privado, resuelve su subproblema: minimiza su costo $f_j(x_j)$ más el gasto a precios anunciados $\langle \lambda^k, x_j \rangle$ más un término cuadrático que lo penaliza por desviarse del reparto compatible con el balance (el término de ρ). Nadie revela su f_j : solo comunica su respuesta x_j^{k+1} .
3. El coordinador observa el *exceso de demanda agregado* $e^{k+1} = \sum_j x_j^{k+1} - d$ y ajusta precios: $\lambda^{k+1} = \lambda^k + \rho e^{k+1}$. Bienes sobredemandados se encarecen; bienes sobreofertados se abaratan.
4. Se repite hasta que el mercado se vacía ($e \approx 0$).



Intuición

Este esquema es un *segundo teorema del bienestar en versión computacional*. El teorema (equilibrio general, [9] cap. 16) dice que todo óptimo de Pareto puede *descentralizarse* con un vector de precios adecuado: existe λ^* tal que los planes óptimos privados frente a λ^* agregan justo al óptimo social. Pero el teorema es existencial: no dice *cómo encontrar* esos precios. El lagrangiano aumentado y ADMM son el algoritmo que falta: el *tâtonnement* $\lambda^{k+1} = \lambda^k + \rho e^{k+1}$ es ascenso en gradiente sobre la función dual, cuyo maximizador es precisamente el precio de soporte λ^* , y converge bajo convexidad. La convexidad de las preferencias y tecnologías, hipótesis central del segundo teorema, reaparece aquí como la condición de convergencia del algoritmo: no es un accidente, es el mismo teorema de punto silla visto por su cara dinámica. Y el término cuadrático de ρ , ausente del *tâtonnement* clásico, es lo que estabiliza el proceso cuando las respuestas individuales a precios son muy elásticas (funciones f_j no estrictamente convexas), el caso en que el subastador walrasiano puro puede oscilar sin converger.

ADMM tiene además una segunda vida moderna en estadística y aprendizaje automático (lasso, regresión distribuida en datos masivos, consenso entre procesadores), siempre con la misma gramática: subproblemas privados más coordinación por precios; ver [2] y [8].

16.5. Aplicación desarrollada: el portafolio de Markowitz [P4]

16.5.1. Formulación como programa cuadrático

El problema de selección de portafolio de media-varianza (*mean-variance portfolio selection*) de Markowitz es el ejemplo canónico de programa cuadrático (QP) en finanzas [4]. Hay n activos; el activo i tiene retorno esperado μ_i , y $\Sigma \in \mathbb{R}^{n \times n}$ es la matriz de covarianzas de los retornos (simétrica y definida positiva). Un portafolio es un vector de ponderaciones $x \in \mathbb{R}^n$, donde x_i es la fracción de la riqueza invertida en el activo i . Su retorno esperado es $\mu^\top x$ y su varianza es $x^\top \Sigma x$. El inversionista busca la mínima varianza compatible con un retorno objetivo r y con invertir toda la riqueza:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top \Sigma x \quad \text{s.a.} \quad \mu^\top x = r, \quad \mathbf{1}^\top x = 1, \quad (16.2)$$

donde $\mathbf{1} = (1, \dots, 1)$. (El factor $\frac{1}{2}$ es cosmético; permitimos ventas cortas al no exigir $x \geq 0$.) Es un QP con objetivo estrictamente convexo y dos restricciones lineales de igualdad: exactamente la clase cubierta por el Teorema 16.8.

16.5.2. Solución analítica por lagrangiano con tres activos

Ejemplo 16.12 (Markowitz con tres activos, todos los cálculos). Tomemos $n = 3$ activos no correlacionados con

$$\Sigma = \text{diag}(1, 2, 4), \quad \mu = (1, 2, 3), \quad r = 2.$$

(Unidades: retornos en puntos porcentuales; el activo 3 rinde más pero es cuatro veces más volátil que el 1.) El lagrangiano, con multiplicadores λ para el retorno y γ para el presupuesto, es

$$L(x, \lambda, \gamma) = \frac{1}{2} x^\top \Sigma x - \lambda(\mu^\top x - r) - \gamma(\mathbf{1}^\top x - 1)$$

(los signos de λ, γ son convención; con igualdades no hay restricción de signo). La condición de primer orden en x :

$$\Sigma x = \lambda \mu + \gamma \mathbf{1} \quad \implies \quad x = \lambda \Sigma^{-1} \mu + \gamma \Sigma^{-1} \mathbf{1}.$$

Con $\Sigma^{-1} = \text{diag}(1, \frac{1}{2}, \frac{1}{4})$ calculamos los tres escalares clásicos:

$$A := \mu^\top \Sigma^{-1} \mu = 1 \cdot 1 + 2 \cdot \frac{2}{2} + 3 \cdot \frac{3}{4} = 1 + 2 + \frac{9}{4} = \frac{21}{4},$$

$$B := \mu^\top \Sigma^{-1} \mathbf{1} = 1 + 1 + \frac{3}{4} = \frac{11}{4}, \quad C := \mathbf{1}^\top \Sigma^{-1} \mathbf{1} = 1 + \frac{1}{2} + \frac{1}{4} = \frac{7}{4}.$$

Imponiendo las dos restricciones a $x = \lambda \Sigma^{-1} \mu + \gamma \Sigma^{-1} \mathbf{1}$:

$$\mu^\top x = \lambda A + \gamma B = r = 2, \quad \mathbf{1}^\top x = \lambda B + \gamma C = 1,$$

es decir, multiplicando por 4, el sistema lineal 2×2

$$21\lambda + 11\gamma = 8, \quad 11\lambda + 7\gamma = 4.$$

Su determinante es $21 \cdot 7 - 11 \cdot 11 = 147 - 121 = 26$, y por la regla de Cramer:

$$\lambda = \frac{8 \cdot 7 - 11 \cdot 4}{26} = \frac{56 - 44}{26} = \frac{12}{26} = \frac{6}{13}, \quad \gamma = \frac{21 \cdot 4 - 11 \cdot 8}{26} = \frac{84 - 88}{26} = -\frac{2}{13}.$$

Sustituimos en la fórmula de x , coordenada por coordenada:

$$x_1 = \frac{6}{13} \cdot 1 - \frac{2}{13} \cdot 1 = \frac{4}{13}, \quad x_2 = \frac{6}{13} \cdot 1 - \frac{2}{13} \cdot \frac{1}{2} = \frac{6}{13} - \frac{1}{13} = \frac{5}{13},$$

$$x_3 = \frac{6}{13} \cdot \frac{3}{4} - \frac{2}{13} \cdot \frac{1}{4} = \frac{18-2}{52} = \frac{16}{52} = \frac{4}{13}.$$

Verificación (nunca la saltes): presupuesto $\frac{4+5+4}{13} = 1$; retorno $1 \cdot \frac{4}{13} + 2 \cdot \frac{5}{13} + 3 \cdot \frac{4}{13} = \frac{4+10+12}{13} = \frac{26}{13} = 2$. El portafolio óptimo es

$$x^* = \left(\frac{4}{13}, \frac{5}{13}, \frac{4}{13} \right) \approx (0.308, 0.385, 0.308),$$

con varianza mínima

$$(x^*)^\top \Sigma x^* = 1 \cdot \frac{16}{169} + 2 \cdot \frac{25}{169} + 4 \cdot \frac{16}{169} = \frac{16+50+64}{169} = \frac{130}{169} = \frac{10}{13} \approx 0.769.$$

Interpretación de los multiplicadores, por el teorema de la envolvente [11]: si $V(r)$ es el valor óptimo de (16.2), entonces $V'(r) = \lambda = \frac{6}{13}$: exigir una centésima más de retorno objetivo cuesta $\frac{6}{13} \cdot 0.01$ unidades del objetivo $\frac{1}{2} x^\top \Sigma x$ (media varianza): es el *precio sombra del retorno*, la pendiente (reescalada) de la frontera eficiente. Y $\gamma = -\frac{2}{13}$ es el valor marginal de relajar el presupuesto.

16.5.3. Cómo lo resolvería el lagrangiano aumentado

En el ejemplo anterior invertimos Σ a mano porque era diagonal y $n = 3$. Con $n = 500$ activos, restricciones adicionales (sin ventas cortas: $x \geq 0$; topes por sector), la vía analítica muere y entra el lagrangiano aumentado. Para (16.2), con $h(x) = (\mu^\top x - r, \mathbf{1}^\top x - 1)$ y multiplicadores $\lambda = (\lambda_1, \lambda_2)$:

$$L_\rho(x, \lambda) = \frac{1}{2} x^\top \Sigma x + \lambda_1 (\mu^\top x - r) + \lambda_2 (\mathbf{1}^\top x - 1) + \frac{\rho}{2} [(\mu^\top x - r)^2 + (\mathbf{1}^\top x - 1)^2].$$

Cada subproblema en x es cuadrático estrictamente convexo: su solución es el sistema lineal

$$[\Sigma + \rho(\mu\mu^\top + \mathbf{1}\mathbf{1}^\top)] x = \rho(r\mu + \mathbf{1}) - \lambda_1\mu - \lambda_2\mathbf{1},$$

resoluble por gradiente (capítulo anterior) o por factorización; luego el paso dual $\lambda_1^{k+1} = \lambda_1^k + \rho(\mu^\top x^k - r)$, $\lambda_2^{k+1} = \lambda_2^k + \rho(\mathbf{1}^\top x^k - 1)$. Por el Teorema 16.8 (caso cuadrático-lineal con $\Sigma \succ 0$), los multiplicadores convergen linealmente a $(-\lambda, -\gamma) = (-\frac{6}{13}, \frac{2}{13})$ del ejemplo (signos opuestos por la convención de signos del lagrangiano), y con el multiplicador exacto el subproblema entrega x^* *exactamente* con ρ finito. Si se añade $x \geq 0$, se usa la fórmula con máx de la Proposición 16.11 o un esquema ADMM en que el paso en z es la proyección sobre el ortante (gradiente proyectado otra vez). Sobre extensiones dinámicas del modelo media-varianza, puedes ver [4].

Con la misma gramática se calculan los *modelos de equilibrio general computable* (CGE): por

el enfoque de Negishi, un equilibrio walrasiano se obtiene maximizando una suma ponderada de utilidades sujeta a las restricciones de recursos, y las restricciones de balance de cada mercado se manejan con multiplicadores que son, literalmente, los precios de equilibrio; el lagrangiano aumentado y sus variantes distribuidas (sección 16.4) son la maquinaria numérica estándar para ese cálculo.

16.6. Guía práctica: ¿qué método uso? [P3]

Cierra el capítulo una tabla mental de decisión:

- **Penalización cuadrática:** útil como primer prototipo por su simplicidad, o cuando solo se necesita factibilidad aproximada. Evítala si necesitas alta precisión: requiere $\rho \rightarrow \infty$ y hereda mal condicionamiento (sección 16.1).
- **Barrera / puntos interiores:** la opción dominante para problemas *convexos* con desigualdades de tamaño mediano (LP, QP, programas cónicos): precisión alta en pocas decenas de iteraciones de Newton. Necesita un punto inicial estrictamente factible y no aprovecha bien una buena semilla previa (*warm start*).
- **Lagrangiano aumentado:** la elección robusta para restricciones de igualdad no lineales y problemas grandes; exacto con ρ finito, tolera semillas y reoptimizaciones, base de programas profesionales de optimización no lineal (LANCELOT, ALGENCAN).
- **ADMM:** cuando el problema es separable o distribuido (agentes, bloques de datos, consenso): convergencia modesta en precisión pero iteraciones baratísimas y paralelas; ideal en estadística de gran escala [2, 8].

En software: en Python, `scipy.optimize.minimize` (métodos SLSQP y `trust-constr`) y la librería de modelado `cvxpy` (que llama a solucionadores de puntos interiores y a OSQP, un ADMM para QP); en Julia, JuMP con Ipopt (barrera de puntos interiores) o Percival (lagrangiano aumentado). Para el proyecto final del curso basta `scipy` más un lagrangiano aumentado escrito a mano de veinte líneas, como el del Ejemplo 16.10.

Resumen del capítulo

- **Penalización cuadrática:** $Q(x; \rho) = f(x) + \frac{\rho}{2} \|h(x)\|^2$ (más $\frac{\rho}{2} \sum_i \max\{0, g_i\}^2$ con desigualdades). El minimizador $x(\rho)$ converge al óptimo restringido cuando $\rho \rightarrow \infty$, pero con ρ finito es *siempre infactible* (error de orden $1/\rho$) y la hessiana se condiciona mal (autovalores de orden ρ en direcciones normales, de orden 1 en tangentes). Subproducto: $\rho h(x(\rho)) \rightarrow \lambda^*$.
- **Barrera logarítmica:** $B(x; \mu) = f(x) - \mu \sum_i \log(-g_i(x))$; sus minimizadores forman la trayectoria central, que entrega pares primal-dual con brecha de dualidad exactamente $p\mu$ (base de los puntos interiores).
- **Lagrangiano aumentado:** $L_\rho(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle + \frac{\rho}{2} \|h(x)\|^2$. Método de multiplicadores (Hestenes-Powell): minimizar en x , luego $\lambda^{k+1} = \lambda^k + \rho h(x^k)$, que es *ascenso en gradiente sobre la función dual* con el paso natural ρ , y hace que cada

x^k satisfaga la estacionariedad KKT con el precio nuevo.

- **Exactitud:** con $\lambda = \lambda^*$, el mínimo de $L_\rho(\cdot, \lambda^*)$ es exactamente x^* para ρ finito (Teorema 16.8); los multiplicadores convergen linealmente con razón $\frac{1}{1+\rho}$ en el caso modelo.
- **Desigualdades:** actualización proyectada $\lambda_i^{k+1} = \max\{0, \lambda_i^k + \rho g_i(x^k)\}$.
- **ADMM:** para objetivos separables $f(x) + g(z)$ con acople lineal; alterna minimizaciones en bloques y paso dual. Lectura económica: agentes que optimizan en privado y un coordinador que ajusta precios según el exceso de demanda: el segundo teorema del bienestar hecho algoritmo.
- **Aplicaciones:** Markowitz es un QP que el lagrangiano aumentado resuelve con exactitud finita; los multiplicadores son precios sombra del retorno y del presupuesto (envolvente). CGE vía Negishi: los multiplicadores de los balances son los precios de equilibrio.
- Referencias: [5] cap. 17, [6] caps. 6–7, [7], [2], [4].

Ejercicios

Ejercicio 16.13. Aplica la penalización cuadrática al problema $\min_x \frac{1}{2}x^2$ s.a. $x = 2$. Calcula $x(\rho)$, la violación $h(x(\rho))$, y verifica que $\rho h(x(\rho))$ converge al multiplicador de Lagrange del problema. ¿Qué valor de ρ garantiza $|h(x(\rho))| \leq 10^{-3}$?

Solución. El único punto factible es $x^* = 2$; del lagrangiano $\frac{1}{2}x^2 + \lambda(x - 2)$, la estacionariedad $x + \lambda = 0$ en $x^* = 2$ da $\lambda^* = -2$. La función penalizada es $Q(x; \rho) = \frac{1}{2}x^2 + \frac{\rho}{2}(x - 2)^2$, estrictamente convexa; su punto crítico:

$$Q' = x + \rho(x - 2) = (1 + \rho)x - 2\rho = 0 \implies x(\rho) = \frac{2\rho}{1 + \rho}.$$

Violación: $h(x(\rho)) = x(\rho) - 2 = \frac{2\rho - 2(1 + \rho)}{1 + \rho} = -\frac{2}{1 + \rho} \neq 0$ para todo ρ finito, y $x(\rho) \rightarrow 2$. Multiplicador implícito: $\rho h(x(\rho)) = -\frac{2\rho}{1 + \rho} \rightarrow -2 = \lambda^*$. Para la precisión pedida: $\frac{2}{1 + \rho} \leq 10^{-3} \iff 1 + \rho \geq 2000 \iff \rho \geq 1999$: tres dígitos de factibilidad cuestan una multa de orden 10^3 (y un número de condición $Q'' = 1 + \rho \approx 2 \cdot 10^3$), ilustrando por qué la penalización pura escala mal. $\square$

Ejercicio 16.14. Resuelve con barrera logarítmica el problema $\min_x (-x)$ s.a. $x \leq 1$. Escribe $B(x; \mu)$, halla la trayectoria central $x(\mu)$, el multiplicador implícito $\lambda(\mu)$, y comprueba el Teorema 16.6 calculando la brecha de dualidad.

Solución. Aquí $f(x) = -x$ y $g(x) = x - 1 \leq 0$; la solución es $x^* = 1$ y, de la KKT $-1 + \lambda = 0$, $\lambda^* = 1$. La barrera:

$$B(x; \mu) = -x - \mu \log(1 - x), \quad x < 1.$$

Es estrictamente convexa en $(-\infty, 1)$ pues $B'' = \mu/(1-x)^2 > 0$. Punto crítico:

$$B' = -1 + \frac{\mu}{1-x} = 0 \implies 1-x = \mu \implies x(\mu) = 1-\mu,$$

que tiende a $x^* = 1$ por el interior cuando $\mu \rightarrow 0^+$. Multiplicador implícito: $\lambda(\mu) = \frac{\mu}{-g(x(\mu))} = \frac{\mu}{1-x(\mu)} = \frac{\mu}{\mu} = 1 = \lambda^*$ para todo μ . Valores primal y dual: $f(x(\mu)) = \mu - 1$; la dual es $q(\lambda) = \min_x [-x + \lambda(x-1)]$, que vale $-\lambda$ si $\lambda = 1$ (si $\lambda \neq 1$ el ínfimo no está acotado y $q = -\infty$), luego $q(\lambda(\mu)) = -1$. Brecha: $f(x(\mu)) - q(\lambda(\mu)) = (\mu - 1) - (-1) = \mu = p\mu$ con $p = 1$ restricción, tal como afirma el teorema. $\square$

Ejercicio 16.15. Ejecuta tres iteraciones del método de multiplicadores, con $\rho = 1$ y $\lambda^0 = 0$, para

$$\min_x \frac{1}{2}(x-2)^2 \quad \text{s.a.} \quad x = 1.$$

Comprueba que λ^k converge al multiplicador verdadero y halla la razón exacta de convergencia del error $\lambda^k - \lambda^*$.

Solución. Solución exacta: $x^* = 1$; de $(x-2) + \lambda = 0$ en $x = 1$, $\lambda^* = 1$. El lagrangiano aumentado es $L_\rho = \frac{1}{2}(x-2)^2 + \lambda(x-1) + \frac{\rho}{2}(x-1)^2$, con condición de primer orden

$$(x-2) + \lambda + \rho(x-1) = 0 \implies x(\lambda) = \frac{2-\lambda+\rho}{1+\rho}, \quad h(x(\lambda)) = x(\lambda) - 1 = \frac{1-\lambda}{1+\rho}.$$

Con $\rho = 1$: $x(\lambda) = \frac{3-\lambda}{2}$ y $h = \frac{1-\lambda}{2}$. Iteración 0 ($\lambda^0 = 0$): $x^0 = \frac{3}{2}$, $h = \frac{1}{2}$, $\lambda^1 = 0 + 1 \cdot \frac{1}{2} = \frac{1}{2}$. Iteración 1: $x^1 = \frac{3-1/2}{2} = \frac{5}{4}$, $h = \frac{1}{4}$, $\lambda^2 = \frac{1}{2} + \frac{1}{4} = \frac{3}{4}$. Iteración 2: $x^2 = \frac{3-3/4}{2} = \frac{9}{8}$, $h = \frac{1}{8}$, $\lambda^3 = \frac{3}{4} + \frac{1}{8} = \frac{7}{8}$. Así $\lambda^k = 0, \frac{1}{2}, \frac{3}{4}, \frac{7}{8} \rightarrow 1 = \lambda^*$ y $x^k \rightarrow 1$. Para la razón, usa la recursión general:

$$\lambda^{k+1} = \lambda^k + \rho \cdot \frac{1-\lambda^k}{1+\rho} \implies \lambda^{k+1} - 1 = \lambda^k - 1 - \rho \frac{\lambda^k - 1}{1+\rho} = \frac{\lambda^k - 1}{1+\rho} :$$

convergencia lineal con razón exacta $\frac{1}{1+\rho}$ (aquí $\frac{1}{2}$, visible en la tabla: errores $1, \frac{1}{2}, \frac{1}{4}, \frac{1}{8}$). Con $\rho = 99$ la razón sería $\frac{1}{100}$. $\square$

Ejercicio 16.16. Deriva la fórmula de la Proposición 16.11 para una sola desigualdad $g(x) \leq 0$: introduce una holgura $s \geq 0$ con $g(x) + s = 0$, escribe el lagrangiano aumentado de la igualdad,

$$\ell(x, s) = f(x) + \lambda(g(x) + s) + \frac{\rho}{2}(g(x) + s)^2,$$

y minimiza en $s \geq 0$ en forma cerrada.

Solución. Fijemos x y escribamos $u = g(x)$. Como función de s , $\varphi(s) = \lambda(u+s) + \frac{\rho}{2}(u+s)^2$ es una parábola convexa en la variable $v = u+s$; completando la forma, $\varphi = \frac{\rho}{2}(v + \frac{\lambda}{\rho})^2 - \frac{\lambda^2}{2\rho}$. Su mínimo irrestricto está en $v = -\lambda/\rho$, es decir $s = -u - \lambda/\rho$. Dos casos según la restricción $s \geq 0$: (i) si $-u - \lambda/\rho \geq 0$, o sea $\lambda + \rho u \leq 0$, el mínimo irrestricto es admisible y $\varphi_{\min} = -\frac{\lambda^2}{2\rho}$; (ii) si $\lambda + \rho u > 0$, el mínimo con $s \geq 0$ se alcanza en el borde $s = 0$ (la parábola crece a la derecha de su vértice, que queda en $s < 0$), con valor $\varphi(0) = \lambda u + \frac{\rho}{2}u^2 = \frac{1}{2\rho}[(\lambda + \rho u)^2 - \lambda^2]$ (desarrolla

el cuadrado para comprobar la identidad). Ambos casos se escriben de una sola vez como

$$\min_{s \geq 0} \varphi(s) = \frac{1}{2\rho} \left[(\max\{0, \lambda + \rho g(x)\})^2 - \lambda^2 \right],$$

que sumada a $f(x)$ da la fórmula de la proposición. La actualización $\lambda^{k+1} = \lambda^k + \rho(g(x^k) + s^k) = \max\{0, \lambda^k + \rho g(x^k)\}$ sale de sustituir la holgura óptima s^k : si el caso es (ii), $s^k = 0$ y queda $\lambda^k + \rho g(x^k) > 0$; si es (i), $g(x^k) + s^k = -\lambda^k/\rho$ y queda exactamente 0. Es el ascenso dual proyectado sobre $\lambda \geq 0$. $\square$

Ejercicio 16.17. Resuelve el problema de Markowitz (16.2) con $\Sigma = I$ (activos incorrelacionados de varianza 1), $\mu = (1, 2, 3)$ y $r = 2$. Calcula A, B, C , los multiplicadores y el portafolio óptimo, e interpreta económicamente el valor que obtengas para el multiplicador del retorno.

Solución. Con $\Sigma^{-1} = I$: $A = \mu^\top \mu = 1 + 4 + 9 = 14$, $B = \mu^\top \mathbf{1} = 6$, $C = \mathbf{1}^\top \mathbf{1} = 3$. El sistema de la sección 16.5 es

$$14\lambda + 6\gamma = 2, \quad 6\lambda + 3\gamma = 1.$$

Multiplicando la segunda por 2: $12\lambda + 6\gamma = 2$; restando de la primera: $2\lambda = 0$, luego $\lambda = 0$ y, de la segunda, $\gamma = \frac{1}{3}$. El portafolio:

$$x^* = \lambda\mu + \gamma\mathbf{1} = \frac{1}{3}\mathbf{1} = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right),$$

con retorno $\mu^\top x^* = \frac{1+2+3}{3} = 2 = r$ (factible) y varianza $\|x^*\|^2 = \frac{1}{3}$. Interpretación: $\lambda = 0$ dice que la restricción de retorno tiene precio sombra nulo, y no por accidente: el portafolio de *mínima varianza global* (ignorando el retorno objetivo) es aquí el equiponderado $\frac{1}{3}\mathbf{1}$, cuyo retorno ya es exactamente 2. La restricción $\mu^\top x = r$ se cumple sin “costar” nada: $V'(r) = \lambda = 0$, el punto donde la frontera de media-varianza tiene pendiente nula (su vértice). Si el objetivo fuera $r = 2.5$, el mismo sistema daría $\lambda = \frac{1}{4} > 0$ y $\gamma = -\frac{1}{6}$: exigir retorno por encima del vértice sí encarece la varianza, y el multiplicador vuelve a medir cuánto. (Comprobación rápida del caso $r = 2.5$: $14\lambda + 6\gamma = 2.5$ y $6\lambda + 3\gamma = 1$ dan $2\lambda = 0.5$, $\lambda = \frac{1}{4}$, $\gamma = \frac{1-6/4}{3} = -\frac{1}{6}$, y $x^* = \frac{1}{4}\mu - \frac{1}{6}\mathbf{1} = \left(\frac{1}{12}, \frac{1}{3}, \frac{7}{12}\right)$, que carga más el activo de mayor retorno.) $\square$

Apéndice A

Guía de estudio, examen y glosario

[P2]

Repaso final. Reúne las definiciones exactas, los teoremas con sus hipótesis, las técnicas recurrentes y el plan de estudio para rendir el examen.

Este apéndice no introduce matemática nueva: organiza todo lo anterior para *rendir*. Contiene el mapa de dependencias del curso, un plan de estudio semana a semana, la “chuleta legal” de teoremas con sus hipótesis exactas, el catálogo de errores clásicos de examen, guías de redacción para demostraciones, trabajos prácticos y la exposición final, el puente detallado hacia Microeconomía y un glosario español–inglés para leer la bibliografía ([2], [6], [9]) sin fricción.

A.1. Mapa del curso y dependencias [P2]

A.1.1. El grafo de dependencias

El cuaderno no es una lista lineal: es un grafo. Antes de estudiar un capítulo conviene saber qué debe estar firme. Las dependencias esenciales son:

- **Cap. 1 (Preliminares)** → todo. Topología (compacidad, clausura, interior), Weierstrass, gradiente y Hessiana son prerequisite universal.
- **Cap. 2 (Conjuntos convexos)** → 3, 4, 5, 8. La definición de conjunto convexo y sus operaciones estables es la base geométrica del curso.
- **Cap. 3 (Conos y cápsulas)** → 4, 9, 13. El lema de Farkas vive aquí en versión cónica y reaparece en la demostración de KKT.
- **Cap. 4 (Separación)** → 7, 10, 12, 13. Es el teorema madre del análisis convexo: soporte, subgradiientes, dualidad y Hahn–Banach finito-dimensional son corolarios suyos.
- **Cap. 5 (Funciones cóncavas/convexas)** → 6, 7, 8, 9, 15. Sin las caracterizaciones de primer y segundo orden no hay condiciones de optimalidad.
- **Cap. 6 (Cuasiconcavidad)** → 9 (suficiencia con pseudoconvexidad) y, sobre todo, a la teoría del consumidor de Microeconomía.

- **Cap. 7 (Subdiferencial)** → 8, 12, 15. Generaliza el gradiente; la regla de Fermat $0 \in \partial f(x^*)$ unifica todo lo no diferenciable.
- **Cap. 8 (Optimalidad y proyección)** → 9, 14, 15. La proyección sobre un convexo cerrado es además la herramienta técnica de la separación estricta.
- **Cap. 9 (KKT)** → 10, 11, 14, 16. El corazón operativo del curso y de toda la microeconomía aplicada.
- **Cap. 10 (Punto silla y dualidad)** → 11, 12, 13, 14, 16. Da sentido a los multiplicadores como precios sombra.
- **Cap. 11 (Envolvente)** → estática comparativa, lema de Shephard, identidad de Roy, Milgrom–Segal [11] en subastas (diseño de mecanismos, [9] cap. 23).
- **Cap. 12 (Fenchel)** → 13, 16. La conjugada es la versión funcional de la dualidad y el lenguaje de las funciones de costo y beneficio.
- **Caps. 13, 14, 15, 16** son aplicaciones/algoritmos: consumen todo lo anterior y son la cantera natural de temas para la exposición final.

A.1.2. Las tres columnas vertebrales

Resumen del capítulo

El curso se sostiene sobre tres cadenas lógicas que hay que poder recitar:

1. **Columna geométrica:** separación (cap. 4) $\Rightarrow$ hiperplano soporte $\Rightarrow$ existencia de subgradientes (cap. 7) $\Rightarrow$ dualidad lagrangiana (cap. 10) $\Rightarrow$ dualidad de Fenchel (cap. 12). Todo teorema de dualidad es, en el fondo, un hiperplano bien colocado.
2. **Columna analítica:** convexidad de funciones (cap. 5) $\Rightarrow$ condiciones de optimalidad (cap. 8) $\Rightarrow$ KKT (cap. 9) $\Rightarrow$ teorema de la envolvente (cap. 11). Es la cadena que convierte un problema económico en un sistema de ecuaciones y luego en estática comparativa.
3. **Columna económica:** las dos anteriores se encuentran en la economía. La separación demuestra el segundo teorema del bienestar; KKT resuelve al consumidor, a la firma y al principal; la envolvente produce Shephard, Roy, Hotelling y la equivalencia de ingresos; la dualidad convierte multiplicadores en precios. El hilo conductor: *todo precio de la microeconomía es un hiperplano separador o un multiplicador de Lagrange, y casi siempre ambas cosas a la vez.*

A.2. Plan de estudio semanal [P2]

A.2.1. Semana a semana (S1–S15)

El plan sigue el cronograma oficial. “Rehacer” significa resolver el ejercicio de nuevo en blanco, sin mirar la solución, y comparar después.

S1 (espacios y conjuntos convexos).

Leer caps. 1–2. Bibliografía: [1] caps. 1–2, [3] cap. 1. Rehacer: pruebas de convexidad de intersecciones, sumas de Minkowski y conjuntos presupuestarios.

S2 (conos y cápsulas).

Leer cap. 3. Bibliografía: [1] cap. 2, [6] cap. 2. Rehacer: Carathéodory con un ejemplo numérico en $\mathbb{R}^2$ y cálculo de conos polares de ortantes.

S3 (separación).

Leer cap. 4 *dos veces*: es P1. Bibliografía: [1] cap. 3, [2] secc. 2.5. Rehacer: separación estricta vía proyección, contraejemplo sin compacidad, hiperplano soporte de un convexo con frontera suave.

S4 (funciones cóncavas y cuasicóncavas).

Leer caps. 5–6. Bibliografía: [2] cap. 3, [4] sobre concavidad generalizada. Rehacer: verificación de convexidad por Hessiana, Cobb–Douglas cuasicóncava vía Hessiana orlada, jerarquía cóncava–pseudo–cuasi con contraejemplos.

S5 (subdiferencial).

Leer cap. 7. Bibliografía: [1] cap. 4, [6] cap. 2. Rehacer: $\partial|x|$, subdiferencial de un máximo de funciones afines, regla de Fermat generalizada.

S6 (optimalidad y proyección).

Leer cap. 8. Bibliografía: [3] caps. 2–3, [7] cap. 1. Rehacer: caracterización variacional de la proyección y unicidad de minimizadores con convexidad estricta.

S7 (KKT).

Leer cap. 9 y resolver *todos* sus ejercicios. Bibliografía: [5] cap. 12, [2] cap. 5, [10] apéndice A2. Rehacer: consumidor con solución de esquina, problema con CQ que falla, verificación completa de un punto KKT.

S8 (punto silla y dualidad).

Leer cap. 10. Bibliografía: [2] cap. 5, [6] cap. 4. Rehacer: construcción del dual de un QP, verificación de Slater, brecha de dualidad en un problema no convexo. **Arranca aquí el plan pre-parcial de abajo.**

S9 (Fenchel).

Leer cap. 12. Bibliografía: [1] cap. 5, [6] secc. 2.6. Rehacer: conjugadas de e^x , $\frac{1}{2}\|x\|^2$, indicatrices; desigualdad de Fenchel–Young con caso de igualdad.

S10 (programación lineal).

Leer cap. 13. Bibliografía: [3] cap. 4, [5] cap. 13. Rehacer: dual de un LP en forma estándar y verificación por holgura complementaria.

S11 (SVM).

Leer cap. 14. Bibliografía: [2] secc. 8.6, [8]. Rehacer: derivación del dual del SVM de margen duro e identificación de vectores soporte.

S12–S13 (métodos de primer orden).

Leer cap. 15. Bibliografía: [8] caps. 3–4, [7] cap. 2. Rehacer: tasa $O(1/k)$ del gradiente para

L -suaves, elección de paso $1/L$, gradiente proyectado.

S14 (penalización y lagrangiano aumentado).

Leer cap. 16. Bibliografía: [5] cap. 17, [8]. Rehacer: penalización cuadrática vs. lagrangiano aumentado en un problema con una igualdad.

S15 (aplicaciones).

Repaso transversal y ensayo general de la exposición final (ver secc. A.7); dejar lista la implementación computacional.

A.2.2. Plan intensivo pre-parcial (el EP cae hacia S8–S9)

El examen parcial vale 30 % y cubre, con altísima probabilidad, S1–S8. La prioridad absoluta es P1: separación, funciones convexas, cuasiconcavidad, KKT y dualidad.

Estrategia de examen

Plan de 7 días antes del parcial (unas 3 horas diarias):

1. **Día 1 (geometría).** Releer cap. 4: enunciados exactos de las tres versiones de separación y del teorema de soporte, con sus contraejemplos. Escribir de memoria la demostración de separación estricta vía proyección.
2. **Día 2 (funciones).** Cap. 5: caracterizaciones de primer y segundo orden, operaciones que preservan convexidad, Jensen. Rehacer 5 verificaciones de convexidad por Hessiana.
3. **Día 3 (cuasiconcavidad).** Cap. 6: jerarquía completa con contraejemplos memorizados y Hessiana orlada con sus signos. Rehacer Cobb–Douglas y CES.
4. **Día 4 (KKT).** Cap. 9: escribir el sistema KKT completo de memoria (con convención de signos), enumerar las CQ y el teorema de suficiencia convexa. Resolver 3 problemas con casos de esquina, discutiendo todos los casos de holgura complementaria.
5. **Día 5 (dualidad).** Cap. 10: dual lagrangiano, dualidad débil (demostración de 4 líneas, aprenderla), Slater, punto silla. Construir el dual de dos problemas distintos.
6. **Día 6 (simulacro).** Examen cronometrado de 3 horas con ejercicios de los caps. 4, 5, 6, 9, 10 no rehechos antes.
7. **Día 7 (repaso ligero).** Solo la chuleta de la secc. A.3 y los errores de la secc. A.4. Dormir bien: un enunciado con hipótesis correctas vale más que una hora extra de traspase.

A.3. Los teoremas estrella con hipótesis exactas [P2]

Formato de cada entrada: **Hipótesis** (todas, sin abreviar), **Conclusión** (una línea) y **Error típico** al citarlo mal. En un examen, citar un teorema con una hipótesis de menos es citar un enunciado *falso*.

A.3.1. Existencia y proyección

Weierstrass (cap. 1).

Hipótesis: $f: K \rightarrow \mathbb{R}$ continua, $K \subseteq \mathbb{R}^n$ no vacío y compacto (cerrado y acotado). **Conclusión:** f alcanza máximo y mínimo globales en K . **Error típico:** aplicarlo con K cerrado pero no acotado (el conjunto presupuestario con un precio nulo) o con f solo semicontinua sin decir en qué sentido (para mínimos basta s.c.i.).

Teorema de la proyección (cap. 8).

Hipótesis: $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo; $x \in \mathbb{R}^n$. **Conclusión:** existe un único $\text{proy}_C(x)$, caracterizado por $\langle x - \text{proy}_C(x), y - \text{proy}_C(x) \rangle \leq 0$ para todo $y \in C$. **Error típico:** olvidar que la cerradura da la existencia y la convexidad la unicidad y la desigualdad variacional; sin convexidad la proyección puede ser multivaluada.

A.3.2. Separación, soporte y Carathéodory

Separación punto–conjunto, estricta (cap. 4).

Hipótesis: $C \subseteq \mathbb{R}^n$ no vacío, cerrado y convexo; $x_0 \notin C$. **Conclusión:** existen $p \neq 0$ y $\alpha \in \mathbb{R}$ con $\langle p, x_0 \rangle > \alpha > \langle p, y \rangle$ para todo $y \in C$. **Error típico:** omitir “cerrado”: un punto en la frontera de un convexo abierto no se separa estrictamente.

Separación de dos convexos (Minkowski, cap. 4).

Hipótesis: $C, D \subseteq \mathbb{R}^n$ no vacíos, convexos y disjuntos ($C \cap D = \emptyset$). **Conclusión:** existe $p \neq 0$ con $\sup_{x \in C} \langle p, x \rangle \leq \inf_{y \in D} \langle p, y \rangle$ (separación no necesariamente estricta). **Error típico:** prometer desigualdades estrictas; en dimensión finita disjunción + convexidad solo garantizan separación débil.

Separación estricta de conjuntos (cap. 4).

Hipótesis: C, D no vacíos, convexos, disjuntos, C cerrado y D compacto. **Conclusión:** existen $p \neq 0$, α con $\langle p, x \rangle < \alpha < \langle p, y \rangle$ para todo $x \in C$, $y \in D$. **Error típico:** pedir solo “ambos cerrados”: el eje x y el epígrafo de $1/x$ en $x > 0$ son cerrados, convexos, disjuntos y no se separan estrictamente.

Separación propia (cap. 4).

Hipótesis: C, D convexos no vacíos con $\text{ri}(C) \cap \text{ri}(D) = \emptyset$. **Conclusión:** existe un hiperplano que separa propiamente (no contiene a ambos conjuntos a la vez); la condición es además necesaria. **Error típico:** usar interiores ordinarios: si C tiene interior vacío (un segmento en $\mathbb{R}^2$) el criterio correcto es el interior *relativo*.

Hiperplano soporte (cap. 4).

Hipótesis: $C \subseteq \mathbb{R}^n$ convexo no vacío, $x_0 \in \text{fr}(C)$ (frontera). **Conclusión:** existe $p \neq 0$ con $\langle p, x \rangle \leq \langle p, x_0 \rangle$ para todo $x \in C$: un hiperplano que pasa por x_0 y deja a C en un semiespacio. **Error típico:** invocarlo en un punto interior (no existe) o en conjuntos no convexos (falla: frontera de una corona circular).

Carathéodory (cap. 3).

Hipótesis: $S \subseteq \mathbb{R}^n$, $x \in \text{conv}(S)$. **Conclusión:** x es combinación convexa de a lo sumo $n+1$

puntos de S (para $\text{cono}(S)$: a lo sumo n). **Error típico:** decir “ n puntos” para la cápsula convexa; el triángulo en $\mathbb{R}^2$ necesita $3 = n + 1$.

A.3.3. Convexidad de funciones y jerarquía generalizada

Caracterización de primer orden (cap. 5).

Hipótesis: f diferenciable en un abierto que contiene al convexo C . **Conclusión:** f es convexa en C si y solo si $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ para todos $x, y \in C$ (la gráfica queda sobre cada tangente); estricta con $>$ para $y \neq x$. **Error típico:** olvidar que C debe ser convexo: la condición punto a punto no encadena si el segmento sale del dominio.

Caracterización de segundo orden (cap. 5).

Hipótesis: f de clase C^2 en un abierto convexo C . **Conclusión:** f convexa $\iff \nabla^2 f(x)$ semidefinida positiva para todo $x \in C$; si $\nabla^2 f(x)$ es definida positiva en todo C , f es estrictamente convexa. **Error típico:** creer el recíproco de la parte estricta: $f(x) = x^4$ es estrictamente convexa con $f''(0) = 0$.

Jerarquía cóncava–pseudo–cuasi (cap. 6).

Hipótesis: f definida en un convexo C ; para pseudoconcavidad, f diferenciable. **Conclusión:** cóncava $\Rightarrow$ pseudocóncava (si diferenciable) $\Rightarrow$ cuasicóncava; y estrictamente cóncava $\Rightarrow$ estrictamente cuasicóncava. Ninguna implicación se invierte: x^3 es cuasicóncava y no cóncava en $\mathbb{R}$. **Error típico:** usar la cadena al revés (“cuasicóncava, luego cóncava”) o aplicar pseudoconcavidad sin diferenciabilidad.

Cuasiconcavidad y conjuntos de nivel (cap. 6).

Hipótesis: $f: C \rightarrow \mathbb{R}$ con C convexo. **Conclusión:** f es cuasicóncava $\iff$ todo conjunto de contorno superior $\{x \in C : f(x) \geq \alpha\}$ es convexo. **Error típico:** verificar la convexidad de los conjuntos de nivel *inferiores* (eso caracteriza cuasiconvexidad) o de las curvas de nivel (no basta).

A.3.4. Condiciones de optimalidad

Fermat generalizada (caps. 7, 8).

Hipótesis: $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ convexa y propia. **Conclusión:** x^* es mínimo *global* de f si y solo si $0 \in \partial f(x^*)$; en el caso diferenciable, $\nabla f(x^*) = 0$ es necesaria en puntos interiores y, con convexidad, también suficiente. **Error típico:** usar $\nabla f(x^*) = 0$ como suficiente sin convexidad (puntos silla, $f(x) = x^3$) o buscar *máximos* de una convexa con esta regla (los máximos de una convexa sobre un compacto convexo están en puntos extremos).

Multiplicadores de Lagrange, solo igualdades (cap. 9).

Hipótesis: x^* mínimo local de f sujeto a $h_j(x) = 0$, $j = 1, \dots, m$; f, h_j de clase C^1 ; los gradientes $\nabla h_1(x^*), \dots, \nabla h_m(x^*)$ linealmente independientes. **Conclusión:** existe $\mu^* \in \mathbb{R}^m$ (sin signo) con $\nabla f(x^*) + \sum_j \mu_j^* \nabla h_j(x^*) = 0$. **Error típico:** olvidar la independencia lineal (mín x s.a. $x^2 = 0$ no tiene multiplicador) o imponer $\mu^* \geq 0$: en igualdades el multiplicador no tiene signo.

KKT, necesidad (cap. 9).

Hipótesis: x^* mínimo local de f s.a. $g_i(x) \leq 0$, $h_j(x) = 0$, todo C^1 , y una cualificación de restricciones (CQ) en x^* : LICQ (gradientes de restricciones activas linealmente independientes), o Mangasarian–Fromovitz, o restricciones afines, o Slater en problemas convexos.

Conclusión: existen $\lambda^* \geq 0$, μ^* con estacionariedad $\nabla f + \sum_i \lambda_i^* \nabla g_i + \sum_j \mu_j^* \nabla h_j = 0$ en x^* , factibilidad y holgura complementaria $\lambda_i^* g_i(x^*) = 0$. **Error típico:** “el óptimo cumple KKT” sin CQ: falso en general (ejemplo clásico mín x_1 s.a. $x_2 \leq x_1^3$, $x_2 \geq 0$).

KKT, suficiencia (cap. 9).

Hipótesis: problema *convexo* (f y las g_i convexas y diferenciables, las h_j afines) y (x^*, λ^*, μ^*) satisface las condiciones KKT. **Conclusión:** x^* es mínimo *global*. (Versión generalizada: basta f pseudoconvexa y g_i cuasiconvexas.) **Error típico:** usar KKT como certificado de óptimo en problemas no convexos: sin convexidad un punto KKT puede ser silla o incluso máximo.

A.3.5. Dualidad, envolvente y Fenchel**Punto silla (cap. 10).**

Hipótesis: (x^*, λ^*) con $\lambda^* \geq 0$ es punto silla del lagrangiano: $L(x^*, \lambda) \leq L(x^*, \lambda^*) \leq L(x, \lambda^*)$ para todo x y todo $\lambda \geq 0$. Sin supuestos de convexidad ni diferenciabilidad. **Conclusión:** x^* es óptimo global del primal, λ^* del dual, y no hay brecha de dualidad. **Error típico:** creer el recíproco sin hipótesis: la *existencia* de punto silla sí exige convexidad + Slater; un óptimo de problema no convexo puede no admitir punto silla.

Dualidad débil (cap. 10).

Hipótesis: ninguna más allá de la definición del dual (vale para cualquier problema, convexo o no). **Conclusión:** $d^* \leq p^*$: todo valor dual factible acota por debajo al primal (convencción de minimización). **Error típico:** invertir la desigualdad al trabajar con un primal de *maximización* (ahí el dual acota por arriba).

Dualidad fuerte (cap. 10).

Hipótesis: problema convexo (f, g_i convexas, h_j afines) + condición de Slater: existe $\hat{x}$ factible con $g_i(\hat{x}) < 0$ para toda restricción no afín. **Conclusión:** $d^* = p^*$ y el dual *alcanza* su óptimo (existe λ^* ; el primal puede no alcanzarlo). **Error típico:** invocarla sin Slater o en problemas no convexos; también olvidar que Slater se relaja a factibilidad simple para restricciones afines (por eso LP no necesita Slater).

Envolvente sin restricciones (cap. 11).

Hipótesis: $V(\theta) = \max_x f(x, \theta)$ con máximo alcanzado en $x^*(\theta)$ diferenciable o, más débilmente, con las condiciones de Milgrom–Segal de abajo. **Conclusión:** $V'(\theta) = \frac{\partial f}{\partial \theta}(x^*(\theta), \theta)$: solo el efecto *directo*; el efecto vía x^* se anula por optimalidad. **Error típico:** derivar también $x^*(\theta)$ (doble conteo) o aplicar la fórmula donde el máximo no se alcanza.

Envolvente con restricciones (cap. 11).

Hipótesis: $V(\theta) = \max_x f(x, \theta)$ s.a. $g(x, \theta) \leq 0$, con soluciones y multiplicadores bien definidos y condiciones de regularidad (p.ej. LICQ y unicidad local). **Conclusión:** $V'(\theta) = \frac{\partial L}{\partial \theta}(x^*(\theta), \lambda^*(\theta), \theta)$; en particular λ_i^* es el precio sombra de relajar g_i . **Error típico:** derivar

f en vez de L cuando θ aparece en las restricciones (así se pierde el precio sombra: es el error que rompe el lema de Shephard).

Milgrom–Segal (cap. 11, [11]).

Hipótesis: X conjunto de elección *arbitrario* (sin convexidad, sin topología), $f(x, \cdot)$ diferenciable en $t \in [0, 1]$ para cada x , familia $\{f_t(x, \cdot)\}$ dominada por una función integrable, y el máximo se alcanza en cada t . **Conclusión:** V es absolutamente continua y $V(t) = V(0) + \int_0^t f_t(x^*(s), s) ds$ para cualquier selección $x^*(s)$ de maximizadores. **Error típico:** exigir unicidad del maximizador, interioridad o concavidad: la gracia de Milgrom–Segal es que *no* las pide (por eso sirve en subastas con estrategias discontinuas).

Fenchel–Young (cap. 12).

Hipótesis: f propia; $f^*(p) = \sup_x \{\langle p, x \rangle - f(x)\}$ su conjugada. **Conclusión:** $f(x) + f^*(p) \geq \langle p, x \rangle$ para todos x, p , con igualdad si y solo si $p \in \partial f(x)$. **Error típico:** enunciar la igualdad sin la condición de subgradiente, u olvidar que para el “si y solo si” con $x \in \partial f^*(p)$ hace falta f convexa y cerrada.

Fenchel–Moreau (biconjugación, cap. 12).

Hipótesis: $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propia, convexa y cerrada (semicontinua inferiormente). **Conclusión:** $f^{**} = f$. **Error típico:** aplicar $f^{**} = f$ a funciones no convexas: en general f^{**} es la envolvente convexa cerrada de f (esto, bien citado, es un resultado útil, no un error).

Dualidad LP y holgura complementaria (cap. 13).

Hipótesis: par primal–dual de programas lineales; para dualidad fuerte basta que *uno* de los dos sea factible y acotado. **Conclusión:** ambos tienen óptimo y $p^* = d^*$; además x factible primal e y factible dual son óptimos si y solo si cumplen holgura complementaria ($x_j > 0 \Rightarrow$ restricción dual j activa; holgura primal $i > 0 \Rightarrow y_i = 0$). **Error típico:** olvidar el caso patológico (primal infactible y dual infactible a la vez es posible) o pedir Slater: en LP sobra.

A.4. Errores clásicos de examen [P2]

Cuidado (error común)

Cada punto de esta lista ha costado nota a generaciones de estudiantes. Repasarla la víspera del examen rinde más que cualquier otro repaso de igual duración.

1. **Confundir necesario con suficiente.** $\nabla f(x^*) = 0$ es *necesaria* en un óptimo interior; solo es *suficiente* con convexidad (o pseudoconvexidad). Análogamente, KKT es necesaria (con CQ) y suficiente (con convexidad): son dos teoremas distintos con hipótesis distintas, y hay que decir cuál se está usando.
2. **Olvidar la cualificación de restricciones.** Escribir “por KKT existen multiplicadores” sin verificar LICQ, Mangasarian–Fromovitz, afinidad o Slater. En el examen: una línea del tipo “las restricciones son afines, luego la CQ se cumple” vale puntos; su ausencia los quita.
3. **Hessiana PSD para cuasiconcavidad.** La cuasiconcavidad *no* se verifica con la definitud

de la Hessiana: el criterio diferencial correcto usa la *Hessiana orlada* con la alternancia de signos de sus menores principales orlados (cap. 6). Cobb–Douglas con rendimientos crecientes es el ejemplo canónico: Hessiana no semidefinida negativa y aun así cuasicóncava.

4. **Separación estricta sin compacidad.** “Dos convexos cerrados disjuntos se separan estrictamente” es falso: hace falta que uno sea compacto. Contraejemplo de memoria: $C = \{(x, y) : y \leq 0\}$ y $D = \{(x, y) : x > 0, y \geq 1/x\}$.
5. **Sumar o transformar cuasicóncavas.** La suma de cuasicóncavas no es cuasicóncava en general (sí lo es la suma de cóncavas). En cambio la cuasiconcavidad sobrevive a transformaciones monótonas crecientes y la concavidad no: $e^{u(x)}$ conserva la cuasiconcavidad de u , no su concavidad. Confundir qué propiedad es ordinal y cuál cardinal es error grave en teoría del consumidor.
6. **Ignorar los casos de esquina.** En KKT hay que discutir *todos* los patrones de holgura complementaria ($\lambda_i = 0$ vs. g_i activa), no solo el caso interior. El consumidor con utilidad cuasilineal y renta baja consume cero de un bien: si no se examina esa rama, la solución entregada es incompleta.
7. **Signos de multiplicadores y convención min/max.** Con mín f s.a. $g \leq 0$ y lagrangiano $L = f + \lambda g$, se tiene $\lambda \geq 0$; con máx f s.a. $g \leq 0$ y $L = f - \lambda g$, también $\lambda \geq 0$. Mezclar convenciones a mitad de un problema produce multiplicadores negativos “imposibles”. Regla práctica: escribir la convención elegida en la primera línea y no cambiarla.
8. **Dualidad fuerte gratis.** Escribir $p^* = d^*$ sin verificar convexidad + Slater (o linealidad). En problemas no convexos la brecha de dualidad puede ser estrictamente positiva, y la dualidad débil $d^* \leq p^*$ es todo lo que se tiene.
9. **Máximos de funciones convexas.** Buscar el máximo de una función convexa igualando el gradiente a cero. El máximo de una convexa sobre un politopo se alcanza en un vértice: es un problema combinatorio, no de primer orden.
10. **Aplicar Weierstrass sin compacidad.** “El problema tiene solución por Weierstrass” exige exhibir compacidad (o coercividad de f , que la reemplaza para mínimos). Con precios nulos o restricciones no acotadas, primero se argumenta la acotación efectiva del conjunto relevante.

A.5. Cómo escribir demostraciones y soluciones de máxima nota [P2]

A.5.1. Estructura de una demostración

Estrategia de examen

Esqueleto en tres capas que el corrector agradece:

1. **Hipótesis y objetivo.** Primera línea: “Sean C convexo cerrado no vacío y $x_0 \notin C$. Queremos probar que existe $p \neq 0$ tal que...”. Reescribir el objetivo en símbolos

elimina la mitad de los errores.

2. **Afirmaciones encadenadas.** Cada paso es una afirmación verificable con su justificación entre paréntesis: definición usada, teorema citado (¡con sus hipótesis verificadas!) o cálculo. Si un paso requiere un teorema, comprobar *por escrito* que sus hipótesis se cumplen antes de usarlo.
3. **Cierre.** Última línea explícita: “lo que prueba la afirmación”; en desigualdades, indicar dónde se usó cada hipótesis (si una hipótesis no se usó nunca, sospechar un error).

A.5.2. Frases estándar del español matemático

Fórmulas de redacción que conviene tener automatizadas: “Sea $x \in C$ arbitrario”; “sin pérdida de generalidad podemos suponer”; “supongamos, por reducción al absurdo, que”; “por la convexidad de f aplicada a x, y con $\lambda \in [0, 1]$ ”; “tomando el límite cuando $k \rightarrow \infty$ y usando la continuidad de f ”; “por el teorema de separación (cap. 4), cuyas hipótesis se verifican pues C es cerrado, convexo y $x_0 \notin C$ ”; “la desigualdad es estricta porque”; “recíprocamente”; “lo que contradice la elección de x_0 y concluye la prueba”. Evitar: “es obvio que”, “claramente” (si lo fuera, cuesta una línea probarlo) y los cuantificadores implícitos (“ $f(x) \leq f(y)$ ” sin decir para qué x, y).

A.5.3. Verificar un KKT antes de entregarlo

Resumen del capítulo

Lista de control de 6 puntos para cualquier solución por KKT:

1. **Factibilidad primal:** $g_i(x^*) \leq 0$ y $h_j(x^*) = 0$, verificadas numéricamente, no “por construcción”.
2. **Signo dual:** $\lambda_i^* \geq 0$ para todas las desigualdades (los μ_j^* de igualdades son libres).
3. **Holgura complementaria:** $\lambda_i^* g_i(x^*) = 0$ para cada i ; listar qué restricciones están activas.
4. **Estacionariedad:** sustituir los números en $\nabla f + \sum \lambda_i \nabla g_i + \sum \mu_j \nabla h_j = 0$ y comprobar componente a componente.
5. **CQ:** una línea justificando la cualificación usada.
6. **Optimalidad global:** una línea invocando la suficiencia (convexidad del problema) o, si no la hay, comparar valores entre los candidatos KKT.

Si los seis puntos están escritos, la solución es inatacable.

A.5.4. Gestión del tiempo en el examen

Con un examen de 3 horas y 4–5 preguntas: (i) primeros 10 minutos, leer todo y clasificar cada pregunta como *directa* (definición + teorema conocido), *computacional* (KKT, duales) o *creativa*

(demostración nueva); (ii) resolver primero las directas y computacionales (aseguran la base de la nota); (iii) presupuestar minutos por puntos (pregunta de 20 % $\approx$ 35 minutos) y *abandonar temporalmente* al agotar el presupuesto; (iv) en las creativas, si no sale la prueba completa, escribir el enunciado preciso del teorema relevante, la verificación de sus hipótesis y el plan de la demostración: eso captura puntos parciales; (v) reservar 10 minutos finales para releer signos de multiplicadores y cuantificadores.

A.6. Estrategia para los cuatro trabajos prácticos (30 %) [P2]

Los TP son escritos y se promedian: consistencia vale más que un TP brillante y tres flojos. Reglas de oro:

- **Rigor de redacción.** Cada TP se redacta como un pequeño artículo: enunciado, notación, resolución con la estructura de la secc. A.5, conclusión. Todo teorema citado va con nombre, referencia del cuaderno o de la bibliografía y verificación explícita de hipótesis: en un curso de análisis convexo, la precisión en las hipótesis es exactamente lo que se evalúa.
- **Verificación numérica en Python.** Siempre que el problema lo permita, acompañar la solución analítica con una comprobación numérica (`numpy + scipy.optimize` o `cvxpy`): resolver el problema, comparar el óptimo con el punto KKT hallado a mano y reportar los multiplicadores del solver frente a los analíticos. Un párrafo de dos líneas (“el solver confirma $x^* = (2, 1)$ y $\lambda^* = 0.5$ con error 10^{-8} ”) distingue un TP excelente. Si no coinciden, hay un error: encontrarlo antes que el corrector.
- **Contraejemplos dibujados.** Cuando el TP pida discutir hipótesis, incluir el contraejemplo con una figura (aunque sea esquemática): separación sin cerradura, cuasicóncavas que no suman, CQ que falla.
- **Ortografía matemática.** Ecuaciones puntuadas como parte de la oración, símbolos definidos antes de usarse, y ningún resultado numérico sin unidades ni contexto. Releer el TP entero un día después de terminarlo, antes de entregarlo.

A.7. Estrategia para la exposición final (40 %: la nota más pesada) [P2]

A.7.1. Criterios probables del jurado

Los criterios previsibles de cualquier jurado son: (i) *corrección matemática*: enunciados con hipótesis completas y al menos una demostración no trivial hecha con soltura; (ii) *dominio*: responder preguntas del tipo “¿y si quito esta hipótesis?” (preparar de antemano los contraejemplos); (iii) *conexión con el curso*: que el tema use visiblemente separación, dualidad o KKT, no solo los mencione; (iv) *valor añadido*: una implementación computacional o una aplicación económica que no esté en las notas de clase; (v) *claridad*: una charla que se entiende de principio a fin vale más que una enciclopedia atropellada.

A.7.2. Seis propuestas de tema desarrolladas

1. **SVM primal–dual con datos económicos.** *Contenido:* margen duro y blando, derivación completa del dual, vectores soporte como restricciones activas, holgura complementaria como clasificador. *Capítulos:* 9, 10, 14. *Implementación:* clasificar hogares (p.ej. morosidad crediticia o pobreza con datos tipo ENAHO) resolviendo primal y dual en `cvxpy` y mostrando que los multiplicadores no nulos son exactamente los vectores soporte. *Por qué luce:* es el ejemplo perfecto de toda la maquinaria KKT–dualidad funcionando de punta a punta, con gráfico final impactante.
2. **El lagrangiano aumentado y ADMM como subastador walrasiano.** *Contenido:* descomposición dual, interpretación del precio como multiplicador que se ajusta por exceso de demanda (*tâtonnement* = ascenso dual), por qué la penalización cuadrática estabiliza. *Capítulos:* 10, 15, 16. *Implementación:* economía de intercambio con utilidades cóncavas resuelta por ADMM, más un portafolio de Markowitz resuelto por lagrangiano aumentado, graficando la convergencia de los “precios”. *Por qué luce:* traduce un algoritmo moderno a la metáfora económica más clásica; combina teoría y cómputo a partes iguales.
3. **Milgrom–Segal y equivalencia de ingresos en subastas.** *Contenido:* teorema de la envolvente clásico vs. [11], por qué los conjuntos de estrategias de una subasta no son convexos ni compactos, y cómo la fórmula integral da la utilidad de equilibrio del postor y el teorema de equivalencia de ingresos. *Capítulos:* 5, 11. *Implementación:* simular subastas de primer y segundo precio con valores uniformes y verificar numéricamente la igualdad de ingresos esperados. *Por qué luce:* conecta directamente con el diseño de mecanismos ([9] cap. 23) y muestra lectura de un artículo seminal.
4. **El segundo teorema del bienestar vía separación, y dónde falla.** *Contenido:* demostración del teorema con separación de convexos (el agregado de conjuntos preferidos vs. el conjunto de producción), papel exacto de cada hipótesis, y dos contraejemplos no convexos (preferencias con indivisibilidades; rendimientos crecientes) donde ningún precio sostiene el óptimo de Pareto. *Capítulos:* 2, 4, más [9] cap. 16. *Implementación:* caja de Edgeworth graficada con curvas de indiferencia no convexas mostrando el hiperplano que no existe. *Por qué luce:* es el puente entre el curso y la teoría del equilibrio general ([9] caps. 15–18), y discutir hipótesis es justo lo que el jurado premia.
5. **Dualidad de Fenchel y recuperación de tecnologías.** *Contenido:* la función de costo como conjugada (soporte) del conjunto de producción, lema de Shephard vía Fenchel–Young, teorema de dualidad costo–tecnología: de $c(w, y)$ se recupera la envolvente convexa cerrada de la tecnología (Fenchel–Moreau). *Capítulos:* 4, 11, 12. *Implementación:* partir de una tecnología no convexa, calcular numéricamente c y reconstruir c^* mostrando qué se pierde (exactamente la parte no convexa). *Por qué luce:* matemática elegante con lectura económica profunda: los datos de costos solo identifican la “convexificación” de la tecnología.
6. **Concavidad generalizada y teoría de la demanda.** *Contenido:* por qué la utilidad solo necesita ser cuasicóncava (ordinalidad), jerarquía cóncava–pseudo–cuasi, Hessiana orlada, condiciones bajo las cuales una cuasicóncava admite una transformación cóncava (concavi-

ficabilidad) y qué se sabe cuando no. *Capítulos*: 5, 6, 9, con [4] y la literatura especializada en concavidad generalizada. *Implementación*: mapa de curvas de indiferencia de una cuasicóncava no concavificable y verificación numérica de la Hessiana orlada. *Por qué luce*: es un área de investigación viva y de conexión directa con la teoría del consumidor; citar y entender sus resultados es apuesta de alto retorno (y alto riesgo: dominar los detalles antes de elegirlo).

A.7.3. Estructura de los 20 minutos

Estrategia de examen

Guion probado: **min 0–2**, el problema en una frase y por qué importa (motivación económica); **min 2–6**, herramientas del curso que se usarán, enunciadas con hipótesis exactas (una diapositiva por teorema); **min 6–13**, el resultado central con *una* demostración o derivación completa a paso firme (mejor una prueba entera que tres a medias); **min 13–17**, implementación computacional o aplicación con un gráfico protagonista; **min 17–19**, qué pasa si se quitan hipótesis (contraejemplo preparado); **min 19–20**, resumen en tres líneas. Ensayar dos veces con reloj; preparar dos diapositivas de apéndice para las preguntas previsibles del jurado.

A.8. Puente completo a Microeconomía [P2]

El curso de Microeconomía se apoya en este material parte por parte. Las tablas siguen la organización canónica de Mas-Colell, Whinston y Green [9], en cinco partes, y resumen qué repasar de este cuaderno para cada una.

Parte del curso de Microeconomía	Capítulos del cuaderno	Resultados específicos que usarás
Decisión individual (MWG 1–6: preferencia y elección, demanda y dualidad, producción, incertidumbre)	1, 5, 6, 9, 11, 12	Weierstrass (existencia de la demanda); cuasiconcavidad de la utilidad y demanda bien definida; KKT en el problema del consumidor y en el de minimización del gasto; <i>envolvente</i> como fuente de la identidad de Roy, el lema de Shephard y el lema de Hotelling; conjugada de Fenchel y la función de costo como soporte de la tecnología; concavidad de Bernoulli = aversión al riesgo y desigualdad de Jensen.
Teoría de juegos (MWG 7–9: Nash en puras y mixtas, juegos dinámicos, bayesianos y repetidos)	3, 10, 13	Símples de estrategias mixtas como cápsula convexa de las puras y teorema de Carathéodory; <i>punto silla</i> y <i>teorema minimax</i> en juegos de suma cero; par primal–dual de programación lineal asociado a un juego matricial y valor del juego = valor común de ambos programas; compacidad y convexidad del conjunto de estrategias como hipótesis de los teoremas de existencia.

Parte del curso de Microeconomía	Capítulos del cuaderno	Resultados específicos que usarás
Equilibrio de mercado y fallas de mercado (MWG 10–14: externalidades, poder de mercado, selección adversa y señalización, principal–agente)	5, 9, 10, 11, 13	Concavidad de Bernoulli = aversión al riesgo; problema del principal como programa con restricciones IC e IR: multiplicadores como precio de los incentivos; validez del enfoque de primer orden (concavidad del problema del agente); envolvente para la estática comparativa del contrato óptimo; KKT en el escrutinio (<i>screening</i>) y en la discriminación de precios; con tipos finitos y asignación fija, el problema en las transferencias es un programa lineal y la holgura complementaria dice qué restricciones de incentivos amarran (cap. 13); concavidad del excedente agregado.
Equilibrio general (MWG 15–18: Edgeworth, Pareto, bienestar, núcleo)	1, 2, 4, 6, 9, 13	Weierstrass (existencia de demanda); convexidad de preferencias y del conjunto de producción; <i>segundo teorema del bienestar por separación</i> ; hiperplano soporte = precios; cuasiconcavidad y demanda bien definida; KKT en la caracterización de óptimos de Pareto (maximizar utilidad de 1 sujeto a utilidades de los demás); análisis de actividades de Koopmans, donde los precios que valoran los recursos son las variables duales de un programa lineal (cap. 13).
Bienestar e incentivos (MWG 21–23: elección social, economía del bienestar, diseño de mecanismos e implementación)	9, 10, 11, 12, 13	<i>Milgrom–Segal</i> [11] para pagos de equilibrio y equivalencia de ingresos; monotonía + envolvente = caracterización de implementabilidad; principio de revelación y programas con continuo de restricciones IC (relajación lagrangiana); holgura complementaria para saber qué IC ligan (“adyacentes hacia abajo”); el problema de asignación entre compradores y objetos como programa lineal de transporte, cuyo dual entrega los precios que sostienen la asignación eficiente (cap. 13); punto silla en problemas del diseñador con res-

Intuición

Consejo de fin de semana: el fin de semana previo al inicio de cada parte nueva, repasar en este orden: (1) los capítulos de la tabla, releendo solo definiciones, teoremas y las cajas de resumen; (2) la entrada correspondiente de la chuleta (secc. A.3); (3) rehacer *un* ejercicio representativo (decisión individual: identidad de Roy y lema de Shephard por envolvente; teoría de juegos: valor de un juego matricial 2×2 por el par primal-dual; fallas de mercado: principal-agente con dos esfuerzos por KKT; equilibrio general: segundo teorema del bienestar en una Edgeworth 2×2 ; diseño de mecanismos: envolvente en la subasta de primer precio y qué restricciones IC ligan en un modelo de tres tipos). Dos horas bien elegidas el fin de semana evitan diez de confusión el lunes.

A.9. Glosario español–inglés [P2]

Toda la bibliografía central ([2], [6], [5], [8], [9], [10], [11]) está en inglés. Estas tablas, organizadas por temas, cubren el vocabulario del curso para leer sin fricción y para buscar literatura (usar el término inglés en los buscadores académicos).

Topología y preliminares (cap. 1)

Español	Inglés
conjunto abierto / cerrado	open / closed set
conjunto acotado	bounded set
conjunto compacto	compact set
clausura (cerradura)	closure
interior	interior
frontera	boundary
entorno (vecindad)	neighborhood
sucesión convergente	convergent sequence
punto de acumulación	limit point, accumulation point
función continua	continuous function
semicontinua inferiormente (s.c.i.)	lower semicontinuous (l.s.c.)
función coerciva	coercive function
producto interno	inner product
norma	norm
bola unitaria	unit ball

Conjuntos convexos y conos (caps. 2–4)

Español	Inglés
conjunto convexo	convex set
combinación convexa	convex combination
cápsula (envolvente) convexa	convex hull
cápsula afín	affine hull
interior relativo	relative interior
cono	cone
cápsula cónica	conic hull
cono polar / dual	polar / dual cone
cono normal	normal cone
cono tangente	tangent cone
cono de recesión	recession cone
semiespacio	halfspace
hiperplano	hyperplane
hiperplano soporte (de apoyo)	supporting hyperplane
hiperplano separador	separating hyperplane
separación estricta / propia	strict / proper separation
poliedro	polyhedron
politopo	polytope
punto extremo	extreme point
vértice	vertex
cara	face
simplex (simplejo)	simplex
suma de Minkowski	Minkowski sum

Funciones cóncavas, convexas y generalizadas (caps. 5–7)

Español	Inglés
función cóncava / convexa	concave / convex function
estrictamente convexa	strictly convex
fuertemente convexa	strongly convex
cuasicóncava / cuasiconvexa	quasiconcave / quasiconvex
pseudocóncava	pseudoconcave
concavificable	concavifiable
epígrafo	epigraph
hipógrafo	hypograph
dominio efectivo	effective domain
función propia	proper function
función cerrada	closed function
conjunto de nivel	level set
conjunto de contorno superior	upper contour (level) set
conjunto de subnivel	sublevel set
función indicatriz	indicator function
función soporte	support function
gradiente	gradient
Hessiana	Hessian (matrix)
Hessiana orlada	bordered Hessian
(semi)definida positiva / negativa	positive / negative (semi)definite
desigualdad de Jensen	Jensen's inequality
subgradiente	subgradient
subdiferencial	subdifferential
derivada direccional	directional derivative
Lipschitz-continua	Lipschitz continuous
suave (L -suave)	smooth (L -smooth)
transformación monótona creciente	increasing monotone transformation

Optimización y KKT (caps. 8–9)

Español	Inglés
función objetivo	objective function
conjunto factible	feasible set
punto factible	feasible point
restricción de igualdad / desigualdad	equality / inequality constraint
restricción activa (que satura, liga)	active (binding) constraint
restricción inactiva (holgada)	inactive (slack) constraint
cualificación de restricciones	constraint qualification (CQ)
condición de primer orden (CPO)	first-order condition (FOC)
condición de segundo orden	second-order condition (SOC)
punto estacionario	stationary point
punto crítico	critical point
mínimo local / global	local / global minimum
maximizador / minimizador	maximizer / minimizer
solución interior / de esquina	interior / corner solution
multiplicador de Lagrange	Lagrange multiplier
lagrangiano	Lagrangian
condiciones KKT	KKT conditions
holgura complementaria	complementary slackness
proyección (ortogonal)	(orthogonal) projection
desigualdad variacional	variational inequality
problema sin restricciones	unconstrained problem

Dualidad, envolvente y Fenchel (caps. 10–12)

Español	Inglés
problema primal / dual	primal / dual problem
función dual (lagrangiana)	(Lagrangian) dual function
dualidad débil / fuerte	weak / strong duality
brecha de dualidad	duality gap
condición de Slater	Slater's condition
punto silla	saddle point
precio sombra	shadow price
función valor	value function
teorema de la envolvente	envelope theorem
estática comparativa	comparative statics
función conjugada (de Fenchel)	(Fenchel) conjugate function
biconjugada	biconjugate
desigualdad de Fenchel–Young	Fenchel–Young inequality
envolvente convexa cerrada	closed convex envelope (hull)
perturbación	perturbation
relajación lagrangiana	Lagrangian relaxation

Programación lineal y algoritmos (caps. 13–16)

Español	Inglés
programa lineal	linear program (LP)
forma estándar	standard form
método símplex	simplex method
solución básica factible	basic feasible solution
degenerada	degenerate
análisis de sensibilidad	sensitivity analysis
rayo de no acotación	unbounded ray
máquina de vectores soporte	support vector machine (SVM)
margen (duro / blando)	(hard / soft) margin
pérdida bisagra	hinge loss
descenso de gradiente	gradient descent
tamaño (longitud) de paso	step size
búsqueda lineal	line search
tasa de convergencia	convergence rate
gradiente proyectado	projected gradient
operador proximal	proximal operator
método de penalización	penalty method
lagrangiano aumentado	augmented Lagrangian
método de multiplicadores	method of multipliers
condición de parada	stopping criterion

Términos económicos (para [9], [10])

Español	Inglés
conjunto presupuestario	budget set
función de utilidad	utility function
utilidad indirecta	indirect utility
función de gasto	expenditure function
función de costos	cost function
función de beneficios	profit function
conjunto de producción	production set
correspondencia de demanda	demand correspondence
equilibrio walrasiano	Walrasian equilibrium
óptimo de Pareto (eficiente)	Pareto optimal (efficient)
teoremas del bienestar	welfare theorems
núcleo (de la economía)	core
caja de Edgeworth	Edgeworth box
aversión al riesgo	risk aversion
utilidad esperada	expected utility
riesgo moral	moral hazard
selección adversa	adverse selection
señalización	signaling
diseño de mecanismos	mechanism design
compatibilidad de incentivos (CI)	incentive compatibility (IC)
restricción de participación	participation (IR) constraint
principio de revelación	revelation principle
subasta (de primer / segundo precio)	(first- / second-price) auction
equivalencia de ingresos	revenue equivalence
discriminación de precios	price discrimination
lema de Shephard / identidad de Roy	Shephard's lemma / Roy's identity

Resumen del capítulo

Cierre del cuaderno. Si de aquí solo quedaran cinco ideas: (1) todo el análisis convexo cuelga del teorema de separación; (2) un teorema citado sin sus hipótesis es un enunciado falso; (3) KKT es dos teoremas (necesidad con CQ, suficiencia con convexidad) y la holgura complementaria obliga a discutir casos; (4) la cuasiconcavidad, no la concavidad, es la propiedad ordinal de la teoría del consumidor, y se verifica con la Hessiana orlada; (5) multiplicadores, precios sombra e hiperplanos soporte son la misma cosa vista desde tres capítulos distintos, y esa identidad es el corazón de la microeconomía que viene. Suerte en el parcial, en los trabajos y en la exposición.

Bibliografía

- [1] Aragón, F., Goberna, M.A., López, M.A. & Rodríguez, M. *Nonlinear Optimization*. Springer, 2019.
- [2] Boyd, S. & Vandenberghe, L. *Convex Optimization*. Cambridge University Press, 2009. Disponible en <https://web.stanford.edu/~boyd/cvxbook/>.
- [3] Brinkhuis, J. *Convex Analysis for Optimization: A Unified Approach*. Springer, 2020.
- [4] Li, Li. *Selected Applications of Convex Optimization*. Springer, 2015.
- [5] Nocedal, J. & Wright, S.J. *Numerical Optimization*, 2.^a ed. Springer, 2006.
- [6] Ruszczyński, A. *Nonlinear Optimization*. Princeton University Press, 2006.
- [7] Snyman, J.A. & Wilke, D.N. *Practical Mathematical Optimization*, 2.^a ed. Springer, 2018.
- [8] Wright, S. & Recht, B. *Optimization for Data Analysis*. Cambridge University Press, 2022.
- [9] Mas-Colell, A., Whinston, M.D. & Green, J.R. *Microeconomic Theory*. Oxford University Press, 1995.
- [10] Jehle, G. & Reny, P. *Advanced Microeconomic Theory*, 3.^a ed. Prentice Hall, 2011.
- [11] Milgrom, P. & Segal, I. “Envelope Theorems for Arbitrary Choice Sets”. *Econometrica* 70(2), 2002, 583–601.